

Bản đọc tiếng Việt - đối chiếu với `access.tex`

PGA-UNet: kiến trúc Attention U-Net nhẹ, có định hướng bằng prompt, cho phân đoạn tổn thương xương X-quang tương tác

Bản dịch/tóm lược để tự kiểm tra nội dung - không phải bản nộp

Lưu ý: File này chỉ để đọc và đối chiếu ý với bản tiếng Anh thật (`access.tex`). Toàn bộ số liệu (Dice, IoU, HD95, CBL, số tham số...) giữ nguyên y hệt bản gốc; chỉ phần chữ được dịch. Theo quy ước của repo (xem `CLAUDE.md`), nhánh `main` chỉ được chứa nội dung tiếng Anh trong các file sẽ nộp/commit; file này nên ở dạng *chưa commit* (untracked), chỉ dùng cục bộ để đọc.

Tóm tắt (*Abstract*)

Phân đoạn tổn thương xương trên ảnh X-quang là bài toán khó vì tổn thương thường có kích thước nhỏ, tương phản thấp, và dễ lẫn vào cấu trúc giải phẫu xung quanh về mặt thị giác. Trong bối cảnh đó, thách thức chính thường nằm ở khâu định vị vùng nghi ngờ hơn là tinh chỉnh đường biên của tổn thương. Một hướng tiếp cận thực tế là thu hẹp vùng tìm kiếm trước khi thực hiện phân đoạn. Chúng tôi hiện thực hóa ý tưởng này theo một cách tiếp cận tương tác trực tiếp: bác sĩ cung cấp một hộp giới hạn thô để mô hình sử dụng như một tín hiệu định hướng không gian.

Chúng tôi đề xuất **PGA-UNet**, một mạng CNN nhẹ có định hướng bằng prompt, chuyển prompt hộp giới hạn thành bản đồ nhiệt Gaussian dạng cao nguyên, điều biến đặc trưng theo prompt thông qua **Prompt Spatial Gate (PSG)** tại bộ mã hóa, và duy trì ảnh hưởng của prompt ở bộ giải mã nhờ **Conditional Attention Decoder (CAD)**. Mục tiêu không chỉ là sử dụng prompt để xác định vùng cần phân đoạn, mà còn là duy trì đặc trưng liên quan đến tổn thương nhỏ xuyên suốt mạng.

Attention U-Net được sử dụng làm mô hình cơ sở cho phân đoạn tự động không sử dụng prompt. Ở độ phân giải 512×512 và prompt bao phủ, PGA-UNet đạt kết quả Dice **0.8788** trên tập dữ liệu BTXRD và **0.8286** trên FracAtlas, cao hơn nhiều so với **0.5160** và **0.3075** của Attention U-Net. Ở cùng điều kiện có sử dụng prompt và độ phân giải 256×256 , PGA-UNet vượt SAM-Med2D đã tinh chỉnh dưới cả prompt bao phủ lẫn lệch tâm, trên cả hai bộ dữ liệu, dù PGA-UNet chỉ được huấn luyện với dạng bao phủ trong khi SAM-Med2D đã tinh chỉnh trên cả hai dạng. Khoảng cách lớn nhất xuất hiện ở 50 tổn thương nhỏ nhất của BTXRD và FracAtlas, chỉ số Dice của SAM-Med2D giảm xuống **0.1903** trong khi PGA-UNet đạt **0.7650**; đồng thời độ định vị theo tâm (CBL) cũng đạt kết quả cao hơn trên PGA-UNet (**0.9261** so với **0.4489**), cho thấy khả năng định vị tổn thương tốt hơn.

Phân tích đóng góp thành phần cho thấy PSG và CAD mang lại hiệu quả cao nhất khi kết hợp, đồng thời lợi ích của Gaussian prompt so với binary box chỉ trở nên rõ rệt khi sử dụng kiến trúc đầy đủ. Với 2.95 triệu tham số, PGA-UNet giảm lần lượt khoảng **92×** số lượng tham số, **11.9×** FLOPs và **6.0×** độ trễ suy luận GPU so với SAM-Med2D ở cùng cấu hình 256×256 được kiểm thử. Các kết quả này cho thấy, với tổn thương rất nhỏ, prompt hiệu quả nhất khi được xem như một prior không gian dày đặc, luôn được duy trì từ giai đoạn mã hóa đến giải mã cuối cùng.

Từ khóa: ảnh X-quang xương, phân đoạn tương tác, phân đoạn ảnh y tế, học có định hướng bằng prompt, Attention U-Net.

Mục I. Giới thiệu (Introduction)

Ảnh X-quang xương được dùng rộng rãi trong sàng lọc, hỗ trợ chẩn đoán, và theo dõi nhờ ưu điểm về tốc độ, chi phí và khả năng tiếp cận. Tuy nhiên, phân đoạn tổn thương trên ảnh X-quang vẫn gặp nhiều khó khăn khi tổn thương có kích thước rất nhỏ, độ tương phản mờ nhạt, hoặc bị che khuất một phần bởi cấu trúc giải phẫu xung quanh. Trong các trường hợp này, một trong những thách thức chính nằm ở khâu định vị: trước khi có thể tinh chỉnh đường biên, mô hình cần phải xác định được vùng nghi ngờ trong toàn bộ ảnh.

Đây là lý do vì sao phân đoạn tổn thương nhỏ hiếm khi chỉ đơn thuần là bài toán xác định đường biên. Khi tổn thương chỉ chiếm một phần rất nhỏ trong toàn bộ pixel, việc tìm kiếm trên toàn ảnh không những kém hiệu quả mà còn thiếu chính xác. Một hướng tiếp cận tự nhiên là thu hẹp không gian tìm kiếm trước, rồi mới thực hiện phân đoạn vùng mục tiêu. Các phương pháp tự động hoàn toàn cố gắng học quá trình này một cách nội tại. Dù U-Net và Attention U-Net là những mô hình đại diện tiêu biểu cho hướng tiếp cận này, chúng vẫn bắt buộc mạng phải tự định vị và phân đoạn tổn thương hoàn toàn từ đầu mà không có sự trợ giúp nào.

Một hướng khác là khai thác chỉ dẫn về vùng quan tâm từ bên ngoài. Trong thực hành lâm sàng, bác sĩ có thể dễ dàng vẽ một hộp giới hạn thô quanh vùng nghi ngờ, điều mà các mô hình tự động hoàn toàn khó có thể phát hiện một cách đáng tin cậy đối với các tổn thương rất nhỏ. Theo nghĩa đó, prompt hộp giới hạn không chỉ là một tiện ích tương tác, mà còn là một phương thức thực tế nhằm tích hợp tri thức không gian vào quy trình xử lý trước khi bắt đầu phân đoạn chi tiết. Các phương pháp phân đoạn tương tác dựa trên prompt đã được phát triển từ ý tưởng này, từ các điểm nhấp chuột và nét vẽ cho đến các mô hình nền tảng gần đây như SAM và SAM-Med2D.

Tuy nhiên, với bài toán ở đây, một vấn đề vẫn chưa được giải quyết. Một khi prompt đã xác định được vùng quan tâm, liệu prompt chỉ nên đóng vai trò một ràng buộc vị trí để sinh mask, hay cần tiếp tục định hình quá trình trích xuất đặc trưng để bảo toàn các tín hiệu tổn thương mờ nhạt trong quá trình giảm mẫu? Sự khác biệt này đặc biệt quan trọng với tổn thương rất nhỏ, nơi mà một sai lệch không gian nhỏ có thể ảnh hưởng đáng kể đến kết quả phân đoạn.

Chúng tôi giải quyết câu hỏi đó bằng PGA-UNet, một CNN nhẹ có định hướng bằng prompt, trong đó box prompt được xem như một prior không gian có cấu trúc thay vì được dùng như một kênh đầu vào phụ. Prompt được mã hóa thành bản đồ nhiệt Gaussian dạng cao nguyên, sau đó được điều biến vào đặc trưng tại bộ mã hóa thông qua Prompt Spatial Gate (PSG), và tái sử dụng ở bộ giải mã nhờ vào Conditional Attention Decoder (CAD). Thiết kế này nhằm duy trì các đặc trưng tổn thương được định hướng bởi prompt xuyên suốt mạng, thay vì chỉ giới hạn quá trình phân đoạn trong một vùng hộp đã xác định.

Cách tiếp cận này cũng định hình phương pháp đánh giá thực nghiệm. Vì Attention U-Net không nhận gợi ý không gian nào từ bác sĩ, nên mô hình chỉ đóng vai trò cho thấy mức độ phức tạp của bài toán khi hoàn toàn tự động. Trong khi đó, SAM-Med2D được lựa chọn làm đối chứng trực tiếp vì sử dụng cùng điều kiện đầu vào là prompt hộp giới hạn. Vấn đề trọng tâm ở đây không phải là liệu prompt có hữu ích hay không, mà là liệu một kiến trúc nhẹ có thể khai thác prompt thô từ bác sĩ hiệu quả hơn bằng cách bảo toàn các tín hiệu tổn thương yếu, thay vì chỉ xem prompt như một ràng buộc không gian đơn thuần.

Đóng góp chính (Main contributions)

- Đề xuất PGA-UNet, một kiến trúc nhẹ có tiếp nhận định hướng bằng prompt cho phân đoạn tổn thương xương trên ảnh X-quang.

- Thiết kế cơ chế điều kiện hóa prompt hiệu quả, kết hợp prompt Gaussian dạng cao nguyên, Cổng không gian (PSG) tại bộ mã hóa, và Cơ chế chú ý có điều kiện (CAD).
- Xây dựng khung huấn luyện ngoại tuyến và suy luận tương tác trực tuyến, có định nghĩa bằng công thức toán học rõ ràng cho việc mã hóa prompt, cổng hóa encoder, và điều kiện hóa decoder.
- Đánh giá thực nghiệm trên hai tập dữ liệu là BTXRD và FracAtlas dưới các điều kiện prompt bao phủ và lệch tâm; thực hiện so sánh với Attention U-Net và SAM-Med2D bằng các chỉ số Dice, độ đo định vị theo tâm (CBL), và HD95, Monte Carlo cross-validation, và hiệu năng tính toán.
- Báo cáo kết quả phân tích đóng góp thành phần, đánh giá hiệu năng tính toán, và phân tích tổn thương nhỏ để làm rõ ưu thế của thiết kế điều kiện hóa prompt.

Mục II. Công trình liên quan (*Related Work*)

Phân đoạn tổn thương nhỏ trong ảnh y tế từ lâu đã bị ràng buộc bởi một thực tế thực hành đơn giản: trước khi mô hình phân đoạn tốt một mục tiêu rất nhỏ, nó phải thu hẹp được vùng cần nhìn vào trước đã. Trong hướng tự động hoàn toàn, việc thắt chặt không gian tìm kiếm này được học ngầm bên trong mạng. U-Net đặt nền móng cho kiến trúc encoder-decoder đa tỉ lệ kinh điển trong phân đoạn y sinh, còn Attention U-Net sau đó bổ sung cổng attention trên skip connection để phía decoder có thể lọc bỏ phản hồi không gian không liên quan một cách chọn lọc hơn. Các mô hình này cải thiện chất lượng phân đoạn tự động, nhưng vẫn giả định rằng bản thân mạng phải tự khu trú và vẽ mask chỉ từ ảnh đầu vào.

Phân đoạn y tế tương tác phát triển song song, xuất phát từ quan sát rằng chỉ một phần hướng dẫn từ người dùng cũng có thể đơn giản hóa đáng kể bài toán. Các phương pháp sớm dùng click, scribble, và geodesic cue; các nghiên cứu sau đưa thêm bounding box như một dạng prompt thô, thực tế hơn. Về bản chất, các phương pháp này chuyển một phần gánh nặng khu trú từ mô hình sang người dùng. Với tổn thương X-quang rất nhỏ, sự chuyển giao này đặc biệt có ý nghĩa: bác sĩ có thể chỉ ra một vùng nghi ngờ một cách thô ngay cả khi một hệ thống tự động hoàn toàn sẽ gặp khó khăn để tìm ra nó một cách đáng tin cậy trong toàn ảnh.

Bước phát triển lớn tiếp theo là các mô hình nền tảng nhận prompt như SAM, SAM-Med2D, và MedSAM, tổng quát hóa phân đoạn theo prompt trên nhiều miền y tế. Các mô hình này linh hoạt, nhưng cách dùng prompt của chúng khác biệt về mặt kiến trúc so với các CNN nhẹ chuyên biệt cho một tác vụ, và chi phí tính toán cao hơn nhiều. Quan trọng hơn đối với bài toán ở đây, chúng vẫn để ngỏ một câu hỏi thiết kế trở nên cấp thiết với tổn thương X-quang rất nhỏ: một khi prompt đã khu trú được vùng gần đúng, prompt đó chỉ nên dùng để chỉ ra nơi tạo mask, hay còn cần tiếp tục định hình quá trình trích xuất và giải mã đặc trưng để bằng chứng tổn thương yếu không bị mất đi?

Bài báo này xuất phát từ đúng khoảng trống đó. Trên ảnh X-quang xương thang xám, vấn đề không chỉ là biết *tổn thương nằm khoảng đâu*, mà còn là bảo toàn bằng chứng tổn thương yếu trong khi vẫn lọc bỏ nhiễu nền xung quanh, sau khi không gian tìm kiếm đã được thu hẹp. Một CNN nhẹ có định hướng bằng prompt vì vậy có thể hưởng lợi từ việc giữ thông tin prompt luôn hoạt động, từ giai đoạn mã hóa sớm đến giải mã muộn, thay vì chỉ dùng prompt như một gợi ý ban đầu hoặc một ràng buộc vị trí.

Table 1: Bảng 1 - Công trình tiêu biểu trước đây và khoảng trống còn lại mà bài báo này giải quyết.

Công trình	Nguyên lý	Phương pháp	Bằng chứng hiệu năng	Ưu điểm	Nhược điểm
U-Net	Encoder-decoder tích chập đầy đủ	Mạng phân đoạn đa tỉ lệ, có skip connection	Benchmark y sinh rộng; báo cáo overlap theo Dice	Đơn giản, hiệu quả, baseline kinh điển mạnh	Không có định hướng prompt; toàn bộ định vị phải tự động
Attention U-Net	Lọc skip-feature bằng cổng attention	U-Net có skip connection gắn cổng	Tác vụ phân đoạn y tế, đo bằng Dice và IoU	Baseline tự động mạnh hơn U-Net thường	Attention vẫn được học mà không có điều kiện hóa prompt tương minh
DeepIGeoS & các pp tương tác liên quan	Gợi ý người dùng thu hẹp không gian tìm kiếm	Phân đoạn dựa trên geodesic / nhận biết tương tác	Phân đoạn y tế tương tác theo đầu vào người dùng	Phản ánh tương tác lâm sàng tốt hơn	Cơ chế tương tác có thể đặc thù theo tác vụ hoặc tổn kém để duy trì
SAM-Med2D / MedSAM	Phân đoạn nền tảng nhận prompt	Mô hình tiền huấn luyện lớn, giải mã mật nạ theo prompt	Đánh giá đa bộ dữ liệu y tế, đo theo prompt	Linh hoạt, áp dụng rộng	Nặng; ảnh hưởng prompt không thiết kế như prior nhẹ, chuyên biệt X-quang, xuyên suốt end-to-end
Bài báo này	Prompt như prior không gian dày đặc, xuyên suốt mạng	Prompt cao nguyên Gaussian + PSG + CAD trong CNN nhẹ	BTXRD & FracAtlas; Dice, IoU, HD95, CBL, hiệu năng, tổn thương nhỏ	Nhẹ, nhận biết prompt từ encoder đến decoder, bền vững trước nhiễu loạn prompt	Vẫn cần mật nạ giám sát và tiền xử lý độ phân giải cố định

Mục III. Phương pháp (Method)

3.1 Khung offline & online (Offline and Online Framework)

Hệ thống có hai giai đoạn. Ở giai đoạn **offline**, mô hình được huấn luyện trên ảnh X-quang đi kèm đa giác tổn thương. Mỗi đa giác được chuyển thành một prompt huấn luyện bằng cách sinh một hộp giới hạn mô phỏng, rồi biến hộp đó thành bản đồ nhiệt cao nguyên làm mượt Gaussian. Mạng học ánh xạ cặp (ảnh, prompt) sang mật nạ tổn thương nhị phân. Ở giai đoạn **online**, người dùng vẽ một hộp giới hạn thô quanh vùng nghi ngờ trên ảnh mới; cùng quy trình dựng prompt được áp dụng, và mô hình đã huấn luyện dự đoán mật nạ cuối cùng.

Đóng góp khoa học của khung này là: prompt không được coi là đầu vào phụ tùy chọn chỉ dùng ở lớp đầu tiên. Thay vào đó, prompt được mã hóa thành một prior không gian dày đặc và được kích hoạt ở cả encoder lẫn decoder. Hệ quả thực tế là độ bền vững được cải thiện khi prompt thô, hơi lệch tâm, hoặc áp dụng cho tổn thương rất nhỏ.

3.2 Bài toán (Problem Setting)

Cho ảnh X-quang xám $\mathbf{I} \in \mathbb{R}^{H \times W}$ và hộp giới hạn $\mathbf{B}$ do người dùng cung cấp, mục tiêu là dự đoán mật nạ tổn thương nhị phân $\mathbf{M}$. Gọi $\mathbf{H}(\mathbf{B})$ là bản đồ nhiệt prompt suy ra từ

hộp. PGA-UNet dự đoán

$$\hat{\mathbf{M}} = \mathbf{1} [f_{\text{PGA}}(\mathbf{I}, \mathbf{H}(\mathbf{B}); \theta) \geq 0.5]. \quad (1)$$

3.3 Biểu diễn prompt (*Prompt Representation*)

Prompt đầu vào không được mã hóa như một hình chữ nhật nhị phân cứng. Thay vào đó, phần bên trong hộp được rasterize thành bản đồ “cao nguyên” ở độ phân giải ảnh gốc, rồi biên được làm mềm bằng kernel Gaussian 31×31 cố định, trước khi bản đồ nhiệt được resize + pad xuống độ phân giải vuông mục tiêu cùng với ảnh. Kernel không đổi theo độ phân giải mục tiêu (256×256 hay 512×512): áp dụng kernel một lần ở độ phân giải gốc, trước khi downsample, giữ cho độ mờ hiệu dụng nhất quán tương đối so với khung ảnh vuông cuối cùng mà mạng nhìn thấy. Cao nguyên chỉ phủ đúng vùng hộp (đã mở rộng nếu có), **không có biên tối thiểu nào thêm vào**; việc bao phủ vùng quan tâm do chính bước mở rộng hộp (mô tả bên dưới) đảm bảo, không phải do một bước biên riêng.

Khi đánh giá, prompt được kiểm thử ở hai chế độ. **Prompt bao phủ (covering)** mở rộng hộp giới hạn tổn thương thêm 15%–45% chiều rộng/cao tổn thương. **Prompt lệch tâm (off-center)** áp dụng cùng độ mở rộng đó rồi dịch hộp tối đa 30% chiều rộng/cao trong khi vẫn phải bao phủ tổn thương. Mỗi bộ dữ liệu và độ phân giải huấn luyện một mô hình riêng; điều kiện prompt chỉ thay đổi ở lúc đánh giá, trừ khi ablation nói khác.

Gọi (x_1, y_1, x_2, y_2) là hộp tổn thương bo sát, $w = x_2 - x_1$ và $h = y_2 - y_1$. Hộp bao phủ mô phỏng mở rộng mỗi cạnh theo một tỉ lệ ngẫu nhiên trong $[0.15, 0.45]$ của w hoặc h khi huấn luyện, và theo tỉ lệ cố định 0.30 khi đánh giá. Hộp lệch tâm áp dụng cùng độ mở rộng đó rồi cộng thêm một độ dịch bị chặn trong $0.30w$ theo chiều ngang và $0.30h$ theo chiều dọc, trong khi vẫn giữ bao phủ tổn thương. Việc mô phỏng này không thay thế được prompt do chính bác sĩ X-quang vẽ, nhưng cho một cách có kiểm soát để kiểm tra độ nhạy của mô hình trước các biến thể hộp hợp lý.

Về thuật toán, việc dựng prompt gồm 3 bước: (1) suy ra hộp tổn thương từ đa giác gán nhãn hoặc từ input người dùng và mở rộng theo tỉ lệ đã mô tả, (2) rasterize vùng đã mở rộng thành mặt nạ cao nguyên ở độ phân giải ảnh gốc, (3) làm mượt biên cao nguyên bằng kernel Gaussian cố định trước khi resize xuống độ phân giải mục tiêu. Trình tự này tránh sự phụ thuộc vào biên cứng của một hộp nhị phân, trong khi vẫn giữ được một prior không gian rõ ràng.

3.4 Prompt Spatial Gate (PSG)

Gọi $\mathbf{x}^l$ là bản đồ đặc trưng encoder ở tầng l . PSG điều biến nó bằng bản đồ attention suy ra từ prompt $\mathbf{A}_{\text{PSG}}^l$:

$$\tilde{\mathbf{x}}^l = \mathbf{x}^l \odot \left(1 + \alpha_{\text{PSG}}^l \mathbf{A}_{\text{PSG}}^l\right), \quad (2)$$

trong đó $\odot$ là nhân theo từng phần tử, α_{PSG}^l là tham số học được (khởi tạo 0.1, giới hạn trong $[0, 1]$). Dạng residual này giữ nguyên luồng đặc trưng gốc trong khi vẫn nhấn mạnh vùng liên quan đến prompt.

3.5 Conditional Attention Decoder (CAD)

CAD mở rộng attention của decoder bằng cách điều kiện hóa cổng skip theo đặc trưng đã mã hóa prompt. Gọi $\mathbf{g}^l$ là đặc trưng cổng decoder, $\mathbf{p}_{\text{enc}}^l$ là mã hóa prompt cùng tỉ lệ. Cổng đã điều kiện hóa:

$$\mathbf{g}'^l = \mathbf{g}^l + c^l \alpha_{\text{CAD}}^l w_l \mathbf{p}_{\text{enc}}^l, \quad (3)$$

với c^l là hệ số “độ tin cậy prompt”, α_{CAD}^l học được, w_l là hệ số độ sâu cố định. Thiết kế này giúp decoder vẫn bám theo prompt ngay cả khi hộp không được căn giữa hoàn hảo.

Bộ mã hóa prompt trong CAD dùng hai tích chập 3×3 với instance normalization và ReLU. Hệ số tin cậy c^l được tạo bằng global average pooling, sau đó tích chập 1×1 và sigmoid. Hệ số độ sâu decoder cố định $\{1.0, 0.7, 0.4, 0.2\}$ từ sâu đến nông. Với feature scale 4, độ rộng kênh là $\{16, 32, 64, 128, 256\}$ từ tầng encoder nông nhất đến bottleneck. Hệ số trộn CAD được tham số hóa qua sigmoid, khởi tạo gần 0.3.

Tóm lại, phương pháp gồm 4 bước: (1) tiền xử lý ảnh và prompt về cùng một độ phân giải vuông, (2) mã hóa prior không gian liên quan đến prompt bằng PSG ở encoder, (3) lan truyền ngữ cảnh có điều kiện theo prompt qua CAD ở decoder, (4) dự đoán mặt nạ tổn thương nhị phân cuối cùng. Ý nghĩa khoa học: thông tin prompt vừa được làm mềm về không gian, vừa được tái sử dụng liên tục, chứ không chỉ tiêm vào một lần rồi mất dần.

[Hình 1 - *images/architecture/architecture_pga_unet.png*]: Tổng quan kiến trúc PGA-UNet. Thông tin prompt suy ra từ hộp giới hạn được tiêm vào đặc trưng encoder qua PSG, và tái sử dụng ở skip-attention của decoder qua CAD.

Mục IV. Thiết lập thực nghiệm (Experimental Setup)

4.1 Bộ dữ liệu (Datasets)

Đánh giá trên hai bộ dữ liệu X-quang xương công khai. **BTXRD** là bộ dữ liệu u xương chính, có nhãn đa góc cho phân loại, định vị, phân đoạn. Tập chia BTXRD: 1.493/187/187 ảnh, 1.848/238/232 đa góc tổn thương cho train/validation/test. **FracAtlas** là bộ dữ liệu gãy xương có nhãn phân loại, định vị, phân đoạn. Sau làm sạch và chuẩn hóa đa góc, tập chia FracAtlas: 573/72/72 ảnh, 730/95/92 đa góc tổn thương cho train/validation/test.

Việc chia tách được thực hiện ở mức ảnh, mọi đa góc của cùng một ảnh nằm trong cùng một tập. Metadata công khai chưa đủ để xác minh việc tách biệt nghiêm ngặt theo từng bệnh nhân. Mỗi đa góc được coi là một mẫu tổn thương có thể prompt riêng khi huấn luyện. Khi đánh giá ở mức ảnh, nếu một ảnh có nhiều tổn thương, mô hình chạy riêng cho từng hộp tổn thương, rồi hợp bản đồ xác suất bằng phép max theo từng pixel trước khi ngưỡng hóa ở 0.5. Mặt nạ ground-truth được hợp bằng phép union trên cùng một ảnh.

Ảnh đầu vào được resize đẳng hướng (giữ tỉ lệ khung hình) và đệm (pad) về hình vuông 256×256 hoặc 512×512 . Ảnh, mặt nạ, và bản đồ prompt đều qua cùng phép tiền xử lý hình học này.

4.2 Chi tiết huấn luyện (Training Details)

Tất cả mô hình CNN cài đặt bằng PyTorch, huấn luyện trên GPU NVIDIA Tesla T4 16GB. PGA-UNet và Attention U-Net được huấn luyện riêng cho từng bộ dữ liệu và từng độ phân giải. Nói cách khác, bài báo nghiên cứu *một* họ kiến trúc chung, được cài đặt thành các mô hình riêng biệt với bộ tham số riêng biệt cho BTXRD và FracAtlas, chứ không phải một mô hình duy nhất huấn luyện chung trên cả hai bộ dữ liệu. Optimizer AdamW, learning rate 10^{-4} , weight decay 10^{-4} . Hàm loss là tổng của binary cross-entropy và Dice loss. Batch size 4, tối đa 100 epoch, early stopping với patience 15. Tiêu chí chọn mô hình chính là Dice trên tập validation dưới điều kiện prompt bao phủ.

Data augmentation lúc huấn luyện gồm lật ngang và xoay ngẫu nhiên trong $\pm 15^\circ$. Cài đặt còn áp dụng “prompt dropout” hoặc nhiều prompt cho một phần các bước

huấn luyện, để giảm phụ thuộc quá mức vào một prompt lý tưởng. Bản thân PGA-UNet chỉ được huấn luyện dưới điều kiện prompt bao phủ (zoom-out); điều kiện lệch tâm chỉ xuất hiện lúc đánh giá, nên kết quả đánh giá lệch tâm đo khả năng tổng quát hóa sang một nhiễu loạn prompt mà mạng chưa từng thấy khi huấn luyện. Vì vậy, bài báo hiện tại nên được đọc như một nghiên cứu có kiểm soát đầu tiên dưới prompt hộp mô phỏng, chưa phải là đánh giá dưới hộp do chính bác sĩ X-quang vẽ trong thực tế hoàn toàn tự nhiên.

Với so sánh SAM-Med2D đã fine-tune: bộ mã hóa ảnh tiền huấn luyện được đóng băng, trừ các lớp Adapter nhẹ; bộ mã hóa prompt và bộ giải mã mặt nạ được cập nhật đầy đủ trên từng bộ dữ liệu, cùng giao thức chia tách. Thay vì kiểu nhiễu loạn hộp lúc huấn luyện của tác giả gốc (hộp sát tổn thương + jitter vài pixel + tinh chỉnh lặp theo điểm), SAM-Med2D ở đây được fine-tune *chỉ bằng hộp*: mỗi hộp huấn luyện được chọn độc lập theo tỉ lệ 50/50 từ cùng giao thức prompt bao phủ dùng cho PGA-UNet, hoặc mở rộng ngẫu nhiên 15%–45% mỗi cạnh, hoặc cùng độ mở rộng đó rồi dịch lệch tâm tối đa 30%. Khác với PGA-UNet, SAM-Med2D vì vậy được huấn luyện trên *cả hai* điều kiện bao phủ và lệch tâm, nên hiệu năng lệch tâm của SAM-Med2D phản ánh một điều kiện “trong phân phối” (in-distribution), còn với PGA-UNet đó là tổng quát hóa “ngoài phân phối” (out-of-distribution).

Sự bất đối xứng này là **cốt ý**: mỗi baseline được huấn luyện theo đúng cách nó thường được huấn luyện (hoặc, với SAM-Med2D, theo giao thức khớp với phân phối prompt bao phủ của PGA-UNet), để tránh nhầm lẫn giữa khác biệt kiến trúc với khác biệt phân phối train/test không liên quan; nhưng cả hai mô hình đều được *đánh giá* theo cùng một giao thức test (bao phủ + lệch tâm) để so sánh công bằng.

Validation lúc fine-tune SAM-Med2D và tập test cuối cùng dùng cùng giao thức prompt bao phủ như PGA-UNet, batch size 4, tối đa 100 epoch, early stopping patience 30, learning rate 10^{-5} . Ngoài ra còn có thực nghiệm ổn định bằng Monte Carlo cross-validation, tức là chia tách ngẫu nhiên lặp lại ở mức ảnh, không phải k-fold không chồng lấn nghiêm ngặt.

Hai chi tiết đánh giá quan trọng: (1) bản thân việc dựng prompt *không* phụ thuộc độ phân giải: bản đồ cao nguyên được dựng và làm mượt bằng kernel Gaussian 31×31 cố định ở độ phân giải ảnh gốc, sau đó mới resize + pad xuống 256×256 hoặc 512×512 cùng ảnh, nên cùng một độ mờ tuyệt đối bị nén khác nhau ở 2 độ phân giải mục tiêu chứ không phải được tham số hóa riêng cho từng độ phân giải; (2) các thực nghiệm Monte Carlo cross-validation là bằng chứng ổn định bổ sung, không thay thế cho tập chia train/validation/test cố định dùng trong các bảng chính.

4.3 Baseline & độ đo (*Baselines and Metrics*)

PGA-UNet được so với **Attention U-Net** (baseline tự động chính) và **SAM-Med2D** (baseline có prompt chính). Attention U-Net huấn luyện không có prompt, dùng để đặc trưng hóa bài toán khó đến mức nào khi việc khu trú phải được giải quyết hoàn toàn tự động. SAM-Med2D được đánh giá ở 256×256 , dạng đã fine-tune, cùng tập chia và cùng hộp prompt như PGA-UNet, khiến nó trở thành so sánh khớp-điều-kiện-prompt chính.

Các độ đo báo cáo: Dice, IoU, precision, recall, HD95, và **CBL** (center-based localization: định vị theo tâm). Với tâm mặt nạ dự đoán (x_p, y_p) , tâm ground-truth (x_g, y_g) , và đường chéo D_{GT} của hộp ground-truth:

$$\text{CBL} = \max \left(0, 1 - \frac{\sqrt{(x_p - x_g)^2 + (y_p - y_g)^2}}{D_{GT}} \right). \quad (4)$$

HD95 tính từ khoảng cách biên hai chiều. Nếu cả hai mặt nạ đều rỗng, HD95 = 0. Nếu chỉ một mặt nạ rỗng, HD95 = độ dài cạnh ảnh (256 hoặc 512 pixel). Không loại bỏ mẫu nào.

4.4 Phạm vi phân tích (Scope of Analysis)

Bài báo tập trung vào bản thân phân đoạn có định hướng prompt, không đưa vào pipeline sàng lọc phụ trợ đã khảo sát riêng trong khóa luận gốc. Để giữ bài báo gọn, chỉ giữ lại các phân tích nhóm phụ hỗ trợ trực tiếp nhất cho luận điểm chính: vai trò của việc khu trú theo prompt, độ bền vững khi prompt không hoàn hảo, và hiệu quả trên tổn thương rất nhỏ.

Mục V. Kết quả (Results)

5.1 So sánh chính giữa các bộ dữ liệu & độ phân giải

Nhóm thực nghiệm đầu tiên trả lời câu hỏi cơ bản nhất: PGA-UNet có còn hiệu quả trên cả hai bộ dữ liệu, cả hai độ phân giải đầu vào được kiểm thử, cả hai kịch bản prompt không? Các thực nghiệm này chủ yếu kiểm chứng đóng góp chính ở mức hệ thống: việc xử lý có điều kiện theo prompt ở cả encoder lẫn decoder vẫn hữu ích sau khi không gian tìm kiếm đã được thắt chặt bởi một box prompt thô. PGA-UNet hoạt động tốt trên cả BTXRD và FracAtlas theo đúng quy trình dự kiến, với gợi ý hộp thô. Xuyên suốt các thực nghiệm chính, mô hình vẫn cạnh tranh ở cả 256×256 lẫn 512×512 , dưới cả hai điều kiện prompt bao phủ và lệch tâm. Xu hướng nhất quán trên các bộ dữ liệu, độ phân giải, và kịch bản prompt là: thông tin prompt tiếp tục có ích dù BTXRD và FracAtlas khác biệt đáng kể về đặc điểm tổn thương và được huấn luyện thành các mô hình riêng biệt chứ không phải qua một mô hình chung huấn luyện trên cả hai bộ dữ liệu.

5.2 Ảnh hưởng của độ phân giải đầu vào

Thực nghiệm này cô lập đóng góp của độ phân giải ảnh trong cùng một kiến trúc và giao thức prompt, ủng hộ luận điểm rằng phương pháp đề xuất đặc biệt hữu ích khi bằng chứng tổn thương nhỏ vốn sẽ bị suy yếu sau khi không gian tìm kiếm đã thu hẹp nhưng bản thân tín hiệu tổn thương vẫn còn mong manh. PGA-UNet được huấn luyện độc lập ở 256×256 và 512×512 trên từng bộ dữ liệu. Độ phân giải cao hơn cải thiện Dice nhất quán ở cả hai điều kiện prompt, mức tăng ở BTXRD nhỉnh hơn FracAtlas một chút, phù hợp với đặc điểm dữ liệu: BTXRD có nhiều tổn thương nhỏ/bất thường mà bằng chứng cục bộ suy giảm rõ rệt sau khi downsample mạnh, còn FracAtlas thường có cấu trúc gãy dài nhưng đơn giản hơn về mặt hình ảnh.

Table 2: Bảng 2 - Dice của PGA-UNet dưới prompt bao phủ và lệch tâm ở hai độ phân giải.

Bộ dữ liệu	Độ phân giải	Bao phủ	Lệch tâm
BTXRD	256×256	0.8449	0.8111
BTXRD	512×512	0.8788	0.8496
FracAtlas	256×256	0.7974	0.7619
FracAtlas	512×512	0.8286	0.7925

Không nên hiểu đây thuần túy là hiệu ứng “ảnh lớn hơn thì tốt hơn”, vì bản đồ prompt được dựng một lần ở độ phân giải ảnh gốc với kernel Gaussian cố định, rồi mới downsample cùng ảnh, nên cùng một độ mờ tuyệt đối bị nén mạnh hơn vào khung 256×256 so với khung 512×512 . Dù vậy xu hướng chính vẫn có ý nghĩa: phân đoạn tổn thương nhỏ trên ảnh X-quang có lợi khi giữ được nhiều chi tiết không gian hơn, đặc biệt khi tổn thương chỉ chiếm một phần rất nhỏ của ảnh.

5.3 Monte Carlo Cross-Validation

Thực nghiệm này kiểm tra xem kết quả chính có ổn định không khi chia lại tập ảnh nhiều lần trên dữ liệu hạn chế; đây là bằng chứng bền vững ở mức *chia tách dữ liệu*, khác với bền vững ở mức *nhiều loạn prompt*. Thực nghiệm bổ sung dùng Monte Carlo cross-validation, tức 4 lần chia ngẫu nhiên lặp lại ở mức ảnh của cấu hình PGA-UNet 512×512 , đánh giá riêng theo prompt bao phủ và lệch tâm. Các kết quả này không nhằm thay thế các bảng chính với tập chia cố định, mà cung cấp bằng chứng bổ sung rằng lợi ích từ prompt không phụ thuộc vào một cách chia dữ liệu thuận lợi duy nhất.

Table 3: Bảng 3 - Monte Carlo cross-validation cho PGA-UNet ở 512×512 (4 lần chia ngẫu nhiên lặp lại, trung bình $\pm$ độ lệch chuẩn).

Bộ dữ liệu	Prompt	Dice	CBL	HD95
BTXRD	Bao phủ	0.8715 ± 0.0083	0.9600 ± 0.0028	8.09 ± 0.67
	Lệch tâm	0.8357 ± 0.0120	0.9390 ± 0.0062	10.45 ± 0.65
FracAtlas	Bao phủ	0.8281 ± 0.0052	0.9597 ± 0.0039	6.93 ± 0.08
	Lệch tâm	0.7862 ± 0.0114	0.9297 ± 0.0054	8.75 ± 0.48

Độ lệch chuẩn qua 4 lần chia luôn dưới 0.012 Dice; thứ tự bao phủ $>$ lệch tâm giống bảng chính (Bảng 2) được giữ nguyên ở mọi lần chia, cho thấy xu hướng độ phân giải/prompt không phải ngẫu nhiên do một cách chia thuận lợi.

[Hình 2 - *images/results/prompt_robustness_examples.png*]: Hành vi định tính khi prompt bị nhiễu loạn. PGA-UNet ổn định hơn khi prompt bị dịch khỏi hộp bao phủ lý tưởng, dù các tổn thương gãy mảnh/mỏng vẫn khó hơn tổn thương lớn, gọn.

5.4 So sánh với baseline tự động (Attention U-Net)

Attention U-Net không nhận bounding box từ bác sĩ, nên đây không phải phép so sánh công bằng giữa hai phương pháp cùng dùng prompt. Mục đích của so sánh này là đo xem bài toán phân đoạn này khó đến mức nào, trên toàn bộ tập test, khi mạng phải tự khu trú hoàn toàn, tức đúng bước mà một prompt thô từ bác sĩ được thiết kế để loại bỏ. Bảng 4 so sánh PGA-UNet với Attention U-Net ở 512×512 trong điều kiện thông tin không đối xứng này.

Table 4: Bảng 4 - So sánh với baseline tự động ở 512×512 , dưới prompt bao phủ.

Bộ dữ liệu	Mô hình	Dice	CBL	HD95
BTXRD	Attention U-Net	0.5160	0.5995	129.67
	PGA-UNet	0.8788	0.9619	9.08
FracAtlas	Attention U-Net	0.3075	0.4658	110.83
	PGA-UNet	0.8286	0.9615	6.21

Trên cả BTXRD và FracAtlas, Dice thấp cùng HD95 rất cao của Attention U-Net cho thấy khu trú, chứ không phải tinh chỉnh biên, mới là nút thắt chính khi thiếu prompt; CBL cũng thấp (0.4658–0.5995), xác nhận vùng dự đoán thường không hề nằm đúng tâm tổn thương. Khoảng cách với PGA-UNet vì vậy là bằng chứng cho thấy tri thức khu trú từ bác sĩ là thiết yếu với tổn thương rất nhỏ, chứ không phải minh chứng rằng kiến trúc PGA-UNet vốn dĩ vượt trội hơn Attention U-Net.

5.5 Nhóm Top-Dice / Bottom-Dice của Attention U-Net

Phân tích nhóm phụ này mở rộng so sánh baseline tự động. Với mỗi bộ dữ liệu, chọn 50 ảnh test có Dice Attention U-Net cao nhất và 50 ảnh có Dice thấp nhất, rồi đánh giá lại PGA-UNet trên đúng hai nhóm đó. **Lưu ý:** phân tích này không định nghĩa độ khó dữ liệu nội tại; nó chỉ báo cáo hiệu năng trên các tập con do chính thứ hạng của Attention U-Net tạo ra.

Table 5: Bảng 5 - So sánh nhóm Top-Dice và Bottom-Dice dưới prompt bao phủ ở 512×512 (50 ảnh/nhóm).

Bộ dữ liệu	Nhóm	Mô hình	Dice	CBL	HD95
BTXRD	Top-Dice	Attention U-Net	0.8629	0.9436	39.32
		PGA-UNet	0.9036	0.9709	9.23
	Bottom-Dice	Attention U-Net	0.0335	0.0928	270.72
		PGA-UNet	0.8521	0.9459	5.19
FracAtlas	Top-Dice	Attention U-Net	0.4428	0.6277	82.08
		PGA-UNet	0.8318	0.9666	6.37
	Bottom-Dice	Attention U-Net	0.1529	0.3345	135.76
		PGA-UNet	0.8151	0.9582	6.25

Trên BTXRD, PGA-UNet vượt Attention U-Net ngay cả ở nhóm Top-Dice (0.8629 $\rightarrow$ 0.9036). Khác biệt lớn hơn nhiều ở nhóm Bottom-Dice: Attention U-Net sụp xuống 0.0335 Dice, trong khi PGA-UNet vẫn đạt 0.8521. FracAtlas cho cùng xu hướng nhưng mức độ nghiêm trọng khác: ngay cả nhóm Top-Dice của Attention U-Net cũng chỉ đạt 0.4428, thấp hơn hẳn BTXRD, cho thấy baseline tự động gặp khó khăn rộng hơn trên FracAtlas; PGA-UNet vẫn đạt 0.8318 ở nhóm đó và giữ gần mức đó (0.8151) ở nhóm Bottom-Dice. Vì 4 nhóm được định nghĩa trực tiếp từ điểm Attention U-Net, không nên đọc các số này như trung bình toàn cục; chúng chỉ cho thấy PGA-UNet hành xử ra sao ở những ảnh mà baseline tự động tương đối mạnh hoặc tương đối yếu.

Ví dụ định tính giúp làm rõ: ở nhóm Top-Dice của Attention U-Net, baseline tự động thường đặt được mặt nạ dự đoán vào đúng vùng giải phẫu gần đúng, nhưng vẫn có thể sinh phản hồi giả (false positive) ở xa tổn thương, làm giảm Dice/IOU dù bao phủ tổn thương khá tốt, khớp với HD95 vẫn cao (39.32 ở BTXRD, 82.08 ở FracAtlas) dù Dice trung bình-thấp. PGA-UNet ít gặp kiểu lỗi này hơn vì hộp prompt ràng buộc mô hình vào vùng không gian liên quan hơn. Ở nhóm Bottom-Dice, lỗi nghiêm trọng hơn: baseline tự động có thể định vị sai vùng hoặc bỏ lỡ gần như hoàn toàn tổn thương. Lý do khả dĩ: bản thân cổng attention không có gì đảm bảo học được chính sách gating đúng về mặt lâm sàng: nó lọc bất kỳ đặc trưng nào nó đã học để nhấn mạnh, dù đó là tổn thương thật hay cấu trúc năng lượng cao giả. Khi phản hồi học được bị chi phối bởi nhiễu nền hoặc tín hiệu giống-artifact có cường độ tương đương hoặc lớn hơn bằng chứng tổn thương thật, cổng không còn “cứu” được việc định vị nữa. Ngược lại, PGA-UNet nhận một prior không gian thô nên có thể xác định vùng tổn thương đáng tin cậy hơn trước khi tinh chỉnh mặt nạ.

[Hình 3 - *images/results/unet_extreme_groups_btxrd.png*]: So sánh định tính giữa Attention U-Net và PGA-UNet trên BTXRD, cho một ca thuộc nhóm Top-Dice (IMG000184) và một ca thuộc nhóm Bottom-Dice (IMG000791) của Attention U-Net. Mỗi hàng có 4 panel; với PGA-UNet, panel ảnh đầu vào và panel hộp prompt được gộp thành một panel duy nhất “Input image (with prompt)”.

5.6 So sánh khớp điều kiện với SAM-Med2D

So sánh này kiểm tra đóng góp kiến trúc của cách xử lý prompt để xuất so với một baseline nền tảng có prompt, trong điều kiện đầu vào khớp nhau. Cả hai mô hình nhận cùng loại prompt và cùng độ phân giải, nên khác biệt quan sát được gần trực

tiếp hơn với cách thông tin prompt được biểu diễn và lan truyền, sau khi bước khu trú đã được cung cấp từ bên ngoài. Bảng 6 báo cáo Dice ở 256×256 dưới cả hai điều kiện prompt. PGA-UNet đạt Dice cao hơn SAM-Med2D đã fine-tune dưới cả hai điều kiện prompt, trên cả hai bộ dữ liệu. Phân tích tổn thương nhỏ trình bày tiếp theo nên được đọc như phần mở rộng của so sánh SAM-Med2D này, sang tình huống mà việc khai thác prompt được kỳ vọng quan trọng nhất.

Table 6: Bảng 6 - So sánh Dice với SAM-Med2D đã fine-tune ở 256×256 .

Bộ dữ liệu	Prompt	PGA-UNet	SAM-Med2D-FT
BTXRD	Bao phủ	0.8449	0.7624
	Lệch tâm	0.8111	0.7542
FracAtlas	Bao phủ	0.7974	0.7439
	Lệch tâm	0.7619	0.7275

Với prompt bao phủ, PGA-UNet vượt SAM-Med2D đã fine-tune 0.0825 Dice trên BTXRD và 0.0535 Dice trên FracAtlas ở cùng độ phân giải 256×256 ; với prompt lệch tâm, khoảng cách là 0.0569 và 0.0344 Dice. PGA-UNet vì vậy luôn dẫn trước về Dice tuyệt đối ở cả hai điều kiện prompt, trên cả hai bộ dữ liệu, cho thấy một khi vùng tổn thương gần đúng đã được biết, cách PGA-UNet khai thác thông tin prompt vẫn hiệu quả hơn trong bối cảnh này.

Mức suy giảm tương đối từ bao phủ sang lệch tâm nên đọc cẩn thận, không nên coi là một bảng xếp hạng “độ bền vững” đơn giản. PGA-UNet giảm 0.0338 Dice (BTXRD) và 0.0355 Dice (FracAtlas); SAM-Med2D đã fine-tune giảm ít hơn, 0.0082 và 0.0164. Nhìn bề ngoài có vẻ SAM-Med2D “bền” hơn trước nhiễu loạn prompt, nhưng hai mô hình *không* được huấn luyện trên cùng phân phối prompt: PGA-UNet chỉ huấn luyện với prompt bao phủ và bị đánh giá trên prompt lệch tâm chưa từng thấy, còn SAM-Med2D được huấn luyện trên hỗn hợp 50/50 cả hai loại, nên điều kiện lệch tâm là “trong phân phối” với SAM-Med2D nhưng “ngoài phân phối” với PGA-UNet. Dù bất lợi này, PGA-UNet vẫn đạt Dice tuyệt đối cao hơn SAM-Med2D đã fine-tune dưới prompt lệch tâm, trên cả hai bộ dữ liệu, phù hợp với quan điểm rằng hành vi lệch tâm của PGA-UNet đến từ cách PSG và CAD lan truyền/tái sử dụng thông tin prompt về mặt kiến trúc, chứ không phải vì đã được huấn luyện sẵn trên đúng kiểu nhiễu loạn đang kiểm thử.

5.7 Hiệu năng trên tổn thương nhỏ

Thực nghiệm này mở rộng so sánh SAM-Med2D sang tình huống mà đóng góp của việc giữ đặc trưng theo prompt được kỳ vọng rõ nhất: tổn thương rất nhỏ. Với mỗi bộ dữ liệu, tập con gồm 50 ảnh test có tổng diện tích tổn thương nhỏ nhất, đánh giá dưới prompt bao phủ. Tập con này dùng cho 2 so sánh: PGA-UNet so với SAM-Med2D đã fine-tune ở cùng 256×256 , và PGA-UNet₂₅₆ so với PGA-UNet₅₁₂ để xem ảnh hưởng độ phân giải. Mọi độ đo tính trên cùng khung tham chiếu 512×512 (dự đoán 256×256 được upsample trước khi chấm điểm) để cả 3 mô hình được so trên đúng cùng mặt nạ ground-truth.

Trên tập tổn thương nhỏ BTXRD, PGA-UNet ở 256×256 tăng 0.5747 Dice so với SAM-Med2D đã fine-tune cùng độ phân giải; tăng thêm 0.0833 Dice khi lên 512×512 . Khoảng cách HD95 còn ấn tượng hơn: SAM-Med2D đã fine-tune trung bình 240.72 pixel, gần mức phạt tối đa có thể trên khung 512×512 , cho thấy nó thường *bỏ lỡ hoàn toàn* tổn thương nhỏ chứ không chỉ vẽ biên thiếu chính xác. CBL xác nhận điều này từ một góc độ độc lập: tâm mặt nạ dự đoán của SAM-Med2D đã fine-tune trôi rất xa tâm tổn thương thật (CBL chỉ 0.4489 trên BTXRD và 0.7116 trên FracAtlas), trong khi

Table 7: Bảng 7 - Dice, CBL, và HD95 trên 50 tổn thương nhỏ nhất mỗi bộ dữ liệu. Bảng không đưa IoU vào vì với tổn thương cỡ này, IoU là độ đo nhạy với sai số biên và dễ gây nhiễu; Dice, CBL, và HD95 phản ánh rõ hơn việc mô hình có định vị đúng vùng hay không.

Bộ dữ liệu	Mô hình	Dice	CBL	HD95
BTXRD	SAM-Med2D-FT 256×256	0.1903	0.4489	240.72
	PGA-UNet 256×256	0.7650	0.9261	3.11
	PGA-UNet 512×512	0.8483	0.9451	2.32
FracAtlas	SAM-Med2D-FT 256×256	0.3736	0.7116	105.19
	PGA-UNet 256×256	0.7973	0.9569	5.62
	PGA-UNet 512×512	0.8348	0.9609	4.83

PGA-UNet giữ CBL trong khoảng 0.9261–0.9609 ở cả hai độ phân giải và cả hai bộ dữ liệu, nghĩa là vùng dự đoán vẫn bám đúng tâm tổn thương dù tổn thương chỉ còn vài pixel. Trên FracAtlas, cùng xu hướng nhưng mức độ nhỏ hơn: PGA-UNet 256×256 tăng 0.4237 Dice so với SAM-Med2D-FT, tăng thêm 0.0375 Dice ở 512×512 . Kết quả phù hợp với quan điểm: tổn thương nhỏ hưởng lợi từ cả điều kiện hóa prompt tường minh lẫn độ phân giải không gian cao hơn.

Một cách giải thích khả dĩ: tổn thương nhỏ vốn đã cung cấp ít bằng chứng thị giác, và việc resize ảnh X-quang lớn về 256×256 càng làm yếu bằng chứng đó. Trong điều kiện này, cách dùng thông tin prompt trở nên đặc biệt quan trọng. Ở SAM-Med2D, hộp prompt chủ yếu đóng vai trò gợi ý vị trí thô cho việc sinh mặt nạ. Khi tổn thương chỉ còn rất ít pixel sau resize, gợi ý đó một mình có thể không đủ để khôi phục mặt nạ chi tiết. Ngược lại, PGA-UNet dùng hộp giới hạn như một prior không gian dày đặc, khuếch đại vùng tổn thương và lan truyền thông tin prompt qua cả encoder lẫn decoder; thiết kế này có vẻ phù hợp hơn để giữ bằng chứng cục bộ yếu cho tổn thương nhỏ. Kết quả mạnh hơn của PGA-UNet ở 512×512 cũng phù hợp cách giải thích này, vì độ phân giải cao hơn giữ được nhiều chi tiết tổn thương hơn trước khi giải mã theo prompt.

[Hình 4 - *images/results/small_lesion_sam_pga256_pga512.png*]: So sánh định tính trên tổn thương nhỏ ở BTXRD (ảnh dùng: IMG000868, có hai tổn thương nhỏ tách biệt). Ví dụ đối chiếu SAM-Med2D đã fine-tune ở 256×256 , PGA-UNet ở 256×256 , và PGA-UNet ở 512×512 ; panel ảnh đầu vào và panel hộp prompt được gộp thành một panel duy nhất "Input image (with prompt)". SAM-Med2D không tạo được dự đoán nào từ cùng prompt đó (Dice=0.000), trong khi cả hai biến thể PGA-UNet đều khôi phục được cả hai tổn thương.

5.8 Phân tích hiệu năng tính toán

Thực nghiệm này đánh giá xem các lợi ích trên có đi kèm một hồ sơ tính toán thực tế hay không; ủng hộ luận điểm rằng phương pháp phù hợp cho tương tác lặp lại, độ trễ thấp, chứ không chỉ suy luận theo lô ngoại tuyến. Đo trên cùng GPU Tesla T4 dùng để huấn luyện (độ trễ trung bình qua nhiều lượt forward, batch size 1).

Table 8: Bảng 8 - So sánh hiệu năng tính toán trong môi trường kiểm thử.

Mô hình	Tham số	GFLOPs	Kích thước	GPU (ms)	CPU (ms)
PGA-UNet 256	2.95M	7.74	11.35 MB	8.17	109.17
PGA-UNet 512	2.95M	30.97	11.35 MB	18.28	336.74
SAM-Med2D 256	271.24M	92.02	2443.16 MB	48.75	1263.77

PGA-UNet chỉ có 2.95M tham số. Ở cấu hình 256×256 kiểm thử, đây là mức giảm khoảng **92 lần** số tham số và **11.9 lần** FLOPs so với SAM-Med2D, cùng với suy luận GPU nhanh hơn **6.0×** và CPU nhanh hơn **11.6×**.

5.9 Nghiên cứu Ablation

Nghiên cứu ablation kiểm tra trực tiếp thành phần nào tạo ra lợi ích quan sát được: bản thân cách biểu diễn prompt, cổng prompt phía encoder (PSG), attention có điều kiện prompt phía decoder (CAD), hay sự kết hợp của chúng. Ba yếu tố được cô lập: có/không có PSG ở encoder; kiểu skip-attention decoder (không có / cổng Attention U-Net gốc chưa điều kiện hóa / CAD); prompt biểu diễn dạng nhị phân hay cao nguyên Gaussian. Kết hợp 3 yếu tố cho 8 cấu hình huấn luyện mỗi bộ dữ liệu, đều ở 512×512 : 7 biến thể một phần cô lập từng yếu tố và tương tác đôi giữa chúng, cộng với PGA-UNet đầy đủ (dùng cả PSG, CAD, và prompt Gaussian).

Table 9: Bảng 9 - Kết quả ablation (Dice) trên BTXRD ở 512×512 .

PSG	Attention decoder	Prompt	Bao phủ	Lệch tâm
Không	Không có	Gaussian	0.8596	0.8230
Không	Không có	Nhị phân	0.8597	0.8253
Không	Cổng gốc (vanilla)	Gaussian	0.8671	0.8408
Không	CAD	Gaussian	0.8685	0.8358
Có	Không có	Gaussian	0.8567	0.8297
Có	Cổng gốc (vanilla)	Gaussian	0.8611	0.8314
Có	CAD	Nhị phân	0.8611	0.8317
Có	CAD	Gaussian (PGA-UNet)	0.8788	0.8496

Table 10: Bảng 10 - Kết quả ablation (Dice) trên FracAtlas ở 512×512 .

PSG	Attention decoder	Prompt	Bao phủ	Lệch tâm
Không	Không có	Gaussian	0.7727	0.7356
Không	Không có	Nhị phân	0.7670	0.7199
Không	Cổng gốc (vanilla)	Gaussian	0.7560	0.7311
Không	CAD	Gaussian	0.8158	0.7777
Có	Không có	Gaussian	0.7115	0.6990
Có	Cổng gốc (vanilla)	Gaussian	0.7372	0.7170
Có	CAD	Nhị phân	0.8132	0.7896
Có	CAD	Gaussian (PGA-UNet)	0.8286	0.7925

Cấu hình PGA-UNet đầy đủ (PSG + CAD + prompt Gaussian) là dòng tốt nhất trong cả hai bảng, dưới cả hai điều kiện prompt, trên cả hai bộ dữ liệu. Đây là kết quả rõ ràng nhất của ablation: không biến thể một phần nào trong 7 biến thể sánh được với tổ hợp đầy đủ, ở bất kỳ trong 4 tổ hợp (bao phủ/lệch tâm $\times$ bộ dữ liệu).

So sánh từng thành phần cho thấy một mô hình **hiệp lực (synergy)**, không phải ba đóng góp cộng dồn độc lập. **Thứ nhất**, PSG một mình (không có CAD) không chắc giúp ích và có thể gây hại: trên BTXRD gần như không đổi Dice so với baseline không-PSG-không-attention (0.8567 so với 0.8596, bao phủ); trên FracAtlas giảm 0.0612 (bao phủ) và 0.0366 (lệch tâm) so với cùng baseline. Khuếch đại prompt phía encoder mà không có cơ chế phía decoder tương ứng để tận dụng nó có thể phản tác dụng. **Thứ hai**, CAD một mình (không có PSG) giúp ích trên cả 2 bộ dữ liệu (Dice bao phủ tăng 0.0089 trên BTXRD, 0.0431 trên FracAtlas so với baseline), và đáng tin cậy hơn cổng attention gốc chưa điều kiện hóa: thay CAD bằng cổng vanilla trong cùng cấu hình không-PSG làm mất 0.0167 Dice bao phủ trên FracAtlas, nơi cổng chưa điều kiện hóa còn tệ hơn cả không dùng attention. **Thứ ba**, khi kết hợp PSG và CAD, cặp đôi vượt trội hơn hẳn từng thành phần riêng lẻ, rõ nhất trên FracAtlas: mô hình đầy đủ vượt biến thể chỉ-CAD 0.0128 (bao phủ) / 0.0148 (lệch tâm) Dice, và vượt biến thể chỉ-PSG

tới 0.1171 (bao phủ) / 0.0935 (lệch tâm) Dice. Điều này cho thấy lợi ích của PSG *phụ thuộc điều kiện* vào việc có CAD để tận dụng đặc trưng encoder đã khuếch đại; PSG không hữu ích một cách độc lập.

So sánh cách biểu diễn prompt cho một mô hình tương tự. Thay prompt Gaussian bằng prompt nhị phân trong kiến trúc PSG+CAD đầy đủ làm mất 0.0177 (bao phủ) / 0.0179 (lệch tâm) Dice trên BTXRD, và 0.0154 / 0.0029 Dice trên FracAtlas. Nhưng ở baseline không-PSG-không-attention, cùng phép thay thế đó gần như không ảnh hưởng (trong khoảng 0.006 Dice trên BTXRD; khoảng cách nhỏ hơn 0.0057–0.0157 Dice trên FracAtlas, nghiêng nhẹ về Gaussian nhưng thấp hơn nhiều so với khoảng cách quan sát ở kiến trúc đầy đủ). Vậy biểu diễn cao nguyên Gaussian chỉ thực sự có lợi rõ rệt khi mạng được thiết kế để tái sử dụng thông tin prompt xuyên suốt encoder và decoder; một lần nữa chỉ ra tính hiệp lực giữa ba lựa chọn thiết kế, chứ không phải bất kỳ lựa chọn nào trong đó tự nó đã đủ.

[Hình 5 - *images/ablation/ablation_gaussian_vs_binary_case.png*]: So sánh định tính giữa biểu diễn prompt Gaussian và prompt nhị phân. Phiên bản Gaussian cho biên sạch hơn và overlap tốt hơn trên ví dụ tiêu biểu này của BTXRD.

5.10 Các kiểu lỗi (Failure Modes)

Phương pháp vẫn còn các ca lỗi có thể nhận diện được. Theo rà soát định tính thu thập trong thực nghiệm khóa luận, Dice thấp hơn thường rơi vào: tổn thương có hình dạng rất dài/phân nhánh, tổn thương nằm ở vùng giải phẫu rối rắm (ví dụ vai, xương đòn), và tổn thương tương phản yếu so với cấu trúc xung quanh. Các ca này quan trọng vì cho thấy định hướng bằng prompt không loại bỏ được sự mơ hồ một khi bằng chứng ảnh cục bộ vốn đã kém.

[Hình 6 - *images/failure/failure_case_overlap.png*]: Ca lỗi tiêu biểu ở vùng giải phẫu chồng lấn. Dù có prompt bao phủ, biên tổn thương vẫn khó vì cấu trúc X-quang cục bộ bị nhầm lẫn về mặt thị giác.

Mục VI. Thảo luận (Discussion)

Kết quả ủng hộ một cách diễn giải khá nhất quán về bài toán. **Thứ nhất**, PGA-UNet hoạt động tốt trên cả hai bộ dữ liệu, và Monte Carlo cross-validation cho thấy hiệu năng này ổn định qua nhiều lần chia ngẫu nhiên lặp lại ở mức ảnh, chứ không gắn với một cách chia thuận lợi duy nhất. **Thứ hai**, Attention U-Net không nhận box từ bác sĩ, nên kết quả của nó trên cả hai bộ dữ liệu không phải một phương pháp cạnh tranh cùng dùng prompt; nó chỉ cho thấy phần lớn độ khó của bài toán này đến từ riêng bước khu trú, và khoảng cách với PGA-UNet lớn nhất chính xác ở những ảnh mà baseline tự động này yếu nhất. Theo nghĩa đó, so sánh với Attention U-Net nên được đọc như bằng chứng cho tầm quan trọng của tri thức không gian cung cấp từ bên ngoài, chứ không đơn thuần là một bảng xếp hạng kiến trúc mạng. **Thứ ba**, so sánh khớp điều kiện prompt thật sự kiểm chứng thiết kế đề xuất là với SAM-Med2D đã fine-tune ở cùng độ phân giải 256×256 , nơi PGA-UNet hoạt động tốt hơn trên cả hai bộ dữ liệu, dưới cả hai điều kiện prompt bao phủ và lệch tâm, dù chỉ được huấn luyện với prompt bao phủ trong khi SAM-Med2D được huấn luyện trên cả hai. **Thứ tư**, lợi thế này càng rõ hơn trên tập con tổn thương nhỏ, nơi SAM-Med2D đã fine-tune gần như thất bại trong việc tạo ra một mặt nạ dùng được, cho thấy chỉ riêng box prompt là chưa đủ một khi mục tiêu đủ nhỏ. **Thứ năm**, kết quả ablation cho thấy PSG và CAD hiệu quả nhất khi kết hợp chứ không phải độc lập, với tổ hợp đầy đủ vượt mọi cấu hình một phần dưới cả hai điều kiện prompt trên cả hai bộ dữ liệu. **Cuối cùng**, phân tích hiệu năng tính toán cho thấy mô hình vẫn nhẹ và nhanh hơn đáng kể so với SAM-Med2D.

Phạm vi phân tích được thu hẹp có chủ đích: pipeline sàng lọc phụ trợ bị loại vì giải quyết câu hỏi khác với bản thân phân đoạn có định hướng prompt. Tương tự, các phân tích nhóm phụ được giữ lại là các cách xây dựng khách quan, gắn với kích thước tổn thương hoặc thứ hạng do baseline định nghĩa.

Nghiên cứu vẫn còn một số hạn chế quan trọng. Mô hình hiện phụ thuộc việc resize đầu vào về độ phân giải cố định, có thể làm loãng chi tiết của các tổn thương rất nhỏ. Prompt cũng mới được mô phỏng từ nhãn có sẵn chứ chưa thu thập từ bác sĩ X-quang thực tế, nên chưa phản ánh đầy đủ cách bác sĩ thực sự khoanh vùng; một bounding box bao quá sát tổn thương thì thuận tiện về mặt thực nghiệm nhưng chưa chắc tự nhiên về mặt lâm sàng. Điều này quan trọng vì luận điểm trung tâm của bài báo là tương tác và hướng đến bác sĩ, trong khi các thực nghiệm hiện tại vẫn dùng một giao thức prompt có kiểm soát, chứ chưa phải prompt tự nhiên hoàn toàn từ người dùng thật. Cấu hình hiện tại cũng chưa khai thác thêm nguồn thông tin nào ngoài ảnh và box prompt, và vẫn cần giám sát bằng mask dày đặc khi huấn luyện. Đánh giá hiện mới dừng ở hai bộ dữ liệu công khai, với BTXRD và FracAtlas huấn luyện riêng thay vì huấn luyện chung hoặc đánh giá chuyển giao miền ngoài. Thực nghiệm Monte Carlo cross-validation chỉ bao phủ xu hướng chính về độ phân giải và điều kiện prompt ở 512×512 , còn nghiên cứu ablation vẫn được báo cáo từ một lần chia cố định thay vì huấn luyện lặp lại với nhiều seed.

Một hạn chế khác nằm ở các thành phần tối ưu hóa và đánh giá. Hàm loss hiện tại chưa nhấn mạnh đủ vào đặc tính “tổn thương nhỏ” hoặc “khu trú đúng tâm” mà bài toán này thực sự cần, dù phần đánh giá đã có CBL. Bài báo hiện tại vì vậy mới chứng minh được hiệu quả hệ thống của PGA-UNet với cấu hình loss đang có, chứ chưa khai thác hết khả năng cải tiến nếu bổ sung các số hạng loss chú ý đến vùng nhỏ, tâm tổn thương, hoặc độ tin cậy dự đoán.

Cuối cùng, phần diễn giải cơ chế vẫn ở mức hệ thống hơn là nhân quả nội tại. Các kết quả rất phù hợp với giả thuyết rằng PSG, CAD và prompt Gaussian giúp khuếch đại rồi bảo toàn tín hiệu tổn thương nhỏ, nhưng bài báo chưa có probing ở mức đặc trưng để khẳng định một cơ chế duy nhất bên trong mạng. Vì vậy, điểm mạnh hiện tại của nghiên cứu là lập luận nhất quán giữa bài toán, thiết kế kiến trúc và kết quả thực nghiệm, hơn là một chứng minh giải thích đầy đủ ở cấp độ biểu diễn.

Mục VII. Kết luận (Conclusion)

Bài báo trình bày **PGA-UNet**, một CNN nhẹ có định hướng bằng prompt cho phân đoạn tổn thương xương X-quang tương tác. Ý tưởng cốt lõi không chỉ là phân đoạn bên trong một hộp đã được prompt, mà là xem hộp đó như một prior không gian dày đặc, vừa thắt chặt không gian tìm kiếm vừa giúp bảo toàn bằng chứng tổn thương nhỏ, yếu, xuyên suốt mạng. Bằng cách kết hợp bản đồ prompt Gaussian dạng cao nguyên với Prompt Spatial Gate phía encoder và Conditional Attention Decoder phía decoder, mô hình khuếch đại rồi bảo toàn tín hiệu tổn thương nhỏ, thay vì chỉ giới hạn vùng tạo mask. Attention U-Net, vốn không nhận bounding box từ bác sĩ, chỉ được dùng để cho thấy bài toán khu trú khó đến mức nào; so sánh công bằng thực sự kiểm chứng thiết kế là với SAM-Med2D đã fine-tune, nơi PGA-UNet đạt kết quả tốt hơn trên cả BTXRD và FracAtlas trong khi vẫn nhỏ và nhanh hơn đáng kể. Bằng chứng nhất quán nhất cho thiết kế nằm ở: (1) nghiên cứu ablation, nơi tổ hợp đầy đủ PSG+CAD+Gaussian vượt mọi cấu hình một phần dưới cả hai điều kiện prompt, trên cả hai bộ dữ liệu; (2) so sánh tổn thương nhỏ, nơi SAM-Med2D đã fine-tune gần như thất bại trong khi PGA-UNet vẫn dùng được và vẫn giữ đúng tâm tổn thương theo CBL; và (3) độ ổn định cao hơn trên nhóm ảnh mà Attention U-Net thất bại, cho thấy lợi ích tập trung đúng vào chỗ khu trú khó nhất. Hướng nghiên cứu tiếp theo nên đánh giá phương pháp với prompt do chính bác sĩ X-quang cung cấp, với giao thức bounding box thoải mái và thực tế

hơn, trên các tập dữ liệu ngoài, xử lý độ phân giải cao hơn mà không resize mạnh, và các bối cảnh tương tác lâm sàng rộng hơn.

Các mục còn lại

Tính sẵn có của dữ liệu (*Data Availability*)

BTXRD và FracAtlas là bộ dữ liệu công khai được trích dẫn trong bài báo. Bản thảo báo cáo thực nghiệm trên các tập chia train/validation/test ở mức ảnh, suy ra từ hai bộ dữ liệu đó. Mã nguồn và chi tiết cách chia sẽ được công bố cùng gói tái lập kết quả cuối cùng.

Đóng góp của tác giả (*Author Contributions*)

Thông Lục: ý tưởng, phương pháp luận, cài đặt phần mềm, thực nghiệm, phân tích định lượng, trực quan hóa, viết bản thảo gốc. **Nguyễn Hữu Bình:** hỗ trợ phần mềm, chuẩn bị dữ liệu, kiểm chứng thực nghiệm, rà soát & biên tập. **Lý Quốc Ngọc:** hướng dẫn, thẩm định, rà soát & biên tập.

Tuyên bố đạo đức (*Ethics Statement*)

Nghiên cứu dùng bộ dữ liệu X-quang công khai đã ẩn danh, không thu thập dữ liệu tiền cứu, không tiếp xúc bệnh nhân, không can thiệp.

Lời cảm ơn (*Acknowledgment*)

OpenAI ChatGPT chỉ được dùng để chỉnh từ vựng & ngữ pháp cho một số đoạn văn phi kỹ thuật trong bản thảo. Toàn bộ nội dung kỹ thuật, thiết kế thực nghiệm, công thức toán học, hình, bảng, và kết luận do các tác giả chuẩn bị và xác minh, và các tác giả chịu trách nhiệm hoàn toàn về bản thảo cuối cùng.

Tài liệu tham khảo (*References - giữ nguyên, không dịch tên bài/tạp chí*)

1. Kirillov *et al.*, "Segment Anything," ICCV 2023.
2. Cheng *et al.*, "SAM-Med2D," arXiv:2308.16184, 2023.
3. Ronneberger, Fischer, Brox, "U-Net: Convolutional Networks for Biomedical Image Segmentation," MICCAI 2015.
4. Oktay *et al.*, "Attention U-Net: Learning Where to Look for the Pancreas," MIDL 2018.
5. Xu, Price, Cohen, Yang, Huang, "Deep Interactive Object Selection," CVPR 2016.
6. Wang *et al.*, "DeepIGeoS: A Deep Interactive Geodesic Framework for Medical Image Segmentation," IEEE TPAMI 2019.
7. Yao *et al.*, "A Radiograph Dataset for the Classification, Localization, and Segmentation of Primary Bone Tumors," Scientific Data 2025.
8. Abedeen *et al.*, "FracAtlas: A Dataset for Fracture Classification, Localization and Segmentation of Musculoskeletal Radiographs," Scientific Data 2023.
9. Ma *et al.*, "Segment Anything in Medical Images," Nature Communications 2024.

Tiểu sử tác giả (*Biography*)

Thông Lực là sinh viên năm cuối chương trình Cử nhân Khoa học Máy tính, Khoa Công nghệ Thông tin, Trường Đại học Khoa học Tự nhiên, ĐHQG-HCM. Hướng nghiên cứu: thị giác máy tính, deep learning, phân tích ảnh y tế, phân đoạn ảnh, phân đoạn có định hướng prompt tương tác. Công việc hiện tại tập trung vào phân đoạn có định hướng prompt cho ảnh X-quang xương bằng deep learning.

Nguyễn Hữu Bình là sinh viên ngành Khoa học Máy tính, Khoa Công nghệ Thông tin, Trường Đại học Khoa học Tự nhiên, ĐHQG-HCM. Hướng nghiên cứu: thị giác máy tính, deep learning, phân đoạn ảnh. Nghiên cứu hiện tại tập trung vào các phương pháp deep learning cho phân đoạn ảnh y tế dùng visual prompt.

Lý Quốc Ngọc: phần tiểu sử trong file gốc vẫn còn để trống dạng placeholder tiếng Việt [cần điền thông tin], cả ở mục \address[2] lẫn phần tiểu sử cuối bài, chưa có nội dung thật.

Hết. File này chỉ để tự đối chiếu ý; không dùng để nộp, không thay thế bản LaTeX gốc access.tex.