

Bản đọc tiếng Việt, đối chiếu với access.tex

PGA-UNet: kiến trúc Attention U-Net nhẹ, có định hướng bằng prompt, cho phân đoạn tổn thương xương X-quang tương tác

Bản dịch để tự kiểm tra nội dung, không phải bản nộp

Lưu ý: File này chỉ để đọc và đối chiếu ý với bản tiếng Anh thật (access.tex). Toàn bộ số liệu (Dice, CBL, HD95, số tham số...) giữ nguyên y hệt bản gốc; chỉ phần chữ được dịch. File này nên ở dạng chưa commit (untracked), chỉ dùng cục bộ.

Tóm tắt (Abstract)

Phân đoạn tổn thương xương trên ảnh X-quang gặp nhiều khó khăn do tổn thương thường có kích thước nhỏ, độ tương phản thấp và dễ lẫn vào cấu trúc giải phẫu xung quanh. Trên thực tế, khâu quyết định thường là định vị đúng vùng nghi ngờ, chứ không phải tinh chỉnh đường biên tổn thương. Từ nhận định đó, chúng tôi chọn hướng thu hẹp vùng tìm kiếm trước khi phân đoạn, thông qua một cơ chế tương tác: bác sĩ vẽ một hộp giới hạn thô quanh vùng nghi ngờ, mô hình dùng hộp này làm tín hiệu định hướng không gian.

Bài báo đề xuất **PGA-UNet**, một mạng CNN nhẹ có định hướng bằng prompt. Hộp giới hạn được chuyển thành bản đồ nhiệt Gaussian dạng cao nguyên, sau đó dùng để điều biến đặc trưng encoder qua **Prompt Spatial Gate (PSG)** và duy trì ảnh hưởng ở decoder qua **Conditional Attention Decoder (CAD)**. Thiết kế này không chỉ dùng prompt để chỉ định vùng cần phân đoạn, mà còn giữ cho các đặc trưng liên quan đến tổn thương nhỏ luôn được kích hoạt xuyên suốt mạng.

Chúng tôi dùng Attention U-Net không prompt làm mô hình tham chiếu tự động, và SAM-Med2D làm mô hình tham chiếu có prompt. Thực nghiệm trên hai bộ dữ liệu BTXRD và FracAtlas, ở ba độ phân giải 128, 256 và 512, dưới hai kiểu hộp: bao phủ và lệch tâm có kiểm soát. Kết quả cho thấy phân đoạn không prompt là bài toán rất khó: Attention U-Net chỉ đạt 0.52 và 0.34 Dice trên hai bộ dữ liệu. Khi được cấp cùng một hộp, PGA-UNet luôn vượt trội so với hai baseline quy ước có prompt và SAM-Med2D đã fine-tune. Khoảng cách này rộng nhất trên FracAtlas, bộ dữ liệu khó hơn, và trên nhóm tổn thương nhỏ nhất: SAM-Med2D fine-tune tụt xuống còn 0.26 đến 0.37 Dice, trong khi PGA-UNet vẫn giữ được 0.65 đến 0.72. Kết quả ổn định qua nhiều lần chia dữ liệu ngẫu nhiên, và PGA-UNet nhẹ hơn SAM-Med2D khoảng 92 lần về số tham số. Ngoài ra, một điểm tự đánh giá không cần huấn luyện, dựa trên độ dứt khoát của mask và độ ổn định khi prompt bị nhiễu, cho phép xếp hạng độ tin cậy của dự đoán mà không cần nhãn thật, đạt tương quan thứ hạng khoảng 0.5 đến 0.7 với Dice thực tế.

Cần lưu ý là mọi hộp trong thực nghiệm đều được mô phỏng quanh vùng tổn thương đã có nhãn sẵn, nên các kết quả trên chỉ phản ánh khả năng phân đoạn khi đã có một prompt tốt. Bài báo chưa trả lời được các câu hỏi về: phát hiện tổn thương hoàn toàn tự động, hộp chỉ phủ một phần hoặc sai vùng, độ tin cậy đã hiệu chuẩn, khả năng ứng dụng lâm sàng thực tế, khả năng tổng quát theo từng bệnh nhân, hay việc chuyển sang bộ dữ liệu khác.

Từ khóa: ảnh X-quang xương, phân đoạn tương tác, phân đoạn ảnh y tế, học có định hướng bằng prompt, Attention U-Net.

Mục I. Giới thiệu (Introduction)

Nhờ chi phí thấp, tốc độ nhanh và dễ tiếp cận, ảnh X-quang xương được dùng rộng rãi trong sàng lọc, hỗ trợ chẩn đoán và theo dõi điều trị. Tuy nhiên, việc phân đoạn tổn thương trên loại ảnh này không hề đơn giản khi tổn thương có kích thước rất nhỏ, độ tương phản thấp, hoặc bị che khuất một phần bởi cấu trúc xương xung quanh. Ở những trường hợp như vậy, khó khăn chính không nằm ở việc vẽ đường biên chính xác, mà nằm ở khâu định vị: mô hình phải tìm ra vùng nghi ngờ trong toàn bộ ảnh trước khi có thể tinh chỉnh bất kỳ đường biên nào.

Chính vì vậy, phân đoạn tổn thương nhỏ hiếm khi chỉ đơn thuần là bài toán vẽ đường biên. Khi tổn thương chỉ chiếm một phần rất nhỏ của ảnh, tìm kiếm trên toàn bộ ảnh vừa tốn kém vừa dễ dẫn đến sai sót. Cách tiếp cận tự nhiên là thu hẹp không gian tìm kiếm trước, rồi mới phân đoạn trong vùng đã thu hẹp. Các phương pháp phân đoạn tự động hoàn toàn, tiêu biểu là U-Net và Attention U-Net, cố gắng học ngầm cả quá trình định vị lẫn phân đoạn trong cùng một mạng, không có bất kỳ trợ giúp nào từ bên ngoài.

Một hướng đi khác là tận dụng chỉ dẫn từ bên ngoài về vị trí tổn thương. Trên thực hành lâm sàng, bác sĩ hoàn toàn có thể vẽ nhanh một hộp giới hạn thô quanh vùng nghi ngờ, việc mà một mô hình tự động khó làm tốt với những tổn thương rất nhỏ. Nhìn theo hướng này, hộp giới hạn không đơn thuần là một tiện ích tương tác, mà là cách thực tế để đưa tri thức không gian vào mô hình trước khi bước vào phân đoạn chi tiết. Nhiều phương pháp phân đoạn tương tác theo prompt đã ra đời từ ý tưởng này, từ các thao tác đơn giản như click, vẽ nguệch ngoạc (scribble), cho đến các mô hình nền tảng gần đây như SAM và SAM-Med2D.

Dù vậy, một câu hỏi vẫn chưa có lời giải: sau khi prompt đã xác định được vùng quan tâm, nó chỉ nên đóng vai trò một ràng buộc vị trí để sinh mask, hay cần tiếp tục tham gia định hình quá trình trích xuất đặc trưng, giúp tín hiệu tổn thương vốn đã mờ nhạt không bị mất đi qua các lớp downsampling? Câu hỏi này quan trọng nhất đối với tổn thương rất nhỏ, bởi chỉ một sai lệch không gian nhỏ cũng có thể ảnh hưởng đáng kể đến kết quả cuối cùng.

Bài báo trả lời câu hỏi trên bằng PGA-UNet, một mạng CNN nhẹ có định hướng bằng prompt, trong đó hộp giới hạn được xem như một prior không gian có cấu trúc, chứ không chỉ là một kênh đầu vào phụ. Hộp được mã hóa thành bản đồ nhiệt Gaussian dạng cao nguyên, dùng để điều biến đặc trưng encoder qua Prompt Spatial Gate (PSG), rồi tiếp tục được tái sử dụng ở decoder qua Conditional Attention Decoder (CAD). Nhờ vậy, đặc trưng tổn thương được prompt định hướng luôn ở trạng thái hoạt động xuyên suốt mạng, thay vì chỉ dừng lại ở việc giới hạn phân đoạn trong phạm vi hộp đã cho.

Cách nhìn nhận này cũng quyết định cách chúng tôi thiết kế và đọc kết quả thực nghiệm. Attention U-Net không nhận bất kỳ chỉ dẫn không gian nào từ bác sĩ, nên vai trò của nó chỉ để cho thấy bài toán khó đến mức nào khi khâu định vị phải hoàn toàn tự động. Ngược lại, SAM-Med2D được chọn làm mô hình so sánh trực tiếp vì cùng nhận đầu vào là hộp giới hạn. Câu hỏi trọng tâm của bài báo, do đó, không phải prompt có hữu ích hay không nói chung, mà là liệu một kiến trúc nhẹ có thể khai thác một prompt thô từ bác sĩ hiệu quả hơn hay không, bằng cách giữ lại tín hiệu tổn thương yếu thay vì chỉ dùng prompt như một ràng buộc vị trí đơn thuần.

Đóng góp chính (Main contributions)

- Đề xuất PGA-UNet: kiến trúc nhẹ, có định hướng bằng prompt, dùng cho phân đoạn tương tác tổn thương xương trên ảnh X-quang.
- Xây dựng cơ chế điều kiện hóa prompt gồm ba phần: prompt Gaussian dạng cao

nguyên, Prompt Spatial Gate (PSG) ở phía encoder, và Conditional Attention Decoder (CAD) ở phía decoder.

- Xây dựng khung huấn luyện ngoại tuyến kết hợp suy luận tương tác trực tuyến, cùng các định nghĩa toán học tường minh cho việc mã hóa prompt, cổng hóa ở encoder và điều kiện hóa ở decoder.
- Đánh giá phương pháp trên hai bộ dữ liệu BTXRD và FracAtlas dưới điều kiện prompt bao phủ và lệch tâm, so sánh với Attention U-Net tự động, hai biến thể Attention U-Net do chúng tôi tự bổ sung để xem một mạng quy ước sẽ ra sao khi cũng được cấp cùng một hộp prompt (một bản ghép prompt làm kênh đầu vào, một bản chỉ nhìn vùng crop theo prompt), và SAM-Med2D; dùng Dice và IoU cho độ chồng lấn vùng, CBL cho định vị theo tâm, HD95 cho khoảng cách biên, cùng Monte Carlo cross-validation và đo hiệu năng tính toán.
- Qua phân tích tổn thương nhỏ và một lát cắt độ khó do Attention U-Net định nghĩa, cho thấy lợi ích của việc xử lý có điều kiện theo prompt tập trung đúng ở nơi khâu định vị tự động thất bại và ở những tổn thương nhỏ nhất.
- Mô tả một điểm tự đánh giá không cần huấn luyện, dựa trên độ đứt khoát của mask và độ ổn định khi prompt bị nhiễu, cho phép xếp hạng độ tin cậy mà không cần nhân thật, đồng thời có thể lọc ra một danh sách ngăn vùng nghi ngờ để bác sĩ xem lại.

Mục II. Công trình liên quan (*Related Work*)

Từ lâu, phân đoạn tổn thương nhỏ trong ảnh y tế luôn vấp phải một thực tế đơn giản: muốn phân đoạn tốt một mục tiêu rất nhỏ, mô hình trước hết phải thu hẹp được vùng cần nhìn. Ở hướng tự động hoàn toàn, việc thu hẹp này được học ngầm bên trong mạng. U-Net là kiến trúc encoder-decoder đa tỉ lệ đặt nền móng cho phân đoạn y sinh, còn Attention U-Net sau đó bổ sung cổng attention trên skip connection để phía decoder lọc bỏ những phản hồi không gian không liên quan một cách chọn lọc hơn. Các pipeline tự cấu hình như nnU-Net đi xa hơn nữa, tự động thích ứng khâu tiền xử lý, hình dạng mạng và lịch huấn luyện theo từng bộ dữ liệu. Những mô hình này giúp chất lượng phân đoạn tự động tăng lên đáng kể, nhưng vẫn dựa trên một giả định chung: mạng phải tự khu trú và vẽ mask chỉ từ ảnh đầu vào, không có bất kỳ gợi ý nào về vị trí tổn thương.

Song song đó, phân đoạn y tế tương tác cũng phát triển, xuất phát từ quan sát rằng chỉ cần một chút hướng dẫn từ người dùng cũng đủ giúp bài toán đơn giản đi đáng kể. Các phương pháp đầu tiên dùng click, vẽ nguệch ngoạc (scribble), hoặc gợi ý theo đường trắc địa (geodesic); về sau, bounding box được bổ sung như một dạng prompt nhanh và thô. Gần đây hơn, các mô hình tương tác như ScribblePrompt có thể xử lý nhiều loại prompt trong cùng một khung, trên nhiều bộ dữ liệu y sinh. Nhìn chung, các phương pháp này chuyển bớt gánh nặng khu trú từ mô hình sang người dùng. Với tổn thương X-quang rất nhỏ, sự chuyển giao đó đặc biệt có giá trị, vì bác sĩ thường chỉ ra được vùng nghi ngờ một cách thô ngay cả khi hệ thống tự động khó tìm ra nó đáng tin cậy trong toàn ảnh.

Các mô hình nền tảng nhận prompt đưa ý tưởng này đi xa hơn nữa. SAM mở đầu bằng cách đưa phân đoạn theo prompt trở thành bài toán tổng quát; SAM-Med2D và MedSAM đưa nó vào lĩnh vực y tế; các biến thể dùng adapter như EMedSAM và MedSA giúp giảm chi phí khi chuyên biệt hóa các mô hình này cho dữ liệu y tế. Những mô hình đó khá linh hoạt, nhưng lại tiêu thụ prompt chủ yếu ở mask decoder, mang theo một backbone rất lớn, và không mô hình nào được tinh chỉnh riêng cho một tác vụ

X-quang cụ thể. Đối với tổn thương xương rất nhỏ, đây chính là khoảng trống: prompt chỉ đánh dấu nơi đặt mask, còn việc tiếp tục định hình quá trình trích xuất đặc trưng sau đó, đúng chỗ tín hiệu yếu dễ bị mất đi, thì chưa có cơ chế nào đảm nhận.

Bài báo này bắt đầu từ chính khoảng trống đó. Trên ảnh X-quang xương thang xám, biết được tổn thương nằm khoảng đâu mới chỉ giải quyết được một nửa vấn đề; phần khó hơn nằm ở việc giữ lại bằng chứng mờ nhạt trong khi vẫn lọc bỏ nhiễu, sau khi không gian tìm kiếm đã được thu hẹp. Chúng tôi cho rằng một mạng CNN nhẹ có định hướng bằng prompt có thể làm tốt việc này hơn, nếu giữ cho prompt luôn hoạt động liên tục từ tầng encoder đầu tiên cho đến tầng decoder cuối cùng. Trong bài báo, chúng tôi khảo sát trực tiếp bối cảnh đó, dùng SAM-Med2D làm mô hình tham chiếu nhận prompt; việc so sánh rộng hơn với các mô hình y tế nhận prompt mới hơn xin để dành cho những nghiên cứu tiếp theo.

Table 1: Công trình tiêu biểu trước đây và khoảng trống còn lại mà bài báo này giải quyết.

Công trình	Nguyên lý	Phương pháp	Bằng chứng hiệu năng	Ưu điểm	Nhược điểm
U-Net	Encoder-decoder tích chập đầy đủ	Mạng phân đoạn đa tỉ lệ có skip connection	Baseline kinh điển trong phân đoạn y sinh	Đơn giản, hiệu quả, mô hình tham chiếu mạnh	Không có định hướng prompt; mọi khu trú phải tự động
Attention U-Net	Lọc skip-feature bằng cổng attention	U-Net có skip connection gắn cổng	Tác vụ phân đoạn y tế, đo bằng Dice và IoU	Baseline tự động mạnh hơn U-Net thường	Attention vẫn học mà không có điều kiện hóa prompt tường minh
nnU-Net	Pipeline tự động tự cấu hình	Tự thích ứng tiền xử lý, kiến trúc, lịch huấn luyện	Kết quả tự động mạnh trên nhiều benchmark y tế	Pipeline tự động bền, ít chỉnh tay	Không có cơ chế prompt; khu trú vẫn hoàn toàn tự động
DeepIGeoS và các pp tương tác liên quan	Gợi ý người dùng thu hẹp không gian tìm kiếm	Phân đoạn dựa trên geodesic hoặc nhận biết tương tác	Phân đoạn y tế tương tác theo đầu vào người dùng	Phản ánh tương tác lâm sàng tốt hơn	Cơ chế tương tác có thể đặc thù theo tác vụ hoặc tổn kém duy trì
ScribblePrompt	Phân đoạn y sinh tương tác tổng quát	Một mô hình cho scribble, click, box trên nhiều dataset	Đánh giá tương tác đa dataset với nhiều loại prompt	Linh hoạt, các kiểu tương tác thực tế	Đa dụng, không phải một prior prompt nhẹ chuyên biệt X-quang
SAM-Med2D / MedSAM	Phân đoạn nền tảng nhận prompt	Mô hình tiền huấn luyện lớn, giải mã mask theo prompt	Đánh giá đa dataset y tế, đo theo prompt	Linh hoạt, áp dụng rộng	Nặng; ảnh hưởng prompt không thiết kế như prior nhẹ, end-to-end, chuyên biệt X-quang
EMedSAM / Med-SA	Tinh chỉnh adapter của SAM cho ảnh y tế	Adapter nhẹ trên backbone SAM đóng băng	Phân đoạn y tế với chi phí thích ứng thấp hơn	Chuyên biệt hóa mô hình nền tảng rẻ hơn	Vẫn là backbone SAM lớn; prompt tác động chủ yếu ở mask decoder
Bài báo này	Prompt như prior không gian đầy đặc xuyên suốt mạng	Prompt cao nguyên Gaussian + PSG + CAD trong CNN nhẹ	BTXRD và FracAtlas; Dice, CBL, HD95, hiệu năng, phân tích tổn thương nhỏ	Nhẹ, nhận biết prompt từ encoder đến decoder, đánh giá dưới dịch prompt có kiểm soát	Vẫn cần mask giám sát và tiền xử lý độ phân giải cố định

Mục III. Phương pháp (Method)

3.1 Khung offline và online (Offline and Online Framework)

Hệ thống được vận hành qua hai giai đoạn. Ở giai đoạn ngoại tuyến (offline), mô hình được huấn luyện trên các ảnh X-quang có sẵn đa giác tổn thương. Mỗi đa giác được

chuyển thành một prompt huấn luyện bằng cách sinh ra một hộp giới hạn mô phỏng, sau đó biến hộp này thành bản đồ nhiệt cao nguyên đã làm mượt bằng Gaussian. Mạng học cách ánh xạ cặp (ảnh, prompt) sang mask tổn thương nhị phân. Sang giai đoạn trực tuyến (online), người dùng chỉ cần vẽ một hộp giới hạn thô quanh vùng nghi ngờ trên ảnh mới; cùng quy trình dựng prompt đó được áp dụng lại, và mô hình đã huấn luyện sẽ đưa ra mask dự đoán cuối cùng.

Điểm khác biệt là chỗ prompt sống: thay vì chỉ đi vào một lần ở lớp đầu tiên, nó được giữ lại như một prior không gian dày đặc, hoạt động xuyên suốt encoder và decoder, điều này nên giúp ích khi hộp thô, hơi lệch tâm, hoặc bọc quanh một tổn thương rất nhỏ.

Một minh họa tương tác của giai đoạn online được cho ở Hình 1: người dùng vẽ một hộp trên ảnh X-quang, và mô hình trả về mask cùng với điểm dừng prompt của CAD và điểm tự đánh giá ở Mục III.F, cả hai đều không cần đáp án.

Interactive Demo: PGA-UNet (Prompt-Guided Attention U-Net)

Select a dataset and a test image with available ground truth, click two points to draw a lesion box, inspect the segmentation output, and compare all six metrics against the reference mask. Multiple prompt rounds can be added with Continue before switching to another image with Finish. Use Suggest prompts to have the model rank a batch of randomly sized/positioned boxes by the training, free self-assessment score Q , then click a thumbnail to apply it like any other box.

1. Which dataset does this image belong to?
BTXRD

2. Test image (with ground truth)
IMG000020.png

3. PGA-UNet checkpoint used for inference
BTXRD

Load Image

Status
 Segmentation round 1 completed. Choose 'Continue' to add another prompt or 'Finish' to switch to a different image.

3. 512x512 canvas: click two points to draw the box



Confirm Box

Reset points

☐ Show ground truth (green outline)

4. Overlay result (red = prediction, green = ground truth)



Results after 1 prompts (round 1): PGA-UNet checkpoint: BTXRD

No GT signals for the last prompt: CAD prompt confidence 97.7%, self-assessment score Q 0.96

Dice +	IoU +	Precision +	Recall +	HD95 + (px)	CBL +
0.9683	0.9386	0.9792	0.9577	3.00	0.9977

Figure 1: Minh họa tương tác giai đoạn online trên một ca BTXRD. Bác sĩ vẽ một hộp trên canvas bên trái; panel bên phải phủ mask dự đoán, và panel bên dưới báo cáo các độ đo tham chiếu cùng điểm dừng prompt của CAD và điểm tự đánh giá Q , đều không cần đáp án. Một ca FracAtlas theo cùng bố cục ở phần bổ sung.

3.2 Bài toán (Problem Setting)

Cho ảnh X-quang xám $\mathbf{I} \in \mathbb{R}^{H \times W}$ và hộp giới hạn $\mathbf{B}$ do người dùng cung cấp, mục tiêu là dự đoán mask tổn thương nhị phân $\mathbf{M}$. Gọi $\mathbf{H}(\mathbf{B})$ là bản đồ nhiệt prompt suy ra từ hộp. PGA-UNet dự đoán

$$\hat{\mathbf{M}} = \mathbf{1} [f_{\text{PGA}}(\mathbf{I}, \mathbf{H}(\mathbf{B}); \theta) \geq 0.5]. \quad (1)$$

3.3 Biểu diễn prompt (Prompt Representation)

Thay vì mã hóa prompt đầu vào như một hình chữ nhật nhị phân cứng, chúng tôi rasterize phần bên trong hộp thành một bản đồ cao nguyên ở độ phân giải ảnh gốc, làm mềm biên bằng kernel Gaussian 31×31 cố định, rồi mới resize và pad bản đồ nhiệt này xuống độ phân giải vuông mục tiêu cùng với ảnh. Kích thước kernel không thay đổi theo độ phân giải mục tiêu (256×256 hay 512×512): việc áp dụng một lần duy nhất

ở độ phân giải gốc, trước khi downsample, giúp giữ độ mờ hiệu dụng nhất quán bất kể khung ảnh vuông cuối cùng mà mạng nhìn thấy là gì. Cao nguyên chỉ phủ đúng phần diện tích của hộp (đã mở rộng nếu có), không cộng thêm biên tối thiểu nào; việc bao phủ vùng quan tâm đã được đảm bảo ngay từ bước mở rộng hộp, nên không cần thêm một bước biên riêng.

Ở bước đánh giá, prompt được kiểm thử theo hai chế độ cố định. Chế độ bao phủ (center_zoom) phóng to hộp tổn thương bo sát từ chính tâm của nó theo hệ số cố định 3.0. Chế độ lệch tâm (center_shift) áp dụng cùng độ phóng to đó, sau đó dịch hộp đi một tỉ lệ của kích thước hộp bo sát (chặn trên bởi shift_ratio=0.5), rồi mở rộng lại nếu cần để hộp vẫn chứa trọn tổn thương. Lúc test, độ dịch này được xác định cố định theo từng tổn thương (gieo hạt từ chỉ số mẫu), nên mọi mô hình đều được đánh giá trên đúng cùng một tập hộp lệch tâm; còn lúc huấn luyện, độ dịch được lấy ngẫu nhiên lại ở mỗi vòng lặp. Với mỗi bộ dữ liệu và độ phân giải, chúng tôi huấn luyện một mô hình duy nhất bằng center_mixed: chọn center_shift với xác suất 0.8 và center_zoom với xác suất 0.2, còn khi test thì hai chế độ được chấm riêng. Phạm vi bài toán giả định người dùng đã xác định được vùng nghi ngờ và cố ý vẽ một hộp bao phủ tổn thương; hộp chỉ phủ một phần, hộp âm, hay hộp sai vùng đều nằm ngoài protocol có kiểm soát này, còn việc bác sĩ có tự tìm đúng vùng hay không lại là một câu hỏi khác, không thuộc phạm vi bài.

Ký hiệu (x_1, y_1, x_2, y_2) là hộp tổn thương bo sát, với $w = x_2 - x_1$ và $h = y_2 - y_1$. Hộp bao phủ mô phỏng dùng đúng phép phóng to từ tâm cố định như trên, áp dụng cho cả huấn luyện lẫn đánh giá. Hộp lệch tâm dùng lại hộp đã phóng to đó, rồi áp dụng quy tắc dịch xác định lúc test được cài đặt trong dataset.py, vẫn đảm bảo bao phủ tổn thương. Hệ số phóng to, tỉ lệ dịch và kích thước kernel Gaussian đều được chọn từ thí nghiệm sơ bộ trên tập train và validation rồi khóa lại; tập test hoàn toàn không tham gia vào việc chọn protocol hay siêu tham số nào. Đây chỉ là các giá trị protocol cố định được dùng xuyên suốt bài, không phải một cấu hình tối ưu toàn cục. Việc mô phỏng này tất nhiên không thay thế được prompt do bác sĩ X-quang thật sự vẽ, nhưng cho một cách có kiểm soát để đo độ nhạy của mô hình với sai lệch prompt đã định nghĩa trước.

Tóm lại, việc dựng prompt gồm ba bước: (1) suy ra hộp tổn thương từ đa giác gán nhãn hoặc từ input của người dùng, rồi mở rộng như đã mô tả; (2) rasterize vùng đã mở rộng thành mask cao nguyên ở độ phân giải ảnh gốc; (3) làm mượt biên cao nguyên bằng kernel Gaussian cố định trước khi resize xuống độ phân giải mục tiêu. Cách làm này tránh được sự phụ thuộc vào biên cứng của một hộp nhị phân, trong khi vẫn giữ được một prior không gian rõ ràng.

3.4 Prompt Spatial Gate (PSG)

Gọi $\mathbf{x}^l$ là bản đồ đặc trưng encoder ở tầng l . PSG điều biến nó bằng bản đồ attention suy ra từ prompt $\mathbf{A}_{\text{PSG}}^l$:

$$\tilde{\mathbf{x}}^l = \mathbf{x}^l \odot \left(1 + \alpha_{\text{PSG}}^l \mathbf{A}_{\text{PSG}}^l\right), \quad (2)$$

trong đó $\odot$ là nhân theo từng phần tử, α_{PSG}^l là tham số học được, khởi tạo 0.1 và giới hạn trong $[0, 1]$. Dạng residual giữ nguyên luồng đặc trưng gốc trong khi nhấn mạnh vùng liên quan đến prompt.

3.5 Conditional Attention Decoder (CAD)

CAD mở rộng attention của decoder bằng cách điều kiện hóa cổng skip theo đặc trưng đã mã hóa prompt. Gọi $\mathbf{g}^l$ là đặc trưng cổng decoder, $\mathbf{p}_{\text{enc}}^l$ là mã hóa prompt cùng tỉ lệ. Cổng đã điều kiện hóa:

$$\mathbf{g}'^l = \mathbf{g}^l + c^l \alpha_{\text{CAD}}^l w_l \mathbf{p}_{\text{enc}}^l, \quad (3)$$

với c^l là hệ số dùng prompt suy ra từ decoder, α_{CAD}^l học được, w_l là hệ số độ sâu cố định. Nhờ vậy, cổng vẫn phản hồi với prompt ngay cả khi hộp không căn giữa hoàn hảo.

Bộ mã hóa prompt bên trong CAD gồm hai lớp tích chập 3×3 kèm instance normalization và ReLU. Hệ số dùng prompt c^l được tạo ra bằng global average pooling, tiếp theo là một tích chập 1×1 và hàm sigmoid; hệ số này chỉ được tính bên trong cổng, dùng để nhân với số hạng prompt ở tầng đó, và không được xuất ra hay phân tích như một đầu ra riêng của mô hình trong bài. Các hệ số độ sâu của decoder được cố định ở $\{1.0, 0.7, 0.4, 0.2\}$ theo thứ tự từ sâu đến nông. Với feature scale bằng 4, độ rộng kênh lần lượt là $\{16, 32, 64, 128, 256\}$ từ tầng encoder nông nhất đến bottleneck, và toàn bộ mô hình có khoảng 2.95 triệu tham số. Các giá trị protocol này đều được chọn từ thí nghiệm sơ bộ trên tập train và validation, giữ cố định trong suốt quá trình đánh giá chính, tập test không tham gia tinh chỉnh; chúng tôi không khẳng định đây là cấu hình tối ưu. Hệ số trộn của CAD được tham số hóa qua sigmoid và khởi tạo ở giá trị gần 0.3.

Tóm lại, phương pháp gồm 4 bước: (1) tiền xử lý ảnh và prompt về cùng độ phân giải vuông, (2) mã hóa prior không gian liên quan đến prompt bằng PSG ở encoder, (3) lan truyền ngữ cảnh có điều kiện theo prompt qua CAD ở decoder, (4) dự đoán mask tổn thương nhị phân cuối cùng.




Figure 2: Tổng quan PGA-UNet. Thông tin prompt suy ra từ hộp giới hạn được tiêm vào đặc trưng encoder qua PSG, và tái sử dụng ở skip-attention của decoder qua CAD.

3.6 Điểm tự đánh giá không cần huấn luyện (*Training-Free Self-Assessment Score*)

Bên cạnh mask dự đoán, PGA-UNet còn trả về một số vô hướng Q , ước lượng mức độ đáng tin của dự đoán mà không cần đến đáp án thật. Q không phải một đại lượng được học; nó chỉ được tính từ chính đầu ra của mô hình lúc suy luận, là trung bình cộng của hai chỉ dấu.

Chỉ dấu thứ nhất, S_{sharp} , đo độ dứt khoát của mask dự đoán. Gọi p là bản đồ xác

suất sigmoid và $\Omega = \{p > 0.5\}$ là vùng dương dự đoán. Khi đó

$$S_{\text{sharp}} = \text{clip}_{[0,1]} \left(\frac{1}{|\Omega|} \sum_{u \in \Omega} (2p(u) - 1) \right). \quad (4)$$

Một mask có độ tự tin cao, tức xác suất gần 1, sẽ cho điểm gần 1; ngược lại, một mask có nhiều pixel nằm sát ngưỡng quyết định sẽ cho điểm thấp hơn.

Chỉ dấu thứ hai, S_{stab} , đo độ ổn định của dự đoán khi prompt bị nhiễu loạn nhẹ. Hộp được nhích ngẫu nhiên K lần, mỗi lần với một độ dịch và co giãn nhỏ; mô hình được chạy lại cho từng hộp đã nhích, và S_{stab} chính là IoU trung bình giữa mask nhị phân gốc $\hat{\mathbf{M}}$ và các mask thu được từ những lần nhích đó, $\hat{\mathbf{M}}_k$:

$$S_{\text{stab}} = \frac{1}{K} \sum_{k=1}^K \text{IoU}(\hat{\mathbf{M}}, \hat{\mathbf{M}}_k). \quad (5)$$

Một dự đoán gần như không đổi khi hộp bị dịch nhẹ được xem là đáng tin hơn một dự đoán bị sập hoặc trôi đi nơi khác.

Điểm cuối cùng là $Q = \frac{1}{2}(S_{\text{sharp}} + S_{\text{stab}})$, với $K = 6$, độ dịch tối đa bằng 0.12 cạnh hộp, và hệ số co giãn trong khoảng ± 0.10 . Cần nhấn mạnh Q chỉ là một tín hiệu xếp hạng theo kiểu heuristic, không phải một xác suất đã hiệu chuẩn: giá trị 0.7 không có nghĩa là xác suất 70% mask đúng.

Chúng tôi tái dùng chính điểm số này để lọc ra một danh sách ngắn các vùng nghi ngờ khi không có prompt: lấy mẫu một tập hợp với kích thước và vị trí thay đổi, chấm điểm từng hộp bằng Q , rồi trả về vài hộp có điểm cao nhất để bác sĩ chấp nhận, chỉnh sửa, hoặc bỏ qua. Đây chỉ là một công cụ hỗ trợ xem lại, không phải một bộ phát hiện tự động.

Mục IV. Thiết lập thực nghiệm (Experimental Setup)

4.1 Bộ dữ liệu (Datasets)

Chúng tôi tiến hành thực nghiệm trên hai bộ dữ liệu X-quang xương công khai. BTXRD là bộ dữ liệu về u xương nguyên phát, có nhãn đa giác phục vụ cho cả phân loại, định vị và phân đoạn. FracAtlas là bộ dữ liệu về gãy xương, cùng loại nhãn; chúng tôi làm sạch và chuẩn hóa lại các đa giác trước khi sử dụng. Cả hai bộ dữ liệu đều được chia ở mức ảnh, sao cho mọi đa giác thuộc cùng một ảnh luôn nằm chung một tập (Bảng 2).

Table 2: Tập chia train / validation / test ở mức ảnh. Mỗi đa giác tổn thương là một mẫu có thể prompt.

Bộ dữ liệu	Ảnh			Đa giác tổn thương		
	Train	Val	Test	Train	Val	Test
BTXRD	1.493	187	187	1.848	238	232
FracAtlas	573	72	72	730	95	92

Vì metadata công khai không đủ thông tin để xác minh việc tách biệt nghiêm ngặt theo từng bệnh nhân, nên về nguyên tắc ảnh của cùng một bệnh nhân vẫn có thể rơi vào các tập khác nhau; chúng tôi xem đây là một hạn chế của cách đánh giá này. Khi

đánh giá ở mức ảnh, nếu một ảnh có nhiều tổn thương, mô hình sẽ chạy riêng cho từng hộp, sau đó hợp các bản đồ xác suất bằng phép lấy max theo từng pixel trước khi ngưỡng hóa ở mức 0.5; mask ground-truth cũng được hợp lại theo phép hợp (union).

Ảnh đầu vào được resize đẳng hướng để giữ tỉ lệ khung hình, rồi pad về hình vuông kích thước 256×256 hoặc 512×512 . Ảnh, mask và bản đồ prompt đều trải qua cùng một phép tiền xử lý hình học này.

4.2 Chi tiết huấn luyện (Training Details)

Toàn bộ các mô hình CNN được cài đặt bằng PyTorch và huấn luyện trên một GPU NVIDIA Tesla T4 16GB. PGA-UNet và Attention U-Net được huấn luyện riêng cho từng bộ dữ liệu và từng độ phân giải; nói cách khác, bài báo nghiên cứu một họ kiến trúc chung nhưng cài đặt thành các mô hình riêng biệt, với bộ tham số riêng cho BTXRD và FracAtlas, chứ không huấn luyện chung một mô hình duy nhất trên cả hai. Chúng tôi dùng optimizer AdamW với learning rate 10^{-4} và weight decay 10^{-4} ; hàm loss là tổng của binary cross-entropy và Dice loss. Do mục tiêu phân đoạn thường có kích thước nhỏ, chúng tôi thử nghiệm thêm: huấn luyện PGA-UNet ở 512×512 với số hạng Dice được thay bằng size-conditioned Tversky loss, và ở một lần chạy riêng khác, thay bằng Focal Dice loss, mọi cài đặt khác giữ nguyên. Hai phép thay thế này loại trừ lẫn nhau và chỉ được báo cáo sau như một đối chứng âm cho hàm mục tiêu. Batch size là 4, huấn luyện tối đa 150 epoch, dùng early stopping với patience bằng 15. Mọi thí nghiệm chính và ablation đều dùng chung một seed huấn luyện cố định là 22120196, gieo hạt cho Python, NumPy và PyTorch trên cả CPU lẫn CUDA. Tiêu chí chọn mô hình chính là Dice sau khi merge theo ảnh, đo trên tập validation dưới điều kiện center_shift.

Trong lúc huấn luyện, chúng tôi áp dụng augmentation gồm lật ngang và xoay ngẫu nhiên trong khoảng $\pm 15^\circ$. PGA-UNet được huấn luyện bằng center_mixed: chọn center_shift với xác suất 0.8 và center_zoom với xác suất 0.2. Vì các prompt đều được mô phỏng từ vùng tổn thương đã gán nhãn, đây là một protocol phân đoạn có prompt trong điều kiện có kiểm soát; bài báo nên được đọc theo đúng nghĩa đó, tức là nghiên cứu trên hộp mô phỏng bao phủ quanh tổn thương do người dùng xác định, chứ không phải một đánh giá phát hiện tổn thương tự do hay hộp do bác sĩ vẽ hoàn toàn ngoài đời thực.

Đối với so sánh SAM-Med2D đã fine-tune, bộ mã hóa ảnh tiền huấn luyện được đóng băng, chỉ các lớp Adapter nhẹ được huấn luyện thêm, trong khi bộ mã hóa prompt và bộ giải mã mask được cập nhật đầy đủ trên từng bộ dữ liệu, theo cùng giao thức chia tách. SAM-Med2D chỉ được fine-tune bằng hộp, dùng cùng protocol bao phủ và lệch tâm phóng từ tâm như PGA-UNet; nhánh point prompt và bước tinh chỉnh điểm lập đều bị tắt. Cách dựng hộp này khác với cách lấy mẫu nhiễu ngẫu nhiên nhỏ get_boxes_from_mask mà nhóm tác giả SAM-Med2D gốc dùng, chúng tôi không áp dụng cách đó ở đây. Cả khi validation lúc fine-tune SAM-Med2D lẫn khi đánh giá tập test cuối cùng, hai điều kiện prompt đều được báo cáo riêng; batch size là 4, tối đa 150 epoch, early stopping patience bằng 30, learning rate 10^{-5} . Giao thức khớp này giúp giảm bớt khác biệt do phân phối prompt và độ phân giải gây ra, nhưng không thể loại bỏ hết khác biệt về quy mô mô hình, cách khởi tạo, hay quá trình tối ưu hóa.

Chúng tôi còn thực hiện thêm thực nghiệm ổn định bằng Monte Carlo cross-validation, tức là chia tách ngẫu nhiên lặp lại ở mức ảnh, khác với k-fold không chồng lấn nghiêm ngặt. Các thực nghiệm này giữ nguyên seed huấn luyện ở 22120196, chỉ thay đổi seed chia tách qua các giá trị 1, 2, 3, 4.

Có hai chi tiết đáng lưu ý khi đọc kết quả đánh giá. Thứ nhất, việc dựng prompt không phụ thuộc vào độ phân giải: bản đồ cao nguyên được dựng và làm mượt bằng kernel Gaussian 31×31 cố định, ngay ở độ phân giải ảnh gốc, rồi mới resize và pad

xuống 256×256 hoặc 512×512 cùng với ảnh. Nói cách khác, cùng một độ mờ tuyệt đối sẽ bị nén khác nhau ở hai độ phân giải mục tiêu, chứ không được tham số hóa riêng cho từng độ phân giải. Thứ hai, các thực nghiệm Monte Carlo chỉ là bằng chứng ổn định bổ sung, không nhằm thay thế cho tập chia train/validation/test cố định vốn được dùng xuyên suốt các bảng kết quả chính.

4.3 Baseline và độ đo (*Baselines and Metrics*)

Chúng tôi so sánh PGA-UNet với hai baseline chính: Attention U-Net đóng vai trò baseline tự động, và SAM-Med2D đóng vai trò baseline có prompt. Attention U-Net được huấn luyện không có prompt, dùng để cho thấy bài toán khó đến mức nào khi khâu định vị phải hoàn toàn tự động. SAM-Med2D được đánh giá ở 256×256 , ở dạng đã fine-tune, dùng cùng tập chia và cùng hộp prompt như PGA-UNet, nên đây là so sánh khớp prompt chính của bài.

Để tách bạch xem lợi thế của PGA-UNet đến từ kiến trúc hay chỉ đơn thuần từ việc có prompt hộp, chúng tôi bổ sung thêm hai baseline quy ước khớp prompt, cùng dựa trên khung Attention U-Net, nhận đúng hộp prompt mà PGA-UNet nhận nhưng không có bản đồ nhiệt Gaussian, PSG hay CAD. Baseline thứ nhất, Attention U-Net kênh prompt, ghép bản đồ nhiệt prompt làm channel đầu vào thứ hai rồi dự đoán trên toàn ảnh qua một decoder skip-connection thuần. Baseline thứ hai, Attention U-Net trên vùng crop theo prompt, thu hẹp trường nhìn của mạng: ảnh đầu vào được crop theo hộp prompt trước khi resize về độ phân giải đầu vào của mô hình, Attention U-Net thuần dự đoán mask chỉ trên vùng crop đó, rồi kết quả được dán lại vào khung ảnh đầy đủ để đánh giá. Cả hai baseline đều được huấn luyện dưới cùng giao thức hộp bao phủ và lệch tâm như PGA-UNet, nên khoảng cách còn lại phản ánh sự khác biệt về kiến trúc, chứ không phải do một prompt không công bằng. Khi so sánh chéo giữa các mô hình, chúng tôi dùng độ đo full-frame đã dán lại cho baseline prompt-crop, chứ không dùng các giá trị chẩn đoán đo trong khung crop.

Mọi bảng so sánh trong bài đều báo cáo Dice và IoU cho độ chồng lấn vùng, CBL cho định vị, và HD95 cho khoảng cách biên. Dice và IoU là hai độ đo chồng lấn tương quan khá mạnh với nhau, chúng tôi đặt cạnh nhau chỉ để người đọc tiện đối chiếu. Riêng trên các tập con tổn thương nhỏ, IoU có giá trị tuyệt đối thấp và khá nhạy với vài pixel ở biên, nên Dice mới là độ đo chồng lấn chính được dùng ở đó. Precision và recall được lưu trong log công bố kèm theo bài. Gọi (x_p, y_p) là tâm mask dự đoán, (x_g, y_g) là tâm ground-truth, và D_{GT} là đường chéo của hộp ground-truth, CBL được định nghĩa như sau:

$$CBL = \max \left(0, 1 - \frac{\sqrt{(x_p - x_g)^2 + (y_p - y_g)^2}}{D_{GT}} \right). \quad (6)$$

HD95 được tính từ khoảng cách biên hai chiều. Trường hợp cả hai mask đều rỗng, HD95 nhận giá trị 0; nếu chỉ một trong hai mask rỗng, HD95 được gán bằng độ dài cạnh ảnh S (256 hoặc 512 pixel). Không có mẫu nào bị loại bỏ khỏi tính toán. Với các so sánh xuyên độ phân giải, chúng tôi báo cáo thêm HD95 ở dạng chuẩn hóa $HD95/(\sqrt{2}S)$, vì khoảng cách tính bằng pixel thô không thể so sánh trực tiếp giữa các khung 128, 256 và 512. Một số so sánh nhóm phụ có trộn mô hình huấn luyện ở 256×256 và 512×512 ; trong trường hợp đó, mọi thứ được chấm chung trong một khung 512×512 , với dự đoán ở 256×256 được upsample trước khi chấm điểm, để mọi mô hình đều được đo trên đúng cùng một mask ground-truth, thay vì trong khung gốc riêng của nó.

Đối với điểm tự đánh giá không cần huấn luyện, mỗi prompt tổn thương sẽ cho ra một điểm Q cùng với Dice thật đã ngưỡng hóa của chính mask dự đoán tương ứng; chúng tôi báo cáo tương quan Pearson và Spearman giữa hai đại lượng này, tách riêng cho điều kiện bao phủ và lệch tâm. Với danh sách vùng ứng viên, mỗi ảnh test được

lấy 50 hộp có cạnh phân bố đều trong khoảng $[0.15, 0.55]$ so với khung ảnh, mỗi hộp được chấm bằng Q , giữ lại năm hộp có điểm cao nhất; mỗi hộp được giữ lại sau đó được chấm theo độ phủ, tức tỉ lệ pixel tổn thương ground-truth nằm trong hộp đó, và không có mask dự đoán nào tham gia vào phép đo độ phủ này.

4.4 Phạm vi phân tích (*Scope of Analysis*)

Bài báo chỉ tập trung vào bản thân bài toán phân đoạn có định hướng bằng prompt. Một tầng phân loại dùng để sàng lọc tổn thương đã được khảo sát ở một nghiên cứu riêng, không thuộc phạm vi bài này. Điểm tự đánh giá và danh sách vùng ứng viên chỉ được xem là phân tích phụ trợ, đúng phạm vi hẹp đã nói ở Mục III.F, không mở rộng thêm gì ở đây. Để giữ bài gọn, chúng tôi chỉ giữ lại những phân tích nhóm phụ hỗ trợ trực tiếp nhất cho luận điểm chính: vai trò của khâu định vị theo prompt, độ nhạy khi prompt bị dịch có kiểm soát theo đúng định nghĩa ở trên, và hiệu quả trên các tổn thương rất nhỏ. Với mỗi bộ dữ liệu, tập con tổn thương nhỏ được định nghĩa là 50 ảnh test có tổng diện tích tổn thương nhỏ nhất. Trong so sánh ba độ phân giải trên tổn thương nhỏ, cùng một tập ảnh này được giữ cố định và đánh giá lần lượt ở 128, 256 và 512; dự đoán cùng ground-truth được merge ở mức ảnh tại mỗi độ phân giải, HD95 được báo cáo ở cả dạng pixel gốc lẫn dạng chuẩn hóa, và mức tụt được tính so với kết quả ở độ phân giải 512. Cũng xin nhắc lại: hộp phủ một phần, hộp âm, hay hộp sai vùng không nằm trong phạm vi khảo sát này, nên các tuyên bố của bài không dựa vào chúng.

Mục V. Kết quả (*Results*)

Trừ khi có ghi chú khác, mọi con số trong các bảng dưới đây đều theo đúng protocol hiện tại: huấn luyện bằng center_mixed với 80% center_shift và 20% center_zoom, 150 epoch, chọn mô hình theo Dice validation đã merge ở mức ảnh dưới điều kiện center_shift, và đánh giá trên tập test cũng merge ở mức ảnh. Ở mọi bảng có cả hai điều kiện, prompt bao phủ (center_zoom) và prompt lệch tâm (center_shift) luôn được báo cáo riêng.

5.1 Kết quả chính giữa các bộ dữ liệu và độ phân giải

PGA-UNet được huấn luyện từ đầu ở ba độ phân giải 128×128 , 256×256 và 512×512 trên mỗi bộ dữ liệu, tổng cộng sáu mô hình. Bảng 3 trình bày kết quả của chúng dưới cả hai điều kiện prompt.

Table 3: PGA-UNet qua các độ phân giải, merge ở mức ảnh. Dice, IoU, CBL và HD95 (pixel gốc và chuẩn hóa $HD95/(\sqrt{2}S)$) cho ở dạng bao phủ / lệch tâm.

Bộ dữ liệu	Độ p.giải	Dice	IoU	HD95 _{px}	HD95 _n	CBL
BTXRD	128	0.714 / 0.717	0.572 / 0.577	5.8 / 5.3	0.032 / 0.029	0.859 / 0.857
	256	0.762 / 0.743	0.633 / 0.611	10.9 / 12.8	0.030 / 0.035	0.902 / 0.885
	512	0.782 / 0.774	0.661 / 0.652	22.8 / 24.5	0.031 / 0.034	0.918 / 0.912
FracAtlas	128	0.596 / 0.542	0.445 / 0.389	8.1 / 9.5	0.044 / 0.053	0.849 / 0.790
	256	0.629 / 0.594	0.470 / 0.436	10.6 / 11.7	0.029 / 0.032	0.895 / 0.849
	512	0.727 / 0.713	0.585 / 0.570	10.5 / 10.4	0.015 / 0.014	0.913 / 0.897

Có thể thấy độ phân giải cao hơn giúp ích ở mọi bước: Dice luôn theo thứ tự $512 > 256 > 128$ trên cả hai bộ dữ liệu và cả hai điều kiện prompt, trong đó FracAtlas được lợi nhiều hơn, điều này khá hợp lý vì các vết gãy vốn mảnh sẽ mất tỉ lệ chi tiết lớn hơn

khi ảnh bị thu nhỏ. Vì HD95 tính bằng pixel thô không so sánh được giữa các khung khác kích thước, chúng tôi cũng đưa ra dạng chuẩn hóa: giá trị này giữ ở mức gần 0.03 qua các độ phân giải trên BTXRD, còn trên FracAtlas thì giảm dần khi khung ảnh lớn lên, cho thấy sai số biên không hề xấu đi ở độ phân giải cao hơn. Cần lưu ý mỗi mô hình chỉ được đánh giá trên chính bộ dữ liệu nó được huấn luyện; bài báo không đưa ra tuyên bố nào về khả năng chuyển giao chéo dataset.

5.2 So sánh với Attention U-Net tự động và khớp prompt

Khi phải tự tìm tổn thương mà không có bất kỳ hỗ trợ nào, Attention U-Net chỉ đạt Dice 0.517 trên BTXRD và 0.342 trên FracAtlas ở 512×512 , với HD95 vượt quá 120 pixel trên cả hai bộ dữ liệu (Bảng 4). Con số này không nên hiểu là một đánh giá về kiến trúc, vì bản thân mô hình chưa từng được thấy hộp; nó chỉ cho thấy khâu định vị tự động khó đến mức nào, đúng phần việc mà prompt giúp loại bỏ.

Khi được cấp cùng một hộp, Attention U-Net thuần cho kết quả khá hơn hẳn, nhưng khoảng cách với PGA-UNet vẫn còn (Bảng 4, cột Δ Dice). PGA-UNet vượt qua cả hai biến thể khớp prompt trên cả hai bộ dữ liệu, với biên cách biệt nhỏ trên BTXRD nhưng rộng hơn nhiều trên FracAtlas, đồng thời có HD95 thấp hơn cả hai.

Table 4: So sánh ở 512×512 dưới prompt bao phủ. Attention U-Net (không prompt) không nhận hộp; các dòng còn lại dùng đúng hộp PGA-UNet nhận. Δ Dice là mỗi dòng trừ PGA-UNet.

Bộ dữ liệu	Mô hình	Dice	Δ Dice	IoU	HD95	CBL
BTXRD	Attention U-Net (không prompt)	0.517	-0.265	0.418	120.4	0.620
	Attention U-Net + kênh prompt	0.760	-0.022	0.635	33.0	0.895
	Attention U-Net + crop theo prompt	0.741	-0.041	0.615	24.7	0.912
	PGA-UNet	0.782	—	0.661	22.8	0.918
FracAtlas	Attention U-Net (không prompt)	0.342	-0.385	0.253	139.9	0.478
	Attention U-Net + kênh prompt	0.593	-0.134	0.434	22.9	0.887
	Attention U-Net + crop theo prompt	0.590	-0.137	0.451	22.0	0.865
	PGA-UNet	0.727	—	0.585	10.5	0.913

Như vậy, khâu định vị chiếm phần lớn độ khó của bài toán này, nhưng chỉ có hộp thôi vẫn chưa đủ để giải thích hết kết quả. Cách PGA-UNet khai thác hộp đó vẫn tạo ra thêm một khoảng cách ổn định so với một mạng quy ước nhận cùng đầu vào.

5.3 Nhóm Top-Dice và Bottom-Dice của Attention U-Net

Để tìm hiểu khoảng cách đó đến từ đâu, chúng tôi xếp hạng các ảnh test theo Dice của Attention U-Net, giữ lại 50 ảnh có Dice cao nhất và 50 ảnh thấp nhất ở mỗi bộ dữ liệu, rồi chạy lại cả bốn mô hình trên đúng những ảnh đó (Bảng 5, prompt bao phủ). Ở nhóm top-50, các mô hình có prompt cho kết quả khá gần nhau. Ngược lại, ở nhóm bottom-50, Attention U-Net sụp hẳn, chỉ còn 0.031 trên BTXRD và 0.169 trên FracAtlas, trong khi PGA-UNet vẫn giữ được 0.712 và 0.687. Hai baseline prompt quy ước cũng hồi phục phần nào nhưng kém hơn: ở nhóm bottom, PGA-UNet vẫn dẫn trước chúng từ 0.04 đến 0.07 Dice trên BTXRD và từ 0.10 đến 0.19 trên FracAtlas. Điều này cho thấy có prompt là điều kiện cần nhưng chưa đủ; lợi ích của việc xử lý có điều kiện theo prompt tập trung đúng vào những nơi mà khâu định vị tự động thất bại. Cũng cần lưu ý, hai nhóm này được xác định hoàn toàn dựa trên Attention U-Net, chứ không theo một tiêu chí độ khó khách quan nào khác.

Table 5: Nhóm Top-Dice và Bottom-Dice ở 512×512 , 50 ảnh mỗi nhóm, prompt bao phủ. Nhóm do Attention U-Net thuần định nghĩa.

Bộ dữ liệu	Nhóm	Mô hình	Dice	IoU	HD95	CBL
BTXRD	Top-50	Attention U-Net	0.872	0.775	35.0	0.945
		AttUNet + kênh	0.846	0.740	24.3	0.942
		AttUNet + crop	0.844	0.739	27.5	0.946
		PGA-UNet	0.862	0.763	19.2	0.944
	Bottom-50	Attention U-Net	0.031	0.016	277.8	0.105
		AttUNet + kênh	0.668	0.541	43.3	0.831
		AttUNet + crop	0.652	0.518	17.6	0.875
		PGA-UNet	0.712	0.589	23.2	0.879
FracAtlas	Top-50	Attention U-Net	0.493	0.365	85.7	0.640
		AttUNet + kênh	0.605	0.447	26.6	0.887
		AttUNet + crop	0.658	0.515	24.9	0.881
		PGA-UNet	0.754	0.615	10.6	0.927
	Bottom-50	Attention U-Net	0.169	0.106	182.3	0.315
		AttUNet + kênh	0.574	0.416	25.3	0.875
		AttUNet + crop	0.509	0.369	26.0	0.834
		PGA-UNet	0.687	0.535	11.8	0.896




Figure 3: Attention U-Net (không prompt) so với PGA-UNet trên BTXRD, ca nhóm Top-Dice của Attention U-Net (IMG001375). Cả hai mô hình đều tốt trên ca dễ.



Figure 4: Attention U-Net (không prompt) so với PGA-UNet trên BTXRD, ca nhóm Bottom-Dice của Attention U-Net (IMG000791). Không có prompt, dự đoán của Attention U-Net lệch hẳn vị trí; PGA-UNet có điều kiện hóa theo prompt vẫn khôi phục được tổn thương.

5.4 So sánh khớp với SAM-Med2D

Cả hai mô hình đều nhận cùng một hộp ở 256×256 (Bảng 6). Ở chế độ zero-shot, SAM-Med2D gần như không hoạt động được trên ảnh X-quang xương: chỉ đạt 0.255 Dice trên BTXRD và 0.262 trên FracAtlas. Sau khi fine-tune trên cùng tập chia và cùng protocol prompt, con số này được nâng lên 0.630 và 0.563; tuy nhiên PGA-UNet ở cùng độ phân giải đạt 0.762 và 0.629 dưới prompt bao phủ, tức dẫn trước 0.132 và 0.066 Dice, cùng một khoảng cách tương tự ở CBL. SAM-Med2D chỉ vượt lên ở đúng một chỗ: khoảng cách biên trên FracAtlas, nơi HD95 sau fine-tune của nó là 8.0 pixel, thấp hơn mức 10.6 của PGA-UNet. Việc thay đổi từ prompt bao phủ sang lệch tâm sẽ được bàn riêng ở Mục V.F.

Table 6: So sánh với SAM-Med2D ở 256×256 , merge ở mức ảnh, prompt bao phủ.

Bộ dữ liệu	Mô hình	Dice	IoU	HD95	CBL
BTXRD	SAM-Med2D zero-shot	0.255	0.156	41.2	0.734
	SAM-Med2D fine-tuned	0.630	0.497	17.3	0.836
	PGA-UNet	0.762	0.633	10.9	0.902
FracAtlas	SAM-Med2D zero-shot	0.262	0.156	21.3	0.752
	SAM-Med2D fine-tuned	0.563	0.417	8.0	0.846
	PGA-UNet	0.629	0.470	10.6	0.895

5.5 Hiệu năng trên tổn thương nhỏ

Đây là nơi mà việc giữ đặc trưng theo prompt luôn hoạt động nên phát huy tác dụng rõ nhất: tập con tổn thương nhỏ gồm 50 ảnh test mỗi bộ dữ liệu có tổng diện tích tổn thương nhỏ nhất, dao động từ 7 đến 433 pixel trên BTXRD và từ 145 đến 944 pixel trên FracAtlas. Mọi con số ở đây đều được chấm trong một khung 512×512 chung.

So với SAM-Med2D ở cùng độ phân giải. SAM-Med2D gặp khó khăn rõ rệt ở kích thước tổn thương này (Bảng 7). Ngay cả sau khi fine-tune ở 256, nó cũng chỉ đạt 0.256 Dice trên BTXRD và 0.371 trên FracAtlas; còn ở chế độ zero-shot thì gần như bằng không. Trong khi đó, PGA-UNet ở cùng độ phân giải 256 vẫn giữ được 0.705 và 0.648, với HD95 thấp hơn nhiều.

Table 7: Tập con tổn thương nhỏ, PGA-UNet so với SAM-Med2D ở cùng độ phân giải 256×256 . 50 ảnh mỗi bộ dữ liệu, prompt bao phủ, chấm trong khung 512×512 chung.

Bộ dữ liệu	Mô hình	Dice	IoU	HD95	CBL
BTXRD	SAM-Med2D zero-shot 256	0.139	0.082	62.4	0.515
	SAM-Med2D fine-tuned 256	0.256	0.170	123.8	0.561
	PGA-UNet 256	0.705	0.559	14.7	0.877
FracAtlas	SAM-Med2D zero-shot 256	0.205	0.123	33.5	0.659
	SAM-Med2D fine-tuned 256	0.371	0.256	62.1	0.736
	PGA-UNet 256	0.648	0.491	20.6	0.897




Figure 5: Ca tổn thương nhỏ trên BTXRD (IMG000932): SAM-Med2D zero-shot, SAM-Med2D fine-tuned, và PGA-UNet, cùng ở 256×256 . Cả hai biến thể SAM-Med2D đều bỏ sót hoàn toàn tổn thương; PGA-UNet thì không.

So với Attention U-Net khớp prompt ở 512. Khi được cấp cùng một hộp ở 512, hai baseline prompt quy ước kém PGA-UNet khoảng 0.04 trên BTXRD và từ 0.11 đến 0.16 trên FracAtlas, còn Attention U-Net không prompt thì tụt xuống chỉ còn khoảng 0.28 (Bảng 8). Biến thể prompt-crop đạt HD95 thấp hơn trên BTXRD, có lẽ vì crop chặt vừa khớp với một mục tiêu nhỏ gọn, nhưng điều này không lặp lại trên FracAtlas.

Table 8: Tập con tổn thương nhỏ ở 512×512 , PGA-UNet so với các baseline Attention U-Net. 50 ảnh mỗi bộ dữ liệu, prompt bao phủ.

Bộ dữ liệu	Mô hình	Dice	IoU	HD95	CBL
BTXRD	Attention U-Net (không prompt)	0.283	0.219	178.2	0.283
	Attention U-Net + kênh prompt	0.728	0.591	14.2	0.879
	Attention U-Net + crop theo prompt	0.724	0.602	5.5	0.909
	PGA-UNet	0.766	0.637	14.0	0.897
FracAtlas	Attention U-Net (không prompt)	0.291	0.216	139.4	0.401
	Attention U-Net + kênh prompt	0.610	0.449	21.9	0.888
	Attention U-Net + crop theo prompt	0.564	0.425	22.6	0.855
	PGA-UNet	0.720	0.578	8.3	0.907




Figure 6: Ca tổn thương nhỏ trên BTXRD (IMG000932): Attention U-Net (không prompt), Attention U-Net kênh prompt, Attention U-Net crop theo prompt, và PGA-UNet, cùng ở 512×512 .

Độ phân giải trên các stem tổn thương nhỏ. Chính ở nhóm ảnh này, độ phân giải cho thấy ảnh hưởng rõ rệt nhất. Trên tập stem tổn thương nhỏ cố định, Dice của PGA-UNet giảm từ 0.766 ở 512 xuống còn 0.631 ở 128 trên BTXRD, và từ 0.720 xuống 0.609 trên FracAtlas; mức mất khi đi từ 512 xuống 128 lần lượt là 0.135 và 0.111, lớn hơn hẳn so với mức mất trên toàn tập test (Bảng 9).

Table 9: PGA-UNet trên tập con tổn thương nhỏ qua các độ phân giải, 50 stem cố định mỗi bộ dữ liệu. Dice, CBL và HD95 (pixel gốc / chuẩn hóa) ở dạng bao phủ / lệch tâm. Δ là mức mất Dice bao phủ so với 512.

Bộ dữ liệu	Độ p.giải	Dice	IoU	CBL	HD95 _{px/n}	Δ Dice
BTXRD	128	0.631 / 0.662	0.488 / 0.517	0.738 / 0.758	3.9 / 0.022	-0.135
	256	0.714 / 0.695	0.570 / 0.548	0.869 / 0.849	7.2 / 0.020	-0.052
	512	0.766 / 0.757	0.637 / 0.627	0.897 / 0.890	14.0 / 0.019	—
FracAtlas	128	0.609 / 0.543	0.462 / 0.393	0.828 / 0.757	8.9 / 0.049	-0.111
	256	0.642 / 0.610	0.484 / 0.451	0.887 / 0.845	10.3 / 0.029	-0.079
	512	0.720 / 0.712	0.578 / 0.570	0.907 / 0.893	8.3 / 0.012	—




Figure 7: PGA-UNet trên cùng một ca tổn thương nhỏ trên BTXRD (IMG000932) ở 128×128 , 256×256 , và 512×512 . Dự đoán khít dẫn quanh tổn thương khi độ phân giải tăng.

Nhìn chung, trên chính những tổn thương nhỏ nhất này, cả việc điều kiện hóa theo prompt lẫn độ phân giải đầu vào đều có ảnh hưởng lớn hơn hẳn so với trên toàn tập test.

5.6 Độ nhạy với dịch prompt

Bảng 10 trình bày kết quả khi hộp bị dịch lệch tâm theo một quy tắc cố định. PGA-UNet chỉ mất 0.008 Dice trên BTXRD và 0.014 trên FracAtlas, với CBL giảm tương ứng 0.006 và 0.015; riêng trên tập con tổn thương nhỏ, mức mất vẫn giữ dưới 0.01 ở cả hai bộ dữ liệu. Các baseline prompt quy ước mất một lượng tương đương hoặc nhỉnh hơn một chút, còn SAM-Med2D đã fine-tune mất khoảng 0.03. Đây chỉ là độ nhạy đối với một quy tắc dịch đã cố định từ trước. Chúng tôi cũng chưa thử hộp phủ một phần hay hộp sai vùng, nên con số này không nói được gì về hộp do bác sĩ tự vẽ tùy ý ngoài đời.

Table 10: Độ nhạy với dịch prompt. Mọi mô hình dưới prompt bao phủ (z) và lệch tâm (s). Attention U-Net (không prompt) bất biến với prompt. Các dòng AttUNet và PGA-UNet ở 512×512 ; SAM-Med2D fine-tuned ở 256×256 , merge ở mức ảnh.

Bộ dữ liệu	Mô hình	Dice z/s	Δ Dice	IoU z/s	HD95 z/s	CBL z/s
BTXRD	Attention U-Net (không prompt)	0.517 / 0.517	0.000	0.418 / 0.418	120.4 / 120.4	0.620 / 0.620
	Attention U-Net + kênh prompt	0.760 / 0.748	-0.012	0.635 / 0.626	33.0 / 32.6	0.895 / 0.890
	Attention U-Net + crop theo prompt	0.741 / 0.733	-0.008	0.615 / 0.607	24.7 / 26.4	0.912 / 0.896
	SAM-Med2D fine-tuned	0.630 / 0.601	-0.029	0.497 / 0.471	17.3 / 17.5	0.836 / 0.813
	PGA-UNet	0.782 / 0.774	-0.008	0.661 / 0.652	22.8 / 24.5	0.918 / 0.912
FracAtlas	Attention U-Net (không prompt)	0.342 / 0.342	0.000	0.253 / 0.253	139.9 / 139.9	0.478 / 0.478
	Attention U-Net + kênh prompt	0.593 / 0.588	-0.005	0.434 / 0.428	22.9 / 24.0	0.887 / 0.860
	Attention U-Net + crop theo prompt	0.590 / 0.563	-0.027	0.451 / 0.428	22.0 / 23.8	0.865 / 0.833
	SAM-Med2D fine-tuned	0.563 / 0.532	-0.031	0.417 / 0.389	8.0 / 8.4	0.846 / 0.816
	PGA-UNet	0.727 / 0.713	-0.014	0.585 / 0.570	10.5 / 10.4	0.913 / 0.897




Figure 8: PGA-UNet trên cùng một ca BTXRD (IMG000020) dưới prompt bao phủ (trên) và prompt lệch tâm (dưới); Dice không đổi ở 0.942.

5.7 Monte Carlo cross-validation

Vì một tập chia cố định có thể vô tình làm lợi hoặc gây bất lợi cho phương pháp, chúng tôi huấn luyện lại PGA-UNet ở 512×512 trên bốn tập chia ngẫu nhiên mức ảnh khác nhau, giữ nguyên seed huấn luyện ở 22120196 và chỉ thay đổi seed chia tách

(Bảng 11). Kết quả cho thấy Dice chỉ biến động tối đa 0.011 qua các lần chia, trên mỗi bộ dữ liệu và mỗi điều kiện prompt; CBL biến động tối đa 0.013. Đáng chú ý, trung bình các lần chia lặp lại trên FracAtlas là 0.733, cao hơn một chút so với kết quả 0.727 của tập chia cố định dùng trong bài, cho thấy nếu có khác biệt thì tập chia được chọn để báo cáo còn hơi khó hơn mức điển hình. Đây là bằng chứng cho thấy PGA-UNet ổn định qua các lần chia dữ liệu khác nhau, chứ không phải bằng chứng cho thấy nó vượt trội hơn baseline nào.

Table 11: Monte Carlo cross-validation của PGA-UNet ở 512×512 , bốn lần chia ngẫu nhiên mức ảnh lặp lại, trung bình $\pm$ độ lệch chuẩn.

Bộ dữ liệu	Prompt	Dice	IoU	HD95	CBL
BTXRD	Bao phủ	0.769 ± 0.005	0.647 ± 0.006	25.0 ± 2.5	0.905 ± 0.005
	Lệch tâm	0.762 ± 0.004	0.639 ± 0.007	25.7 ± 2.0	0.901 ± 0.007
FracAtlas	Bao phủ	0.733 ± 0.007	0.595 ± 0.007	14.1 ± 2.7	0.909 ± 0.006
	Lệch tâm	0.728 ± 0.011	0.590 ± 0.010	15.6 ± 3.9	0.904 ± 0.013

5.8 Nghiên cứu ablation

Thí nghiệm ablation lần lượt bỏ đi từng yếu tố khỏi mô hình đầy đủ (prompt Gaussian kết hợp PSG và CAD), đồng thời thử riêng việc thay prompt Gaussian bằng một hộp nhị phân (Bảng 12). Mô hình đầy đủ đạt Dice tốt nhất ở ba trong bốn tổ hợp dataset và điều kiện prompt. Ngoại lệ duy nhất là BTXRD dưới prompt bao phủ, nơi biến thể dùng hộp nhị phân nhỉnh hơn 0.006 Dice, một mức chênh nằm trong khoảng nhiễu của một tập chia; ở đúng cấu hình đó, mô hình đầy đủ vẫn giữ HD95 thấp nhất và CBL cao nhất. Ưu thế của prompt Gaussian thể hiện rõ nhất dưới prompt lệch tâm, nơi mô hình đầy đủ thắng trên cả hai bộ dữ liệu, và đặc biệt trên FracAtlas, nơi nó thắng ở mọi cấu hình và mọi độ đo. Mục tiêu của thí nghiệm này là kiểm tra cả tổ hợp như một hệ thống, không nhằm khẳng định một cơ chế nội tại duy nhất nào là quan trọng nhất. Đây mới là kết quả trên một tập chia.

Table 12: Ablation ở 512×512 , merge ở mức ảnh, một tập chia. Dice, IoU, HD95 và CBL ở dạng bao phủ / lệch tâm.

Bộ dữ liệu	Cấu hình	Dice	IoU	HD95	CBL
BTXRD	Chỉ CAD	0.771 / 0.759	0.649 / 0.635	23.1 / 24.2	0.915 / 0.905
	Chỉ PSG	0.779 / 0.771	0.660 / 0.651	29.4 / 28.4	0.908 / 0.902
	PSG + cổng attention thường	0.769 / 0.757	0.645 / 0.633	26.4 / 28.7	0.906 / 0.896
	Đầy đủ + hộp nhị phân	0.788 / 0.770	0.668 / 0.651	23.1 / 28.5	0.914 / 0.900
	PGA-UNet đầy đủ (Gaussian + PSG + CAD)	0.782 / 0.774	0.661 / 0.652	22.8 / 24.5	0.918 / 0.912
FracAtlas	Chỉ CAD	0.696 / 0.685	0.551 / 0.540	18.0 / 12.0	0.903 / 0.885
	Chỉ PSG	0.635 / 0.611	0.479 / 0.459	14.5 / 14.8	0.894 / 0.857
	PSG + cổng attention thường	0.690 / 0.691	0.548 / 0.547	14.0 / 14.1	0.892 / 0.881
	Đầy đủ + hộp nhị phân	0.668 / 0.657	0.514 / 0.505	12.0 / 13.2	0.904 / 0.886
	PGA-UNet đầy đủ (Gaussian + PSG + CAD)	0.727 / 0.713	0.585 / 0.570	10.5 / 10.4	0.913 / 0.897




Figure 9: PGA-UNet đầy đủ trên cùng một ca BTXRD (IMG000054) với prompt Gaussian dạng cao nguyên so với prompt hộp nhị phân, cùng ở 512×512 . Biến thể nhị phân mất khả năng định vị dù PSG và CAD không đổi.

5.9 Hiệu năng tính toán

PGA-UNet có kích thước rất nhỏ, toàn bộ 2.955 triệu tham số đều có thể huấn luyện được (Bảng 13). Ở độ phân giải khớp 256×256 , mô hình này nhẹ hơn SAM-Med2D đã fine-tune khoảng 92 lần về số tham số, 12 lần về FLOPs, nhỏ hơn 215 lần về dung lượng lưu trữ, và nhanh hơn 6 lần khi chạy trên GPU. Đây chỉ là các con số chi phí đo được trên một cách cài đặt cụ thể, một GPU cụ thể, và hai độ phân giải đã dùng, không nên suy rộng ra hơn thế.

Table 13: Hiệu năng trong môi trường kiểm thử (NVIDIA Tesla T4, batch size 1).

Mô hình	Tham số	GFLOPs	Kích thước	GPU ms	CPU ms
PGA-UNet 256	2.96M	7.74	11.4 MB	8.5	112
PGA-UNet 512	2.96M	30.97	11.4 MB	18.5	375
SAM-Med2D 256	271.24M	92.02	2443 MB	50.1	1324

5.10 So sánh thăm dò các hàm loss phân đoạn

Vì các mục tiêu phân đoạn trong bài đều có kích thước nhỏ, chúng tôi thử thay số hạng Dice bằng một size-conditioned Tversky loss, và ở một lần thử khác, bằng Focal Dice loss, mọi cài đặt còn lại giữ nguyên (Bảng 14). Kết quả là không phương án nào tốt hơn: hàm mặc định Dice + BCE luôn tốt nhất hoặc ngang bằng trên cả hai bộ dữ liệu và cả hai điều kiện prompt, còn Focal Dice thậm chí là một bước lùi rõ rệt trên FracAtlas, với HD95 vượt quá 100 pixel. Chúng tôi xem đây là một đối chứng âm: dưới protocol hiện tại, hàm mục tiêu mặc định vẫn là lựa chọn tốt, và không có biến thể nào trong hai biến thể trên được áp dụng.

Table 14: So sánh thăm dò hàm loss phân đoạn cho PGA-UNet ở 512×512 , mọi thứ khác giữ nguyên. Dice, IoU, CBL ở dạng bao phủ / lệch tâm. Mặc định không đổi.

Bộ dữ liệu	Loss	Dice	IoU	HD95	CBL
BTXRD	Dice + BCE (mặc định)	0.782 / 0.774	0.661 / 0.652	22.8 / 24.5	0.918 / 0.912
	Size-conditioned Tversky	0.778 / 0.767	0.660 / 0.649	25.2 / 30.3	0.916 / 0.903
	Focal Dice	0.773 / 0.765	0.649 / 0.642	25.6 / 25.6	0.913 / 0.907
FracAtlas	Dice + BCE (mặc định)	0.727 / 0.713	0.585 / 0.570	10.5 / 10.4	0.913 / 0.897
	Size-conditioned Tversky	0.709 / 0.680	0.561 / 0.530	11.0 / 12.2	0.918 / 0.888
	Focal Dice	0.642 / 0.578	0.493 / 0.425	105.5 / 110.1	0.802 / 0.732

5.11 Các kiểu lỗi (*Failure Modes*)

PGA-UNet vẫn còn mắc lỗi, và các lỗi này không xuất hiện ngẫu nhiên mà lặp lại theo một số khuôn mẫu nhất định. Khi rà soát định tính, chúng tôi nhận thấy Dice thấp thường tập trung ở các tổn thương có hình dạng dài hoặc phân nhánh, các tổn thương nằm ở vùng giải phẫu phức tạp như vai hay xương đòn, hoặc những tổn thương gần như không nổi bật so với phần xương xung quanh. Trong những trường hợp như vậy, một hộp bao phủ tốt cũng không giúp được gì nếu bản thân bằng chứng hình ảnh cục bộ đã quá yếu.




Figure 10: Ca lỗi trên BTXRD (IMG000013, Dice 0.120): prompt phủ đúng tổn thương ở bờ ngực/sườn, nhưng dự đoán của PGA-UNet lại lệch ra chỗ khác. Một hộp bao phủ không sửa được ca mà bản thân bằng chứng ảnh cục bộ đã mơ hồ.

5.12 Tự đánh giá không cần huấn luyện và gợi ý vùng

Dù không cần đến đáp án thật, điểm Q đã trình bày ở Mục III.F vẫn bám khá sát Dice thật của từng prompt (Bảng 15). Tương quan Spearman giữa Q và Dice thật đạt 0.70 (bao phủ) và 0.60 (lệch tâm) trên BTXRD, và 0.65 cùng 0.48 trên FracAtlas. Cả hai chỉ dấu thành phần đều đóng góp thực chất: riêng độ dứt khoát của mask đã đạt Spearman gần 0.4, độ ổn định khi nhích đạt khoảng 0.5 đến 0.6, và khi lấy trung bình hai chỉ dấu, kết quả luôn tốt ít nhất bằng từng chỉ dấu riêng lẻ. Để đối chứng, chúng tôi cũng thử huấn luyện một đầu nhỏ để hồi quy trực tiếp ra Dice; đầu này lại sập về một đầu ra gần như hằng số, Spearman dưới 0.2 trên cả hai bộ dữ liệu, nên không được sử dụng.

Table 15: Tương quan Spearman giữa mỗi chỉ dấu không cần huấn luyện và Dice thật của từng prompt. $Q = \text{mean}(S_{\text{sharp}}, S_{\text{stab}})$.

Chỉ dấu	BTXRD		FracAtlas	
	bao phủ	lệch tâm	bao phủ	lệch tâm
S_{sharp} (độ dứt khoát mask)	0.42	0.39	0.47	0.43
S_{stab} (độ ổn định khi nhích)	0.64	0.56	0.63	0.45
Q	0.70	0.60	0.65	0.48

Đảo ngược lại cách dùng, Q còn có thể xếp hạng 50 hộp ứng viên được lấy mẫu ngẫu nhiên và chỉ giữ lại vài hộp tốt nhất (Bảng 16, Hình 11). Với ít nhất một trong năm hộp đầu, có 67% ảnh BTXRD và 82% ảnh FracAtlas mà hộp đó phủ hơn một nửa tổn thương, và hộp tốt nhất trong năm hộp phủ trung bình lần lượt 0.84 và 0.90 diện tích tổn thương. Nói cho chắc: đây chỉ là công cụ hỗ trợ xem lại thôi, Q không phải xác suất thật, và danh sách này không thay được việc bác sĩ tự kiểm tra lại.

Table 16: Danh sách ngắn vùng ứng viên xếp theo Q , giữ 5 hộp điểm cao nhất trong số 50 hộp không prompt lấy mẫu mỗi ảnh. Độ phủ là tỉ lệ pixel tổn thương nằm trong một hộp; tỉ lệ phủ-đủ đếm các ảnh có hộp tốt nhất trong danh sách phủ hơn nửa tổn thương.

Bộ dữ liệu	Phủ TB	Phủ tốt nhất	Tỉ lệ phủ-đủ
BTXRD	0.52	0.84	66.8%
FracAtlas	0.62	0.90	81.9%




Figure 11: Danh sách ngắn vùng ứng viên trên một ca BTXRD. Năm mươi hộp được lấy mẫu không có prompt, chấm bằng điểm tự đánh giá Q , và năm hộp điểm cao nhất được hiển thị để bác sĩ chấp nhận, chỉnh, hoặc bỏ. Một ca FracAtlas ở phần bổ sung.

Mục VI. Thảo luận (Discussion)

Câu hỏi bài báo đặt ra chưa bao giờ đơn thuần là prompt có ích hay không nói chung. Câu hỏi thật sự là: một khi hộp thô đã thu hẹp việc tìm kiếm, cách mô hình xử lý prompt đó có còn quan trọng hay không? Attention U-Net khi không có hộp trả lời một câu hỏi khác hẳn, và Dice thấp của nó, gần 0.34 trên FracAtlas, chỉ đo phần việc tìm ra tổn thương. Những so sánh thực sự kiểm chứng được thiết kế là khi cùng một hộp được đưa cho một Attention U-Net thuần và cho SAM-Med2D đã fine-tune. Ở cả hai trường hợp, PGA-UNet đều giữ được một khoảng cách: khiêm tốn trên BTXRD, rõ rệt hơn trên FracAtlas, và lớn nhất ở nhóm Bottom-Dice của Attention U-Net cũng như ở các tổn thương nhỏ nhất. Đây đúng là khuôn mẫu có thể kỳ vọng nếu PSG và CAD đang làm tốt vai trò của mình: giữ cho prompt luôn hoạt động xuyên suốt encoder và decoder, để một tín hiệu mờ nhạt không bị mất đi qua downsampling. Kết quả ablation từng thành phần trên một tập chia (Bảng 12) cũng nhất quán với nhận định này, khi prompt Gaussian luôn dẫn trước dưới prompt lệch tâm và trên FracAtlas.

Ngoài kết quả chính, nghiên cứu còn ghi nhận hai kết quả phụ. Thứ nhất, so sánh các hàm loss cho một kết quả âm tính khá rõ ràng: cả size-conditioned Tversky loss lẫn Focal Dice loss đều không giúp ích, thậm chí Focal Dice còn làm mọi thứ tệ hơn hẳn trên FracAtlas, nên chúng tôi vẫn giữ hàm mục tiêu mặc định Dice + BCE. Thứ hai, điểm tự đánh giá cho một kết quả dương tính ở mức vừa phải: Q tương quan với Dice thật ở mức thứ hạng khoảng 0.5 đến 0.7 mà hoàn toàn không cần đến nhãn nào, và nó làm được điều mà một đầu hồi quy học nhỏ không làm được, vì đầu đó rốt cuộc chỉ dự đoán ra một giá trị trung bình. Dù vậy, Q vẫn chỉ là một con số heuristic, chưa được hiệu chuẩn, nên danh sách ứng viên dự đoán từ nó chỉ nên dùng để gợi ý bác sĩ nên nhìn vào đâu trước, chứ không thể thay thế việc tự phát hiện.

Nghiên cứu này cũng có những giới hạn khá cụ thể. Ảnh đầu vào bị resize về một hình vuông cố định, và chính các kết quả theo độ phân giải cho thấy điều đó gây tổn độ chính xác thật sự trên các tổn thương nhỏ nhất. Prompt trong bài đều được vẽ từ nhãn có sẵn, không phải do bác sĩ X-quang trực tiếp vẽ, và protocol giả định người dùng đã tìm ra đúng vùng rồi mới vẽ một hộp phủ lên nó. Trường hợp hộp chỉ phủ một phần, hộp âm, hay hộp sai vùng thì bài này chưa chạm tới. BTXRD và FracAtlas được huấn luyện tách biệt hoàn toàn, không có mô hình chung và không có bước test chéo dataset nào, còn việc tách biệt theo từng bệnh nhân thì không thể xác nhận được từ metadata công khai. Các lần chạy Monte Carlo chỉ cho thấy sự ổn định qua các lần chia, chứ không chứng minh được tính vượt trội. Thí nghiệm ablation hiện vẫn đang trong giai đoạn chuyển từ một lần chia sang nhiều lần chia. Ở vòng này, SAM-Med2D vẫn là mô hình nền tảng nhận prompt duy nhất được dùng làm tham chiếu; việc so sánh với các mô hình y tế nhận prompt mới hơn xin để dành cho sau. Cuối cùng, dù các lợi ích quan sát được khi prompt bị nhiễu loạn khá nhất quán với ý đồ thiết kế ban đầu, chúng vẫn chưa được kiểm chứng bằng cách phân tích trực tiếp ở mức đặc trưng; vì vậy, một khi hoàn tất, thí nghiệm ablation sẽ chỉ nói lên được tính hữu ích của thiết kế như một tổng thể, chứ chưa thể khẳng định chính xác cơ chế nào bên trong nó đang đóng vai trò quyết định.

Mục VII. Kết luận (Conclusion)

Bài báo này trình bày PGA-UNet, một mạng CNN nhẹ có định hướng bằng prompt, dùng cho phân đoạn tương tác tổn thương xương trên ảnh X-quang. Thiết kế của mô hình biến một hộp bao phủ tổn thương do người dùng cung cấp thành một prior không gian dày đặc, rồi tái sử dụng prior này qua PSG ở phía encoder và CAD ở phía decoder. Trên hai bộ dữ liệu BTXRD và FracAtlas, đánh giá dưới cả prompt bao phủ lẫn lệch tâm

có kiểm soát, PGA-UNet luôn vượt qua các baseline quy ước khớp prompt cũng như SAM-Med2D đã fine-tune khi nhận cùng một hộp; khoảng cách này tập trung rõ nhất ở những nơi khâu định vị tự động thất bại và ở những tổn thương nhỏ nhất, trong khi số tham số của mô hình chỉ bằng khoảng 1/92 so với SAM-Med2D. Các thực nghiệm chia lặp lại cho thấy xu hướng này khá ổn định, và một điểm tự đánh giá không cần huấn luyện cũng cho ra một cách xếp hạng độ tin cậy tuy chưa hiệu chuẩn nhưng vẫn dùng được, ngay cả khi không có nhãn thật.

Kết luận này chỉ đúng trong phạm vi protocol đã dùng: hộp mô phỏng quanh tổn thương có nhãn. Nó chưa nói được gì về: phát hiện tự do, hộp sai vùng hay phủ một phần, prompt tự tay bác sĩ vẽ, độ tin cậy đã hiệu chuẩn, khả năng tổng quát theo bệnh nhân, hay việc chuyển sang dataset khác. Trước mắt, chúng tôi sẽ hoàn tất thí nghiệm ablation với nhiều seed, mở rộng đánh giá sang nhiều bộ dữ liệu hơn và hướng tới một mô hình dùng chung thay vì huấn luyện riêng cho từng bộ dữ liệu như hiện tại, đồng thời so sánh thêm với các mô hình y tế nhận prompt gần đây hơn. Về lâu dài, chúng tôi muốn đưa phương pháp gần hơn với điều kiện thực tế: thay các hộp mô phỏng bằng những protocol prompt lỏng và thực tế hơn, bỏ bước resize ảnh về kích thước cố định, và tận dụng thêm thông tin lâm sàng đi kèm để cải thiện cả kết quả phân đoạn lẫn chất lượng vùng gợi ý. Cuối cùng, để giảm chi phí gán nhãn và tiến gần hơn tới một công cụ dùng được trong lâm sàng, hướng đi tiếp theo là học bán giám sát, tận dụng việc vẽ một hộp giới hạn thô nhanh hơn nhiều so với vẽ mask chuẩn theo từng pixel. Chúng tôi muốn khai thác phần lớn dữ liệu chỉ có nhãn hộp rỗng này, kết hợp với một lượng nhỏ mask chuẩn, thay vì đòi hỏi mask chi tiết cho mọi mẫu như hiện tại, cùng với việc biến điểm tự đánh giá thành một tín hiệu đã hiệu chuẩn để dùng cho việc gợi ý vùng nghi ngờ trong một quy trình xem lại lâm sàng thực sự.

Các mục còn lại

Tính sẵn có của dữ liệu (*Data Availability*)

BTXRD và FracAtlas là bộ dữ liệu công khai được trích dẫn trong bài. Bản thảo báo cáo thực nghiệm trên các tập chia train/validation/test ở mức ảnh, suy ra từ hai bộ dữ liệu đó. Mã nguồn và chi tiết cách chia sẽ được công bố cùng gói tái lập kết quả cuối cùng.

Đóng góp của tác giả (*Author Contributions*)

Thông Lức: ý tưởng, phương pháp luận, phần mềm, khảo sát, phân tích chính thức, trực quan hóa, viết bản thảo gốc. **Nguyễn Hữu Bình:** hỗ trợ phần mềm, chuẩn bị dữ liệu, kiểm chứng thực nghiệm, rà soát và biên tập. **Lý Quốc Ngọc:** hướng dẫn, thẩm định, rà soát và biên tập.

Tuyên bố đạo đức (*Ethics Statement*)

Nghiên cứu dùng bộ dữ liệu X-quang công khai đã ẩn danh, không thu thập dữ liệu tiên cứu, không tiếp xúc bệnh nhân, không can thiệp.

Lời cảm ơn (*Acknowledgment*)

Nghiên cứu này được tài trợ bởi Đại học Quốc gia Thành phố Hồ Chí Minh (VNU-HCM) theo Đề tài số A2025-18-03.

[AUTHOR ACTION: cập nhật phần công bố việc dùng AI cho khớp quy trình cuối cùng và chính sách hiện hành của IEEE.]

Tài liệu tham khảo (References, giữ nguyên, không dịch tên bài/tạp chí)

1. Kirillov *et al.*, “Segment Anything,” ICCV 2023.
2. Cheng *et al.*, “SAM-Med2D,” arXiv:2308.16184, 2023.
3. Ronneberger, Fischer, Brox, “U-Net: Convolutional Networks for Biomedical Image Segmentation,” MICCAI 2015.
4. Oktay *et al.*, “Attention U-Net: Learning Where to Look for the Pancreas,” MIDL 2018.
5. Xu, Price, Cohen, Yang, Huang, “Deep Interactive Object Selection,” CVPR 2016.
6. Wang *et al.*, “DeepIGeoS: A Deep Interactive Geodesic Framework for Medical Image Segmentation,” IEEE TPAMI 2019.
7. Yao *et al.*, “A Radiograph Dataset for the Classification, Localization, and Segmentation of Primary Bone Tumors,” Scientific Data 2025.
8. Abedeen *et al.*, “FracAtlas: A Dataset for Fracture Classification, Localization and Segmentation of Musculoskeletal Radiographs,” Scientific Data 2023.
9. Ma *et al.*, “Segment Anything in Medical Images,” Nature Communications 2024.
10. Isensee *et al.*, “nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation,” Nature Methods 2021.
11. Wong, Rakic, Guttag, Dalca, “ScribblePrompt: Fast and Flexible Interactive Segmentation for Any Biomedical Image,” ECCV 2024.
12. Dong *et al.*, “An efficient segment anything model for the segmentation of medical images,” Scientific Reports 2024.
13. Wu *et al.*, “Medical SAM adapter: Adapting segment anything model for medical image segmentation,” Medical Image Analysis 2025.

Tiểu sử tác giả (Biography)

Thông Lúc là sinh viên năm cuối chương trình Cử nhân Khoa học Máy tính, Khoa Công nghệ Thông tin, Trường Đại học Khoa học Tự nhiên, ĐHQG-HCM. Hướng nghiên cứu: thị giác máy tính, deep learning, phân tích ảnh y tế, phân đoạn ảnh, phân đoạn có định hướng prompt tương tác.

Nguyễn Hữu Bình là sinh viên ngành Khoa học Máy tính, Khoa Công nghệ Thông tin, Trường Đại học Khoa học Tự nhiên, ĐHQG-HCM. Hướng nghiên cứu: thị giác máy tính, deep learning, phân đoạn ảnh y tế dùng visual prompt.

Lý Quốc Ngọc: phần tiểu sử và affiliation trong bản gốc vẫn còn placeholder, chưa có nội dung thật.

Hết. File này chỉ để tự đối chiếu ý; không dùng để nộp, không thay thế bản LaTeX gốc *access.tex*.