

Bản đọc tiếng Việt, đối chiếu với access.tex

PGA-UNet: kiến trúc Attention U-Net nhẹ, có định hướng bằng prompt, cho phân đoạn tổn thương xương X-quang tương tác

Bản dịch để tự kiểm tra nội dung, không phải bản nộp

Lưu ý: File này chỉ để đọc và đối chiếu ý với bản tiếng Anh thật (access.tex). Toàn bộ số liệu (Dice, CBL, HD95, số tham số...) giữ nguyên y hệt bản gốc; chỉ phần chữ được dịch. File này nên ở dạng chưa commit (untracked), chỉ dùng cục bộ.

Tóm tắt (Abstract)

Phân đoạn tổn thương xương trên ảnh X-quang là bài toán khó vì tổn thương thường nhỏ, tương phản thấp, và lẫn vào cấu trúc giải phẫu xung quanh về mặt thị giác. Trong bối cảnh đó, thách thức chính thường nằm ở khâu định vị vùng nghi ngờ hơn là tinh chỉnh đường biên. Một hướng thực tế là thu hẹp vùng tìm kiếm trước khi phân đoạn. Chúng tôi hiện thực hóa ý tưởng này theo cách tương tác trực tiếp: bác sĩ cung cấp một hộp giới hạn thô để mô hình dùng làm tín hiệu định hướng không gian.

Chúng tôi đề xuất **PGA-UNet**, một CNN nhẹ có định hướng bằng prompt, chuyển prompt hộp giới hạn thành bản đồ nhiệt Gaussian dạng cao nguyên, điều biến đặc trưng encoder theo prompt qua **Prompt Spatial Gate (PSG)**, và duy trì ảnh hưởng của prompt ở decoder qua **Conditional Attention Decoder (CAD)**. Mục tiêu không chỉ là dùng prompt để chỉ vùng cần phân đoạn, mà còn giữ các đặc trưng liên quan đến tổn thương nhỏ luôn hoạt động xuyên suốt mạng.

Attention U-Net không prompt đóng vai trò tham chiếu tự động, còn SAM-Med2D là tham chiếu khớp prompt. Trên BTXRD và FracAtlas, đánh giá ở các độ phân giải 128, 256, 512 dưới hộp bao phủ và lệch tâm có kiểm soát, phân đoạn không prompt là bài toán khó: Attention U-Net chỉ đạt 0.52 và 0.34 Dice. Với cùng một hộp, PGA-UNet luôn dẫn trước hai baseline quy ước khớp prompt và SAM-Med2D đã fine-tune, biên rộng nhất trên dữ liệu khó hơn là FracAtlas và trên các tổn thương nhỏ nhất, nơi SAM-Med2D đã fine-tune tụt xuống 0.26 đến 0.37 Dice còn PGA-UNet giữ 0.65 đến 0.72. Các lần chia ngẫu nhiên lặp lại cho thấy xu hướng ổn định, và PGA-UNet nhẹ hơn SAM-Med2D khoảng 92 lần về số tham số. Một điểm tính không cần huấn luyện, dựng từ độ dứt khoát của mask và độ ổn định khi nhích prompt, cho một thứ hạng độ tin cậy không cần đáp án dùng được, với tương quan thứ hạng với Dice thật vào khoảng 0.5 đến 0.7.

Vì mọi hộp đều được mô phỏng quanh vùng tổn thương đã gán nhãn, bằng chứng nói về phân đoạn có prompt sau khi đã khu trú có kiểm soát, không phải phát hiện tự do, hộp phủ một phần hay sai vùng, xác suất tin cậy đã hiệu chuẩn, khả năng dùng lâm sàng, tổng quát hóa mức bệnh nhân, hay chuyển giao chéo dataset. Một ablation từng thành phần với nhiều seed vẫn đang chạy.

Từ khóa: ảnh X-quang xương, phân đoạn tương tác, phân đoạn ảnh y tế, học có định hướng bằng prompt, Attention U-Net.

Mục I. Giới thiệu (Introduction)

Ảnh X-quang xương được dùng rộng rãi trong sàng lọc, hỗ trợ chẩn đoán, và theo dõi nhờ tốc độ, chi phí thấp, và khả năng tiếp cận. Tuy nhiên, phân đoạn tổn thương vẫn khó khi tổn thương rất nhỏ, tương phản mờ, hoặc bị che một phần bởi giải phẫu xung quanh. Trong các trường hợp này, một thách thức chính nằm ở khâu định vị: trước khi tinh chỉnh đường biên, mô hình phải xác định được vùng nghi ngờ trong toàn ảnh.

Đây là lý do phân đoạn tổn thương nhỏ hiếm khi chỉ là bài toán vẽ đường biên. Khi tổn thương chỉ chiếm một phần rất nhỏ, tìm kiếm trên toàn ảnh vừa kém hiệu quả vừa dễ sai. Một hướng tự nhiên là thu hẹp không gian tìm kiếm trước, rồi phân đoạn trong vùng đã thu hẹp. Các phương pháp tự động hoàn toàn cố học quá trình này một cách nội tại. U-Net và Attention U-Net là các mô hình đại diện của hướng này, nhưng vẫn buộc mạng tự định vị và phân đoạn tổn thương hoàn toàn từ đầu, không có trợ giúp nào từ bên ngoài.

Một hướng khác là lấy chỉ dẫn về vùng quan tâm từ nguồn bên ngoài. Trong thực hành lâm sàng, bác sĩ có thể dễ dàng vẽ một hộp giới hạn thô quanh vùng nghi ngờ, điều mà mô hình tự động khó làm đáng tin cậy với tổn thương rất nhỏ. Theo nghĩa đó, prompt hộp giới hạn không chỉ là tiện ích tương tác, mà là một cách thực tế để đưa tri thức không gian vào quy trình trước khi phân đoạn chi tiết. Các phương pháp phân đoạn tương tác theo prompt lớn lên từ ý này, từ click và scribble đến các mô hình nền tảng nhận prompt gần đây như SAM và SAM-Med2D.

Tuy vậy, với bài toán ở đây, một vấn đề vẫn để ngỏ. Một khi prompt đã xác định vùng quan tâm, prompt chỉ nên là một ràng buộc vị trí để sinh mask, hay cần tiếp tục định hình việc trích xuất đặc trưng để tín hiệu tổn thương mờ nhạt sống sót qua downsampling? Sự khác biệt này quan trọng nhất với tổn thương rất nhỏ, nơi một sai lệch không gian nhỏ có thể ảnh hưởng đáng kể đến kết quả.

Chúng tôi giải quyết câu hỏi đó bằng PGA-UNet, một CNN nhẹ có định hướng bằng prompt, trong đó box prompt được xem như một prior không gian có cấu trúc thay vì một kênh đầu vào phụ. Prompt được mã hóa thành bản đồ nhiệt Gaussian dạng cao nguyên, điều biến vào đặc trưng encoder qua Prompt Spatial Gate (PSG), và tái sử dụng ở decoder qua Conditional Attention Decoder (CAD). Thiết kế này nhằm giữ các đặc trưng tổn thương được định hướng bởi prompt luôn hoạt động xuyên suốt mạng, thay vì chỉ giới hạn phân đoạn trong một vùng hộp đã cho.

Góc nhìn này cũng định hình cách đọc thực nghiệm. Vì Attention U-Net không nhận chỉ dẫn không gian nào từ bác sĩ, vai trò của nó chỉ là cho thấy bài toán khó đến mức nào khi việc khu trú phải hoàn toàn tự động. SAM-Med2D, ngược lại, được chọn làm so sánh trực tiếp vì nhận cùng đầu vào là prompt hộp giới hạn. Câu hỏi trọng tâm vì vậy không phải prompt có hữu ích chung chung hay không, mà là liệu một kiến trúc nhẹ có khai thác prompt thô của bác sĩ hiệu quả hơn bằng cách bảo toàn tín hiệu tổn thương yếu, thay vì chỉ coi prompt như một ràng buộc không gian.

Đóng góp chính (Main contributions)

- Đề xuất PGA-UNet, một kiến trúc nhẹ có định hướng bằng prompt cho phân đoạn tổn thương xương trên ảnh X-quang tương tác.
- Thiết kế cơ chế điều kiện hóa prompt kết hợp prompt Gaussian dạng cao nguyên, Prompt Spatial Gate (PSG) phía encoder, và Conditional Attention Decoder (CAD) phía decoder.
- Xây dựng khung huấn luyện ngoại tuyến và suy luận tương tác trực tuyến, với định nghĩa toán học rõ ràng cho mã hóa prompt, cổng hóa encoder, và điều kiện hóa decoder.

- Đánh giá phương pháp trên BTXRD và FracAtlas dưới các điều kiện prompt bao phủ và lệch tâm, so sánh với một Attention U-Net tự động, hai baseline Attention U-Net khớp prompt nhận cùng hộp, và SAM-Med2D, dùng Dice, độ đo định vị theo tâm (CBL), và HD95, kèm Monte Carlo cross-validation và đo hiệu năng tính toán.
- Cho thấy, qua phân tích tổn thương nhỏ và một lát cắt độ khó do Attention U-Net định nghĩa, rằng lợi ích của xử lý có điều kiện theo prompt tập trung ở nơi khu trú tự động thất bại và ở nơi tổn thương nhỏ nhất.
- Mô tả một điểm tự đánh giá không cần huấn luyện, dựng từ độ đứt khoát của mask và độ ổn định khi nhích prompt, cho một thứ hạng độ tin cậy không cần đáp án dùng được và có thể lọc ra một danh sách ngắn vùng nghi ngờ cho bác sĩ xem lại.

Mục II. Công trình liên quan (*Related Work*)

Phân đoạn tổn thương nhỏ trong ảnh y tế từ lâu bị ràng buộc bởi một thực tế đơn giản: trước khi phân đoạn tốt một mục tiêu rất nhỏ, mô hình phải thu hẹp được vùng cần nhìn. Trong hướng tự động hoàn toàn, việc thắt chặt này được học ngầm bên trong mạng. U-Net đặt nền cho kiến trúc encoder-decoder đa tỉ lệ kinh điển trong phân đoạn y sinh, còn Attention U-Net sau đó thêm cổng attention trên skip connection để phía decoder lọc bỏ phản hồi không gian không liên quan chọn lọc hơn. Các pipeline tự cấu hình như nnU-Net đẩy hướng này xa hơn bằng cách tự thích ứng tiền xử lý, hình dạng mạng, và lịch huấn luyện cho từng dataset. Các mô hình này nâng đáng kể chất lượng phân đoạn tự động, nhưng vẫn giả định mạng phải tự khu trú và vẽ mask chỉ từ ảnh đầu vào, không có gợi ý nào về vị trí tổn thương.

Phân đoạn y tế tương tác phát triển song song, xuất phát từ quan sát rằng chỉ một phần hướng dẫn từ người dùng cũng đơn giản hóa đáng kể bài toán. Các phương pháp sớm dùng click, scribble, và geodesic cue; các nghiên cứu sau thêm bounding box như một prompt thô, nhanh. Các mô hình tương tác gần đây như ScribblePrompt xử lý nhiều loại prompt trong một khung và trên nhiều dataset y sinh. Về bản chất, các phương pháp này chuyển một phần gánh nặng khu trú từ mô hình sang người dùng. Với tổn thương X-quang rất nhỏ, sự chuyển giao đó đặc biệt có giá trị: bác sĩ thường chỉ ra được vùng nghi ngờ một cách thô ngay cả khi hệ thống tự động khó tìm ra nó đáng tin cậy trong toàn ảnh.

Các mô hình nền tảng nhận prompt đầy ý này đi xa hơn. SAM làm phân đoạn theo prompt trở nên tổng quát, SAM-Med2D và MedSAM đưa nó vào y tế, và các biến thể adapter như EMedSAM và Med-SA giảm chi phí chuyên biệt hóa các mô hình đó cho dữ liệu y tế. Chúng linh hoạt, nhưng chủ yếu tiêu thụ prompt ở mask decoder, mang một backbone lớn, và không cái nào được tinh chỉnh cho một tác vụ X-quang cụ thể. Điều đó để ngỏ một câu hỏi với tổn thương xương rất nhỏ: một khi prompt đã khu trú vùng, prompt chỉ nên đánh dấu nơi đặt mask, hay còn định hình việc trích xuất đặc trưng để tín hiệu tổn thương yếu sống sót qua downsampling?

Câu hỏi đó là nơi bài báo này bắt đầu. Trên ảnh X-quang xương thang xám, biết tổn thương nằm khoảng đâu chỉ giải quyết được một phần; phần khó hơn là giữ được bằng chứng mờ nhạt trong khi lọc bỏ nhiễu sau khi không gian tìm kiếm đã thu hẹp. Một CNN nhẹ có định hướng bằng prompt có thể tốt hơn nhờ giữ prompt luôn sống từ tầng encoder đầu tiên đến tầng decoder cuối, thay vì dùng một lần rồi để nó phai đi. Chúng tôi nghiên cứu bối cảnh đó trực tiếp, với SAM-Med2D làm tham chiếu nhận prompt; một so sánh rộng hơn với các mô hình y tế nhận prompt mới hơn được để dành cho công việc sau.

Mục III. Phương pháp (Method)

3.1 Khung offline và online (Offline and Online Framework)

Hệ thống có hai giai đoạn. Ở giai đoạn offline, mô hình được huấn luyện trên ảnh X-quang đi kèm đa giác tổn thương. Mỗi đa giác được chuyển thành một prompt huấn luyện bằng cách sinh một hộp giới hạn mô phỏng, rồi biến hộp đó thành bản đồ nhiệt cao nguyên làm mượt Gaussian. Mạng học ánh xạ cặp (ảnh, prompt) sang mask tổn thương nhị phân. Ở giai đoạn online, người dùng vẽ một hộp giới hạn thô quanh vùng nghi ngờ trên ảnh mới; cùng quy trình dựng prompt được áp dụng, và mô hình đã huấn luyện dự đoán mask cuối cùng.

Điểm khác biệt là chỗ prompt sống. Nó không phải một đầu vào phụ được tiêu thụ ở lớp đầu tiên rồi quên đi. Nó trở thành một prior không gian dày đặc, luôn hoạt động xuyên suốt encoder và decoder, và đó là điều nên giúp ích khi hộp thô, hơi lệch tâm, hoặc bọc quanh một tổn thương rất nhỏ.

Một minh họa tương tác của giai đoạn online được cho ở Hình 1: người dùng vẽ một hộp trên ảnh X-quang, và mô hình trả về mask cùng với điểm dừng prompt của CAD và điểm tự đánh giá ở Mục III.F, cả hai đều không cần đáp án.

[Hình 1. *images/demo/demo_segmentation_btprd.png*]: Minh họa tương tác giai đoạn online trên một ca BTXRD. Bác sĩ vẽ một hộp trên canvas bên trái; panel bên phải phủ mask dự đoán, và panel bên dưới báo cáo các độ đo tham chiếu cùng điểm dừng prompt của CAD và điểm tự đánh giá Q , đều không cần đáp án. Một ca FracAtlas theo cùng bố cục ở phần bổ sung.

3.2 Bài toán (Problem Setting)

Cho ảnh X-quang xám $\mathbf{I} \in \mathbb{R}^{H \times W}$ và hộp giới hạn $\mathbf{B}$ do người dùng cung cấp, mục tiêu là dự đoán mask tổn thương nhị phân $\mathbf{M}$. Gọi $\mathbf{H}(\mathbf{B})$ là bản đồ nhiệt prompt suy ra từ hộp. PGA-UNet dự đoán

$$\hat{\mathbf{M}} = \mathbf{1} [f_{\text{PGA}}(\mathbf{I}, \mathbf{H}(\mathbf{B}); \theta) \geq 0.5]. \quad (1)$$

3.3 Biểu diễn prompt (Prompt Representation)

Prompt đầu vào không được mã hóa như một hình chữ nhật nhị phân cứng. Thay vào đó, phần bên trong hộp được rasterize thành bản đồ cao nguyên ở độ phân giải ảnh gốc, biên được làm mềm bằng kernel Gaussian 31×31 cố định, trước khi bản đồ nhiệt được resize và pad xuống độ phân giải vuông mục tiêu cùng với ảnh. Kernel không đổi theo độ phân giải mục tiêu (256×256 hay 512×512): áp dụng một lần ở độ phân giải gốc, trước khi downsample, giữ độ mờ hiệu dụng nhất quán so với khung ảnh vuông mà mạng cuối cùng nhìn thấy. Cao nguyên chỉ phủ đúng vùng hộp (đã mở rộng nếu có), không có biên tối thiểu thêm vào; việc bao phủ vùng quan tâm do bước mở rộng hộp bên dưới đảm bảo, không phải do một bước biên riêng.

Khi đánh giá, prompt được kiểm thử ở hai chế độ cố định. Prompt bao phủ (*center_zoom*) phóng to hộp tổn thương bo sát từ chính tâm của nó theo hệ số cố định 3.0. Prompt lệch tâm (*center_shift*) áp dụng cùng độ phóng to rồi dịch hộp theo một tỉ lệ của kích thước hộp bo sát, chặn trên bởi *shift_ratio*=0.5, sau đó hộp được mở rộng lại nếu cần để vẫn chứa trọn tổn thương. Ở thời điểm test, độ dịch này là xác định theo từng tổn thương, gieo hạt từ chỉ số mẫu, nên mọi mô hình được đánh giá trên đúng cùng các hộp lệch tâm; khi huấn luyện, độ dịch được lấy ngẫu nhiên lại ở mỗi vòng lặp. Mỗi bộ dữ liệu và độ phân giải huấn luyện một mô hình bằng *center_mixed*, chọn *center_shift* với xác suất 0.8 và *center_zoom* với xác suất 0.2, và hai điều kiện được chấm riêng lúc test. Phạm vi bài toán giả định người dùng đã xác định vùng nghi ngờ và cung cấp

một hộp có chủ đích bao phủ tổn thương; hộp phủ một phần, hộp âm, và hộp sai vùng nằm ngoài protocol có kiểm soát này, cũng như câu hỏi riêng về việc bác sĩ có tự tìm đúng vùng hay không.

Gọi (x_1, y_1, x_2, y_2) là hộp tổn thương bao sát, $w = x_2 - x_1$ và $h = y_2 - y_1$. Hộp bao phủ mô phỏng dùng phép phóng to từ tâm cố định nêu trên trong cả huấn luyện và đánh giá. Hộp lệch tâm dùng cùng hộp đã phóng to và áp dụng quy tắc dịch xác định lúc test cài trong `dataset.py`, vẫn giữ bao phủ tổn thương. Hệ số phóng to, tỉ lệ dịch, và kích thước kernel Gaussian được chọn từ thí nghiệm sơ bộ trên dữ liệu train và validation rồi khóa lại; tập test không được dùng cho bất kỳ lựa chọn protocol hay siêu tham số nào. Chúng được trình bày là các giá trị protocol cố định, không phải cấu hình tối ưu toàn cục. Việc mô phỏng này không thay thế prompt do bác sĩ X-quang vẽ, nhưng cho một cách có kiểm soát để đo độ nhạy với sai lệch prompt đã định nghĩa.

Về thuật toán, dựng prompt gồm 3 bước: (1) suy ra hộp tổn thương từ đa giác gán nhãn hoặc input người dùng và mở rộng như trên, (2) rasterize vùng đã mở rộng thành mask cao nguyên ở độ phân giải ảnh gốc, (3) làm mượt biên cao nguyên bằng kernel Gaussian cố định trước khi resize xuống độ phân giải mục tiêu. Trình tự này tránh sự phụ thuộc vào biên cứng của một hộp nhị phân trong khi vẫn giữ một prior không gian rõ ràng.

3.4 Prompt Spatial Gate (PSG)

Gọi $\mathbf{x}^l$ là bản đồ đặc trưng encoder ở tầng l . PSG điều biến nó bằng bản đồ attention suy ra từ prompt $\mathbf{A}_{\text{PSG}}^l$:

$$\tilde{\mathbf{x}}^l = \mathbf{x}^l \odot \left(1 + \alpha_{\text{PSG}}^l \mathbf{A}_{\text{PSG}}^l\right), \quad (2)$$

trong đó $\odot$ là nhân theo từng phần tử, α_{PSG}^l là tham số học được, khởi tạo 0.1 và giới hạn trong $[0, 1]$. Dạng residual giữ nguyên luồng đặc trưng gốc trong khi nhấn mạnh vùng liên quan đến prompt.

3.5 Conditional Attention Decoder (CAD)

CAD mở rộng attention của decoder bằng cách điều kiện hóa cổng skip theo đặc trưng đã mã hóa prompt. Gọi $\mathbf{g}^l$ là đặc trưng cổng decoder, $\mathbf{p}_{\text{enc}}^l$ là mã hóa prompt cùng tỉ lệ. Cổng đã điều kiện hóa:

$$\mathbf{g}'^l = \mathbf{g}^l + c^l \alpha_{\text{CAD}}^l w_l \mathbf{p}_{\text{enc}}^l, \quad (3)$$

với c^l là hệ số dùng prompt suy ra từ decoder, α_{CAD}^l học được, w_l là hệ số độ sâu cố định. Thiết kế này giúp decoder vẫn bám prompt ngay cả khi hộp không căn giữa hoàn hảo.

Bộ mã hóa prompt trong CAD dùng hai tích chập 3×3 với instance normalization và ReLU. Hệ số dùng prompt c^l được tạo bằng global average pooling, sau đó tích chập 1×1 và sigmoid. Nó được tính bên trong cổng từ mã hóa prompt và chỉ dùng để nhân với số hạng prompt ở tầng đó; nó không được xuất ra hay phân tích như một đầu ra riêng của mô hình trong bài này. Hệ số độ sâu decoder cố định $\{1.0, 0.7, 0.4, 0.2\}$ từ sâu đến nông. Với feature scale 4, độ rộng kênh là $\{16, 32, 64, 128, 256\}$ từ tầng encoder nông nhất đến bottleneck, và mô hình đầy đủ có khoảng 2.95 triệu tham số. Các giá trị protocol này được chọn từ thí nghiệm sơ bộ trên dữ liệu train và validation và giữ cố định cho đánh giá chính, với tập test không tham gia bất kỳ việc tinh chỉnh nào; không có tuyên bố về tính tối ưu. Hệ số trộn CAD được tham số hóa qua sigmoid, khởi tạo gần 0.3.

Tóm lại, phương pháp gồm 4 bước: (1) tiền xử lý ảnh và prompt về cùng độ phân giải vuông, (2) mã hóa prior không gian liên quan đến prompt bằng PSG ở encoder, (3) lan truyền ngữ cảnh có điều kiện theo prompt qua CAD ở decoder, (4) dự đoán mask tổn thương nhị phân cuối cùng. Ý nghĩa khoa học: thông tin prompt vừa được

làm mềm về không gian, vừa được tái sử dụng liên tục, chứ không chỉ tiêm vào một lần rồi mất dần.

[Hình 2. *images/architecture/architecture_pga_unet.png*]: Tổng quan PGA-UNet. Thông tin prompt suy ra từ hộp giới hạn được tiêm vào đặc trưng encoder qua PSG, và tái sử dụng ở skip-attention của decoder qua CAD.

3.6 Điểm tự đánh giá không cần huấn luyện (*Training-Free Self-Assessment Score*)

PGA-UNet cũng trả về một số vô hướng Q ước lượng, không cần đáp án, một dự đoán đáng tin đến đâu. Không có gì trong Q được học. Nó được đọc từ chính đầu ra của mô hình lúc suy luận, là trung bình của hai chỉ dấu.

Chỉ dấu thứ nhất, S_{sharp} , đo độ dứt khoát của mask dự đoán. Gọi p là bản đồ xác suất sigmoid và $\Omega = \{p > 0.5\}$ là vùng dương dự đoán. Khi đó

$$S_{\text{sharp}} = \text{clip}_{[0,1]} \left(\frac{1}{|\Omega|} \sum_{u \in \Omega} (2p(u) - 1) \right). \quad (4)$$

Một mask tự tin với xác suất gần một sẽ đạt gần một; một mask có nhiều pixel gần ngưỡng quyết định sẽ thấp hơn.

Chỉ dấu thứ hai, S_{stab} , đo độ ổn định khi nhiễu loạn prompt. Hộp được nhích ngẫu nhiên K lần với một độ dịch và co giãn nhỏ, mô hình chạy lại cho từng hộp nhích, và S_{stab} là IoU trung bình giữa mask nhị phân gốc $\hat{\mathbf{M}}$ và các mask nhích $\hat{\mathbf{M}}_k$:

$$S_{\text{stab}} = \frac{1}{K} \sum_{k=1}^K \text{IoU}(\hat{\mathbf{M}}, \hat{\mathbf{M}}_k). \quad (5)$$

Một dự đoán gần như không đổi khi hộp dịch nhẹ được coi là đáng tin hơn một dự đoán sập hoặc trôi.

Điểm cuối là $Q = \frac{1}{2}(S_{\text{sharp}} + S_{\text{stab}})$, với $K = 6$, độ dịch tối đa 0.12 cạnh hộp, và hệ số co giãn trong ± 0.10 . Q là một tín hiệu xếp hạng theo heuristic, không phải xác suất đã hiệu chuẩn: giá trị 0.7 không có nghĩa xác suất 70% mask đúng.

Cùng điểm này được tái dùng để lọc ra một danh sách ngắn vùng nghi ngờ khi không có prompt. Một tập hộp được lấy mẫu với kích thước và vị trí thay đổi, mỗi hộp được chấm bằng Q , và vài hộp điểm cao nhất được trả về để bác sĩ chấp nhận, chỉnh, hoặc bỏ. Đây là công cụ hỗ trợ xem lại, không phải một bộ phát hiện tự động.

Mục IV. Thiết lập thực nghiệm (*Experimental Setup*)

4.1 Bộ dữ liệu (*Datasets*)

Đánh giá trên hai bộ dữ liệu X-quang xương công khai. BTXRD là bộ dữ liệu u xương nguyên phát, có nhãn đa giác cho phân loại, định vị, phân đoạn. Tập chia BTXRD: 1.493/187/187 ảnh, 1.848/238/232 đa giác tổn thương cho train/validation/test. FracAtlas là bộ dữ liệu gãy xương có nhãn phân loại, định vị, phân đoạn. Sau làm sạch và chuẩn hóa đa giác, tập chia FracAtlas: 573/72/72 ảnh, 730/95/92 đa giác tổn thương.

Việc chia tách ở mức ảnh, mọi đa giác của cùng một ảnh nằm cùng một tập. Metadata công khai không đủ để xác minh tách biệt nghiêm ngặt theo bệnh nhân, nên về nguyên tắc các ảnh của cùng một bệnh nhân có thể rơi vào các tập khác nhau; chúng tôi coi đây là một hạn chế của đánh giá. Mỗi đa giác được coi là một mẫu tổn thương có thể prompt riêng khi huấn luyện. Khi đánh giá ở mức ảnh, nếu một ảnh có nhiều tổn thương, mô hình chạy riêng cho từng hộp, rồi hợp bản đồ xác suất bằng max theo

từng pixel trước khi ngưỡng hóa ở 0.5. Mask ground-truth được hợp bằng union trên cùng một ảnh.

Ảnh đầu vào được resize đẳng hướng giữ tỉ lệ và pad về hình vuông 256×256 hoặc 512×512 . Ảnh, mask, và bản đồ prompt đều qua cùng phép tiền xử lý hình học này.

4.2 Chi tiết huấn luyện (*Training Details*)

Tất cả mô hình CNN cài đặt bằng PyTorch, huấn luyện trên GPU NVIDIA Tesla T4 16GB. PGA-UNet và Attention U-Net huấn luyện riêng cho từng bộ dữ liệu và từng độ phân giải. Nói cách khác, bài báo nghiên cứu một họ kiến trúc chung, cài đặt thành các mô hình riêng với bộ tham số riêng cho BTXRD và FracAtlas, chứ không phải một mô hình duy nhất huấn luyện chung trên cả hai. Optimizer AdamW, learning rate 10^{-4} , weight decay 10^{-4} . Loss là tổng của binary cross-entropy và Dice loss. Như một phép thử thăm dò xuất phát từ kích thước nhỏ của mục tiêu, PGA-UNet còn được huấn luyện thêm ở 512×512 với số hạng Dice thay bằng một size-conditioned Tversky loss và, trong một lần chạy riêng, bằng một Focal Dice loss, mọi cài đặt khác giữ nguyên; hai phép thay thế loại trừ lẫn nhau và chỉ được báo cáo sau như một đối chứng âm về hàm mục tiêu. Batch size 4, tối đa 150 epoch, early stopping với patience 15. Mọi thí nghiệm chính và ablation dùng seed huấn luyện cố định 22120196, gieo hạt cho Python, NumPy, và PyTorch trên cả CPU và CUDA. Tiêu chí chọn mô hình chính là Dice sau merge theo ảnh trên tập validation dưới điều kiện center_shift.

Augmentation lúc huấn luyện gồm lật ngang và xoay ngẫu nhiên trong $\pm 15^\circ$. Cài đặt còn áp dụng prompt dropout hoặc nhiễu prompt cho một phần các bước huấn luyện, để giảm phụ thuộc quá mức vào một prompt lý tưởng. PGA-UNet được huấn luyện bằng center_mixed, chọn center_shift với xác suất 0.8 và center_zoom với xác suất 0.2. Các prompt được mô phỏng từ vùng tổn thương gán nhãn để cho một protocol phân đoạn có prompt có kiểm soát. Bài báo vì vậy nên được đọc như một nghiên cứu dưới hộp mô phỏng bao phủ quanh tổn thương do người dùng xác định, không phải một đánh giá phát hiện tổn thương tự do hay hộp do bác sĩ vẽ hoàn toàn thực tế. Với so sánh SAM-Med2D đã fine-tune, bộ mã hóa ảnh tiền huấn luyện được đóng băng trừ các lớp Adapter nhẹ, còn bộ mã hóa prompt và bộ giải mã mask được cập nhật đầy đủ trên từng bộ dữ liệu theo cùng giao thức chia tách. SAM-Med2D được fine-tune chỉ bằng hộp, dùng cùng protocol bao phủ và lệch tâm phóng từ tâm như PGA-UNet; nhánh point prompt và tinh chỉnh điểm lập được tắt. Cách dựng hộp này khác với việc lấy mẫu nhiễu ngẫu nhiên get_boxes_from_mask của nhóm tác giả SAM-Med2D gốc, ở đây không dùng. Validation lúc fine-tune SAM-Med2D và tập test cuối cùng đều báo cáo riêng hai điều kiện prompt, batch size 4, tối đa 150 epoch, early stopping patience 30, learning rate 10^{-5} . Giao thức khớp làm giảm khác biệt do phân phối prompt và độ phân giải, nhưng không loại bỏ khác biệt về quy mô mô hình, khởi tạo, hay tối ưu hóa. Thực nghiệm ổn định bổ sung dùng Monte Carlo cross-validation, tức chia tách ngẫu nhiên lặp lại ở mức ảnh, không phải k-fold không chồng lấn nghiêm ngặt. Các thực nghiệm Monte Carlo giữ seed huấn luyện cố định ở 22120196 và chỉ thay đổi seed chia tách qua 1, 2, 3, 4.

Các checkpoint huấn luyện cũng chứa một đầu hồi quy chất lượng phụ trợ nhỏ, được huấn luyện chung để dự đoán Dice của từng mẫu. Nó được detach khỏi nhánh phân đoạn và không ảnh hưởng đến mask dự đoán. Đầu ra của nó không được dùng trong bài này; thay vào đó dùng điểm tự đánh giá ở Mục III.F, và Mục V nói rõ lý do.

Hai chi tiết đánh giá quan trọng. Thứ nhất, bản thân việc dựng prompt không phụ thuộc độ phân giải: bản đồ cao nguyên được dựng và làm mượt bằng kernel Gaussian 31×31 cố định ở độ phân giải ảnh gốc, rồi mới resize và pad xuống 256×256 hoặc 512×512 cùng ảnh, nên cùng một độ mờ tuyệt đối bị nén khác nhau ở hai độ phân giải mục tiêu chứ không được tham số hóa riêng. Thứ hai, các thực nghiệm Monte Carlo

là bằng chứng ổn định bổ sung, không thay thế cho tập chia train/validation/test cố định dùng trong các bảng chính.

4.3 Baseline và độ đo (*Baselines and Metrics*)

PGA-UNet được so với Attention U-Net làm baseline tự động chính và với SAM-Med2D làm baseline có prompt chính. Attention U-Net huấn luyện không prompt, dùng để đặc trưng hóa bài toán khó đến mức nào khi khu trú phải hoàn toàn tự động. SAM-Med2D được đánh giá ở 256×256 , dạng đã fine-tune, cùng tập chia và cùng hộp prompt như PGA-UNet, khiến nó là so sánh khớp prompt chính.

Để tách bạch xem lợi thế của PGA-UNet đến từ kiến trúc hay chỉ từ việc có prompt hộp, chúng tôi bổ sung hai baseline quy ước khớp prompt, cùng khung Attention U-Net, nhận đúng hộp prompt mà PGA-UNet nhận, nhưng không có bản đồ nhiệt Gaussian, PSG, hay CAD của PGA-UNet. Attention U-Net + kênh prompt ghép bản đồ nhiệt prompt làm channel đầu vào thứ hai, dự đoán trên toàn ảnh qua một decoder skip-connection thuận. Attention U-Net trên vùng crop theo prompt thu hẹp trường nhìn của mạng: ảnh đầu vào được crop theo hộp prompt trước khi resize về độ phân giải đầu vào của mô hình, Attention U-Net thuận dự đoán mask chỉ trên vùng crop đó, rồi kết quả được dán lại vào khung ảnh đầy đủ để đánh giá. Cả hai baseline đều huấn luyện dưới cùng giao thức hộp bao phủ và lệch tâm như PGA-UNet, nên khoảng cách còn lại phản ánh kiến trúc chứ không phải một prompt không công bằng. So sánh chéo mô hình dùng các độ đo full-frame đã dán lại cho baseline prompt-crop, không phải các giá trị chẩn đoán trong khung crop.

Bài báo nhấn mạnh Dice, CBL, và HD95, trong khi mã nguồn và báo cáo xuất ra còn ghi IoU, precision, và recall. Với tâm mask dự đoán (x_p, y_p) , tâm ground-truth (x_g, y_g) , và đường chéo D_{GT} của hộp ground-truth, CBL được định nghĩa:

$$\text{CBL} = \max \left(0, 1 - \frac{\sqrt{(x_p - x_g)^2 + (y_p - y_g)^2}}{D_{GT}} \right). \quad (6)$$

HD95 tính từ khoảng cách biên hai chiều. Nếu cả hai mask đều rỗng, HD95 = 0. Nếu chỉ một mask rỗng, HD95 = độ dài cạnh ảnh S (256 hoặc 512 pixel). Không loại bỏ mẫu nào. Với các so sánh xuyên độ phân giải, HD95 còn được báo cáo ở dạng chuẩn hóa $\text{HD95}/(\sqrt{2}S)$, vì khoảng cách pixel thô không so sánh được qua các khung 128, 256, 512. Một số so sánh nhóm phụ trộn mô hình huấn luyện ở 256×256 và 512×512 được chấm trong một khung 512×512 chung: dự đoán 256×256 được upsample trước khi chấm, nên mọi mô hình được đo trên đúng cùng mask ground-truth chứ không phải trong khung gốc của riêng nó.

Với điểm tự đánh giá không cần huấn luyện, mỗi prompt tổn thương cho một điểm Q và Dice thật đã ngưỡng hóa của chính mask dự đoán của nó; chúng tôi báo cáo tương quan Pearson và Spearman giữa hai đại lượng, riêng cho điều kiện bao phủ và lệch tâm. Với danh sách vùng ứng viên, mỗi ảnh test lấy 50 hộp với cạnh phân bố đều trong $[0.15, 0.55]$ của khung, chấm mỗi hộp bằng Q , giữ ba và năm hộp điểm cao nhất, và chấm một hộp được giữ theo độ phủ, tỉ lệ pixel tổn thương ground-truth nằm trong nó; không có mask dự đoán nào tham gia vào độ đo độ phủ này.

4.4 Phạm vi phân tích (*Scope of Analysis*)

Bài báo tập trung vào bản thân phân đoạn có định hướng prompt. Một tầng phân loại sàng lọc tổn thương đã được khảo sát riêng và không thuộc bài này. Điểm tự đánh giá và danh sách vùng ứng viên được báo cáo như các phân tích phụ trợ với phạm vi hẹp có chủ đích: Q là một tín hiệu xếp hạng heuristic chứ không phải xác suất đã hiệu chuẩn, và danh sách ngắn là một công cụ hỗ trợ xem lại chứ không phải một bộ phát

hiện tự động. Để giữ bài gọn, chỉ giữ các phân tích nhóm phụ hỗ trợ trực tiếp nhất cho luận điểm chính: vai trò của khu trú theo prompt, độ nhạy với dịch prompt có kiểm soát đã định nghĩa, và hiệu quả trên tổn thương rất nhỏ. Tập con tổn thương nhỏ được định nghĩa cho mỗi bộ dữ liệu là 50 ảnh test có tổng diện tích tổn thương nhỏ nhất. Với so sánh ba độ phân giải trên tổn thương nhỏ, cùng tập stem ảnh này được giữ cố định và đánh giá ở 128, 256, 512; dự đoán và ground-truth được merge ở mức ảnh tại mỗi độ phân giải, HD95 được báo cáo ở cả pixel native lẫn dạng chuẩn hóa trên, và mức tụt được báo cáo so với kết quả 512. Hộp phủ một phần, hộp âm, và hộp sai vùng nằm ngoài phạm vi bài toán và không dùng để ủng hộ hay bác bỏ các tuyên bố của bài.

Mục V. Kết quả (Results)

Trừ khi nói khác, mọi bảng báo cáo số theo protocol hiện tại: huấn luyện center_mixed với 80% center_shift và 20% center_zoom, 150 epoch, chọn mô hình theo Dice validation merge ở mức ảnh dưới center_shift, và đánh giá test merge ở mức ảnh. Hai điều kiện prompt test, bao phủ và lệch tâm, luôn báo cáo riêng. Nghiên cứu ablation ở Mục V.H là ngoại lệ duy nhất và vẫn đang được chạy lại với nhiều seed.

5.1 Kết quả chính giữa các bộ dữ liệu và độ phân giải

PGA-UNet được huấn luyện từ đầu ở 128×128 , 256×256 , và 512×512 trên từng bộ dữ liệu, cho sáu mô hình. Bảng 2 liệt kê Dice và CBL của chúng dưới hai điều kiện prompt.

Độ phân giải cao hơn giúp ở mọi bước. Dice theo thứ tự $512 > 256 > 128$ trên cả hai bộ dữ liệu và cả hai điều kiện prompt, và FracAtlas được lợi nhiều hơn, phù hợp với các vết gãy mảnh mất tỉ lệ chi tiết lớn hơn khi ảnh thu nhỏ. HD95 pixel thô không so sánh được qua các khung, nên chúng tôi chuẩn hóa nó thành $HD95/(\sqrt{2}S)$. Chuẩn hóa rồi, sai số biên giữ ở gần 0.03 qua các độ phân giải BTXRD và thực ra giảm trên FracAtlas, từ khoảng 0.044 xuống 0.015, nên nó không xấu đi khi khung lớn lên. Mỗi mô hình chỉ được đánh giá trên chính bộ dữ liệu của nó; không có tuyên bố chuyển giao chéo dataset.

5.2 So sánh với Attention U-Net tự động và khớp prompt

Bị bỏ mặc phải tự tìm tổn thương, Attention U-Net chỉ đạt Dice 0.517 trên BTXRD và 0.342 trên FracAtlas ở 512×512 , với HD95 vượt 120 pixel trên cả hai (Bảng 3). Con số đó không phải một phán quyết về kiến trúc, vì mô hình này không hề thấy hộp; nó đo việc khu trú tự động khó đến đâu, đúng bước mà prompt loại bỏ.

Đưa cùng một hộp cho một Attention U-Net thuần thì bức tranh đổi khác nhưng khoảng cách vẫn còn. Trên BTXRD, PGA-UNet dẫn trước biến thể kênh prompt 0.022 Dice ở prompt bao phủ và 0.026 ở lệch tâm, và dẫn trước biến thể prompt-crop khoảng 0.041 ở cả hai. Trên FracAtlas các khoảng cách đó lớn lên thành 0.134 / 0.125 và 0.137 / 0.151. HD95 của PGA-UNet thấp hơn cả hai biến thể trên cả hai bộ dữ liệu.

Vậy khu trú là một phần lớn của độ khó ở đây, nhưng có hộp chưa phải toàn bộ câu chuyện. Cách PGA-UNet tiêu thụ hộp đó mua thêm một biên nhất quán so với một mạng quy ước nhận cùng đầu vào, và biên rộng hơn nhiều trên dữ liệu khó hơn là FracAtlas.

5.3 Nhóm Top-Dice và Bottom-Dice của Attention U-Net

Biên đó đến từ đâu? Chúng tôi xếp hạng các ảnh test theo Dice của Attention U-Net, giữ 50 ảnh cao nhất và 50 ảnh thấp nhất mỗi bộ dữ liệu, rồi chạy lại các mô hình có

prompt trên đúng các stem đó (Bảng 4). Ở nhóm top 50, nơi Attention U-Net đã ở 0.872 trên BTXRD và 0.493 trên FracAtlas, các mô hình có prompt xúm lại gần nhau. Ở nhóm bottom 50, Attention U-Net sập, xuống 0.031 và 0.169, trong khi PGA-UNet vẫn giữ 0.712 và 0.687 dưới prompt bao phủ. Hai baseline prompt quy ước cũng hồi phục, nhưng kém hơn: PGA-UNet dẫn trước chúng ở nhóm bottom BTXRD 0.044 đến 0.074 Dice và ở nhóm bottom FracAtlas 0.104 đến 0.189. Các nhóm này do Attention U-Net định nghĩa, không phải theo bất kỳ khái niệm độ khó khách quan nào, nên tuyên bố duy nhất là lợi ích của xử lý có điều kiện theo prompt tập trung đúng nơi khu trú tự động đổ vỡ.

[Hình 3. *images/results/unet_extreme_groups_btxrd.png*]: So sánh định tính giữa Attention U-Net và PGA-UNet trên BTXRD cho một ca nhóm Top-Dice (IMG000184) và một ca nhóm Bottom-Dice (IMG000791) của Attention U-Net. Các hàng dùng cùng stem ảnh; với PGA-UNet, panel ảnh đầu vào và panel hộp prompt được gộp làm một.

5.4 So sánh khớp với SAM-Med2D

Cả hai mô hình nhận cùng hộp ở 256×256 (Bảng 5). Zero-shot, SAM-Med2D gần như không chạy được trên X-quang xương: 0.255 Dice trên BTXRD, 0.262 trên FracAtlas. Fine-tune trên cùng tập chia và protocol prompt nâng nó lên 0.630 và 0.563, nhưng PGA-UNet ở độ phân giải đó đạt 0.762 và 0.629 dưới prompt bao phủ, dẫn trước 0.132 và 0.066 Dice và một khoảng tương tự ở CBL. SAM-Med2D chỉ vượt lên ở một chỗ, khoảng cách biên trên FracAtlas, nơi HD95 đã fine-tune của nó là 8.0 pixel, thấp hơn 10.6 của PGA-UNet. Độ chính xác tuyệt đối và mức đổi từ bao phủ sang lệch tâm là hai câu hỏi riêng; Mục VF bàn câu thứ hai.

5.5 Hiệu năng trên tổn thương nhỏ

Nếu việc giữ bằng chứng yếu sống qua mạng có ý nghĩa ở đâu, thì là ở đây. Tập con tổn thương nhỏ là 50 ảnh test mỗi bộ dữ liệu có tổng diện tích tổn thương nhỏ nhất, 7 đến 433 pixel trên BTXRD và 145 đến 944 trên FracAtlas. Bảng 6 chấm ba so sánh trên nó trong một khung 512×512 chung.

SAM-Med2D chật vật rõ ở kích thước này: đã fine-tune, nó chỉ đạt 0.256 Dice trên BTXRD và 0.371 trên FracAtlas, và zero-shot thì gần bằng không, trong khi PGA-UNet ở 256 giữ 0.705 và 0.648. Các baseline prompt quy ước ở 512 kém PGA-UNet 0.04 đến 0.11 Dice trên BTXRD và 0.11 đến 0.16 trên FracAtlas, và Attention U-Net không prompt tụt xuống khoảng 0.28. Độ phân giải cần mạnh nhất ở đây: trên các stem tổn thương nhỏ cố định, Dice của PGA-UNet tụt từ 0.766 ở 512 xuống 0.714 ở 256 và 0.631 ở 128 trên BTXRD, và từ 0.720 xuống 0.642 và 0.609 trên FracAtlas, mức mất từ 512 xuống 128 là 0.135 và 0.112, lớn hơn trên toàn tập test.

[Hình 4. *images/results/small_lesion_sam_pga256_pga512.png*]: So sánh tổn thương nhỏ tiêu biểu trên BTXRD (IMG000868, hai đa giác nhỏ): SAM-Med2D đã fine-tune ở 256×256 , PGA-UNet ở 256×256 , và PGA-UNet ở 512×512 . Panel ảnh đầu vào và panel hộp prompt được gộp làm một.

Độc hẹp, điều này nói rằng các tổn thương nhỏ nhất là ca thử thách cho toàn bộ cách tiếp cận, và cả điều kiện hóa prompt lẫn độ phân giải đầu vào đều đáng giá hơn ở đây so với trên toàn tập.

5.6 Độ nhạy với dịch prompt

Dịch hộp lệch tâm tổn của PGA-UNet rất ít ở 512×512 : 0.008 Dice trên BTXRD, 0.014 trên FracAtlas, với CBL giảm 0.006 và 0.015. Trên tập con tổn thương nhỏ, mức mất giữ dưới 0.01 Dice trên cả hai bộ dữ liệu. Các baseline prompt quy ước mất một lượng

tương đương hoặc hơi lớn hơn, và SAM-Med2D đã fine-tune khoảng 0.03. Tất cả những cái này là độ nhạy với một quy tắc dịch đã cố định trước. Nó không nói gì về hộp tùy ý do bác sĩ vẽ, và hộp phủ một phần hay sai vùng chưa bao giờ được thử.

[Hình 5. *images/results/prompt_robustness_examples.png*]: Hành vi tiêu biểu khi nhiều loạn prompt trên cả hai bộ dữ liệu. Các vết gãy mảnh vẫn khó hơn tổn thương gọn ngay cả khi hộp vẫn phủ mục tiêu.

5.7 Monte Carlo cross-validation

Một tập chia cố định có thể vô tình có lợi hoặc có hại cho phương pháp, nên PGA-UNet ở 512×512 được huấn luyện lại trên bốn tập chia ngẫu nhiên mức ảnh mới, seed huấn luyện giữ ở 22120196 và chỉ đổi seed chia tách (Bảng 7). Dice biến động tối đa 0.011 qua các lần chia trên mỗi bộ dữ liệu và mỗi điều kiện prompt; CBL tối đa 0.013. Trung bình các lần chia lặp lại của FracAtlas, 0.733, nằm ngay trên kết quả tập chia cố định 0.727, nên nếu có thì tập chia được báo cáo hơi khó hơn mức điển hình. Đây là bằng chứng PGA-UNet ổn định qua các lần chia, không phải nó thắng baseline nào.

5.8 Nghiên cứu ablation

Một lần chạy đơn tập chia đầu tiên để các cấu hình đủ gần nhau đến mức thứ tự không an toàn để báo cáo. Ablation vì vậy đang được chạy lại với nhiều seed, và các con số sẽ xuất hiện ở đây khi các lần chạy đó xong. Thiết kế so sánh mô hình đầy đủ, prompt Gaussian với PSG và CAD, với các biến thể bỏ một yếu tố mỗi lần hoặc thay prompt Gaussian bằng một hộp nhị phân; mục tiêu là kiểm tra tổ hợp như một hệ thống, không phải khẳng định một cơ chế nội tại duy nhất. Hình 6 cho một ca mà prompt Gaussian cho biên sạch hơn hộp nhị phân.

[Hình 6. *images/ablation/ablation_gaussian_vs_binary_case.png*]: So sánh tiêu biểu giữa biểu diễn prompt Gaussian dạng cao nguyên và một hộp nhị phân trong kiến trúc đầy đủ.

5.9 Hiệu năng tính toán

PGA-UNet nhỏ: 2.955M tham số, đều là trainable, checkpoint 11.4 MB, 7.74 GFLOPs ở 256×256 và 31.0 ở 512×512 . Trên Tesla T4 nó chạy 8.5 ms mỗi ảnh ở 256 và 18.5 ms ở 512, và trên CPU là 112 ms và 375 ms. SAM-Med2D đã fine-tune ở 256×256 mang 271.24M tham số, checkpoint 2.4 GB, và 92.0 GFLOPs, mất 50.1 ms trên GPU và 1324 ms trên CPU. Ở độ phân giải khớp, PGA-UNet vì vậy nhẹ hơn khoảng 92 lần về tham số, 12 lần về FLOPs, nhỏ hơn 215 lần trên đĩa, và nhanh hơn 6 lần trên GPU. Đây là chi phí đo được trên một cài đặt, một GPU, và hai độ phân giải, không hơn.

5.10 So sánh thăm dò các hàm loss phân đoạn

Vì mục tiêu nhỏ, chúng tôi cũng thử thay số hạng Dice bằng một size-conditioned Tversky loss, và riêng bằng một Focal Dice loss, mọi thứ khác giữ nguyên. Không cái nào giúp. Trên BTXRD, Dice + BCE mặc định cho 0.782 / 0.774 Dice (bao phủ / lệch tâm), so với 0.778 / 0.767 cho Tversky và 0.773 / 0.765 cho Focal Dice. Trên FracAtlas, mặc định cho 0.727 / 0.713, so với 0.709 / 0.680 cho Tversky và 0.642 / 0.578 cho Focal Dice, cái sau là một bước lùi rõ với HD95 vượt 100 pixel. Chúng tôi giữ đây như một đối chứng âm: dưới protocol hiện tại, hàm mục tiêu mặc định đã là một lựa chọn tốt, và không nhận biến thể nào.

5.11 Các kiểu lỗi (*Failure Modes*)

PGA-UNet vẫn lỗi, và các lỗi có một khuôn. Trong rà soát định tính, Dice thấp tụ vào các tổn thương dài hoặc phân nhánh, các tổn thương nằm ở giải phẫu rối rắm như vai hoặc xương đòn, hoặc các tổn thương gần như không nổi lên so với xương xung quanh. Một hộp bao phủ không sửa được một ca mà bản thân bằng chứng ảnh cục bộ đã kém.

[Hình 7. *images/failure/failure_case_overlap.png*]: Ca lỗi tiêu biểu ở vùng giải phẫu chồng lấn. Ngay cả với một hộp bao phủ, biên vẫn khó vì các cấu trúc cục bộ bị nhầm lẫn về mặt thị giác.

5.12 Tự đánh giá không cần huấn luyện và gợi ý vùng

Không cần đáp án, điểm Q ở Mục III.F vẫn bám theo Dice thật của từng prompt. Tương quan Spearman của nó với Dice thật là 0.70 (bao phủ) và 0.60 (lệch tâm) trên BTXRD, và 0.65 và 0.48 trên FracAtlas. Hai chỉ dấu đều có sức nặng: độ dứt khoát của mask một mình đạt Spearman gần 0.4, độ ổn định khi nhích gần 0.5 đến 0.6, và trung bình của chúng tốt ít nhất bằng từng cái. Chúng tôi cũng huấn luyện một đầu nhỏ để hồi quy Dice trực tiếp; nó sập về một đầu ra gần như hằng số, Spearman dưới 0.2 trên cả hai bộ dữ liệu, và không được dùng.

Lật lại, Q có thể xếp hạng 50 hộp ứng viên ngẫu nhiên và giữ năm hộp đầu (Hình 8). Khi đó ít nhất một trong năm hộp phủ hơn một nửa tổn thương cho 67% ảnh BTXRD và 82% ảnh FracAtlas, và hộp tốt nhất trong năm phủ trung bình 0.84 và 0.90 diện tích tổn thương; một danh sách ba hộp cho 58% / 78% và 0.77 / 0.87. Đây là một công cụ hỗ trợ xem lại chứ không hơn: Q là một heuristic, không phải xác suất đã hiệu chuẩn, và danh sách ngắn không phải một bộ phát hiện.

[Hình 8. *images/demo/demo_suggestion_btxrd.png*]: Danh sách ngắn vùng ứng viên trên một ca BTXRD. Năm mươi hộp được lấy mẫu không có prompt, chấm bằng điểm tự đánh giá Q , và năm hộp điểm cao nhất được hiển thị để bác sĩ chấp nhận, chỉnh, hoặc bỏ. Một ca FracAtlas ở phần bổ sung.

Mục VI. Thảo luận (*Discussion*)

Câu hỏi bài báo đặt ra chưa bao giờ là prompt có ích theo nghĩa trừu tượng hay không. Nó là liệu cách một mô hình xử lý prompt có còn quan trọng một khi một hộp thô đã thu hẹp việc tìm kiếm. Attention U-Net không hộp trả lời một câu hỏi khác, và Dice thấp của nó, gần 0.34 trên FracAtlas, đo phần bài toán chỉ là tìm tổn thương. Các so sánh thực sự kiểm tra thiết kế đưa cùng một hộp cho một Attention U-Net thuần và cho SAM-Med2D đã fine-tune. Ở cả hai, PGA-UNet giữ một biên: khiêm tốn trên BTXRD, rõ hơn trên FracAtlas, và lớn nhất ở nhóm Bottom-Dice của Attention U-Net và ở các tổn thương nhỏ nhất. Đó là khuôn ta trông đợi nếu PSG và CAD đang làm đúng việc của chúng, giữ prompt sống qua encoder và decoder để một tín hiệu mờ nhạt không bị mất vào downsampling. Ablation từng thành phần để chốt điều này vẫn đang chạy lại với nhiều seed.

Hai kết quả bên lề đáng nói không cần vòng vo. So sánh loss là một âm tính sạch: một size-conditioned Tversky loss hay một Focal Dice loss không giúp, và Focal Dice trên FracAtlas làm mọi thứ tệ hơn, nên hàm mục tiêu Dice + BCE thuần được giữ. Điểm tự đánh giá là một dương tính vừa phải: Q tương quan với Dice thật ở mức thứ hạng khoảng 0.5 đến 0.7 mà không cần nhãn nào, và nó làm được ở nơi một đầu hồi quy học nhỏ không làm được, vì đầu đó chỉ đơn giản dự đoán mức trung bình. Q vẫn là một heuristic. Nó chưa được hiệu chuẩn, và danh sách ngắn vùng ứng viên dựng từ nó là một cách hướng sự chú ý của bác sĩ, không phải một bộ phát hiện.

Giới hạn của nghiên cứu là cụ thể. Đầu vào được resize về một hình vuông cố định, và các kết quả độ phân giải cho thấy điều đó tổn độ chính xác thật trên các tổn thương nhỏ nhất. Prompt được vẽ từ nhãn, không phải bởi bác sĩ X-quang, và protocol giả định người dùng đã tìm ra vùng và vẽ một hộp phủ nó; hộp phủ một phần, âm, và sai vùng chưa bao giờ trong phạm vi. BTXRD và FracAtlas được huấn luyện tách nhau, không có mô hình chung và không có test chéo dataset, và tách biệt mức bệnh nhân không xác nhận được từ metadata công khai. Các lần chạy Monte Carlo cho thấy ổn định qua các lần chia, không phải vượt trội. Ablation đang giữa quá trình chuyển từ một lần chia sang nhiều. Vòng này cũng để SAM-Med2D là tham chiếu mô hình nền tảng nhận prompt duy nhất; một so sánh với các mô hình y tế nhận prompt mới hơn để dành cho sau. Và các lợi ích khi nhiều loạn prompt, dù nhất quán với ý đồ thiết kế, không được chứng thực bằng probing mức đặc trưng, nên ablation, một khi xong, sẽ nói về tính hữu ích của thiết kế như một tổng thể chứ không phải về cơ chế chính xác bên trong nó.

Mục VII. Kết luận (Conclusion)

Bài báo trình bày PGA-UNet, một CNN nhẹ có định hướng bằng prompt cho phân đoạn tổn thương xương X-quang tương tác. Thiết kế biến một hộp bao phủ tổn thương do người dùng cung cấp thành một prior không gian dày đặc và tái sử dụng nó qua PSG phía encoder và CAD phía decoder. Trên BTXRD và FracAtlas, đánh giá dưới các prompt bao phủ và lệch tâm có kiểm soát, PGA-UNet luôn dẫn trước các baseline quy ước khớp prompt và SAM-Med2D đã fine-tune khi nhận cùng một hộp, với biên tập trung ở nơi khu trú tự động thất bại và ở nơi tổn thương nhỏ nhất, và làm được với khoảng 92 lần ít tham số hơn SAM-Med2D. Các thực nghiệm chia lặp lại cho thấy xu hướng ổn định, và một điểm tự đánh giá không cần huấn luyện cho một thứ hạng độ tin cậy không cần đáp án dùng được, dù chưa hiệu chuẩn.

Các kết luận bị chặn bởi protocol. Chúng nói về hộp bao phủ tổn thương mô phỏng từ nhãn, không phải phát hiện tự do, hộp phủ một phần hay sai vùng, prompt do bác sĩ vẽ, xác suất tin cậy đã hiệu chuẩn, tổng quát hóa mức bệnh nhân, hay chuyển giao chéo dataset. Công việc sau nên hoàn tất ablation nhiều seed, thêm một so sánh rộng hơn với các mô hình y tế nhận prompt gần đây, thay hộp mô phỏng bằng các protocol prompt lỏng và thực tế hơn, và biến điểm tự đánh giá thành một tín hiệu đã hiệu chuẩn để rồi dùng cho gợi ý vùng nghi ngờ trong một vòng xem lại lâm sàng.

Các mục còn lại

Tính sẵn có của dữ liệu (Data Availability)

BTXRD và FracAtlas là bộ dữ liệu công khai được trích dẫn trong bài. Bản thảo báo cáo thực nghiệm trên các tập chia train/validation/test ở mức ảnh, suy ra từ hai bộ dữ liệu đó. Mã nguồn và chi tiết cách chia sẽ được công bố cùng gói tái lập kết quả cuối cùng.

Đóng góp của tác giả (Author Contributions)

Thông Lức: ý tưởng, phương pháp luận, phân mềm, khảo sát, phân tích chính thức, trực quan hóa, viết bản thảo gốc. **Nguyễn Hữu Bình:** hỗ trợ phần mềm, chuẩn bị dữ liệu, kiểm chứng thực nghiệm, rà soát và biên tập. **Lý Quốc Ngọc:** hướng dẫn, thẩm định, rà soát và biên tập.

Tuyên bố đạo đức (*Ethics Statement*)

Nghiên cứu dùng bộ dữ liệu X-quang công khai đã ẩn danh, không thu thập dữ liệu tiền cứu, không tiếp xúc bệnh nhân, không can thiệp.

Lời cảm ơn (*Acknowledgment*)

[AUTHOR ACTION: cập nhật phần công bố việc dùng AI cho khớp quy trình cuối cùng và chính sách hiện hành của IEEE.]

Tài liệu tham khảo (*References, giữ nguyên, không dịch tên bài/tạp chí*)

1. Kirillov *et al.*, “Segment Anything,” ICCV 2023.
2. Cheng *et al.*, “SAM-Med2D,” arXiv:2308.16184, 2023.
3. Ronneberger, Fischer, Brox, “U-Net: Convolutional Networks for Biomedical Image Segmentation,” MICCAI 2015.
4. Oktay *et al.*, “Attention U-Net: Learning Where to Look for the Pancreas,” MIDL 2018.
5. Xu, Price, Cohen, Yang, Huang, “Deep Interactive Object Selection,” CVPR 2016.
6. Wang *et al.*, “DeepIGeoS: A Deep Interactive Geodesic Framework for Medical Image Segmentation,” IEEE TPAMI 2019.
7. Yao *et al.*, “A Radiograph Dataset for the Classification, Localization, and Segmentation of Primary Bone Tumors,” Scientific Data 2025.
8. Abedeen *et al.*, “FracAtlas: A Dataset for Fracture Classification, Localization and Segmentation of Musculoskeletal Radiographs,” Scientific Data 2023.
9. Ma *et al.*, “Segment Anything in Medical Images,” Nature Communications 2024.
10. Isensee *et al.*, “nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation,” Nature Methods 2021.
11. Wong, Rakic, Guttag, Dalca, “ScribblePrompt: Fast and Flexible Interactive Segmentation for Any Biomedical Image,” ECCV 2024.
12. Dong *et al.*, “An efficient segment anything model for the segmentation of medical images,” Scientific Reports 2024.
13. Wu *et al.*, “Medical SAM adapter: Adapting segment anything model for medical image segmentation,” Medical Image Analysis 2025.

Tiểu sử tác giả (*Biography*)

Thông Lúc là sinh viên năm cuối chương trình Cử nhân Khoa học Máy tính, Khoa Công nghệ Thông tin, Trường Đại học Khoa học Tự nhiên, ĐHQG-HCM. Hướng nghiên cứu: thị giác máy tính, deep learning, phân tích ảnh y tế, phân đoạn ảnh, phân đoạn có định hướng prompt tương tác.

Nguyễn Hữu Bình là sinh viên ngành Khoa học Máy tính, Khoa Công nghệ Thông tin, Trường Đại học Khoa học Tự nhiên, ĐHQG-HCM. Hướng nghiên cứu: thị giác máy tính, deep learning, phân đoạn ảnh y tế dùng visual prompt.

Lý Quốc Ngọc: phần tiểu sử và affiliation trong bản gốc vẫn còn placeholder, chưa có nội dung thật.

Hết. File này chỉ để tự đối chiếu ý; không dùng để nộp, không thay thế bản LaTeX gốc access.tex.

Table 1: Bảng 1. Công trình tiêu biểu trước đây và khoảng trống còn lại mà bài báo này giải quyết.

Công trình	Nguyên lý	Phương pháp	Bằng chứng hiệu năng	Ưu điểm	Nhược điểm
U-Net	Encoder-decoder tích chập đầy đủ	Mạng phân đoạn đa tỉ lệ có skip connection	Baseline kinh điển trong phân đoạn y sinh	Đơn giản, hiệu quả, mô hình tham chiếu mạnh	Không có định hướng prompt; mọi khu trú phải tự động
Attention U-Net	Lọc skip-feature bằng cổng attention	U-Net có skip connection gần cổng	Tác vụ phân đoạn y tế, đo bằng Dice và IoU	Baseline tự động mạnh hơn U-Net thường	Attention vẫn học mà không có điều kiện hóa prompt tường minh
nnU-Net	Pipeline tự động tự cấu hình	Tự thích ứng tiền xử lý, kiến trúc, lịch huấn luyện	Kết quả tự động mạnh trên nhiều benchmark y tế	Pipeline tự động bền, ít chỉnh tay	Không có cơ chế prompt; khu trú vẫn hoàn toàn tự động
DeepIGeoS và các pp tương tác liên quan	Gợi ý người dùng thu hẹp không gian tìm kiếm	Phân đoạn dựa trên geodesic hoặc nhận biết tương tác	Phân đoạn y tế tương tác theo đầu vào người dùng	Phản ánh tương tác lâm sàng tốt hơn	Cơ chế tương tác có thể đặc thù theo tác vụ hoặc tổn kém duy trì
ScribblePrompt	Phân đoạn y sinh tương tác tổng quát	Một mô hình cho scribble, click, box trên nhiều dataset	Đánh giá tương tác đa dataset với nhiều loại prompt	Linh hoạt, các kiểu tương tác thực tế	Đa dụng, không phải một prior prompt nhẹ chuyên biệt X-quang
SAM-Med2D / MedSAM	Phân đoạn nền tảng nhận prompt	Mô hình tiền huấn luyện lớn, giải mã mask theo prompt	Đánh giá đa dataset y tế, đo theo prompt	Linh hoạt, áp dụng rộng	Nặng; ảnh hưởng prompt không thiết kế như prior nhẹ, end-to-end, chuyên biệt X-quang
EMedSAM / Med-SA	Tinh chỉnh adapter của SAM cho ảnh y tế	Adapter nhẹ trên backbone SAM đóng băng	Phân đoạn y tế với chi phí thích ứng thấp hơn	Chuyên biệt hóa mô hình nền tảng rẻ hơn	Vẫn là backbone SAM lớn; prompt tác động chủ yếu ở mask decoder
Bài báo này	Prompt như prior không gian dày đặc xuyên suốt mạng	Prompt cao nguyên Gaussian + PSG + CAD trong CNN nhẹ	BTXRD và FracAtlas; Dice, CBL, HD95, hiệu năng, phân tích tổn thương nhỏ	Nhẹ, nhận biết prompt từ encoder đến decoder, đánh giá dưới dịch prompt có kiểm soát	Vẫn cần mask giám sát và tiền xử lý độ phân giải cố định

Table 2: Bảng 2. PGA-UNet qua các độ phân giải, merge ở mức ảnh. Dice và CBL cho ở dạng bao phủ / lệch tâm.

Bộ dữ liệu	Độ phân giải	Dice	CBL
BTXRD	128×128	0.714 / 0.717	0.859 / 0.857
	256×256	0.762 / 0.743	0.902 / 0.885
	512×512	0.782 / 0.774	0.918 / 0.912
FracAtlas	128×128	0.596 / 0.542	0.849 / 0.790
	256×256	0.629 / 0.594	0.895 / 0.849
	512×512	0.727 / 0.713	0.913 / 0.897

Table 3: Bảng 3. So sánh ở 512×512 dưới prompt bao phủ. Attention U-Net không nhận hộp; các dòng còn lại dùng đúng hộp PGA-UNet nhận.

Bộ dữ liệu	Mô hình	Dice	CBL	HD95
BTXRD	Attention U-Net (không prompt)	0.517	0.620	120.4
	Attention U-Net + kênh prompt	0.760	0.895	33.0
	Attention U-Net + crop theo prompt	0.741	0.912	24.7
	PGA-UNet	0.782	0.918	22.8
FracAtlas	Attention U-Net (không prompt)	0.342	0.478	139.9
	Attention U-Net + kênh prompt	0.593	0.887	22.9
	Attention U-Net + crop theo prompt	0.590	0.865	22.0
	PGA-UNet	0.727	0.913	10.5

Table 4: Bảng 4. Nhóm Top-Dice và Bottom-Dice ở 512×512 , 50 ảnh mỗi nhóm, prompt bao phủ. Nhóm do Attention U-Net thuần định nghĩa.

Bộ dữ liệu	Nhóm	Mô hình	Dice	CBL
BTXRD	Top-Dice	Attention U-Net	0.872	0.945
		PGA-UNet	0.862	0.944
	Bottom-Dice	Attention U-Net	0.031	0.105
		PGA-UNet	0.712	0.879
FracAtlas	Top-Dice	Attention U-Net	0.493	0.640
		PGA-UNet	0.754	0.927
	Bottom-Dice	Attention U-Net	0.169	0.315
		PGA-UNet	0.687	0.896

Table 5: Bảng 5. So sánh với SAM-Med2D ở 256×256 , merge ở mức ảnh, prompt bao phủ.

Bộ dữ liệu	Mô hình	Dice	CBL	HD95
BTXRD	SAM-Med2D zero-shot	0.255	0.734	41.2
	SAM-Med2D fine-tuned	0.630	0.836	17.3
	PGA-UNet	0.762	0.902	10.9
FracAtlas	SAM-Med2D zero-shot	0.262	0.752	21.3
	SAM-Med2D fine-tuned	0.563	0.846	8.0
	PGA-UNet	0.629	0.895	10.6

Table 6: Bảng 6. Tập con tổn thương nhỏ, 50 ảnh mỗi bộ dữ liệu, prompt bao phủ, chấm trong khung 512×512 chung. Bảng không đưa IoU vì nó nhiều ở kích thước tổn thương này.

Bộ dữ liệu	Mô hình	Dice	CBL	HD95
BTXRD	SAM-Med2D fine-tuned 256	0.256	0.561	123.8
	Attention U-Net + kênh prompt 512	0.728	0.879	14.2
	Attention U-Net + crop theo prompt 512	0.724	0.909	5.5
	PGA-UNet 256	0.705	0.877	14.7
	PGA-UNet 512	0.766	0.897	14.0
FracAtlas	SAM-Med2D fine-tuned 256	0.371	0.736	62.1
	Attention U-Net + kênh prompt 512	0.610	0.888	21.9
	Attention U-Net + crop theo prompt 512	0.564	0.855	22.6
	PGA-UNet 256	0.648	0.897	20.6
	PGA-UNet 512	0.720	0.907	8.3

Table 7: Bảng 7. Monte Carlo cross-validation của PGA-UNet ở 512×512 , bốn lần chia ngẫu nhiên lặp lại, trung bình $\pm$ độ lệch chuẩn.

Bộ dữ liệu	Prompt	Dice	CBL	HD95
BTXRD	Bao phủ	0.769 ± 0.005	0.905 ± 0.005	25.0 ± 2.5
	Lệch tâm	0.762 ± 0.004	0.901 ± 0.007	25.7 ± 2.0
FracAtlas	Bao phủ	0.733 ± 0.007	0.909 ± 0.006	14.1 ± 2.7
	Lệch tâm	0.728 ± 0.011	0.904 ± 0.013	15.6 ± 3.9

Table 8: Bảng 8. Hiệu năng trong môi trường kiểm thử (NVIDIA Tesla T4, batch size 1).

Mô hình	Tham số	GFLOPs	Kích thước	GPU ms	CPU ms
PGA-UNet 256	2.96M	7.74	11.4 MB	8.5	112
PGA-UNet 512	2.96M	30.97	11.4 MB	18.5	375
SAM-Med2D 256	271.24M	92.02	2443 MB	50.1	1324