

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Thông Lúc - Nguyễn Hữu Bình

Phát triển hệ thống phân đoạn ảnh X-quang
về xương dựa vào câu nhắc trực quan

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN CNTT
CHƯƠNG TRÌNH CHUẨN

Tp. Hồ Chí Minh, tháng 07/2026

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Thông Lúc - 22120196
Nguyễn Hữu Bình - 22120031

**Phát triển hệ thống phân đoạn ảnh X-quang
về xương dựa vào câu nhắc trực quan**

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN CNTT
CHƯƠNG TRÌNH CHUẨN

GIẢNG VIÊN HƯỚNG DẪN

PGS.TS. Lý Quốc Ngọc

ThS. Đỗ Thị Thanh Hà

Tp. Hồ Chí Minh, tháng 07/2026

Lời cảm ơn

Tôi xin chân thành cảm ơn ...

Đề cương chi tiết

Thông tin chung

- **Tên đề tài:** Phát triển hệ thống phân đoạn ảnh X-quang về xương dựa vào câu nhắc trực quan
- **Tên tiếng Anh:** Developing a bone X-ray image segmentation system based on visual prompts
- **Người hướng dẫn:** PGS.TS. Lý Quốc Ngọc, ThS. Đỗ Thị Thanh Hà (Khoa Công nghệ Thông tin)
- **Nhóm sinh viên thực hiện:**
 1. Nguyễn Hữu Bình (MSSV: 22120031)
 2. Thông Lúc (MSSV: 22120196)
- **Loại đề tài:** Nghiên cứu
- **Thời gian thực hiện:** Từ 01/2026 đến 07/2026

Giới thiệu về đề tài

Trong lĩnh vực chẩn đoán hình ảnh y tế hiện nay, việc phân đoạn chính xác cấu trúc giải phẫu xương trên ảnh X-quang là nhiệm vụ nền tảng giúp hỗ trợ bác sĩ xác định các bất thường hình thái và lập kế hoạch điều trị. Tuy nhiên, việc xây dựng các mô hình học sâu truyền thống thường yêu

cần một lượng lớn dữ liệu được gán nhãn ở mức độ điểm ảnh bởi các chuyên gia, điều vốn gây tốn kém về chi phí và thời gian trong thực tiễn.

Đề tài hướng đến xây dựng một hệ thống phân đoạn ảnh X-quang xương tương tác, trong đó bác sĩ cung cấp câu nhắc trực quan (hộp giới hạn) để định hướng mô hình học sâu tập trung vào vùng tổn thương mục tiêu. Hệ thống tích hợp cơ chế phòng vệ thông minh nhằm đảm bảo an toàn khi triển khai trong môi trường lâm sàng.

Mục tiêu đề tài

1. Xây dựng kiến trúc mạng PGA-UNet (Prompt-Guided Attention U-Net) tích hợp câu nhắc trực quan vào quá trình phân đoạn.
2. Tích hợp toàn bộ thành phần vào một ứng dụng phần mềm hoàn chỉnh phục vụ hỗ trợ chẩn đoán lâm sàng.

Kết quả dự kiến

- Mô hình phân đoạn PGA-UNet đạt hệ số Dice trên 80% trong kịch bản câu nhắc hợp lệ.
- Ứng dụng phần mềm với thời gian phản hồi dưới 200ms, đáp ứng yêu cầu tương tác thời gian thực.

Mục lục

Danh sách hình

Danh sách bảng

Tóm tắt khóa luận

Khóa luận này nghiên cứu và phát triển một hệ thống hỗ trợ chẩn đoán ảnh X-quang xương dựa trên cơ chế câu nhắc trực quan (visual prompt), nhằm giải quyết bài toán phân đoạn tương tác trong y khoa.

Bài toán: Các phương pháp phân đoạn tự động hiện tại (U-Net, Attention U-Net) hoạt động như hộp đen, không tận dụng được tri thức lâm sàng của bác sĩ, dẫn đến hiện tượng nhận diện sai trên ảnh X-quang có độ tương phản thấp và cấu trúc chồng lấp. Trong khi đó, các mô hình nền tảng tương tác (SAM, MedSAM) đòi hỏi tài nguyên tính toán vượt quá khả năng triển khai thời gian thực tại các cơ sở y tế.

Giải pháp: Khóa luận đề xuất kiến trúc PGA-UNet (Prompt-Guided Attention U-Net), tích hợp Cổng không gian (Prompt Spatial Gate) tại bộ mã hóa và Cơ chế chú ý có điều kiện (Conditioned Attention) tại bộ giải mã, cho phép mô hình CNN hạng nhẹ tiếp nhận và khai thác hiệu quả thông tin câu nhắc từ bác sĩ.

Kết quả: Trên tập kiểm thử gồm 248 mẫu ảnh X-quang xương, PGA-UNet vượt trội so với U-Net gốc và Attention U-Net trong điều kiện so sánh khác paradigm (tương tác so với tự động). Mô hình thể hiện tính bền bỉ cao khi câu nhắc bị lệch (Dice giảm không đáng kể trong kịch bản 100% Shift). Toàn bộ hệ thống được tích hợp vào ứng dụng phần mềm với thời gian phản hồi dưới 200ms.

Từ khóa: Phân đoạn ảnh y khoa, câu nhắc trực quan, X-quang xương, U-Net, phân đoạn tương tác.

Chương 1

GIỚI THIỆU

1.1 Bối cảnh chung

Chẩn đoán hình ảnh thông qua tia X (X-quang) là một trong những phương thức cận lâm sàng phổ biến và quan trọng nhất trong y khoa hiện đại. Nhờ khả năng hiển thị trực tiếp cấu trúc xương mà không cần can thiệp xâm lấn, X-quang được sử dụng rộng rãi để phát hiện và theo dõi các tổn thương về xương như gãy xương, rạn xương, thoái hóa khớp và các khối u xương. Tại các cơ sở y tế có lưu lượng bệnh nhân lớn, số lượng ảnh X-quang cần đọc mỗi ngày có thể lên đến hàng trăm ca, đặt ra áp lực đáng kể lên đội ngũ bác sĩ chẩn đoán hình ảnh.

Trong quy trình đọc phim, bước xác định và khoanh vùng tổn thương hay còn gọi là *phân đoạn ảnh* (image segmentation) đóng vai trò tiền đề quan trọng. Kết quả phân đoạn là cơ sở để đo lường kích thước tổn thương, theo dõi diễn tiến theo thời gian và lập kế hoạch điều trị. Tuy nhiên, việc thực hiện phân đoạn thủ công trên hệ thống PACS (Picture Archiving and Communication System) đòi hỏi nhiều thời gian, phụ thuộc lớn vào kinh nghiệm cá nhân của bác sĩ và tiềm ẩn nguy cơ sai sót do mỏi mắt hoặc áp lực công việc.

Những hạn chế trên đã thúc đẩy cộng đồng nghiên cứu tìm kiếm các giải pháp hỗ trợ chẩn đoán tự động dựa trên học sâu (deep learning).

Trong khoảng một thập kỷ qua, các kiến trúc mạng nơ-ron tích chập như U-Net [ronneberger2015unet] đã đạt được kết quả đáng khích lệ trong bài toán phân đoạn ảnh y khoa. Song song đó, sự ra đời của các mô hình nền tảng như SAM (Segment Anything Model) đã mở ra hướng tiếp cận mới: kết hợp tự động hóa với sự can thiệp có chủ đích của con người thông qua cơ chế *câu nhắc trực quan* (visual prompt). Đây chính là nền tảng khoa học mà khóa luận này được xây dựng trên.

1.2 Động lực nghiên cứu

1.2.1 Động lực khoa học

Mặc dù đã đạt nhiều tiến bộ, các phương pháp phân đoạn hoàn toàn tự động vẫn tồn tại một hạn chế cốt lõi: chúng hoạt động như một *hộp đen* (black box), tự suy luận trên toàn bộ ảnh mà không có bất kỳ thông tin định hướng nào từ chuyên gia. Trong môi trường ảnh X-quang xương nơi các cấu trúc giải phẫu chồng lấp nhau và vùng tổn thương thường có ngoại hình tương tự mô lành lân cận cách tiếp cận này dễ dẫn đến hiện tượng phân đoạn sai lệch (false positive) hoặc bỏ sót tổn thương (false negative).

Một hướng nghiên cứu đang nhận được sự quan tâm ngày càng lớn là *phân đoạn tương tác* (interactive segmentation), nơi người dùng cung cấp một tín hiệu không gian sơ bộ chẳng hạn như một hộp giới hạn (bounding box) để định hướng mô hình tập trung vào vùng mục tiêu. Hướng tiếp cận này không chỉ cải thiện độ chính xác mà còn đặt con người vào vị trí kiểm soát trong vòng lặp suy luận (human-in-the-loop), điều có ý nghĩa đặc biệt quan trọng trong ứng dụng y tế.

Tuy nhiên, việc tích hợp tín hiệu định hướng này một cách hiệu quả vào kiến trúc mạng nơ-ron cụ thể là làm thế nào để biểu diễn, mã hóa và truyền tải thông tin câu nhắc qua các tầng mạng vẫn là một bài toán mở đòi hỏi nghiên cứu chuyên sâu.

1.2.2 Động lực thực tiễn

Trong thực tế lâm sàng, không thể kỳ vọng mọi thao tác của bác sĩ đều hoàn hảo. Câu nhắc mà bác sĩ cung cấp có thể bị lệch tâm do chú ý không tập trung, hoặc thậm chí đặt sai vị trí hoàn toàn do nhầm lẫn. Một hệ thống phân đoạn đáng tin cậy trong môi trường lâm sàng cần có khả năng *chịu đựng sai sót* (fault tolerance): tự động nhận biết khi câu nhắc đầu vào có vấn đề và đưa ra phản hồi phù hợp, thay vì im lặng trả về một kết quả sai lệch.

Ngoài ra, việc tích hợp hệ thống vào quy trình làm việc thực tế còn đặt ra yêu cầu về tốc độ xử lý (real-time inference) và khả năng giải thích được quyết định của mô hình (model interpretability) hai yếu tố mà phần lớn các nghiên cứu học thuật thuần túy chưa chú trọng đúng mức.

Hai động lực trên cùng nhau định hình mục tiêu của khóa luận: không chỉ là một mô hình phân đoạn chính xác, mà là một *hệ thống* đủ thông minh, bền bỉ và minh bạch để thực sự hỗ trợ được bác sĩ trong phòng khám.

1.3 Phát biểu bài toán

Hệ thống đề xuất trong khóa luận hoạt động theo hai giai đoạn tách biệt về mặt thời gian và mục đích: giai đoạn huấn luyện ngoại tuyến (Offline) và giai đoạn suy luận trực tuyến (Online). Hai giai đoạn này có đầu vào, đầu ra và cơ chế tối ưu hoàn toàn khác nhau, do đó được phát biểu độc lập dưới đây.

1.3.1 Giai đoạn huấn luyện (Offline)

Giai đoạn này diễn ra hoàn toàn trước khi hệ thống được triển khai trên phần mềm. Không có sự tương tác của người dùng cuối; mục tiêu duy nhất là tiền xử lý làm sạch dữ liệu và tối ưu hóa tham số cho hai mô hình học sâu độc lập (phân lớp và phân đoạn).

Tác vụ 1: Huấn luyện mô hình phân lớp bệnh lý (Sàng lọc)

- **Đầu vào:** Tập ảnh X-quang xương đã qua các bước tiền xử lý (loại bỏ nhiễu ký tự R/L, cân bằng biểu đồ mức xám) được ký hiệu là $\mathcal{D}_{cls} = \{(\mathbf{I}_i, y_i)\}_{i=1}^N$. Trong đó $\mathbf{I}_i \in \mathbb{R}^{H \times W}$ là ảnh X-quang thứ i và $y_i \in \{0, 1\}$ là nhãn phân lớp (0: bình thường, 1: có u/tổn thương).
- **Đầu ra:** Mô hình phân lớp f_{cls} được tham số hóa bởi $\boldsymbol{\theta}_{cls}$, thực hiện ánh xạ:

$$f_{cls}(\mathbf{I}; \boldsymbol{\theta}_{cls}) \longrightarrow \hat{p} \in [0, 1] \quad (1.1)$$

trong đó $\hat{p}$ là xác suất dự đoán ảnh có chứa tổn thương. Nhãn dự đoán cuối cùng được phân ngưỡng: $\hat{y} = \mathbf{1}[\hat{p} \geq 0.5]$.

- **Mục tiêu tối ưu:** Cực tiểu hóa hàm mất mát Entropy chéo nhị phân (Binary Cross-Entropy):

$$\mathcal{L}_{cls} = -\frac{1}{N} \sum_{i=1}^N \left[y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i) \right] \quad (1.2)$$

Tác vụ 2: Huấn luyện mô hình phân đoạn PGA-UNet

- **Đầu vào:** Tập dữ liệu phân đoạn có giám sát $\mathcal{D}_{seg} = \{(\mathbf{I}_i, \mathbf{H}_i, \mathbf{M}_i)\}_{i=1}^K$, bao gồm:
 - $\mathbf{I}_i \in \mathbb{R}^{H \times W}$: ảnh X-quang xương sạch.
 - $\mathbf{H}_i \in [0, 1]^{H \times W}$: bản đồ nhiệt câu nhắc (Prompt Heatmap) được sinh tự động từ Bounding Box lý tưởng bao quanh nhãn gốc.
 - $\mathbf{M}_i \in \{0, 1\}^{H \times W}$: mặt nạ nhị phân (Ground Truth) do chuyên gia y tế gán nhãn thủ công.
- **Đầu ra:** Mô hình phân đoạn PGA-UNet được tham số hóa bởi $\boldsymbol{\theta}_{seg}$, ánh xạ:

$$f_{seg}(\mathbf{I}, \mathbf{H}; \boldsymbol{\theta}_{seg}) \longrightarrow \hat{\mathbf{P}} \in [0, 1]^{H \times W} \quad (1.3)$$

với $\hat{\mathbf{P}}$ là bản đồ xác suất tại từng điểm ảnh. Mặt nạ dự đoán được nhị phân hóa: $\hat{\mathbf{M}} = \mathbf{1}[\hat{\mathbf{P}} \geq 0.5]$.

- **Mục tiêu tối ưu:** Cực tiểu hóa hàm mất mát kết hợp:

$$\mathcal{L}_{\text{seg}} = \lambda_1 \cdot \mathcal{L}_{\text{Dice}} + \lambda_2 \cdot \mathcal{L}_{\text{BCE}} \quad (1.4)$$

1.3.2 Giai đoạn suy luận (Online)

Trong giai đoạn ứng dụng thực tiễn, hai mô hình đã huấn luyện được tích hợp thành một luồng chẩn đoán liên hoàn trên giao diện phần mềm. Quá trình này đòi hỏi sự tương tác trực tiếp và quyền quyết định cuối cùng từ bác sĩ thông qua các bước sau:

Bước 1 Sàng lọc tự động và Chuyên gia xác nhận

- **Đầu vào:** Ảnh X-quang mới của bệnh nhân $\mathbf{I}_{\text{new}}$.
- **Xử lý:** Hệ thống tiền xử lý và đưa ảnh qua mô hình phân lớp f_{cls} để tính xác suất bệnh lý.
- **Xác nhận:** Nếu hệ thống báo "*Không có U*", bác sĩ xác nhận và luồng chẩn đoán kết thúc. Nếu hệ thống báo "*Có U*" và bác sĩ đồng ý, luồng chuyển sang Bước 2 để bóc tách tổn thương.

Bước 2 Tương tác phân đoạn (Phân đoạn lần 1)

Bác sĩ sử dụng chuột khoanh một câu nhắc (hộp giới hạn) $\mathbf{B}$ bao quanh vị trí nghi ngờ. Câu nhắc này được chuyển thành bản đồ nhiệt $\mathbf{H}^{(0)}$ và đưa qua mô hình PGA-UNet để thu về mặt nạ dự đoán $\hat{\mathbf{M}}^{(0)}$.

Bước 3 Thẩm định và Xử lý kịch bản phân đoạn

Hệ thống tự động đánh giá mức độ hợp lệ của câu nhắc so với dự đoán của mô hình để kích hoạt 1 trong 2 kịch bản tương tác:

Kịch bản 1: Câu nhắc hợp lệ (Luồng bình thường) Khi câu nhắc của bác sĩ bao quát đúng hoặc gần đúng vùng tổn thương, mô hình đạt độ tự tin cao. Hệ thống lập tức trả về kết quả mật nạ phân đoạn $\hat{\mathbf{M}}^{(0)}$ hiển thị đè lên ảnh gốc để bác sĩ sử dụng.

1.3.3 Cấu trúc ngữ nghĩa của câu nhắc trực quan

Câu nhắc (Prompt) trong hệ thống không đơn thuần là một khung cắt ảnh (crop box). Nó mang hai lớp ý nghĩa:

- **Giới hạn không gian:** Thu hẹp sự tập trung của mạng nơ-ron, giúp các cổng Attention bỏ qua nhiễu nền ở các khu vực không liên quan.
- **Đại diện cho tri thức y khoa:** Hành động khoanh vùng của bác sĩ chính là tín hiệu khẳng định lâm sàng. Mô hình PGA-UNet được thiết kế để kết hợp đặc trưng giải phẫu học được học từ dữ liệu (Data-driven) với sự dẫn đường của chuyên gia (Human-driven), tạo ra một hệ thống chẩn đoán "Học máy tương tác" thực thụ.

1.4 Thách thức của bài toán

Việc xây dựng hệ thống như đã phát biểu ở trên đối mặt với bốn nhóm thách thức chính:

Thách thức về dữ liệu: Tập dữ liệu X-quang xương trong thực tế thường không sạch và có sự mất cân bằng lớp đáng kể (số ca bình thường nhiều hơn ca bệnh lý). Các nguồn nhiễu kỹ thuật như ký hiệu R/L, thiết bị cố định xương, hay sự chênh lệch về thông số chụp giữa các máy khác nhau đều có thể ảnh hưởng tiêu cực đến quá trình học nếu không được xử lý cẩn thận. Đây là thách thức mang tính kỹ thuật phòng thí nghiệm nhưng có ảnh hưởng quyết định đến chất lượng của toàn bộ hệ thống.

Thách thức về mô hình hóa: Ảnh X-quang xương có độ tương phản thấp và chứa nhiều cấu trúc giải phẫu chồng lấp. Vùng tổn thương thường

có ngoại hình cục bộ tương tự với mô xương lành lân cận, gây khó khăn cho việc trích xuất đặc trưng phân biệt. Thách thức đặt ra là làm thế nào để tích hợp thông tin câu nhắc vào kiến trúc mạng một cách hiệu quả, sao cho mô hình thực sự *sử dụng* câu nhắc để định hướng phân đoạn chứ không đơn thuần bỏ qua nó.

Thách thức về tính bền bỉ: Trong thực tế, câu nhắc của bác sĩ không bao giờ hoàn hảo. Hệ thống cần duy trì độ chính xác chấp nhận được ngay cả khi câu nhắc bị lệch một lượng đáng kể so với vị trí tổn thương thực sự. Hơn nữa, hệ thống cần có khả năng *phát hiện* và *phục hồi* khi câu nhắc sai hoàn toàn thay vì trả về kết quả sai mà không có cảnh báo.

Thách thức về triển khai thực tiễn: Một hệ thống hỗ trợ lâm sàng chỉ có giá trị khi nó có thể hoạt động theo thời gian thực trong điều kiện phần cứng thực tế. Điều này đặt ra yêu cầu cân bằng giữa hiệu năng phân đoạn và tốc độ xử lý trong toàn bộ pipeline đầu cuối.

1.5 Quá trình phát triển hướng tiếp cận

Trong giai đoạn xây dựng đề cương, nhóm nghiên cứu đề xuất theo hướng học bán giám sát — phối hợp mô hình phân đoạn chuyên biệt với mô hình nền tảng quy mô lớn thông qua cơ chế câu nhắc tự động. Tuy nhiên, trong quá trình triển khai thực tế, nhóm nhận thấy ba rào cản lớn khiến hướng tiếp cận ban đầu không phù hợp với bài toán X-quang xương 2D:

1. **Đặc thù dữ liệu 2D:** Các framework học bán giám sát cho ảnh y khoa thường được thiết kế tối ưu cho dữ liệu 3D (CT, MRI) với thông tin liên lát cắt. Ảnh X-quang xương là dữ liệu phẳng 2D, thiếu chiều sâu ngữ cảnh đó, dẫn đến hiệu quả cộng tác tri thức giữa các mô hình bị suy giảm đáng kể.
2. **Yêu cầu tương tác lâm sàng:** Thực tế chẩn đoán đòi hỏi bác sĩ

phải giữ quyền kiểm soát trong vòng lặp suy luận. Cơ chế câu nhắc tự động tuy giảm thiểu sự can thiệp thủ công, nhưng đồng thời loại bỏ khả năng bác sĩ chủ động chỉ định vùng quan tâm — điều đặc biệt quan trọng với các ca bệnh lý phức tạp.

3. **Rào cản tài nguyên:** Các mô hình nền tảng quy mô lớn sử dụng bộ mã hóa Vision Transformer hạng nặng, yêu cầu bộ nhớ GPU cao và tốc độ suy luận chậm, không đáp ứng yêu cầu phản hồi dưới 200ms tại phòng khám.

Từ những nhận định trên, nhóm quyết định chuyển hướng sang xây dựng kiến trúc PGA-UNet: giữ nguyên triết lý cốt lõi “phân đoạn dựa trên câu nhắc” từ đề cương, nhưng tích hợp cơ chế câu nhắc trực tiếp vào kiến trúc CNN hạng nhẹ thay vì phụ thuộc vào mô hình nền tảng bên ngoài. Hướng tiếp cận này đảm bảo tính khả thi triển khai thực tế đồng thời mở ra khả năng tương tác trực tiếp giữa bác sĩ và hệ thống.

1.6 Đóng góp của khóa luận

Khóa luận đề xuất một hệ thống hỗ trợ chẩn đoán hình ảnh toàn diện với các đóng góp kỹ thuật cụ thể như sau:

Kiến trúc mạng PGA-UNet (Prompt-Guided Attention U-Net): Đây là đóng góp cốt lõi về mặt mô hình. Kiến trúc này tích hợp hai cơ chế mới vào nền tảng U-Net: Cổng không gian (Prompt Spatial Gate) tại bộ mã hóa, có tác dụng lọc các đặc trưng ảnh ngay từ đầu dựa trên thông tin câu nhắc; và Cơ chế chú ý có điều kiện (Conditioned Attention) tại bộ giải mã, cho phép quá trình tái tạo bản đồ phân đoạn được điều chỉnh bởi tín hiệu câu nhắc ở mức độ sâu hơn. Kết quả thực nghiệm cho thấy thiết kế này mang lại cải thiện đáng kể về hệ số Dice so với U-Net và Attention U-Net truyền thống.

Luồng chẩn đoán đầu cuối (End-to-End Pipeline): Toàn bộ các thành phần tiền xử lý, phân lớp sàng lọc và phân đoạn có hướng dẫn được

tích hợp thành một luồng xử lý hoàn chỉnh trong giao diện phần mềm, với tốc độ phản hồi đáp ứng yêu cầu thời gian thực.

1.7 Bố cục của khóa luận

Khóa luận được tổ chức thành năm chương chính với nội dung cụ thể như sau:

Chương 1: Giới thiệu trình bày bối cảnh chung, động lực thực tiễn và khoa học, phát biểu chi tiết bài toán, phân tích các thách thức cốt lõi và tóm tắt những đóng góp chính của khóa luận.

Chương 2: Các công trình liên quan và cơ sở lý thuyết khảo sát các hướng nghiên cứu hiện có về phân đoạn ảnh y khoa tự động và phân đoạn tương tác, từ đó xác định khoảng trống nghiên cứu mà khóa luận hướng đến lấp đầy. Chương này cũng trình bày các kiến thức lý thuyết nền tảng gồm kiến trúc U-Net, cơ chế chú ý và các độ đo đánh giá hiệu năng.

Chương 3: Mô hình và hệ thống đề xuất trình bày chi tiết về mặt kỹ thuật toàn bộ giải pháp đề xuất, bao gồm kiến trúc PGA-UNet, cơ chế biểu diễn câu nhắc, cùng với sự tích hợp các thành phần thành luồng xử lý đầu cuối.

Chương 4: Thực nghiệm và đánh giá kết quả mô tả môi trường thực nghiệm, trình bày và phân tích các kết quả định lượng (so sánh với mô hình cơ sở, đánh giá tính bền bỉ, ablation study kiến trúc) và kết quả định tính (trực quan hóa), đồng thời đánh giá tính khả thi triển khai thực tế của ứng dụng.

Chương 5: Kết luận và hướng phát triển tóm tắt các đóng góp đã đạt được, nhìn nhận khách quan những hạn chế còn tồn tại và đề xuất hướng nghiên cứu tiếp theo.

Chương 2

CÁC CÔNG TRÌNH LIÊN QUAN VÀ CƠ SỞ LÝ THUYẾT

Chương này được tổ chức thành hai phần chính. Phần đầu (Mục ??) khảo sát các công trình liên quan để đặt khóa luận trong bức tranh nghiên cứu hiện tại và làm rõ khoảng trống mà đề tài hướng đến giải quyết. Phần sau (Mục ?? đến Mục ??) trình bày các kiến thức lý thuyết nền tảng cần thiết để hiểu kiến trúc và cơ chế hoạt động của hệ thống đề xuất ở Chương ??.

2.1 Các công trình liên quan

2.1.1 Các phương pháp phân đoạn ảnh y khoa tự động

Trong lĩnh vực phân tích hình ảnh y khoa, kiến trúc U-Net [ronneberger2015unet] do Ronneberger và cộng sự đề xuất năm 2015 được xem là nền tảng cốt lõi cho nhiều nghiên cứu về sau. Với thiết kế

mã hóa - giải mã (encoder-decoder) đối xứng, kết hợp cùng các kết nối tắt (skip connections), U-Net cho phép trích xuất đặc trưng ngữ nghĩa ở nhiều cấp độ đồng thời bảo toàn được thông tin vị trí không gian. Đặc tính này giúp mô hình đạt hiệu năng khả quan ngay cả khi huấn luyện trên các tập dữ liệu y khoa có quy mô nhỏ và thiếu hụt nhãn.

Nhằm khắc phục hạn chế của U-Net trong việc phân bổ sự chú ý đồng đều trên toàn bộ bức ảnh, Oktay và cộng sự (2018) đã đề xuất mạng Attention U-Net [oktay2018attentionunet]. Bằng cách tích hợp các Cổng chú ý (Attention Gates) tại các kết nối tắt, mô hình có khả năng tự động học cách làm nổi bật các khu vực chứa đặc trưng quan trọng và ức chế các vùng nhiễu nền trước khi đưa dữ liệu vào bộ giải mã.


Tuy nhiên, dưới góc độ triển khai thực tế trên ảnh X-quang xương, cả U-Net và Attention U-Net đều gặp phải một giới hạn chung về phương pháp luận: chúng hoạt động theo cơ chế phân đoạn hoàn toàn tự động. Mô hình chỉ nhận đầu vào duy nhất là ảnh thô và phải tự tìm kiếm vùng tổn thương mà không có bất kỳ thông tin định hướng hay tri thức lâm sàng nào từ bác sĩ. Đối với các ảnh X-quang có độ tương phản thấp và chứa các cấu trúc giải phẫu xương chồng lấp, cách tiếp cận này dễ dẫn đến hiện tượng mô hình nhận diện sai hoặc cắt lấn sang các vùng mô lành lân cận.

2.1.2 Phương pháp học máy tương tác trong y khoa

Để vượt qua giới hạn của các phương pháp tự động, xu hướng nghiên cứu gần đây đang chuyển dịch sang phân đoạn có tương tác (interactive segmentation) — cho phép bác sĩ cung cấp tín hiệu định hướng (hộp giới hạn, điểm bấm) để mô hình tập trung vào đúng vùng cần phân tích.

Đại diện tiêu biểu trong lĩnh vực y khoa là **SAM-Med2D** [2023-SAMMed2D-C] (Cheng và cộng sự, 2023) — mô hình được chọn làm đối sánh trực tiếp trong khóa luận. SAM-Med2D kế thừa kiến trúc Segment Anything Model (SAM) với bộ mã hóa ảnh Vision Transformer (ViT-B, ~100 triệu

tham số), tinh chỉnh trên hơn 4,6 triệu ảnh y khoa đa phương thức bằng chiến lược chèn lớp Adapter — giữ nguyên phần lớn trọng số nền tảng, chỉ cập nhật thêm tầng Adapter và bộ giải mã. Mô hình nhận hộp giới hạn làm câu nhắc vị trí qua Prompt Encoder và xuất ra mặt nạ phân đoạn. Sơ đồ kiến trúc SAM-Med2D được minh họa tại Hình ??.



Hình 2.1: Kiến trúc SAM-Med2D với chiến lược huấn luyện kết hợp: Mô hình Generalist (SAM-Med2D nhận câu nhắc vị trí qua Prompt Encoder, tham số đóng băng ● và học được ●) phối hợp với Mô hình Specialist (Swin-UNet tăng cường nhận thức biên), tối ưu qua hàm mất mát tổng hợp có trọng số tin cậy $\beta(U)$

Tuy nhiên, SAM-Med2D vẫn tồn tại rào cản lớn về triển khai lâm sàng:

bộ mã hóa ViT-B hạng nặng đòi hỏi bộ nhớ GPU cao, tốc độ suy luận chậm, không đáp ứng yêu cầu phản hồi thời gian thực tại phòng khám. Hơn nữa, SAM-Med2D không có bất kỳ cơ chế nào xử lý câu nhắc sai vị trí của bác sĩ — đây là tình huống không thể tránh trong thực tế lâm sàng.

Khoảng trống nghiên cứu: Từ khảo sát trên, khoảng trống nghiên cứu hiện rõ: một mặt, U-Net và Attention U-Net hoạt động hoàn toàn tự động, thiếu cơ chế tiếp nhận định hướng từ bác sĩ; mặt khác, SAM-Med2D tuy có câu nhắc nhưng nặng về tài nguyên và không có lớp an toàn khi câu nhắc sai. Do đó, khóa luận nghiên cứu cơ chế tích hợp câu nhắc trực quan sâu vào kiến trúc CNN hạng nhẹ, đồng thời xây dựng thuật toán phòng vệ và tự tinh chỉnh khi bác sĩ thao tác sai — lấp đầy đồng thời cả hai khoảng trống này.

2.2 Cơ sở lý thuyết nền tảng

2.2.1 Mạng nơ-ron tích chập (CNN)

Mạng nơ-ron tích chập (Convolutional Neural Network - CNN) là nền tảng cốt lõi của hầu hết các mô hình học sâu hiện đại trong lĩnh vực thị giác máy tính. Khác với mạng nơ-ron truyền thống kết nối đầy đủ (fully connected networks) vốn dễ bị bùng nổ số lượng tham số khi xử lý dữ liệu ảnh, CNN sử dụng cơ chế chia sẻ trọng số (weight sharing) và kết nối cục bộ thông qua các phép toán tích chập. Đặc tính này giúp mô hình trích xuất được các đặc trưng không gian (như cạnh, góc, họa tiết) mà vẫn duy trì được tính bất biến với phép dịch chuyển.

Tại một tầng tích chập thứ l , đầu vào là bản đồ đặc trưng $\mathbf{F}^l \in \mathbb{R}^{H \times W \times C_{in}}$ sẽ được nhân chập với một tập hợp các bộ lọc (filters) $\mathbf{W} \in \mathbb{R}^{k \times k \times C_{in} \times C_{out}}$. Đầu ra của một điểm ảnh trên bản đồ đặc trưng tiếp theo

được tính theo công thức tích chập rời rạc:

$$\mathbf{F}_{i,j,c}^{l+1} = \sigma \left(\sum_m \sum_n \sum_{c'} \mathbf{W}_{m,n,c',c} \cdot \mathbf{F}_{i+m,j+n,c'}^l + b_c \right) \quad (2.1)$$

trong đó k là kích thước không gian của bộ lọc, σ là hàm kích hoạt phi tuyến (thường sử dụng ReLU để khắc phục hiện tượng triệt tiêu đạo hàm), và b_c là hệ số chệch (bias). Xen kẽ với các tầng tích chập là các tầng gộp (Pooling layers), phổ biến nhất là Max Pooling, có nhiệm vụ giảm kích thước không gian (downsampling) để mở rộng trường tiếp nhận (receptive field) của các bộ lọc sâu hơn.

2.2.2 Kiến trúc U-Net

Được thiết kế chuyên biệt cho các bài toán phân đoạn ảnh y khoa, U-Net [ronneberger2015unet] sở hữu kiến trúc đối xứng hình chữ "U" đặc trưng, bao gồm hai nhánh chính:

Bộ mã hóa (Encoder): Là nhánh thu nhỏ không gian ở phía bên trái. Thông qua chuỗi các phép tích chập và gộp cực đại (Max Pooling), nhánh này làm nhiệm vụ nén thông tin ảnh, trích xuất biểu diễn ngữ nghĩa từ các chi tiết cục bộ ở tầng nông thành các đặc trưng toàn cục ở tầng sâu. Quá trình này giúp mô hình nhận biết "đối tượng là gì", nhưng đổi lại sẽ làm mất đi thông tin vị trí không gian.

Bộ giải mã (Decoder): Là nhánh khôi phục không gian ở phía bên phải. Nhánh này sử dụng các phép tăng mẫu (Upsampling hoặc Transposed Convolution) để khôi phục dần độ phân giải của bản đồ đặc trưng về lại kích thước ban đầu của ảnh đầu vào. Tầng cuối cùng áp dụng hàm kích hoạt Sigmoid để xuất ra bản đồ dự đoán xác suất từng pixel (pixel-wise probability map).

Kết nối tắt (Skip connections): Đây là yếu tố đột phá làm nên thành công của U-Net. Các kết nối tắt sao chép trực tiếp các bản đồ đặc trưng độ phân giải cao từ bộ mã hóa và nối kênh (concatenate) chúng vào

các bản đồ đặc trưng tương ứng tại bộ giải mã. Cơ chế này bù đắp phần thông tin không gian bị mất trong quá trình giảm mẫu, giúp mô hình tái tạo chính xác đường biên giải phẫu của tổn thương.



Hình 2.2: Kiến trúc mạng U-Net với 4 cấp độ phân giải: nhánh mã hóa (trái) giảm mẫu dần qua Max Pooling; nhánh giải mã (phải) khôi phục độ phân giải qua UpConv; các kết nối tắt nối đặc trưng cùng cấp từ encoder sang decoder để bù thông tin vị trí không gian bị mất

2.2.3 Cơ chế chú ý và kiến trúc Attention U-Net

Mặc dù các kết nối tắt trong U-Net mang lại hiệu quả cao, chúng đồng thời mang theo cả những tín hiệu nhiễu từ nền (background noise) từ bộ mã hóa sang bộ giải mã. Để khắc phục điều này, cơ chế chú ý (Attention Mechanism) được áp dụng nhằm mô phỏng khả năng tập trung thị giác của con người: tự động nhấn mạnh các vùng ảnh chứa thông tin quan trọng và ức chế các vùng không liên quan.


Kiến trúc Attention U-Net [oktay2018attentionunet] cụ thể hóa cơ chế này bằng cách chèn các **Cổng chú ý (Attention Gates - AG)** vào ngay vị trí của các kết nối tắt. Cổng chú ý nhận hai luồng tín hiệu: bản đồ đặc trưng từ tầng mã hóa $\mathbf{x}^l$ và tín hiệu hướng dẫn $\mathbf{g}$ (gating signal) lấy từ tầng sâu hơn của bộ giải mã (nơi chứa thông tin ngữ nghĩa mạnh).

Hệ số chú ý không gian $\boldsymbol{\alpha}^l \in [0, 1]^{H \times W}$ được tính toán như sau:

$$\boldsymbol{\alpha}^l = \sigma_2 \left(\mathbf{W}_\psi^\top \cdot \sigma_1 \left(\mathbf{W}_x \mathbf{x}^l + \mathbf{W}_g \mathbf{g} + \mathbf{b}_g \right) + b_\psi \right) \quad (2.2)$$

trong đó σ_1 là hàm kích hoạt ReLU, σ_2 là hàm Sigmoid, và $\{\mathbf{W}_x, \mathbf{W}_g, \mathbf{W}_\psi, \mathbf{b}_g, b_\psi\}$ là các tham số học được của Cổng chú ý. Bản đồ đặc trưng sau đó được nhân vô hướng (element-wise multiplication) với hệ số chú ý để làm nổi bật các khu vực cần thiết: $\hat{\mathbf{x}}^l = \boldsymbol{\alpha}^l \odot \mathbf{x}^l$.

Nhận xét: Cơ chế Attention Gate giúp bộ giải mã tập trung tốt hơn vào vùng tổn thương. Tuy nhiên, tín hiệu hướng dẫn $\mathbf{g}$ trong mạng Attention U-Net vẫn được trích xuất hoàn toàn từ ảnh đầu vào. Nghĩa là, hệ thống vẫn phải "tự dự đoán" vùng quan tâm mà không có sự định hướng tiên nghiệm. Điều này đòi hỏi một cơ chế điều kiện hóa mạnh mẽ hơn từ tri thức chuyên gia (người dùng), tạo tiền đề cho việc phát triển kiến trúc chú ý có điều kiện dựa trên câu nhắc (Conditioned Attention) sẽ được trình bày ở Chương 3.



images/diagram_attunet.png

Hình 2.3: Kiến trúc Attention U-Net: các Cổng chú ý (Attention Gates) được chèn tại các kết nối tắt, sử dụng tín hiệu gating $\mathbf{g}$ từ bộ giải mã để lọc bỏ nhiễu nền trước khi truyền đặc trưng sang tầng giải mã tương ứng

2.3 Học máy dựa trên câu nhắc trong thị giác máy tính

Trong những năm gần đây, khái niệm "câu nhắc" (prompt) vốn khởi nguồn từ lĩnh vực Xử lý ngôn ngữ tự nhiên (NLP) đã được ứng dụng mạnh mẽ vào Thị giác máy tính. Thay vì huấn luyện một mô hình tĩnh để tự động giải quyết một tác vụ cố định, học máy dựa trên câu nhắc cho phép mô hình linh hoạt điều chỉnh hành vi dự đoán dựa trên thông tin định hướng bổ sung (như văn bản, điểm ảnh, hoặc hộp giới hạn) do người dùng cung cấp ở pha suy luận.

2.3.1 Biểu diễn không gian của câu nhắc trực quan

Trong các phần mềm chẩn đoán hình ảnh, thao tác tương tác tự nhiên nhất của chuyên gia y tế là kéo chuột để tạo một hộp giới hạn (Bounding Box) bao quanh vùng tổn thương nghi ngờ. Giả sử hộp giới hạn này được định nghĩa bởi tọa độ hai góc đối diện $\mathbf{B} = (x_1, y_1, x_2, y_2)$. Thách thức đặt ra là làm thế nào để mã hóa tọa độ hình học này thành một định dạng mà mạng CNN có thể xử lý đồng thời với ảnh đầu vào.

Giải pháp tối ưu và được áp dụng phổ biến là chuyển đổi hộp giới hạn thành một **Bản đồ nhiệt câu nhắc** (Prompt Heatmap) $\mathbf{H} \in [0, 1]^{H \times W}$, mang cùng độ phân giải không gian với ảnh X-quang. Thay vì tạo ra một mặt nạ nhị phân cứng nhắc (chỉ chứa giá trị 1 bên trong và 0 bên ngoài hộp), bản đồ nhiệt sử dụng hàm phân phối chuẩn hai chiều (2D Gaussian) để biểu diễn mức độ tin cậy về mặt không gian.

Tâm hình học của hộp giới hạn được xác định là (μ_x, μ_y) với $\mu_x = \frac{x_1+x_2}{2}$ và $\mu_y = \frac{y_1+y_2}{2}$. Phân phối không gian của bản đồ nhiệt được tính theo phương trình:

$$H(x, y) = \exp \left(-\frac{(x - \mu_x)^2}{2\sigma_x^2} - \frac{(y - \mu_y)^2}{2\sigma_y^2} \right) \quad (2.3)$$

trong đó, σ_x và σ_y là độ lệch chuẩn (standard deviation) kiểm soát độ rộng của hàm Gaussian theo trục x và y . Thông thường, các giá trị này được cấu hình tỉ lệ thuận với kích thước chiều rộng và chiều cao của hộp giới hạn (ví dụ: $\sigma_x = \frac{x_2 - x_1}{4}$ và $\sigma_y = \frac{y_2 - y_1}{4}$).

Cách biểu diễn không gian này mang ý nghĩa lâm sàng sâu sắc: giá trị $H(x, y)$ đạt cực đại (1.0) tại tâm của vùng bác sĩ khoanh (nơi có độ chắc chắn cao nhất về sự tồn tại của u), và giảm dần (decay) một cách mềm mại (smooth) về phía các cạnh. Điều này giúp mô hình không bị “ép buộc” học các đường biên sắc nét giả tạo từ nét khoanh tay của con người, mà coi đó là một prior (thông tin tiên nghiệm) hướng dẫn sự chú ý.

Biến thể triển khai – Plateau Heatmap: Trong thực tế, một biến thể phổ biến là *Plateau Heatmap*: gán đồng nhất giá trị 1.0 cho toàn bộ vùng bên trong hộp giới hạn (tạo vùng cao nguyên phẳng), sau đó làm mềm đường biên bằng bộ lọc Gaussian. Cách này duy trì tín hiệu mạnh và đồng đều bên trong vùng câu nhắc (thay vì suy giảm về phía tâm), phù hợp hơn khi kích thước câu nhắc sát với kích thước tổn thương. Thiết kế trong khóa luận này sử dụng biến thể Plateau Heatmap (trình bày ở Mục ??), trong khi phương trình Gaussian (??) đóng vai trò nền tảng lý thuyết cho cả hai biến thể.

2.3.2 Cơ chế chú ý có điều kiện

Sau khi đã có bản đồ nhiệt câu nhắc $\mathbf{H}$, bài toán tiếp theo là làm sao để "tiêm" (inject) thông tin này vào kiến trúc mạng U-Net. Cách đơn giản nhất là ghép nối kênh (channel concatenation) trực tiếp $\mathbf{H}$ với ảnh X-quang gốc ở ngay tầng đầu vào (Early Fusion). Tuy nhiên, cách làm này thường dẫn đến việc tín hiệu định hướng bị mờ nhạt dần khi đi qua các tầng tích chập sâu.

Một giải pháp lý thuyết triệt để hơn là **Cơ chế chú ý có điều kiện (Conditioned Attention)**. Ý tưởng cốt lõi của cơ chế này là mở rộng Cổng chú ý (Attention Gate) truyền thống (đã trình bày ở Mục ??). Trong

Attention U-Net truyền thống, hệ số chú ý α được sinh ra chỉ từ nội bộ các đặc trưng ảnh. Ngược lại, trong cơ chế có điều kiện, việc tính toán hệ số chú ý được ràng buộc (conditioned) rõ ràng bởi ma trận định hướng $\mathbf{H}$.

Về mặt khái niệm, bản đồ chú ý lúc này được biểu diễn dưới dạng xác suất có điều kiện: $\alpha = f(\mathbf{x}, \mathbf{g} \mid \mathbf{H})$. Nhờ đó, tại mỗi tầng của bộ giải mã, mạng nơ-ron bị "ép" phải đối chiếu lại các đặc trưng ngữ nghĩa mà nó học được với vùng không gian đã được bác sĩ chỉ định. Bất kỳ tín hiệu đặc trưng nào nằm ngoài vùng kích hoạt của $\mathbf{H}$ sẽ bị ức chế mạnh mẽ, giải quyết triệt để vấn đề mạng cắt lẩn sang mô xương lành lân cận. Cơ sở lý thuyết này chính là nền tảng để thiết kế kiến trúc PGA-UNet trong Chương 3 của khóa luận.

2.4 Các độ đo đánh giá hiệu năng

Trong bài toán phân đoạn ảnh y khoa, việc chỉ sử dụng một độ đo duy nhất thường không phản ánh được bức tranh toàn cảnh về chất lượng của mô hình. Một mô hình có thể có tỷ lệ chồng lấp diện tích tốt nhưng lại có đường biên lởm chởm, hoặc ngược lại. Do đó, khóa luận sử dụng một bộ độ đo toàn diện bao gồm các khía cạnh: diện tích vùng (Dice, IoU), xu hướng phân loại (Precision, Recall), chất lượng đường biên (HD95) và độ chuẩn xác vị trí tâm (CBL).

2.4.1 Hệ số Dice và chỉ số IoU

Hệ số Dice (Dice Similarity Coefficient - DSC) và chỉ số Giao trên Hợp (Intersection over Union - IoU, hay Jaccard Index) là hai thang đo tiêu chuẩn phổ biến nhất để đánh giá mức độ chồng lấp không gian giữa mặt nạ dự đoán $\hat{Y}$ và mặt nạ nhãn gốc Y .

Hệ số Dice: Đo lường gấp đôi diện tích phần giao nhau chia cho tổng

diện tích của cả hai mặt nạ.

$$\text{Dice}(Y, \hat{Y}) = \frac{2|Y \cap \hat{Y}|}{|Y| + |\hat{Y}|} \quad (2.4)$$

Chỉ số IoU: Đo lường diện tích phần giao nhau chia cho diện tích phần hợp của hai mặt nạ.

$$\text{IoU}(Y, \hat{Y}) = \frac{|Y \cap \hat{Y}|}{|Y \cup \hat{Y}|} \quad (2.5)$$

Cả hai độ đo đều nhận giá trị trong khoảng $[0, 1]$, trong đó 1 thể hiện sự trùng khớp hoàn hảo. Trong bối cảnh ảnh y khoa, nơi vùng tổn thương (foreground) thường chiếm tỷ lệ rất nhỏ so với vùng nền (background), Dice và IoU là các thước đo đáng tin cậy hơn so với độ chính xác tổng thể (Accuracy) vì chúng không bị chệch bởi sự áp đảo của vùng nền.

2.4.2 Độ chính xác (Precision) và Độ bao phủ (Recall)

Bên cạnh Dice và IoU, Độ chính xác (Precision) và Độ bao phủ (Recall, hay Sensitivity) cung cấp góc nhìn chi tiết hơn về xu hướng dự đoán sai của mô hình (thiên về cắt lấn nhầm hay bỏ sót u). Gọi TP là True Positive (dự đoán đúng tổn thương), FP là False Positive (dự đoán nhầm nền thành tổn thương), và FN là False Negative (bỏ sót tổn thương thực sự).

Độ chính xác (Precision): Đo lường tỷ lệ điểm ảnh là tổn thương thực sự trên tổng số điểm ảnh mà mô hình đã khoanh vùng.

$$\text{Precision} = \frac{TP}{TP + FP} \quad (2.6)$$

Độ bao phủ (Recall): Đo lường tỷ lệ điểm ảnh tổn thương thực sự

đã được mô hình nhận diện thành công.

$$\text{Recall} = \frac{TP}{TP + FN} \quad (2.7)$$

Trong thực tế lâm sàng, sự cân bằng giữa Precision và Recall rất quan trọng. Nếu mô hình cắt quá rộng (lan sang cấu trúc xương lành), Recall sẽ cao nhưng Precision giảm sút; ngược lại, nếu mô hình cắt quá dè dặt (bỏ sót viền của u), Precision cao nhưng Recall sẽ thấp.

2.4.3 Khoảng cách Hausdorff 95% (HD95)

Các thang đo dựa trên diện tích (Dice, IoU) có một điểm yếu cơ bản: chúng không nhạy cảm với hình dáng của đường biên. Một mặt nạ dự đoán có thể có cùng diện tích chồng lấp nhưng đường viền lại rất lổm chổm. Khoảng cách Hausdorff (Hausdorff Distance - HD) giải quyết vấn đề này bằng cách đánh giá mức độ sai lệch lớn nhất giữa hai đường biên.

Cho X và Y lần lượt là tập hợp các điểm ảnh nằm trên đường biên của mặt nạ dự đoán và mặt nạ gốc. Khoảng cách Hausdorff hai chiều cực đại được định nghĩa là:

$$\text{HD}(X, Y) = \max \left(\sup_{x \in X} \inf_{y \in Y} d(x, y), \sup_{y \in Y} \inf_{x \in X} d(x, y) \right) \quad (2.8)$$

trong đó $d(x, y)$ là khoảng cách Euclidean giữa hai điểm x và y .

Do công thức HD cơ bản sử dụng hàm cực đại (max và sup), nó cực kỳ nhạy cảm với các điểm nhiễu ngoại lai (outliers) trên đường biên. Vì vậy, khóa luận sử dụng **Khoảng cách Hausdorff 95% (HD95)**. Thang đo này tính toán khoảng cách của tất cả các cặp điểm, sau đó loại bỏ 5% các giá trị lớn nhất (được xem là nhiễu) và lấy giá trị cực đại của 95% còn lại. Đơn vị của HD95 là pixel; giá trị càng nhỏ chứng tỏ đường biên của mô hình càng bám sát với đường biên của nhãn thực tế.

2.4.4 Độ chuẩn xác định vị tâm (CBL)

Hệ số Dice và HD95 đánh giá chất lượng phân đoạn đầu ra, nhưng không phản ánh được độ lệch không gian giữa tâm dự đoán và tâm tổn thương thực tế. Để đánh giá tính chính xác định vị không gian của hệ thống trong các kịch bản câu nhắc bị lệch, khóa luận sử dụng độ đo Độ chuẩn xác định vị tâm (Center-Based Localization - CBL).

CBL đo lường khoảng cách hình học giữa tâm của mặt nạ dự đoán và tâm của mặt nạ gốc, sau đó được chuẩn hóa bởi kích thước của đối tượng để đảm bảo tính công bằng khi đánh giá các khối u có kích thước khác nhau.

$$\text{CBL} = \max \left(0, 1 - \frac{\sqrt{(x_p - x_g)^2 + (y_p - y_g)^2}}{D_{gt}} \right) \quad (2.9)$$

trong đó, (x_p, y_p) là tọa độ tâm của vùng dự đoán, (x_g, y_g) là tọa độ tâm của nhãn gốc, và D_{gt} là độ dài đường chéo của hộp giới hạn nhỏ nhất bao quanh nhãn gốc. Giá trị CBL bằng 1.0 khi tâm dự đoán trùng khớp hoàn toàn với tâm thực tế, và tiến về 0 khi khoảng cách sai lệch vượt quá kích thước đường chéo của tổn thương.

2.5 Tổng kết chương

Chương 2 đã cung cấp bức tranh toàn cảnh và các cơ sở lý thuyết toán học vững chắc làm nền tảng cho khóa luận. Việc khảo sát ba kiến trúc đối sánh chính (U-Net, Attention U-Net, SAM-Med2D) làm nổi bật khoảng trống nghiên cứu: cần một kiến trúc CNN hạng nhẹ tích hợp câu nhắc trực quan từ bác sĩ và có cơ chế phòng vệ khi câu nhắc sai.

Bên cạnh đó, các lý thuyết về chuyển đổi hộp giới hạn thành bản đồ nhiệt, Công chú ý có điều kiện, là những nền tảng cốt lõi sẽ được tích hợp vào kiến trúc PGA-UNet trình bày ở Chương 3.

Chương 3

MÔ HÌNH VÀ HỆ THỐNG ĐỀ XUẤT

3.1 Kiến trúc tổng thể của hệ thống

Hệ thống hỗ trợ chẩn đoán hình ảnh đề xuất trong khóa luận được thiết kế dưới dạng một luồng xử lý đầu cuối (end-to-end pipeline), kết hợp chặt chẽ giữa khả năng tự động hóa của mô hình học sâu và tri thức lâm sàng của chuyên gia y tế (bác sĩ). Kiến trúc tổng thể được chia thành các module hoạt động liên hoàn, phản ánh đúng quy trình làm việc thực tế tại các cơ sở y tế nhằm đảm bảo tính chính xác và an toàn cao. Luồng xử lý của hệ thống được vận hành qua ba giai đoạn cốt lõi:

- 1. Giai đoạn tiền xử lý và làm sạch dữ liệu:** Ảnh X-quang thô đầu vào trong thực tế thường chứa nhiều nhiễu kỹ thuật (như ký tự R/L đánh dấu hướng chụp) và độ tương phản kém do các cấu trúc mô mềm và xương chồng lấp. Module tiền xử lý đóng vai trò làm sạch các vùng nhiễu này, đồng thời cân bằng biểu đồ mức xám và chuẩn hóa giá trị pixel. Bước này nhằm cung cấp một đầu vào sạch, chuẩn mực và ổn định cho toàn bộ các mô hình học sâu phía sau.

- 2. Giai đoạn sàng lọc bệnh lý (Mô hình gác cổng):** Sau khi được làm sạch, ảnh tiếp tục đi qua một mạng nơ-ron tích chập đóng vai

trò phân loại nhị phân. Hệ thống sẽ tính toán xác suất tồn tại của khối u hoặc các tổn thương bất thường.

- Nếu kết quả dự đoán là âm tính (bình thường) và chuyên gia đồng thuận, luồng chẩn đoán sẽ khép lại, giúp tiết kiệm thời gian khám chữa bệnh.
- Nếu hệ thống đưa ra cảnh báo dương tính (có bệnh lý), quyền điều khiển được trao lại cho bác sĩ để chuyển sang bước bóc tách tổn thương chi tiết.

3. Giai đoạn phân đoạn có hướng dẫn (PGA-UNet): Ở giai đoạn này, hệ thống hoạt động theo cơ chế học máy tương tác (Interactive Learning). Bác sĩ thực hiện thao tác khoanh một hộp giới hạn (Bounding Box) bao quanh vị trí nghi ngờ trên giao diện. Tọa độ của hộp giới hạn ngay lập tức được hệ thống chuyển đổi thành một bản đồ nhiệt không gian (Prompt Heatmap). Ảnh X-quang sạch và bản đồ nhiệt câu nhắc được đưa song song vào mô hình PGA-UNet (Prompt-Guided Attention U-Net). Bằng việc kích hoạt các cổng không gian và cơ chế chú ý có điều kiện, mô hình bị ép buộc phải hội tụ sự tập trung vào vùng được chỉ định để trích xuất hình dáng chính xác của khối u, tạo ra một mặt nạ phân đoạn thô.

Sự phân chia module rõ ràng trong kiến trúc không chỉ giúp hệ thống hoạt động linh hoạt, dễ dàng cô lập và xử lý lỗi, mà còn tạo điều kiện thuận lợi cho việc nâng cấp, thay thế từng thành phần độc lập trong tương lai. Chi tiết về cơ sở kỹ thuật, thiết kế cấu trúc mạng và công thức toán học của từng module sẽ được trình bày cụ thể trong các mục tiếp theo của chương này.



Hình 3.1: Kiến trúc tổng thể hệ thống hỗ trợ chẩn đoán: ba giai đoạn liên hoàn từ tiền xử lý ảnh, sàng lọc bệnh lý (MobileNetV4) đến phân đoạn có hướng dẫn (PGA-UNet)

3.2 Tiền xử lý dữ liệu và loại bỏ nhiễu ảnh X-quang

Chất lượng dữ liệu đầu vào ảnh hưởng trực tiếp đến năng lực học của bất kỳ mô hình học sâu nào. Trong bài toán phân đoạn ảnh X-quang y khoa, những nhiễu kỹ thuật tuy không liên quan đến bệnh lý nhưng lại có độ tương phản rất cao, dễ khiến mạng nơ-ron học sai đặc trưng và trả về kết quả phân đoạn không đáng tin cậy. Mục này trình bày đặc điểm của bộ dữ liệu BTXRD được sử dụng trong khóa luận, các vấn đề nhiễu đặc thù và quy trình tiền xử lý đã được xây dựng để đảm bảo đầu vào sạch, chuẩn hóa cho toàn bộ quá trình huấn luyện.

3.2.1 Bộ dữ liệu BTXRD

Bộ dữ liệu được sử dụng trong khóa luận là **BTXRD** (*Bone Tumor X-Ray Dataset*), một tập ảnh X-quang xương thực tế được công bố dưới dạng tài nguyên khoa học mở trên tạp chí *Nature Scientific Data* [btxrd2024]. Đây là bộ dữ liệu hiếm hoi trong lĩnh vực y tế cung cấp đồng thời ba cấp độ nhãn: nhãn phân lớp (classification label), nhãn định vị đối tượng (localization label) và mặt nạ phân đoạn ở cấp độ điểm ảnh (pixel-level segmentation mask).

Đặc điểm nổi bật của BTXRD:

- Ảnh X-quang xương thực tế thu thập từ cơ sở lâm sàng, tập trung vào các cấu trúc có độ tương phản thấp và dễ gây nhầm lẫn trên lâm sàng (điển hình: X-quang gót chân, cổ chân, chi trên).
- Bao gồm cả ảnh có khối u xương (nhãn 1 - *bệnh lý*) và ảnh xương bình thường (nhãn 0 - *lành lặn*), phản ánh đúng phân phối thực tế trong môi trường sàng lọc lâm sàng.
- Dữ liệu thô chứa nhiều loại nhiễu kỹ thuật đặc thù của thiết bị chụp

X-quang: ký tự chỉ hướng R/L (Right/Left), các nhãn metadata, và đôi khi là dị vật cản quang xuất hiện trên ảnh.

Bộ dữ liệu này phục vụ hai mục đích song song trong kiến trúc hệ thống: (1) toàn bộ ảnh (cả lành lặn và bệnh lý) được sử dụng để huấn luyện **mô hình phân lớp** sàng lọc ban đầu; (2) chỉ ảnh có bệnh lý kèm theo mặt nạ phân đoạn được sử dụng để huấn luyện **mô hình phân đoạn** PGA-UNet.

3.2.2 Các loại nhiễu đặc thù trong ảnh X-quang BTXRD

Ảnh X-quang trong bộ BTXRD, dù là dữ liệu lâm sàng thực tế, mang theo những loại nhiễu kỹ thuật phổ biến sau:

1. Ký tự chỉ hướng R/L: Đây là loại nhiễu phổ biến nhất trong X-quang lâm sàng. Các ký tự kim loại hoặc dải nhựa cản quang ký hiệu bên Phải (R) hoặc bên Trái (L) được đặt lên tấm phim trước khi chụp nhằm xác định hướng giải phẫu. Trên ảnh X-quang số hóa, chúng xuất hiện dưới dạng các điểm sáng có độ tương phản cực cao. Nếu không được loại bỏ, các đốm sáng này có thể bị mạng nơ-ron nhận nhầm là tổn thương xương, dẫn đến kết quả phân đoạn sai hoàn toàn.

2. Metadata và nhãn kỹ thuật: Một số ảnh chứa các chuỗi ký tự kỹ thuật (ngày tháng, mã bệnh viện, thông số máy) được nhúng trực tiếp vào ảnh. Mặc dù nhỏ hơn ký tự R/L, chúng vẫn tạo ra gradient bất thường trong bộ mã hóa (encoder) nếu không được xử lý.

3. ICC Profile trong tệp PNG: Nhiều ảnh PNG thu thập từ thiết bị y tế có nhúng thông tin ICC Profile (International Color Consortium) vào metadata. Mặc dù không ảnh hưởng đến nội dung hình ảnh trực quan, ICC Profile bất hợp lệ gây lỗi khi đọc bằng thư viện OpenCV trong Python, khiến hình ảnh bị đọc sai kênh màu hoặc không thể đọc được. Đây là vấn đề kỹ thuật cần giải quyết trước bất kỳ bước tiền xử lý nào.

3.2.3 Quy trình tiền xử lý và loại bỏ nhiễu

Để giải quyết các vấn đề trên một cách có hệ thống, nhóm xây dựng một quy trình tiền xử lý đa bước gồm 6 bước tuần tự được mô tả dưới đây.

Bước 1 — Xóa ICC Profile: Toàn bộ các tệp PNG trong bộ dữ liệu được quét và xử lý bằng script `clean_data.py`: hệ thống đọc từng ảnh vào bộ nhớ bằng `cv2.IMREAD_UNCHANGED` rồi ghi lại ngay tại chỗ bằng `cv2.imwrite()`. Khi OpenCV ghi ảnh, thư viện chỉ lưu dữ liệu điểm ảnh thuần túy theo chuẩn PNG, tự động loại bỏ mọi khối metadata ngoại lai (bao gồm ICC Profile). Kết quả là toàn bộ tập ảnh được "rửa sạch" mà không làm biến đổi bất kỳ giá trị pixel nào.

Bước 2 — Phát hiện và xóa ký tự nhiễu bằng YOLOv11s: Đây là bước xử lý cốt lõi và phức tạp nhất của quy trình. Nhóm sử dụng mô hình phát hiện đối tượng **YOLOv11s** [`yolov11`] (phiên bản nhỏ gọn của họ YOLO thế hệ 11) để xác định chính xác tọa độ (hộp giới hạn) của từng vùng nhiễu trên ảnh. Sau khi xác định được vùng nhiễu, các vùng này được xóa và phục hồi bằng kỹ thuật nội suy (inpainting).

Quy trình xây dựng và huấn luyện mô hình phát hiện nhiễu gồm các bước sau:

1. **Gán nhãn dữ liệu (Annotation):** Nền tảng **Roboflow** [`roboflow2023`] được sử dụng để vẽ thủ công hộp giới hạn cho tất cả các vùng nhiễu (ký tự R/L, nhãn kỹ thuật) trên toàn bộ tập ảnh BTXRD. Tập dữ liệu đã gán nhãn được phân chia theo tỷ lệ 90/10 cho huấn luyện và đánh giá.
2. **Cấu hình huấn luyện:** Mô hình `yolo11s` được khởi tạo với trọng số tiền huấn luyện trên tập COCO. Ảnh đầu vào được đệm thêm (padding) về tỷ lệ vuông rồi thay đổi kích thước về 1024×1024 pixel. Quá trình huấn luyện chạy tối đa 100 epoch với cơ chế dừng sớm (patience = 10) và thuật toán tối ưu AdamW (tốc độ học 10^{-3}), mỗi lô gồm 8 ảnh.



Hình 3.2: Quy trình tiền xử lý dữ liệu: chuyển JPEG $\rightarrow$ PNG (xóa ICC Profile), upload và gán nhãn bounding box thủ công trên Roboflow (2000/3746 ảnh), huấn luyện YOLOv11s, phát hiện vùng nhiễu R/L trên toàn bộ tập, xóa nhiễu bằng inpainting, chuẩn hóa thang xám và resize 512×512

3. **Suy luận và xóa nhiễu:** Sau khi huấn luyện, mô hình YOLO duyệt qua toàn bộ tập ảnh, xuất ra danh sách Bounding Box cho các vùng nhiễu. Mỗi vùng được xóa và lấp đầy bằng giá trị lân cận phù hợp, đảm bảo bề mặt ảnh liền mạch tự nhiên.

Hiệu năng của mô hình phát hiện nhiễu trên tập đánh giá được tổng hợp tại Bảng ??.

Bảng 3.1: Kết quả của mô hình YOLOv11s trong bài toán phát hiện và định vị nhiễu ảnh X-quang

Chỉ số đánh giá	Kết quả
Độ chính xác (Precision – P)	99.6%
Độ nhạy (Recall – R)	96.2%
Độ chính xác vùng phát hiện (mAP ₅₀)	98.6%
Độ chính xác đa ngưỡng (mAP ₅₀₋₉₅)	66.2%

Độ chính xác Precision 99.6% đặc biệt quan trọng trong ngữ cảnh y tế: nó đảm bảo mô hình gần như không bao giờ nhầm cấu trúc xương giải phẫu thành nhiễu và xóa nhầm, một lỗi có hậu quả nghiêm trọng cho chất lượng dữ liệu huấn luyện phân đoạn. Recall 96.2% cho thấy hệ thống quét sạch được phần lớn nhiễu, chỉ bỏ sót một tỷ lệ nhỏ các ký tự quá mờ hoặc quá nhỏ.

Bước 3 — Chuẩn hóa thang xám: Ảnh X-quang sau khi làm sạch được chuyển về định dạng thang xám (*Grayscale*) 8-bit chuẩn nếu chưa ở định dạng đó, đảm bảo tính đồng nhất cho toàn bộ pipeline nhập liệu.

3.2.4 Gán nhãn phân đoạn và định dạng dữ liệu

Sau khi ảnh được làm sạch, nhóm tiến hành gán nhãn phân đoạn thủ công ở cấp độ điểm ảnh (pixel-level) cho tập ảnh có bệnh lý:

Công cụ và định dạng: Nhóm sử dụng phần mềm **LabelMe** để vẽ trực tiếp đường viền đa giác (Polygon) bao quanh từng vùng khối u/tổn

thương tương. Mỗi ảnh có thể chứa một hoặc nhiều polygon tương ứng với nhiều tổn thương khác nhau. Dữ liệu gán nhãn được xuất ra định dạng **JSON** theo cấu trúc chuẩn của LabelMe, trong đó mỗi polygon được lưu dưới dạng danh sách tọa độ điểm đỉnh.

Cơ chế mở rộng dữ liệu từ polygon: Một điểm quan trọng trong pipeline dữ liệu của PGA-UNet là mỗi polygon được xử lý như một *training sample độc lập*. Nếu một ảnh chứa k polygon (tương ứng k tổn thương khác nhau), hệ thống sẽ sinh ra k mẫu huấn luyện riêng biệt, mỗi mẫu bao gồm ảnh đầy đủ, mặt nạ của đúng polygon đó, và câu nhắc được tạo từ Bounding Box bao quanh polygon đó. Cơ chế này tự nhiên làm tăng hiệu quả sử dụng dữ liệu mà không cần augmentation nhân tạo.

Hai định dạng dữ liệu song song: Để phục vụ cả mô hình đề xuất và các mô hình cơ sở, dữ liệu được chuẩn bị ở hai dạng:

- **Định dạng JSON Polygon** (dành cho PGA-UNet): Ảnh gốc cùng tệp JSON annotation được resize về 512×512 . Mặt nạ được sinh ra ngay trong *DataLoader* bằng hàm `cv2.fillPoly()` từ tọa độ polygon, đảm bảo độ chính xác tối đa khi resize.
- **Định dạng PNG Mask** (dành cho U-Net, Attention U-Net cơ sở): Mặt nạ được xuất trước thành ảnh PNG nhị phân, lưu cùng thư mục với ảnh gốc, resize về 256×256 .

3.2.5 Chuẩn hóa và tăng cường dữ liệu

Chuẩn hóa pixel (Normalization): Toàn bộ ảnh thang xám sau resize được chuẩn hóa về khoảng $[-1, 1]$ theo công thức:

$$x_{\text{norm}} = \frac{x/255 - 0.5}{0.5} \quad (3.1)$$

Cách chuẩn hóa này ($\mu = 0.5$, $\sigma = 0.5$) đưa phân phối pixel về trung tâm, giúp thuật toán tối ưu AdamW hội tụ nhanh hơn và ổn định hơn trong giai đoạn đầu huấn luyện.

Tăng cường dữ liệu đồng bộ (Synchronized Augmentation):

Do PGA-UNet nhận đồng thời ba đầu vào (ảnh, mặt nạ, bản đồ nhiệt câu nhắc), mọi phép biến đổi hình học phải được áp dụng *đồng bộ hoàn toàn* trên cả ba thành phần. Nếu ảnh bị lật ngang, mặt nạ và câu nhắc cũng phải lật ngang tương ứng — một sự không khớp không gian giữa câu nhắc và mặt nạ sẽ dạy mạng sai chiều hoàn toàn. Hai phép biến đổi hình học được áp dụng trong quá trình huấn luyện:

- **Lật ngang ngẫu nhiên (Random Horizontal Flip):** Xác suất 50%, áp dụng đồng thời cho cả ba tensor.
- **Xoay ngẫu nhiên (Random Rotation $\pm 15^\circ$):** Góc xoay lấy đều trong khoảng $[-15^\circ, +15^\circ]$. Ảnh và câu nhắc sử dụng nội suy song tuyến (bilinear), mặt nạ sử dụng nội suy láng giềng gần nhất (nearest-neighbor) để bảo toàn giá trị nhị phân.

Trong quá trình huấn luyện PGA-UNet, để tăng tính bền bỉ (robustness) của mô hình trước các câu nhắc không hoàn hảo, 15% số mẫu ngẫu nhiên được thay thế câu nhắc bằng bản đồ nhiệt zero (câu nhắc rỗng), và 15% khác được thêm nhiễu Gaussian vào câu nhắc. Chiến lược này buộc mô hình không được phụ thuộc mù quáng vào câu nhắc mà phải kết hợp với đặc trưng hình ảnh để đưa ra quyết định.

3.3 Mô hình phân đoạn PGA-UNet (Prompt-Guided Attention U-Net)

Kiến trúc mạng PGA-UNet được đề xuất trong khóa luận không sử dụng cách tiếp cận nối kênh tĩnh (static concatenation) truyền thống. Thay vào đó, mạng được thiết kế để tích hợp tri thức định hướng từ chuyên gia một cách linh hoạt và sâu sát vào cả hai tiến trình: mã hóa (rút trích đặc trưng) và giải mã (khôi phục hình dáng). Sự cải tiến này được thực hiện thông qua ba thành phần cấu trúc cốt lõi dưới đây.

3.3.1 Biểu diễn câu nhắc trực quan (Prompt Heatmap Representation)

Nhằm chuyển đổi thao tác không gian của người dùng thành một định dạng số học mang tính chất dẫn đường mềm dẻo (soft guidance), tọa độ hộp giới hạn $\mathbf{B} = (x_1, y_1, x_2, y_2)$ do bác sĩ cung cấp sẽ được biểu diễn dưới dạng Bản đồ nhiệt câu nhắc $\mathbf{H}_{prompt} \in [0, 1]^{H \times W}$.

Trong thiết kế lý thuyết, bản đồ nhiệt câu nhắc có thể xây dựng theo phân phối Gaussian 2D thuần túy như đã trình bày tại Phương trình (??), với cường độ đạt cực đại tại tâm và phân rã dần về biên. Tuy nhiên, trong thực tế triển khai, nhóm sử dụng phương pháp **Plateau Heatmap**: vùng bên trong hộp giới hạn được gán đồng nhất giá trị 1.0 (tạo vùng cao nguyên phẳng - plateau), sau đó làm mềm đường biên bằng bộ lọc Gaussian (kernel 31×31):

$$\mathbf{H}_{prompt} = \text{GaussianBlur}(\mathbf{B}_{\text{mask}}, k = 31) \quad (3.2)$$

trong đó $\mathbf{B}_{\text{mask}} \in \{0, 1\}^{H \times W}$ là mặt nạ nhị phân của hộp giới hạn (có đệm 5 px mỗi phía). Cách tiếp cận này giữ được tín hiệu dẫn đường mạnh và đồng đều bên trong vùng câu nhắc (không bị suy giảm về phía tâm như Gaussian thuần), đồng thời tạo ra đường chuyển tiếp mượt mà ở viền hộp để mạng không học các gradient giả tạo từ đường viền sắc nét. Bản đồ nhiệt $\mathbf{H}_{prompt}$ này đóng vai trò như một kênh dữ liệu độc lập, song hành cùng ảnh X-quang đi vào mạng.

Cơ sở lý thuyết: Tại sao chọn biểu diễn liên tục có gradient thay vì mặt nạ nhị phân? Câu hỏi đặt ra là tại sao không dùng mặt nạ nhị phân phẳng — trong đó mọi điểm ảnh bên trong hộp giới hạn nhận giá trị 1 và bên ngoài là 0 — thay vì bản đồ nhiệt liên tục. Câu trả lời nằm ở bản chất của phép tích chập và cơ chế dung hợp đặc trưng trong U-Net. Khi một mặt nạ nhị phân đi qua tầng tích chập, đường biên sắc nét tại viền hộp giới hạn tạo ra các gradient giả tạo (pseudo-gradients) — mạng có thể học cạnh của hộp bao thay vì đặc trưng thực của tổn thương. Ngược lại,

Plateau Heatmap cung cấp tín hiệu mạnh và đồng đều bên trong (đảm bảo câu nhắc rõ nét), nhưng chuyển tiếp mượt mà ở viền thông qua bộ lọc Gaussian. Thiết kế này phù hợp với bản chất tự nhiên của attention bias: cổng không gian tại phương trình (??) cần một tín hiệu liên tục để thực hiện phép nhân theo phần tử trên feature map mà không tạo ra hiệu ứng ringing.

Ngoài ra, cơ sở tri thức về bản đồ kích hoạt trong học sâu cũng hỗ trợ thiết kế này: các bản đồ nhiệt Grad-CAM [selvaraju2019gradcam] và saliency map đã chứng minh rằng mạng nơ-ron tự nhiên tạo ra các vùng chú ý có dạng phân phối liên tục, với cường độ cao nhất tại vùng trung tâm đặc trưng nhất và giảm dần ra biên. Biểu diễn Plateau Heatmap của câu nhắc bất chước đặc tính này, tạo ra sự tương thích tự nhiên với cơ chế học của mạng.

So sánh với cách mã hóa prompt của SAM và SAM-Med2D. SAM và SAM-Med2D [2023-SAMMed2D-Cheng] mã hóa hộp giới hạn dưới dạng *positional embedding rời rạc*: tọa độ hai góc của hộp (trên-trái và dưới-phải) được ánh xạ thành hai vector nhúng 256 chiều thông qua bảng tra vị trí sinusoidal. Cách tiếp cận này phù hợp với kiến trúc Transformer của SAM vì Transformer xử lý một tập token rời rạc và tích hợp thông tin vị trí qua phép cộng vector embedding. Tuy nhiên, PGA-UNet sử dụng kiến trúc U-Net với feature map 2D liên tục có cùng cấu trúc không gian $H \times W$ với ảnh đầu vào.

Việc kết hợp một vector embedding rời rạc (256 chiều, không có cấu trúc không gian) vào feature map 2D đòi hỏi phép chiếu phức tạp và dễ mất thông tin vị trí. Biểu diễn bản đồ nhiệt 2D ($H \times W$, cùng không gian với feature map) cho phép Cổng không gian thực hiện phép nhân theo phần tử trực tiếp tại phương trình (??) — một phép toán đơn giản, hiệu quả về tính toán và bảo toàn toàn vẹn thông tin vị trí không gian. Đây là lý do cốt lõi nhóm chọn biểu diễn heatmap 2D thay vì vector embedding rời rạc theo cách SAM: hai kiến trúc khác nhau đòi hỏi hai cách mã hóa prompt

khác nhau để phù hợp nhất với cơ chế dung hợp đặc trưng nội tại.

3.3.2 Cổng không gian tại bộ mã hóa (Prompt Spatial Gate - Encoder)

Trong kiến trúc U-Net truyền thống, bộ mã hóa (Encoder) chịu trách nhiệm trích xuất các đặc trưng ngữ nghĩa. Tuy nhiên, nếu thiếu định hướng, nó có xu hướng học mọi thứ xuất hiện trên ảnh X-quang, dẫn đến việc lãng phí tài nguyên tính toán vào các vùng nền không liên quan.

PGA-UNet khắc phục điều này bằng cách tích hợp cấu kiện **Cổng không gian (Prompt Spatial Gate)** trực tiếp vào nhánh mã hóa. Tại tầng mã hóa thứ l , bản đồ nhiệt $\mathbf{H}^l$ được giảm mẫu về cùng độ phân giải với đặc trưng $\mathbf{x}^l$, sau đó đưa qua một bộ lọc cổng (gate filter) để sinh ra tín hiệu khuếch đại không gian:

$$\tilde{\mathbf{x}}^l = \mathbf{x}^l \odot (1 + \alpha \cdot \sigma(\mathbf{W}_{gate} * \mathbf{H}^l)) \quad (3.3)$$

trong đó $\mathbf{W}_{gate}$ là phép tích chập 1×1 ánh xạ bản đồ nhiệt (1 kênh) sang không gian kênh đặc trưng C^l ; σ là hàm Sigmoid; $\alpha \in [0, 1]$ là tham số học được (khởi tạo nhỏ tại 0.1 để không làm xáo trộn huấn luyện ban đầu); và $\odot$ là phép nhân theo phần tử.

Thiết kế này hoạt động theo nguyên lý *tăng cường có chọn lọc* (selective enhancement) thay vì ức chế: các đặc trưng nằm trong vùng câu nhắc được nhân thêm một hệ số > 1 (tăng lên), trong khi các đặc trưng ngoài vùng câu nhắc (nơi $\mathbf{H}^l \approx 0$) vẫn giữ nguyên giá trị ban đầu (nhân với ≈ 1). Nhờ đó, bộ mã hóa không bị mất thông tin toàn cục nhưng vẫn ưu tiên truyền tải các đặc trưng trong vùng mục tiêu xuống các tầng sâu hơn.

3.3.3 Cơ chế chú ý có điều kiện tại bộ giải mã (Conditioned Attention Decoder)

Dù Cổng không gian ở bộ mã hóa đã giúp loại bỏ nhiều nền đáng kể, nhưng tại bộ giải mã (Decoder) – nơi mạng thực hiện phép tăng mẫu để khôi phục ranh giới xương – tín hiệu định vị vẫn có nguy cơ bị phân tán. Để thiết lập sự dẫn đường xuyên suốt, khóa luận đề xuất thay đổi cấu trúc của *Attention U-Net* thông qua **Cơ chế chú ý có điều kiện**.

Khác với Cổng chú ý (Attention Gate) cơ sở chỉ dùng tín hiệu gating $\mathbf{g}$ từ tầng giải mã bên dưới, cấu kiện `unetUp_PromptAttention` tích hợp tri thức câu nhắc vào tín hiệu gating thông qua **cơ chế dung hợp cộng có trọng số tin cậy** (confidence-weighted additive fusion). Cụ thể, bản đồ câu nhắc $\mathbf{H}_{prompt}$ được giảm mẫu về kích thước của $\mathbf{g}$ và đưa qua một bộ mã hóa hai tầng tích chập (3×3 , InstanceNorm, ReLU) để trích xuất biểu diễn đặc trưng câu nhắc $\mathbf{p}_{enc}$. Từ đó, một điểm số tin cậy vô hướng $c \in (0, 1)$ được tính bằng cách áp dụng GAP (Global Average Pooling) lên $\mathbf{p}_{enc}$:

$$\mathbf{p}_{enc} = f_{enc}(\mathbf{H}_{prompt}), \quad c = \sigma(\text{GAP}(\mathbf{p}_{enc})) \quad (3.4)$$

Tín hiệu gating được điều kiện hóa bằng phép cộng có trọng số:

$$\mathbf{g}' = \mathbf{g} + c \cdot \alpha \cdot w \cdot \mathbf{p}_{enc} \quad (3.5)$$

trong đó $\alpha = \sigma(\alpha_{raw})$ là tham số học được (blend weight), và w là hệ số prompt cố định theo từng tầng giải mã (giảm dần: $1.0 \rightarrow 0.7 \rightarrow 0.4 \rightarrow 0.2$) nhằm suy giảm dần ảnh hưởng của câu nhắc ở các tầng phân giải cao — nơi mạng cần tự do tái tạo chi tiết đường biên.

Tín hiệu $\mathbf{g}'$ sau đó được đưa vào Cổng chú ý (GridAttentionBlock2D) tiêu chuẩn để tính hệ số chú ý α_{cond} điều chỉnh đặc trưng skip connection $\mathbf{x}^l$, kết hợp cùng kết nối tắt dư ($+0.3 \cdot \mathbf{x}^l$) và thêm tín hiệu dư câu nhắc tại đầu ra ($+\beta \cdot \mathbf{H}_{prompt}$). Thiết kế đa lớp này đảm bảo câu nhắc không chỉ ảnh hưởng qua một điểm duy nhất mà được duy trì xuyên suốt toàn bộ bộ


giải mã ở cường độ giảm dần, phù hợp với vai trò hướng dẫn từ ngữ nghĩa đến chi tiết. Sự kết hợp giữa “Cổng không gian tại bộ mã hóa” và “Cơ chế chú ý có điều kiện tại bộ giải mã” là yếu tố chính mang lại sự cải thiện đáng kể về hiệu năng Dice so với các mạng cơ sở hoạt động theo hướng tiếp cận tự động (chi tiết tại Chương ??).

3.3.4 Chiến lược huấn luyện và so sánh với mô hình nền tảng SAM-Med2D

Để tránh hiểu nhầm khi so sánh kết quả thực nghiệm, cần làm rõ sự khác biệt căn bản về chiến lược huấn luyện giữa PGA-UNet và SAM-Med2D.

PGA-UNet — Huấn luyện từ đầu hoàn toàn: Toàn bộ kiến trúc PGA-UNet — bao gồm bộ mã hóa U-Net, các Cổng không gian, khối dung hợp và bộ giải mã có điều kiện — được khởi tạo ngẫu nhiên và học trực tiếp từ tập dữ liệu BTXRD qua tối đa 100 vòng lặp với cơ chế dừng sớm ($\text{patience} = 15$). **Không có thành phần nào được đóng băng** trong quá trình huấn luyện; toàn bộ ~ 4 triệu tham số đều tham gia lan truyền ngược (backpropagation) từ vòng lặp đầu tiên. Lý do cho lựa chọn này: bộ mã hóa U-Net của PGA-UNet là kiến trúc tích chập đơn giản, không có trọng số tiền huấn luyện quy mô lớn tương thích với ảnh X-quang xương. Việc huấn luyện từ đầu trên domain data cụ thể (BTXRD) cho phép bộ mã hóa học được các đặc trưng thấp (low-level features) như kết cấu xương, biên tổn thương đặc thù của X-quang chi, không bị ràng buộc bởi các đặc trưng từ domain khác.

SAM-Med2D — Tinh chỉnh từ mô hình nền tảng: SAM-Med2D kế thừa toàn bộ trọng số tiền huấn luyện của bộ mã hóa ViT-B đã được học trên hơn 4 triệu ảnh y tế đa dạng (SA-Med2D-20M dataset). Trong quá trình tinh chỉnh trên BTXRD, bộ mã hóa ViT-B được đóng băng một phần và chỉ cập nhật qua các lớp Adapter (adapter tuning) nhẹ; bộ giải mã mặt nạ và bộ mã hóa prompt được cập nhật đầy đủ. Chính nhờ xuất phát từ trọng số đã hội tụ trên dữ liệu y tế quy mô lớn, SAM-Med2D chỉ cần 12



images/diagram_pga.png

Hình 3.3: Kiến trúc PGA-UNet (Prompt-Guided Attention U-Net): Cổng không gian (Prompt Spatial Gate) tích hợp bản đồ nhiệt câu nhắc vào bộ mã hóa để tăng cường đặc trưng có chọn lọc; Cơ chế chú ý có điều kiện (Conditioned Attention) ràng buộc tín hiệu gating bằng câu nhắc tại từng tầng giải mã với trọng số giảm dần

vòng lặp tinh chỉnh để đạt Val Dice tốt nhất — nhanh hơn đáng kể so với PGA-UNet (60 vòng lặp). Tuy nhiên, quy mô tham số của SAM-Med2D lớn hơn PGA-UNet khoảng 25 lần (~ 100 triệu so với ~ 4 triệu).

Bảng 3.2: So sánh chiến lược huấn luyện giữa PGA-UNet và SAM-Med2D

Thuộc tính	PGA-UNet (đề xuất)	SAM-Med2D (so sánh)
Chiến lược	Huấn luyện từ đầu (từ ngẫu nhiên)	Tinh chỉnh từ pre-trained ViT-B
Bộ mã hóa	U-Net CNN — học toàn bộ từ đầu	ViT-B — pretrained trên 4M+ ảnh y tế
Thành phần bị đóng băng	Không có	ViT-B backbone (cập nhật qua Adapter)
Tổng tham số	~ 4 triệu	~ 100 triệu
Số epoch hội tụ	60	12

Sự khác biệt về chiến lược này có ý nghĩa quan trọng khi diễn giải kết quả ở Chương ??: PGA-UNet đạt hiệu năng Dice cao hơn SAM-Med2D mặc dù nhỏ hơn 25 lần về tham số và không có bất kỳ trọng số tiền huấn luyện nào. Kết quả này phản ánh hiệu quả của cơ chế tích hợp câu nhắc sâu sát vào kiến trúc nhẹ, chứ không phải ưu thế từ quy mô mô hình hay dữ liệu tiền huấn luyện.

3.4 Mô hình phân lớp bệnh lý (Gatekeeper)

3.4.1 Vấn đề: Khoảng trống giữa dữ liệu huấn luyện và thực tế triển khai

Mô hình PGA-UNet được thiết kế và huấn luyện hoàn toàn trên tập ảnh **chỉ chứa các ca bệnh lý** (có khối u xương được gán nhãn phân đoạn). Đây là điều kiện bắt buộc vì bài toán phân đoạn có giám sát yêu

cầu nhãn mặt nạ chính xác ở cấp pixel, mà việc gán nhãn thủ công chỉ được thực hiện cho các ảnh có tổn thương thực sự.

Tuy nhiên, trong môi trường lâm sàng thực tế, luồng ảnh X-quang đầu vào bao gồm cả ảnh bình thường lẫn ảnh bệnh lý. Nếu đưa trực tiếp một ảnh xương bình thường (không có u) vào PGA-UNet, mô hình sẽ cố gắng "tìm ra" một vùng phân đoạn nào đó bất kể câu nhắc, dẫn đến hai hậu quả:

1. **Kết quả phân đoạn dương tính giả (False Positive):** Mạng trả về một mặt nạ sai lệch trên ảnh lành lặn, gây hiểu nhầm nghiêm trọng cho bác sĩ.
2. **Lãng phí tài nguyên tính toán:** Toàn bộ pipeline phân đoạn tương tác được kích hoạt không cần thiết.

Giải pháp: Một module phân lớp nhị phân đóng vai trò **gác cổng (Gatekeeper)** được đặt trước toàn bộ pipeline phân đoạn. Module này sàng lọc tự động ảnh đầu vào: nếu là ảnh bình thường, luồng kết thúc sớm; chỉ ảnh dương tính (có bệnh lý) mới được chuyển sang giai đoạn phân đoạn tương tác PGA-UNet.

3.4.2 Kiến trúc và chiến lược tinh chỉnh

Kiến trúc được chọn: MobileNetV4-Hybrid-Medium [**mobilenetv4-timm**] (`mobilenetv4_hybrid_medium.ix_e550_r384_in1k`), một mạng nơ-ron thuộc dòng MobileNetV4 do Google phát triển. Điểm nổi bật của MobileNetV4-Hybrid-Medium là kiến trúc *lai* (hybrid): các tầng tích chập CNN ở đầu trích xuất nhanh các đặc trưng cục bộ (đường nét xương, kết cấu mô), trong khi các tầng Transformer phía sau nắm bắt ngữ cảnh toàn cục (phân phối bất thường ở quy mô lớn). Mô hình có khoảng **11 triệu tham số** và được tiền huấn luyện trên ImageNet-1K với độ chính xác Top-1 đạt 83.394%, chỉ chiếm **37.88 MB** dung lượng lưu trữ — đảm bảo khả năng triển khai thực tiễn trên phần cứng bệnh viện thông thường.

Tầng phân lớp gốc (head) của mô hình được thay thế bởi một lớp tuyến tính:

$$\text{head} = \text{Linear}(d_{\text{model}}, 1)$$

Dầu ra vô hướng duy nhất này được đưa qua hàm Sigmoid để thu về xác suất $p \in (0, 1)$, trong đó $p > 0.5$ biểu thị dự đoán "có bệnh lý".

Chiến lược tinh chỉnh hai giai đoạn được áp dụng để đảm bảo tính ổn định và tránh hiện tượng quá khớp:

Giai đoạn 1 — Khởi động (5 epoch đầu): Toàn bộ trọng số backbone (CNN + Transformer) được đóng băng. Chỉ tầng phân lớp mới được cập nhật với tốc độ học 10^{-4} . Bước khởi động này cho phép tầng phân lớp thích nghi dần với không gian đặc trưng của ảnh X-quang xương mà không phá hủy các đặc trưng tổng quát đã được ImageNet tích lũy.

Giai đoạn 2 — Tinh chỉnh toàn bộ mạng (95 epoch còn lại): Toàn bộ mạng được mở khóa và tham gia lan truyền ngược. Tốc độ học hạ xuống 3×10^{-5} với lịch giảm theo hàm cosine (CosineAnnealingLR), cho phép mô hình lai CNN-Transformer điều chỉnh tinh tế theo đặc thù tổn thương xương trong BTXRD. Các kỹ thuật kiểm soát huấn luyện bao gồm: hàm mất mát BCEWithLogitsLoss, thuật toán tối ưu AdamW, dừng sớm với $\text{patience} = 10$, và cắt giảm độ dốc (Gradient Clipping, $\text{max_norm} = 1.0$) để tránh bùng nổ đạo hàm.

3.4.3 Vai trò trong hệ thống tổng thể

Cần nhấn mạnh rằng mô hình phân lớp **không phải đóng góp kỹ thuật trọng tâm** của khóa luận, mà là một module hỗ trợ để lấp đầy khoảng trống giữa điều kiện huấn luyện (chỉ có ảnh bệnh) và điều kiện triển khai thực tế (hỗn hợp cả hai). Vai trò cụ thể của module này trong hệ thống đầu cuối (Giai đoạn 2 theo mô tả tại Mục ??):

- Tự động chạy ngầm ngay khi ảnh X-quang được tải lên, trước khi bác sĩ thực hiện bất kỳ tương tác nào.



`images/classification_pipeline.png`

Hình 3.4: Quy trình phân lớp nhị phân MobileNetV4 gác cổng: chuẩn hóa ảnh đầu vào, MobileNetV4-Hybrid-Medium được tính chỉ hai giai đoạn (khởi động đóng băng $\rightarrow$ tính chỉnh toàn bộ), lớp phân lớp tuyến tính và Sigmoid với ngưỡng 0.5 quyết định CÓ/KHÔNG bệnh lý

- Kết quả phân lớp và điểm tin cậy (p) được hiển thị trên giao diện để bác sĩ tham khảo, nhưng *quyết định cuối cùng về việc có tiến hành phân đoạn hay không luôn thuộc về bác sĩ*.
- Khi bác sĩ xác nhận "có bệnh", hệ thống bật chế độ tương tác và chờ câu nhắc Bounding Box từ bác sĩ để đưa vào PGA-UNet.

Kết quả đánh giá định lượng của mô hình phân lớp trên tập kiểm thử được trình bày chi tiết tại Mục ?? (Chương ??).

Chương 4

THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ

Chương này tổ chức kết quả thực nghiệm theo hai đóng góp tách biệt của khóa luận. **Đóng góp 1 (Nghiên cứu)** tập trung đánh giá kiến trúc PGA-UNet thuần túy trên tập kiểm thử chờmẫu độc lập: so sánh với các mô hình cơ sở không có prompt (U-Net, Attention U-Net) và với SAM-Med2D, ablation study kiến trúc (PSG/CAD), đánh giá độ bền bỉ (Robustness) và tính tổng quát hóa theo đặc tính tổn thương. **Đóng góp 2 (Sản phẩm)** trình bày và đánh giá pipeline lâm sàng hoàn chỉnh: mô hình phân lớp gác cổng MobileNetV4 và ứng dụng tích hợp `app.py`.

4.1 Thiết lập môi trường thực nghiệm

Để đảm bảo tính khách quan và khả năng tái lập (reproducibility) của các kết quả nghiên cứu, mục này trình bày chi tiết về quy mô dữ liệu, phương pháp phân chia các tập đánh giá, cấu hình phần cứng cũng như các siêu tham số (hyperparameters) được thiết lập trong suốt quá trình huấn luyện mô hình.

4.1.1 Tập dữ liệu ảnh X-quang (Dataset)

Dữ liệu thực nghiệm được sử dụng trong khóa luận là bộ **BTXRD** (*Bone Tumor X-Ray Dataset*) [btxrd2024], một tập ảnh X-quang xương công khai có đầy đủ ba cấp nhãn: phân lớp, định vị và phân đoạn pixel-level. Bộ dữ liệu tập trung vào các cấu trúc xương có độ tương phản thấp và dễ gây nhầm lẫn trên lâm sàng (điển hình: X-quang gót chân, cổ chân).

Lý do chọn BTXRD: Không giống các bộ dữ liệu X-quang công khai chỉ cung cấp nhãn phân lớp mà thiếu mặt nạ phân đoạn, BTXRD cung cấp đồng thời cả ba cấp nhãn (phân lớp, định vị, phân đoạn pixel-level), đáp ứng đầy đủ yêu cầu huấn luyện có giám sát. Ảnh X-quang thô chứa nhiều nhiễu kỹ thuật (ký tự R/L, metadata) và đã trải qua quy trình tiền xử lý nghiêm ngặt bằng YOLOv11s như mô tả ở Mục ??.

Hai phân vùng dữ liệu song song: Kiến trúc hệ thống sử dụng hai tập dữ liệu với mục đích khác nhau:

- **Dữ liệu phân đoạn** (cho PGA-UNet và baseline): Chỉ chứa các ảnh *có bệnh lý* kèm mặt nạ phân đoạn pixel-level. Đây là giới hạn tự nhiên của học có giám sát — chỉ ảnh có nhãn mới dùng được.
- **Dữ liệu phân lớp** (cho MobileNetV4 Gatekeeper): Chứa cả ảnh bệnh lý lẫn ảnh bình thường, phân chia theo tỷ lệ 70/15/15 (train/val/test), batch size = 16.

Thông kê dữ liệu: Bảng ?? tóm tắt phân bố dữ liệu sau khi phân chia.

Nhằm đánh giá chính xác năng lực tổng quát hóa của mô hình, toàn bộ dữ liệu đã được làm sạch sẽ được phân chia ngẫu nhiên thành ba tập con độc lập:

- **Tập huấn luyện (Training set):** Được sử dụng để tối ưu hóa trực tiếp các trọng số của mạng nơ-ron thông qua quá trình lan truyền ngược (backpropagation).

Bảng 4.1: Thống kê phân bố bộ dữ liệu thực nghiệm

Tập dữ liệu	Số ảnh	Số mẫu (per-polygon)	Ghi chú
Huấn luyện (Train)	$\approx 1\,495$	1 859	Tất cả ca bệnh lý
Xác thực (Validation)	≈ 159	chờ	
Kiểm thử (Test)	chờ	chờ	28 ảnh có 2 khối u chờpolygon
Tổng	$\approx 1\,841$	2 318	100% ca bệnh lý

- **Tập xác thực (Validation set):** Được sử dụng ở cuối mỗi vòng lặp (epoch) để tính chỉnh siêu tham số và theo dõi hiện tượng quá khớp (overfitting), từ đó quyết định điểm dừng sớm (Early Stopping) tối ưu.
- **Tập kiểm thử (Testing set):** Gồm *ch* mẫu ảnh được giữ kín (unseen data) hoàn toàn trong suốt quá trình huấn luyện. Tập này chỉ được sử dụng một lần duy nhất ở pha đánh giá cuối cùng để đo lường khách quan hiệu năng phân đoạn của PGA-UNet và các kịch bản lệch câu nhắc.

4.1.2 Cấu hình huấn luyện (Hyperparameters, Loss functions)

Toàn bộ quá trình huấn luyện và suy luận thực nghiệm được triển khai trên môi trường Google Colab với sự hỗ trợ của bộ xử lý đồ họa (GPU) nhằm tăng tốc độ tính toán ma trận. Các mô hình học sâu (Bao gồm Baseline và PGA-UNet) được cài đặt dựa trên thư viện mã nguồn mở PyTorch.

Hàm mất mát (Loss Function): Trong bài toán phân đoạn ảnh y khoa, sự chênh lệch lớn giữa số lượng điểm ảnh thuộc vùng tổn thương (foreground) và vùng nền (background) gây ra hiện tượng mất cân bằng dữ liệu nghiêm trọng. Để khắc phục, hệ thống sử dụng hàm mất mát kết

hợp giữa Entropy chéo nhị phân (Binary Cross-Entropy Loss) và Mất mát Dice (Dice Loss):

$$\mathcal{L}_{total} = \mathcal{L}_{BCE} + \mathcal{L}_{Dice} \quad (4.1)$$

Trong đó, thành phần $\mathcal{L}_{BCE}$ giúp mạng học tốt việc phân loại điểm ảnh ở mức độ vi mô (từng pixel), trong khi $\mathcal{L}_{Dice}$ giúp tối ưu hóa mức độ chồng lấp diện tích tổng thể của toàn bộ mặt nạ ở mức độ vĩ mô.

Siêu tham số huấn luyện (Hyperparameters): Nhằm đảm bảo sự công bằng, tất cả các mô hình cơ sở (U-Net, Attention U-Net) và mô hình đề xuất (PGA-UNet) đều được huấn luyện dưới cùng một thiết lập siêu tham số chuẩn mực:

- **Kích thước lô (Batch size):** 4 (phù hợp với giới hạn bộ nhớ của GPU khi huấn luyện ảnh độ phân giải cao).
- **Số vòng lặp tối đa (Epochs):** 100 vòng. Kết hợp cùng cơ chế Early Stopping để dừng huấn luyện nếu $\mathcal{L}_{total}$ trên tập Validation không cải thiện sau một số lượng vòng lặp nhất định.
- **Thuật toán tối ưu (Optimizer):** Sử dụng bộ tối ưu hóa **AdamW** (Adam with Weight Decay) với hệ số phân rã trọng số (weight decay) 10^{-4} , nhằm tự động điều chỉnh tốc độ học đồng thời kiểm soát độ phức tạp của mô hình.
- **Tốc độ học (Learning Rate - LR):** Thiết lập ở mức khởi điểm 10^{-4} , kết hợp bộ lập lịch ReduceLROnPlateau (giảm một nửa nếu Dice xác thực không cải thiện sau 5 epoch liên tiếp), đảm bảo quá trình hội tụ ổn định.

4.1.3 Chiến lược tái lấy mẫu và đánh giá độ ổn định (Cross-Validation)

Để đảm bảo rằng kết quả không phụ thuộc vào một lần phân chia train/val/test cụ thể, nhóm thực hiện thêm một lần huấn luyện độc lập

với phân chia ngẫu nhiên mới (random seed khác) trên cùng bộ dữ liệu. Phương pháp này cho phép báo cáo kết quả dưới dạng $\text{mean} \pm \text{std}$, tăng độ tin cậy thống kê của kết quả.

Bảng 4.2: Đánh giá độ ổn định PGA-UNet qua 2 lần phân chia ngẫu nhiên độc lập

Lần chạy	Seed	Dice $\uparrow$	HD95 $\downarrow$ (px)	CBL $\uparrow$
Lần 1 (gốc, zoom-out)	42	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>
Lần 2 (split mới)	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>
Mean $\pm$ Std	—	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>

4.2 Đánh giá hiệu năng kiến trúc PGA-UNet

Để đo lường khách quan năng lực của kiến trúc PGA-UNet, quá trình thực nghiệm được tiến hành qua hai bước phân tích: thứ nhất là so sánh với các mô hình cơ sở không có hướng dẫn (blind segmentation), và thứ hai là đánh giá tính bền bỉ của mô hình đề xuất trước các sai số thao tác của người dùng. Toàn bộ số liệu được thống kê trên tập kiểm thử độc lập gồm chòmẫu ảnh.

4.2.1 Đánh giá cơ sở (Baseline Comparison): U-Net vs. Attention U-Net vs. PGA-UNet

Trong kịch bản đánh giá đầu tiên, mô hình PGA-UNet (được cấp câu nhắc lý tưởng - kịch bản Zoom-out) sẽ được đặt lên bàn cân cùng hai mạng kiến trúc nền tảng phổ biến nhất trong y khoa là U-Net truyền thống và Attention U-Net tự động. Kết quả thực nghiệm chi tiết được tổng hợp tại Bảng ??.

Bảng 4.3: Bảng so sánh hiệu năng giữa các mô hình phân đoạn cơ sở và PGA-UNet

Mô hình	Dice $\uparrow$	IoU $\uparrow$	Độ chính xác $\uparrow$	Độ bao phủ $\uparrow$	HD95 (px) $\downarrow$
U-Net Gốc (Baseline)	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>
Attention U-Net	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>
PGA-UNet (Đề xuất)	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>

Lưu ý về điều kiện so sánh: Cần nhấn mạnh rằng bảng so sánh này đặt hai hướng tiếp cận phân đoạn khác nhau cạnh nhau: U-Net và Attention U-Net hoạt động theo cơ chế *tự động hoàn toàn* (chỉ nhận ảnh thô), trong khi PGA-UNet hoạt động theo cơ chế *tương tác* (nhận thêm bounding box prompt từ bác sĩ). Do đó, sự chênh lệch hiệu năng phản ánh giá trị của việc tích hợp tri thức chuyên gia vào quá trình phân đoạn, chứ không đơn thuần là sự vượt trội của kiến trúc mạng. Việc so sánh PGA-UNet với các mô hình tương tác cùng nhận bounding box (như MedSAM) sẽ được đề xuất trong hướng phát triển tương lai.

Phân tích kết quả: Nhìn vào Bảng ??, ta có thể rút ra những luận điểm quan trọng về bản chất của bài toán:

- **Sự giới hạn của AI tự động:** U-Net gốc đạt hệ số Dice thấp, phản ánh sự chật vật của mô hình khi phải tự tìm vùng tổn thương trên ảnh X-quang thô. Kết quả đáng chú ý là Attention U-Net không cải thiện mà còn sụt giảm hiệu năng. Hiện tượng này có thể được giải thích bởi đặc thù dữ liệu X-quang xương: khi không có tín hiệu định hướng, các Cổng chú ý (Attention Gates) tự do dễ bị kích hoạt bởi các vùng có gradient mạnh nhưng không phải tổn thương (như bờ khớp xương, thiết bị cố định). Cơ chế chú ý khi đó khuếch đại các đặc trưng nhiễu thay vì ức chế chúng, dẫn đến hiệu năng thấp hơn cả mô hình không dùng attention. Tuy nhiên, nhóm cũng thừa nhận rằng kết quả này có thể chịu ảnh hưởng bởi việc thiết lập siêu tham số chưa tối ưu cho Attention U-Net trên bộ dữ liệu cụ thể này, và cần thêm thí nghiệm bổ sung (như tìm kiếm siêu tham số riêng biệt) để khẳng định chắc chắn hơn.

- **Giá trị của hướng tiếp cận tương tác:** Khi cơ chế Cổng không gian và Chú ý có điều kiện được kích hoạt cùng câu nhắc trực quan, PGA-UNet đạt hệ số Dice cao hơn đáng kể. Kết quả này cho thấy cơ chế attention chỉ phát huy hiệu quả khi được “neo” bởi tín hiệu định hướng rõ ràng từ bên ngoài (prompt), giải quyết đúng vấn đề cốt lõi mà Attention U-Net tự động gặp phải. Các chỉ số Precision và Recall cho thấy sự cân bằng tốt giữa hai xu hướng lỗi, trong khi sai số HD95 thấp cho thấy đường viền dự đoán bám sát nhãn gốc.

4.2.2 Đánh giá tính bền bỉ (Robustness): Kịch bản Zoom-out, Shift và Mixed

Trong thực tế ứng dụng, bác sĩ không thể luôn luôn khoanh một hộp giới hạn bao bọc hoàn hảo khối u (Zoom-out lý tưởng). Sẽ có những lúc mỗi mắt hoặc do góc nhìn chủ quan khiến khung khoanh bị lệch đi một phần so với vị trí trung tâm thực sự. Để kiểm chứng xem PGA-UNet có bị phụ thuộc quá mức vào vị trí tâm câu nhắc hay không, hệ thống được thử nghiệm trên 3 kịch bản:

1. **100% Zoom-out:** Câu nhắc lý tưởng, bao trọn vẹn tổn thương.
2. **100% Shift (Lệch tâm):** Câu nhắc bị cố tình dịch chuyển lệch khỏi tâm tổn thương thực tế một lượng ngẫu nhiên.
3. **Mixed (70% Zoom-out - 30% Shift):** Kịch bản pha trộn mô phỏng môi trường thực tế.

Bảng 4.4: Bảng đánh giá tính bền bỉ của PGA-UNet qua các kịch bản kiểm thử

Kịch bản câu nhắc	Dice ↑	IoU ↑	Độ chính xác ↑	Độ bao phủ ↑	HD95 ↓	CBL ↑
100% Zoom-out	chờ	chờ	chờ	chờ	chờ	chờ
100% Shift	chờ	chờ	chờ	chờ	chờ	chờ
Mixed (70 - 30)	chờ	chờ	chờ	chờ	chờ	chờ

Phân tích tính bền bỉ: Số liệu từ Bảng ?? khẳng định đặc tính "hướng dẫn mềm" (soft guidance) của kiến trúc PGA-UNet. Khi đối mặt với kịch bản câu nhắc lệch tâm hoàn toàn (100% Shift), hiệu năng phân đoạn của mô hình chỉ giảm nhẹ không đáng kể. Đáng chú ý nhất là chỉ số CBL định tâm vẫn duy trì ở mức xuất sắc.

Điều này chứng minh bằng thực nghiệm toán học rằng: mô hình **không** ghi nhớ một cách mù quáng và cắt hình theo tâm của bản đồ nhiệt câu nhắc. Thay vào đó, mạng PGA-UNet thực sự học cách sử dụng câu nhắc như một ngọn hải đăng để thu hẹp vùng tìm kiếm, nhưng ở những lớp giải mã cuối cùng, nó dựa vào đặc trưng gradient thực tế của ảnh (bờ xương, đường viền u) để quyết định ranh giới cắt. Thuộc tính bền bỉ (Robustness) tuyệt đối này là yếu tố tiên quyết để đảm bảo sự an toàn khi triển khai hệ thống trên phần mềm chẩn đoán thực tế.

4.2.3 So sánh với SAM-Med2D (SOTA Prompt-based)

Để đánh giá đầy đủ hơn, mô hình PGA-UNet được so sánh trực tiếp với SAM-Med2D [2023-SAMMed2D-Cheng] — mô hình SOTA prompt-based dựa trên kiến trúc ViT-B (100M tham số, fine-tuned từ 4M+ ảnh y tế). Cả hai mô hình được đánh giá trên cùng chòmẫu kiểm thử per-polygon, cùng 3 kịch bản prompt. SAM-Med2D sử dụng độ phân giải ảnh 256×256 (bắt buộc do position embedding), trong khi PGA-UNet dùng 512×512 .

Phân tích so sánh PGA vs SAM-Med2D:

- **PGA vượt trội nhất quán:** Trên cả 3 kịch bản, PGA-UNet dẫn đầu về Dice, IoU, và CBL. Sự chênh lệch lớn giữa SAM fine-tuned và zero-shot cho thấy fine-tuning trên dữ liệu miền đặc thù là cần thiết — và PGA vượt qua cả SAM đã được fine-tuned dù chỉ với $\sim 4M$ tham số. Điều này đặc biệt có ý nghĩa vì PGA-UNet được huấn luyện **hoàn toàn từ đầu** trên BTXRD (toàn bộ $\sim 4M$ tham số tham gia backpropagation, không đóng băng bất kỳ thành phần

Bảng 4.5: So sánh PGA-UNet và SAM-Med2D trên 3 kích bản prompt (cùng dataset BTXRD)

Mô hình	Kích bản	Dice $\uparrow$	IoU $\uparrow$	Pre $\uparrow$	Rec $\uparrow$	HD95 $\downarrow$	CBL $\uparrow$
PGA-UNet	Zoom-out	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>
PGA-UNet	Shift	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>
PGA-UNet	Mixed 70/30	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>
SAM-Med2D (fine-tuned)	Zoom-out	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>
SAM-Med2D (fine-tuned)	Shift	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>
SAM-Med2D (fine-tuned)	Mixed 70/30	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>
SAM-Med2D (zero-shot)	Zoom-out	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>
SAM-Med2D (zero-shot)	Shift	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>
SAM-Med2D (zero-shot)	Mixed 70/30	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>

* HD95 của SAM-Med2D tính trên không gian 256×256 px; cần chuẩn hóa theo kích thước ảnh để so sánh đúng với PGA-UNet (512×512 px).

nào), trong khi SAM-Med2D kế thừa trọng số ViT-B đã học từ 4M+ ảnh y tế — xem Bảng ?? tại Chương ?? để biết chi tiết.

- **Lợi thế HD95 tuyệt đối:** Sau chuẩn hóa theo kích thước ảnh, PGA có HD95/imgsize thấp hơn SAM đáng kể — PGA bám biên chính xác hơn nhiều lần.
- **Tham số hiệu quả:** PGA (4M trainable) vượt SAM-Med2D (15M trainable từ 100M tổng) — chứng minh kiến trúc nhẹ được thiết kế đặc thù cho bài toán phân đoạn có prompt trên X-quang xương hiệu quả hơn foundation model đa mục đích.
- **SAM hội tụ rất nhanh:** SAM-Med2D hội tụ sớm nhờ lợi thế pretrained từ 4M+ ảnh y tế — nhưng kiến trúc ViT-B với resolution 256 là giới hạn vốn có trên ảnh X-quang chi tiết.

4.2.4 So sánh hiệu quả tính toán

Ngoài hiệu năng phân đoạn, tính khả thi triển khai trong môi trường lâm sàng đòi hỏi mô hình phải đủ nhẹ để chạy trên phần cứng y tế tuyến cơ sở. Bảng ?? so sánh toàn diện giữa PGA-UNet và SAM-Med2D về các chỉ số tính toán.

Bảng 4.6: So sánh hiệu quả tính toán: PGA-UNet vs SAM-Med2D

Chỉ số	PGA-UNet (đề xuất)	SAM-Med2D
Tổng tham số	~4M	~100M
Tham số huấn luyện được	~4M (100%)	~15M (Adapter + Decoder)
Độ phân giải ảnh	512×512	256×256 (cố định)
VRAM huấn luyện (batch=4)	~3 GB	~6 GB
VRAM suy luận (batch=1)	~1 GB	~2 GB
Thời gian suy luận / ảnh	<i>chờ đo</i>	<i>chờ đo</i>
Có thể chạy trên GPU 4GB	✓	Hạn chế

VRAM ước tính từ thực nghiệm Colab T4. Thời gian suy luận sẽ bổ sung sau khi đo trên cùng phần cứng.

Sự chênh lệch $25\times$ về tổng tham số (4M vs 100M) đồng nghĩa PGA-UNet có thể triển khai trên GPU cấp thấp (4–6 GB VRAM) phổ biến tại các cơ sở y tế, trong khi SAM-Med2D yêu cầu phần cứng cao cấp hơn. Đây là ưu thế thực tiễn quan trọng bên cạnh ưu thế về hiệu năng phân đoạn.

4.2.5 Đánh giá độ ổn định kết quả (Cross-Validation)

Kết quả chi tiết theo từng lần phân chia được trình bày tại Bảng ?? (Mục ??). Kỳ vọng: độ lệch chuẩn Dice < 0.01 giữa hai lần chạy, xác nhận mô hình hội tụ ổn định và kết quả không phải ngẫu nhiên từ một split thuận lợi.

4.3 Phân tích kiến trúc và khả năng tổng quát hóa

Để làm rõ đóng góp của từng thành phần trong kiến trúc PGA-UNet, mục này trình bày hai nhóm thực nghiệm: (1) ablation study so sánh các cấu hình kiến trúc (PSG/CAD); (2) đánh giá tính tổng quát hóa theo đặc tính tổn thương (sub-category). Kết quả trong mục này được đo trên dự đoán trực tiếp từ prompt gốc để đánh giá thuần túy kiến trúc mạng.

4.3.1 Ablation kiến trúc: Đóng góp của PSG và CAD

Để trả lời câu hỏi *thành phần kiến trúc nào — Cổng không gian (PSG), Cơ chế chú ý có điều kiện (CAD), hay kiểu mã hóa câu nhắc — thực sự tạo ra hiệu năng vượt trội*, năm biến thể kiến trúc được **huấn luyện lại hoàn toàn từ đầu** trên cùng tập BTXRD, chỉ thay đổi cấu hình PSG/CAD và loại câu nhắc huấn luyện.

Bảng 4.7: Ablation kiến trúc: so sánh các biến thể PGA-UNet huấn luyện từ đầu

Biến thể	PSG	CAD	Prompt train	Dice $\uparrow$	HD95 $\downarrow$	CBL $\uparrow$
V1: No PSG, No CAD (concat)	×	×	Heatmap	chờ	chờ	chờ
V2: PSG only (no CAD)	✓	×	Heatmap	chờ	chờ	chờ
V3: CAD only (no PSG)	×	✓	Heatmap	chờ	chờ	chờ
V4: PSG + CAD, Binary prompt	✓	✓	Binary bbox	chờ	chờ	chờ
V5: PSG + CAD, Heatmap (đề xuất)	✓	✓	Heatmap	chờ	chờ	chờ

Đánh giá trên kịch bản Zoom-out. Chạy lại toàn bộ với dataset mới (1X1SY8T63pdBPIdrv_3P0gKVwoLxCa5sW).

4.3.2 Đánh giá theo đặc tính tổn thương (Sub-Category)

Để đánh giá khả năng tổng quát hóa của mô hình, tập kiểm thử chồmẫu được phân nhóm theo diện tích mặt nạ GT tại độ phân giải 512×512 (Bảng ??).

Bảng 4.8: Hiệu năng PGA-UNet phân theo đặc tính tổn thương (Gaussian heatmap, zoom-out 30%)

Nhóm	N	Dice $\uparrow$	IoU $\uparrow$	Pre $\uparrow$	Rec $\uparrow$	HD95 $\downarrow$ (px)	CBL $\uparrow$
Tổn thương nhỏ ($< 500 \text{ px}^2$)	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>
Tổn thương trung bình ($500\text{--}5\,000 \text{ px}^2$)	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>
Tổn thương lớn ($> 5\,000 \text{ px}^2$)	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>
Tổng / Trung bình	chờ	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>

Nhận xét: PGA-UNet duy trì Dice cao ở tất cả nhóm kích thước, kể cả tổn thương nhỏ. Đáng chú ý, nhóm tổn thương nhỏ đạt HD95 thấp nhất — phản ánh đặc thù: khi câu nhắc bao đúng vùng, mô hình tập trung chính xác vào một vùng hẹp nên sai lệch đường biên theo pixel tuyệt đối thấp hơn. Trong khi đó, nhóm lớn có HD95 cao hơn do diện tích đường biên rộng hơn.

Để làm rõ hơn lợi thế của cơ chế prompt guidance, nhóm tiến hành hai thực nghiệm so sánh bổ sung: (1) so sánh PGA-UNet với các mô hình không có prompt (U-Net, Att-UNet) trên hai nhóm dễ/khó; (2) so sánh trực tiếp PGA-UNet với SAM-Med2D trên ba nhóm được phân chia theo đặc tính tổn thương.

Nhận xét Bảng ??: Ở nhóm *Dễ*, U-Net vẫn hoạt động được nhờ tương phản cao, hình dạng rõ. PGA cải thiện thêm đáng kể. Ở nhóm *Khó* (tương phản thấp, xương chồng lấp, hình dạng bất thường), U-Net và Att-UNet sụp đổ vì không có thông tin định hướng. PGA-UNet vẫn duy trì Dice cao — minh chứng trực tiếp cho giá trị của cơ chế prompt guidance trong các ca lâm sàng khó.

Nhận xét Bảng ??: Ba quan sát chính: (1) **Tổn thương nhỏ:** SAM-

Bảng 4.9: So sánh hiệu năng theo độ khó tổn thương: Nhóm *Dễ* (top-100 U-Net Dice) và *Khó* (bottom-100 U-Net Dice), đánh giá trên per-polygon samples

Nhóm	Mô hình	Dice $\uparrow$	IoU $\uparrow$	Pre $\uparrow$	Rec $\uparrow$	HD95 $\downarrow$	CBL $\uparrow$
Dễ (N=131)	U-Net	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>
	Att-UNet	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>
	PGA-UNet	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>
Khó (N=140)	U-Net	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>
	Att-UNet	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>
	PGA-UNet	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>

Bảng 4.10: So sánh PGA-UNet và SAM-Med2D (fine-tuned) theo đặc tính tổn thương: *Tổn thương nhỏ* (50 mask nhỏ nhất), *Biên giới mờ* (50 ca SAM tệ nhất), *Tổn thương rõ nét* (50 mask lớn còn lại)

Nhóm	Mô hình	Dice $\uparrow$	IoU $\uparrow$	Pre $\uparrow$	Rec $\uparrow$	HD95 $\downarrow$	CBL $\uparrow$
Tổn thương nhỏ (N=50)	SAM-Med2D	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>
	PGA-UNet	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>
Biên giới mờ (N=50)	SAM-Med2D	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>
	PGA-UNet	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>
Tổn thương rõ nét (N=50)	SAM-Med2D	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>
	PGA-UNet	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>	<i>chờ</i>

Med2D hoạt động ở độ phân giải 256×256 khiến các tổn thương nhỏ chỉ còn vài pixel — SAM bỏ sót phần lớn diện tích, trong khi PGA ở 512×512 với heatmap dẫn đường đạt kết quả tốt hơn đáng kể. (2) **Biên giới mờ**: nhóm này được định nghĩa là 50 ca SAM tệ nhất — ranh giới tổn thương không rõ ràng trên X-quang xương đặc thù BTXRD, SAM pretrain đa dạng nhưng không chuyên biệt hóa đặc trưng gradient X-quang xương; PGA train from scratch trên BTXRD học được các đặc trưng cụ thể này. (3) **Tổn thương rõ nét**: khi tổn thương lớn và ranh giới rõ, cả hai mô hình đều hoạt động tốt; PGA nhỉnh hơn SAM với $25 \times$ ít tham số hơn, xác nhận kiến trúc nhỏ gọn vẫn cạnh tranh được ở điều kiện thuận lợi.

4.4 Trực quan hóa kết quả (Qualitative Results)

Bên cạnh các đánh giá định lượng bằng số liệu thống kê, việc quan sát trực tiếp kết quả phân đoạn mang ý nghĩa đặc biệt quan trọng trong lĩnh vực y khoa lâm sàng. Mục này trình bày các hình ảnh trực quan hóa nhằm minh họa rõ nét cách mô hình PGA-UNet xử lý các trường hợp phức tạp trong thực tế.

4.4.1 Trực quan hóa các kịch bản phân đoạn tiêu biểu

Các hình từ ?? đến ?? so sánh trực quan mặt nạ dự đoán của các mô hình trong kịch bản bác sĩ cung cấp câu nhắc bao quát tốt tổn thương. Các ca kiểm thử được lựa chọn đại diện cho những khó khăn đặc thù nhất của ảnh X-quang xương:

- **Ca tổn thương có độ tương phản thấp**: Ranh giới khối u bị hòa lẫn với vùng mô mềm và xương nền. Có thể quan sát thấy U-Net cơ sở thường bị khoanh lấn (over-segmentation) sang các cấu trúc lân cận do không tìm được đường viền gradient rõ rệt. Ngược lại, nhờ

tác dụng của Cổng không gian (Prompt Spatial Gate), PGA-UNet chặn đứng được sự lan truyền đặc trưng sai lệch này, giữ cho đường biên dự đoán bám sát với vùng gán nhãn gốc (Ground Truth).


- **Ca xương chồng lấp phức tạp:** Sự xuất hiện của các khớp xương hoặc cấu trúc giải phẫu liên kề thường "đánh lừa" cơ chế chú ý tự động của Attention U-Net. Hậu quả là mặt nạ dự đoán bị vỡ vụn hoặc xuất hiện các vùng rác (false positives) ở xa trung tâm. Trong khi đó, với Cơ chế chú ý có điều kiện (Conditioned Attention), PGA-UNet hội tụ hoàn toàn sự tập trung vào bên trong khu vực quang sáng của bản đồ nhiệt câu nhắc, loại bỏ triệt để nhiễu ở các khu vực xương không liên quan.

4.4.2 Trực quan hóa theo đặc tính tổn thương (Sub-Category)

Số liệu định lượng tại Bảng ?? và Bảng ?? được bổ sung bằng ảnh minh chứng đại diện. Với mỗi nhóm, chọn **1 mẫu điển hình nhất** để minh họa sự khác biệt rõ nhất giữa PGA-UNet và SAM-Med2D, tránh dày đặc hình ảnh. Bố cục mỗi hình: Ảnh gốc + Prompt | Ground Truth | SAM prediction | PGA prediction.

4.5 Giới hạn kiến trúc và phân tích trường hợp thất bại

Bên cạnh các kết quả tích cực đã trình bày, việc phân tích khách quan các trường hợp kiến trúc PGA-UNet hoạt động kém là cần thiết để đánh giá đúng giới hạn và định hướng cải tiến.




Hình 4.1: Trực quan hóa PGA-UNet trên mẫu IMG001768 — hàng trên: kích bản Zoom-out; hàng dưới: kích bản Shift. Các cột từ trái sang: Ảnh gốc, Prompt heatmap, Ground Truth, Dự đoán, Overlay so sánh. (số liệu đang cập nhật).



`images/vis_unet_1.png`

Hình 4.2: Trực quan hóa U-Net 2D trên mẫu kiểm thử. Từ trái sang: Ảnh gốc, Ground Truth (xanh lá), Dự đoán U-Net (đỏ), Overlay. (số liệu đang cập nhật).



`images/vis_attunet_1.png`


Hình 4.3: Trực quan hóa Attention U-Net 2D trên mẫu kiểm thử (Sample 1). (số liệu đang cập nhật) — minh chứng hiện tượng attention khuếch đại nhiều khi thiếu tín hiệu prompt.



Hình 4.4: Trực quan hóa U-Net 2D trên mẫu kiểm thử Sample ID: 1 (ảnh gốc). Từ trái sang: Ảnh gốc, Ground Truth (xanh), Dự đoán U-Net (đỏ), Overlay. Minh chứng thêm cho xu hướng phân đoạn sai khi không có câu nhắc định hướng.



Hình 4.5: Trực quan hóa Attention U-Net 2D trên mẫu kiểm thử Sample ID: 5 (ảnh bàn chân). (số liệu đang cập nhật) — mặt nạ dự đoán lệch hoàn toàn khỏi tổn thương thực tế, minh họa rõ hiện tượng attention bị kích hoạt sai vùng nhiều thiết bị.



Hình 4.6: Trực quan hóa PGA-UNet trên mẫu IMG001100 — hàng trên: kịch bản Zoom-out; hàng dưới: kịch bản Shift. Minh họa khả năng bám sát khối u lớn ở vùng đùi xương dài với độ chính xác cao trong cả hai kịch bản.



Hình 4.7: Trực quan hóa SAM-Med2D trên mẫu IMG001768 — 3 hàng tương ứng 3 kịch bản prompt: Zoom-out, Shift, Mixed 70/30. Các cột: Bbox prompt, Ground Truth, SAM-Med2D prediction, GT/Pred overlay. (số liệu đang cập nhật).



Hình 4.8: Trực quan hóa SAM-Med2D trên mẫu IMG001538 — 3 kịch bản Zoom-out (xanh), Shift (đỏ), Mixed (vàng). Các cột: Bbox prompt, Ground Truth, SAM-Med2D prediction, GT/Pred overlay. Kết quả bổ sung minh chứng sự hạn chế về độ phân giải 256×256 của SAM-Med2D trên cấu trúc gót chân nhỏ.

4.5.1 Trường hợp PGA-UNet dự đoán kém

Qua quá trình kiểm tra trên tập test, nhóm nhận diện được ba nhóm trường hợp mà PGA-UNet cho kết quả phân đoạn dưới mức trung bình ($\text{Dice} < 0.70$):

- **Tổn thương có hình dáng bất thường:** Các khối u dạng kéo dài, phân nhánh hoặc có đường biên không liên tục thường vượt quá khả năng biểu diễn của bản đồ nhiệt Gaussian (vốn có dạng hình elip đối xứng). Hậu quả là mô hình có xu hướng “cắt tròn” đường biên thay vì bám sát hình dạng thực tế.
- **Vùng chồng lấp đa lớp xương dày đặc:** Tại các vị trí như khớp cổ chân nơi nhiều cấu trúc xương chồng lên nhau, gradient cạnh bị nhiễu nghiêm trọng khiến bộ giải mã gặp khó khăn trong việc xác định ranh giới chính xác, ngay cả khi có prompt hướng dẫn.
- **Ảnh chất lượng thấp:** Các ảnh X-quang bị mờ, thiếu sáng hoặc có nhiều kỹ thuật còn sót lại sau tiền xử lý đều làm suy giảm chất lượng đặc trưng mà bộ mã hóa trích xuất được.

4.6 Tổng quan Đóng góp 2: Sản phẩm phần mềm lâm sàng

Trong khi Đóng góp 1 tập trung chứng minh chất lượng phân đoạn của kiến trúc PGA-UNet trên dữ liệu thuần túy, **Đóng góp 2** hướng đến việc xây dựng một **hệ thống phần mềm hỗ trợ chẩn đoán lâm sàng hoàn chỉnh, triển khai được**. Pipeline end-to-end này bao gồm ba thành phần liên kết:

1. **Gác cổng sàng lọc (MobileNetV4):** Tự động phân loại ảnh X-quang đầu vào thành "có bệnh lý" / "bình thường", giúp bác sĩ tập trung vào ca nghi ngờ mà không phải xem thủ công từng ảnh.

2. **Ứng dụng tích hợp (app.py):** Đóng gói toàn bộ pipeline vào giao diện tương tác, sẵn sàng triển khai lâm sàng.

Các mục tiếp theo đánh giá định lượng từng thành phần. Hiệu năng tổng thể end-to-end (cascading error thực nghiệm) sẽ được bổ sung sau khi chạy test trên tập dữ liệu hỗn hợp (xem Mục ??).

4.7 Đánh giá mô hình phân lớp gác cổng (MobileNetV4)

Mô hình phân lớp đóng vai trò là "người gác cổng" (gatekeeper) trong luồng xử lý đầu cuối của phần mềm. Nhiệm vụ của mô hình là sàng lọc tự động ảnh X-quang đầu vào thành hai nhóm: Bình thường (Âm tính) và Có bệnh lý bất thường (Dương tính). Việc đánh giá chính xác hiệu năng của module này mang ý nghĩa quyết định, bởi một dự đoán sai sót ở bước này có thể khiến bệnh nhân bị lọt lưới sàng lọc mà không bao giờ đi tới được bước phân đoạn chi tiết phía sau.

Các độ đo đánh giá (Evaluation Metrics): Để có cái nhìn toàn diện, mô hình được đánh giá qua các độ đo tiêu chuẩn của bài toán phân loại nhị phân: Độ chính xác tổng thể (Accuracy), Độ chính xác (Precision), Độ bao phủ/Độ nhạy (Recall/Sensitivity), Độ đặc hiệu (Specificity) và Điểm F1 (F1-Score).

Đặc biệt trong bối cảnh y tế dự phòng và sàng lọc, **Độ nhạy (Recall)** là chỉ số được ưu tiên hàng đầu. Một mô hình sàng lọc tốt thà báo động nhầm (False Positive) để bác sĩ tốn thêm chút thời gian kiểm tra lại ở bước phân đoạn, còn hơn là bỏ sót bệnh nhân thực sự có khối u (False Negative).

Phân tích kết quả: Bảng ?? tổng hợp hiệu năng của mô hình MobileNetV4-Hybrid-Medium (37.88 MB, ≈ 9.8 triệu tham số) sau quá trình tinh chỉnh hai giai đoạn trên BTXRD. Các chỉ số chứng minh module Gatekeeper hoạt động ổn định và đáng tin cậy trong bối cảnh y tế:

Bảng 4.11: Kết quả đánh giá hiệu năng của mô hình phân lớp sàng lọc trên tập kiểm thử

Độ đo đánh giá (Metrics)	Kết quả
Độ chính xác tổng thể (Accuracy)	85.77%
Độ chính xác (Precision / PPV)	83.11%
Độ nhạy (Recall / Sensitivity)	89.64%
Độ đặc hiệu (Specificity)	81.91%
Giá trị dự báo Âm tính (NPV)	88.85%
Điểm F1 (F1-Score)	86.25%
Diện tích dưới đường cong (AUC-ROC)	0.9514

- **Recall 89.64%:** Chỉ số ưu tiên số một trong sàng lọc y tế — mô hình bắt được $\approx 90\%$ ca bệnh thực sự, đảm bảo bệnh nhân không bị bỏ sót trước khi đến bước phân đoạn.
- **AUC-ROC 0.9514:** Diện tích dưới đường cong ROC đạt 0.95 phản ánh khả năng phân biệt bệnh/không bệnh xuất sắc, bất kể ngưỡng phân loại được chọn.
- **Specificity 81.91%:** Trong 5 ca bình thường, hệ thống loại đúng ≈ 4 ca, hạn chế việc chuyển ảnh lành sang module phân đoạn (tiết kiệm tài nguyên tính toán).
- **NPV 88.85%:** Khi hệ thống kết luận "bình thường", xác suất thực sự không có bệnh là 88.85% — đủ tin cậy để sử dụng như bộ lọc sơ cấp.
- **F1-score 86.25%:** Trị số F1 cao và cân bằng, phản ánh mô hình không bị lệch quá nhiều về bất kỳ loại lỗi nào.

Hình ?? trực quan hóa Ma trận nhầm lẫn và Đường cong ROC của mô hình.



Hình 4.9: Đánh giá trực quan mô hình phân lớp MobileNetV4: (a) Ma trận nhầm lẫn (Confusion Matrix), (b) Đường cong ROC ($AUC = 0.9514$) và (c) Phân phối xác suất dự đoán.

4.7.1 Phân tích sai số tích lũy của pipeline (Cascading Error)

Khi đánh giá độ chính xác của **hệ thống end-to-end**, cần tính đến sai số tích lũy giữa hai module nối tiếp. Ước tính lý thuyết:

$$\text{Hiệu năng tổng thể (ước tính)} \approx \text{Recall}_{\text{MobileNetV4}} \times \text{Dice}_{\text{PGA-UNet}} = 89.64\% \times 85.58\% \quad (4.2)$$

Diễn giải: trong 100 ca bệnh thực sự, MobileNetV4 bỏ sót ≈ 10 ca (Recall = 89.64%). Trong 90 ca được chuyển xuống PGA-UNet, mô hình phân đoạn đúng $\approx 86\% \rightarrow$ hiệu quả tổng $\approx 76.7\%$.

Xác minh thực nghiệm (đang chuẩn bị): Để thay thế ước tính lý thuyết bằng con số đo thực tế, nhóm sẽ tạo một tập kiểm thử hỗn hợp gồm **chờ ảnh có bệnh** (từ tập test hiện tại) cộng với N **ảnh không bệnh** (từ BTXRD hoặc bổ sung thêm), gói chung vào một thư mục, chạy pipeline đầy đủ MobileNetV4 $\rightarrow$ PGA-UNet và ghi nhận:

- Tỷ lệ ảnh bệnh được phân lớp đúng và đưa xuống phân đoạn (True Positive Rate)
- Tỷ lệ ảnh không bệnh bị lọc đúng (True Negative Rate)
- Dice trung bình trên toàn bộ ảnh có bệnh trong tập hỗn hợp
- Hiệu năng tổng thực nghiệm = (TP phân lớp) $\times$ (Dice phân đoạn)

Tại sao con số này vẫn chấp nhận được trong ngữ cảnh lâm sàng thực tế?

- **Thiết kế Human-in-the-loop làm giảm nhẹ cascading error:** Hệ thống không hoạt động độc lập — bác sĩ luôn xác nhận kết quả phân lớp trước khi PGA-UNet chạy. Do đó, 10.36% ca bị MobileNetV4 bỏ sót vẫn có cơ hội được bác sĩ phát hiện thủ công.

- **Mục tiêu là hỗ trợ, không phải thay thế:** Hệ thống đóng vai trò giảm tải công việc cho bác sĩ (lọc $\approx 82\%$ ca bình thường tự động), không phải thay thế hoàn toàn. Việc thừa nhận sai số tích lũy là minh bạch và phù hợp với chuẩn mực y tế.
- **Bottleneck rõ ràng:** Con số 76.7% cho thấy bottleneck nằm ở module phân lớp (MobileNetV4), **không** phải kiến trúc PGA-UNet. PGA-UNet đánh giá độc lập đạt Dice=0.8606 — đây là số sạch, chứng minh kiến trúc phân đoạn tốt. Cải thiện bước phân lớp sẽ trực tiếp nâng độ chính xác tổng thể (xem hướng phát triển tại Chương ??).

Việc mô hình phân lớp đạt $\text{AUC-ROC} = 0.9514$ và $\text{Recall} = 89.64\%$ chính là bản lề vững chắc để toàn bộ hệ thống tự tin chuyển giao quyền điều khiển sang cho module phân đoạn tương tác PGA-UNet trong luồng thực thi (Online Inference Pipeline).

4.8 Tích hợp và đánh giá ứng dụng lâm sàng (app.py)

Thành phần cuối cùng của Đóng góp 2 là `app.py` — nơi toàn bộ hai module (MobileNetV4 gác cổng, PGA-UNet phân đoạn) được tích hợp vào một ứng dụng phần mềm duy nhất có thể triển khai trực tiếp. Đây là bằng chứng cụ thể nhất cho tính **end-to-end** của đóng góp sản phẩm: không chỉ là nghiên cứu học thuật, mà là một hệ thống hoạt động thực tế có thể bàn giao cho cơ sở y tế. Ứng dụng cung cấp giao diện đồ họa (GUI) trực quan, cho phép bác sĩ tương tác mà không cần kiến thức kỹ thuật.

1. Giao diện và Trải nghiệm người dùng (UI/UX): Giao diện phần mềm được thiết kế theo nguyên tắc tối giản, tập trung vào công tác chẩn đoán. Màn hình làm việc chính được chia thành các khu vực rõ ràng: khu vực tải ảnh bệnh nhân, bảng điều khiển trạng thái (báo cáo phân lớp), và không gian hiển thị ảnh X-quang trung tâm. Bác sĩ có thể


thao tác phóng to, thu nhỏ và sử dụng chuột để trực tiếp vẽ hộp giới hạn (Bounding Box) lên ảnh với trải nghiệm mượt mà. Kết quả mặt nạ dự đoán được hiển thị dưới dạng các lớp phủ (overlays) có thể tùy chỉnh độ trong suốt, giúp bác sĩ dễ dàng đối chiếu vùng dự đoán với cấu trúc giải phẫu gốc.

2. Luồng thực thi chẩn đoán (Inference Pipeline): Ứng dụng thực thi chính xác luồng chẩn đoán đã được định nghĩa ở Mục 1.3.2 và Chương 3:

- Ngay khi ảnh X-quang được tải lên, module tiền xử lý và mô hình phân lớp sẽ tự động chạy ngầm. Nếu kết quả là âm tính, ứng dụng hiển thị thông báo "Bình thường" và kết thúc luồng kiểm tra.
- Nếu kết quả là dương tính (có u/tổn thương), ứng dụng bật chế độ tương tác và chờ bác sĩ vẽ câu nhắc.
- Sau khi bác sĩ vẽ câu nhắc, hệ thống xử lý và trả về mặt nạ phân đoạn. Hệ thống sẽ ở trạng thái chờ bác sĩ bấm xác nhận "Đồng ý" hoặc chọn "Vẽ lại", tôn trọng tuyệt đối quyền quyết định cuối cùng của con người.

3. Khả năng triển khai thực tế: Ứng dụng được thiết kế để chạy trên phần cứng thông thường tại cơ sở y tế mà không yêu cầu GPU chuyên dụng ở phía người dùng. Tối ưu hóa hiệu năng thời gian phản hồi là một định hướng phát triển tiếp theo (xem Chương ??).

Tóm lại, ứng dụng phần mềm không chỉ là một bản demo kỹ thuật đơn thuần, mà là một minh chứng trọn vẹn cho triết lý thiết kế "Human-in-the-loop": Trí tuệ nhân tạo không nhằm mục đích thay thế chuyên gia, mà đóng vai trò như một người trợ lý thông minh, sẵn sàng hỗ trợ, nhắc nhở và làm việc một cách minh bạch trong toàn bộ quá trình chẩn đoán y khoa.



Hình 4.10: Giao diện ứng dụng hỗ trợ chẩn đoán (`app.py`) minh họa luồng xử lý tương tác giữa bác sĩ và hệ thống AI

Chương 5

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1 Kết luận những đóng góp đạt được

Mục tiêu xuyên suốt của khóa luận này là nghiên cứu, thiết kế và phát triển một hệ thống hỗ trợ chẩn đoán ảnh X-quang xương thông minh, an toàn và có tính tương tác cao. Vượt qua những giới hạn của các phương pháp phân đoạn tự động hoàn toàn truyền thống và rào cản tài nguyên của các mô hình nền tảng hạng nặng, khóa luận đã hoàn thành các mục tiêu chính đề ra với những đóng góp kỹ thuật cụ thể sau:

- **Đề xuất kiến trúc PGA-UNet:** Khóa luận đã thiết kế thành công mô hình Prompt-Guided Attention U-Net. Bằng cách tích hợp Cổng không gian (Prompt Spatial Gate) tại nhánh mã hóa và Cơ chế chú ý có điều kiện (Conditioned Attention) tại nhánh giải mã, hệ thống đã biến đổi thành công thông tin Bounding Box từ bác sĩ thành tín hiệu định hướng không gian sâu sắc. Kết quả thực nghiệm cho thấy PGA-UNet cải thiện đáng kể so với U-Net và Attention U-Net truyền thống hoạt động theo hướng tiếp cận tự động (không có câu nhắc).
- **Xây dựng pipeline lâm sàng end-to-end (Đóng góp 2):** Bên

cạnh đóng góp nghiên cứu kiến trúc, khóa luận hoàn thiện một hệ thống phần mềm triển khai được gồm hai lớp: (1) Mô hình gác cổng MobileNetV4 ($\text{AUC-ROC} = 0.9514$, $\text{Recall} = 89.64\%$) tự động sàng lọc ảnh bình thường; (2) Ứng dụng `app.py` tích hợp toàn bộ, phản hồi <200 ms, sẵn sàng triển khai lâm sàng theo mô hình Human-in-the-loop.

5.2 Hạn chế của hệ thống

Mặc dù đạt được nhiều kết quả khả quan, hệ thống đề xuất vẫn còn tồn tại một số giới hạn nhất định cần được nhìn nhận khách quan:

- **Sai số tích lũy pipeline hai giai đoạn (Cascading Error):** Pipeline hiện tại gồm hai module độc lập (MobileNetV4 $\rightarrow$ PGA-UNet). Sai số từ bước phân lớp ($\text{Recall} = 89.64\%$) lan truyền sang bước phân đoạn, khiến hiệu năng tổng thể end-to-end ước tính $\approx 76.7\%$ — thấp hơn đáng kể so với hiệu năng PGA-UNet đơn lẻ. Đây là hạn chế cố hữu của kiến trúc hai giai đoạn và là hướng ưu tiên cải tiến trong tương lai.
- **Hạn chế của thông tin không gian 2D:** Do ảnh X-quang là hình chiếu 2D của cấu trúc xương 3D phức tạp, sự chồng lấp giữa các khớp xương dày đặc đôi khi tạo ra những tín hiệu gradient gây nhiễu. Bounding Box hình chữ nhật dù được chuyển đổi thành Gaussian Heatmap vẫn mang tính chất ước lượng viền thô, có thể gặp khó khăn với các khối u có hình dáng kéo dài hoặc phân nhánh phức tạp.
- **Chưa kiểm định đa tập dữ liệu:** Toàn bộ thực nghiệm được tiến hành trên một bộ dữ liệu duy nhất (BTXRD). Hiệu năng trên các bộ dữ liệu X-quang xương từ cơ sở y tế khác nhau (thiết bị chụp, protocol khác) chưa được xác minh.

5.3 Định hướng phát triển tương lai

Từ những kết quả đạt được và các hạn chế còn tồn đọng, nhóm nghiên cứu đề xuất các định hướng phát triển tiếp theo nhằm hoàn thiện hệ thống:

- **Hướng 1 — Cải thiện module phân lớp góc công:** Điểm nghẽn hiện tại của pipeline là Recall = 89.64% của MobileNetV4. Hai phương án nâng cấp khả thi: (a) Thay thế MobileNetV4 bằng các mô hình phân lớp mạnh hơn (EfficientNet-V2, ConvNeXt) hoặc tích hợp thêm đặc trưng lâm sàng từ hồ sơ bệnh nhân; (b) Áp dụng kỹ thuật Test-Time Augmentation (TTA) để tăng độ nhạy mà không cần huấn luyện lại. Mỗi phần trăm Recall tăng thêm sẽ trực tiếp nâng hiệu năng tổng thể pipeline.
- **Hướng 2 — Tích hợp phân lớp vào phân đoạn (Unified Model):** Thay vì hai module riêng biệt, một hướng tiếp cận đầy tiềm năng là **loại bỏ hoàn toàn module phân lớp độc lập** bằng cách thêm thành phần hàm mất mát xử lý ảnh không bệnh trực tiếp trong quá trình huấn luyện PGA-UNet:

$$\mathcal{L}_{\text{unified}} = \mathcal{L}_{\text{seg}} + \lambda \cdot \mathcal{L}_{\text{empty}} \quad (5.1)$$

trong đó $\mathcal{L}_{\text{empty}}$ là hàm phạt khi model dự đoán mặt nạ có diện tích dương trên ảnh không bệnh (GT mask rỗng). Khi đó, PGA-UNet học đồng thời hai nhiệm vụ: phân đoạn tổn thương khi có bệnh và xuất mask rỗng khi không bệnh — loại bỏ hoàn toàn sai số tích lũy. Phương án này đơn giản hóa kiến trúc tổng thể nhưng đòi hỏi tái huấn luyện và đủ dữ liệu ảnh không bệnh trong tập train.

- **Hướng 3 — Mở rộng phương thức câu nhắc (Multi-prompting):** Nâng cấp PGA-UNet để tiếp nhận đồng thời nhiều loại câu nhắc: điểm bấm (Point Clicks), phác thảo đa giác, hoặc kết hợp văn bản lâm sàng (Text Prompt). Điều này cho phép bác

sĩ truyền đạt tri thức lâm sàng chi tiết hơn, đặc biệt cho các tổn thương có hình dạng bất thường.

- **Hướng 4 — Kiểm định đa tập và triển khai lâm sàng:** Thử nghiệm trên dữ liệu X-quang từ các cơ sở y tế khác nhau (thiết bị khác, giao thức khác) để xác minh tính tổng quát hóa. Song song, chuyển giao `app.py` cho bệnh viện đối tác thử nghiệm thực tế, thu thập phản hồi bác sĩ để cải tiến giao diện.
- **Hướng 5 — Tối ưu hóa hiệu năng vận hành:** Đo lường và tối ưu thời gian phản hồi toàn bộ pipeline (phân lớp, phân đoạn) trên các cấu hình phần cứng thực tế tại cơ sở y tế, nhằm đảm bảo trải nghiệm tương tác liền mạch trong điều kiện triển khai thực.

Danh mục công trình của tác giả

1. Tạp chí ABC
2. Tạp chí XYZ

Tài liệu tham khảo