

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Thông Lúc - Nguyễn Hữu Bình

Phát triển hệ thống phân đoạn ảnh X-quang
về xương dựa vào câu nhắc trực quan

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN CNTT
CHƯƠNG TRÌNH CHUẨN

Tp. Hồ Chí Minh, tháng 07/2026

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Thông Lúc - 22120196
Nguyễn Hữu Bình - 22120031

**Phát triển hệ thống phân đoạn ảnh X-quang
về xương dựa vào câu nhắc trực quan**

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN CNTT
CHƯƠNG TRÌNH CHUẨN

GIẢNG VIÊN HƯỚNG DẪN

PGS.TS. Lý Quốc Ngọc

ThS. Đỗ Thị Thanh Hà

Tp. Hồ Chí Minh, tháng 07/2026

LỜI CAM ĐOAN

Chúng tôi xin cam đoan đây là công trình nghiên cứu của nhóm chúng tôi. Các số liệu và kết quả nghiên cứu trong khóa luận này là trung thực và không trùng lặp với các đề tài khác.

LỜI CẢM ƠN

Em xin gửi lời cảm ơn chân thành đến **PGS.TS. Lý Quốc Ngọc** và **ThS. Đỗ Thị Thanh Hà** đã tận tình hướng dẫn, định hướng nghiên cứu và dành thời gian phản hồi chi tiết trong suốt quá trình thực hiện khóa luận. Những góp ý thẳng thắn và sâu sắc của thầy cô đã giúp em nhận ra nhiều thiếu sót trong tư duy và cách tiếp cận bài toán, đồng thời là động lực để em không ngừng cải thiện chất lượng công trình.

Em cũng xin cảm ơn **Khoa Công nghệ Thông tin**, Trường Đại học Khoa học Tự nhiên, ĐHQG-HCM đã tạo điều kiện học tập và nghiên cứu thuận lợi trong suốt những năm qua, cung cấp nền tảng kiến thức và môi trường học thuật để em có thể tự tin tiếp cận một bài toán ứng dụng trí tuệ nhân tạo trong lĩnh vực y tế.

Mặc dù đã cố gắng hết sức, công trình này chắc chắn vẫn còn nhiều hạn chế. Em rất mong nhận được những góp ý thêm từ quý thầy cô và hội đồng phản biện để tiếp tục hoàn thiện.

Thành phố Hồ Chí Minh, tháng 6 năm 2026

Nhóm sinh viên thực hiện

Thông Lúc (MSSV: 22120196)

Nguyễn Hữu Bình (MSSV: 22120031)



ĐỀ CƯƠNG KHOÁ LUẬN TỐT NGHIỆP

PHÁT TRIỂN HỆ THỐNG PHÂN ĐOẠN ẢNH X-QUANG VỀ XƯƠNG DỰA VÀO CÂU NHẮC TRỰC QUAN

(Developing a bone X-ray image segmentation system based on visual prompts)

1 THÔNG TIN CHUNG

Người hướng dẫn:

- PGS.TS. Lý Quốc Ngọc (Khoa Công nghệ Thông tin)
- ThS. Đỗ Thị Thanh Hà (Khoa Công nghệ Thông tin)

Nhóm sinh viên thực hiện:

1. Nguyễn Hữu Bình (MSSV: 22120031)
2. Thông Lúc (MSSV: 22120196)

Loại đề tài: Nghiên cứu

Thời gian thực hiện: Từ 01/2026 đến 07/2026

2 NỘI DUNG THỰC HIỆN

2.1 Giới thiệu về đề tài

Chẩn đoán hình ảnh qua X-quang là phương thức cận lâm sàng phổ biến, quan trọng trong phát hiện tổn thương xương như gãy xương, rạn xương và khối u xương nguyên phát. Tại các cơ sở y tế lớn, số ca chụp X-quang mỗi ngày lên đến hàng trăm, đặt áp lực đáng kể lên đội ngũ bác sĩ về tốc độ đọc phim và độ chính xác chẩn đoán. Bước khoanh vùng tổn thương (phân đoạn ảnh) là cơ sở để đo kích thước khối u, theo dõi diễn tiến bệnh và lập kế hoạch điều trị; tuy nhiên hiện vẫn thực hiện thủ công trên hệ thống PACS, tốn thời gian và phụ thuộc kinh nghiệm cá nhân.

Các mô hình học sâu tự động như U-Net [1] đạt kết quả khả quan trong phân đoạn ảnh y khoa, nhưng gặp khó khăn đặc thù trên ảnh X-quang xương: độ tương phản thấp, cấu trúc giải phẫu chồng lấp khiến vùng tổn thương dễ nhầm với mô xương lành. Các mô hình nền tảng dạng câu nhắc như SAM-Med2D [2] mở ra hướng tiếp cận tương tác nhưng kiến trúc rất nặng ($\sim 91\text{M}$ tham số), chi phí tính toán cao, không phù hợp triển khai trên phần cứng y tế thông thường.

Đề tài đề xuất xây dựng kiến trúc **PGA-UNet** (Prompt-Guided Attention U-Net): mô hình U-Net nhẹ tích hợp sâu câu nhắc hộp giới hạn của bác sĩ vào cả bộ mã hóa và bộ giải mã, kết hợp module phân lớp sàng lọc để tạo thành luồng xử lý đầu cuối hoàn chỉnh. Toàn bộ hệ thống được huấn luyện và đánh giá trên bộ dữ liệu BTXRD (Bone Tumor X-Ray Dataset) [3].

2.2 Mục tiêu đề tài

1. **Đề xuất và xây dựng kiến trúc PGA-UNet:** Thiết kế mô hình phân đoạn nhẹ ($\sim 3\text{M}$ tham số) tích hợp câu nhắc hộp giới hạn qua Cổng không gian (PSG) tại bộ mã hóa và Cơ chế chú ý có điều kiện (CAD) tại bộ giải mã; huấn luyện từ đầu trên BTXRD với chiến lược tăng cường câu nhắc (câu nhắc rộng/nhiều) để tăng tính bền bỉ.

2. **Phát triển module sàng lọc (Gatekeeper):** Xây dựng mô hình phân lớp nhị phân EfficientNet_B3 [4] để tự động phân biệt ảnh bình thường và ảnh có bệnh lý, ghép với PGA-UNet thành luồng xử lý đầu cuối.
3. **Thực nghiệm và đánh giá đa khía cạnh:** So sánh PGA-UNet với U-Net [1] và SAM-Med2D [2] trên Dice, IoU, Precision, Recall; đánh giá tính bền bỉ với câu nhắc không hoàn hảo; đánh giá luồng xử lý toàn hệ thống trên tập dữ liệu hỗn hợp mô phỏng một phần điều kiện lâm sàng.
4. **Đánh giá khả năng tổng quát hóa:** Huấn luyện lại toàn bộ kiến trúc và luồng xử lý trên một bộ dữ liệu X-quang xương độc lập thứ hai, FracAtlas [5] (đặc tính tổn thương gãy xương, khác biệt với khối u BTXRD), nhằm kiểm chứng thiết kế PSG+CAD không chỉ phù hợp với một bộ dữ liệu cụ thể.

2.3 Phạm vi của đề tài

Phạm vi thực hiện:

- Dữ liệu: Bộ dữ liệu BTXRD [3] (ảnh X-quang xương 2D thực tế, công bố trên Nature Scientific Data) làm dữ liệu chính; bộ dữ liệu FracAtlas [5] (X-quang gãy xương) dùng để đánh giá bổ sung khả năng tổng quát hóa.
- Bài toán: Phân đoạn nhị phân vùng khối u xương (pixel-level mask) với câu nhắc hộp giới hạn; phân lớp nhị phân bình thường/bệnh lý.
- Đánh giá: So sánh với các mô hình nền tảng (U-Net [1], SAM-Med2D [2]) và đánh giá luồng xử lý đầu cuối trên tập kiểm tra hỗn hợp.

Giới hạn:

- Chỉ xử lý ảnh X-quang 2D, không bao gồm CT 3D hay MRI.
- Câu nhắc đầu vào là hộp giới hạn; chưa hỗ trợ câu nhắc dạng điểm hoặc văn bản.
- Hệ thống đóng vai trò hỗ trợ chẩn đoán, không thay thế quyết định lâm sàng của bác sĩ.

2.4 Cách tiếp cận thực hiện

Giai đoạn 1: Nghiên cứu tài liệu: Khảo sát kiến trúc U-Net [1], Attention U-Net [6], SAM-Med2D [2]; tìm hiểu cơ chế tích hợp câu nhắc không gian vào mạng tích chập; phân tích đặc điểm bộ dữ liệu BTXRD [3].

Giai đoạn 2: Chuẩn bị dữ liệu: Tạo các tệp mặt nạ nhị phân tương ứng với ảnh từ các tệp chú thích và chia tập huấn luyện/xác thực/kiểm tra; huấn luyện trực tiếp trên ảnh X-quang gốc, không qua bước tiền xử lý loại bỏ nhiễu kỹ thuật.

Giai đoạn 3: Thiết kế và huấn luyện mô hình:

- Biểu diễn câu nhắc hộp giới hạn dưới dạng bản đồ nhiệt (heatmap) làm mịn biên.
- PGA-UNet: tích hợp câu nhắc qua Cổng không gian (PSG) tại bộ mã hóa và Cơ chế chú ý có điều kiện (CAD) tại bộ giải mã.
- Huấn luyện từ đầu với hàm mất mát Dice + BCE, kết hợp tăng cường dữ liệu và tăng cường câu nhắc để cải thiện tính bền bỉ.
- EfficientNet_B3 tinh chỉnh hai giai đoạn cho bài toán phân lớp sàng lọc.

Giai đoạn 4: Thực nghiệm và đánh giá: So sánh định lượng Dice/IoU/Precision/Recall/HD95 với các mô hình baseline; ablation study từng thành phần kiến trúc; đánh giá tính bền bỉ kích bản câu nhắc lệch tâm; đánh giá luồng xử lý toàn hệ thống trên tập hỗn hợp; lặp lại các thực nghiệm cốt lõi sau khi huấn luyện lại trên FracAtlas [5] để kiểm chứng tổng quát hóa.

2.5 Kết quả dự kiến của đề tài

- **Bộ dữ liệu đã xử lý:** Tập ảnh BTXRD gốc kèm nhãn phân đoạn polygon và câu nhắc hộp giới hạn, chia sẵn tập huấn luyện/xác thực/kiểm tra.
- **Mô hình PGA-UNet:** Kiến trúc $\sim 3M$ tham số, dự kiến đạt Dice $\geq 0,80$ và IoU $\geq 0,70$ trên tập kiểm tra với câu nhắc hợp lệ; thể hiện tính bền bỉ khi câu nhắc bị lệch tâm.
- **Luồng xử lý đầu cuối:** EfficientNet_B3 đạt AUC-ROC $\geq 0,92$; đánh giá luồng xử lý toàn hệ thống (Dice, IoU tính trên cả trường hợp âm tính giả) phản ánh sát điều kiện lâm sàng.
- **Kết quả tổng quát hóa:** Kỳ vọng kiến trúc PSG+CAD huấn luyện lại trên FracAtlas vẫn duy trì ưu thế so với các mô hình so sánh, qua đó đánh giá mức độ tổng quát của thiết kế ngoài phạm vi BTXRD.
- **Báo cáo và mã nguồn:** Báo cáo khóa luận hoàn chỉnh; bộ mã nguồn có chú thích đầy đủ, tái tạo được toàn bộ kết quả thực nghiệm.

2.6 Kế hoạch thực hiện

Giai đoạn	Nội dung	Thời gian
1	Nghiên cứu tài liệu; phân tích bộ dữ liệu BTXRD	Tuần 1–3 (01/2026)
2	Tạo nhãn mặt nạ phân đoạn từ các tệp dữ liệu; chia tập dữ liệu (huấn luyện trực tiếp trên ảnh gốc, không qua bước tiền xử lý loại nhiễu)	Tuần 4–7 (02/2026)
3	Thiết kế và huấn luyện PGA-UNet; module phân lớp EfficientNet_B3	Tuần 8–14 (03–04/2026)
4	Thực nghiệm so sánh; ablation study; đánh giá tính bền bỉ; đánh giá tổng quát hóa trên FracAtlas	Tuần 15–18 (04–05/2026)
5	Đánh giá luồng xử lý đầu cuối trên tập hỗn hợp	Tuần 19–21 (05/2026)
6	Viết báo cáo khóa luận; chuẩn bị bảo vệ	Tuần 22–26 (06–07/2026)

TÀI LIỆU THAM KHẢO

- [1] O. Ronneberger, P. Fischer, and T. Brox, “U-Net: Convolutional Networks for Biomedical Image Segmentation,” in *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, Springer, 2015, pp. 234–241.
- [2] J. Cheng et al., “SAM-Med2D,” arXiv preprint arXiv:2308.16184, 2023.
- [3] S. Yao et al., “A Radiograph Dataset for the Classification, Localization, and Segmentation of Primary Bone Tumors,” *Scientific Data*, Nature, 2025.
- [4] M. Tan and Q. V. Le, “EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks,” in *Proc. International Conference on Machine Learning (ICML)*, 2019, pp. 6105–6114.
- [5] I. Abedeen et al., “FracAtlas: A Dataset for Fracture Classification, Localization and Segmentation of Musculoskeletal Radiographs,” *Scientific Data*, Nature, 2023.
- [6] O. Oktay et al., “Attention U-Net: Learning Where to Look for the Pancreas,” in *Proc. Medical Imaging with Deep Learning (MIDL)*, 2018. arXiv:1804.03999.

XÁC NHẬN
CỦA NGƯỜI HƯỚNG DẪN
(Ký và ghi rõ họ tên)

TP. Hồ Chí Minh, ngày ... tháng ... năm ...
NHÓM SINH VIÊN THỰC HIỆN
(Ký và ghi rõ họ tên)

MỤC LỤC

Lời cam đoan	i
Lời cảm ơn	ii
Đề cương chi tiết	iii
Mục lục	x
Danh mục các ký hiệu và chữ viết tắt	xix
Bảng đối chiếu thuật ngữ chuyên ngành Anh – Việt	xxiii
Tóm tắt	xxvi
1 GIỚI THIỆU	1
1.1 Bối cảnh chung	1
1.2 Động lực nghiên cứu	2
1.2.1 Động lực khoa học	2
1.2.2 Động lực thực tiễn	2
1.3 Phát biểu bài toán	3
1.4 Thách thức của bài toán	5
1.5 Đóng góp của khóa luận	5
1.6 Bố cục của khóa luận	7
2 CÁC CÔNG TRÌNH LIÊN QUAN VÀ CƠ SỞ LÝ THUYẾT	9
2.1 Các công trình liên quan	9
2.1.1 Các phương pháp phân đoạn ảnh y khoa tự động .	9
2.1.2 Phương pháp học máy tương tác trong y khoa . . .	10

2.2	Cơ sở lý thuyết nền tảng	11
2.2.1	Mạng nơ-ron tích chập (CNN)	11
2.2.2	Kiến trúc U-Net	12
2.2.3	Cơ chế chú ý và kiến trúc Attention U-Net	12
2.3	Học máy dựa trên câu nhắc trong thị giác máy tính	14
2.3.1	Biểu diễn không gian của câu nhắc trực quan	14
2.3.2	Cơ chế chú ý có điều kiện	15
2.4	Các độ đo đánh giá hiệu năng	16
2.4.1	Hệ số Dice và chỉ số IoU	16
2.4.2	Độ chính xác (Precision) và Độ bao phủ (Recall)	17
2.4.3	Khoảng cách Hausdorff 95% (HD95)	17
2.4.4	Độ chuẩn xác định vị tâm (CBL)	18
2.5	Tổng kết chương	19
3	MÔ HÌNH VÀ HỆ THỐNG ĐỀ XUẤT	20
3.1	Kiến trúc tổng thể của hệ thống	20
3.2	Bộ dữ liệu ảnh X-quang và đặc điểm nhiều kỹ thuật	23
3.2.1	Bộ dữ liệu BTXRD	23
3.2.2	Huấn luyện trực tiếp trên ảnh gốc, không qua bước tiền xử lý loại nhiễu	24
3.3	Mô hình phân đoạn PGA-UNet (Prompt-Guided Attention U-Net)	24
3.3.1	Biểu diễn câu nhắc trực quan (Prompt Heatmap Rep- resentation)	26
3.3.2	Cổng không gian tại bộ mã hóa (PSG)	28
3.3.3	Cơ chế chú ý có điều kiện tại bộ giải mã (CAD)	29
3.3.4	Chiến lược huấn luyện và so sánh với mô hình nền tảng SAM-Med2D	31
3.4	Module sàng lọc (Gatekeeper)	33
3.5	Tóm tắt giải thuật hệ thống: Huấn luyện và Suy luận	34
3.6	Tổng kết chương	37

4	THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ	38
4.1	Thiết lập môi trường thực nghiệm	38
4.1.1	Tập dữ liệu ảnh X-quang	38
4.1.2	Mô hình so sánh trong thực nghiệm	40
4.1.3	Cấu hình huấn luyện	41
4.1.4	Phương pháp đánh giá cấp độ ảnh (image-level) . .	42
4.2	Đánh giá hiệu năng kiến trúc PGA-UNet	43
4.2.1	Đánh giá cơ sở: U-Net so với PGA-UNet	43
4.2.2	Đánh giá tính bền bỉ trước sai lệch câu nhắc: Kịch bản Zoom-out, Shift và Mixed	44
4.2.3	So sánh với mô hình nền tảng SAM-Med2D	46
4.2.4	PGA-UNet ở hai độ phân giải: 256×256 so với 512×512 (BTXRD)	48
4.2.5	So sánh hiệu quả tính toán	51
4.3	Phân tích kiến trúc và khả năng tổng quát hóa	52
4.3.1	Ablation kiến trúc: Đóng góp của PSG và CAD . .	52
4.3.2	Kiểm định độ ổn định bằng đánh giá chéo	57
4.3.3	Đánh giá theo đặc tính tổn thương	58
4.4	Đánh giá bổ sung trên bộ dữ liệu thứ hai (FracAtlas) . . .	63
4.4.1	Giới thiệu bộ dữ liệu FracAtlas	64
4.4.2	PGA-UNet toàn diện trên FracAtlas (256×256 và 512×512 , ba kịch bản câu nhắc)	65
4.4.3	So sánh cơ sở: PGA-UNet so với U-Net trên FracAtlas	66
4.4.4	So sánh với SAM-Med2D (Đã tinh chỉnh và Chưa tinh chỉnh) trên FracAtlas	68
4.4.5	Đánh giá theo đặc tính tổn thương trên FracAtlas .	69
4.4.6	Ablation kiến trúc trên FracAtlas	72
4.4.7	Đánh giá chéo 4-fold trên FracAtlas	75
4.4.8	Đánh giá Gatekeeper trên FracAtlas	76
4.4.9	Phân tích các ca bỏ sót trên FracAtlas	77
4.4.10	Đánh giá luồng xử lý đầu cuối trên FracAtlas . . .	79

4.4.11	Thảo luận: hiệu quả của kiến trúc khi huấn luyện lại trên miền dữ liệu khác	79
4.5	Trực quan hóa kết quả	82
4.5.1	Trực quan hóa các kịch bản phân đoạn tiêu biểu . .	83
4.5.2	Đa dạng ca kiểm thử qua toàn bộ luồng xử lý . . .	83
4.5.3	Tính bền bỉ trước câu nhắc lệch tâm (Shift) và tổn thương kích thước nhỏ	85
4.6	Giới hạn kiến trúc và phân tích trường hợp thất bại	86
4.6.1	Trường hợp PGA-UNet dự đoán kém	86
4.7	Đánh giá module Gatekeeper và luồng xử lý đầu cuối . . .	87
4.7.1	Đánh giá Gatekeeper (EfficientNet_B3)	87
4.7.2	Phân tích các ca bỏ sót và thử nghiệm ngưỡng phân loại	90
4.7.3	Phân tích sai số tích lũy qua hai giai đoạn	93
4.7.4	Đánh giá luồng xử lý đầu cuối trên dữ liệu hỗn hợp	94
4.7.5	Các chỉ số đầu cuối bổ sung: Sensitivity bệnh lý, FNR và Recall cấp độ tổn thương	97
5	KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	100
5.1	Kết luận những đóng góp đạt được	100
5.2	Hạn chế của hệ thống	101
5.3	Định hướng phát triển tương lai	103
	Tài liệu tham khảo	107

DANH SÁCH HÌNH

2.1	Kiến trúc SAM-Med2D [6]: bộ mã hóa ảnh ViT-B (tham số đóng băng ●) được chèn lớp thích ứng nhỏ gọn (tham số học được ●) sau mỗi khối Transformer; câu nhắc hộp giới hạn qua bộ mã hóa câu nhắc tạo vector nhúng vị trí, bộ giải mã mặt nạ kết hợp đặc trưng ảnh và vector nhúng câu nhắc để xuất mặt nạ phân đoạn. Tinh chỉnh trên SA-Med2D-20M ($\sim 4,6$ triệu ảnh y tế 2D đa phương thức).	10
2.2	Kiến trúc U-Net, 4 cấp độ phân giải: nhánh mã hóa (trái) giảm mẫu qua Max Pooling; nhánh giải mã (phải) khôi phục độ phân giải qua UpConv; kết nối tắt nối đặc trưng cùng cấp để bù thông tin vị trí bị mất.	12
2.3	Kiến trúc Attention U-Net: Cổng chú ý chèn tại kết nối tắt, dùng tín hiệu cổng $\mathbf{g}$ từ bộ giải mã để lọc nhiễu nền trước khi truyền đặc trưng sang tầng giải mã tương ứng.	13
3.1	Luồng xử lý tổng thể: EfficientNet_B3 sinh gợi ý sàng lọc, bác sĩ xác nhận (không bệnh $\rightarrow$ kết thúc, có bệnh $\rightarrow$ vẽ hộp giới hạn) trước khi chuyển sang PGA-UNet phân đoạn có hướng dẫn.	22
3.2	Kiến trúc PGA-UNet: PSG tích hợp bản đồ nhiệt câu nhắc vào bộ mã hóa để tăng cường đặc trưng có chọn lọc; CAD ràng buộc tín hiệu cổng bằng câu nhắc tại từng tầng giải mã với hệ số w_l	30
4.1	Dice Score: U-Net (512×512), PGA-UNet (256×256), SAM-Med2D (đã/chưa tinh chỉnh, 256×256), ba kịch bản câu nhắc (Bảng 4.2, 4.4).	49

4.2	PGA-UNet trên BTXRD: 256×256 và 512×512 , ba kích bản câu nhắc (Bảng 4.5).	51
4.3	Ablation study: Dice Score của 8 biến thể kiến trúc PGA-UNet trên ba kích bản câu nhắc (Bảng 4.7). PGA-UNet (đề xuất) tô xanh dương, các biến thể còn lại tô xám.	56
4.4	So sánh U-Net và PGA-UNet theo độ khó tác vụ trên BTXRD (Bảng 4.11).	60
4.5	So sánh PGA-UNet và SAM-Med2D theo ba nhóm đặc tính lâm sàng trên BTXRD (Bảng 4.12).	62
4.6	PGA-UNet trên FracAtlas: Dice Score tại 256×256 và 512×512 , ba kích bản câu nhắc (Bảng 4.15).	67
4.7	So sánh U-Net và PGA-UNet theo độ khó tác vụ trên FracAtlas (Bảng 4.18).	70
4.8	So sánh SAM-Med2D (FT), PGA-UNet (256) và PGA-UNet (512) theo ba nhóm đặc tính tổn thương trên FracAtlas (Bảng 4.19).	72
4.9	Ablation study: Dice Score của 8 biến thể kiến trúc PGA-UNet trên ba kích bản câu nhắc trên FracAtlas (Bảng 4.20). PGA-UNet (đề xuất) tô xanh dương, các biến thể còn lại tô xám.	73
4.10	Hai ca kiểm thử PGA-UNet, kích bản Zoom-out. Từ trái sang phải: ảnh gốc, ảnh kèm hộp giới hạn câu nhắc, mặt nạ dự đoán (Dice/IoU), Ground Truth, lớp phủ đối chiếu TP/FP/FN (Precision/Recall).	83
4.11	6 ca TP tiêu biểu qua toàn bộ luồng xử lý Gatekeeper $\rightarrow$ PGA-UNet trên dataset_online (BTXRD). Từ trái sang phải: ảnh gốc, hộp giới hạn câu nhắc, mặt nạ dự đoán, Ground Truth, lớp phủ TP/FP/FN.	84

4.12	Hai ca kiểm thử ở kịch bản Shift (câu nhắc lệch tâm): đầu gối nhiều tổn thương (trên, Dice=0.851) và vai/xương đòn (dưới, Dice=0.894). Cột thứ hai cho thấy hộp giới hạn không bao trọn vẹn tổn thương thực tế.	85
4.13	Ca tổn thương kích thước nhỏ ở cẳng chân (Dice=0.769, IoU=0.624): PGA-UNet vẫn định vị và phân đoạn đúng dù vùng tổn thương chiếm diện tích rất nhỏ trong ảnh.	86
4.14	Ca tổn thương tại vùng chồng lấp giải phẫu phức tạp (vai/xương đòn/lồng ngực), Dice=0.762 thấp hơn mức trung bình dù câu nhắc chính xác.	87

DANH SÁCH BẢNG

3.1	Kế thừa và đóng góp trong kiến trúc PGA-UNet	25
3.2	So sánh chiến lược huấn luyện giữa PGA-UNet và SAM-Med2D	32
4.1	Thống kê phân bố dữ liệu thực nghiệm	39
4.2	U-Net (tự động) so PGA-UNet (Zoom-out, câu nhắc), N=187 ảnh, cấp độ ảnh	44
4.3	Tính bền bỉ của PGA-UNet trên ba kịch bản câu nhắc (N=187 ảnh, cấp độ ảnh)	46
4.4	PGA-UNet so SAM-Med2D (đã/chưa tinh chỉnh), ba kịch bản câu nhắc, cùng 256×256 , cấp độ ảnh (N=187 ảnh). .	47
4.5	PGA-UNet tại 256×256 và 512×512 trên BTXRD, ba kịch bản câu nhắc (N=187 ảnh, cấp độ ảnh)	49
4.6	So sánh hiệu quả tính toán: PGA-UNet vs SAM-Med2D .	51
4.7	Ablation study: Dice Score của 8 biến thể kiến trúc PGA-UNet, ba kịch bản câu nhắc (N=187 ảnh, cấp độ ảnh). PGA-UNet (đề xuất) là mô hình chính xuyên suốt khóa luận. . .	53
4.8	Wilcoxon signed-rank, 6 cặp so sánh trọng tâm, ba kịch bản câu nhắc, trên BTXRD (N=187) và FracAtlas (N=72). $\Delta\text{Dice} = \text{Dice}(\text{vế trái}) - \text{Dice}(\text{vế phải})$; *** $p < 0,001$, ** $p < 0,01$, * $p < 0,05$, ns = không ý nghĩa.	56
4.9	Dice Score từng fold trong đánh giá chéo 4-fold PGA-UNet (kịch bản Zoom-out / Shift / Mixed)	58
4.10	Kết quả đánh giá chéo 4-fold PGA-UNet trên 3 kịch bản câu nhắc (trung bình 4 fold)	58
4.11	PGA-UNet so U-Net theo độ khó tác vụ (50 ảnh/nhóm, cấp độ ảnh; nhóm dễ/khó theo Dice của U-Net)	59

4.12	PGA-UNet so SAM-Med2D theo ba nhóm đặc tính lâm sàng (Zoom-out, 50 ảnh/nhóm, cấp độ ảnh)	61
4.13	PGA-UNet ₂₅₆ vs SAM-Med2D theo đặc tính lâm sàng, cùng 256×256 (Zoom-out, 50 ảnh/nhóm, cấp độ ảnh)	62
4.14	Thống kê phân bố bộ dữ liệu FracAtlas dùng trong thực nghiệm (đơn vị: mẫu per-polygon)	65
4.15	PGA-UNet trên FracAtlas: 256×256 và 512×512, ba kịch bản câu nhắc (N=72 ảnh, cấp độ ảnh)	66
4.16	U-Net (tự động) so PGA-UNet (512, Zoom-out) trên FracAtlas, cùng 512×512 (N=72 ảnh, cấp độ ảnh)	67
4.17	PGA-UNet (256) so SAM-Med2D (đã/chưa tinh chỉnh) trên FracAtlas, ba kịch bản câu nhắc, cùng 256×256, cấp độ ảnh (N=72 ảnh)	68
4.18	PGA-UNet so U-Net theo độ khó tác vụ trên FracAtlas (36 ảnh/nhóm, cấp độ ảnh; nhóm dễ/khó theo Dice U-Net, Zoom-out)	70
4.19	SAM-Med2D (FT, 256), PGA-UNet (256), PGA-UNet (512) theo đặc tính tổn thương trên FracAtlas (Zoom-out, 24 ảnh/nhóm, cấp độ ảnh)	71
4.20	Ablation study: Dice Score của 8 biến thể kiến trúc PGA-UNet trên FracAtlas, ba kịch bản câu nhắc (N=72 ảnh, cấp độ ảnh)	73
4.21	Dice Score từng fold trong đánh giá chéo 4-fold PGA-UNet trên FracAtlas (kịch bản Zoom-out / Shift / Mixed)	75
4.22	Kết quả đánh giá chéo 4-fold PGA-UNet trên FracAtlas, 3 kịch bản câu nhắc (trung bình 4 fold)	76
4.23	Kết quả đánh giá hiệu năng của Gatekeeper trên tập kiểm thử FracAtlas (N=409: 72 bệnh lý + 337 bình thường)	77
4.24	Phân bố xác suất dự đoán (cls_prob) của 21 ảnh FN trên FracAtlas theo khoảng cách tới ngưỡng 0.5	78

4.25	Đánh đổi Sensitivity/Specificity khi dịch chuyển ngưỡng phân loại của Gatekeeper trên FracAtlas	78
4.26	Kết quả luồng xử lý đầu cuối trên tập kiểm thử hỗn hợp FracAtlas (409 ảnh)	80
4.27	Kết quả đánh giá hiệu năng của mô hình phân lớp sàng lọc trên tập kiểm thử	89
4.28	Phân bố xác suất dự đoán (cls_prob) của 20 ảnh FN theo khoảng cách tới ngưỡng 0.5	91
4.29	So sánh diện tích tổn thương (% diện tích ảnh) giữa nhóm FN và nhóm TP	91
4.30	Đánh đổi Sensitivity/Specificity khi dịch chuyển ngưỡng phân loại của Gatekeeper	92
4.31	Kết quả luồng xử lý đầu cuối trên tập dataset_online (hỗn hợp bình thường + có bệnh)	96
4.32	Các chỉ số đầu cuối bổ sung ở cấp độ tổn thương (lesion-level), tính trên 232 tổn thương của 187 ảnh bệnh lý trong dataset_online	98

DANH MỤC CÁC KÝ HIỆU VÀ CHỮ VIẾT TẮT

Chữ viết tắt	Ý nghĩa
AG	Attention Gate (Cổng chú ý)
ALP	Alkaline Phosphatase (chỉ số xét nghiệm men gan/xương)
AUC-ROC	Area Under the Receiver Operating Characteristic Curve (Diện tích dưới đường cong ROC)
BCE	Binary Cross-Entropy (Entropy chéo nhị phân)
BTXRD	Bone Tumor X-Ray Dataset (bộ dữ liệu X-quang khối u xương)
CAD	Conditioned Attention Decoder (Cơ chế chú ý có điều kiện tại bộ giải mã)
CBL	Center-Based Localization (Độ chuẩn xác định vị tâm)
CNN	Convolutional Neural Network (Mạng nơ-ron tích chập)
COCO	Common Objects in Context (định dạng chú thích/nhân ảnh)
CT	Computed Tomography (Chụp cắt lớp vi tính)
DSC	Dice Similarity Coefficient (Hệ số tương đồng Dice)
FN	False Negative (Âm tính giả)
FP	False Positive (Dương tính giả)
FT	Fine-tuned / Fine-tuning (Tinh chỉnh)
GAP	Global Average Pooling (Gộp trung bình toàn cục)
GPU	Graphics Processing Unit (Bộ xử lý đồ họa)
GT	Ground Truth (Nhãn gốc/Nhãn thực)

Chữ viết tắt	Ý nghĩa
HD / HD95	Hausdorff Distance / Khoảng cách Hausdorff 95%
IoU	Intersection over Union (Chỉ số giao trên hợp)
JSON	JavaScript Object Notation (định dạng dữ liệu)
LDH	Lactate Dehydrogenase (chỉ số xét nghiệm)
LR	Learning Rate (Tốc độ học)
MBConv	Mobile Inverted Bottleneck Convolution
MRI	Magnetic Resonance Imaging (Chụp cộng hưởng từ)
NLP	Natural Language Processing (Xử lý ngôn ngữ tự nhiên)
NPV	Negative Predictive Value (Giá trị dự báo âm tính)
PACS	Picture Archiving and Communication System (Hệ thống lưu trữ và truyền hình ảnh y tế)
PGA-UNet	Prompt-Guided Attention U-Net (mô hình phân đoạn đề xuất của khóa luận)
PNG	Portable Network Graphics (định dạng ảnh)
PPV	Positive Predictive Value (Giá trị dự báo dương tính, đồng nghĩa với Precision)
PSG	Prompt Spatial Gate (Cổng không gian tại bộ mã hóa)
R/L	Right/Left (Ký hiệu chỉ hướng phải/trái trên ảnh X-quang)
ReLU	Rectified Linear Unit (hàm kích hoạt)
ROC	Receiver Operating Characteristic
SAM	Segment Anything Model
SAM-Med2D	Phiên bản SAM tinh chỉnh cho ảnh y tế 2D, mô hình đối sánh chính trong khóa luận
SE	Squeeze-and-Excitation (khối trong kiến trúc EfficientNet)

Chữ viết tắt	Ý nghĩa
SOTA	State-of-the-art (Hiện đại nhất)
TN	True Negative (Âm tính thật)
TP	True Positive (Dương tính thật)
ViT	Vision Transformer
VRAM	Video Random Access Memory (Bộ nhớ đồ họa)
ZS	Zero-shot (không tính chỉnh trên dữ liệu đích)

BẢNG ĐỐI CHIẾU THUẬT NGỮ CHUYÊN NGÀNH ANH – VIỆT

Để giữ văn phong tiếng Việt nhất quán, thân bài khóa luận hạn chế chèn tiếng Anh: thuật ngữ chuyên ngành chung (không phải tên riêng mô hình/kiến trúc, không phải ký hiệu đo lường chuẩn quốc tế) đều dịch sang tiếng Việt và dùng thống nhất. Bảng dưới đối chiếu thuật ngữ tiếng Việt đã dùng với thuật ngữ gốc tiếng Anh.

Riêng tên mô hình/kiến trúc (U-Net, PGA-UNet, SAM-Med2D, EfficientNet_B3, ViT-B, Attention Gate...) và ký hiệu đo lường chuẩn quốc tế (Dice, IoU, HD95, CBL, AUC-ROC, Precision, Recall, F1...) giữ nguyên dạng gốc vì là tên riêng/ký hiệu chuẩn hóa quốc tế; xem Phụ lục Danh mục các ký hiệu và chữ viết tắt.

Thuật ngữ tiếng Việt dùng trong khóa luận	Thuật ngữ gốc tiếng Anh
Bộ mã hóa	Encoder
Bộ giải mã	Decoder
Vòng lặp (huấn luyện)	Epoch
Điểm lưu trọng số	Checkpoint
Mạng nền tảng	Backbone
Lô (dữ liệu)	Batch
Tinh chỉnh / đã tinh chỉnh	Fine-tune / Fine-tuned
Chưa tinh chỉnh	Zero-shot
Cổng / tín hiệu cổng	Gate / Gating
Kết nối dư	Residual (connection)
Kết nối tắt	Skip connection

Thuật ngữ tiếng Việt dùng trong khóa luận	Thuật ngữ gốc tiếng Anh
Bản đồ đặc trưng	Feature map
Cơ chế chú ý	Attention
Cơ chế chú ý chéo	Cross-attention
Vector nhúng	Embedding
Cửa sổ lọc	Kernel
Huấn luyện	Training
Suy luận	Inference
Đệm	Padding
Đạo hàm	Gradient
Phần tử (rời rạc)	Token
Lớp thích ứng	Adapter
Miền dữ liệu	Domain
Hộp giới hạn	Bounding box
Câu nhắc	Prompt
Con người luôn giám sát trong vòng lặp (quyết định)	Human-in-the-loop
Luồng xử lý	Pipeline
Đầu cuối	End-to-end
Tính bền bỉ	Robustness
Quá khớp	Overfitting
Chỉnh lại kích thước (ảnh)	Resize
Bỏ qua (một bước xử lý)	Bypass
Thiên kiến tự động hóa	Automation bias
Hòa trộn sớm	Early fusion

Thuật ngữ tiếng Việt dùng trong khóa luận	Thuật ngữ gốc tiếng Anh
Tầng đầu ra (phân lớp)	(Classification) head
Cấp độ ảnh	Image-level
Nhóm nhỏ (theo đặc tính)	Sub-category

TÓM TẮT KHÓA LUẬN

Khóa luận nghiên cứu và phát triển một hệ thống phân đoạn tương tác ảnh X-quang xương dựa trên câu nhắc trực quan, giúp bác sĩ khoanh vùng tổn thương nhanh và chính xác hơn.

Bài toán: Các mô hình phân đoạn tự động (U-Net, Attention U-Net) không tận dụng được tri thức của bác sĩ nên dễ nhận diện sai trên ảnh X-quang có độ tương phản thấp. Ngược lại, các mô hình tương tác nền tảng (SAM, SAM-Med2D) lại quá nặng để triển khai thực tế tại nhiều cơ sở y tế.

Giải pháp: Khóa luận đề xuất **PGA-UNet** (Prompt-Guided Attention U-Net), một kiến trúc CNN hạng nhẹ tích hợp trực tiếp câu nhắc hộp giới hạn của bác sĩ vào cả bộ mã hóa (qua Cổng không gian) lẫn bộ giải mã (qua Cơ chế chú ý có điều kiện). Một module sàng lọc (EfficientNet_B3) được thêm vào để phân loại ảnh trước khi phân đoạn, tạo thành luồng xử lý đầu cuối hoàn chỉnh.

Kết quả: PGA-UNet đạt $\text{Dice} = 0.8607$ trên tập kiểm thử 187 ảnh, vượt trội U-Net (0.4740) và SAM-Med2D đã tinh chỉnh (0.7541) dù nhỏ hơn nhiều lần về số tham số. Mô hình vẫn giữ $\text{Dice} = 0.8423$ khi câu nhắc bị lệch tâm, cho thấy tính bền vững trước sai lệch bbox trong các kịch bản mô phỏng. Module sàng lọc đạt $\text{AUC-ROC} = 0.9421$; đánh giá cả luồng xử lý trên dữ liệu hỗn hợp mô phỏng một phần điều kiện thực tế cho thấy hệ thống còn sai số tích lũy cần tiếp tục cải thiện (Pipeline Dice end-to-end = 0.6763, tính đủ cả ca bệnh bị bỏ sót). Toàn bộ hệ thống đã được tích hợp vào một ứng dụng demo minh họa quy trình phân đoạn tương tác trên ảnh X-quang.

Từ khóa: Phân đoạn ảnh y khoa, câu nhắc trực quan, X-quang xương, U-Net, phân đoạn tương tác.

CHƯƠNG 1

GIỚI THIỆU

1.1 Bối cảnh chung

Chẩn đoán hình ảnh qua tia X (X-quang) là một trong những phương thức cận lâm sàng phổ biến và quan trọng nhất của y khoa hiện đại: hiển thị trực tiếp cấu trúc xương mà không cần can thiệp xâm lấn, được dùng rộng rãi để phát hiện và theo dõi gãy xương, rạn xương, thoái hóa khớp và khối u xương. Tại các cơ sở y tế lớn, số ca chụp X-quang mỗi ngày lên đến hàng trăm ca – Cambridge University Hospitals (Anh) thực hiện hơn 174.000 ca/năm, riêng khoa ngoại trú tiếp nhận 200–300 bệnh nhân/ngày [1], đặt áp lực đáng kể lên bác sĩ chẩn đoán hình ảnh và tăng nguy cơ sai sót do mỏi mắt, quá tải.

Trong hệ thống hỗ trợ chẩn đoán bằng máy tính, bước xác định và khoanh vùng tổn thương (*phân đoạn ảnh*, image segmentation) là tiền đề để đo kích thước tổn thương, theo dõi diễn tiến và lập kế hoạch điều trị. Phân đoạn thủ công trên hệ thống PACS (Picture Archiving and Communication System) tốn nhiều thời gian, phụ thuộc lớn vào kinh nghiệm cá nhân và tiềm ẩn sai sót do mỏi mắt hoặc áp lực công việc.

Những hạn chế trên thúc đẩy cộng đồng nghiên cứu tìm giải pháp hỗ trợ chẩn đoán tự động dựa trên học sâu (deep learning). Khoảng một thập kỷ qua, các kiến trúc mạng nơ-ron tích chập như U-Net [2] đạt kết quả đáng khích lệ trong phân đoạn ảnh y khoa; song song đó, các mô hình nền tảng như SAM (Segment Anything Model) phổ biến hóa phân đoạn dựa trên câu nhắc trực quan và thúc đẩy hướng nghiên cứu tương tác người-máy – nền tảng khoa học mà khóa luận này kế thừa và phát triển.

1.2 Động lực nghiên cứu

1.2.1 Động lực khoa học

Mặc dù đã đạt nhiều tiến bộ, các phương pháp phân đoạn hoàn toàn tự động vẫn tồn tại hạn chế cốt lõi: hoạt động như *hộp đen*, suy luận tự động trên toàn ảnh mà không có thông tin định hướng nào từ chuyên gia. Trong ảnh X-quang xương, nơi các cấu trúc giải phẫu chồng lấp và vùng tổn thương thường có độ tương phản thấp hoặc đặc điểm hình thái gần giống mô lành lân cận, cách tiếp cận này dễ dẫn đến phân đoạn sai lệch (dương tính giả) hoặc bỏ sót tổn thương (âm tính giả).

Một hướng nghiên cứu đang được quan tâm là *phân đoạn tương tác*, nơi người dùng cung cấp tín hiệu không gian sơ bộ (ví dụ hộp giới hạn) để định hướng mô hình tập trung vào vùng mục tiêu – cải thiện độ chính xác khi câu nhắc phù hợp, đồng thời đặt con người vào vị trí kiểm soát trong vòng lặp suy luận, có ý nghĩa đặc biệt quan trọng trong ứng dụng y tế.

Tuy nhiên, cách tích hợp hiệu quả tín hiệu định hướng này vào kiến trúc mạng nơ-ron – biểu diễn, mã hóa và truyền tải thông tin câu nhắc qua các tầng mạng – vẫn là hướng nghiên cứu đang được quan tâm, đặc biệt trong ảnh y khoa chuyên biệt.

1.2.2 Động lực thực tiễn

Trong thực tế lâm sàng, không thể kỳ vọng mọi thao tác của bác sĩ đều hoàn hảo: câu nhắc có thể bị lệch tâm do chú ý không tập trung, hoặc đặt sai vị trí hoàn toàn do nhầm lẫn. Một hệ thống phân đoạn đáng tin cậy cần khả năng *chịu đựng sai sót*: nhận biết khi câu nhắc có vấn đề và phản hồi phù hợp, thay vì im lặng trả về kết quả sai lệch.

Việc tích hợp hệ thống vào quy trình thực tế còn đòi hỏi tốc độ suy luận thời gian thực và khả năng giải thích quyết định của mô hình – hai yếu tố thường chưa được cân nhắc đồng thời với độ chính xác.

Hai động lực trên định hình mục tiêu của khóa luận: không chỉ một

mô hình phân đoạn chính xác, mà là một *hệ thống* hỗ trợ tương tác, bền bỉ và minh bạch để thực sự hỗ trợ bác sĩ trong phòng khám.

1.3 Phát biểu bài toán

Người dùng cuối: Bác sĩ chẩn đoán hình ảnh làm việc trong ca đọc phim, sử dụng hệ thống PACS để xem xét ảnh X-quang từ nhiều bệnh nhân – có chuyên môn lâm sàng nhưng không nhất thiết có kiến thức kỹ thuật về học sâu; thao tác duy nhất cần thực hiện là khoanh vùng nghi ngờ trên màn hình.

Bài toán: Cho ảnh X-quang xương mới $\mathbf{I} \in \mathbb{R}^{H \times W}$ và hộp giới hạn $\mathbf{B} = (x_1, y_1, x_2, y_2)$ do bác sĩ khoanh lên vùng nghi ngờ, hệ thống cần tự động tạo mặt nạ phân đoạn $\hat{\mathbf{M}} \in \{0, 1\}^{H \times W}$ xác định chính xác ranh giới tổn thương trong vùng chỉ định, đồng thời bền vững trước sai lệch thực tế khi vẽ hộp (lệch tâm, khác kích thước). Trong đó $H \times W$ là chiều cao/rộng ảnh (pixel); (x_1, y_1) , (x_2, y_2) là tọa độ góc trên-trái và dưới-phải của hộp giới hạn.

Cụ thể, đầu vào và đầu ra của hệ thống khi hoạt động trực tuyến được định nghĩa như sau:

- **Đầu vào:**

- Ảnh X-quang xương $\mathbf{I} \in \mathbb{R}^{H \times W}$.
- Hộp giới hạn $\mathbf{B} = (x_1, y_1, x_2, y_2)$ do bác sĩ vẽ bao quanh vùng nghi ngờ tổn thương.

- **Đầu ra:** Mặt nạ phân đoạn nhị phân $\hat{\mathbf{M}} \in \{0, 1\}^{H \times W}$, trong đó pixel có giá trị 1 là vùng được dự đoán là tổn thương.

Luồng xử lý gồm hai bước tuần tự. Bước đầu, ảnh X-quang qua mô hình sàng lọc để đưa ra **gợi ý** (có bệnh/không bệnh kèm độ tin cậy); bác sĩ xem và chủ động xác nhận trước khi hệ thống tiếp tục – mô hình không tự

động dừng hay chuyển bước mà không có xác nhận. Nếu bác sĩ xác nhận không bệnh lý, quy trình kết thúc; nếu xác nhận có bệnh lý (kể cả khi trái với gợi ý), bác sĩ khoanh hộp và bước phân đoạn có hướng dẫn được kích hoạt:

$$\hat{\mathbf{M}} = \mathbf{1}[f_{\text{seg}}(\mathbf{I}, \mathbf{H}(\mathbf{B}); \boldsymbol{\theta}_{\text{seg}}) \geq 0.5] \quad (1.1)$$

trong đó các ký hiệu được định nghĩa như sau:

- $\hat{\mathbf{M}} \in \{0, 1\}^{H \times W}$: mặt nạ phân đoạn nhị phân đầu ra (1 = tổn thương, 0 = nền).
- $\mathbf{1}[\cdot]$: hàm chỉ thị (indicator function), trả về 1 nếu điều kiện bên trong đúng và 0 nếu sai; ở đây dùng để nhị phân hóa xác suất đầu ra theo ngưỡng 0.5.
- $f_{\text{seg}}(\cdot; \boldsymbol{\theta}_{\text{seg}})$: mô hình phân đoạn PGA-UNet, xuất xác suất thuộc tổn thương $\in [0, 1]$ cho từng pixel.
- $\mathbf{I} \in \mathbb{R}^{H \times W}$: ảnh X-quang đầu vào.
- $\mathbf{H}(\mathbf{B}) \in [0, 1]^{H \times W}$: bản đồ nhiệt câu nhắc được tạo từ hộp giới hạn $\mathbf{B} = (x_1, y_1, x_2, y_2)$ do bác sĩ vẽ (chi tiết tại Mục 2.3.1).
- $\boldsymbol{\theta}_{\text{seg}}$: tập tham số học được của PGA-UNet, tối ưu hóa trong giai đoạn huấn luyện ngoại tuyến.
- 0.5: ngưỡng nhị phân hóa, pixel được dự đoán là tổn thương khi xác suất đạt từ 0.5 trở lên.

Thiết kế này phản ánh triết lý *con người luôn giám sát trong vòng lặp* xuyên suốt cả hai bước: ở bước sàng lọc, mô hình chỉ đề xuất gợi ý còn bác sĩ mới xác nhận quyết định (thiết kế *triage mềm*, không phải bộ chặn tự động loại ảnh mà không cho phép can thiệp); ở bước phân đoạn, bác sĩ trực tiếp cung cấp định hướng không gian qua hộp giới hạn – tri thức lâm sàng của chuyên gia luôn tham gia toàn bộ vòng lặp quyết định, không chỉ

riêng bước phân đoạn. Chi tiết kiến trúc và huấn luyện ngoại tuyến của hai mô hình tại Chương 3.

1.4 Thách thức của bài toán

Việc xây dựng hệ thống như phát biểu ở trên đối mặt với bốn nhóm thách thức chính:

Thách thức về dữ liệu: Tập dữ liệu X-quang xương thực tế thường không sạch, chứa nhiều kỹ thuật như ký hiệu R/L, dòng văn bản thông tin bệnh nhân, thiết bị cố định xương – đều có thể ảnh hưởng tiêu cực đến quá trình học nếu không xử lý cẩn thận, một thách thức kỹ thuật phòng thí nghiệm nhưng ảnh hưởng đáng kể đến chất lượng toàn hệ thống.

Thách thức về mô hình hóa: Ảnh X-quang xương có độ tương phản thấp và nhiều cấu trúc giải phẫu chồng lấp; vùng tổn thương thường tương phản thấp hoặc hình thái gần giống mô xương lành lân cận, gây khó khăn trích xuất đặc trưng phân biệt. Thách thức là tích hợp thông tin câu nhắc vào kiến trúc mạng hiệu quả, sao cho mô hình thực sự *sử dụng* câu nhắc để định hướng phân đoạn chứ không bỏ qua nó.

Thách thức về tính bền bỉ: Câu nhắc của bác sĩ có thể lệch tâm hoặc lệch kích thước tùy thao tác vẽ và góc nhìn chủ quan. Hệ thống cần duy trì hiệu năng phân đoạn ổn định ngay cả khi câu nhắc bị lệch đáng kể, không phụ thuộc cứng nhắc vào vị trí tâm câu nhắc.

Thách thức về khả năng triển khai: Hệ thống cần thời gian phản hồi đủ nhanh trong điều kiện phần cứng thực tế cho quy trình lâm sàng – yêu cầu hiệu quả tính toán: độ chính xác phân đoạn cao với số tham số tối thiểu.

1.5 Đóng góp của khóa luận

Khóa luận có hai đóng góp chính:

1. **Đề xuất biểu diễn câu nhắc dạng heatmap và kiến trúc PGA-UNet điều kiện hóa bởi câu nhắc:** Đóng góp trọng tâm là **mã hóa hộp giới hạn thành Gaussian Plateau Heatmap**: kênh 2D liên tục đồng kích thước với bản đồ đặc trưng, cung cấp tín hiệu định hướng với đạo hàm liên tục thay vì vector rời rạc (như SAM/SAM-Med2D) hay mặt nạ nhị phân. Biểu diễn này tương thích cấu trúc với phép tích chập CNN, cho phép tín hiệu câu nhắc lan truyền qua toàn bộ các tầng mạng. Kiến trúc PGA-UNet (~ 3 triệu tham số) hiện thực hóa đóng góp này trên nền U-Net qua hai thành phần:

- *Cổng không gian tại bộ mã hóa (PSG)*: không tồn tại trong U-Net hay Attention U-Net gốc, tích hợp bản đồ heatmap vào từng tầng bộ mã hóa theo cơ chế khuếch đại có chọn lọc (chỉ khuếch đại, không triệt tiêu), tăng cường đặc trưng trong vùng câu nhắc mà không mất thông tin ngoài vùng. Hướng đưa bản đồ không gian vào CNN đã được gợi mở ở các công trình trước [3], [4]; PSG cụ thể hóa thành cơ chế gate nhân huấn luyện từ đầu trên CNN nhẹ (đối chiếu tại Bảng 3.1, Chương 3).
- *Cơ chế chú ý có điều kiện tại bộ giải mã (CAD)*: Kế thừa Cổng chú ý từ Attention U-Net [5], mở rộng bằng cách đưa heatmap câu nhắc trực tiếp vào tín hiệu cổng **g**, thay vì chỉ dựa vào đặc trưng ảnh như thiết kế gốc.

Ablation study xác nhận: Gaussian Heatmap so với câu nhắc nhị phân cải thiện Dice Shift +0.10 (PGA-UNet đề xuất vs PGA-UNet Binary, cùng kiến trúc PSG+CAD); PSG+CAD kết hợp Gaussian tạo hiệu ứng tương hỗ, cải thiện Dice Shift +0.11 so với chỉ nối kênh heatmap đơn giản (PGA-UNet đề xuất vs U-Net+Concat); chi tiết tại Bảng 4.7, Chương 4. Toàn hệ thống được so sánh với U-Net và SAM-Med2D trên bộ dữ liệu BTXRD.

2. **Đánh giá thực nghiệm toàn luồng xử lý:** Xây dựng kịch bản

đánh giá đầu cuối kết hợp module phân lớp sàng lọc (Gatekeeper, EfficientNet_B3) và PGA-UNet trên tập dữ liệu hỗn hợp gồm cả ảnh bình thường và bệnh lý, phân bố gần thực tế hơn so với đánh giá phân đoạn đơn lẻ trên tập ảnh bệnh thuần túy. Gatekeeper đạt $AUC-ROC = 0.9421$; hệ thống hai tầng cho Pipeline Dice end-to-end = 0.6763, thấp hơn PGA-UNet độc lập do sai số tích lũy từ bước phân lớp (phân tích chi tiết ở cấp độ ảnh, cấp độ tổn thương và các ca lỗi cụ thể tại Chương 4, Phần II). Đây là kịch bản **thận trọng nhất** đo cận dưới hiệu năng hệ thống (giả định gợi ý Gatekeeper được làm theo tuyệt đối, chưa mô phỏng bước bác sĩ xác nhận của thiết kế triage mềm thực tế, Chương 3).

1.6 Bố cục của khóa luận

Khóa luận được tổ chức thành năm chương:

Chương 1: Giới thiệu trình bày bối cảnh chung, động lực khoa học và thực tiễn, phát biểu bài toán từ góc nhìn người dùng cuối (bác sĩ chẩn đoán hình ảnh) với đầu vào/đầu ra tại giai đoạn suy luận trực tuyến, thách thức cốt lõi và đóng góp của khóa luận.

Chương 2: Các công trình liên quan và cơ sở lý thuyết khảo sát các phương pháp phân đoạn ảnh y khoa tự động và tương tác, xác định khoảng trống nghiên cứu, trình bày nền tảng lý thuyết gồm kiến trúc U-Net, cơ chế chú ý, biểu diễn câu nhắc và các độ đo đánh giá.

Chương 3: Mô hình và hệ thống đề xuất trình bày chi tiết kỹ thuật kiến trúc PGA-UNet (Cổng không gian, Cơ chế chú ý có điều kiện), đặc điểm bộ dữ liệu và module phân lớp sàng lọc.

Chương 4: Thực nghiệm và đánh giá kết quả mô tả thiết lập thực nghiệm, kết quả so sánh với U-Net và SAM-Med2D, tính bền bỉ câu nhắc, ablation study, kiểm định chéo (cross-validation) và phân tích theo đặc tính tổn thương (sub-category) trên BTXRD; đồng thời trình bày thực nghiệm bổ sung kiểm tra khả năng tổng quát hóa trên bộ dữ liệu độc lập

thứ hai (FracAtlas), cùng đánh giá module sàng lọc và luồng xử lý đầu cuối.

Chương 5: Kết luận và hướng phát triển tóm tắt kết quả đạt được, nhìn nhận khách quan hạn chế và đề xuất hướng nghiên cứu tiếp theo.

CHƯƠNG 2

CÁC CÔNG TRÌNH LIÊN QUAN VÀ CƠ SỞ LÝ THUYẾT

Chương này gồm hai phần. Phần đầu (Mục 2.1) khảo sát các công trình liên quan, đặt khóa luận trong bức tranh nghiên cứu hiện tại và làm rõ khoảng trống cần giải quyết. Phần sau (Mục 2.2–2.4) trình bày cơ sở lý thuyết cần thiết để hiểu kiến trúc và cơ chế hoạt động của hệ thống đề xuất ở Chương 3.

2.1 Các công trình liên quan

2.1.1 Các phương pháp phân đoạn ảnh y khoa tự động

Trong phân tích hình ảnh y khoa, kiến trúc U-Net [2] (Ronneberger và cộng sự, 2015) là nền tảng cốt lõi cho nhiều nghiên cứu về sau. Thiết kế mã hóa - giải mã đối xứng kết hợp kết nối tắt cho phép trích xuất đặc trưng ngữ nghĩa nhiều cấp độ đồng thời bảo toàn thông tin vị trí không gian, giúp mô hình đạt hiệu năng khả quan ngay cả khi huấn luyện trên dữ liệu y khoa quy mô nhỏ và thiếu nhãn.

Để tập trung vào vùng đặc trưng quan trọng và giảm nhiễu nền, Oktay và cộng sự (2018) đề xuất Attention U-Net [5]: tích hợp Cổng chú ý (Attention Gates) tại các kết nối tắt, cho phép mô hình tự động làm nổi bật khu vực chứa đặc trưng quan trọng và ức chế vùng nhiễu nền trước khi đưa vào bộ giải mã.


Tuy nhiên, cả U-Net và Attention U-Net đều có giới hạn chung khi triển khai trên ảnh X-quang xương: phân đoạn hoàn toàn tự động. Mô hình chỉ nhận ảnh thô và phải tự tìm vùng tổn thương, không có thông tin định hướng hay tri thức lâm sàng từ bác sĩ – với ảnh có độ tương phản thấp và

cấu trúc xương chồng lấp, cách tiếp cận này khó xác định chính xác vùng tổn thương, nhất là khi mô lành có đặc trưng hình thái tương tự.

2.1.2 Phương pháp học máy tương tác trong y khoa

Để khắc phục hạn chế của các phương pháp tự động, xu hướng nghiên cứu gần đây quan tâm hơn đến phân đoạn có tương tác, cho phép bác sĩ cung cấp tín hiệu định hướng (hộp giới hạn, điểm bấm) để mô hình tập trung đúng vùng cần phân tích.

Đại diện tiêu biểu trong y khoa là **SAM-Med2D** [6] (Cheng và cộng sự, 2023), mô hình được chọn làm đối sánh trực tiếp trong khóa luận. SAM-Med2D kế thừa kiến trúc Segment Anything Model (SAM) với bộ mã hóa ảnh Vision Transformer (ViT-B, ~ 91 triệu tham số), tinh chỉnh trên khoảng 4,6 triệu ảnh y khoa 2D đa phương thức bằng chiến lược chèn lớp thích ứng, giữ nguyên phần lớn trọng số nền tảng, chỉ cập nhật tầng thích ứng và bộ giải mã. Mô hình nhận hộp giới hạn làm câu nhắc vị trí qua bộ mã hóa câu nhắc và xuất mặt nạ phân đoạn (Hình 2.1).



Hình 2.1: Kiến trúc SAM-Med2D [6]: bộ mã hóa ảnh ViT-B (tham số đóng băng ●) được chèn lớp thích ứng nhỏ gọn (tham số học được ●) sau mỗi khối Transformer; câu nhắc hộp giới hạn qua bộ mã hóa câu nhắc tạo vector nhúng vị trí, bộ giải mã mặt nạ kết hợp đặc trưng ảnh và vector nhúng câu nhắc để xuất mặt nạ phân đoạn. Tinh chỉnh trên SAM-Med2D-20M ($\sim 4,6$ triệu ảnh y tế 2D đa phương thức).

Tuy nhiên, SAM-Med2D vẫn có giới hạn triển khai: bộ mã hóa ViT-B

$\sim 91\text{M}$ tham số đòi hỏi VRAM cao hơn đáng kể so với CNN hạng nhẹ, và độ phân giải đầu vào cố định 256×256 (do vector nhúng vị trí không đổi được) giới hạn khả năng phân đoạn chi tiết trên ảnh X-quang xương vốn cần độ phân giải cao.

Khoảng trống nghiên cứu: U-Net và Attention U-Net thiếu hoàn toàn cơ chế tiếp nhận định hướng từ bác sĩ; SAM-Med2D tuy có câu nhắc nhưng kiến trúc ViT-B nặng tài nguyên và giới hạn độ phân giải. Khóa luận lấp đầy khoảng trống đó bằng cách tích hợp câu nhắc trực quan trực tiếp vào kiến trúc CNN hạng nhẹ chuyên biệt cho ảnh X-quang 2D, huấn luyện hoàn toàn từ đầu trên miền dữ liệu đặc thù với chi phí tính toán thấp hơn đáng kể.

2.2 Cơ sở lý thuyết nền tảng

2.2.1 Mạng nơ-ron tích chập (CNN)

Mạng nơ-ron tích chập (Convolutional Neural Network - CNN) là nền tảng cốt lõi của hầu hết mô hình học sâu hiện đại trong thị giác máy tính. Khác với mạng kết nối đầy đủ truyền thống (dễ bùng nổ số tham số khi áp dụng cho dữ liệu ảnh), CNN dùng cơ chế chia sẻ trọng số và kết nối cục bộ qua phép tích chập, giúp trích xuất hiệu quả đặc trưng không gian (cạnh, góc, họa tiết) và bền vững hơn trước dịch chuyển nhỏ của đối tượng trong ảnh.

Tại tầng tích chập thứ l , bản đồ đặc trưng đầu vào $\mathbf{F}^l \in \mathbb{R}^{H \times W \times C_{in}}$ được nhân chập với bộ lọc $\mathbf{W} \in \mathbb{R}^{k \times k \times C_{in} \times C_{out}}$, cho đầu ra theo công thức tích chập rời rạc:

$$\mathbf{F}_{i,j,c}^{l+1} = \sigma \left(\sum_m \sum_n \sum_{c'} \mathbf{W}_{m,n,c',c} \cdot \mathbf{F}_{i+m,j+n,c'}^l + b_c \right) \quad (2.1)$$

trong đó k là kích thước bộ lọc, σ là hàm kích hoạt phi tuyến (thường ReLU, giúp giảm mất dần đạo hàm khi huấn luyện), b_c là hệ số chệch. Xen

kế các tầng tích chập là tầng gộp (phổ biến nhất Max Pooling), giảm kích thước không gian để mở rộng trường tiếp nhận của các bộ lọc sâu hơn.


2.2.2 Kiến trúc U-Net

Thiết kế chuyên biệt cho phân đoạn ảnh y khoa, U-Net [2] có kiến trúc đối xứng hình chữ "U", gồm hai nhánh chính:

Bộ mã hóa: Nhánh thu nhỏ không gian bên trái. Qua chuỗi tích chập và gộp cực đại (Max Pooling), nhánh này nén thông tin ảnh, biến chi tiết cục bộ ở tầng nông thành đặc trưng toàn cục ở tầng sâu – đặc trưng ngày càng trừu tượng hơn nhưng cũng suy giảm thông tin vị trí và chi tiết không gian do giảm mẫu liên tiếp.

Bộ giải mã: Nhánh khôi phục không gian bên phải, dùng phép tăng mẫu để khôi phục dần độ phân giải về kích thước ảnh gốc. Tầng cuối thường dùng Sigmoid (phân đoạn nhị phân) hoặc Softmax (đa lớp) để xuất bản đồ xác suất theo điểm ảnh.

Kết nối tắt: Yếu tố đột phá của U-Net – sao chép trực tiếp bản đồ đặc trưng độ phân giải cao từ bộ mã hóa và nối kênh (concatenate) vào bộ giải mã tương ứng, bù đắp thông tin không gian bị mất khi giảm mẫu, giúp tái tạo chính xác đường biên giải phẫu của tổn thương (Hình 2.2).



Hình 2.2: Kiến trúc U-Net, 4 cấp độ phân giải: nhánh mã hóa (trái) giảm mẫu qua Max Pooling; nhánh giải mã (phải) khôi phục độ phân giải qua UpConv; kết nối tắt nối đặc trưng cùng cấp để bù thông tin vị trí bị mất.

2.2.3 Cơ chế chú ý và kiến trúc Attention U-Net

Dù kết nối tắt trong U-Net bảo toàn thông tin không gian hiệu quả, chúng cũng có thể truyền sang bộ giải mã các đặc trưng ít liên quan hoặc

nhiều nền. Cơ chế chú ý được áp dụng để tăng cường vùng ảnh mang thông tin hữu ích và giảm trọng số vùng ít quan trọng cho nhiệm vụ phân đoạn.


Kiến trúc Attention U-Net [5] cụ thể hóa cơ chế này bằng cách chèn **Cổng chú ý (AG)** tại các kết nối tắt. Cổng chú ý nhận hai luồng tín hiệu: bản đồ đặc trưng từ tầng mã hóa $\mathbf{x}^l$ và tín hiệu cổng $\mathbf{g}$ lấy từ tầng sâu hơn của bộ giải mã (chứa thông tin ngữ nghĩa mạnh).

Hệ số chú ý không gian $\alpha^l \in [0, 1]^{H \times W}$ được tính toán như sau:

$$\alpha^l = \sigma_2 \left(\mathbf{W}_\psi^\top \cdot \sigma_1 \left(\mathbf{W}_x \mathbf{x}^l + \mathbf{W}_g \mathbf{g} + \mathbf{b}_g \right) + b_\psi \right) \quad (2.2)$$

trong đó σ_1 là hàm kích hoạt ReLU, σ_2 là hàm Sigmoid, và $\{\mathbf{W}_x, \mathbf{W}_g, \mathbf{W}_\psi, \mathbf{b}_g, b_\psi\}$ là các tham số học được của Cổng chú ý. Bản đồ đặc trưng sau đó được nhân vô hướng với hệ số chú ý để làm nổi bật các khu vực cần thiết: $\hat{\mathbf{x}}^l = \alpha^l \odot \mathbf{x}^l$.

Nhận xét: Cổng chú ý giúp bộ giải mã tập trung tốt hơn vào vùng tổn thương. Tuy nhiên, tín hiệu cổng $\mathbf{g}$ vẫn được trích xuất hoàn toàn từ ảnh đầu vào – việc xác định vùng quan tâm chưa có sự hỗ trợ trực tiếp từ thông tin định hướng do người dùng cung cấp, đòi hỏi một cơ chế điều kiện hóa mạnh hơn từ tri thức chuyên gia, tạo tiền đề cho kiến trúc chú ý có điều kiện dựa trên câu nhắc ở Chương 3 (Hình 2.3).



Lưu ý: Mô hình này không có prompt — phân biệt với PGA-UNet (Số đồ 3).

Hình 2.3: Kiến trúc Attention U-Net: Cổng chú ý chèn tại kết nối tắt, dùng tín hiệu cổng $\mathbf{g}$ từ bộ giải mã để lọc nhiễu nền trước khi truyền đặc trưng sang tầng giải mã tương ứng.

2.3 Học máy dựa trên câu nhắc trong thị giác máy tính

Khái niệm "câu nhắc", phổ biến trong Xử lý ngôn ngữ tự nhiên (NLP), đã dần mở rộng sang Thị giác máy tính. Thay vì huấn luyện một mô hình tĩnh giải quyết tác vụ cố định, học máy dựa trên câu nhắc cho phép mô hình linh hoạt điều chỉnh dự đoán theo thông tin định hướng bổ sung (văn bản, điểm ảnh, hộp giới hạn) do người dùng cung cấp ở pha suy luận.

2.3.1 Biểu diễn không gian của câu nhắc trực quan

Trong phần mềm chẩn đoán hình ảnh, thao tác tương tác tự nhiên nhất của chuyên gia y tế là kéo chuột tạo hộp giới hạn bao quanh vùng tổn thương nghi ngờ, định nghĩa bởi tọa độ hai góc đối diện $\mathbf{B} = (x_1, y_1, x_2, y_2)$. Thách thức là mã hóa tọa độ hình học này thành định dạng mà CNN xử lý được đồng thời với ảnh đầu vào.

Cách tiếp cận phổ biến là chuyển hộp giới hạn thành **Bản đồ nhiệt câu nhắc** $\mathbf{H} \in [0, 1]^{H \times W}$, cùng độ phân giải không gian với ảnh X-quang. Thay vì mặt nạ nhị phân cứng (1 bên trong, 0 bên ngoài hộp), bản đồ nhiệt dùng phân phối chuẩn Gaussian hai chiều để biểu diễn mức độ tin cậy không gian.

Tâm hình học của hộp giới hạn là (μ_x, μ_y) với $\mu_x = \frac{x_1+x_2}{2}$, $\mu_y = \frac{y_1+y_2}{2}$. Phân phối không gian của bản đồ nhiệt:

$$H(x, y) = \exp \left(-\frac{(x - \mu_x)^2}{2\sigma_x^2} - \frac{(y - \mu_y)^2}{2\sigma_y^2} \right) \quad (2.3)$$

trong đó σ_x, σ_y là độ lệch chuẩn kiểm soát độ rộng Gaussian theo trục x, y , thường cấu hình tỉ lệ thuận kích thước hộp giới hạn (ví dụ $\sigma_x = \frac{x_2-x_1}{4}$, $\sigma_y = \frac{y_2-y_1}{4}$).

Cách biểu diễn này mang ý nghĩa lâm sàng: $H(x, y)$ đạt cực đại (1.0) tại tâm vùng bác sĩ khoanh (độ chắc chắn cao nhất) và giảm mềm mại về phía cạnh, giúp mô hình không bị “ép buộc” học đường biên sắc nét giả tạo từ nét khoanh tay người dùng, mà coi đó là tín hiệu định hướng không gian hỗ trợ học và suy luận.

Biến thể triển khai – Plateau Heatmap: Một biến thể phổ biến là *Plateau Heatmap*: gán đồng nhất giá trị 1.0 cho toàn bộ vùng trong hộp giới hạn (vùng cao nguyên phẳng), sau đó làm mềm đường biên bằng bộ lọc Gaussian. Cách này duy trì tín hiệu mạnh, đồng đều trong vùng câu nhắc (không suy giảm về tâm), phù hợp hơn khi kích thước câu nhắc sát kích thước tổn thương. Khóa luận dùng biến thể này (Mục 3.3); phương trình Gaussian (2.3) là nền tảng lý thuyết cho cả hai biến thể.

2.3.2 Cơ chế chú ý có điều kiện

Sau khi có bản đồ nhiệt câu nhắc $\mathbf{H}$, bài toán tiếp theo là "tiêm" thông tin này vào U-Net. Cách đơn giản nhất là ghép kênh trực tiếp $\mathbf{H}$ với ảnh X-quang gốc ở tầng đầu vào (hòa trộn sớm), nhưng tín hiệu định hướng ghép sớm có thể suy giảm khi lan truyền qua nhiều tầng tích chập sâu, khiến mô hình khai thác chưa hiệu quả thông tin câu nhắc.

Một hướng khác là **Cơ chế chú ý có điều kiện**: tích hợp thông tin câu nhắc trực tiếp vào tính toán trọng số chú ý, bằng cách mở rộng Cổng chú ý truyền thống (Mục 2.2.3, vốn chỉ nhận đặc trưng ảnh) để chấp nhận thêm tín hiệu định hướng bên ngoài làm điều kiện. Hệ số chú ý α khi đó được ràng buộc rõ bởi ma trận định hướng $\mathbf{H}$, thay vì chỉ phụ thuộc đặc trưng ảnh như thiết kế gốc.

Về khái niệm, bản đồ chú ý được biểu diễn dưới dạng xác suất có điều kiện: $\alpha = f(\mathbf{x}, \mathbf{g} \mid \mathbf{H})$. Tại mỗi tầng giải mã, trọng số chú ý được định hướng bởi cả đặc trưng ảnh và thông tin không gian người dùng cung cấp; tín hiệu ngoài vùng câu nhắc ưu tiên nhận trọng số thấp hơn, giảm hiện tượng phân đoạn lẫn sang mô lành. Cơ sở lý thuyết này là nền tảng thiết kế kiến trúc PGA-UNet ở Chương 3.

2.4 Các độ đo đánh giá hiệu năng

Trong phân đoạn ảnh y khoa, chỉ dùng một độ đo duy nhất thường không phản ánh đầy đủ chất lượng mô hình – một mô hình có thể chồng lấp diện tích tốt nhưng vẫn sai lệch đáng kể ở đường biên, hoặc ngược lại. Do đó, khóa luận dùng bộ độ đo toàn diện: diện tích vùng (Dice, IoU), xu hướng phân loại (Precision, Recall), chất lượng đường biên (HD95) và độ chuẩn xác vị trí tâm (CBL).

2.4.1 Hệ số Dice và chỉ số IoU

Hệ số Dice (Dice Similarity Coefficient - DSC) và chỉ số Giao trên Hợp (Intersection over Union - IoU, hay Jaccard Index) là hai thang đo tiêu chuẩn phổ biến nhất để đánh giá mức độ chồng lấp không gian giữa mặt nạ dự đoán $\hat{Y}$ và mặt nạ nhãn gốc Y .

Hệ số Dice: gấp đôi diện tích phần giao chia tổng diện tích hai mặt nạ.

$$\text{Dice}(Y, \hat{Y}) = \frac{2|Y \cap \hat{Y}|}{|Y| + |\hat{Y}|} \quad (2.4)$$

Chỉ số IoU: diện tích phần giao chia diện tích phần hợp của hai mặt nạ.

$$\text{IoU}(Y, \hat{Y}) = \frac{|Y \cap \hat{Y}|}{|Y \cup \hat{Y}|} \quad (2.5)$$

Cả hai nhận giá trị $[0, 1]$, với 1 là trùng khớp hoàn hảo. Trong ảnh y khoa, nơi vùng tổn thương thường chiếm tỷ lệ nhỏ so với nền, Dice và IoU được ưu tiên hơn độ chính xác tổng thể vì phản ánh trực tiếp mức độ chồng lấp vùng quan tâm và ít bị ảnh hưởng bởi mất cân bằng nền/đối tượng.

2.4.2 Độ chính xác (Precision) và Độ bao phủ (Recall)

Bên cạnh Dice và IoU, Precision và Recall (Sensitivity) cho góc nhìn chi tiết hơn về xu hướng dự đoán sai (cắt lấn nhầm hay bỏ sót u). Gọi TP là True Positive (dự đoán đúng tổn thương), FP là False Positive (dự đoán nhầm nền thành tổn thương), FN là False Negative (bỏ sót tổn thương thực sự).

Precision: tỷ lệ điểm ảnh tổn thương thực sự trên tổng số điểm ảnh mô hình đã khoanh vùng.

$$\text{Precision} = \frac{TP}{TP + FP} \quad (2.6)$$

Recall: tỷ lệ điểm ảnh tổn thương thực sự được mô hình nhận diện thành công.

$$\text{Recall} = \frac{TP}{TP + FN} \quad (2.7)$$

Trong lâm sàng, cân bằng Precision/Recall rất quan trọng: mô hình phân đoạn quá rộng (bao gồm nhiều mô lành) thường tăng Recall nhưng giảm Precision; ngược lại, phân đoạn quá bảo thủ (bỏ sót tổn thương) tăng Precision nhưng giảm Recall.

2.4.3 Khoảng cách Hausdorff 95% (HD95)

Các thang đo diện tích (Dice, IoU) có điểm yếu: không nhạy với hình dáng đường biên. Một mặt nạ dự đoán có thể chồng lấp diện tích tốt với nhãn nhưng vẫn khác biệt đáng kể về hình dạng, vị trí đường biên. Khoảng cách Hausdorff (Hausdorff Distance - HD) giải quyết vấn đề này bằng cách đánh giá sai lệch lớn nhất giữa hai đường biên.

Cho X, Y là tập điểm ảnh trên đường biên của mặt nạ dự đoán và mặt nạ gốc. Khoảng cách Hausdorff hai chiều cực đại:

$$\text{HD}(X, Y) = \max \left(\sup_{x \in X} \inf_{y \in Y} d(x, y), \sup_{y \in Y} \inf_{x \in X} d(x, y) \right) \quad (2.8)$$

trong đó $d(x, y)$ là khoảng cách Euclidean giữa x và y .

Do dùng hàm cực đại (max, sup), HD cơ bản cực kỳ nhạy với điểm nhiễu ngoại lai trên đường biên. Vì vậy khóa luận dùng **Khoảng cách Hausdorff 95% (HD95)**: sắp xếp khoảng cách biên tăng dần và lấy giá trị tại phân vị thứ 95, giảm ảnh hưởng của điểm ngoại lai. Đơn vị HD95 là pixel trong phạm vi khóa luận; giá trị càng nhỏ, sai lệch biên giữa dự đoán và nhãn tham chiếu càng thấp.

2.4.4 Độ chuẩn xác định vị tâm (CBL)

Dice và HD95 đánh giá chất lượng phân đoạn nhưng không phản ánh độ lệch vị trí giữa tâm dự đoán và tâm tổn thương thực tế – thông tin quan trọng khi câu nhắc bị lệch. Các độ đo định vị phổ biến (DIOU, GIOU) đo lệch tâm giữa hai hộp giới hạn, không phải giữa hai mặt nạ phân đoạn theo điểm ảnh, và không chuẩn hóa theo kích thước tổn thương.

Vì vậy khóa luận định nghĩa **Độ chuẩn xác định vị tâm (Center-Based Localization, CBL)**, đo sai lệch tâm giữa mặt nạ dự đoán và mặt nạ gốc, chuẩn hóa theo kích thước tổn thương:

$$\text{CBL} = \max \left(0, 1 - \frac{\sqrt{(x_p - x_g)^2 + (y_p - y_g)^2}}{D_{gt}} \right) \quad (2.9)$$

trong đó (x_p, y_p) là tâm mặt nạ dự đoán, (x_g, y_g) là tâm nhãn gốc, D_{gt} là đường chéo hộp bao nhỏ nhất quanh nhãn gốc (đơn vị chuẩn hóa). $\text{CBL} = 1.0$ khi tâm dự đoán trùng khớp hoàn toàn; $\text{CBL} \rightarrow 0$ khi sai lệch vượt kích thước đường chéo tổn thương. Chuẩn hóa theo D_{gt} đảm bảo công bằng khi so sánh tổn thương kích thước khác nhau – sai lệch 10 pixel có ý nghĩa rất khác nhau với khối u nhỏ so với khối u lớn.

2.5 Tổng kết chương

Chương 2 cung cấp bức tranh toàn cảnh và cơ sở lý thuyết cho khóa luận. Khảo sát U-Net và SAM-Med2D (hai mô hình đối sánh định lượng) cùng cơ chế Attention Gate của Attention U-Net (nền tảng PGA-UNet kế thừa) làm nổi bật khoảng trống nghiên cứu: cần một kiến trúc CNN hạng nhẹ tích hợp câu nhắc trực quan từ bác sĩ, đạt hiệu năng phân đoạn cao và bền bỉ trước câu nhắc không hoàn hảo.

Lý thuyết về biểu diễn hộp giới hạn thành bản đồ nhiệt và Cổng chú ý có điều kiện là nền tảng cốt lõi được tích hợp trực tiếp vào kiến trúc PGA-UNet ở Chương 3.

CHƯƠNG 3

MÔ HÌNH VÀ HỆ THỐNG ĐỀ XUẤT

3.1 Kiến trúc tổng thể của hệ thống

Hệ thống phân đoạn tương tác đề xuất được thiết kế dưới dạng luồng xử lý đầu cuối **bán tự động**, trong đó bác sĩ luôn giữ vai trò xác nhận trước mỗi lần chuyển giai đoạn: đây là thiết kế *triage mềm*, không phải bộ chặn cứng tự động loại bỏ ảnh mà không cho con người can thiệp. Đầu vào là ảnh X-quang; hộp giới hạn lên vùng nghi ngờ chỉ được bác sĩ vẽ sau khi đã xác nhận ảnh có bệnh lý ở bước sàng lọc. Kiến trúc tổng thể chia thành các module liên hoàn qua hai giai đoạn cốt lõi:

1. Giai đoạn sàng lọc bệnh lý (Gatekeeper): Ảnh X-quang đầu vào đi qua một mạng nơ-ron tích chập đóng vai trò phân loại nhị phân. Hệ thống tính toán xác suất tồn tại của khối u hoặc các tổn thương bất thường và **hiển thị kết quả này cho bác sĩ dưới dạng một gợi ý** (ví dụ: "AI dự đoán: CÓ BỆNH, độ tin cậy 0.87"), chứ không tự động hành động dựa trên gợi ý đó. Bác sĩ xem gợi ý rồi chủ động xác nhận một trong hai lựa chọn:


- **Xác nhận không bệnh:** quy trình kết thúc cho ảnh này.
- **Xác nhận có bệnh lý:** hệ thống chuyển sang giai đoạn phân đoạn, sử dụng hộp giới hạn do bác sĩ vẽ làm câu nhắc hướng dẫn.

Vì quyết định cuối cùng luôn do bác sĩ đưa ra, hệ thống **không bao giờ tự động loại một ca nghi ngờ mà không có xác nhận của con người**: ngay cả khi mô hình gợi ý "không bệnh", bác sĩ vẫn có thể bác bỏ và chủ động yêu cầu chuyển sang bước phân đoạn nếu có nghi ngờ lâm sàng riêng – khác với một bộ chặn cứng tự động, giữ đúng triết lý con người luôn giám

sát trong vòng lặp quyết định, kể cả ở bước sàng lọc. Đánh giá định lượng ở Chương 4 (Mục 4.7.4) mô phỏng kịch bản thận trọng nhất (giả định gợi ý của Gatekeeper được làm theo tuyệt đối, không có xác nhận của bác sĩ) nhằm đo cận dưới của hiệu năng hệ thống trong trường hợp xấu nhất.

2. Giai đoạn phân đoạn có hướng dẫn (PGA-UNet): Ở giai đoạn này, hệ thống hoạt động theo cơ chế học máy tương tác: bác sĩ khoanh một hộp giới hạn quanh vị trí nghi ngờ trên giao diện, tọa độ hộp giới hạn được chuyển đổi ngay thành bản đồ nhiệt câu nhắc. Ảnh X-quang gốc và bản đồ nhiệt câu nhắc được đưa song song vào PGA-UNet (Prompt-Guided Attention U-Net); bằng cách kích hoạt các cổng không gian và cơ chế chú ý có điều kiện, mô hình bị ép hội tụ sự tập trung vào vùng được chỉ định để trích xuất hình dáng chính xác của khối u, tạo ra mặt nạ phân đoạn thô.

Sự phân chia module rõ ràng giúp hệ thống hoạt động linh hoạt, dễ cô lập và xử lý lỗi, đồng thời thuận lợi cho việc nâng cấp, thay thế từng thành phần độc lập sau này. Cơ sở kỹ thuật, thiết kế cấu trúc mạng và công thức toán học của từng module được trình bày ở các mục tiếp theo.



Hình 3.1: Luồng xử lý tổng thể: EfficientNet_B3 sinh gợi ý sàng lọc, bác sĩ xác nhận (không bệnh → kết thúc, có bệnh → vẽ hộp giới hạn) trước khi chuyển sang PGA-UNet phân đoạn có hướng dẫn.

3.2 Bộ dữ liệu ảnh X-quang và đặc điểm nhiễu kỹ thuật

Chất lượng dữ liệu đầu vào ảnh hưởng trực tiếp đến năng lực học của mô hình học sâu. Trong phân đoạn ảnh X-quang y khoa, nhiễu kỹ thuật tuy không liên quan bệnh lý nhưng có độ tương phản rất cao, có thể khiến mạng nơ-ron học nhầm đặc trưng nếu thiếu tín hiệu định hướng phù hợp. Mục này trình bày đặc điểm bộ dữ liệu BTXRD và các vấn đề nhiễu đặc thù.

3.2.1 Bộ dữ liệu BTXRD

Bộ dữ liệu sử dụng là **BTXRD** (*Bone Tumor X-Ray Dataset*), tập ảnh X-quang xương thực tế công bố dưới dạng tài nguyên khoa học mở trên *Nature Scientific Data* [7] – bộ dữ liệu hiếm hoi trong y tế cung cấp đồng thời ba cấp độ nhãn: nhãn phân lớp, nhãn định vị đối tượng, và mặt nạ phân đoạn pixel-level.

Đặc điểm nổi bật của BTXRD:

- Ảnh X-quang xương thực tế thu thập từ cơ sở lâm sàng, tập trung vào cấu trúc tương phản thấp, dễ gây nhầm lẫn (điển hình: X-quang gót chân, cổ chân, chi trên).
- Bao gồm cả ảnh có khối u xương (nhãn 1 - *bệnh lý*) và xương bình thường (nhãn 0 - *lành lặn*), phản ánh đúng phân phối thực tế trong sàng lọc lâm sàng.
- Dữ liệu thô chứa nhiều nhiễu kỹ thuật đặc thù của thiết bị chụp: ký tự chỉ hướng R/L, nhãn metadata, đôi khi có dị vật cản quang. Các loại nhiễu này **không** được xử lý hay loại bỏ trước khi huấn luyện (thảo luận bên dưới).

Bộ dữ liệu phục vụ hai mục đích song song: (1) toàn bộ ảnh (lành lặn

và bệnh lý) huấn luyện **mô hình phân lớp** sàng lọc; (2) chỉ ảnh có bệnh lý kèm mặt nạ phân đoạn huấn luyện **mô hình phân đoạn PGA-UNet**.

3.2.2 Huấn luyện trực tiếp trên ảnh gốc, không qua bước tiền xử lý loại nhiễu

Toàn bộ thực nghiệm **huấn luyện và suy luận trực tiếp trên ảnh gốc**, giữ nguyên ký tự R/L, nhãn metadata và các nhiễu kỹ thuật khác, không qua bước làm sạch hay chuẩn hóa nhiễu nào. PGA-UNet và EfficientNet_B3 phải tự học phân biệt vùng sáng bất thường do nhiễu kỹ thuật với vùng tổn thương thực sự – dựa vào tín hiệu câu nhắc bên ngoài (PSG/CAD) đối với PGA-UNet, và dựa hoàn toàn vào đặc trưng học được đối với Gatekeeper.

Lựa chọn này đơn giản hóa luồng chuẩn bị dữ liệu (không cần gán nhãn, huấn luyện và duy trì thêm một mô hình phát hiện nhiễu riêng), đồng thời loại bỏ khác biệt giữa ảnh huấn luyện và ảnh hiển thị cho bác sĩ: cùng một ảnh gốc (có ký tự R/L) dùng xuyên suốt huấn luyện, suy luận và hiển thị, không còn khái niệm “bản sao đã xóa R/L riêng cho mô hình”. Đổi lại, đây là hạn chế cần lưu ý: nhiễu kỹ thuật còn nguyên trong dữ liệu có thể ảnh hưởng chất lượng đặc trưng học được, đặc biệt ở Gatekeeper vốn không có tín hiệu câu nhắc để neo sự chú ý vào đúng vùng tổn thương (thảo luận thêm tại Mục 5.2, Chương 5).

3.3 Mô hình phân đoạn PGA-UNet (Prompt-Guided Attention U-Net)

Kiến trúc mạng PGA-UNet được xây dựng trên nền tảng kế thừa và cải tiến có chủ đích. Bảng 3.1 tóm tắt ranh giới giữa phần kế thừa từ các công trình trước và phần đề xuất mới.

Chuỗi kế thừa tuyến tính: U-Net [2] (nền bộ mã hóa - bộ giải mã) → Attention U-Net [5] (bổ sung Cổng chú ý không gian mềm vào các kết

Bảng 3.1: Kế thừa và đóng góp trong kiến trúc PGA-UNet

Thành phần	Kế thừa từ	Đóng góp mới
Khung bộ mã hóa - bộ giải mã	U-Net [2]: khối tích chập, gộp cực đại, kết nối tắt	Không có
Cổng chú ý không gian mềm	Attention U-Net [5]: cổng chú ý không gian mềm tại các kết nối tắt (Attention U-Net bổ sung cơ chế này lên nền U-Net)	Mở rộng thành CAD: bổ sung tri thức câu nhắc vào tín hiệu cổng g
Mã hóa câu nhắc	SAM-Med2D [6]: ý tưởng câu nhắc dẫn đường	Thay biểu diễn rời rạc/nhị phân bằng Gaussian Plateau Heatmap 2D
Cổng không gian (PSG)	Lấy cảm hứng từ hướng tiêm bản đồ không gian vào CNN: ghép kênh bản đồ khoảng cách tương tác trong DeepIGeoS [3]; gần đây một số công trình tiêm Gaussian heatmap vào các tầng bộ mã hóa của mô hình nền tảng để thích nghi khi suy luận [4]	Cụ thể hóa thành cơ chế gate nhân (không phải ghép kênh) huấn luyện từ đầu trên CNN nhẹ, tăng cường đặc trưng bộ mã hóa có chọn lọc theo vùng câu nhắc với ràng buộc chỉ khuếch đại không triệt tiêu

nổi tắt) $\rightarrow$ **PGA-UNet** (thêm PSG vào bộ mã hóa, mở rộng Cổng chú ý thành CAD, thay mặt nạ nhị phân bằng Gaussian Plateau Heatmap). Attention U-Net là điểm xuất phát trực tiếp được mở rộng, không phải hai baseline độc lập song song.

Ba thành phần cốt lõi sau đây lần lượt hiện thực hóa đóng góp trên.

3.3.1 Biểu diễn câu nhắc trực quan (Prompt Heatmap Representation)

Nhằm chuyển thao tác không gian của người dùng thành một định dạng số học dẫn đường mềm dẻo, tọa độ hộp giới hạn $\mathbf{B} = (x_1, y_1, x_2, y_2)$ do bác sĩ cung cấp được biểu diễn dưới dạng Bản đồ nhiệt câu nhắc $\mathbf{H}_{prompt} \in [0, 1]^{H \times W}$.

Về lý thuyết, bản đồ nhiệt câu nhắc có thể xây dựng theo phân phối Gaussian 2D thuần túy (Phương trình (2.3)), cường độ đạt cực đại tại tâm và phân rã dần về biên. Trong triển khai thực tế, nhóm dùng phương pháp **Plateau Heatmap**: vùng bên trong hộp giới hạn được gán đồng nhất giá trị 1.0 (vùng cao nguyên phẳng - plateau), sau đó làm mềm đường biên bằng bộ lọc Gaussian (cửa sổ 31×31):

$$\mathbf{H}_{prompt} = \text{GaussianBlur}(\mathbf{B}_{\text{mask}}, k = 31) \quad (3.1)$$

trong đó $\mathbf{B}_{\text{mask}} \in \{0, 1\}^{H \times W}$ là mặt nạ nhị phân của hộp giới hạn (đệm 5 px mỗi phía). Cách này giữ tín hiệu dẫn đường mạnh và đồng đều bên trong vùng câu nhắc (không suy giảm về tâm như Gaussian thuần), đồng thời tạo chuyển tiếp mượt ở viền hộp để mạng không học đạo hàm giả tạo từ đường viền sắc nét. Bản đồ nhiệt $\mathbf{H}_{prompt}$ đóng vai trò một kênh dữ liệu độc lập, song hành cùng ảnh X-quang đi vào mạng.

Lý do chọn $k = 31$: Kích thước cửa sổ lọc cân bằng hai yêu cầu đối lập: đủ lớn để tạo vùng chuyển tiếp mịn ≈ 15 px mỗi bên, phủ vùng biên tổn thương điển hình trên ảnh 512×512 , đồng thời đủ nhỏ để tín hiệu câu nhắc không "tràn" sang cấu trúc xương lân cận. Thực nghiệm với

$k \in \{15, 21, 31, 51\}$ cho thấy $k < 21$ tạo chuyển tiếp quá đột ngột (gần mặt nạ nhị phân), $k > 51$ làm tín hiệu lan quá rộng. $k = 31$ (số lẻ, tâm của sổ đối xứng) cho Dice tốt nhất trên tập xác thực và được giữ cố định trong toàn bộ thực nghiệm.

Cơ sở lý thuyết: Tại sao chọn biểu diễn liên tục có đạo hàm thay vì mặt nạ nhị phân? Câu hỏi là tại sao không dùng mặt nạ nhị phân phẳng (mọi điểm bên trong hộp nhận giá trị 1, bên ngoài 0) thay vì bản đồ nhiệt liên tục. Câu trả lời nằm ở bản chất phép tích chập và cơ chế dung hợp đặc trưng trong U-Net: khi mặt nạ nhị phân đi qua tầng tích chập, đường biên sắc nét tại viền hộp tạo ra đạo hàm giả tạo, khiến mạng có thể học cạnh của hộp bao thay vì đặc trưng thực của tổn thương. Plateau Heatmap cung cấp tín hiệu mạnh, đồng đều bên trong (câu nhắc rõ nét) nhưng chuyển tiếp mượt ở viền qua bộ lọc Gaussian – phù hợp với cổng không gian tại Phương trình (3.2), vốn cần tín hiệu liên tục để nhân theo phần tử trên bản đồ đặc trưng mà không tạo hiệu ứng dao động giả ở đường biên.

Ngoài ra, các nghiên cứu về cơ chế chú ý cho thấy mạng nơ-ron tự nhiên tạo ra vùng kích hoạt phân phối liên tục, cường độ cao nhất tại trung tâm và giảm dần ra biên – Plateau Heatmap bắt chước đặc tính này, tạo tương thích tự nhiên với cơ chế học của mạng.

So sánh với cách mã hóa câu nhắc của SAM và SAM-Med2D. SAM và SAM-Med2D [6] mã hóa hộp giới hạn dưới dạng *vector nhúng vị trí rời rạc*: tọa độ hai góc (trên-trái, dưới-phải) được ánh xạ thành hai vector nhúng 256 chiều qua bảng tra vị trí sinusoidal, phù hợp kiến trúc Transformer của SAM vì Transformer xử lý tập phần tử rời rạc và tích hợp vị trí qua phép cộng vector nhúng. PGA-UNet dùng kiến trúc U-Net với bản đồ đặc trưng 2D liên tục, cùng cấu trúc không gian $H \times W$ với ảnh đầu vào.

Kết hợp một vector nhúng rời rạc (256 chiều, không cấu trúc không

gian) vào bản đồ đặc trưng 2D đòi hỏi phép chiếu phức tạp và dễ mất thông tin vị trí. Bản đồ nhiệt 2D ($H \times W$, cùng không gian với bản đồ đặc trưng) cho phép Cổng không gian nhân theo phần tử trực tiếp tại Phương trình (3.2) – đơn giản, hiệu quả tính toán và bảo toàn thông tin vị trí. Đây là lý do cốt lõi chọn bản đồ nhiệt 2D thay vì vector nhúng rời rạc kiểu SAM: hai kiến trúc khác nhau đòi hỏi hai cách mã hóa câu nhắc phù hợp riêng với cơ chế dung hợp đặc trưng nội tại.

3.3.2 Cổng không gian tại bộ mã hóa (PSG)

Trong kiến trúc U-Net truyền thống, bộ mã hóa chịu trách nhiệm trích xuất đặc trưng ngữ nghĩa; nếu thiếu định hướng, nó có xu hướng học mọi thứ xuất hiện trên ảnh, lãng phí tài nguyên tính toán vào vùng nền không liên quan.

PGA-UNet khắc phục điều này bằng cách tích hợp cấu kiện **Cổng không gian (PSG)** trực tiếp vào nhánh mã hóa – thành phần không tồn tại trong U-Net hay Attention U-Net gốc. Hướng đưa bản đồ không gian vào CNN đã được gợi mở ở một số công trình trước, như ghép kênh bản đồ khoảng cách tương tác người dùng trong DeepIGeoS [3], hoặc gần đây là tiêm Gaussian heatmap vào các tầng mô hình nền tảng để thích nghi khi suy luận [4] – các hướng này chủ yếu dùng ghép kênh hoặc áp dụng lên mô hình nền tảng đã tiền huấn luyện, khác bối cảnh khảo sát gần đây về cơ chế câu nhắc trong ảnh y khoa vốn tập trung tinh chỉnh mô hình nền tảng [8]. PSG cụ thể hóa hướng này thành một **cơ chế gate nhân** (không phải ghép kênh) huấn luyện từ đầu trên CNN nhẹ, đưa tín hiệu câu nhắc vào ngay từ giai đoạn trích xuất đặc trưng, với ràng buộc riêng cho bài toán y khoa (chỉ khuếch đại, không triệt tiêu tín hiệu gốc, xem $\alpha \in [0, 1]$ bên dưới). Tại tầng mã hóa thứ l , bản đồ nhiệt $\mathbf{H}^l$ được giảm mẫu về cùng độ phân giải với đặc trưng $\mathbf{x}^l$, sau đó đưa qua bộ lọc cổng để sinh tín hiệu khuếch đại không gian:

$$\tilde{\mathbf{x}}^l = \mathbf{x}^l \odot (1 + \alpha \cdot \sigma(\mathbf{W}_{gate} * \mathbf{H}^l)) \quad (3.2)$$

trong đó $\mathbf{W}_{gate}$ là phép tích chập 1×1 ánh xạ bản đồ nhiệt (1 kênh) sang không gian kênh đặc trưng C^l ; σ là hàm Sigmoid; $\alpha \in [0, 1]$ là tham số học được (khởi tạo nhỏ tại 0.1 để không làm xáo trộn huấn luyện ban đầu); và $\odot$ là phép nhân theo phần tử.

Thiết kế này hoạt động theo nguyên lý *tăng cường có chọn lọc* (selective enhancement) thay vì ức chế: đặc trưng trong vùng câu nhắc được nhân thêm hệ số > 1 , trong khi đặc trưng ngoài vùng câu nhắc (nơi $\mathbf{H}^l \approx 0$) giữ nguyên giá trị ban đầu (nhân ≈ 1). Nhờ đó, bộ mã hóa không mất thông tin toàn cục nhưng vẫn ưu tiên truyền đặc trưng vùng mục tiêu xuống các tầng sâu hơn.

3.3.3 Cơ chế chú ý có điều kiện tại bộ giải mã (CAD)

Dù Cổng không gian ở bộ mã hóa đã loại bỏ nhiều nền đáng kể, tại bộ giải mã – nơi mạng tăng mẫu để khôi phục ranh giới xương – tín hiệu định vị vẫn có nguy cơ bị phân tán. Để dẫn đường xuyên suốt, khóa luận đề xuất **Cơ chế chú ý có điều kiện (CAD)**, thay thế trực tiếp Cổng chú ý cơ sở của Attention U-Net tại từng tầng giải mã.

Điểm khác biệt cốt lõi so với Cổng chú ý gốc [5]: Cổng chú ý cơ sở tính tín hiệu cổng $\mathbf{g}$ hoàn toàn từ đặc trưng tầng giải mã bên dưới – quyết định “nên chú ý chỗ nào” phụ thuộc hoàn toàn vào những gì mạng tự học từ ảnh, không có thông tin định hướng từ bác sĩ. CAD mở rộng thiết kế này bằng cách bổ sung câu nhắc trực tiếp vào $\mathbf{g}$: cấu kiện `unetUp_PromptAttention` tích hợp tri thức câu nhắc vào tín hiệu cổng qua **cơ chế dung hợp cộng có trọng số tin cậy**. Bản đồ câu nhắc $\mathbf{H}_{prompt}$ được giảm mẫu về kích thước của $\mathbf{g}$ và đưa qua bộ mã hóa hai tầng tích chập (3×3 , InstanceNorm, ReLU) để trích xuất biểu diễn $\mathbf{p}_{enc}$. Một điểm số tin cậy vô hướng $c \in (0, 1)$ được tính bằng cách áp dụng GAP lên $\mathbf{p}_{enc}$:


$$\mathbf{p}_{enc} = f_{enc}(\mathbf{H}_{prompt}), \quad c = \sigma(\text{GAP}(\mathbf{p}_{enc})) \quad (3.3)$$

Tín hiệu cổng được điều kiện hóa bằng phép cộng có trọng số:

$$\mathbf{g}' = \mathbf{g} + c \cdot \alpha \cdot w_l \cdot \mathbf{p}_{\text{enc}} \quad (3.4)$$

trong đó $\alpha = \sigma(\alpha_{\text{raw}})$ là tham số học được (blend weight), và w_l là hệ số tỷ lệ theo tầng giải mã l , được xác định qua thực nghiệm trên tập xác thực (lich trình cụ thể tại Chương 4), điều tiết mức độ ảnh hưởng của câu nhắc tại mỗi tầng.

Tín hiệu $\mathbf{g}'$ sau đó được đưa vào Cổng chú ý (GridAttentionBlock2D) tiêu chuẩn để tính hệ số chú ý α_{cond} điều chỉnh đặc trưng kết nối tắt $\mathbf{x}^l$, kết hợp cùng kết nối dư tắt và tín hiệu dư câu nhắc tại đầu ra ($+\beta \cdot \mathbf{H}_{\text{prompt}}$, β học được). Thiết kế đa lớp này đảm bảo câu nhắc được duy trì xuyên suốt bộ giải mã qua hệ số w_l theo từng tầng, không chỉ ảnh hưởng qua một điểm duy nhất. Các siêu tham số cụ thể của PSG và CAD (lich trình w_l , hệ số kết nối dư) là chi tiết triển khai xác định qua thực nghiệm trên tập xác thực, không phải đóng góp kỹ thuật cốt lõi; giá trị chi tiết tại Mục 4.1.3, Chương 4. Sự kết hợp giữa PSG và CAD là yếu tố chính mang lại cải thiện đáng kể về Dice so với các mạng cơ sở tự động (chi tiết tại Chương 4).



Hình 3.2: Kiến trúc PGA-UNet: PSG tích hợp bản đồ nhiệt câu nhắc vào bộ mã hóa để tăng cường đặc trưng có chọn lọc; CAD ràng buộc tín hiệu cổng bằng câu nhắc tại từng tầng giải mã với hệ số w_l .

3.3.4 Chiến lược huấn luyện và so sánh với mô hình nền tảng SAM-Med2D

Hàm mất mát huấn luyện PGA-UNet kết hợp Dice Loss và Binary Cross-Entropy với trọng số bằng nhau:

$$\mathcal{L}_{\text{seg}} = \mathcal{L}_{\text{Dice}} + \mathcal{L}_{\text{BCE}} \quad (3.5)$$

Dice Loss tối ưu trực tiếp độ tương đồng vùng giữa mặt nạ dự đoán và nhãn gốc; BCE phạt sai lệch tại từng điểm ảnh và ổn định đạo hàm. Hai thành phần bổ sung cho nhau, cân bằng giữa hình dạng tổng thể và độ chính xác đường biên.

Vai trò của câu nhắc đối với hàm mất mát: Câu nhắc trực quan được tích hợp hoàn toàn ở *cấp độ kiến trúc* (qua PSG và CAD), *không* thay đổi cấu trúc hàm mất mát. $\mathcal{L}_{\text{seg}}$ vẫn giữ dạng BCE + Dice trên mặt nạ đầu ra $\hat{y}$ so với nhãn ground-truth $\mathbf{M}$, bất kể câu nhắc đầu vào là heatmap Gaussian, mặt nạ nhị phân hay dạng biểu diễn nào khác. Ảnh hưởng của câu nhắc lên quá trình học được truyền ngầm qua đạo hàm của PSG và CAD trong lan truyền ngược, không cần thêm số hạng phạt hay trọng số vào $\mathcal{L}_{\text{seg}}$.

Để tránh hiểu nhầm khi so sánh kết quả thực nghiệm, cần làm rõ khác biệt căn bản về chiến lược huấn luyện giữa PGA-UNet và SAM-Med2D.

PGA-UNet, Huấn luyện từ đầu hoàn toàn: Toàn bộ kiến trúc PGA-UNet – bộ mã hóa U-Net, các Cổng không gian, khối dung hợp và bộ giải mã có điều kiện – được khởi tạo ngẫu nhiên và học trực tiếp từ BTXRD qua tối đa 100 vòng lặp với dừng sớm (patience = 15). **Không có thành phần nào bị đóng băng**; toàn bộ ~ 3 triệu tham số (kiến trúc thực nghiệm với `feature_scale=4`, bộ lọc [16, 32, 64, 128, 256]) tham gia lan truyền ngược từ vòng lặp đầu tiên. Lý do: bộ mã hóa U-Net là kiến trúc tích chập đơn giản, không có trọng số tiền huấn luyện quy mô lớn tương thích ảnh X-quang xương. Huấn luyện từ đầu trên BTXRD cho phép bộ mã hóa học đặc trưng thấp như kết cấu xương, biên tổn thương

đặc thù của X-quang chi, không bị ràng buộc bởi đặc trưng từ miền dữ liệu khác.

SAM-Med2D, Tinh chỉnh từ mô hình nền tảng: SAM-Med2D [6] kế thừa toàn bộ trọng số tiền huấn luyện của bộ mã hóa ViT-B đã học trên ~ 4.6 triệu ảnh y tế 2D (tập SA-Med2D-20M). Khi tinh chỉnh trên BTXRD, ViT-B bị đóng băng một phần, chỉ cập nhật qua các lớp thích ứng nhẹ; bộ giải mã mặt nạ và bộ mã hóa câu nhắc cập nhật đầy đủ. Nhờ xuất phát từ trọng số đã hội tụ trên dữ liệu y tế quy mô lớn, SAM-Med2D chỉ cần 4 vòng lặp để đạt Val Dice tốt nhất (dừng sớm tại vòng lặp 14), nhanh hơn nhiều PGA-UNet (vòng lặp tốt nhất 79, dừng sớm tại 94). Tuy nhiên, quy mô tham số của SAM-Med2D (~ 91 triệu theo ViT-B gốc [6], cộng lớp thích ứng) lớn hơn PGA-UNet khoảng 30 lần (~ 3 triệu).

Bảng 3.2: So sánh chiến lược huấn luyện giữa PGA-UNet và SAM-Med2D

Thuộc tính	PGA-UNet (đề xuất)	SAM-Med2D (so sánh)
Chiến lược	Huấn luyện từ đầu (từ ngẫu nhiên)	Tinh chỉnh từ ViT-B đã tiền huấn luyện
Bộ mã hóa	U-Net CNN, học toàn bộ từ đầu	ViT-B, đã tiền huấn luyện trên 4.6M ảnh y tế 2D
Thành phần bị đóng băng	Không có	Mạng nền tảng ViT-B (cập nhật qua lớp thích ứng)
Tổng tham số	~ 3 triệu	~ 91 triệu (ViT-B gốc) + lớp thích ứng
Số vòng lặp hội tụ (tốt nhất trên tập xác thực)	79	4

Khác biệt chiến lược này có ý nghĩa quan trọng khi diễn giải kết quả ở Chương 4: PGA-UNet nhỏ hơn ~ 30 lần về tổng tham số và không kế thừa trọng số tiền huấn luyện nào, nên nếu đạt hiệu năng ngang bằng hoặc vượt

SAM-Med2D, kết quả đó nên được diễn giải như hiệu quả của cơ chế tích hợp câu nhắc sâu sát vào kiến trúc nhẹ, không phải ưu thế từ quy mô mô hình hay dữ liệu tiền huấn luyện.

3.4 Module sàng lọc (Gatekeeper)

Mô hình PGA-UNet được huấn luyện hoàn toàn trên tập ảnh **chỉ chứa ca bệnh lý**. Trong môi trường lâm sàng thực tế, luồng đầu vào hỗn hợp cả ảnh bình thường lẫn bệnh lý; nếu đưa trực tiếp ảnh xương bình thường vào PGA-UNet, mô hình sẽ tạo mặt nạ sai lệch (False Positive), gây hiểu nhầm nghiêm trọng cho bác sĩ và lãng phí tài nguyên tính toán.

Giải pháp: Một module phân lớp nhị phân (**Gatekeeper**) đặt trước luồng xử lý phân đoạn, đưa ra gợi ý sàng lọc: ảnh nghi ngờ bình thường hay có bệnh lý. Module này **không tự động loại bỏ ảnh**: kết quả luôn hiển thị cho bác sĩ dưới dạng gợi ý kèm độ tin cậy, bác sĩ là người xác nhận bước tiếp theo (Mục 3.1). Thiết kế *triage mềm* này được chọn thay vì bộ chặn cứng tự động vì hai lý do: (1) giữ đúng triết lý con người luôn giám sát trong vòng lặp quyết định xuyên suốt hệ thống, không riêng bước phân đoạn; (2) tránh rủi ro một ca bệnh thực sự bị loại vĩnh viễn khỏi luồng xử lý chỉ vì một dự đoán âm tính giả mà không có cơ hội con người can thiệp – rủi ro này càng đáng lưu ý khi Gatekeeper đạt Sensitivity dưới 90% (chi tiết tại Mục 4.7.1, Chương 4). Module này **không phải đóng góp kỹ thuật trọng tâm** mà là thành phần hỗ trợ lấp đầy khoảng trống giữa điều kiện huấn luyện và triển khai thực tế. Kiến trúc cụ thể (EfficientNet_B3, tinh chỉnh hai giai đoạn) và kết quả định lượng được trình bày đầy đủ tại Mục 4.7.1 (Chương 4).

Module này được tối ưu bằng hàm mất mát Entropy chéo nhị phân:

$$\mathcal{L}_{\text{cls}} = -\frac{1}{N} \sum_{i=1}^N \left[y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i) \right] \quad (3.6)$$

trong đó $y_i \in \{0, 1\}$ là nhãn thực và $\hat{p}_i \in [0, 1]$ là xác suất dự đoán của ảnh thứ i .

Trong luồng xử lý hệ thống (Mục 3.1), Gatekeeper chạy tự động ngay khi ảnh được tải lên và hiển thị gợi ý sàng lọc; bác sĩ xác nhận "không bệnh" (kết thúc) hoặc "có bệnh" (chuyển sang Giai đoạn 2: PGA-UNet phân đoạn với hộp giới hạn do bác sĩ vẽ làm câu nhắc). Quá trình chuyển giai đoạn luôn cần xác nhận của bác sĩ, kể cả khi bác sĩ không đồng ý với gợi ý của mô hình.

3.5 Tóm tắt giải thuật hệ thống: Huấn luyện và Suy luận

Để làm rõ toàn bộ thiết kế đã trình bày, mục này phát biểu chính thức hai giải thuật cốt lõi: quy trình huấn luyện ngoại tuyến (Algorithm 1) và suy luận trực tuyến (Algorithm 2), phân tách rõ **giai đoạn ngoại tuyến** (sinh bản đồ nhiệt từ mặt nạ nhãn gốc, tối ưu tham số) và **giai đoạn trực tuyến** (nhận đầu vào từ bác sĩ, sinh bản đồ nhiệt từ hộp giới hạn người dùng vẽ, trả mặt nạ phân đoạn).

Xử lý câu nhắc rỗng (bước kiểm tra $B = \emptyset$ của Algorithm 2, chỉ xảy ra sau khi bác sĩ đã xác nhận có bệnh lý): Khi bác sĩ chưa vẽ hộp giới hạn, hệ thống từ chối phân đoạn và yêu cầu cung cấp vùng nghi ngờ. Lý do: bản đồ nhiệt tương ứng sẽ là ma trận không ($\mathbf{H} = \mathbf{0}$), không mang thông tin định hướng; Cổng không gian (Phương trình (3.2)) sẽ không khuếch đại vùng nào, và Cơ chế chú ý có điều kiện (Phương trình (3.4)) sẽ dựa hoàn toàn vào tín hiệu bộ giải mã mà không có ràng buộc không gian, dẫn đến mặt nạ đầu ra thiếu tin cậy. Thiết kế từ chối tường minh này ưu tiên an toàn lâm sàng hơn cố gắng phân đoạn với đầu vào không đủ thông tin.

Algorithm 1 Quy trình huấn luyện ngoại tuyến (Offline Training)

Require: Tập dữ liệu $\mathcal{D} = \{(\mathbf{I}_i, \mathbf{M}_i)\}_{i=1}^N$ (ảnh X-quang và mặt nạ phân đoạn pixel-level)

Ensure: Bộ tham số θ^* của PGA-UNet đã hội tụ

- 1: **Chuẩn hóa kích thước:** Chỉnh lại kích thước toàn bộ ảnh trong $\mathcal{D}$ về 512×512 (không qua bước loại bỏ nhiễu kỹ thuật; huấn luyện trực tiếp trên ảnh gốc, xem Mục 3.2)
 - 2: **for** mỗi vòng lặp $e = 1, 2, \dots, E_{\max}$ **do**
 - 3: **for** mỗi lô nhỏ $(\mathbf{I}_i, \mathbf{M}_i)$ **do**
 - 4: Trích hộp giới hạn $\mathbf{B}_i$ từ $\mathbf{M}_i$ (hộp giới hạn bao sát mặt nạ + đệm 5 px)
 - 5: Chọn kích bản câu nhắc ngẫu nhiên: *Zoom-out* (70%) hoặc *Shift* (30%)
 - 6: Sinh bản đồ nhiệt: $\mathbf{H}_i = \text{GaussianBlur}(\mathbf{B}_{i,\text{mask}}, k=31)$ (Phương trình (3.1))
 - 7: Tính đầu ra dự đoán: $\hat{\mathbf{y}}_i = f_{\text{PGA}}(\mathbf{I}_i, \mathbf{H}_i; \theta)$
 - 8: Tính hàm mất mát: $\mathcal{L} = \mathcal{L}_{\text{BCE}} + \mathcal{L}_{\text{Dice}}$ (Phương trình (3.5))
 - 9: Cập nhật: $\theta \leftarrow \theta - \eta \nabla_{\theta} \mathcal{L}$ (AdamW, giới hạn đạo hàm ≤ 1.0)
 - 10: Tính Dice xác thực trên tập xác thực; cập nhật **ReduceLROnPlateau**
 - 11: **if** Dice xác thực không cải thiện sau 15 vòng lặp liên tiếp **then**
 - 12: **break** (dừng sớm)
 - 13: **return** $\theta^* \leftarrow$ tham số tại vòng lặp có Dice xác thực cao nhất
-

Algorithm 2 Quy trình suy luận trực tuyến (Online Inference)

Require: Ảnh X-quang đầu vào $\mathbf{I}$; hộp giới hạn $\mathbf{B} = (x_1, y_1, x_2, y_2)$ do bác sĩ vẽ **sau khi xác nhận có bệnh lý** (có thể rỗng nếu bác sĩ chưa vẽ)

Ensure: Mặt nạ phân đoạn $\hat{\mathbf{M}}$, hoặc thông báo phù hợp

- 1: **Sàng lọc bệnh lý (gợi ý):** $p \leftarrow f_{\text{cls}}(\mathbf{I}; \boldsymbol{\theta}_{\text{cls}})$ (ảnh gốc, không qua bước loại nhiễu); hiển thị gợi ý “CÓ BỆNH” nếu $p \geq 0.5$, ngược lại “KHÔNG BỆNH”, kèm độ tin cậy
 - 2: **Bác sĩ xác nhận:** $c \leftarrow$ lựa chọn của bác sĩ ($c=1$: có bệnh, $c=0$: không bệnh) $\triangleright c$ độc lập với p : bác sĩ có thể bác bỏ gợi ý của mô hình
 - 3: **if** $c = 0$ **then**
 - 4: **return** “Bác sĩ xác nhận không có bệnh lý: kết thúc quy trình”
 - 5: **if** $\mathbf{B} = \emptyset$ (bác sĩ đã xác nhận có bệnh nhưng chưa vẽ câu nhắc) **then**
 - 6: **return** “Vui lòng khoanh hộp giới hạn lên vùng nghi ngờ” $\triangleright$
Heatmap zero không xác định hành vi phân đoạn
 - 7: Sinh bản đồ nhiệt: $\mathbf{H} \leftarrow \text{GaussianBlur}(\mathbf{B}_{\text{mask}}, k=31)$
 - 8: Tính xác suất phân đoạn: $\hat{\mathbf{y}} \leftarrow f_{\text{PGA}}(\mathbf{I}, \mathbf{H}; \boldsymbol{\theta}^*)$
 - 9: Tạo mặt nạ nhị phân: $\hat{\mathbf{M}} \leftarrow \mathbf{1}[\hat{\mathbf{y}} \geq 0.5]$
 - 10: **return** $\hat{\mathbf{M}}$ (hiển thị chồng lên ảnh gốc $\mathbf{I}$, cùng một ảnh dùng xuyên suốt phân lớp, phân đoạn và hiển thị)
-

3.6 Tổng kết chương

Chương này trình bày kiến trúc và quy trình vận hành của hệ thống đề xuất: đặc điểm bộ dữ liệu BTXRD (huấn luyện trực tiếp trên ảnh gốc, không qua tiền xử lý loại nhiễu), ba thành phần cốt lõi của PGA-UNet (Plateau Heatmap, PSG, CAD), module sàng lọc, và hai giải thuật hình thức hóa luồng huấn luyện ngoại tuyến lẫn suy luận trực tuyến. Bảng 3.1 phân định ranh giới giữa phần kế thừa (khung U-Net, Attention Gate) và phần đóng góp mới (PSG, CAD, biểu diễn heatmap liên tục) – cơ sở kỹ thuật để Chương 4 đo lường định lượng hiệu quả từng đóng góp qua thực nghiệm baseline, ablation study và phân tích so sánh chi tiết.

CHƯƠNG 4

THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ

Chương này tổ chức kết quả thực nghiệm thành hai phần. **Phần I** tập trung đánh giá kiến trúc PGA-UNet trên tập kiểm thử 187 ảnh (cấp độ ảnh): so sánh với các mô hình cơ sở và SAM-Med2D (đánh giá cấp độ ảnh, N=187 ảnh), ablation study (PSG/CAD), đánh giá tính bền bỉ (Robustness) và kiểm định xác thực chéo. **Phần II** trình bày đánh giá module Gatekeeper hỗ trợ (EfficientNet_B3) và luồng xử lý đầu cuối trên dữ liệu hỗn hợp thực tế.

4.1 Thiết lập môi trường thực nghiệm

Để đảm bảo tính khách quan và khả năng tái lập (reproducibility) của các kết quả nghiên cứu, mục này trình bày chi tiết về quy mô dữ liệu, phương pháp phân chia các tập đánh giá, cấu hình phần cứng cũng như các siêu tham số (hyperparameters) được thiết lập trong suốt quá trình huấn luyện mô hình.

4.1.1 Tập dữ liệu ảnh X-quang

Dữ liệu thực nghiệm được sử dụng trong khóa luận là bộ **BTXRD** (*Bone Tumor X-Ray Dataset*) [7], một tập ảnh X-quang xương công khai có đầy đủ ba cấp nhãn: phân lớp, định vị và phân đoạn pixel-level.

Lý do chọn BTXRD: Không giống các bộ dữ liệu X-quang công khai chỉ cung cấp nhãn phân lớp mà thiếu mặt nạ phân đoạn, BTXRD cung cấp đồng thời cả ba cấp nhãn (phân lớp, định vị, phân đoạn pixel-level), đáp ứng đầy đủ yêu cầu huấn luyện có giám sát. Ảnh X-quang thô chứa nhiều nhiễu kỹ thuật (ký tự R/L, metadata) nhưng **không** qua bước tiền

xử lý loại nhiễu nào; toàn bộ thực nghiệm huấn luyện trực tiếp trên ảnh gốc như mô tả ở Mục 3.2.

Hai phân vùng dữ liệu song song: Kiến trúc hệ thống sử dụng hai tập dữ liệu với mục đích khác nhau:

- **Dữ liệu phân đoạn** (cho PGA-UNet và baseline): Chỉ chứa các ảnh *có bệnh lý* kèm mặt nạ phân đoạn pixel-level. Đây là giới hạn tự nhiên của học có giám sát, chỉ ảnh có nhãn mới dùng được.
- **Dữ liệu phân lớp** (cho Gatekeeper): Chứa cả ảnh bệnh lý lẫn ảnh bình thường, phân chia theo tỷ lệ 80/10/10 (train/val/test), kích thước lô = 16.

Thông kê dữ liệu: Bảng 4.1 tóm tắt phân bố dữ liệu sau khi phân chia.

Bảng 4.1: Thông kê phân bố dữ liệu thực nghiệm

Tập dữ liệu	Số ảnh	Số mẫu (per-polygon)	Ghi chú
Huấn luyện (Train)	1 493	1848	Tất cả ca bệnh lý
Xác thực (Validation)	187	238	
Kiểm thử (Test)	187	232	Nhiều ảnh có ≥ 2 polygon $\rightarrow$ 232 mẫu per-polygon

Thông kê bộ dữ liệu phân lớp (Gatekeeper): Bộ BTXRD gồm 3.746 ảnh X-quang (cả lành lẫn bệnh lý) được dùng toàn bộ để huấn luyện Gatekeeper, phân chia train/val/test theo tỷ lệ 80/10/10 ($\approx 2.996/375/375$ ảnh). Tập phân lớp và tập phân đoạn dùng chung ảnh bệnh lý nhưng độc lập về nhãn: nhãn nhị phân (lành/bệnh) cho Gatekeeper, nhãn mặt nạ pixel-level cho PGA-UNet.

4.1.2 Mô hình so sánh trong thực nghiệm

Trước khi trình bày kết quả, mục này liệt kê tóm tắt các mô hình được đối sánh xuyên suốt chương, giúp người đọc định vị vai trò của từng mô hình khi bước vào các bảng số liệu ở các mục sau:

- **U-Net (baseline không câu nhắc):** Kiến trúc bộ mã hóa - bộ giải mã cổ điển [2], huấn luyện từ đầu trên BTXRD, *không* nhận bất kỳ câu nhắc không gian nào từ bác sĩ. Đóng vai trò cận dưới tham chiếu, thể hiện hiệu năng khi hoàn toàn không có thông tin định hướng.
- **SAM-Med2D (SOTA dựa trên câu nhắc, mô hình nền tảng):** Mô hình nền tảng phân đoạn y tế [6] tiền huấn luyện trên 4,6 triệu ảnh y tế 2D, nhận hộp giới hạn làm câu nhắc qua bộ mã hóa câu nhắc riêng. Được đánh giá ở hai chế độ: *chưa tinh chỉnh* (dùng thẳng điểm lưu trọng số tiền huấn luyện, không tinh chỉnh trên BTXRD/FracAtlas) và *đã tinh chỉnh* (tinh chỉnh lớp thích ứng + bộ giải mã trên từng bộ dữ liệu). Đây là đối trọng SOTA để định vị PGA-UNet trong nhóm mô hình phân đoạn tương tác dựa trên câu nhắc.
- **PGA-UNet (đề xuất):** Kiến trúc trọng tâm của khóa luận (Chương 3), tích hợp câu nhắc Gaussian heatmap vào cả bộ mã hóa (PSG) lẫn bộ giải mã (CAD), huấn luyện từ đầu trên từng bộ dữ liệu, ~ 3 triệu tham số.

Sự khác biệt căn bản về chiến lược huấn luyện giữa PGA-UNet (huấn luyện từ đầu hoàn toàn) và SAM-Med2D (tinh chỉnh từ trọng số tiền huấn luyện quy mô lớn) đã được trình bày chi tiết tại Mục 3.3.4, Chương 3 (Bảng 3.2); so sánh về chi phí tính toán (số tham số, VRAM) giữa hai mô hình được trình bày riêng tại Mục 4.2.5. Định nghĩa hình thức của các độ đo dùng để so sánh (Dice, IoU, Precision, Recall, HD95, CBL) đã được trình bày tại Chương 2; mục kế tiếp (4.1.4) chỉ tập trung vào phương pháp *tổng hợp* các độ đo này ở cấp độ ảnh.

4.1.3 Cấu hình huấn luyện

Toàn bộ quá trình huấn luyện và suy luận thực nghiệm được triển khai trên môi trường Kaggle/Colab với GPU T4 nhằm tăng tốc độ tính toán. Các mô hình được cài đặt dựa trên thư viện PyTorch.

Hàm mất mát (Loss Function): Để xử lý mất cân bằng giữa foreground (vùng tổn thương) và background, hệ thống sử dụng hàm mất mát kết hợp:

$$\mathcal{L}_{total} = \mathcal{L}_{BCE} + \mathcal{L}_{Dice} \quad (4.1)$$

Thành phần $\mathcal{L}_{BCE}$ tối ưu phân loại từng pixel; $\mathcal{L}_{Dice}$ tối ưu độ chồng lấp diện tích tổng thể.

Siêu tham số huấn luyện: Tất cả mô hình (U-Net, PGA-UNet) được huấn luyện dưới cùng thiết lập:

- **Kích thước lô:** 4 (phù hợp giới hạn VRAM khi dùng ảnh 512×512).
- **Số vòng lặp tối đa:** 100, kết hợp dừng sớm (patience=15).
- **Bộ tối ưu:** AdamW với suy giảm trọng số 10^{-4} .
- **Tốc độ học:** Khởi điểm 10^{-4} , bộ lập lịch ReduceLROnPlateau (giảm $0.5 \times$ sau 5 vòng lặp không cải thiện Dice xác thực).

Siêu tham số kiến trúc PGA-UNet (chi tiết triển khai): Các giá trị dưới đây là tham số cấu hình được xác định qua thực nghiệm trên tập xác thực; chúng là chi tiết triển khai, không phải đóng góp kỹ thuật cần kiểm chứng độc lập.

- **Hệ số w_l theo tầng giải mã (CAD):** $\{1.0, 0.7, 0.4, 0.2\}$ từ tầng 1 đến 4; lịch trình giảm dần này là lựa chọn thử nghiệm thực nghiệm, chưa có kiểm chứng ablation riêng về lịch trình tối ưu.
- **Hệ số kết nối dư λ** $= 0.3$ trong khối CAD.
- **Cửa sổ lọc Gaussian Heatmap:** $k = 31$, đệm 5 px mỗi cạnh hộp giới hạn.

- **Khởi tạo α_{gate} :** 0.1 (PSG), giúp ổn định huấn luyện giai đoạn đầu.

4.1.4 Phương pháp đánh giá cấp độ ảnh (image-level)

Đặc điểm annotation của tập BTXRD. Trong tập kiểm thử, nhiều ảnh X-quang chứa *nhiều hơn một vùng tổn thương*: bác sĩ vẽ từng polygon riêng biệt cho mỗi tổn thương, dẫn đến tổng số 232 mẫu polygon trên 187 ảnh (trung bình ~ 1.24 polygon/ảnh). Nếu tính Dice riêng cho từng polygon, một ảnh có hai tổn thương sẽ đóng góp hai mẫu vào tập đánh giá, làm méo phân phối kết quả và tính nhiều lần trên cùng một bệnh nhân.

Cách tính cấp độ ảnh (image-level). Để khắc phục vấn đề trên và phản ánh trung thực hơn hiệu năng lâm sàng (một điểm số trên mỗi ảnh bệnh nhân), khóa luận áp dụng phương pháp đánh giá cấp độ ảnh sau cho PGA-UNet:

1. **Hợp nhất ground-truth (Union GT):** Với mỗi ảnh chứa $K \geq 1$ polygon, tất cả mask nhị phân GT $\{G_1, G_2, \dots, G_K\}$ được *hợp nhất* thành một mask GT duy nhất theo phép hợp tập:

$$M_{GT} = G_1 \cup G_2 \cup \dots \cup G_K \quad (4.2)$$

2. **Kết hợp dự đoán (Max-Merge Prediction):** Mô hình được chạy suy luận riêng cho từng bbox $\mathbf{B}_k$ tương ứng, sinh ra K mask xác suất $\{\hat{P}_1, \hat{P}_2, \dots, \hat{P}_K\}$ (giá trị $[0, 1]$ mỗi pixel). Các mask xác suất được kết hợp bằng phép lấy *giá trị lớn nhất theo pixel* (pixel-wise maximum):

$$\hat{M}_{\max}(x, y) = \max_{k=1}^K \hat{P}_k(x, y) \quad (4.3)$$

Sau đó ngưỡng hóa tại 0.5 để thu mặt nạ nhị phân cuối cùng $\hat{M}_{\text{pred}} = \mathbf{1}[\hat{M}_{\max} \geq 0.5]$.

3. **Tính Dice cấp độ ảnh:** Chỉ số Dice được tính một lần duy nhất

giữa $\hat{M}_{\text{pred}}$ và M_{GT} :

$$\text{Dice}_{\text{img}} = \frac{2 |M_{\text{GT}} \cap \hat{M}_{\text{pred}}|}{|M_{\text{GT}}| + |\hat{M}_{\text{pred}}|} \quad (4.4)$$

Metric cuối cùng được tính trung bình trên toàn bộ 187 ảnh kiểm thử. Phương pháp này đảm bảo mỗi ảnh bệnh nhân chỉ đóng góp **một điểm số**, tránh hiện tượng ảnh có nhiều tổn thương bị đếm nhiều lần và phản ánh trung thực hơn trải nghiệm đánh giá lâm sàng thực tế.

4.2 Đánh giá hiệu năng kiến trúc PGA-UNet

Để đo lường khách quan năng lực của kiến trúc PGA-UNet, quá trình thực nghiệm được tiến hành qua ba bước: (1) so sánh với mô hình cơ sở không có câu nhắc (U-Net); (2) đánh giá tính bền bỉ trước sai số câu nhắc; (3) so sánh với SAM-Med2D (SOTA dựa trên câu nhắc). PGA-UNet và SAM-Med2D được đánh giá ở cấp độ ảnh ($N=187$ ảnh).

4.2.1 Đánh giá cơ sở: U-Net so với PGA-UNet

Trong kịch bản đánh giá đầu tiên, PGA-UNet (kịch bản câu nhắc Zoom-out lý tưởng) được so sánh với U-Net hoạt động hoàn toàn tự động (phân đoạn không có câu nhắc).

Điều kiện so sánh: PGA-UNet kế thừa khung bộ mã hóa - bộ giải mã của U-Net và Cổng chú ý từ Attention U-Net [5], mở rộng thành PSG+CAD có điều kiện hóa bởi câu nhắc (chi tiết tại Chương 3). U-Net thuần túy (không chú ý, không câu nhắc) được chọn làm baseline để đo đóng góp tổng thể của toàn bộ chuỗi cải tiến: U-Net tự động hoàn toàn (chỉ nhận ảnh thô) đối lập với PGA-UNet tương tác (nhận thêm hộp giới hạn làm câu nhắc). Đây là so sánh có chủ đích, minh chứng lợi ích của hướng tiếp cận dựa trên câu nhắc so với phân đoạn tự động trên ảnh X-quang xương.

Bảng 4.2: U-Net (tự động) so PGA-UNet (Zoom-out, câu nhắc), N=187 ảnh, cấp độ ảnh

Mô hình	Dice↑	IoU↑	Precision↑	Recall↑	HD95↓	CBL↑
U-Net	0.4740	0.3741	0.5847	0.5341	144.37	0.5709
PGA-UNet (Zoom-out)	0.8607	0.7630	0.8476	0.8882	12.12	0.9564

Phân tích kết quả so sánh baseline:

- **Giới hạn của phân đoạn tự động:** U-Net gốc đạt Dice = 0.4740, phản ánh giới hạn cốt lõi khi phải tự tìm vùng tổn thương trên ảnh X-quang thô mà không có bất kỳ thông tin định hướng nào. Kết quả này là minh chứng cho thách thức của phân đoạn hoàn toàn tự động trên ảnh X-quang xương có độ tương phản thấp và cấu trúc giải phẫu chồng lấp.
- **Giá trị của hướng tiếp cận tương tác:** PGA-UNet (Zoom-out) đạt Dice = 0.8607, vượt U-Net tự động +0.3867: cơ chế PSG và CAD chỉ phát huy hiệu quả khi được “neo” bởi tín hiệu định hướng rõ ràng từ bên ngoài, giải quyết đúng hạn chế cốt lõi của phân đoạn tự động. Đáng lưu ý, cả hai mô hình đều chạy trên ảnh đã resize về 512×512 (từ ảnh gốc 2.000–3.000 px, còn $\frac{1}{4}$ – $\frac{1}{6}$ diện tích gốc); tín hiệu câu nhắc vẫn đủ để PGA-UNet phục hồi hiệu năng dù thông tin không gian đầu vào bị thu nhỏ đáng kể.

4.2.2 Đánh giá tính bền bỉ trước sai lệch câu nhắc: Kịch bản Zoom-out, Shift và Mixed

Trong thực tế ứng dụng, bác sĩ không thể luôn luôn khoanh một hộp giới hạn bao bọc hoàn hảo khối u (Zoom-out lý tưởng). Sẽ có những lúc mỗi mắt hoặc do góc nhìn chủ quan khiến khung khoanh bị lệch đi một phần so với vị trí trung tâm thực sự. Để kiểm chứng xem PGA-UNet có bị phụ thuộc quá mức vào vị trí tâm câu nhắc hay không, hệ thống được thử nghiệm trên 3 kịch bản:

1. **100% Zoom-out:** Câu nhắc lý tưởng, bao trọn vẹn tổn thương, cận trên hiệu năng của mô hình.
2. **100% Shift (Lệch tâm):** Câu nhắc bị cố tình dịch chuyển lệch khỏi tâm tổn thương một lượng ngẫu nhiên, kịch bản xấu nhất được định nghĩa trong phạm vi khóa luận, mô phỏng bác sĩ mất tập trung.
3. **Mixed (70% Zoom-out + 30% Shift):** Pha trộn theo tỷ lệ giả định minh họa (chưa có cơ sở thực nghiệm lâm sàng, xem hạn chế tại Mục 5.2, Chương 5), phần lớn câu nhắc đúng, một phần nhỏ bị lệch.

Lý do chọn 3 kịch bản này và không dùng nhiều mạnh hơn: Ba mức độ bao phủ một phần phổ sai số câu nhắc có thể xảy ra, từ hoàn hảo đến lệch tâm có kiểm soát – đây là các kịch bản **mô phỏng**, chưa phải khảo sát trực tiếp cách bác sĩ thật vẽ hộp. Kịch bản Shift đảm bảo ít nhất 30% diện tích hộp giới hạn giao với vùng tổn thương thực ($\text{overlap} \geq 30\%$), dựa trên giả định bác sĩ luôn có thông tin sơ bộ về vùng nghi ngờ nên sai số thường lệch tâm chứ không sai hoàn toàn vị trí; giả định này chưa được kiểm chứng bằng dữ liệu bbox thật. Đây là mức nhiễu cực đoan nhất **trong phạm vi các kịch bản đã định nghĩa** (chưa gồm bbox quá nhỏ/quá lớn, sai hoàn toàn, hay từ nhiều người vẽ khác nhau, xem Mục 5.2, Chương 5); PGA-UNet vẫn duy trì Dice = 0.8423, đủ để kết luận về tính **bền vững trước sai lệch bbox có kiểm soát** trong ba kịch bản đã kiểm định.

Trường hợp câu nhắc sai hoàn toàn vị trí: Nếu bác sĩ khoanh hộp hoàn toàn không liên quan đến tổn thương thực, PGA-UNet (như mọi hệ thống phân đoạn tương tác) sẽ phân đoạn đúng tại vùng được chỉ định thay vì tự tìm vùng tổn thương thực – đây là hành vi đúng về thiết kế: mô hình thực hiện đúng chỉ dẫn, còn nếu tự sửa hướng dẫn sai thì cơ chế tương tác mất ý nghĩa và bác sĩ trở thành thừa. Trách nhiệm định hướng thuộc về bác sĩ, mô hình đảm nhiệm phân đoạn chính xác trong vùng được

chỉ định; vì vậy kích bản bbox sai hoàn toàn không được đưa vào đánh giá định lượng.

Bảng 4.3: Tính bền bỉ của PGA-UNet trên ba kích bản câu nhắc (N=187 ảnh, cấp độ ảnh)

Kịch bản câu nhắc	Dice $\uparrow$	IoU $\uparrow$	Precision $\uparrow$	Recall $\uparrow$	HD95 $\downarrow$	CBL $\uparrow$
Zoom-out (100%, lý tưởng)	0.8607	0.7630	0.8476	0.8882	12.12	0.9564
Shift (100%, lệch tâm)	0.8423	0.7381	0.8405	0.8621	14.14	0.9433
Mixed (70% Zoom-out + 30% Shift)	0.8560	0.7567	0.8477	0.8803	12.62	0.9537

Phân tích tính bền bỉ: Số liệu (Bảng 4.3) khẳng định đặc tính "hướng dẫn mềm" của PGA-UNet: ở kích bản lệch tâm hoàn toàn (100% Shift), Dice chỉ giảm từ 0.8607 (Zoom-out) xuống 0.8423, chênh lệch 0.0184 không đáng kể; Mixed đạt 0.8560, xác nhận mô hình ổn định **trong phạm vi ba kích bản mô phỏng đã kiểm định**, chưa bao hàm các dạng sai lệch khác trong thực tế lâm sàng (Mục 5.2, Chương 5).

Điều này cho thấy mô hình **không** ghi nhớ cứng nhắc vị trí tâm bản đồ nhiệt: PGA-UNet dùng câu nhắc để thu hẹp vùng tìm kiếm, nhưng ở các lớp giải mã cuối vẫn dựa vào đặc trưng đạo hàm thực tế của ảnh (bờ xương, đường viền u) để xác định ranh giới – yếu tố quan trọng cho khả năng triển khai lâm sàng, dù cần thêm đánh giá với câu nhắc do bác sĩ thật vẽ để khẳng định chắc chắn.

4.2.3 So sánh với mô hình nền tảng SAM-Med2D

Để đánh giá đầy đủ hơn, mô hình PGA-UNet được so sánh trực tiếp với SAM-Med2D [6], mô hình SOTA dựa trên câu nhắc dựa trên kiến trúc ViT-B ($\sim 91\text{M}$ tham số [6], đã tinh chỉnh từ 4.6M ảnh y tế 2D). SAM-Med2D bắt buộc sử dụng độ phân giải 256×256 do vector nhúng vị trí của ViT-B được cố định theo kích thước này bởi tác giả gốc, không thể chạy ở độ phân giải lớn hơn nếu không huấn luyện lại từ đầu. Để đảm bảo so sánh công bằng, hoàn toàn kiểm soát được biến độ phân giải, PGA-UNet được huấn luyện lại từ đầu ở cùng 256×256 (điểm lưu trọng số riêng, khác

với điểm lưu trọng số 512×512 dùng ở Bảng 4.2 và 4.3). Cả ba mô hình (PGA-UNet, SAM-Med2D đã tinh chỉnh, SAM-Med2D chưa tinh chỉnh) được đánh giá ở cấp độ ảnh (N=187 ảnh), cùng 3 kịch bản câu nhắc, cùng độ phân giải 256×256 .

Bảng 4.4: PGA-UNet so SAM-Med2D (đã/chưa tinh chỉnh), ba kịch bản câu nhắc, cùng 256×256 , cấp độ ảnh (N=187 ảnh).

Mô hình	Kịch bản	Dice $\uparrow$	IoU $\uparrow$	Pre $\uparrow$	Rec $\uparrow$	HD95 $\downarrow$ (px)	CBL $\uparrow$
PGA-UNet (256)	Zoom-out	0.8433	0.7381	0.8112	0.8937	6.34	0.9488
PGA-UNet (256)	Shift	0.8150	0.6982	0.7929	0.8574	7.59	0.9267
PGA-UNet (256)	Mixed	0.8344	0.7255	0.8061	0.8809	6.73	0.9419
SAM-Med2D (FT)	Zoom-out	0.7541	0.6385	0.7504	0.7932	11.33	0.8949
SAM-Med2D (FT)	Shift	0.6912	0.5645	0.6987	0.7192	12.64	0.8564
SAM-Med2D (FT)	Mixed	0.7334	0.6150	0.7338	0.7687	11.79	0.8819
SAM-Med2D (ZS)	Zoom-out	0.5418	0.4002	0.4852	0.6808	17.50	0.8409
SAM-Med2D (ZS)	Shift	0.5266	0.3853	0.4755	0.6591	21.12	0.8014
SAM-Med2D (ZS)	Mixed	0.5432	0.4002	0.4859	0.6796	17.96	0.8318

Phân tích kết quả so sánh PGA vs SAM-Med2D:


- **PGA vượt trội nhất quán ngay cả khi kiểm soát độ phân giải:** Ở cùng 256×256 , PGA-UNet đạt Dice = 0.8433 (Zoom-out), vượt SAM-Med2D đã tinh chỉnh (0.7541, +0.0892) và chưa tinh chỉnh (0.5418, +0.3015) trên cả ba kịch bản – vì cùng độ phân giải, ưu thế này đến từ bản thân kiến trúc PSG+CAD. Chênh lệch lớn giữa SAM đã và chưa tinh chỉnh cho thấy tinh chỉnh trên dữ liệu miền đặc thù là cần thiết; PGA vượt qua cả SAM đã tinh chỉnh dù chỉ $\sim 3M$ tham số huấn luyện **hoàn toàn từ đầu**, trong khi SAM-Med2D kế thừa trọng số ViT-B học từ 4.6M ảnh y tế 2D (Bảng 3.2, Chương 3).
- **PGA bám biên sát hơn SAM ở cùng độ phân giải:** HD95 của PGA-UNet (6.34–7.59 px) thấp hơn rõ rệt so với SAM-Med2D đã tinh chỉnh (11.33–12.64 px) ở cả ba kịch bản, đo trên cùng lưới ảnh 256×256 nên hoàn toàn so sánh trực tiếp được.

- **Tham số hiệu quả:** PGA ($\sim 3M$, toàn bộ có thể huấn luyện) vượt SAM-Med2D ($\sim 91M$ tổng, chỉ $\sim 15M$ có thể huấn luyện gồm lớp thích ứng + bộ giải mã), cho thấy kiến trúc nhẹ được thiết kế đặc thù cho bài toán có thể hiệu quả hơn mô hình nền tảng đa mục đích trên miền dữ liệu hẹp này.
- **SAM hội tụ rất nhanh:** SAM-Med2D hội tụ sớm nhờ lợi thế đã tiền huấn luyện từ 4.6M ảnh y tế 2D, nhưng kiến trúc ViT-B với độ phân giải 256 là giới hạn vốn có trên ảnh X-quang chi tiết.
- **Về tính bền bỉ, PGA vượt trội SAM ngay cả ở cùng độ phân giải:** Mức sụt Dice Zoom-out $\rightarrow$ Shift của PGA ở 256×256 là -0.0283 (-3.4%), **nhỏ hơn rõ rệt** SAM-Med2D đã tinh chỉnh (-0.0629 , -8.3% , gần gấp 2,2 lần PGA) – khác với lần huấn luyện trước, PGA nay bền bỉ hơn SAM **ngay cả khi kiểm soát cùng độ phân giải**, không chỉ nhờ độ phân giải cao hơn. Ở 512×512 (Bảng 4.3), mức sụt này giảm tiếp còn -0.0184 (-2.1%): độ phân giải cao hơn khuếch đại thêm lợi thế bền bỉ sẵn có của kiến trúc, không phải nguồn gốc duy nhất của lợi thế đó.

4.2.4 PGA-UNet ở hai độ phân giải: 256×256 so với 512×512 (BTXRD)

Mục 4.2.3 vừa chứng minh PGA-UNet vượt SAM-Med2D ngay cả khi bị đặt vào thế bất lợi, cùng chạy ở 256×256 . Mục này bổ sung mảnh ghép còn lại: so sánh trực tiếp PGA-UNet ở hai độ phân giải 256×256 (điểm lưu trọng số dùng ở Bảng 4.4) và 512×512 (điểm lưu trọng số dùng ở Bảng 4.2 và 4.3), để trả lời câu hỏi: khi được phép chạy ở độ phân giải gốc mà kiến trúc CNN cho phép (không bị giới hạn cứng như ViT-B của SAM-Med2D), PGA-UNet cải thiện thêm bao nhiêu?

¶*Lưu ý HD95 khác đơn vị độ phân giải:* Giá trị HD95 thô (px) của PGA-256 và PGA-512 **không thể so sánh trực tiếp** vì đo trên hai không gian



Hình 4.1: Dice Score: U-Net (512×512), PGA-UNet (256×256), SAM-Med2D (đã/chưa tinh chỉnh, 256×256), ba kịch bản câu nhắc (Bảng 4.2, 4.4).


Bảng 4.5: PGA-UNet tại 256×256 và 512×512 trên BTXRD, ba kịch bản câu nhắc (N=187 ảnh, cấp độ ảnh)

Độ phân giải	Kịch bản	Dice↑	IoU↑	Pre↑	Rec↑	HD95↓ (px)	CBL↑
PGA-UNet (256)	Zoom-out	0.8433	0.7381	0.8112	0.8937	6.34 [¶]	0.9488
PGA-UNet (256)	Shift	0.8150	0.6982	0.7929	0.8574	7.59 [¶]	0.9267
PGA-UNet (256)	Mixed	0.8344	0.7255	0.8061	0.8809	6.73 [¶]	0.9419
PGA-UNet (512)	Zoom-out	0.8607	0.7630	0.8476	0.8882	12.12 [¶]	0.9564
PGA-UNet (512)	Shift	0.8423	0.7381	0.8405	0.8621	14.14 [¶]	0.9433
PGA-UNet (512)	Mixed	0.8560	0.7567	0.8477	0.8803	12.62 [¶]	0.9537

ảnh khác kích thước (1 px lỗi tại 256 tương đương ~ 2 px tại 512); do đó cột này không in đậm ở hàng nào, không phải PGA-512 kém bám biên hơn, chỉ là khác đơn vị đo.

Nhận xét: Tăng độ phân giải từ 256 lên 512 cải thiện rõ rệt và nhất quán ở Dice, IoU, Precision và CBL (Dice Zoom-out: $0.8433 \rightarrow 0.8607$, $+0.0174$; Precision: $0.8112 \rightarrow 0.8476$, $+0.0364$). Riêng Recall giảm nhẹ ở Zoom-out (-0.0055) và gần như không đổi ở Mixed (-0.0006), chỉ tăng nhẹ ở Shift ($+0.0047$) – một đánh đổi Precision–Recall hợp lý: ở độ phân giải cao hơn, mô hình thấy chi tiết đường biên rõ hơn nên dự đoán chọn lọc hơn, kéo Precision lên nhưng đôi khi bỏ sót phần biên mà bản đồ nhiệt ở 256 vẫn phủ được. Xét tổng thể qua Dice, 512×512 vẫn là cấu hình tốt hơn ở cả ba kịch bản.

Kết hợp với Mục 4.2.3 (PGA-256 đã vượt SAM-256 ở mọi kịch bản), khi PGA-UNet được chạy ở độ phân giải gốc 512×512 (không bị giới hạn cứng như ViT-B của SAM-Med2D, cố định ở 256×256), khoảng cách với SAM-Med2D thực tế **còn lớn hơn** mức đã chứng minh ở Bảng 4.4 – suy luận bắc cầu ($\text{PGA-512} > \text{PGA-256} > \text{SAM-256}$), tránh phải dựng một bảng trộn lẫn hai độ phân giải dễ gây hiểu lầm khi so HD95 thô.



Hình 4.2: PGA-UNet trên BTXRD: 256×256 và 512×512 , ba kịch bản câu nhắc (Bảng 4.5).

4.2.5 So sánh hiệu quả tính toán

Ngoài hiệu năng phân đoạn, tính khả thi triển khai trong môi trường lâm sàng đòi hỏi mô hình phải đủ nhẹ để chạy trên phần cứng y tế tuyến cơ sở. Bảng 4.6 so sánh toàn diện giữa PGA-UNet và SAM-Med2D về các chỉ số tính toán.

Bảng 4.6: So sánh hiệu quả tính toán: PGA-UNet vs SAM-Med2D

Chỉ số	PGA-UNet (đề xuất)	SAM-Med2D
Tổng tham số	~3M	~91M (ViT-B) + lớp thích ứng
Tham số huấn luyện được	~3M (100%)	~15M (lớp thích ứng + bộ giải mã)
Độ phân giải ảnh	512×512	256×256 (cố định)
VRAM huấn luyện (lô=4)	~3 GB	~6 GB
VRAM suy luận (lô=1)	~1 GB	~2 GB
Có thể chạy trên GPU 4GB	✓	Hạn chế

4.3 Phân tích kiến trúc và khả năng tổng quát hóa

Mục này trình bày hai nhóm thực nghiệm bổ sung: (1) ablation study so sánh các cấu hình kiến trúc PSG/CAD; (2) kiểm định độ ổn định bằng đánh giá chéo 4-fold.

4.3.1 Ablation kiến trúc: Đóng góp của PSG và CAD

Tám biến thể kiến trúc được huấn luyện lại hoàn toàn từ đầu trên cùng tập BTXRD, chỉ thay đổi cấu hình PSG, cơ chế chú ý ở bộ giải mã và loại câu nhắc. Đặt tên trực tiếp theo cấu hình kiến trúc (thay vì ký hiệu V1–V8 trung tính, dù các thư mục kết quả gốc vẫn giữ ký hiệu này để truy vết) để thấy ngay đây là một ablation kiến trúc:

- **U-Net+Concat:** Không có PSG, không có cơ chế chú ý ở bộ giải mã, câu nhắc chỉ được nối thêm (concatenate) như một kênh đầu vào thông thường.
- **U-Net+PSG:** Chỉ có Cổng không gian ở bộ mã hóa, bộ giải mã không có cơ chế chú ý.
- **U-Net+CAD:** Chỉ có Cơ chế chú ý có điều kiện ở bộ giải mã, không có PSG.
- **PGA-UNet (Binary):** Đầy đủ PSG + CAD, nhưng câu nhắc là mặt nạ nhị phân (Binary bbox) thay vì Gaussian Heatmap.
- **U-Net+Binary:** Không có PSG, không có CAD, câu nhắc nối kênh như U-Net+Concat nhưng dùng mặt nạ nhị phân thay vì Gaussian, đối trọng của U-Net+Concat cho riêng trực loại câu nhắc.
- **PGA-UNet (đề xuất):** Đầy đủ PSG + CAD, câu nhắc là Gaussian Heatmap, đây chính là kiến trúc được đề xuất và dùng xuyên suốt các mục trước của chương này.

- **U-Net+PSG+Attention gốc:** Có PSG, bộ giải mã dùng công chú ý nguyên bản của Attention U-Net [5] (tự điều kiện hóa bằng đặc trưng nội bộ của bộ giải mã), không phải CAD (không nhận đặc trưng câu nhắc bên ngoài).
- **U-Net+Attention gốc:** Không có PSG, bộ giải mã dùng cùng công chú ý nguyên bản trên, câu nhắc vẫn nối kênh như U-Net+Concat.

Bốn biến thể dùng Gaussian heatmap và không đổi loại câu nhắc (U-Net+Concat, U-Net+PSG, U-Net+CAD, U-Net+Attention gốc, U-Net+PSG+Attention gốc, PGA-UNet đề xuất) tạo thành một lưới đầy đủ 2×3 : {không PSG, có PSG} $\times$ {không có chú ý, chú ý nguyên bản chưa điều kiện hóa, CAD đã điều kiện hóa}, cho phép tách bạch câu hỏi “bản thân cơ chế chú ý có giúp ích hay không” khỏi câu hỏi “việc điều kiện hóa chú ý bằng đặc trưng câu nhắc có giúp ích hay không”. Hai biến thể còn lại (PGA-UNet Binary, U-Net+Binary) giữ nguyên cấu hình PSG/CAD tương ứng của U-Net+Concat và PGA-UNet (đề xuất), chỉ đổi loại câu nhắc sang nhị phân, dùng để kiểm tra xem đánh đổi Gaussian/Binary có phụ thuộc vào việc kiến trúc có PSG+CAD hay không. Kết quả được trình bày trong Bảng 4.7.

Bảng 4.7: Ablation study: Dice Score của 8 biến thể kiến trúc PGA-UNet, ba kịch bản câu nhắc (N=187 ảnh, cấp độ ảnh). PGA-UNet (đề xuất) là mô hình chính xuyên suốt khóa luận.

Biến thể	PSG	Attention (giải mã)	Prompt	Zoom-out $\uparrow$	Shift $\uparrow$	Mixed $\uparrow$
U-Net+Concat (baseline)	$\times$	Không	Gaussian	0.8763	0.7364	0.8216
U-Net+PSG	$\checkmark$	Không	Gaussian	0.8673	0.7388	0.8162
U-Net+CAD	$\times$	CAD	Gaussian	0.8861	0.7406	0.8292
PGA-UNet (Binary)	$\checkmark$	CAD	Binary	0.8780	0.7434	0.8267
U-Net+Binary	$\times$	Không	Binary	0.8781	0.7312	0.8202
PGA-UNet (đề xuất)	$\checkmark$	CAD	Gaussian	0.8607	0.8423	0.8560
U-Net+PSG+Attention gốc	$\checkmark$	Gốc	Gaussian	0.8680	0.7359	0.8173
U-Net+Attention gốc	$\times$	Gốc	Gaussian	0.8738	0.7314	0.8193

Điểm neo mức không câu nhắc: Trước khi phân tích tám biến thể, cần một điểm tham chiếu hoàn toàn không câu nhắc: Attention U-Net

thuần túy (không PSG, không CAD) đạt $\text{Dice} = 0.4122$, **thấp hơn** U-Net thuần túy (0.4740, Bảng 4.2), chênh -0.0618 – không có tín hiệu phân tách tổn thương với nền, công chú ý tự học dễ khuếch đại nhầm vùng nhiễu. Đây là cơ sở cho câu hỏi ablation: bản thân công chú ý (không điều kiện hóa) có tận dụng được câu nhắc hay chỉ chú ý *được điều kiện hóa đúng cách* (CAD) mới thực sự khai thác được tín hiệu đó?

Phân tích ablation: Năm quan sát chính từ Bảng 4.7:

(1) Đóng góp riêng lẻ của PSG và CAD so với chỉ nổi kênh: So với U-Net+Concat (Shift = 0.7364), PSG đơn độc (0.7388) và CAD đơn độc (0.7406) chỉ cải thiện rất nhẹ ($+0.0024$, $+0.0042$), còn thua xa PGA-UNet đề xuất (0.8423) – xác nhận kiến trúc đầy đủ PSG+CAD mới tạo khác biệt lớn ở kịch bản bền bỉ.

(2) Công chú ý không điều kiện hóa (Gốc) không tự giúp ích có ý nghĩa thống kê trên BTXRD: U-Net+Attention gốc so U-Net+Concat (đều không PSG): Zoom -0.0025 , Shift -0.0050 , Mixed -0.0023 , không kịch bản nào có ý nghĩa ($p = 0,255/0,607/0,395$, Bảng 4.8). Ngay cả có PSG khuếch đại vùng câu nhắc, U-Net+PSG+Attention gốc so U-Net+PSG vẫn không có kịch bản nào ý nghĩa (Zoom $+0.0007$, $p = 0,129$; Shift -0.0030 , $p = 0,376$; Mixed $+0.0011$, $p = 0,074$) – khác kỳ vọng ban đầu rằng PSG sẽ giúp công chú ý nguyên bản phát huy rõ hơn: trên BTXRD, PSG một mình chưa đủ để công chú ý không điều kiện hóa tận dụng tín hiệu câu nhắc đáng tin cậy.

(3) Điều kiện hóa chú ý bằng đặc trưng câu nhắc (CAD) mới là yếu tố quyết định, đặc biệt cho tính bền bỉ: Không có PSG, CAD so công chú ý gốc cải thiện có ý nghĩa ở Zoom và Mixed (U-Net+CAD so U-Net+Attention gốc: $+0.0123$, $p < 0,001$; $+0.0099$, $p = 0,003$; riêng Shift $+0.0092$ không đạt ý nghĩa, $p = 0,152$). Có PSG, khoảng cách lớn hơn nhiều ở hai kịch bản bền bỉ và có ý nghĩa rất mạnh ở Shift (PGA-UNet đề xuất so U-Net+PSG+Attention gốc: $+0.1065$, $p < 0,001$) và Mixed ($+0.0388$, $p = 0,001$); Zoom giảm nhẹ nhưng vẫn có ý nghĩa (-0.0073 , $p = 0,025$). Kết luận: không phải bản thân cơ chế chú ý, mà việc điều kiện


hóa bằng đặc trưng câu nhắc bên ngoài (CAD) mới quyết định hiệu năng có ý nghĩa thống kê, lợi ích lớn nhất đúng ở nhóm kịch bản bên bỉ (đặc biệt Shift) – mục tiêu cốt lõi của khóa luận – đổi lại một phần hiệu năng nhỏ ở kịch bản lý tưởng (Zoom).

(4) Đánh đổi Gaussian và nhị phân chỉ bậc lộ khi có đầy đủ PSG+CAD: Ở cấu hình cơ sở, U-Net+Concat (Gaussian) so U-Net+Binary hầu như không khác biệt (Zoom -0.0018 , Shift $+0.0052$, Mixed $+0.0014$, đều dưới 0.006). Ở cấu hình đầy đủ PSG+CAD, PGA-UNet (Gaussian) so PGA-UNet (Binary) chênh lệch rõ rệt: Shift $+0.0989$ ($0.7434 \rightarrow 0.8423$), Mixed $+0.0293$ ($0.8267 \rightarrow 0.8560$), Zoom giảm nhẹ -0.0173 ($0.8780 \rightarrow 0.8607$). **Đánh đổi này có chủ đích:** Gaussian heatmap làm mờ đường biên tín hiệu câu nhắc, buộc mô hình không ghi nhớ cứng vị trí tâm hộp giới hạn, nhưng lợi ích này chỉ xuất hiện khi PSG+CAD khai thác được tín hiệu đạo hàm liên tục của Gaussian; thiếu PSG+CAD, loại câu nhắc gần như không quan trọng.

(5) Hiệu ứng tương hỗ của PSG+CAD kết hợp: So với U-Net+Concat, PSG đơn độc đóng góp $+0.0024$ và CAD đơn độc $+0.0042$ ở Shift (tổng $+0.0066$), nhưng PSG+CAD kết hợp (PGA-UNet đề xuất) đóng góp **$+0.1059$** ($0.7364 \rightarrow 0.8423$) – gấp ~ 16 lần tổng hai đóng góp riêng lẻ. PSG định hướng bộ mã hóa tập trung vào vùng câu nhắc, CAD duy trì và điều kiện hóa tín hiệu đó xuyên suốt bộ giải mã; thiếu một trong hai, hoặc có chú ý nhưng không điều kiện hóa đúng cách (quan sát (2)(3)), tín hiệu bị suy giảm trước khi đến đầu ra.

Kiểm định thống kê Wilcoxon signed-rank

Năm quan sát ở trên dựa trên chênh lệch Dice trung bình. Để xác nhận các chênh lệch này có ý nghĩa thống kê (không chỉ là nhiễu ngẫu nhiên giữa các ảnh), sáu cặp so sánh trọng tâm (chênh lệch trung bình sát nhau nhất, bỏ qua các cặp PGA-UNet so với U-Net/SAM-Med2D vì khoảng cách đã quá lớn để cần kiểm định) được kiểm định bằng **Wilcoxon signed-rank test** trên Dice từng ảnh (bắt cặp theo `img_name`), lặp lại cho cả BTXRD



Hình 4.3: Ablation study: Dice Score của 8 biến thể kiến trúc PGA-UNet trên ba kịch bản câu nhắc (Bảng 4.7). PGA-UNet (đề xuất) tô xanh dương, các biến thể còn lại tô xám.

(N=187 ảnh) và FracAtlas (N=72 ảnh). Bảng 4.8 trình bày đầy đủ 36 kết quả ($6 \text{ cặp} \times 2 \text{ bộ dữ liệu} \times 3 \text{ kịch bản}$).

Bảng 4.8: Wilcoxon signed-rank, 6 cặp so sánh trọng tâm, ba kịch bản câu nhắc, trên BTXRD (N=187) và FracAtlas (N=72). $\Delta\text{Dice} = \text{Dice}(\text{vế trái}) - \text{Dice}(\text{vế phải})$; *** $p < 0,001$, ** $p < 0,01$, * $p < 0,05$, ns = không ý nghĩa.

Cặp so sánh	Kịch bản	ΔDice (BTXRD)	p (BTXRD)	ΔDice (FracAtlas)	p (FracAtlas)
V8–V1: Attention gốc – Concat (không PSG)	Zoom-out	−0.0024	0,255 ns	−0.0235	<0,001 ***
	Shift	−0.0050	0,607 ns	+0.0050	0,255 ns
	Mixed	−0.0023	0,395 ns	−0.0195	<0,001 ***
V3–V8: CAD – Attention gốc (không PSG)	Zoom-out	+0.0122	<0,001 ***	−0.0089	0,025 *
	Shift	+0.0092	0,152 ns	−0.0079	0,141 ns
	Mixed	+0.0098	0,003 **	−0.0107	0,023 *
V7–V2: Attention gốc – PSG-only (có PSG)	Zoom-out	+0.0007	0,129 ns	+0.0140	0,009 **
	Shift	−0.0030	0,376 ns	+0.0167	0,005 **
	Mixed	+0.0011	0,074 ns	+0.0138	0,002 **
V6–V7: CAD – Attention gốc (có PSG)	Zoom-out	−0.0073	0,025 *	−0.0182	<0,001 ***
	Shift	+0.1065	<0,001 ***	+0.0924	<0,001 ***
	Mixed	+0.0388	0,001 **	+0.0291	0,161 ns
V1–V5: Gaussian – Binary (kiến trúc cơ sở)	Zoom-out	−0.0018	0,896 ns	−0.0072	0,007 **
	Shift	+0.0052	0,013 *	−0.0050	0,284 ns
	Mixed	+0.0015	0,226 ns	−0.0085	0,006 **
V6–V4: Gaussian – Binary (kiến trúc đầy đủ)	Zoom-out	−0.0173	<0,001 ***	+0.0262	<0,001 ***
	Shift	+0.0990	<0,001 ***	+0.1005	<0,001 ***
	Mixed	+0.0293	0,012 *	+0.0655	<0,001 ***

Diễn giải kiểm định: Kết quả vững chắc và nhất quán nhất ở cả hai bộ dữ liệu là **V6–V7 (CAD so Attention gốc, có PSG) ở Shift**: $p < 0,001$ trên cả BTXRD (+0,1065) và FracAtlas (+0,0924), khoảng cách lớn hơn hẳn mọi cặp khác – bằng chứng thống kê mạnh nhất cho luận

điểm trung tâm: điều kiện hóa attention bằng đặc trưng câu nhắc mới quyết định tính bền bỉ, không phải bản thân cơ chế attention. Ngược lại, một số cặp có ý nghĩa ($p < 0,05$) nhưng **đổi chiều dấu giữa hai bộ dữ liệu**: V3–V8 dương trên BTXRD nhưng âm trên FracAtlas ở Zoom/Mixed; V7–V2 không ý nghĩa trên BTXRD nhưng dương và có ý nghĩa trên cả ba kịch bản FracAtlas; V1–V5 đổi chiều tương tự. Đây là hiện tượng thống kê thật (không phải nhiễu đo lường), phản ánh các đóng góp riêng lẻ biên độ nhỏ (dưới 0,02 Dice) phụ thuộc đặc tính hình thái tổn thương từng bộ dữ liệu hơn là một xu hướng kiến trúc phổ quát; khóa luận báo cáo trung thực sự đổi chiều này thay vì chỉ trích dẫn bộ dữ liệu ủng hộ giả thuyết ban đầu. Kết luận ở mức tin cậy cao nhất: *điều kiện hóa attention (CAD) mang lại lợi ích bền bỉ lớn, nhất quán và có ý nghĩa thống kê xuyên suốt cả hai bộ dữ liệu*; các đóng góp thành phần nhỏ hơn có ý nghĩa tùy trường hợp nhưng không nhất quán chiều giữa hai miền dữ liệu, nên không được diễn giải như một quy luật kiến trúc tổng quát.

4.3.2 Kiểm định độ ổn định bằng đánh giá chéo

Để xác minh tính ổn định và khả năng tổng quát hóa của PGA-UNet không phụ thuộc vào một lần phân chia dữ liệu duy nhất, mô hình được đánh giá chéo trên 4 phân vùng dữ liệu khác nhau. Bảng 4.9 trình bày Dice Score chi tiết của từng fold theo ba kịch bản câu nhắc; Bảng 4.10 ngay sau đó tổng hợp kết quả trung bình 4 fold trên đầy đủ sáu chỉ số đánh giá.

Dice Score dao động rất nhỏ giữa các fold: độ lệch chuẩn thấp nhất ở Zoom-out (± 0.0087) và lớn nhất ở Shift (± 0.0119), biên độ chấp nhận được trong nghiên cứu y tế, xác nhận mô hình hội tụ ổn định trên các phân vùng dữ liệu khác nhau, không phụ thuộc vào một cách chia cụ thể.

Bảng 4.10 tổng hợp lại ba hàng trung bình Dice trên, bổ sung các chỉ số còn lại (IoU, Precision, Recall, HD95, CBL) mà bảng theo-fold không thể hiện hết vì lý do gọn bảng.

Các chỉ số cross-validation rất gần tập test chính (Dice Zoom-out:

Bảng 4.9: Dice Score từng fold trong đánh giá chéo 4-fold PGA-UNet (kịch bản Zoom-out / Shift / Mixed)

Fold	Zoom-out↑	Shift↑	Mixed↑
Fold 1	0.8514	0.8206	0.8424
Fold 2	0.8755	0.8534	0.8677
Fold 3	0.8602	0.8414	0.8533
Fold 4	0.8646	0.8426	0.8610
Trung bình $\pm$ Std	0.8629 $\pm$ 0.0087	0.8395 $\pm$ 0.0119	0.8561 $\pm$ 0.0094

Bảng 4.10: Kết quả đánh giá chéo 4-fold PGA-UNet trên 3 kịch bản câu nhắc (trung bình 4 fold)

Kịch bản	Dice↑	IoU↑	Precision↑	Recall↑	HD95↓	CBL↑
Zoom-out	0.8629	0.7672	0.8506	0.8910	11.14	0.9548
Shift	0.8395	0.7332	0.8393	0.8574	13.25	0.9381
Mixed (70% Zoom-out + 30% Shift)	0.8561	0.7573	0.8466	0.8820	11.90	0.9501

0.8629 so với 0.8607, chênh +0.0022), phản ánh mô hình không bị may rủi bởi một cách chia dữ liệu cụ thể, dù vẫn có khác biệt tự nhiên giữa dữ liệu huấn luyện và tập kiểm thử độc lập giữ lại hoàn toàn từ đầu.

Tính ổn định thống kê và độ tin cậy kết quả: Độ lệch chuẩn Dice qua 4 fold rất thấp (± 0.0087 ở Zoom-out, ± 0.0119 ở Shift), trong khi biên độ chênh lệch giữa các mô hình lớn hơn nhiều: PGA-UNet đề xuất cải thiện Shift Dice +0.0989 so với PGA-UNet Binary (0.8423 vs 0.7434, Bảng 4.7), tỷ lệ signal-to-noise $\approx 8,3$. Kiểm định Wilcoxon signed-rank chính thức cho cặp này (Mục 4.3.1, Bảng 4.8) xác nhận $p < 0,001$.

4.3.3 Đánh giá theo đặc tính tổn thương

Để đánh giá sâu hơn khả năng tổng quát hóa của PGA-UNet, ba phân tích nhóm nhỏ (sub-category) được thực hiện: **(1)** so sánh PGA-UNet với U-Net trên nhóm *Đế* (top-50 U-Net Dice) và *Khó* (bottom-50 U-Net Dice), trên $N = 187$ ảnh (50 ảnh mỗi nhóm); **(2)** so sánh PGA-UNet với

SAM-Med2D trên ba nhóm đặc tính lâm sàng (Tổn thương nhỏ, Biên giới mờ, Tổn thương rõ nét), mỗi nhóm 50 ảnh (cấp độ ảnh); **(3)** kiểm chứng công bằng cùng độ phân giải 256×256 để loại trừ lợi thế độ phân giải khi so sánh PGA-UNet với SAM-Med2D.


PGA-UNet so với U-Net theo độ khó tác vụ

Ở nhóm *Dễ* (tương phản cao, hình dạng rõ), U-Net vẫn hoạt động được, PGA kỳ vọng cải thiện thêm đáng kể. Ở nhóm *Khó* (tương phản thấp, xương chồng lấp, hình dạng bất thường), U-Net thiếu thông tin định hướng nên dự đoán suy giảm mạnh, trong khi PGA-UNet nhờ câu nhắc kỳ vọng duy trì Dice ổn định hơn – lý do cốt lõi cho sự tồn tại của hướng tiếp cận tương tác.

Bảng 4.11: PGA-UNet so U-Net theo độ khó tác vụ (50 ảnh/nhóm, cấp độ ảnh; nhóm dễ/khó theo Dice của U-Net)

Nhóm	Mô hình	Dice	IoU	Pre	Rec	HD95 (px)	CBL
Dễ (top-50)	U-Net	0.8488	0.7403	0.8481	0.8618	51.34	0.9194
	PGA-UNet	0.8972	0.8160	0.8656	0.9368	13.20	0.9666
Khó (bottom-50)	U-Net	0.0211	0.0111	0.0396	0.1063	284.72	0.0708
	PGA-UNet	0.8261	0.7168	0.8313	0.8429	7.75	0.9456

Kết quả Bảng 4.11 xác nhận rõ giả thuyết. Ở nhóm *Dễ* (top-50), U-Net đạt Dice = 0.8488 trong khi PGA-UNet đạt 0.8972 ($\Delta = +0.0484$), cải thiện có ý nghĩa nhưng không đột biến vì tổn thương đã rõ. Ở nhóm *Khó* (bottom-50), U-Net gần như sụp đổ, chỉ còn Dice = 0.0211 (HD95 = 284.72 px); PGA-UNet **duy trì ổn định ở 0.8261** ($\Delta = +0.8050$) – cho thấy công không gian câu nhắc có vai trò quan trọng trong xử lý nhất quán các ca bệnh phức tạp.



Hình 4.4: So sánh U-Net và PGA-UNet theo độ khó tác vụ trên BTXRD (Bảng 4.11).

PGA-UNet so với SAM-Med2D theo đặc tính lâm sàng

Ba quan sát chính dự kiến: (1) **Tổn thương nhỏ**: SAM-Med2D hoạt động ở độ phân giải 256×256 khiến tổn thương nhỏ chỉ còn vài pixel, SAM bỏ sót phần lớn diện tích, trong khi PGA ở 512×512 với heatmap dẫn đường đạt kết quả tốt hơn đáng kể. (2) **Biên giới mờ**: ranh giới tổn thương không rõ trên X-quang xương đặc thù BTXRD, SAM tiền huấn luyện đa dạng nhưng không chuyên biệt hóa đặc trưng X-quang xương; PGA huấn luyện từ đầu trên BTXRD học được đặc trưng này. (3) **Tổn thương rõ nét**: khi tổn thương lớn và ranh giới rõ, cả hai mô hình đều tốt; PGA nhỉnh hơn SAM với $\sim 30 \times$ ít tham số hơn.

Kết quả Bảng 4.12 xác nhận cả ba nhận định. **Tổn thương nhỏ**: PGA đạt Dice = 0.8301 trong khi SAM chỉ đạt 0.1356 ($\Delta = +0.6945$),

Bảng 4.12: PGA-UNet so SAM-Med2D theo ba nhóm đặc tính lâm sàng (Zoom-out, 50 ảnh/nhóm, cấp độ ảnh)

Nhóm	Mô hình	Dice	IoU	Pre	Rec	HD95 (px)	CBL
Tổn thương nhỏ	SAM-Med2D	0.1356	0.0909	0.4331	0.0932	265.55	0.4257
	PGA-UNet	0.8301	0.7212	0.8285	0.8553	3.06	0.9408
Biên giới mờ	SAM-Med2D	0.5759	0.4260	0.8866	0.4616	28.74	0.9000
	PGA-UNet	0.8448	0.7421	0.8527	0.8552	13.87	0.9546
Tổn thương rõ nét	SAM-Med2D	0.8529	0.7469	0.8807	0.8342	24.33	0.9587
	PGA-UNet	0.8826	0.7925	0.8477	0.9261	22.79	0.9629


khoảng cách lớn nhất trong ba nhóm, phù hợp giả thuyết về ảnh hưởng độ phân giải 512×512 so với 256×256 . **Biên giới mờ**: PGA = 0.8448 vs SAM = 0.5759 ($\Delta = +0.2689$), cho thấy đặc trưng X-quang xương chuyên biệt mà PGA học được trên BTXRD. **Tổn thương rõ nét**: khoảng cách thu hẹp đáng kể (PGA = 0.8826, SAM = 0.8529, $\Delta = +0.0297$), cả hai mô hình hoạt động tốt khi điều kiện thuận lợi; PGA vẫn nhỉnh hơn với kiến trúc nhỏ gọn hơn $\sim 30\times$. Đáng chú ý, ở hai nhóm *Biên giới mờ* và *Tổn thương rõ nét*, SAM-Med2D đạt Precision cao hơn PGA-UNet (0.8866 vs 0.8527 và 0.8807 vs 0.8477) dù Dice/Recall tổng thể thấp hơn nhiều – cùng khuôn mẫu “mô hình nền tảng bảo thủ hơn” quan sát được trên FracAtlas (Bảng 4.19): SAM dự đoán vùng nhỏ hơn nhưng chính xác khi đã dự đoán, còn PGA-UNet ưu tiên bao phủ đầy đủ vùng tổn thương.

Vì Bảng 4.12 so sánh PGA ở cấu hình mặc định 512×512 với SAM ở 256×256 , phần tiếp theo trình bày kiểm định bổ sung ở cùng 256×256 cho cả hai mô hình (Bảng 4.13), nhằm xác nhận khoảng cách trên không chỉ đến từ lợi thế độ phân giải của PGA.

Kiểm chứng công bằng theo đặc tính tổn thương tại cùng 256×256

Để loại trừ hoàn toàn lợi thế độ phân giải, phân tích nhóm nhỏ được lặp lại với PGA-UNet₂₅₆ (huấn luyện và suy luận tại 256×256) đối chiếu trực tiếp với SAM-Med2D (256×256), cùng nhóm mẫu, cùng hộp giới hạn, chỉ khác điểm lưu trọng số PGA.

Bảng 4.13 xác nhận kết luận chính vẫn đúng khi kiểm soát độ phân



Hình 4.5: So sánh PGA-UNet và SAM-Med2D theo ba nhóm đặc tính lâm sàng trên BTXRD (Bảng 4.12).

Bảng 4.13: PGA-UNet₂₅₆ vs SAM-Med2D theo đặc tính lâm sàng, cùng 256×256 (Zoom-out, 50 ảnh/nhóm, cấp độ ảnh)

Nhóm	Mô hình	Dice	IoU	Pre	Rec	HD95 (px)	CBL
Tồn thương nhỏ	SAM-Med2D	0.1356	0.0909	0.4331	0.0932	265.55	0.4257
	PGA-UNet ₂₅₆	0.6870	0.5383	0.5687	0.9354	5.98	0.9092
Biên giới mờ	SAM-Med2D	0.5759	0.4260	0.8866	0.4616	28.74	0.9000
	PGA-UNet ₂₅₆	0.7970	0.6715	0.7317	0.8977	18.84	0.9397
Tồn thương rõ nét	SAM-Med2D	0.8529	0.7469	0.8807	0.8342	24.33	0.9587
	PGA-UNet ₂₅₆	0.8660	0.7669	0.8050	0.9455	23.08	0.9599

giải: PGA-UNet₂₅₆ vượt SAM-Med2D ở cả ba nhóm về Dice (+0.5514 tổn thương nhỏ, +0.2211 biên giới mờ, +0.0131 tổn thương rõ nét). Ở nhóm **Tổn thương nhỏ**, PGA vượt SAM ở cả Precision (0.5687 vs 0.4331) lẫn Recall (0.9354 vs 0.0932) và HD95 (5.98 vs 265.55 px) – SAM gần như bỏ sót hoàn toàn tổn thương nhỏ ở độ phân giải 256 trong khi PGA vẫn phát hiện và định vị được hầu hết. Ở hai nhóm **Biên giới mờ** và **Tổn thương rõ nét**, SAM vẫn giữ Precision cao hơn PGA (0.8866 vs 0.7317 và 0.8807 vs 0.8050) dù thua Dice/Recall, cùng khuôn mẫu “bảo thủ hơn” đã nêu ở Bảng 4.12. So Bảng 4.12 (PGA@512 vs SAM@256) với Bảng 4.13 (cùng 256), nhóm Tổn thương nhỏ hưởng lợi nhiều nhất từ độ phân giải cao (PGA@512: 0.8301 vs PGA@256: 0.6870, $\Delta = +0.1431$), trong khi Tổn thương rõ nét ít nhạy hơn ($\Delta = +0.0166$).

4.4 Đánh giá bổ sung trên bộ dữ liệu thứ hai (FracAtlas)

Toàn bộ kết quả từ Mục 4.2 đến Mục 4.3.3 được huấn luyện và đánh giá trên BTXRD. Để kiểm chứng kiến trúc PGA-UNet không chỉ “phù hợp” với một bộ dữ liệu cụ thể, mục này lặp lại các thực nghiệm cốt lõi (so sánh PGA vs SAM-Med2D, ba kịch bản câu nhắc, phân tích nhóm nhỏ) trên một bộ dữ liệu X-quang xương độc lập thứ hai: **FracAtlas, sau khi huấn luyện lại (không phải chưa tinh chỉnh) trên chính bộ dữ liệu này** (Bảng 4.14 nêu tỉ lệ chia train/val/test). Đây là bộ dữ liệu có nguồn gốc, quy trình thu thập và đặc điểm tổn thương (gãy xương, dạng đường nứt mảnh) khác biệt với BTXRD (u xương, dạng khối/mảng), phù hợp để kiểm tra xem **phương pháp/kiến trúc** (không phải trọng số đã huấn luyện trên BTXRD) có tiếp tục hiệu quả khi huấn luyện lại trên miền dữ liệu khác – một phép thử tính tổng quát của *thiết kế*, khác với kiểm định tổng quát hóa liên miền theo nghĩa chặt (train một bộ, suy luận trực tiếp chưa tinh chỉnh trên bộ còn lại); thực nghiệm đó **chưa được thực hiện** và được liệt kê như hướng đánh giá bổ sung tại Chương 5.

Mục này được tổ chức song song với cấu trúc đã dùng cho BTXRD (Mục 4.2), theo đúng thứ tự: (1) giới thiệu bộ dữ liệu FracAtlas; (2) PGA-UNet ở hai độ phân giải 256×256 và 512×512 (tương ứng Mục 4.2.4 trên BTXRD); (3) so sánh cơ sở với U-Net cùng 512×512 (tương ứng Mục 4.2); (4) so sánh với SAM-Med2D cùng 256×256 (tương ứng Mục 4.2.3); (5) phân tích theo đặc tính tổn thương (nhóm nhỏ, tương ứng Mục 4.3.3); (6) ablation kiến trúc (tương ứng Mục 4.3.1); (7) đánh giá chéo 4-fold, Gatekeeper và luồng xử lý đầu cuối (tương ứng Mục 4.3.2 và 4.7 trên BTXRD) – ba nội dung này ban đầu chưa có tương đương trên FracAtlas nhưng đã được bổ sung đầy đủ (Mục 4.4.7, 4.4.8, 4.4.10).

4.4.1 Giới thiệu bộ dữ liệu FracAtlas

FracAtlas [9] là bộ dữ liệu X-quang công khai tập trung vào gãy xương (fracture), thu thập từ 3 bệnh viện tại Bangladesh với tổng cộng 4.083 ảnh X-quang vùng tay, vai, hông và chân, trong đó 717 ảnh có bệnh lý (922 vùng gãy xương được khoanh vùng). Nhãn được xây dựng qua quy trình hai giai đoạn: hai bác sĩ X-quang độc lập xác định vị trí gãy, sau đó một bác sĩ chỉnh hình đối chiếu và giải quyết bất đồng; mặt nạ đa giác được vẽ thủ công bằng công cụ mã nguồn mở `makesense.ai` theo định dạng COCO JSON. Cấu trúc nhãn ba cấp (phân lớp, hộp giới hạn định vị, mặt nạ phân đoạn pixel-level) tương đồng với BTXRD nên có thể tái sử dụng trực tiếp toàn bộ luồng xử lý huấn luyện/suy luận (PGA-UNet, SAM-Med2D) mà không cần thay đổi kiến trúc hay hàm mất mát. Điểm khác biệt cốt lõi so với BTXRD là đặc tính hình thái tổn thương: đường gãy xương thường mảnh, tuyến tính và có diện tích nhỏ hơn nhiều so với khối u xương, tạo ra một phép thử tổng quát hóa có ý nghĩa cho cơ chế PSG và CAD.

Kiểm tra chéo số liệu: Tổng số mẫu per-polygon dùng trong ba tập ($730 + 95 + 92 = 917$) khớp gần đúng với con số 922 vùng gãy xương mà bài báo gốc công bố trên 717 ảnh bệnh lý [9]; chênh lệch nhỏ (5 mẫu, $<1\%$) hợp lý do một số polygon bị loại khi lọc dữ liệu (quá nhỏ hoặc lỗi định dạng), củng cố độ tin cậy quy trình chuẩn bị dữ liệu.

Bảng 4.14: Thống kê phân bố bộ dữ liệu FracAtlas dùng trong thực nghiệm (đơn vị: mẫu per-polygon)

Tập dữ liệu	Số ảnh	Số mẫu (per-polygon)	Ghi chú
Huấn luyện (Train)	573	730	
Xác thực (Validation)	72	95	
Kiểm thử (Test)	72	92	Trung bình ~ 1.28 polygon/ảnh

Quy mô huấn luyện của FracAtlas (573 ảnh, 730 mẫu per-polygon) nhỏ hơn đáng kể BTXRD (1 493 ảnh, 1848 mẫu per-polygon), chỉ bằng $\approx 38\%$ theo số ảnh ($\approx 39\%$ theo số mẫu per-polygon) – điều kiện thực nghiệm khắt khe hơn để đánh giá khả năng học đặc trưng của PGA-UNet với ít dữ liệu huấn luyện hơn.

4.4.2 PGA-UNet toàn diện trên FracAtlas (256×256 và 512×512 , ba kịch bản câu nhắc)

Tương tự Mục 4.2.3 (so sánh công bằng cùng 256×256 với SAM-Med2D trên BTXRD) và Bảng 4.3 (PGA-UNet ở độ phân giải gốc 512×512), PGA-UNet được huấn luyện lại từ đầu trên FracAtlas ở cả hai độ phân giải 256×256 và 512×512 , đánh giá trên cả ba kịch bản câu nhắc (Zoom-out, Shift, Mixed 70/30), cấp độ ảnh ($N=72$ ảnh).

¶*Lưu ý HD95 khác đơn vị độ phân giải:* Giá trị HD95 thô (px) của PGA-256 và PGA-512 **không thể so sánh trực tiếp** vì đo trên hai không gian ảnh khác kích thước (1 px lỗi tại 256 tương đương ~ 2 px tại 512); do đó HD95 không được in đậm ở hàng 512 dù giá trị tuyệt đối cao hơn – đây không phải PGA-512 kém bám biên hơn, chỉ là khác đơn vị đo.

Nhận xét: Ngay cả với chỉ 573 ảnh huấn luyện ($\approx 38\%$ BTXRD), PGA-UNet vẫn đạt Dice > 0.78 ở cả ba kịch bản tại cả hai độ phân giải.

Bảng 4.15: PGA-UNet trên FracAtlas: 256×256 và 512×512 , ba kích bản câu nhắc (N=72 ảnh, cấp độ ảnh)


Độ phân giải	Kích bản	Dice $\uparrow$	IoU $\uparrow$	Pre $\uparrow$	Rec $\uparrow$	HD95 $\downarrow$ (px)	CBL $\uparrow$
PGA-UNet (256)	Zoom-out	0.8110	0.6886	0.7790	0.8628	3.57	0.9456
PGA-UNet (256)	Shift	0.7842	0.6531	0.7566	0.8333	4.02	0.9260
PGA-UNet (256)	Mixed	0.8088	0.6864	0.7801	0.8581	3.57	0.9431
PGA-UNet (512)	Zoom-out	0.8169	0.6953	0.7645	0.8975	7.45 [¶]	0.9546
PGA-UNet (512)	Shift	0.7850	0.6537	0.7349	0.8618	8.88 [¶]	0.9308
PGA-UNet (512)	Mixed	0.8129	0.6904	0.7614	0.8913	7.80 [¶]	0.9499

Tăng độ phân giải lên 512×512 cải thiện hầu hết chỉ số (Zoom-out Dice: $0.8110 \rightarrow 0.8169$; Shift: $0.7842 \rightarrow 0.7850$; Mixed: $0.8088 \rightarrow 0.8129$; IoU, Recall, CBL tăng tương ứng), nhất quán với quan sát trên BTXRD rằng độ phân giải cao hơn có lợi cho PGA-UNet. Riêng Precision giảm nhẹ ở cả ba kích bản khi tăng độ phân giải ($256 \rightarrow 512$: $-0.0145/-0.0217/-0.0187$), khác xu hướng chung trên BTXRD – có thể phản ánh đặc thù đường gãy mảnh: độ phân giải cao hơn giúp mô hình phát hiện nhiều vùng nghi ngờ hơn (Recall tăng) nhưng cũng bắt luôn một số vùng biên mờ không phải gãy xương thực sự (Precision giảm nhẹ), đánh đổi hợp lý về lâm sàng (thà nghi ngờ thêm còn hơn bỏ sót). Mức sụt Dice Zoom-out $\rightarrow$ Shift cũng nhỏ ở cả hai độ phân giải (-0.0268 ; -0.0319), xác nhận tính bền bỉ của Gaussian heatmap không phụ thuộc độ phân giải. Nhìn chung, kiến trúc PSG+CAD không chỉ hiệu quả với tổn thương dạng khối (u xương, BTXRD) mà còn khái quát tốt sang tổn thương dạng đường nứt mảnh (gãy xương, FracAtlas), dù tập huấn luyện nhỏ hơn đáng kể.

4.4.3 So sánh cơ sở: PGA-UNet so với U-Net trên FracAtlas

Tương tự Mục 4.2 trên BTXRD, U-Net (không câu nhắc) được huấn luyện lại từ đầu trên FracAtlas ở 512×512 để làm baseline cơ sở, đối chiếu với PGA-UNet (512) kích bản Zoom-out, cùng N=72 ảnh cấp độ ảnh.

Nhận xét: Khoảng cách U-Net/PGA-UNet trên FracAtlas (Δ Dice = $+0.4338$) còn lớn hơn trên BTXRD ($+0.3867$, Bảng 4.2) – phân tích thêm



Hình 4.6: PGA-UNet trên FracAtlas: Dice Score tại 256×256 và 512×512, ba kịch bản câu nhắc (Bảng 4.15).

Bảng 4.16: U-Net (tự động) so PGA-UNet (512, Zoom-out) trên FracAtlas, cùng 512×512 (N=72 ảnh, cấp độ ảnh)

Mô hình	Dice↑	IoU↑	Precision↑	Recall↑	HD95↓ (px)	CBL↑
U-Net	0.3831	0.2836	0.4387	0.4642	136.82	0.4628
PGA-UNet (512, Zoom-out)	0.8169	0.6953	0.7645	0.8975	7.45	0.9546

ở Mục 4.4.4: đặc tính đường gãy mảnh của FracAtlas càng bất lợi hơn cho mô hình không có định hướng không gian. HD95 của U-Net (136.82 px) cũng cao hơn nhiều PGA-UNet (7.45 px, ~ 18 lần), cho thấy khi không có câu nhắc, U-Net không chỉ bỏ sót tổn thương mà còn định vị sai vị trí ở nhiều ca.

4.4.4 So sánh với SAM-Med2D (Đã tinh chỉnh và Chưa tinh chỉnh) trên FracAtlas

Khác với thực nghiệm trên BTXRD (nơi PGA-UNet đánh giá cấp độ ảnh còn SAM-Med2D chỉ đánh giá per-polygon do giới hạn triển khai ban đầu), ở FracAtlas cả ba mô hình (PGA-UNet, SAM-Med2D đã tinh chỉnh, SAM-Med2D chưa tinh chỉnh) đều được quy về **cùng đơn vị đánh giá cấp độ ảnh** (N=72 ảnh, GT union + max-merge dự đoán), cho phép so sánh trực tiếp không cần quy đổi.

Bảng 4.17: PGA-UNet (256) so SAM-Med2D (đã/chưa tinh chỉnh) trên FracAtlas, ba kịch bản câu nhắc, cùng 256×256 , cấp độ ảnh (N=72 ảnh)

Mô hình	Kịch bản	Dice $\uparrow$	IoU $\uparrow$	Pre $\uparrow$	Rec $\uparrow$	HD95 $\downarrow$ (px)	CBL $\uparrow$
PGA-UNet (256)	Zoom-out	0.8110	0.6886	0.7790	0.8628	3.57	0.9456
PGA-UNet (256)	Shift	0.7842	0.6531	0.7566	0.8333	4.02	0.9260
PGA-UNet (256)	Mixed	0.8088	0.6864	0.7801	0.8581	3.57	0.9431
SAM-Med2D (FT)	Zoom-out	0.7339	0.5897	0.7358	0.7508	4.33	0.9040
SAM-Med2D (FT)	Shift	0.6743	0.5227	0.6715	0.6925	5.19	0.8606
SAM-Med2D (FT)	Mixed	0.7209	0.5745	0.7185	0.7396	4.57	0.8916
SAM-Med2D (ZS)	Zoom-out	0.5278	0.3720	0.4854	0.6519	8.53	0.8514
SAM-Med2D (ZS)	Shift	0.4983	0.3460	0.4503	0.6195	9.72	0.8098
SAM-Med2D (ZS)	Mixed	0.5242	0.3691	0.4858	0.6436	8.86	0.8402

Ghi chú về điểm lưu trọng số đã tinh chỉnh: Lần huấn luyện đầu tiên của SAM-Med2D trên FracAtlas hội tụ quá sớm (điểm lưu trọng số tốt nhất lưu ngay tại vòng lặp 1, do quá khớp trên tập huấn luyện nhỏ khiến dừng sớm kích hoạt sau đó), khiến dự đoán gần như trùng khớp với chưa tinh chỉnh. Sau khi huấn luyện lại, điểm lưu trọng số đã tinh chỉnh hiện

tại (`best_sam.pth`, train Dice tăng liên tục $0.6266 \rightarrow 0.8981$ qua 11 vòng lặp) hội tụ đầy đủ và cải thiện rõ rệt so với chưa tinh chỉnh ở cả ba kịch bản – số liệu trình bày trong bảng trên là kết quả sau khi huấn luyện lại.

Phân tích: Sau khi tinh chỉnh hội tụ đầy đủ, SAM-Med2D (FT) cải thiện rõ rệt so với chưa tinh chỉnh ở cả ba kịch bản (Dice: $+0.2061/+0.1760/+0.1967$), xác nhận việc tinh chỉnh trên FracAtlas thực sự có lợi khi huấn luyện đủ vòng lặp. Dù vậy, PGA-UNet vẫn vượt trội SAM-Med2D (FT) ở cả ba kịch bản, biên độ đã thu hẹp đáng kể so với chưa tinh chỉnh ($+0.08$ đến $+0.11$ Dice so với FT, so với $+0.28-0.29$ so với ZS). Biên độ còn lại phù hợp đặc tính hình thái FracAtlas: đường gãy mảnh có diện tích nhỏ hơn nhiều khối u BTXRD, khiến giới hạn độ phân giải 256×256 của SAM-Med2D vẫn bất lợi dù đã tinh chỉnh đúng cách (tương tự nhóm “Tổn thương nhỏ” Bảng 4.12). PGA-UNet cũng giữ tính bền bỉ tốt hơn: mức sụt Dice Zoom-out $\rightarrow$ Shift chỉ -0.0268 (256), nhỏ hơn PGA-UNet@256 trên BTXRD (-0.0372) và nhỏ hơn cả SAM-Med2D (FT) trên FracAtlas (-0.0596) – cơ chế hướng dẫn mềm (Gaussian heatmap) ổn định hơn trước sai lệch câu nhắc ngay cả so với một mô hình nền tảng đã tinh chỉnh đúng cách.

4.4.5 Đánh giá theo đặc tính tổn thương trên FracAtlas

PGA-UNet so với U-Net theo độ khó tác vụ


Tương tự Mục 4.3.3 trên BTXRD, tập test FracAtlas được chia thành hai nhóm **hậu nghiệm** theo chính Dice của U-Net (baseline không câu nhắc): TOP-DICE (nhóm ảnh U-Net dự đoán tốt nhất) và BOTTOM-DICE (nhóm ảnh U-Net dự đoán kém nhất). Do FracAtlas chỉ có 72 ảnh test (nhỏ hơn nhiều so với 187 ảnh của BTXRD), quy mô mỗi nhóm được điều chỉnh còn $N=36$ ảnh/nhóm (thay vì top/bottom-50 như BTXRD) để hai nhóm không chồng lấp lên nhau ($2 \times 36 = 72 = 72$).

Nhận xét: Xu hướng từ BTXRD (Bảng 4.11) được tái khẳng định trên FracAtlas. Ở nhóm TOP-DICE, U-Net đạt Dice khá (0.6532) vì đây là ca

Bảng 4.18: PGA-UNet so U-Net theo độ khó tác vụ trên FracAtlas (36 ảnh/nhóm, cấp độ ảnh; nhóm dễ/khó theo Dice U-Net, Zoom-out)

Nhóm	Mô hình	Dice	IoU	Pre	Rec	HD95 (px)	CBL
TOP-DICE (N=36)	U-Net	0.6532	0.5018	0.6266	0.7500	82.10	0.7595
	PGA-UNet	0.8324	0.7179	0.7920	0.8975	8.04	0.9600
BOTTOM-DICE (N=36)	U-Net	0.1130	0.0654	0.1397	0.1784	191.54	0.1662
	PGA-UNet	0.8015	0.6726	0.7370	0.8974	6.85	0.9493

dễ nhất theo chính đánh giá của nó; PGA-UNet vẫn vượt trội hơn ($\Delta = +0.1791$). Ở nhóm BOTTOM-DICE, U-Net gần như sụp đổ (Dice = 0.1130, HD95 = 191.54 px), trong khi PGA-UNet **gần như không đổi** so với TOP-DICE (0.8015 so với 0.8324, $\Delta = +0.6886$ so với U-Net) – ở cả hai bộ dữ liệu, cơ chế câu nhắc giúp mô hình không phụ thuộc việc ảnh "dễ" hay "khó" theo tiêu chuẩn mô hình tự động, mà luôn bám theo vùng được bác sĩ chỉ định.



Hình 4.7: So sánh U-Net và PGA-UNet theo độ khó tác vụ trên FracAtlas (Bảng 4.18).

PGA-UNet so với SAM-Med2D theo đặc tính lâm sàng


Tương tự Mục 4.3.3, tập test FracAtlas được chia thành ba nhóm bằng nhau theo cùng tiêu chí (diện tích tổn thương nhỏ nhất, Dice SAM-Med2D thấp nhất trong phần còn lại, diện tích lớn nhất trong phần còn lại), 24 ảnh/nhóm ($3 \times 24 = 72$). Theo yêu cầu phạm vi, chỉ kịch bản **Zoom-out** được trình bày ở phân tích nhóm nhỏ (kịch bản đại diện, nhất quán với cách trình bày nhóm nhỏ trên BTXRD).

Bảng 4.19: SAM-Med2D (FT, 256), PGA-UNet (256), PGA-UNet (512) theo đặc tính tổn thương trên FracAtlas (Zoom-out, 24 ảnh/nhóm, cấp độ ảnh)

Nhóm	Mô hình	Dice	IoU	Pre	Rec	HD95 (px)	CBL
Tổn thương nhỏ (N=24)	SAM-Med2D (FT)	0.4395	0.3141	0.7793	0.3507	30.94	0.8210
	PGA-UNet (256)	0.7584	0.6178	0.6652	0.9006	6.04	0.9125
	PGA-UNet (512)	0.8028	0.6756	0.7269	0.9150	5.05	0.9400
Biên giới mờ (N=24)	SAM-Med2D (FT)	0.5787	0.4132	0.7814	0.4953	14.80	0.9005
	PGA-UNet (256)	0.7926	0.6627	0.7118	0.9060	9.41	0.9566
	PGA-UNet (512)	0.8039	0.6775	0.7439	0.8925	9.29	0.9552
Tổn thương rõ nét (N=24)	SAM-Med2D (FT)	0.7677	0.6253	0.8451	0.7178	9.86	0.9373
	PGA-UNet (256)	0.8358	0.7213	0.8105	0.8801	8.17	0.9563
	PGA-UNet (512)	0.8404	0.7280	0.8203	0.8786	8.09	0.9626

Phân tích: Xu hướng chính từ BTXRD (Bảng 4.12) được tái khẳng định trên FracAtlas: PGA-UNet vượt SAM-Med2D (256, đã tinh chỉnh đúng cách) về Dice ở cả ba nhóm, khoảng cách lớn nhất tại *Tổn thương nhỏ* ($\Delta = +0.3633$ so với PGA-512, xấp xỉ mức chênh lệch tương ứng trên BTXRD $+0.3759$), thu hẹp dần ở *Biên giới mờ* ($\Delta = +0.2251$) và *Tổn thương rõ nét* ($\Delta = +0.0726$) – cùng khuôn mẫu quan sát trên BTXRD. Ở cả ba nhóm, SAM-Med2D lại đạt Precision cao hơn PGA-UNet (ví dụ Tổn thương rõ nét: SAM = 0.8451 so với PGA-512 = 0.8203) dù Recall/Dice tổng thể thấp hơn nhiều – mô hình nền tảng đã tinh chỉnh có xu hướng dự đoán bảo thủ hơn (vùng nhỏ hơn nhưng chính xác khi đã dự đoán), còn PGA-UNet ưu tiên bao phủ đầy đủ vùng tổn thương (Recall cao hơn), đánh đổi hợp lý về lâm sàng vì bỏ sót tổn thương thường nguy hiểm hơn dự đoán dư. Không còn bất thường về độ phân giải như trước (PGA-UNet 512 nay vượt PGA-UNet 256 ở cả ba nhóm, nhất quán với các bảng khác):

do hai nhóm *Biên giới mờ/Tổn thương rõ nét* được phân loại hậu nghiệm theo thứ hạng Dice của chính SAM-Med2D, nên khi điểm lưu trọng số SAM-Med2D huấn luyện lại đúng cách, thành phần ảnh trong hai nhóm này thay đổi theo, kéo theo số liệu PGA-UNet được tính lại trên tập ảnh mới.



Hình 4.8: So sánh SAM-Med2D (FT), PGA-UNet (256) và PGA-UNet (512) theo ba nhóm đặc tính tổn thương trên FracAtlas (Bảng 4.19).


4.4.6 Ablation kiến trúc trên FracAtlas

Để kiểm tra xem các quan sát ablation ở Mục 4.3.1 (BTXRD) có phải đặc thù một bộ dữ liệu hay đặc tính chung của kiến trúc, cùng tám biến thể (định nghĩa chi tiết tại Mục 4.3.1) được huấn luyện lại hoàn toàn từ đầu trên FracAtlas. Điểm neo mức không câu nhắc cũng lặp lại: Attention U-Net thuần túy đạt Dice = 0.2467, thấp hơn U-Net thuần túy (0.3831, Bảng 4.16), chênh -0.1364 , cùng chiều và rộng hơn chênh lệch tương ứng trên BTXRD (-0.0668).

Phân tích, đối chiếu với BTXRD (kèm kiểm định Wilcoxon, Bảng 4.8): Một phát hiện tái lập nhất quán và có ý nghĩa thống kê ở cả hai bộ dữ liệu, và ba nhóm phát hiện chỉ đúng một phần hoặc đối chiếu

Bảng 4.20: Ablation study: Dice Score của 8 biến thể kiến trúc PGA-UNet trên FracAtlas, ba kịch bản câu nhắc (N=72 ảnh, cấp độ ảnh)

Biến thể	PSG	Attention (giải mã)	Prompt	Zoom-out $\uparrow$	Shift $\uparrow$	Mixed $\uparrow$
U-Net+Concat (baseline)	×	Không	Gaussian	0.8131	0.6579	0.7573
U-Net+PSG	✓	Không	Gaussian	0.8211	0.6760	0.7700
U-Net+CAD	×	CAD	Gaussian	0.7806	0.6551	0.7271
PGA-UNet (Binary)	✓	CAD	Binary	0.7907	0.6845	0.7474
U-Net+Binary	×	Không	Binary	0.8203	0.6630	0.7658
PGA-UNet (đề xuất)	✓	CAD	Gaussian	0.8169	0.7850	0.8129
U-Net+PSG+Attention gốc	✓	Gốc	Gaussian	0.8351	0.6927	0.7838
U-Net+Attention gốc	×	Gốc	Gaussian	0.7896	0.6630	0.7378



Hình 4.9: Ablation study: Dice Score của 8 biến thể kiến trúc PGA-UNet trên ba kịch bản câu nhắc trên FracAtlas (Bảng 4.20). PGA-UNet (đề xuất) tô xanh dương, các biến thể còn lại tô xám.

dấu (một số vẫn có ý nghĩa trong từng bộ dữ liệu riêng lẻ), cần nêu trung thực thay vì ép theo khuôn mẫu BTXRD:

- **Tái lập nhất quán và có ý nghĩa mạnh nhất: điều kiện hóa (CAD) mới quyết định tính bền bỉ.** Có PSG, chuyển từ công chú ý nguyên bản sang CAD (V6–V7) cải thiện mạnh và có ý nghĩa rất cao ở Shift: FracAtlas $+0,0924$ ($p < 0,001$), BTXRD $+0,1065$ ($p < 0,001$); ở Mixed, có ý nghĩa trên BTXRD ($+0,0388$, $p = 0,001$) nhưng không đạt ý nghĩa trên FracAtlas ($+0,0291$, $p = 0,161$, có thể do cỡ mẫu nhỏ hơn, $N=72$ so với 187); Zoom giảm nhẹ và có ý nghĩa ở cả hai ($-0,0182/-0,0073$, $p < 0,05$). Shift là kịch bản có bằng chứng mạnh và nhất quán nhất toàn bảng, củng cố kết luận Mục 4.3.1: lợi ích quyết định đến từ điều kiện hóa attention bằng đặc trưng câu nhắc, không phải bản thân cơ chế attention.
- **Tái lập: đánh đổi Gaussian/Binary chỉ rõ rệt và nhất quán khi có đầy đủ PSG+CAD.** Ở cấu hình cơ sở (V1–V5), chênh lệch nhỏ, vài kịch bản có ý nghĩa nhưng biên độ dưới 0,009. Ở cấu hình đầy đủ (V6–V7), chênh lệch lớn và có ý nghĩa rất cao ở cả ba kịch bản, cả hai bộ dữ liệu ($p < 0,001$ ở 5/6 trường hợp): Shift $+0,0990/+0,1005$, Mixed $+0,0293/+0,0655$; riêng dấu Zoom đổi chiều giữa hai bộ dữ liệu ($-0,0173$ BTXRD so với $+0,0262$ FracAtlas, cả hai $p < 0,001$) nhưng kết luận chung (giá trị Gaussian heatmap chỉ bộc lộ rõ khi có PSG+CAD) vẫn giữ nguyên.
- **Tái lập: hiệu ứng tương hỗ PSG+CAD lớn hơn nhiều tổng hai đóng góp riêng lẻ.** So U-Net+Concat, PSG đơn độc đóng góp $+0.0181$ Shift, CAD đơn độc -0.0028 Shift (tổng $+0.0153$), trong khi PSG+CAD kết hợp đóng góp $+0.1271$ Shift, gấp hơn 8 lần tổng hai đóng góp riêng lẻ – biên độ tương hỗ còn rõ hơn BTXRD (~ 16 lần, nhưng trên nền cả hai đóng góp riêng lẻ đều dương).
- **Khác biệt thật với BTXRD, xác nhận bằng kiểm định: hai**

đóng góp riêng lẻ biên độ nhỏ đổi chiều dấu có ý nghĩa ở cả hai bộ dữ liệu. CAD đơn độc không PSG (V3–V8): dương và có ý nghĩa trên BTXRD ở Zoom/Mixed (+0,0122/+0,0098, $p < 0,01$) nhưng âm và có ý nghĩa trên FracAtlas cùng hai kịch bản (−0,0089/−0,0107, $p < 0,05$). Attention gốc đơn độc có PSG (V7–V2): không ý nghĩa trên BTXRD ($p > 0,07$) nhưng dương và có ý nghĩa trên cả ba kịch bản FracAtlas (+0,0140 đến +0,0167, $p < 0,01$). Vì cả hai chiều đều đạt $p < 0,05$ trong bộ dữ liệu tương ứng, đây là hiện tượng thống kê thật, không phải nhiễu ngẫu nhiên; do biên độ tuyệt đối vẫn nhỏ (dưới 0,02 Dice) và đổi chiều giữa hai đặc tính hình thái tổn thương (khối u BTXRD, đường gãy mảnh FracAtlas), khóa luận không diễn giải hai đóng góp riêng lẻ này như một quy luật kiến trúc tổng quát – khác phát hiện về CAD (mục đầu) vốn nhất quán chiều và có ý nghĩa mạnh ở cả hai bộ dữ liệu.

4.4.7 Đánh giá chéo 4-fold trên FracAtlas

Tương tự Mục 4.3.2 trên BTXRD, PGA-UNet (512) được đánh giá chéo trên 4 phân vùng dữ liệu khác nhau của FracAtlas để xác minh kết quả không phụ thuộc vào một cách chia tập cụ thể. Do FracAtlas có ít ảnh test hơn BTXRD, số mẫu per-polygon mỗi fold dao động 89–95 thay vì cố định.

Bảng 4.21: Dice Score từng fold trong đánh giá chéo 4-fold PGA-UNet trên FracAtlas (kịch bản Zoom-out / Shift / Mixed)

Fold	N (mẫu)	Zoom-out↑	Shift↑	Mixed↑
Fold 1	89	0.8127	0.8025	0.8060
Fold 2	93	0.8026	0.7862	0.7981
Fold 3	95	0.8200	0.7930	0.8161
Fold 4	90	0.8222	0.7798	0.8082
Trung bình ± Std	–	0.8144 ± 0.0077	0.7904 ± 0.0084	0.8071 ± 0.0064

Nhận xét: Độ lệch chuẩn Dice qua 4 fold rất thấp (± 0.0077)

Bảng 4.22: Kết quả đánh giá chéo 4-fold PGA-UNet trên FracAtlas, 3 kịch bản câu nhắc (trung bình 4 fold)

Kịch bản	Dice $\uparrow$	IoU $\uparrow$	Precision $\uparrow$	Recall $\uparrow$	HD95 $\downarrow$	CBL $\uparrow$
Zoom-out	0.8144	0.6955	0.7735	0.8809	8.28	0.9541
Shift	0.7904	0.6627	0.7589	0.8460	9.57	0.9337
Mixed (70% Zoom-out + 30% Shift)	0.8071	0.6859	0.7671	0.8723	8.84	0.9476

ở Zoom-out, ± 0.0084 ở Shift), tương đương biên độ trên BTXRD ($\pm 0.0087/\pm 0.0119$), dù tập huấn luyện FracAtlas nhỏ hơn nhiều. Các chỉ số cross-validation rất gần tập test chính (Bảng 4.15: 0.8169/0.7850/0.8129, chênh lệch tuyệt đối đều dưới 0.006), xác nhận PGA-UNet trên FracAtlas cũng ổn định qua nhiều cách chia dữ liệu, không phải kết quả may rủi từ một lần chia cụ thể.

4.4.8 Đánh giá Gatekeeper trên FracAtlas

Tương tự Mục 4.7.1 trên BTXRD, một Gatekeeper (EfficientNet_B3, kiến trúc và quy trình huấn luyện hai giai đoạn giống hệt bản BTXRD) được huấn luyện để phân loại ảnh FracAtlas thành Bình thường/Có bệnh, đánh giá trên tập kiểm thử hỗn hợp **409 ảnh** (72 ảnh bệnh lý + 337 ảnh bình thường) – tỉ lệ mất cân bằng lớp rõ rệt hơn nhiều so với BTXRD (187 so với 188), phản ánh đúng tỉ lệ hiếm gặp của gãy xương trong toàn bộ 4.083 ảnh gốc của FracAtlas [9].

Phân tích, đối chiếu với BTXRD: Confusion matrix: TP=51, FP=27, FN=21, TN=310. AUC-ROC (0.9132) vẫn ở mức khá, gần BTXRD (0.9421), cho thấy Gatekeeper phân biệt bệnh/không bệnh khá tốt bất kể ngưỡng. Tuy nhiên, **Sensitivity trên FracAtlas (70.83%) thấp hơn rõ rệt BTXRD (89.30%)**: Gatekeeper bỏ sót 21/72 ảnh có gãy xương (29.17%), gần gấp 3 lần tỉ lệ bỏ sót của BTXRD (10.70%). Ngược lại, Specificity (91.99%) và NPV (93.66%) đều cao hơn BTXRD, phản ánh mất cân bằng lớp: chỉ 72/409 ảnh dương tính khiến mô hình thiên về dự đoán "bình thường". Đây là hạn chế riêng của FracAtlas:

Bảng 4.23: Kết quả đánh giá hiệu năng của Gatekeeper trên tập kiểm thử FracAtlas (N=409: 72 bệnh lý + 337 bình thường)

Độ đo đánh giá (Metrics)	Kết quả
Độ chính xác tổng thể (Accuracy)	88.26%
Độ chính xác (Precision / PPV)	65.38%
Độ nhạy (Recall / Sensitivity)	70.83%
Độ đặc hiệu (Specificity)	91.99%
Giá trị dự báo Âm tính (NPV)	93.66%
Điểm F1 (F1-Score)	68.00%
Diện tích dưới đường cong (AUC-ROC)	0.9132

đường gãy xương mảnh, khó nhận diện ở cấp độ phân loại toàn ảnh hơn khối u BTXRD, khiến vai trò sàng lọc của Gatekeeper kém tin cậy hơn trên miền dữ liệu này – càng củng cố lý do thiết kế *triage mềm* (bác sĩ luôn xác nhận lại) thay vì để Gatekeeper tự động quyết định.

4.4.9 Phân tích các ca bỏ sót trên FracAtlas

Tương tự Mục 4.7.2 trên BTXRD, phần này phân tích sâu hơn 21 ca FN của Gatekeeper trên FracAtlas, dùng dữ liệu per-image (`cls_prob`, `gt_label`) từ `results/pipeline_detail.csv` của lần chạy pipeline FracAtlas.

Đặc điểm của 21 ca FN: Xác suất dự đoán p dao động trong khoảng $[0,0269; 0,4863]$, trung bình 0,2540, trung vị 0,2687 – khác hẳn BTXRD (nơi không còn ca “suýt đúng” nào): trên FracAtlas có tới **5/21 ca (23,8%) rơi đúng vào vùng cận ngưỡng** $[0.4, 0.5)$, tức thực sự là các ca “suýt đúng”.

Khác BTXRD (nơi hơn một nửa số ca FN là dự đoán tự tin sai), trên FracAtlas số ca phân bố tương đối đều qua các khoảng, với gần một nửa (10/21, 47,6%) nằm trong vùng cận ngưỡng $[0.3, 0.5)$ – gợi ý việc hạ ngưỡng phân loại trên FracAtlas có tiềm năng cứu được nhiều ca FN hơn so với

Bảng 4.24: Phân bố xác suất dự đoán (cls_prob) của 21 ảnh FN trên FracAtlas theo khoảng cách tới ngưỡng 0.5

Khoảng xác suất dự đoán	Số ca (/21)
$p \in [0.4, 0.5)$: cận ngưỡng (“near-miss”)	5 (23,8%)
$p \in [0.3, 0.4)$	5 (23,8%)
$p \in [0.2, 0.3)$	3 (14,3%)
$p \in [0.1, 0.2)$	3 (14,3%)
$p < 0.1$: mô hình dự đoán tự tin (nhưng sai) là ảnh lành	5 (23,8%)

BTXRD.

Bảng 4.25: Đánh đổi Sensitivity/Specificity khi dịch chuyển ngưỡng phân loại của Gatekeeper trên FracAtlas

Ngưỡng	TP	FP	FN	TN	Sensitivity	Specificity
0.50 (mặc định)	51	27	21	310	70.83%	91.99%
0.40	56	41	16	296	77.78%	87.83%
0.30	61	51	11	286	84.72%	84.87%
0.20	64	81	8	256	88.89%	75.96%
0.10	67	132	5	205	93.06%	60.83%
0.05	69	181	3	156	95.83%	46.29%
0.01	72	271	0	66	100.00%	19.58%

Nhận xét, đối chiếu với BTXRD: Đường cong đánh đổi trên FracAtlas thuận lợi hơn BTXRD ở đoạn đầu: hạ ngưỡng từ 0.5 xuống 0.3 tăng Sensitivity từ 70.83% lên 84.72% (+13,89 điểm), Specificity chỉ giảm từ 91.99% xuống 84.87% (−7,12 điểm) – đánh đổi hợp lý hơn nhiều so với BTXRD (cùng khoảng ngưỡng không cứu được ca FN nào). Tuy nhiên, do FracAtlas mất cân bằng lớp nghiêm trọng hơn (72 bệnh / 337 lành so với 187/188 của BTXRD), hạ ngưỡng quá sâu gây sụp đổ Specificity

nhANH hơn: tại ngưỡng 0.01, dù Sensitivity đạt 100%, Specificity chỉ còn 19.58% (271/337 ảnh lành báo động nhầm), thấp hơn nhiều mức sụp đổ cùng ngưỡng trên BTXRD (60.11%) – trên miền dữ liệu càng lệch bệnh/lành, chỉ điều chỉnh ngưỡng càng dễ đánh đổi quá đắt, càng củng cố sự cần thiết của thiết kế triage mềm.

4.4.10 Đánh giá luồng xử lý đầu cuối trên FracAtlas

Tương tự Mục 4.7.4 trên BTXRD, luồng xử lý hai tầng (Gatekeeper $\rightarrow$ PGA-UNet) được đánh giá trên toàn bộ 409 ảnh hỗn hợp của FracAtlas, cùng công thức Pipeline Dice (mẫu số = ảnh TP + ảnh FP + ảnh FN, mỗi ảnh FP/FN đóng góp Dice = 0).

Nhận xét: Pipeline Dice end-to-end trên FracAtlas chỉ đạt **0.4230**, thấp hơn rất nhiều PGA-UNet độc lập (0.8169, Bảng 4.15) và thấp hơn đáng kể Pipeline Dice trên BTXRD (0.6763, Bảng 4.31). Khoảng cách này đến từ đúng hạn chế nêu ở Mục 4.4.8: Sensitivity thấp (70.83%) khiến 21/72 ảnh bệnh (29.17%) bị loại hoàn toàn khỏi luồng phân đoạn và gán Dice = 0, tỉ trọng cao hơn nhiều BTXRD (10.70%) – minh chứng rõ cho luận điểm sai số tích lũy của kiến trúc hai tầng (Mục 4.7.3): khi module sàng lọc hoạt động kém trên miền dữ liệu mới, toàn bộ hiệu năng đầu cuối bị kéo xuống bất kể module phân đoạn phía sau vẫn tốt (Dice trung bình trên ảnh TP vẫn đạt 0.8211, gần hiệu năng PGA-UNet độc lập). Khả năng tổng quát hóa liên miền của toàn hệ thống hai tầng phụ thuộc vào cả hai module, và Gatekeeper hiện là mắt xích yếu hơn khi áp dụng sang miền dữ liệu có đặc tính tổn thương khác biệt – hạn chế cần cải thiện trước khi mở rộng triển khai (Chương 5).

4.4.11 Thảo luận: hiệu quả của kiến trúc khi huấn luyện lại trên miền dữ liệu khác

Ba quan sát tổng hợp từ thực nghiệm FracAtlas (cả ba đều dựa trên PGA-UNet **đã được huấn luyện lại từ đầu trên FracAtlas**, không

Bảng 4.26: Kết quả luồng xử lý đầu cuối trên tập kiểm thử hỗn hợp FracAtlas (409 ảnh)

Thống kê	Giá trị
Tổng ảnh đầu vào	409 (72 có bệnh, 337 bình thường)
TP / FP / FN / TN (ảnh)	51 / 27 / 21 / 310
<i>Kết quả phân đoạn qua luồng xử lý (PGA-UNet, đánh giá cấp độ ảnh)</i>	
Dice trung bình thuần trên ảnh TP (tham khảo, có điều kiện Gatekeeper phân loại đúng)	0.8211
Ảnh FP (Dice = 0)	27 ảnh
Ảnh FN (Dice = 0, bệnh bị bỏ sót hoàn toàn)	21 ảnh
Mẫu số đầu cuối (TP + FP + FN)	$51 + 27 + 21 = \mathbf{99 \text{ đơn vị}}$
Pipeline Dice (đầu cuối)	0.4230
Pipeline IoU (đầu cuối)	0.3611
Tham khảo: cách tính bỏ qua FN (mẫu số = 78)	$\text{Dice} = 0.5369 / \text{IoU} = 0.4584$

phải mô hình BTXRD suy luận trực tiếp chưa tinh chỉnh):

- **Tổng quát hóa kiến trúc, không phải quá khớp vào BTXRD:** Dù huấn luyện lại hoàn toàn từ đầu trên bộ dữ liệu có nguồn gốc, đặc tính tổn thương và quy mô khác biệt (573 ảnh so với 1 493 ảnh, chỉ $\approx 38\%$), PGA-UNet vẫn đạt Dice > 0.78 ở mọi kích bản và cả hai độ phân giải, vượt U-Net với biên độ còn lớn hơn BTXRD (+0.4338 so với +0.3867) và vượt SAM-Med2D (FT) với biên độ +0.08–0.11 Dice (+0.28–0.29 so với chưa tinh chỉnh). Phân tích theo độ khó tác vụ (Bảng 4.18) cho thấy PGA-UNet gần như không đổi giữa nhóm dễ/khó trong khi U-Net sụp đổ ở nhóm khó – cùng khuôn mẫu trên BTXRD (Bảng 4.11), củng cố rằng lợi ích của PSG và CAD không phải hiện tượng quá khớp của một bộ dữ liệu, mà là đặc tính kiến trúc tổng quát.
- **Tính bền bỉ trước sai số câu nhắc được tái khẳng định ở cả hai độ phân giải:** Mức sụt Dice Zoom-out $\rightarrow$ Shift trên FracAtlas nhỏ ở cả 256 (-0.0268) và 512 (-0.0319), thấp hơn BTXRD cùng độ phân giải (-0.0372 tại 256) và thấp hơn cả SAM-Med2D (FT) trên FracAtlas (-0.0596) – cơ chế hướng dẫn mềm (Gaussian heatmap) ổn định qua các miền dữ liệu khác nhau.
- **SAM-Med2D đã tinh chỉnh cải thiện rõ rệt, nhưng PGA-UNet vẫn duy trì ưu thế:** Sau khi tinh chỉnh hội tụ đầy đủ (train Dice $0.6266 \rightarrow 0.8981$ qua 11 vòng lặp), SAM-Med2D (FT) vượt chưa tinh chỉnh +0.18–0.21 Dice ở cả ba kích bản (Bảng 4.17). Dù vậy, PGA-UNet vẫn vượt trội SAM-Med2D (FT) ở cả ba kích bản (+0.08–0.11 Dice) – lợi thế của kiến trúc nhẹ huấn luyện trực tiếp trên miền đích vẫn giữ vững ngay cả khi so với một SAM-Med2D đã tinh chỉnh đúng cách.
- **Đánh giá chéo 4-fold xác nhận tính ổn định, nhưng luồng xử lý đầu cuối lộ rõ hạn chế riêng của Gatekeeper trên miền dữ**

liệu mới: Đánh giá chéo 4-fold (Bảng 4.22) cho std thấp ($\pm 0.0077-0.0084$), xác nhận PGA-UNet ổn định trên FracAtlas không kém BTXRD. Tuy nhiên, Gatekeeper huấn luyện lại trên FracAtlas chỉ đạt Sensitivity 70.83% (so với 89.30% BTXRD) do đường gãy xương mảnh khó nhận diện hơn ở cấp độ phân loại toàn ảnh, kéo Pipeline Dice xuống 0.4230 (so với 0.6763 BTXRD) dù PGA-UNet trên các ảnh lọt qua đúng vẫn đạt Dice ≈ 0.82 – **khả năng tổng quát hóa của module phân đoạn không đồng nghĩa với khả năng tổng quát hóa của toàn hệ thống hai tầng:** Gatekeeper là mắt xích cần cải thiện thêm.


Về mức độ tổng quát hóa có thể kết luận: Kết quả trên chứng minh *thiết kế* PSG+CAD tiếp tục hiệu quả khi huấn luyện lại trên bộ dữ liệu, đặc tính tổn thương và quy mô khác biệt – dấu hiệu tổng quát hóa tốt ở cấp độ phương pháp **của riêng module phân đoạn**. Đây **chưa phải** bằng chứng tổng quát hóa liên miền theo nghĩa chặt (một mô hình duy nhất, huấn luyện một lần, suy luận tốt trên miền dữ liệu chưa từng thấy mà không tinh chỉnh), và quy mô tập test FracAtlas (N=72 ảnh) còn nhỏ. Quan trọng hơn, kết quả Gatekeeper/luồng xử lý đầu cuối cho thấy tính tổng quát hóa **không đồng đều giữa các module**: PGA-UNet tổng quát tốt, Gatekeeper thì không, nên tuyên bố tổng quát hóa cần giới hạn đúng phạm vi module phân đoạn, không suy rộng ra toàn hệ thống. Thí nghiệm chưa tinh chỉnh hai chiều (train BTXRD $\rightarrow$ test FracAtlas và ngược lại) là hướng đánh giá bổ sung cần thiết, nêu tại Chương 5.

4.5 Trực quan hóa kết quả

Bên cạnh các đánh giá định lượng bằng số liệu thống kê, việc quan sát trực tiếp kết quả phân đoạn mang ý nghĩa đặc biệt quan trọng trong lĩnh vực y khoa lâm sàng. Mục này trình bày các hình ảnh trực quan hóa nhằm minh họa rõ nét cách mô hình PGA-UNet xử lý các trường hợp phức tạp trong thực tế.

4.5.1 Trực quan hóa các kích bản phân đoạn tiêu biểu


Hình 4.10 minh họa hai ca kiểm thử tiêu biểu của PGA-UNet (kích bản Zoom-out): mặt nạ phân đoạn bám sát đường biên tổn thương nhờ cơ chế PSG và CAD dẫn đường từ bản đồ nhiệt câu nhắc.



Hình 4.10: Hai ca kiểm thử PGA-UNet, kích bản Zoom-out. Từ trái sang phải: ảnh gốc, ảnh kèm hộp giới hạn câu nhắc, mặt nạ dự đoán (Dice/IoU), Ground Truth, lớp phủ đối chiếu TP/FP/FN (Precision/Recall).

4.5.2 Đa dạng ca kiểm thử qua toàn bộ luồng xử lý


Hình 4.11 minh họa 6 ca kiểm thử tiêu biểu đi qua toàn bộ luồng xử lý (Gatekeeper $\rightarrow$ PGA-UNet) và được phân loại đúng là có bệnh (TP), Dice dao động 0.779–0.960. Mỗi hàng gồm 5 cột: ảnh gốc, ảnh kèm hộp giới hạn câu nhắc, mặt nạ dự đoán, Ground Truth, lớp phủ đối chiếu TP (xanh lá)/FP (đỏ)/FN (xanh dương). Các ca bao trùm nhiều vị trí giải phẫu (đầu gối, cổ tay, lồng ngực, xương chậu, vai), minh chứng khả năng khái quát của kiến trúc trên nhiều dạng tổn thương và vị trí chụp khác nhau.



Hình 4.11: 6 ca TP tiêu biểu qua toàn bộ luồng xử lý Gatekeeper → PGA-UNet trên dataset_online (BTXRD). Từ trái sang phải: ảnh gốc, hộp giới hạn câu nhắc, mặt nạ dự đoán, Ground Truth, lớp phủ TP/FP/FN.


4.5.3 Tính bền bỉ trước câu nhắc lệch tâm (Shift) và tổn thương kích thước nhỏ

Hình 4.12 minh họa hai ca kiểm thử ở kịch bản Shift (câu nhắc bị dịch chuyển lệch khỏi tâm tổn thương): ca trên có 4 tổn thương riêng biệt tại đầu gối, ca dưới có 2 tổn thương tại vùng vai/xương đòn. Ở cả hai ca, hộp giới hạn (khung cam) không bao trọn vẹn tổn thương như kịch bản Zoom-out lý tưởng, nhưng PGA-UNet vẫn giữ Dice lần lượt 0.851 và 0.894 – minh chứng tính bền bỉ đã trình bày ở Mục 4.7.4: mô hình dùng câu nhắc để thu hẹp vùng tìm kiếm chứ không ghi nhớ cứng vị trí tâm.



Hình 4.12: Hai ca kiểm thử ở kịch bản Shift (câu nhắc lệch tâm): đầu gối nhiều tổn thương (trên, Dice=0.851) và vai/xương đòn (dưới, Dice=0.894). Cột thứ hai cho thấy hộp giới hạn không bao trọn vẹn tổn thương thực tế.

Hình 4.13 minh họa một trường hợp tổn thương rất nhỏ (hộp giới hạn là dải mảnh hẹp ở cẳng chân): dù diện tích chiếm chưa đến 1% ảnh, PGA-UNet vẫn định vị và phân đoạn được với Dice=0.769, nhất quán với phát hiện ở Bảng 4.12 rằng PGA-UNet duy trì hiệu năng tốt hơn hẳn SAM-Med2D đúng ở nhóm tổn thương nhỏ.



Hình 4.13: Ca tổn thương kích thước nhỏ ở cẳng chân ($Dice=0.769$, $IoU=0.624$): PGA-UNet vẫn định vị và phân đoạn đúng dù vùng tổn thương chiếm diện tích rất nhỏ trong ảnh.

4.6 Giới hạn kiến trúc và phân tích trường hợp thất bại

Bên cạnh các kết quả tích cực đã trình bày, việc phân tích khách quan các trường hợp kiến trúc PGA-UNet hoạt động kém là cần thiết để đánh giá đúng giới hạn và định hướng cải tiến.

4.6.1 Trường hợp PGA-UNet dự đoán kém

Qua quá trình phân tích trên tập kiểm thử, ba nhóm trường hợp mà PGA-UNet cho kết quả phân đoạn dưới mức trung bình ($Dice < 0.70$) được nhận diện như sau:

- **Tổn thương có hình dáng bất thường:** Khối u dạng kéo dài, phân nhánh hoặc đường biên không liên tục vượt quá khả năng biểu diễn của bản đồ nhiệt Gaussian (dạng elip đối xứng), khiến mô hình có xu hướng “cắt tròn” đường biên thay vì bám sát hình dạng thực tế.
- **Vùng chồng lấp đa lớp xương dày đặc:** Tại các vị trí như khớp cổ chân nơi nhiều cấu trúc xương chồng lên nhau, đạo hàm cạnh bị nhiễu nghiêm trọng khiến bộ giải mã khó xác định ranh giới chính xác dù có câu nhắc hướng dẫn.
- **Ảnh chất lượng thấp:** Ảnh X-quang mờ, thiếu sáng hoặc có nhiễu

kỹ thuật (ký tự R/L, nhãn metadata, không qua bước loại nhiễu nào, Mục 3.2) làm suy giảm chất lượng đặc trưng mà bộ mã hóa trích xuất được.

Hình 4.14 minh họa trường hợp thuộc nhóm thứ hai: tổn thương nằm sát vùng vai/xương đòn, nơi lồng ngực và xương bả vai chồng lấp trên ảnh chiếu 2D. Dice chỉ đạt 0.762, thấp hơn đáng kể các ca ở vùng giải phẫu đơn giản hơn (Hình 4.11), dù câu nhắc đã chỉ đúng vị trí tổn thương.



Hình 4.14: Ca tổn thương tại vùng chồng lấp giải phẫu phức tạp (vai/xương đòn/lồng ngực), Dice=0.762 thấp hơn mức trung bình dù câu nhắc chính xác.

4.7 Đánh giá module Gatekeeper và luồng xử lý đầu cuối

Phần này trình bày đánh giá module Gatekeeper (EfficientNet_B3), thành phần hỗ trợ được tích hợp để lấp đầy khoảng trống giữa điều kiện huấn luyện và triển khai thực tế, cùng với đánh giá luồng xử lý đầu cuối trên dữ liệu hỗn hợp. Phân tích sai số tích lũy của luồng xử lý được trình bày tại Mục 4.7.3.

4.7.1 Đánh giá Gatekeeper (EfficientNet_B3)

Gatekeeper đảm nhận vai trò sàng lọc trong luồng xử lý đầu cuối: sàng lọc tự động ảnh X-quang đầu vào thành Bình thường (Âm tính) và Có bệnh lý bất thường (Dương tính). Đánh giá chính xác hiệu năng module này mang ý nghĩa quyết định, vì một dự đoán sai ở bước này có thể khiến

bệnh nhân bị lọt lưới sàng lọc mà không bao giờ tới được bước phân đoạn chi tiết phía sau.

Kiến trúc: EfficientNet_B3 tinh chỉnh hai giai đoạn. **EfficientNet_B3** [10] được tiền huấn luyện trên ImageNet-1K bằng chiến lược *compound scaling* (mở rộng đồng thời chiều rộng, chiều sâu, độ phân giải), gồm các khối MBConv kết hợp Squeeze-and-Excitation (SE). Với $\sim 10.7\text{M}$ tham số và đầu vào 300×300 , mô hình đạt cân bằng tốt giữa hiệu năng phân lớp và tốc độ suy luận. Tầng phân lớp gốc được thay bởi $\text{Linear}(1536, 1) + \text{Sigmoid}$, xuất xác suất $p \in (0, 1)$; ngưỡng $p \geq 0.5 \rightarrow$ dương tính.

Giai đoạn 1 (25 vòng lặp): Đóng băng mạng nền tảng, chỉ cập nhật tầng đầu ra với $\text{LR} = 10^{-4}$, giúp tầng đầu ra thích nghi không gian đặc trưng X-quang mà không phá hủy biểu diễn ImageNet.

Giai đoạn 2 (tối đa 100 vòng lặp, dừng sớm tại vòng lặp 68): Mở khóa toàn bộ, $\text{LR} = 10^{-5}$, CosineAnnealingLR. Hàm mất mát: BCEWithLogitsLoss; tối ưu: AdamW; dừng sớm: patience = 15 (theo Accuracy); giới hạn đạo hàm: max_norm = 1.0. Lưu song song hai điểm lưu trọng số: theo Loss tốt nhất và theo Accuracy tốt nhất.

Các độ đo đánh giá (Evaluation Metrics): Để có cái nhìn toàn diện, mô hình được đánh giá qua các độ đo tiêu chuẩn của bài toán phân loại nhị phân: Độ chính xác tổng thể (Accuracy), Độ chính xác (Precision), Độ bao phủ/Độ nhạy (Recall/Sensitivity), Độ đặc hiệu (Specificity) và Điểm F1 (F1-Score).

Trong bối cảnh y tế dự phòng và sàng lọc, **Độ nhạy (Recall)** là chỉ số ưu tiên hàng đầu: một mô hình sàng lọc tốt thà báo động nhầm (False Positive) để bác sĩ tốn thêm thời gian kiểm tra lại, còn hơn bỏ sót bệnh nhân thực sự có khối u (False Negative).

Phân tích kết quả: Bảng 4.27 tổng hợp hiệu năng Gatekeeper sau tinh chỉnh hai giai đoạn, đánh giá trên tập kiểm thử **dataset_online** (375 ảnh: 187 bệnh lý + 188 bình thường). Gatekeeper đạt hiệu năng ban đầu khá tốt và tương đối cân bằng giữa Sensitivity và Specificity, nhưng **chưa**

Bảng 4.27: Kết quả đánh giá hiệu năng của mô hình phân lớp sàng lọc trên tập kiểm thử

Độ đo đánh giá (Metrics)	Kết quả
Độ chính xác tổng thể (Accuracy)	87.73%
Độ chính xác (Precision / PPV)	86.53%
Độ nhạy (Recall / Sensitivity)	89.30%
Độ đặc hiệu (Specificity)	86.17%
Giá trị dự báo Âm tính (NPV)	89.01%
Điểm F1 (F1-Score)	87.90%
Diện tích dưới đường cong (AUC-ROC)	0.9421

đủ để tự động chặn ảnh âm tính một cách an toàn nếu không có thêm cơ chế bảo vệ:

- **AUC-ROC 0.9421:** Khả năng phân biệt bệnh/không bệnh khá tốt, bất kể ngưỡng.
- **Recall/Sensitivity 89.30%:** Phát hiện đúng $\approx 89\%$ ca bệnh, nhưng vẫn bỏ sót 20/187 ca (10.70%) – **chưa đủ an toàn** để tự động loại bỏ ảnh âm tính mà không có xác nhận của bác sĩ. Đặc điểm các ca này và đánh đổi khi hạ ngưỡng được phân tích tại Mục 4.7.2.
- **Specificity 86.17%:** Loại đúng $\approx 86\%$ ca bình thường (26/188 ảnh lành bị phân loại nhầm dương tính).
- **Precision 86.53%:** Khi báo dương tính, xác suất đúng $\approx 87\%$.
- **NPV 89.01%:** Khi kết luận "bình thường", xác suất thực sự không bệnh $\approx 89\%$ – cứ khoảng 9 ảnh "bình thường" thì có 1 ảnh thực chất có bệnh. Mức tin cậy này **chưa đủ để dùng làm bộ lọc sơ cấp độc lập**, một trong các lý do hệ thống thiết kế theo kiểu *triage mềm* với bác sĩ luôn xác nhận lại (Mục 3.1, Chương 3).

- **F1-Score 87.90%:** Cân bằng Precision/Recall, phù hợp dữ liệu cân bằng (187 vs 188), nhưng không phản ánh rủi ro lâm sàng riêng của nhóm FN.

Tóm lại, Gatekeeper là module sàng lọc **có hiệu năng ban đầu khả quan nhưng chưa đủ an toàn để vận hành như bộ chặn tự động độc lập**; tăng Sensitivity (giảm FN) nên là ưu tiên cải tiến hàng đầu trước khi cân nhắc giảm vai trò xác nhận của bác sĩ.

4.7.2 Phân tích các ca bỏ sót và thử nghiệm ngưỡng phân loại

Bảng 4.31 (Mục 4.7.4) cho thấy Gatekeeper bỏ sót 20/187 ảnh bệnh lý (FN) ở ngưỡng mặc định $p = 0.5$. Mục này phân tích sâu hơn đặc điểm các ca bị bỏ sót và thử nghiệm dịch chuyển ngưỡng để đánh giá đánh đổi Sensitivity/Specificity.

Lưu ý về phạm vi số liệu: Toàn bộ các phân tích trong mục này (phân bố xác suất dự đoán của các ca FN, thử nghiệm dịch chuyển ngưỡng, so sánh diện tích tổn thương FN so với TP) cùng phần lớn bảng chỉ số cấp độ tổn thương ở Mục 4.7.5 nay đã được **tính lại đầy đủ** trên cấu hình confusion matrix hiện tại (TP=167, FP=26, FN=20, TN=162): phân bố xác suất và threshold sweep dùng dữ liệu per-image (`cls_prob`, `gt_label`) từ `results/pipeline_detail.csv`; so sánh diện tích tổn thương và số lượng/recall/FNR cấp độ tổn thương dùng diện tích polygon đo trực tiếp từ JSON annotation gốc (`dataset_json/BTXRD`) đối chiếu với danh sách ảnh TP/FN trong CSV. Chỉ còn duy nhất 2 chỉ số Dice per-polygon ở cuối bảng Mục 4.7.5 (Dice trung bình từng tổn thương, tỉ lệ đạt ngưỡng $\text{Dice} \geq 0.5/0.7$) vẫn dùng số liệu từ cấu hình cũ, vì cần dữ liệu mặt nạ dự đoán chi tiết theo từng polygon mà CSV hiện có không cung cấp (chỉ có Dice gộp theo ảnh) – đã ghi chú lại tại đúng vị trí.

Đặc điểm của 20 ca FN: Xác suất dự đoán p của mô hình cho 20 ảnh này dao động trong khoảng $[0,0000; 0,2709]$, trung bình 0,1168, trung vị 0,0642, không có ca nào rơi vào vùng cận ngưỡng $[0.3, 0.5)$, tức **không**

còn ca “suýt đúng” nào trong cấu hình mới (khác với cấu hình cũ từng có 2 ca cận ngưỡng $[0.4, 0.5)$).

Bảng 4.28: Phân bố xác suất dự đoán (cls_prob) của 20 ảnh FN theo khoảng cách tới ngưỡng 0.5

Khoảng xác suất dự đoán	Số ca (/20)
$p \in [0.4, 0.5)$: cận ngưỡng (“near-miss”)	0 (0,0%)
$p \in [0.3, 0.4)$	0 (0,0%)
$p \in [0.2, 0.3)$	8 (40,0%)
$p \in [0.1, 0.2)$	1 (5,0%)
$p < 0.1$: mô hình dự đoán tự tin (nhưng sai) là ảnh lành	11 (55,0%)

Như vậy hơn một nửa số ca FN (11/20) không phải lỗi “suýt đúng” mà là ca mô hình dự đoán rất tự tin là bình thường (xác suất $< 0,1$) – hạ ngưỡng đơn thuần khó cứu được nhóm này; 8 ca còn lại (40%) rơi vào khoảng $[0.2, 0.3)$, chắc chắn hơn nhưng vẫn cách xa ngưỡng quyết định.

Tương quan với kích thước tổn thương (đã tính lại đầy đủ trên cấu hình hiện tại, $\text{TP}=167/\text{FP}=26/\text{FN}=20/\text{TN}=162$, dùng diện tích polygon đo trực tiếp từ JSON annotation gốc của 187 ảnh bệnh lý): So sánh diện tích tổn thương (tính theo % diện tích ảnh, tính bằng công thức shoelace trên tọa độ polygon GT) giữa nhóm bị bỏ sót (FN, 22 tổn thương trong 20 ảnh) và nhóm phát hiện đúng (TP, 210 tổn thương trong 167 ảnh):

Bảng 4.29: So sánh diện tích tổn thương (% diện tích ảnh) giữa nhóm FN và nhóm TP

Thống kê diện tích tổn thương	Nhóm FN (n=22)	Nhóm TP (n=210)
Trung vị (% diện tích ảnh)	0.186%	1.005%
Trung bình	0.287%	2.072%
Nhỏ nhất / Lớn nhất	0.019% / 1.389%	0.003% / 18.256%

Trung vị diện tích tổn thương ở nhóm FN chỉ bằng khoảng 18,5% trung vị nhóm TP (0.186% so với 1.005% diện tích ảnh); kiểm định Mann–Whitney U một phía (diện tích FN nhỏ hơn TP) cho $p = 2,4 \times 10^{-5}$, khác biệt rất có ý nghĩa. Các ca bị Gatekeeper bỏ sót **không phải lỗi ngẫu nhiên**, mà tương quan rõ với tổn thương kích thước nhỏ, nhất quán với hạn chế đã biết của mô hình phân loại toàn ảnh khi tín hiệu bất thường chỉ chiếm phần rất nhỏ diện tích đầu vào.

Thử nghiệm dịch chuyển ngưỡng phân loại: Bảng 4.30 khảo sát Sensitivity/Specificity khi hạ ngưỡng quyết định dương tính từ mặc định 0.5 xuống các mức thấp hơn (tính lại trên toàn bộ 375 ảnh của dataset_online).

Bảng 4.30: Đánh đổi Sensitivity/Specificity khi dịch chuyển ngưỡng phân loại của Gatekeeper

Ngưỡng	TP	FP	FN	TN	Sensitivity	Specificity
0.50 (mặc định)	167	26	20	162	89.30%	86.17%
0.40	167	32	20	156	89.30%	82.98%
0.30	167	35	20	153	89.30%	81.38%
0.20	175	39	12	149	93.58%	79.26%
0.10	176	46	11	142	94.12%	75.53%
0.05	179	55	8	133	95.72%	70.74%
0.01	180	75	7	113	96.26%	60.11%

Nhận xét: Không tồn tại ngưỡng nào cho phép tăng mạnh Sensitivity mà gần như không đánh đổi Specificity – đường cong khá thoải, không có điểm “miễn phí”. Hạ ngưỡng từ 0.5 xuống 0.3 **không cứu thêm được ca FN nào** (Sensitivity giữ 89.30%, vì không còn ca FN nào trong khoảng [0.3, 0.5), Bảng 4.28), trong khi Specificity giảm liên tục (86.17% $\rightarrow$ 81.38%) – đoạn ngưỡng này chỉ đánh đổi bất lợi. Phải hạ tới 0.2 mới bắt đầu cứu thêm ca FN (Sensitivity $\rightarrow$ 93.58%), đổi lại Specificity giảm còn 79.26%; hạ tiếp 0.1 cứu thêm 1 ca (94.12%) nhưng Specificity

còn 75.53%. Để loại gần hết FN (Sensitivity $\rightarrow$ 100%) cần ngưỡng gần bằng 0, tại đó Specificity sụp đổ (60.11% ở ngưỡng 0.01), mất phần lớn khả năng phân biệt của Gatekeeper. Do đó điều chỉnh ngưỡng không phải giải pháp triệt để; thiết kế triage mềm (Mục 3.1, Chương 3), nơi bác sĩ luôn xác nhận lại, là lớp phòng vệ bổ sung cần thiết bên cạnh cải thiện bản thân mô hình phân lớp.

Hậu quả khi Gatekeeper chặn nhầm một ca có bệnh (kịch bản không có xác nhận của bác sĩ): Trong kịch bản đánh giá thận trọng nhất của Mục 4.7.4 (không có bước bác sĩ xác nhận), mỗi ca FN đồng nghĩa một tổn thương thật – thường là tổn thương nhỏ (trung vị 0.226% diện tích ảnh) – hoàn toàn không được đưa vào PGA-UNet và bị tính Dice = 0 trong Pipeline Dice end-to-end. Trong hệ thống triển khai thực tế (Chương 3), hậu quả này chỉ xảy ra nếu bác sĩ cũng không phát hiện tổn thương khi xem lại ảnh gốc – rủi ro thuộc phạm trù *thiên kiến tự động hóa* chưa được đánh giá trong khóa luận này (nêu tại Chương 5).

4.7.3 Phân tích sai số tích lũy qua hai giai đoạn

Khi đánh giá **hệ thống đầu cuối** trên tập **dataset_online** (375 ảnh hỗn hợp, bao gồm 187 ảnh bệnh lý và 188 ảnh bình thường), sai số từ bước phân lớp lan truyền sang bước phân đoạn qua hai kênh, và cả hai kênh đều phải được tính là lỗi phân đoạn (Dice = 0) trong một chỉ số đầu cuối đúng nghĩa:

1. **Sai số Recall (FN):** Các ca bệnh bị Gatekeeper bỏ sót $\rightarrow$ không chuyển xuống PGA-UNet, bệnh nhân có tổn thương thật nhưng không được phân đoạn (20 ảnh FN, tương ứng Sensitivity = 89.30%). Đây là lỗi nghiêm trọng nhất trong một luồng xử lý y khoa và **phải được gán Dice = 0**, không thể loại khỏi mẫu số như một trường hợp “không tính”.
2. **Sai số Specificity (FP):** Các ảnh bình thường bị phân loại nhầm thành dương tính $\rightarrow$ PGA-UNet chạy nhưng không có GT mask (26

ảnh FP, tương ứng Specificity = 86.17%), cũng đóng góp Dice = 0 vào mẫu số.

Chất lượng phân đoạn thuần của PGA-UNet, tính *có điều kiện* ảnh đã được Gatekeeper chuyển đúng xuống (167/167 ảnh TP), đạt $\overline{\text{Dice}}_{\text{TP}} = 86.26\%$ – **không phải** hiệu năng thật của toàn hệ thống vì bỏ qua hoàn toàn 20 ảnh FN và 26 ảnh FP.

Phân rã theo từng kênh lỗi (mẫu số chỉ tính một kênh tại một thời điểm):

- Chỉ tính kênh FP (mẫu số = 167 TP + 26 FP = 193): Dice = **0.7464**: đây là con số từng được báo cáo là “Pipeline Dice”, nhưng thực chất bỏ hẳn 20 ảnh FN ra khỏi phép tính nên đo hiệu năng *cao hơn thực tế*.
- Chỉ tính kênh FN (mẫu số = 167 TP + 20 FN = 187, tương đương Sensitivity $\times \overline{\text{Dice}}_{\text{TP}} = 89.30\% \times 86.26\%$): Dice = **0.7704**.

Khi tính **đúng và đủ** trên toàn bộ 213 ảnh liên quan đến bước phân đoạn (167 TP + 26 FP + 20 FN), với cả FP lẫn FN đều đóng góp Dice = 0 vào mẫu số:

$$\text{Pipeline Dice}_{\text{end-to-end}} = \frac{\sum_{i \in \text{ảnh TP}} \text{Dice}_{\text{img}}(i)}{N_{\text{TP}} + N_{\text{FP}} + N_{\text{FN}}} = \frac{\sum \text{Dice}_{\text{TP}}}{167 + 26 + 20} = \mathbf{0.6763} \quad (4.5)$$

tức **thấp hơn 0.0701 điểm Dice** so với 0.7464 nếu bỏ qua FN, đúng như kỳ vọng vì phạt đầy đủ cả 20 ca bệnh bị bỏ sót hoàn toàn. Đây là chỉ số Pipeline Dice chính thức dùng trong Mục 4.7.4. Cải thiện đồng thời Sensitivity và Specificity là hướng ưu tiên tiếp theo (Chương 5).

4.7.4 Đánh giá luồng xử lý đầu cuối trên dữ liệu hỗn hợp

Để đánh giá luồng xử lý trong điều kiện thực tế, nơi không phải ảnh nào cũng có bệnh lý, hệ thống được chạy trên tập **dataset_online** (375

ảnh: 187 bệnh lý + 188 bình thường), ghép từ **tập kiểm thử của PGA-UNet** (187 ảnh bệnh lý, có chú thích đa giác) và **tập kiểm thử của EfficientNet_B3** (188 ảnh bình thường), cả hai thuộc phân vùng kiểm thử BTXRD (10%), đảm bảo không mô hình nào đã thấy các ảnh này khi huấn luyện.

Thiết kế đánh giá: Đánh giá này mô phỏng kịch bản **thận trọng nhất**: giả định gợi ý của Gatekeeper được làm theo tuyệt đối, không có bước bác sĩ xem lại như trong thiết kế *triage mềm* thực tế (Mục 3.1, Chương 3), nhằm đo cận dưới của hiệu năng đầu cuối trong trường hợp xấu nhất. Mỗi ảnh đi qua toàn bộ luồng xử lý (EfficientNet_B3 $\rightarrow$ PGA-UNet). Kết quả chia 4 trường hợp: TP (có JSON, dự đoán dương, PGA chạy thực tế), FP (không có JSON, dự đoán dương, Dice = 0 vì không có GT mask), FN (có JSON, dự đoán âm, không qua PGA, **Dice = 0 vì bệnh nhân có tổn thương thật không được phân đoạn**), TN (không có JSON, dự đoán âm, không tính vào mẫu số phân đoạn).

Pipeline Dice được tính trên *toàn bộ ảnh có liên quan đến nhiệm vụ phân đoạn*, tức mọi ảnh mà hệ thống **lẽ ra phải phân đoạn đúng** (mẫu số = ảnh TP + ảnh FP + ảnh FN), phản ánh đúng rủi ro lâm sàng khi cả sai số dương giả lẫn âm giả đều làm giảm chất lượng đầu cuối. Mỗi ảnh TP được tính một Dice cấp độ ảnh (max-merge predictions, union GT); mỗi ảnh FP và FN đóng góp 1 đơn vị với Dice = 0:

$$\text{Pipeline Dice} = \frac{\sum_{i \in \text{ảnh TP}} \text{Dice}_{\text{img}}(i)}{N_{\text{ảnh TP}} + N_{\text{ảnh FP}} + N_{\text{ảnh FN}}} \quad (4.6)$$

Nhận xét: Pipeline Dice end-to-end = **0.6763** (mẫu số 213 đơn vị: 167 TP, 26 FP, 20 FN, cả FP lẫn FN gán Dice = 0) phản ánh đúng và đủ hiệu năng tổng thể của luồng xử lý trên luồng ảnh hỗn hợp, kể cả các ca bị Gatekeeper bỏ sót hoàn toàn. Con số này thấp hơn PGA-UNet độc lập (0.8607) do hai nguồn suy giảm: (1) 26 ảnh bình thường bị phân loại sai (FP) đóng góp Dice = 0; (2) 20 ảnh bệnh bị bỏ sót hoàn toàn (FN) cũng

Bảng 4.31: Kết quả luồng xử lý đầu cuối trên tập dataset_online (hỗn hợp bình thường + có bệnh)

Thống kê	Giá trị
Tổng ảnh đầu vào	375 (187 có bệnh, 188 bình thường)
TP / FP / FN / TN (ảnh)	167 / 26 / 20 / 162
<i>Phân loại (EfficientNet_B3 trên dataset_online)</i>	
Sensitivity (Recall)	89.30%
Specificity	86.17%
Accuracy	87.73%
AUC-ROC	0.9421
<i>Kết quả phân đoạn qua luồng xử lý (PGA-UNet, đánh giá cấp độ ảnh)</i>	
Ảnh TP đưa vào PGA	167 ảnh
Dice trung bình thuần trên ảnh TP (tham khảo, có điều kiện Gatekeeper phân loại đúng)	0.8626
Ảnh FP (Dice = 0)	26 ảnh
Ảnh FN (Dice = 0, bệnh bị bỏ sót hoàn toàn)	20 ảnh
Mẫu số đầu cuối (TP + FP + FN)	$167 + 26 + 20 = \mathbf{213}$ đơn vị
Pipeline Dice (đầu cuối)	0.6763
Pipeline IoU (đầu cuối)	0.6003
Tham khảo: cách tính bỏ qua FN (mẫu số = 193)	Dice = 0.7464

đóng góp Dice = 0 thay vì bị loại khỏi phép tính. So với cách tính bỏ qua FN (0.7464), chỉ số đã sửa lại thấp hơn 0.0701 điểm, phản ánh trung thực hơn rủi ro lâm sàng: một ca bệnh bị Gatekeeper bỏ sót gây hậu quả tương đương một ca phân đoạn sai hoàn toàn, không phải trường hợp “không tính”. Đây là **kết quả thực nghiệm đầy đủ** trên dữ liệu hỗn hợp thực tế, minh chứng sai số tích lũy tất yếu của kiến trúc hai tầng.

Gatekeeper đạt AUC-ROC = 0.9421 trên dataset_online là bản lề để toàn hệ thống vận hành ổn định. Cải thiện đồng thời Sensitivity và Specificity (hiện ~87–89%) nhằm giảm cả FN lẫn FP là hướng ưu tiên phát triển tiếp theo (Chương 5).

4.7.5 Các chỉ số đầu cuối bổ sung: Sensitivity bệnh lý, FNR và Recall cấp độ tổn thương

Pipeline Dice end-to-end (Mục 4.7.4) là một chỉ số tổng hợp duy nhất, không đủ để thể hiện rủi ro lâm sàng cụ thể của một hệ thống sàng lọc y khoa. Phần này báo cáo bổ sung các chỉ số an toàn ở cấp độ ảnh và cấp độ từng tổn thương (lesion-level), tách bạch nguồn gốc rủi ro.

Cấp độ ảnh: Sensitivity bệnh lý (Recall) = **89.30%** (167/187 ảnh bệnh được Gatekeeper phát hiện đúng); False Negative Rate (FNR) = **10.70%** (20/187 ảnh bệnh bị Gatekeeper bỏ sót hoàn toàn).

Cấp độ tổn thương (lesion-level): Một ảnh có thể chứa nhiều đa giác tổn thương, nên chỉ số cấp độ ảnh có thể che khuất rủi ro thực sự trên từng tổn thương riêng lẻ. Số lượng tổn thương và tỉ lệ recall/FNR bên dưới **đã được tính lại đầy đủ** trên cấu hình confusion matrix hiện tại (TP=167, FP=26, FN=20, TN=162), đếm trực tiếp số polygon trong JSON annotation gốc của 187 ảnh bệnh lý. Riêng hai chỉ số Dice per-polygon (dòng cuối bảng) **vẫn dùng số liệu cũ** vì cần dữ liệu mặt nạ dự đoán chi tiết theo từng polygon mà CSV hiện có không cung cấp (chỉ có Dice gộp theo ảnh):

(*) *Ba chỉ số này vẫn dùng số liệu từ cấu hình confusion matrix trước đó (TP=166, FP=24, FN=21, TN=164), chưa tính lại được vì cần Dice*

Bảng 4.32: Các chỉ số đầu cuối bổ sung ở cấp độ tổn thương (lesion-level), tính trên 232 tổn thương của 187 ảnh bệnh lý trong dataset_online

Chỉ số	Giá trị
Tổng số tổn thương (đa giác) trong 187 ảnh bệnh	232 (210 trong 167 ảnh TP + 22 trong 20 ảnh FN)
Lesion-level Recall (tổn thương đến được PGA-UNet, không bị Gatekeeper bỏ sót)	90.52% (210/232)
Lesion-level FNR (tổn thương bị mất hoàn toàn do Gatekeeper)	9.48% (22/232)
Dice trung bình trên từng tổn thương riêng lẻ (167 ảnh TP, chưa gộp theo ảnh) (*)	0.8560
Tỉ lệ tổn thương đạt $\text{Dice} \geq 0.5$ trên toàn luồng xử lý (tổn thương bị FN tính là không đạt) (*)	89.66% (208/232)
Tỉ lệ tổn thương đạt $\text{Dice} \geq 0.7$ trên toàn luồng xử lý (tổn thương bị FN tính là không đạt) (*)	84.91% (197/232)

đo riêng từng polygon (không gộp theo ảnh) mà dữ liệu hiện có không cung cấp; do cấu hình mới chỉ lệch 1 ảnh so với cấu hình cũ ở mỗi kênh lỗi, các con số này nhiều khả năng vẫn xấp xỉ đúng nhưng chưa được xác nhận chính thức.

Nhận xét: Lesion-level Recall (90.52%) cao hơn nhẹ Sensitivity cấp độ ảnh (89.30%): 20 ảnh FN có trung bình 1.10 tổn thương/ảnh, thấp hơn 1.26 tổn thương/ảnh của 167 ảnh TP – Gatekeeper có xu hướng phát hiện đúng nhiều hơn ở ảnh có nhiều tổn thương. Tỷ lệ tổn thương đạt Dice ≥ 0.5 toàn hệ thống ước tính **89.66%** (208/232), giảm còn **84.91%** ở ngưỡng chặt hơn (Dice ≥ 0.7) – xem ghi chú (*) về phạm vi chưa xác nhận của hai con số này: cứ khoảng 6–10 tổn thương thì có 1 tổn thương bị Gatekeeper bỏ sót hoàn toàn hoặc bị PGA-UNet phân đoạn dưới ngưỡng chấp nhận được. Các chỉ số lesion-level và FNR phản ánh trực tiếp hơn hậu quả lâm sàng so với một Pipeline Dice tổng hợp duy nhất, nên được báo cáo song song khi đánh giá mức độ sẵn sàng của hệ thống.

CHƯƠNG 5

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1 Kết luận những đóng góp đạt được

Mục tiêu xuyên suốt của khóa luận là nghiên cứu, thiết kế và bước đầu phát triển một hệ thống phân đoạn tương tác ảnh X-quang xương, hỗ trợ bác sĩ đọc ảnh trong việc xác định và khoanh vùng tổn thương – vượt qua giới hạn của các phương pháp phân đoạn tự động hoàn toàn và rào cản tài nguyên của các mô hình nền tảng hạng nặng. Khóa luận đạt được các đóng góp kỹ thuật cụ thể sau:

- **Đề xuất kiến trúc PGA-UNet:** Khóa luận thiết kế thành công mô hình Prompt-Guided Attention U-Net ($\sim 3M$ tham số). Tích hợp Cổng không gian (PSG) tại nhánh mã hóa và Cơ chế chú ý có điều kiện (CAD) tại nhánh giải mã, hệ thống biến đổi thành công hộp giới hạn thành tín hiệu định hướng không gian sâu sát. Thực nghiệm trên $N=187$ ảnh cấp độ ảnh (BTXRD): PGA-UNet đạt **Dice = 0.8607** (Zoom-out), vượt U-Net (0.4740, +0.3867) và SAM-Med2D đã tinh chỉnh (0.7541, +0.1066) dù nhỏ hơn $\sim 30\times$ tham số. Câu nhắc Gaussian heatmap giúp duy trì Dice = 0.8423 ngay cả khi lệch tâm (Shift), chứng minh tính **bền vững trước sai lệch bbox có kiểm soát ở Zoom-out/Shift/Mixed** (Mục 5.2 nêu các dạng sai lệch bbox chưa được đánh giá, như bbox từ nhiều bác sĩ khác nhau hay bbox sai hoàn toàn vị trí). Phân tích nhóm nhỏ cho thấy lợi thế lớn nhất ở nhóm khó (PGA Dice = 0.8261 vs U-Net Dice = 0.0211, $\Delta=+0.8050$).
- **Đánh giá thực nghiệm toàn luồng xử lý đầu cuối:** Khóa luận xây dựng kịch bản đánh giá kết hợp Gatekeeper (EfficientNet_B3,

AUC-ROC = 0.9421) và PGA-UNet trên tập dữ liệu hỗn hợp 375 ảnh (cả bình thường và bệnh lý), phân bố gần thực tế hơn đánh giá phân đoạn đơn lẻ trên tập ảnh bệnh thuần túy. Đây là đóng góp thực nghiệm bổ sung, đo kích bản **thận trọng nhất** (giả định gợi ý Gatekeeper được làm theo tuyệt đối, chưa mô phỏng bước bác sĩ xác nhận của thiết kế triage mềm, Chương 3), tức cận dưới của hiệu năng hệ thống. Luồng xử lý đạt **Pipeline Dice end-to-end = 0.6763** (mẫu số 213 đơn vị: 167 TP + 26 FP + 20 FN, cả FP lẫn FN gán Dice = 0), suy giảm so với PGA-UNet độc lập (0.8607) do sai số tích lũy tất yếu của kiến trúc hai tầng, và là hướng ưu tiên cải tiến.

Nhìn chung, các kết quả trên khẳng định PGA-UNet là kiến trúc phân đoạn tương tác hạng nhẹ, hiệu quả và có cơ sở kỹ thuật vững chắc **trong phạm vi các thực nghiệm đã kiểm định**. Tuy nhiên, đây là hệ thống ở giai đoạn **thử nghiệm/tiền lâm sàng**, đánh giá trên bộ dữ liệu công khai với kịch bản câu nhắc mô phỏng có kiểm soát, chưa phải sản phẩm đã kiểm định đầy đủ để triển khai lâm sàng. Khóa luận **chưa** có đủ bằng chứng để khẳng định: (i) tính an toàn khi vận hành với bbox do bác sĩ thật vẽ tay hoặc bbox sai vị trí; (ii) độ tin cậy của Gatekeeper ở mức đủ để tự động hóa hoàn toàn bước sàng lọc mà không cần bác sĩ xác nhận lại; (iii) khả năng tổng quát hóa sang dữ liệu lâm sàng thô thu thập trực tiếp từ một cơ sở y tế cụ thể. Các hạn chế này được trình bày chi tiết ở Mục 5.2 và là cơ sở cho định hướng phát triển tại Mục 5.3.

5.2 Hạn chế của hệ thống

Mặc dù đạt được nhiều kết quả khả quan, hệ thống đề xuất vẫn còn tồn tại một số giới hạn nhất định cần được nhìn nhận khách quan:

- **Sai số tích lũy luồng xử lý hai giai đoạn:** Luồng xử lý hiện tại gồm hai module độc lập (Gatekeeper → PGA-UNet); sai số từ bước phân lớp lan truyền sang bước phân đoạn. Thực nghiệm trên tập

hỗn hợp 375 ảnh đạt Pipeline Dice end-to-end = 0.6763 (mẫu số 213 đơn vị: 167 TP + 26 FP + 20 FN, cả FP lẫn FN gán Dice = 0), thấp hơn đáng kể PGA-UNet đơn lẻ (0.8607). Nguồn suy giảm: 26 ảnh bình thường bị phân loại sai (FP, Specificity = 86.17%) và 20 ảnh bệnh bị Gatekeeper bỏ sót hoàn toàn (FN, Recall = 89.30%), cả hai đều phải phạt Dice = 0 thay vì loại khỏi phép tính – hạn chế cố hữu của kiến trúc hai giai đoạn và hướng ưu tiên cải tiến. Con số này đo kích bản thận trọng nhất (gợi ý Gatekeeper được làm theo tuyệt đối, không qua xác nhận con người); trong thiết kế triage mềm thực tế (Mục 3.1, Chương 3), bác sĩ luôn xem và xác nhận gợi ý, nên một ca FN không nhất thiết thành ca bị bỏ sót thực tế nếu bác sĩ phát hiện và bác bỏ gợi ý sai. Tuy nhiên, rủi ro con người quá tin tưởng gợi ý AI (thiên kiến tự động hóa) vẫn tồn tại và chưa được đánh giá trong khóa luận này.

- **Hạn chế của thông tin không gian 2D:** Ảnh X-quang là hình chiếu 2D của cấu trúc xương 3D phức tạp, sự chồng lấp giữa các khớp xương dày đặc đôi khi tạo tín hiệu đạo hàm gây nhiễu. Hộp giới hạn hình chữ nhật dù chuyển đổi thành Gaussian Heatmap vẫn mang tính ước lượng viền thô, có thể gặp khó khăn với khối u hình dáng kéo dài hoặc phân nhánh phức tạp.
- **Kiểm định đa tập dữ liệu mới ở bước đầu:** Ngoài BTXRD, khóa luận đã huấn luyện lại và đánh giá đầy đủ PGA-UNet (cả hai độ phân giải, ba kịch bản câu nhắc), U-Net baseline, ablation kiến trúc, đánh giá chéo 4-fold, Gatekeeper và luồng xử lý đầu cuối trên bộ dữ liệu độc lập thứ hai (FracAtlas, gãy xương, khác đặc tính hình thái với u xương BTXRD), xác nhận *thiết kế* PSG+CAD tiếp tục hiệu quả khi huấn luyện lại trên miền dữ liệu khác (Mục 4.4, Chương 4). Đây là dấu hiệu tổng quát hóa tốt ở cấp độ phương pháp, **chưa phải** kiểm định tổng quát hóa liên miền theo nghĩa chặt: mô hình được huấn luyện lại từ đầu trên FracAtlas (train/val/test riêng 573/72/72

ảnh), không phải một mô hình duy nhất huấn luyện trên BTXRD rồi suy luận trực tiếp chưa tinh chỉnh trên FracAtlas; thí nghiệm chưa tinh chỉnh hai chiều này vẫn còn thiếu. Đáng chú ý, tính tổng quát hóa **không đồng đều giữa các module**: PGA-UNet tổng quát tốt, nhưng Gatekeeper trên FracAtlas chỉ đạt Sensitivity 70.83% (so với 89.30% BTXRD), kéo Pipeline Dice xuống 0.4230 (Mục 4.4.10, Chương 4) dù PGA-UNet vẫn hoạt động tốt trên ảnh lọt qua đúng – module phân lớp sàng lọc là mắt xích cần cải thiện ưu tiên khi mở rộng sang miền dữ liệu mới. Hạn chế khác: cả hai bộ dữ liệu là ảnh công khai đã qua chuẩn hóa, chưa kiểm định trên dữ liệu thô thu thập trực tiếp từ một cơ sở y tế cụ thể; quy mô tập test FracAtlas (72 ảnh) cũng còn nhỏ.

- **Hạn chế về độ phân giải ảnh đầu vào:** Ảnh X-quang BTXRD gốc có kích thước 2.000–3.000 px mỗi chiều; chỉnh lại kích thước về 512×512 tương đương thu nhỏ còn $\frac{1}{4}-\frac{1}{6}$ diện tích gốc. Trên bản đồ đặc trưng tầng sâu nhất của U-Net ($\frac{512}{16} = 32 \times 32$), chi tiết cấu trúc xương nhỏ có thể mất hoàn toàn – yếu tố tiềm ẩn hạn chế hiệu năng, đặc biệt với tổn thương nhỏ.
- **Câu nhắc lý tưởng:** Hộp giới hạn $\mathbf{B}_i$ được sinh *tự động* từ mặt nạ nhãn gốc theo kịch bản Zoom-out và Shift có kiểm soát. Trong triển khai thực tế, bác sĩ vẽ hộp bằng tay không có nhãn gốc tham chiếu, hộp thực tế có thể rộng hơn hoặc lệch tâm hơn hai kịch bản mô phỏng. Mô hình chưa được kiểm định trên câu nhắc do bác sĩ thực sự tạo ra, và giả định 30% Shift trong kịch bản Mixed là ước lượng chưa có cơ sở thực nghiệm lâm sàng.

5.3 Định hướng phát triển tương lai

Từ những kết quả đạt được và các hạn chế còn tồn đọng, nhóm nghiên cứu đề xuất các định hướng phát triển tiếp theo nhằm hoàn thiện hệ thống:

- **Hướng 1: Mô hình đa phương thức tích hợp thông tin lâm sàng:** Hệ thống hiện tại chỉ xử lý tín hiệu hình ảnh (câu nhắc trực quan + ảnh X-quang), thiếu khả năng tận dụng ngữ cảnh lâm sàng mà bác sĩ đã có trước khi chụp. Hướng này đề xuất xây dựng **mô hình đa phương thức mới** kết hợp đặc trưng hình ảnh và đặc trưng lâm sàng phi hình ảnh (tuổi, giới tính, vị trí đau, thời gian khởi phát, tiền sử gia đình, xét nghiệm ALP, LDH) thành một luồng suy luận thống nhất, vẫn duy trì tốc độ phản hồi đủ nhanh cho môi trường lâm sàng.

Thông tin lâm sàng được mã hóa thành vector số học (qua bảng tra cứu hoặc một mô hình ngôn ngữ nhỏ) và dung hợp với đặc trưng hình ảnh qua cơ chế chú ý chéo hoặc phép cộng có trọng số. Kiến trúc này cải thiện đồng thời hai nhiệm vụ:

- **Phân lớp chính xác hơn:** Với ca biên giới mà tín hiệu hình ảnh đơn thuần không đủ phân biệt bình thường/bệnh lý, thông tin lâm sàng cung cấp ngữ cảnh bổ sung giúp giảm cả FP lẫn FN, hai nguồn suy giảm chính của Pipeline Dice hiện tại.
- **Phân đoạn có ngữ cảnh:** Biết trước tuổi bệnh nhân và giá trị ALP/LDH, mô hình có thể điều chỉnh độ nhạy với vùng nghi ngờ u, từng bước hướng tới hỗ trợ phân loại lành tính/ác tính dựa trên hình thái kết hợp hồ sơ lâm sàng.

Hướng này giải quyết đồng thời ba hạn chế: nâng hiệu năng phân lớp, tăng bối cảnh cho phân đoạn, và duy trì kiến trúc nhẹ đủ triển khai trên phần cứng y tế. Khi thông tin lâm sàng đã xác nhận rõ sự hiện diện khối u (sinh thiết, chẩn đoán trước đó), luồng phân lớp có thể được bỏ qua để đưa thẳng ảnh vào module phân đoạn, tránh rủi ro phân loại nhầm ca bệnh đã biết.

- **Hướng 2: Xử lý ảnh gốc không chỉnh lại kích thước:** Hạn chế kích thước đầu vào hiện tại (2.000–3.000 px về 512×512 , giữ lại $\frac{1}{4}$ – $\frac{1}{6}$

diện tích gốc) khiến tổn thương nhỏ có thể mất hoàn toàn ở tầng sâu nhất của bộ mã hóa. Hướng này tập trung **loại bỏ hoàn toàn bước chỉnh lại kích thước** để mô hình học trực tiếp trên ảnh gốc độ phân giải cao.

Hai phương án phù hợp: (a) *Cửa sổ trượt kết hợp ghép nối có nhận biết câu nhắc*: chia ảnh gốc thành patch chồng lấp (512×512 mỗi patch, bước trượt 256 px), chạy PGA-UNet trên từng patch với heatmap câu nhắc chiếu về tọa độ cục bộ, rồi hợp mặt nạ từ các patch; (b) *Bộ mã hóa phân cấp* (Swin Transformer, chú ý theo cửa sổ) học đặc trưng cục bộ chi tiết mà không tốn bộ nhớ bậc hai như ViT. Cả hai giữ nguyên module phân đoạn và cơ chế câu nhắc hiện có, chỉ thay bước tiền xử lý kích thước. Hướng này đặc biệt quan trọng cho nhóm *Tổn thương nhỏ* (Mục 4.3.3), nhóm hưởng lợi nhiều nhất từ bảo toàn độ phân giải.

- **Hướng 3: Học bán giám sát dựa trên câu nhắc thừa và thông tin lâm sàng:** Thực nghiệm hiện tại giả định mỗi ảnh huấn luyện có mặt nạ pixel-level đầy đủ, trong khi gán nhãn polygon do bác sĩ chuyên khoa thực hiện rất tốn kém và khó mở rộng. Hướng này giảm phụ thuộc vào nhãn đầy đủ bằng cách khai thác chính đặc tính PGA-UNet: mô hình vốn nhận hộp giới hạn làm câu nhắc, mà hộp giới hạn là loại nhãn rẻ hơn polygon rất nhiều.

Tập huấn luyện chia hai nhóm: một tập nhỏ có đầy đủ (ảnh, hộp giới hạn, mặt nạ pixel-level) huấn luyện có giám sát như hiện tại, và một tập lớn hơn chỉ có (ảnh, hộp giới hạn, thông tin lâm sàng) không có mặt nạ pixel-level. Với tập không nhãn pixel, PGA-UNet huấn luyện từ tập nhỏ dùng để sinh nhãn giả; thông tin lâm sàng (cùng nguồn với Hướng 1) đóng vai trò bộ lọc độ tin cậy: chỉ giữ nhãn giả tại ca có ngữ cảnh lâm sàng phù hợp dự đoán hình ảnh (ví dụ vị trí đau khớp vị trí mô hình khoanh vùng), loại bỏ nhãn giả ở ca có mâu thuẫn ngữ cảnh rõ ràng. Kết hợp ràng buộc nhất quán giữa các phép biến đổi

câu nhắc trên cùng ảnh (Zoom-out/Shift/Mixed, Chương 3), hướng này mở rộng quy mô tập huấn luyện mà không tăng tương ứng chi phí gán nhãn polygon – đặc biệt phù hợp khi mở rộng sang bộ dữ liệu mới như FracAtlas (Mục 4.4) nơi nhãn pixel-level đầy đủ không phải lúc nào cũng sẵn có.

TÀI LIỆU THAM KHẢO

- [1] Cambridge University Hospitals NHS Foundation Trust, *X-ray – Imaging & Radiology*, 2024. [Online]. Available: <https://www.cuh.nhs.uk/our-services/imaging-radiology/x-ray/> (visited on 01/01/2025).
- [2] O. Ronneberger, P. Fischer, and T. Brox, “U-Net: Convolutional Networks for Biomedical Image Segmentation,” in *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, Springer, 2015, pp. 234–241. DOI: 10.1007/978-3-319-24574-4_28.
- [3] G. Wang, M. A. Zuluaga, W. Li, *et al.*, “DeepIGeoS: A Deep Interactive Geodesic Framework for Medical Image Segmentation,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 41, no. 7, pp. 1559–1572, 2019. [Online]. Available: <https://arxiv.org/abs/1707.00652>.
- [4] C. Xu, L. Zhang, L. Wang, *et al.*, *Boundary-Aware Test-Time Adaptation for Zero-Shot Medical Image Segmentation*, 2025. [Online]. Available: <https://arxiv.org/abs/2512.04520>.
- [5] O. Oktay, J. Schlemper, L. L. Folgoc, *et al.*, “Attention U-Net: Learning Where to Look for the Pancreas,” in *Medical Imaging with Deep Learning (MIDL)*, 2018. [Online]. Available: <https://arxiv.org/abs/1804.03999>.
- [6] J. Cheng, J. Ye, Z. Deng, *et al.*, “SAM-Med2D,” *arXiv preprint arXiv:2308.16184*, 2023. [Online]. Available: <https://arxiv.org/abs/2308.16184>.
- [7] S. Yao, Y. Huang, X. Wang, *et al.*, “A Radiograph Dataset for the Classification, Localization, and Segmentation of Primary Bone

- Tumors,” *Scientific Data*, vol. 12, p. 88, 2025. DOI: 10.1038/s41597-024-04311-y.
- [8] H. Yang, X. Liang, Z. Li, *et al.*, *Prompt Mechanisms in Medical Imaging: A Comprehensive Survey*, 2025. [Online]. Available: <https://arxiv.org/abs/2507.01055>.
 - [9] I. Abedeen, M. A. Rahman, F. Zohra Prottyasha, T. Ahmed, T. M. Chowdhury, and S. Shatabda, “FracAtlas: A Dataset for Fracture Classification, Localization and Segmentation of Musculoskeletal Radiographs,” *Scientific Data*, vol. 10, p. 521, 2023. DOI: 10.1038/s41597-023-02432-4.
 - [10] M. Tan and Q. V. Le, “EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks,” in *International Conference on Machine Learning (ICML)*, 2019, pp. 6105–6114. [Online]. Available: <https://arxiv.org/abs/1905.11946>.