

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Thông Lúc - Nguyễn Hữu Bình

Phát triển hệ thống phân đoạn tổn thương
xương trên ảnh X-quang dựa trên câu nhắc
trực quan

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN CNTT
CHƯƠNG TRÌNH CHUẨN

Tp. Hồ Chí Minh, tháng 07/2026

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Thông Lúc - 22120196
Nguyễn Hữu Bình - 22120031

Phát triển hệ thống phân đoạn tổn thương
xương trên ảnh X-quang dựa trên câu nhắc
trực quan

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN CNTT
CHƯƠNG TRÌNH CHUẨN

GIẢNG VIÊN HƯỚNG DẪN

PGS.TS. Lý Quốc Ngọc

ThS. Đỗ Thị Thanh Hà

Tp. Hồ Chí Minh, tháng 07/2026

LỜI CAM ĐOAN

Chúng tôi xin cam đoan khóa luận này là kết quả làm việc và nghiên cứu của chính nhóm chúng tôi dưới sự hướng dẫn của giảng viên hướng dẫn. Các số liệu, kết quả thực nghiệm và phần trình bày trong báo cáo được thực hiện một cách trung thực. Những tài liệu, công trình hoặc ý tưởng có tham khảo từ nguồn khác đều đã được trích dẫn trong phần tài liệu tham khảo.

LỜI CẢM ƠN

Trước hết, chúng tôi xin cảm ơn PGS.TS. Lý Quốc Ngọc và ThS. Đỗ Thị Thanh Hà đã hướng dẫn nhóm trong suốt quá trình làm khóa luận. Trong thời gian thực hiện, thầy cô đã dành nhiều thời gian đọc, góp ý và chỉnh cho chúng tôi từ cách đặt vấn đề, cách làm thí nghiệm cho đến cách trình bày báo cáo. Nhiều lúc nhóm còn làm chưa chặt, suy nghĩ còn đơn giản, nhưng nhờ những góp ý thẳng và rõ của thầy cô mà chúng tôi dần nhìn ra vấn đề để sửa từng phần.

Chúng tôi cũng xin cảm ơn Khoa Công nghệ Thông tin, Trường Đại học Khoa học Tự nhiên, ĐHQG-HCM đã tạo điều kiện học tập trong suốt những năm đại học. Những môn học, những bài tập lớn và môi trường học tập tại trường là nền tảng quan trọng để chúng tôi có thể theo đuổi một hướng làm vừa có tính kỹ thuật, vừa có liên hệ đến ứng dụng trong y tế.

Ngoài ra, chúng tôi xin gửi lời cảm ơn đến gia đình, bạn bè và những người đã hỗ trợ, động viên trong thời gian nhóm thực hiện khóa luận. Quá trình làm khóa luận có nhiều giai đoạn khá áp lực, nhất là lúc chạy thí nghiệm, kiểm tra kết quả và chỉnh sửa báo cáo, nên sự động viên đó là điều rất cần thiết đối với chúng tôi.

Mặc dù đã cố gắng trong khả năng của mình, khóa luận này chắc chắn vẫn còn những chỗ chưa tốt và còn nhiều điểm lẽ ra có thể làm kỹ hơn. Chúng tôi mong sẽ tiếp tục nhận được góp ý từ quý thầy cô và hội đồng để hoàn thiện hơn về sau.

Thành phố Hồ Chí Minh, tháng 6 năm 2026

Nhóm sinh viên thực hiện
Thông Lúc (MSSV: 22120196)
Nguyễn Hữu Bình (MSSV: 22120031)



ĐỀ CƯƠNG KHOÁ LUẬN TỐT NGHIỆP

PHÁT TRIỂN HỆ THỐNG PHÂN ĐOẠN TỔN THƯƠNG XƯƠNG TRÊN ẢNH X-QUANG DỰA TRÊN CÂU NHẮC TRỰC QUAN

(Developing a bone lesion segmentation system on X-ray images based on visual prompts)

1 THÔNG TIN CHUNG

Người hướng dẫn:

- PGS.TS. Lý Quốc Ngọc (Khoa Công nghệ Thông tin)
- ThS. Đỗ Thị Thanh Hà (Khoa Công nghệ Thông tin)

Nhóm sinh viên thực hiện:

1. Nguyễn Hữu Bình (MSSV: 22120031)
2. Thông Lúc (MSSV: 22120196)

Loại đề tài: Nghiên cứu

Thời gian thực hiện: Từ 01/2026 đến 07/2026

2 NỘI DUNG THỰC HIỆN

2.1 Giới thiệu về đề tài

Ảnh X-quang là một phương thức cận lâm sàng rất phổ biến trong phát hiện các tổn thương xương như gãy xương, rạn xương và khối u xương nguyên phát. Ở các cơ sở y tế lớn, số lượng ảnh cần đọc mỗi ngày có thể rất nhiều, tạo áp lực lên thời gian và độ chính xác của quá trình chẩn đoán. Trong bối cảnh đó, bước khoanh vùng tổn thương vẫn thường được thực hiện thủ công trên hệ thống PACS, vừa tốn thời gian vừa phụ thuộc không ít vào kinh nghiệm của người thực hiện.

Các mô hình học sâu tự động như U-Net [1] thường gặp khó trên ảnh X-quang xương vì tổn thương có thể nhỏ, độ tương phản thấp và dễ bị lẫn với các cấu trúc xương lành. Trong khi đó, các mô hình nền tảng có dùng câu nhắc như SAM-Med2D [2] cho thấy một hướng tiếp cận đáng chú ý, nhưng kiến trúc lại khá nặng ($\sim 91\text{M}$ tham số), nên việc triển khai trên phần cứng thông thường không phải lúc nào cũng thuận lợi.

Từ đó, đề tài đề xuất xây dựng PGA-UNet (Prompt-Guided Attention U-Net), là một mô hình U-Net gọn hơn nhưng tích hợp câu nhắc hộp giới hạn vào cả bộ mã hóa và bộ giải mã. Ngoài ra, để minh họa khả năng ứng dụng thực tế hơn, PGA-UNet còn được đặt cùng với một mô hình phân lớp sàng lọc để tạo thành một luồng xử lý hỗ trợ.

2.2 Mục tiêu đề tài

1. Đề xuất và xây dựng kiến trúc PGA-UNet: Thiết kế mô hình phân đoạn nhẹ ($\sim 3\text{M}$ tham số) tích hợp câu nhắc hộp giới hạn qua Cổng không gian (PSG) tại bộ mã hóa và Cơ chế chú ý có điều kiện (CAD) tại bộ giải mã; mô hình được huấn luyện từ đầu trên cả hai bộ dữ liệu BTXRD [3] và FracAtlas [5] (đặc tính tổn thương khác nhau), kết hợp tăng cường câu nhắc (hộp giới hạn to hơn hoặc lệch nhẹ so với tổn thương) để tăng tính bền bỉ.

2. Mở rộng khả năng ứng dụng thực tế của PGA-UNet: Kết hợp PGA-UNet với một mô hình phân lớp nhị phân sàng lọc (EfficientNet-B3 [4]) thành một hệ thống hai giai đoạn nhằm hỗ trợ bác sĩ tốt hơn trên luồng ảnh hỗn hợp thực tế.
3. Thực nghiệm và đánh giá đa khía cạnh: So sánh PGA-UNet với U-Net [1], Attention U-Net [6] và SAM-Med2D [2] trên Dice, IoU, Precision, Recall, HD95 và CBL; phân tích bóc tách từng thành phần kiến trúc (PSG, CAD) và ảnh hưởng của kích thước ảnh đầu vào; đánh giá tính bền bỉ với câu nhắc không hoàn hảo nhưng nằm trong phạm vi hợp lý; đánh giá hệ thống trên tập dữ liệu hỗn hợp mô phỏng một phần điều kiện lâm sàng.

2.3 Phạm vi của đề tài

Phạm vi thực hiện:

- Dữ liệu: Hai bộ dữ liệu X-quang xương công khai, BTXRD [3] (khối u xương) và FracAtlas [5] (gãy xương), mang lại cái nhìn tổng quan hơn với nhiều dạng tổn thương khác nhau để khảo nghiệm kiến trúc.
- Bài toán: Phân đoạn nhị phân vùng tổn thương xương (mặt nạ cấp độ điểm ảnh) với câu nhắc hộp giới hạn.
- Đánh giá: So sánh với các mô hình (U-Net [1], Attention U-Net [6], SAM-Med2D [2]) và đánh giá hệ thống trên tập kiểm tra hỗn hợp.

Giới hạn:

- Chỉ xử lý ảnh X-quang hai chiều, không bao gồm CT hay MRI.
- Câu nhắc đầu vào là hộp giới hạn; chưa hỗ trợ câu nhắc dạng điểm hoặc văn bản.
- Hệ thống đóng vai trò hỗ trợ chẩn đoán, không thay thế quyết định lâm sàng của bác sĩ.

2.4 Cách tiếp cận thực hiện

Giai đoạn 1: Nghiên cứu tài liệu: Khảo sát các kiến trúc U-Net [1], Attention U-Net [6], SAM-Med2D [2]; tìm hiểu các cách đưa câu nhắc không gian vào mạng tích chập; đồng thời phân tích đặc điểm của hai bộ dữ liệu BTXRD [3] và FracAtlas [5].

Giai đoạn 2: Chuẩn bị dữ liệu: Tạo các tệp mặt nạ nhị phân tương ứng với ảnh từ các tệp chú thích, chuẩn hóa kích thước ảnh và chia tập huấn luyện/xác thực/kiểm tra.

Giai đoạn 3: Thiết kế và huấn luyện mô hình:

- Biểu diễn câu nhắc hộp giới hạn dưới dạng Bản đồ nhiệt làm mịn biên.
- PGA-UNet: tích hợp câu nhắc qua Cổng không gian (PSG) tại bộ mã hóa và Cơ chế chú ý có điều kiện (CAD) tại bộ giải mã.
- Huấn luyện từ đầu với hàm mất mát Dice + BCE, kết hợp tăng cường dữ liệu và tăng cường câu nhắc để cải thiện tính bền bỉ.
- EfficientNet-B3 tinh chỉnh hai giai đoạn cho bài toán phân lớp sàng lọc.

Giai đoạn 4: Thực nghiệm và đánh giá trên hai bộ dữ liệu: So sánh các chỉ số Dice/IoU/Precision/Recall/HD95/CBL với các mô hình cơ sở; thử nghiệm bóc tách từng thành phần kiến trúc; đánh giá mức độ ổn định với câu nhắc lệch tâm; và đánh giá thêm luồng xử lý toàn hệ thống trên tập hỗn hợp.

2.5 Kết quả dự kiến của đề tài

- Bộ dữ liệu đã xử lý: Tập ảnh BTXRD và FracAtlas gốc kèm nhãn phân đoạn và câu nhắc hộp giới hạn, chia sẵn tập huấn luyện/xác thực/kiểm tra cho cả hai bộ dữ liệu.
- Mô hình PGA-UNet: Kiến trúc $\sim 3M$ tham số, dự kiến đạt Dice $\geq 0,80$ và IoU $\geq 0,70$ trên tập kiểm tra với câu nhắc hợp lệ; thể hiện tính bền bỉ khi câu nhắc bị lệch tâm.

- Hệ thống: EfficientNet-B3 đạt $\text{AUC-ROC} \geq 0,90$; đánh giá hệ thống (Dice, IoU tính trên cả trường hợp âm tính giả) phản ánh sát điều kiện lâm sàng.
- Kết quả tổng quát hóa: Kỳ vọng kiến trúc PSG+CAD duy trì ưu thế so với các mô hình so sánh trên cả hai bộ dữ liệu, qua đó xác nhận mức độ tổng quát của thiết kế trên nhiều dạng tổn thương khác nhau.
- Báo cáo và mã nguồn: Báo cáo khóa luận hoàn chỉnh; bộ mã nguồn có chú thích đầy đủ, tái tạo được toàn bộ kết quả thực nghiệm.

2.6 Kế hoạch thực hiện

Giai đoạn	Nội dung	Thời gian
1	Nghiên cứu tài liệu; phân tích hai bộ dữ liệu BTXRD và FracAtlas	Tuần 1–3 (01/2026)
2	Tạo nhãn mặt nạ phân đoạn từ các tệp dữ liệu; chuẩn hóa kích thước ảnh; chia tập dữ liệu cho cả hai bộ dữ liệu	Tuần 4–7 (02/2026)
3	Thiết kế và huấn luyện PGA-UNet trên hai bộ dữ liệu; mô hình phân lớp EfficientNet-B3	Tuần 8–14 (03–04/2026)
4	Thực nghiệm so sánh; thử nghiệm bóc tách; đánh giá tính bền bỉ trên hai bộ dữ liệu	Tuần 15–18 (04–05/2026)
5	Đánh giá hệ thống trên tập hỗn hợp	Tuần 19–21 (05/2026)
6	Viết báo cáo khóa luận; chuẩn bị bảo vệ	Tuần 22–26 (06–07/2026)

TÀI LIỆU THAM KHẢO

- [1] O. Ronneberger, P. Fischer, and T. Brox, “U-Net: Convolutional Networks for Biomedical Image Segmentation,” in *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, Springer, 2015, pp. 234–241.
- [2] J. Cheng et al., “SAM-Med2D,” arXiv preprint arXiv:2308.16184, 2023.
- [3] S. Yao et al., “A Radiograph Dataset for the Classification, Localization, and Segmentation of Primary Bone Tumors,” *Scientific Data*, Nature, 2025.
- [4] M. Tan and Q. V. Le, “EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks,” in *Proc. International Conference on Machine Learning (ICML)*, 2019, pp. 6105–6114.
- [5] I. Abedeen et al., “FracAtlas: A Dataset for Fracture Classification, Localization and Segmentation of Musculoskeletal Radiographs,” *Scientific Data*, Nature, 2023.
- [6] O. Oktay et al., “Attention U-Net: Learning Where to Look for the Pancreas,” in *Proc. Medical Imaging with Deep Learning (MIDL)*, 2018. arXiv:1804.03999.

XÁC NHẬN
CỦA NGƯỜI HƯỚNG DẪN
(Ký và ghi rõ họ tên)

TP. Hồ Chí Minh, ngày... tháng... năm...
NHÓM SINH VIÊN THỰC HIỆN
(Ký và ghi rõ họ tên)

MỤC LỤC

Lời cam đoan	i
Lời cảm ơn	ii
Đề cương	iii
Mục lục	ix
Danh sách hình	xiii
Danh sách bảng	xvi
Tóm tắt	xviii
Danh mục các ký hiệu và chữ viết tắt	xx
Bảng đối chiếu thuật ngữ chuyên ngành Anh – Việt	xxiii
1 GIỚI THIỆU	1
1.1 Bối cảnh nghiên cứu	2
1.2 Động lực nghiên cứu	3
1.2.1 Động lực khoa học	3
1.2.2 Động lực thực tiễn	4
1.3 Phát biểu bài toán	4
1.4 Thách thức của bài toán	6
1.5 Đóng góp của khóa luận	7
1.6 Phạm vi nghiên cứu	8
1.7 Bố cục khóa luận	9

2	CÁC CÔNG TRÌNH LIÊN QUAN VÀ CƠ SỞ LÝ THUYẾT	11
2.1	Các công trình liên quan	11
2.1.1	Phân đoạn ảnh y khoa tự động	11
2.1.2	Phân đoạn tương tác dựa trên CNN	12
2.1.3	Mô hình nền tảng dựa trên câu nhắc	13
2.1.4	Khoảng trống nghiên cứu	15
2.2	Cơ sở kiến trúc nền tảng	15
2.2.1	Kiến trúc U-Net	15
2.2.2	Kiến trúc Attention U-Net	17
2.3	Biểu diễn và tích hợp câu nhắc trực quan	18
2.3.1	Biểu diễn không gian của câu nhắc	19
2.3.2	Điều biến đặc trưng theo tín hiệu điều kiện	20
2.3.3	Cơ chế chú ý có điều kiện	20
2.4	Các độ đo đánh giá	21
2.4.1	Hệ số Dice và chỉ số IoU	22
2.4.2	Precision và Recall	22
2.4.3	Khoảng cách Hausdorff 95%	23
2.4.4	Chỉ số định vị tâm CBL	24
2.5	Tổng kết chương	25
3	MÔ HÌNH VÀ HỆ THỐNG ĐỀ XUẤT	26
3.1	Mô hình phân đoạn PGA-UNet	26
3.1.1	Biểu diễn câu nhắc trực quan	27
3.1.2	Cổng không gian tại bộ mã hóa	29
3.1.3	Cơ chế chú ý có điều kiện trên kết nối tắt của nhánh giải mã	30
3.2	Quy trình huấn luyện và suy luận	32
3.2.1	Quy trình huấn luyện	33
3.2.2	Quy trình suy luận	35
3.3	Mở rộng luồng xử lý với mô-đun sàng lọc	36

3.3.1	Sàng lọc ảnh đầu vào	36
3.3.2	Phân đoạn có hướng dẫn	37
3.4	Tổng kết chương	39
4	THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ	40
4.1	Thiết lập môi trường thực nghiệm	40
4.1.1	Hai bộ dữ liệu ảnh X-quang và tiền xử lý đầu vào .	41
4.1.2	Mô hình so sánh và cấu hình huấn luyện	43
4.1.3	Phương pháp đánh giá cấp độ ảnh	45
4.2	Đánh giá hiệu năng kiến trúc PGA-UNet	46
4.2.1	So sánh với các mô hình cơ sở	47
4.2.2	So sánh với mô hình nền tảng SAM-Med2D	49
4.2.3	Hiệu quả tính toán	51
4.2.4	Ảnh hưởng của độ phân giải và sai lệch câu nhắc .	52
4.3	Tổng hợp đóng góp kiến trúc và tính nhất quán trên hai bộ dữ liệu	56
4.3.1	Đóng góp của PSG, CAD và bản đồ nhiệt Gaussian	56
4.3.2	Độ ổn định qua các phân vùng dữ liệu	58
4.3.3	Hiệu năng theo đặc tính tổn thương	58
4.3.4	Kết luận về phạm vi đóng góp kiến trúc	60
4.4	Đánh giá luồng xử lý hỗ trợ hai giai đoạn	61
4.5	Tổng kết chương	62
5	KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	63
5.1	Kết luận và đóng góp đạt được	64
5.2	Hạn chế của nghiên cứu	66
5.3	Định hướng phát triển	68
	Tài liệu tham khảo	70
	Phụ lục	76

A	PHÂN TÍCH CHUYÊN SÂU KIẾN TRÚC VÀ KHẢ NĂNG TỔNG QUÁT HÓA	77
A.1	Hiệu quả tính toán của PGA-UNet và SAM-Med2D	77
A.2	Phân tích trên BTXRD	79
A.2.1	Đóng góp của kiến trúc và câu nhắc	79
A.2.2	Đánh giá độ ổn định bằng đánh giá chéo	83
A.2.3	Phân tích theo đặc tính tổn thương	85
A.3	Phân tích trên FracAtlas	93
A.3.1	Đóng góp của kiến trúc và câu nhắc	93
A.3.2	Đánh giá độ ổn định bằng đánh giá chéo	97
A.3.3	Phân tích theo đặc tính tổn thương	99
A.4	Kết luận đóng góp kiến trúc trên hai miền dữ liệu	107
B	ĐÁNH GIÁ LUỒNG XỬ LÝ HAI GIAI ĐOẠN	111
B.1	Kết quả trên BTXRD	112
B.1.1	Hiệu năng của Gatekeeper	112
B.1.2	Ảnh hưởng đến luồng phân đoạn	113
B.2	Kết quả trên FracAtlas	116
B.2.1	Hiệu năng của Gatekeeper	116
B.2.2	Ảnh hưởng đến luồng phân đoạn	117

DANH SÁCH HÌNH

2.1	Kiến trúc SAM-Med2D với bộ mã hóa ảnh, bộ mã hóa câu nhắc, bộ giải mã mặt nạ và các lớp adapter thích ứng [13].	14
2.2	Kiến trúc U-Net với bốn cấp độ phân giải.	16
2.3	Kiến trúc Attention U-Net với các cổng chú ý tại các kết nối tắt.	18
3.1	Kiến trúc PGA-UNet với PSG tại bộ mã hóa và CAD trên các kết nối tắt của nhánh giải mã.	27
3.2	Luồng xử lý hỗ trợ gồm Gatekeeper và PGA-UNet.	38
4.1	Kết quả phân đoạn của PGA-UNet trong kịch bản Bao trọn. Từ trái sang phải: ảnh X-quang, hộp giới hạn câu nhắc, mặt nạ dự đoán, mặt nạ nhãn gốc và lớp phủ biểu diễn TP, FP và FN.	48
4.2	So sánh Dice của PGA-UNet và SAM-Med2D trong kịch bản Bao trọn trên BTXRD và FracAtlas. Các cấu hình đều sử dụng độ phân giải 256×256 và được đánh giá ở cấp độ ảnh.	51
4.3	Kết quả PGA-UNet tại hai độ phân giải trong ba kịch bản câu nhắc trên BTXRD và FracAtlas.	54
4.4	Kết quả PGA-UNet với câu nhắc Bao trọn và Lệnh tâm trên BTXRD (hàng trên) và FracAtlas (hàng dưới).	55
4.5	Trường hợp tổn thương tại vùng giải phẫu chông lấp ở vai, xương đòn và lồng ngực, với Dice đạt 0,762.	59
A.1	Biểu đồ tổng hợp sáu chỉ số hiệu quả tính toán giữa PGA-UNet và SAM-Med2D, trích từ notebook đo lường <code>measure_efficiency.ipynb</code>	78

A.2	Dice của tám cấu hình trong nghiên cứu loại bỏ thành phần trên BTXRD. PGA-UNet đạt kết quả cao nhất trong hai kịch bản Lệch tâm và Hỗn hợp.	83
A.3	Dice của U-Net và PGA-UNet trên nhóm U-Net hoạt động tốt và nhóm U-Net hoạt động kém.	86
A.4	Kết quả định tính của U-Net và PGA-UNet trên một ảnh thuộc mỗi nhóm hiệu năng của U-Net.	87
A.5	So sánh Dice của PGA-UNet và SAM-Med2D theo đặc tính tổn thương ở cùng độ phân giải 256×256 trên BTXRD. .	89
A.6	Kết quả định tính của SAM-Med2D, PGA-UNet ₂₅₆ và PGA-UNet ₅₁₂ trên một ảnh đại diện mỗi nhóm đặc tính tổn thương, BTXRD.	90
A.7	Ảnh hưởng của độ phân giải đến Dice của PGA-UNet theo ba nhóm đặc tính tổn thương trên BTXRD.	92
A.8	Tổng hợp Dice của SAM-Med2D và PGA-UNet (256×256 , 512×512) theo ba nhóm đặc tính tổn thương trên BTXRD.	92
A.9	Dice của tám cấu hình trong nghiên cứu loại bỏ thành phần trên FracAtlas. PGA-UNet đạt kết quả cao nhất trong hai kịch bản Lệch tâm và Hỗn hợp.	96
A.10	Minh họa định tính so sánh cấu hình PGA-UNet (Gaussian) với cấu hình dùng câu nhắc nhị phân trên BTXRD, tương ứng hai hàng cuối của Bảng A.2.	96
A.11	Minh họa định tính so sánh cấu hình PGA-UNet (Gaussian) với cấu hình dùng câu nhắc nhị phân trên FracAtlas, tương ứng hai hàng cuối của Bảng A.8.	97
A.12	Dice của U-Net và PGA-UNet trên nhóm TOP-DICE và BOTTOM-DICE, FracAtlas.	100
A.13	Kết quả định tính của U-Net và PGA-UNet trên một ảnh thuộc mỗi nhóm hiệu năng của U-Net, FracAtlas.	101
A.14	So sánh Dice của PGA-UNet và SAM-Med2D theo đặc tính tổn thương ở cùng độ phân giải 256×256 trên FracAtlas. .	103

A.15	Kết quả định tính của SAM-Med2D và PGA-UNet trên các ảnh đại diện thuộc ba nhóm đặc tính tổn thương trên FracAtlas.	104
A.16	Ảnh hưởng của độ phân giải đến Dice của PGA-UNet theo ba nhóm đặc tính tổn thương trên FracAtlas.	105
B.1	Một số kết quả phân đoạn của ảnh được Gatekeeper chuyển đúng sang PGA-UNet trên BTXRD. Từ trái sang phải: ảnh X-quang, hộp giới hạn, mặt nạ dự đoán, mặt nạ nhãn gốc và lớp phủ TP, FP, FN.	115

DANH SÁCH BẢNG

3.1	Các thành phần kế thừa và thiết kế trong PGA-UNet . . .	26
4.1	Thống kê phân bố hai bộ dữ liệu dùng trong thực nghiệm .	41
4.2	So sánh PGA-UNet với các mô hình cơ sở trên BTXRD ở độ phân giải 512×512 (N=187 ảnh)	47
4.3	So sánh PGA-UNet với các mô hình cơ sở trên FracAtlas ở độ phân giải 512×512 (N=72 ảnh)	47
4.4	So sánh PGA-UNet với SAM-Med2D trên BTXRD ở độ phân giải 256×256 (N=187 ảnh)	49
4.5	So sánh PGA-UNet với SAM-Med2D trên FracAtlas ở độ phân giải 256×256 (N=72 ảnh)	50
4.6	Kết quả PGA-UNet tại hai độ phân giải trên BTXRD (N=187 ảnh)	53
4.7	Kết quả PGA-UNet tại hai độ phân giải trên FracAtlas (N=72 ảnh)	53
4.8	Tổng hợp Dice của ba cấu hình chính trong nghiên cứu loại bỏ thành phần trên BTXRD và FracAtlas (ba kịch bản câu nhắc)	57
A.1	Bảng rút gọn từ <code>efficiency_comparison.csv</code> : so sánh hiệu quả tính toán giữa PGA-UNet và SAM-Med2D trong cùng môi trường thực nghiệm	78
A.2	Kết quả nghiên cứu loại bỏ thành phần trên BTXRD trong ba kịch bản câu nhắc (N=187 ảnh)	80
A.3	Dice Score từng Phân vùng trong đánh giá chéo 4-fold PGA-UNet (kịch bản Bao trọn / Lệch tâm / Hỗn hợp)	84
A.4	Kết quả đánh giá chéo 4-fold PGA-UNet trên 3 kịch bản câu nhắc (trung bình 4 fold)	84

A.5	So sánh PGA-UNet với U-Net theo mức hiệu năng của U-Net trên BTXRD (50 ảnh/nhóm)	85
A.6	So sánh PGA-UNet với SAM-Med2D theo đặc tính tổn thương ở cùng độ phân giải 256×256 trên BTXRD (Bao trọn, 50 ảnh/nhóm)	88
A.7	Ảnh hưởng của độ phân giải đối với PGA-UNet theo đặc tính tổn thương trên BTXRD (Bao trọn, 50 ảnh/nhóm) . .	91
A.8	Kết quả nghiên cứu loại bỏ thành phần trên FracAtlas trong ba kịch bản câu nhắc ($N=72$ ảnh)	93
A.9	Dice của PGA-UNet trên từng Phân vùng của FracAtlas trong ba kịch bản câu nhắc	98
A.10	Kết quả trung bình của đánh giá chéo 4-fold trên FracAtlas	98
A.11	So sánh PGA-UNet với U-Net theo mức hiệu năng của U-Net trên FracAtlas (36 ảnh/nhóm)	99
A.12	So sánh PGA-UNet với SAM-Med2D theo đặc tính tổn thương ở cùng độ phân giải 256×256 trên FracAtlas (Bao trọn, 24 ảnh/nhóm)	102
A.13	Ảnh hưởng của độ phân giải đối với PGA-UNet theo đặc tính tổn thương trên FracAtlas (Bao trọn, 24 ảnh/nhóm) .	103
A.14	Kiểm định Wilcoxon cho sáu cặp cấu hình trên BTXRD và FracAtlas. Δ Dice được tính bằng Dice của cấu hình thứ nhất trừ cấu hình thứ hai; các giá trị p chưa được hiệu chỉnh cho so sánh nhiều lần	107
B.1	Kết quả phân loại của Gatekeeper trên BTXRD	112
B.2	Kết quả mô phỏng luồng xử lý hai giai đoạn trên BTXRD	114
B.3	Kết quả phân loại của Gatekeeper trên FracAtlas	116
B.4	Kết quả mô phỏng luồng xử lý hai giai đoạn trên FracAtlas	118

TÓM TẮT

Khóa luận này nghiên cứu bài toán phân đoạn tổn thương xương trên ảnh X-quang theo hướng có tương tác với người dùng. Nói đơn giản hơn, thay vì để mô hình tự tìm hết mọi tổn thương trên ảnh, người dùng sẽ khoanh trước một hộp giới hạn sơ bộ rồi mô hình mới phân đoạn chi tiết hơn trong vùng đó. Cách làm này hợp với ảnh X-quang xương hơn vì tổn thương thường nhỏ, biên không rõ hoặc bị chồng với các cấu trúc giải phẫu khác.

Từ hướng làm đó, khóa luận đề xuất PGA-UNet (*Prompt-Guided Attention U-Net*), là một mô hình CNN gọn nhẹ với khoảng 3 triệu tham số. Hộp giới hạn được đổi thành một bản đồ nhiệt câu nhắc dạng cao nguyên, trong đó phần biên được làm mềm bằng bộ lọc Gaussian. Tín hiệu câu nhắc này được đưa vào bộ mã hóa qua Cổng không gian câu nhắc (PSG) và được dùng tiếp ở nhánh giải mã qua Cơ chế chú ý có điều kiện (CAD).

Mô hình được thực nghiệm trên hai bộ dữ liệu là BTXRD và FracAtlas. Phần đánh giá gồm so sánh với các mô hình cơ sở, nghiên cứu loại bỏ thành phần, đánh giá chéo và thử nghiệm với các câu nhắc bị sai lệch. Cũng cần nói trước là các kết quả trong khóa luận đều nằm trong thiết lập phân đoạn có hướng dẫn bằng hộp giới hạn, trong đó câu nhắc được tạo từ nhãn gốc để mô phỏng thao tác người dùng. Nói cách khác, khi so với U-Net và Attention U-Net thì kết quả chủ yếu phản ánh khác biệt giữa mô hình có câu nhắc và mô hình không có câu nhắc. Còn phép so sánh cùng điều kiện đầu vào thì chủ yếu được làm với SAM-Med2D ở độ phân giải 256×256 .

Trong thiết lập này, trên BTXRD ở độ phân giải 512×512 , PGA-UNet đạt Dice 0,8607, còn U-Net chỉ đạt 0,4740. Khi câu nhắc bị lệch tâm, mô hình vẫn giữ được Dice 0,8423. Với phép so sánh cùng điều kiện câu nhắc với SAM-Med2D tại độ phân giải 256×256 , PGA-UNet đạt Dice 0,8433, cao hơn mức 0,7541 của SAM-Med2D đã tinh chỉnh. Trên FracAtlas, mô

hình đạt Dice 0,8169 và xu hướng chung cũng gần như vậy. Phần ablation cũng cho thấy PSG, CAD và bản đồ nhiệt Gaussian khi đi cùng nhau giúp mô hình giữ kết quả ổn hơn khi câu nhắc bị sai lệch.

Ngoài ra, khóa luận còn đo hiệu quả tính toán trong cùng một môi trường thực nghiệm. Ở độ phân giải 256×256 , PGA-UNet nhỏ hơn SAM-Med2D khoảng 92 lần về số tham số, 11,9 lần về FLOPs và có độ trễ suy luận thấp hơn trên cả GPU lẫn CPU. Khóa luận cũng thử thêm một luồng xử lý hai giai đoạn bằng cách đặt mô-đun sàng lọc EfficientNet-B3 trước PGA-UNet. Phần này cho thấy nếu bước sàng lọc bỏ sót ảnh bệnh lý thì hiệu năng toàn hệ thống giảm đi rõ rệt.

Từ khóa: Phân đoạn ảnh y khoa, phân đoạn tương tác, câu nhắc trực quan, ảnh X-quang xương, PGA-UNet.

DANH MỤC CÁC KÝ HIỆU VÀ CHỮ VIẾT TẮT

Chữ viết tắt	Ý nghĩa
AG	Attention Gate (Cổng chú ý)
ALP	Alkaline Phosphatase (chỉ số xét nghiệm men gan/xương)
AUC-ROC	Area Under the Receiver Operating Characteristic Curve (Diện tích dưới đường cong ROC)
BCE	Binary Cross-Entropy (Entropy chéo nhị phân)
BTXRD	Bone Tumor X-Ray Dataset (bộ dữ liệu X-quang khối u xương)
CAD	Conditioned Attention Decoder (Cơ chế chú ý có điều kiện trên kết nối tắt của nhánh giải mã)
CBL	Center-Based Localization (Độ chuẩn xác định vị tâm)
CNN	Convolutional Neural Network (Mạng nơ-ron tích chập)
COCO	Common Objects in Context (định dạng chú thích/nhân ảnh)
CT	Computed Tomography (Chụp cắt lớp vi tính)
DSC	Dice Similarity Coefficient (Hệ số tương đồng Dice)
FN	False Negative (Âm tính giả)
FP	False Positive (Dương tính giả)
FT	Fine-tuned / Fine-tuning (Tinh chỉnh)
GAP	Global Average Pooling (Gộp trung bình toàn cục)
GPU	Graphics Processing Unit (Bộ xử lý đồ họa)
GT	Ground Truth (Nhãn gốc/Nhãn thực)

Chữ viết tắt	Ý nghĩa
HD / HD95	Hausdorff Distance / Khoảng cách Hausdorff 95%
IoU	Intersection over Union (Chỉ số giao trên hợp)
LDH	Lactate Dehydrogenase (chỉ số xét nghiệm)
LR	Learning Rate (Tốc độ học)
MBConv	Mobile Inverted Bottleneck Convolution
MRI	Magnetic Resonance Imaging (Chụp cộng hưởng từ)
NLP	Natural Language Processing (Xử lý ngôn ngữ tự nhiên)
NPV	Negative Predictive Value (Giá trị dự báo âm tính)
PACS	Picture Archiving and Communication System (Hệ thống lưu trữ và truyền hình ảnh y tế)
PGA-UNet	Prompt-Guided Attention U-Net (mô hình phân đoạn đề xuất của khóa luận)
PPV	Positive Predictive Value (Giá trị dự báo dương tính, đồng nghĩa với Precision)
PSG	Prompt Spatial Gate (Cổng không gian tại bộ mã hóa)
ReLU	Rectified Linear Unit (hàm kích hoạt)
ROC	Receiver Operating Characteristic
SAM	Segment Anything Model
SAM-Med2D	Phiên bản SAM tinh chỉnh cho ảnh y tế 2D, mô hình đối sánh chính trong khóa luận
SE	Squeeze-and-Excitation (khối trong kiến trúc EfficientNet)
SOTA	State-of-the-art (Hiện đại nhất)
TN	True Negative (Âm tính thật)
TP	True Positive (Dương tính thật)
ViT	Vision Transformer

Chữ viết tắt	Ý nghĩa
VRAM	Video Random Access Memory (Bộ nhớ đồ họa)
ZS	Zero-shot (không tinh chỉnh trên dữ liệu đích)

BẢNG ĐỐI CHIẾU THUẬT NGỮ CHUYÊN NGÀNH ANH – VIỆT

Trong phần nội dung chính, khóa luận cố gắng dùng tiếng Việt tương đối thống nhất để bài viết dễ đọc hơn. Tuy nhiên, do khóa luận thuộc lĩnh vực học sâu và ảnh y khoa nên vẫn có nhiều thuật ngữ tiếng Anh cần giữ lại hoặc dùng song song để tránh hiểu sai. Bảng dưới đây dùng để đối chiếu các thuật ngữ tiếng Việt được sử dụng trong báo cáo với thuật ngữ gốc tiếng Anh.

Đối với tên riêng của mô hình, kiến trúc hoặc các chỉ số đã quá quen thuộc trong tài liệu chuyên ngành như U-Net, PGA-UNet, SAM-Med2D, Dice, IoU, HD95, CBL, AUC-ROC, Precision, Recall..., khóa luận giữ nguyên cách viết gốc để đảm bảo thống nhất với tài liệu tham khảo.

Thuật ngữ tiếng Việt dùng trong khóa luận	Thuật ngữ gốc tiếng Anh
Bộ mã hóa	Encoder
Bộ giải mã	Decoder
Vòng lặp (huấn luyện)	Epoch
Điểm lưu trọng số	Checkpoint
Mạng nền tảng	Backbone
Lô (dữ liệu)	Batch
Tinh chỉnh / đã tinh chỉnh	Fine-tune / Fine-tuned
Chưa tinh chỉnh	Zero-shot
Cổng / tín hiệu cổng	Gate / Gating
Kết nối dư	Residual (connection)
Kết nối tắt	Skip connection

Thuật ngữ tiếng Việt dùng trong khóa luận	Thuật ngữ gốc tiếng Anh
Bản đồ đặc trưng	Feature map
Cơ chế chú ý	Attention
Cơ chế chú ý chéo	Cross-attention
Vector nhúng	Embedding
Cửa sổ lọc	Kernel
Huấn luyện	Training
Suy luận	Inference
Đệm	Padding
Đạo hàm	Gradient
Phần tử (rời rạc)	Token
Lớp thích ứng	Adapter
Miền dữ liệu	Domain
Hộp giới hạn	Bounding box
Câu nhắc	Prompt
Con người luôn giám sát trong vòng lặp (quyết định)	Human-in-the-loop
Luồng xử lý	Pipeline
Đầu cuối	End-to-end
Tính bền bỉ	Robustness
Quá khớp	Overfitting
Chỉnh lại kích thước (ảnh)	Resize
Bỏ qua (một bước xử lý)	Bypass
Thiên kiến tự động hóa	Automation bias
Hòa trộn sớm	Early fusion

Thuật ngữ tiếng Việt dùng trong khóa luận	Thuật ngữ gốc tiếng Anh
Tầng đầu ra (phân lớp)	(Classification) head
Cấp độ ảnh	Image-level
Cấp độ pixel	Pixel-level
Nhóm nhỏ (theo đặc tính)	Sub-category
Học sâu	Deep learning
Siêu tham số	Hyperparameter
Hàm chỉ thị	Indicator function
Đánh giá chéo	Cross-validation
Nối kênh	Concatenate
Gộp cực đại	Max pooling
Hàm mất mát	Loss function
Vùng nền (ảnh)	Background
Trọng số pha trộn	Blend weight
Siêu dữ liệu	Metadata

CHƯƠNG 1

GIỚI THIỆU

1.1

Bối cảnh nghiên cứu

Chụp X-quang là một kỹ thuật chẩn đoán hình ảnh rất quen thuộc trong khám chữa bệnh vì thao tác nhanh, chi phí không quá cao và có thể quan sát được cấu trúc xương mà không cần can thiệp xâm lấn. Ảnh X-quang thường được dùng để hỗ trợ phát hiện và theo dõi nhiều bất thường như gãy xương, rạn xương, thoái hóa khớp hoặc khối u xương. Lượng ảnh cần xử lý ở các cơ sở y tế cũng không hề nhỏ; chẳng hạn Cambridge University Hospitals ghi nhận hơn 174.000 lượt chụp X-quang mỗi năm, riêng khoa X-quang ngoại trú tiếp nhận khoảng 200–300 người mỗi ngày [1].

Trong bài toán phân tích ảnh y khoa, phân đoạn là bước xác định chính xác vùng tổn thương ở cấp độ điểm ảnh. Kết quả phân đoạn có thể hỗ trợ bác sĩ quan sát hình dạng tổn thương, ước lượng kích thước và theo dõi diễn tiến theo thời gian. Tuy vậy, nếu làm hoàn toàn thủ công thì công việc này khá tốn thời gian và đòi hỏi sự cẩn thận. Trên ảnh X-quang xương, vấn đề còn khó hơn vì có những tổn thương rất nhỏ, biên không rõ hoặc bị chồng lấp bởi các cấu trúc giải phẫu khác.

Những năm gần đây, học sâu được dùng nhiều trong xử lý ảnh y khoa và cho ra không ít kết quả tốt [2]–[4]. Từ các kiến trúc phân đoạn tổng quát như FCN [5], SegNet [6] và DeepLabv3+ [7], nhiều mô hình hợp với dữ liệu y khoa hơn đã được phát triển như V-Net [8], U-Net [9], UNet++ [10] và nnU-Net [11]. Gần đây hơn, Segment Anything Model (SAM) [12] và các biến thể cho ảnh y khoa như SAM-Med2D [13] mở ra hướng phân đoạn dựa trên câu nhắc trực quan, tức là người dùng có thể cung cấp điểm hoặc hộp giới hạn để định hướng vùng cần xử lý.

Trong khóa luận này, hướng phân đoạn có câu nhắc được chọn vì nó đứng ở khoảng giữa của hai bên: con người vẫn định vị sơ bộ, còn mô hình làm phần khoanh chi tiết ở cấp độ pixel. Cách tiếp cận này thực tế hơn so với việc bắt mô hình tự tìm toàn bộ tổn thương trên ảnh ngay từ đầu, nhất là khi ảnh X-quang xương vốn khó và dễ nhiễu. Nó cũng hợp với hướng

làm hệ thống hỗ trợ, tức là mô hình giúp người dùng làm nhanh hơn và đều tay hơn, chứ không thay hẳn người dùng chuyên môn [14]–[16].

1.2

Động lực nghiên cứu

1.2.1

Động lực khoa học

Trong thiết lập phân đoạn tự động, việc bắt mô hình vừa tìm tổn thương vừa phân đoạn nó trên ảnh X-quang xương không hề dễ. Nguyên nhân chính là ảnh thường có độ tương phản thấp, nhiều vùng bị chồng cấu trúc và tổn thương có thể rất nhỏ. Khi chuyển sang phân đoạn tương tác, người dùng có thể cung cấp thêm thông tin không gian, nhưng nếu câu nhắc chỉ được ghép với ảnh ngay từ đầu vào thì về sau tín hiệu này có thể yếu dần qua nhiều tầng tích chập. Vì vậy, một động lực quan trọng của khóa luận là tìm cách đưa câu nhắc vào sâu hơn trong mạng để nó vẫn còn tác dụng ở cả phân mã hóa lẫn giải mã.

Một vấn đề khác cũng rất đáng quan tâm là độ ổn định của mô hình. Trong thực tế, người dùng khó vẽ được một hộp giới hạn lúc nào cũng đẹp và sát hoàn toàn với tổn thương. Hộp có thể rộng hơn cần thiết hoặc hơi lệch tâm. Nếu mô hình bám quá cứng vào đường biên của hộp thì chỉ cần thao tác lệch một chút là kết quả sẽ giảm rõ rệt. Cho nên khóa luận hướng đến một cách biểu diễn câu nhắc mềm hơn và một cơ chế tiếp nhận linh hoạt hơn để mô hình chịu lỗi tốt hơn trong các tình huống hợp lý.

1.2.2

Động lực thực tiễn

Các mô hình nền tảng dựa trên Transformer có nhiều ưu điểm, nhưng thường nặng nề về số tham số và tài nguyên chạy. Nếu muốn triển khai trên phần cứng hạn chế hoặc trong các tình huống cần phản hồi nhanh thì đây là một trở ngại. So với hướng đó, một mô hình CNN gọn hơn nhưng tận dụng tốt hộp giới hạn đầu vào có lẽ hợp hơn cho một hệ thống hỗ trợ. Trong kịch bản mà khóa luận hướng đến, người dùng chỉ cần khoanh sơ bộ vùng nghi ngờ, xem kết quả, rồi nếu cần thì chỉnh lại hộp và chạy lại.

Từ các lý do trên, khóa luận tập trung xây dựng một mô hình phân đoạn ảnh X-quang xương theo ba tiêu chí chính: tận dụng được thông tin từ hộp giới hạn, giữ kết quả tương đối ổn khi câu nhắc bị lệch trong mức hợp lý và có kiến trúc đủ gọn để dễ huấn luyện, cũng như đỡ nặng hơn lúc triển khai.

1.3

Phát biểu bài toán

Bài toán chính của khóa luận là phân đoạn tương tác vùng tổn thương trên ảnh X-quang xương. Đầu vào của mô hình gồm ảnh X-quang:

$$\mathbf{I} \in \mathbb{R}^{H \times W} \quad (1.1)$$

và hộp giới hạn vùng nghi ngờ:

$$\mathbf{B} = (x_1, y_1, x_2, y_2), \quad (1.2)$$

trong đó (x_1, y_1) và (x_2, y_2) lần lượt là tọa độ góc trên bên trái và góc dưới bên phải. Hộp giới hạn được chuyển thành bản đồ nhiệt câu nhắc:

$$\mathbf{H}(\mathbf{B}) \in [0, 1]^{H \times W}. \quad (1.3)$$

Mục tiêu của mô hình là dự đoán mặt nạ nhị phân:

$$\widehat{\mathbf{M}} \in \{0, 1\}^{H \times W}, \quad (1.4)$$

trong đó giá trị 1 biểu thị điểm ảnh được dự đoán thuộc vùng tổn thương. Quá trình suy luận được biểu diễn bởi:

$$\widehat{\mathbf{M}} = \mathbf{1} [f_{\text{PGA}}(\mathbf{I}, \mathbf{H}(\mathbf{B}); \boldsymbol{\theta}) \geq 0,5], \quad (1.5)$$

trong đó f_{PGA} là PGA-UNet, $\boldsymbol{\theta}$ là bộ tham số học được và $\mathbf{1}[\cdot]$ là phép nhị phân hóa đầu ra xác suất tại ngưỡng 0,5.

Mô hình được kỳ vọng đáp ứng các yêu cầu sau:

- Dự đoán mặt nạ có mức độ chồng lấp cao với nhãn tham chiếu;
- Duy trì đường biên và vị trí vùng tổn thương;
- Duy trì hiệu năng tốt khi hộp giới hạn rộng hơn hoặc bị lệch khỏi vị trí lý tưởng;
- Có số lượng tham số và chi phí suy luận phù hợp với quá trình tương tác.

Trong giai đoạn huấn luyện, hộp giới hạn được tạo từ mặt nạ nhãn gốc rồi biến đổi theo một số kích bản mô phỏng. Khi suy luận, hộp sẽ do người dùng cung cấp. Do đó, kết quả thực nghiệm trong khóa luận phản ánh hành vi của mô hình trong thiết lập đã có thông tin định vị sơ bộ khá gần với tổn thương, chứ chưa thể xem là đánh giá đầy đủ cho trường hợp bác sĩ vẽ tự do trong thực tế. Phần đánh giá với câu nhắc thực tế được xem là hướng phát triển tiếp theo.

Ngoài bài toán phân đoạn chính, khóa luận còn có một thử nghiệm mở rộng với Gatekeeper dùng EfficientNet-B3. Thành phần này chỉ đóng vai trò gợi ý sàng lọc ảnh trước khi người dùng xác nhận và cung cấp hộp giới hạn. Nó không phải là đóng góp kiến trúc chính của khóa luận và cũng không thay thế quyết định của người dùng.

1.4

Thách thức của bài toán

Việc xây dựng một mô hình phân đoạn tương tác cho ảnh X-quang xương gặp bốn nhóm khó khăn chính:

- **Dữ liệu và chú thích:** Mặt nạ phân đoạn ở cấp độ điểm ảnh tốn nhiều thời gian để xây dựng, trong khi số lượng ảnh bệnh lý có chú thích thường hạn chế. Ngoài ra, một ảnh có thể chứa nhiều vùng tổn thương được biểu diễn bởi các đa giác riêng biệt, đòi hỏi quy trình tiền xử lý và đánh giá nhất quán.
- **Đặc điểm ảnh X-quang:** Ảnh X-quang có độ tương phản không đồng đều và chứa nhiều cấu trúc giải phẫu chồng lấp. Vùng khối u có thể có hình dạng bất thường, trong khi đường gãy thường nhỏ, mảnh và khó phân biệt với các đường biên xương tự nhiên.
- **Tích hợp và duy trì câu nhắc:** Mô hình cần khai thác thông tin không gian từ hộp giới hạn tại nhiều mức đặc trưng. Câu nhắc không nên chỉ ảnh hưởng tại đầu vào rồi suy giảm qua các tầng sâu, đồng thời cũng không được khiến mô hình phụ thuộc cứng vào đường biên hộp.
- **Độ ổn định và hiệu quả tính toán:** Mô hình cần duy trì hiệu năng khi câu nhắc bị lệch tâm hoặc thay đổi kích thước. Bên cạnh độ chính xác, kiến trúc phải đủ gọn để hỗ trợ suy luận lặp lại khi người dùng điều chỉnh hộp giới hạn.

1.5

Đóng góp của khóa luận

Đóng góp chính của khóa luận là đề xuất và đánh giá PGA-UNet, một kiến trúc CNN hạng nhẹ cho bài toán phân đoạn tương tác ảnh X-quang xương. Cụ thể hơn, khóa luận có các đóng góp sau:

1. Biểu diễn hộp giới hạn bằng bản đồ nhiệt dạng cao nguyên.

Hộp giới hạn được chuyển thành một bản đồ hai chiều có giá trị cao tương đối đều ở bên trong và được làm mềm ở phần biên bằng bộ lọc Gaussian. Cách biểu diễn này giúp mô hình không chỉ chú ý vào tâm hộp mà còn giữ được thông tin trên toàn bộ vùng câu nhắc. Hiệu quả của dạng Gaussian và dạng nhị phân được so sánh lại trong phần nghiên cứu loại bỏ thành phần.

2. Tích hợp câu nhắc vào bộ mã hóa bằng PSG.

Cổng không gian PSG (*Prompt Spatial Gate*) dùng bản đồ nhiệt để điều biến đặc trưng ở các tầng mã hóa. Có thể hiểu đơn giản là mô hình được nhắc phải chú ý nhiều hơn vào vùng mà người dùng đã khoanh, nhưng vẫn giữ đường truyền của đặc trưng ảnh gốc nhờ kết nối dư.

3. Điều kiện hóa bộ giải mã bằng CAD.

CAD (*Conditional Attention Decoder*) mở rộng cổng chú ý của Attention U-Net [17] bằng cách đưa thêm đặc trưng câu nhắc vào tín hiệu điều khiển. Nhờ đó, phần chú ý ở kết nối tắt không chỉ phụ thuộc vào đặc trưng ảnh mà còn phụ thuộc vào vùng người dùng đang quan tâm.

4. Đánh giá thiết kế trên hai bộ dữ liệu và nhiều điều kiện câu nhắc.

PGA-UNet được huấn luyện và đánh giá riêng trên BTXRD và FracAtlas, là hai bộ dữ liệu có dạng tổn thương khác nhau gồm khối u xương và gãy xương. Thực nghiệm bao gồm so sánh với U-Net, Attention U-Net và SAM-Med2D; đánh giá trong các kịch bản câu nhắc Bao trọn, Lệnh

tâm và Hỗn hợp; nghiên cứu loại bỏ thành phần; đánh giá chéo và phân tích theo từng nhóm tổn thương.

5. Khảo sát khả năng tích hợp vào luồng xử lý hỗ trợ.

Khóa luận bổ sung Gatekeeper như một thử nghiệm mở rộng để minh họa cách PGA-UNet có thể đặt trong một luồng xử lý gồm cả ảnh bình thường và ảnh bệnh lý. Thành phần này chỉ có ý nghĩa hỗ trợ sàng lọc, không được xem là đóng góp kiến trúc độc lập.

Trong các nội dung trên, phần cốt lõi nhất vẫn là cách phối hợp giữa biểu diễn câu nhắc, PSG và CAD. Hiệu quả của từng phần sẽ được kiểm tra lại bằng thực nghiệm ở Chương 4.

1.6

Phạm vi nghiên cứu

Khóa luận giới hạn trong phạm vi sau:

- nghiên cứu phân đoạn ảnh X-quang xương hai chiều;
- sử dụng ảnh bệnh lý có mặt nạ cấp độ điểm ảnh để huấn luyện mô-đun phân đoạn;
- sử dụng hộp giới hạn làm dạng câu nhắc trực quan chính;
- đánh giá trên hai bộ dữ liệu công khai BTXRD và FracAtlas;
- mô phỏng sai lệch câu nhắc bằng các phép mở rộng và dịch chuyển hộp giới hạn theo quy tắc có kiểm soát, không thay thế cho đánh giá với câu nhắc thực do người dùng cung cấp;
- chưa thực hiện thử nghiệm với câu nhắc do bác sĩ vẽ trực tiếp hoặc dữ liệu thô được thu thập tại cơ sở y tế;

- Gatekeeper chỉ được khảo sát như một thành phần hỗ trợ, không phải hệ thống chẩn đoán tự động.

Các kết quả trong khóa luận chỉ phản ánh hiệu năng kỹ thuật trong điều kiện thực nghiệm có kiểm soát. Chúng không được dùng như kết luận chẩn đoán và cũng chưa đủ để khẳng định hệ thống đã sẵn sàng cho triển khai lâm sàng.

1.7

Bố cục khóa luận

Khóa luận được trình bày trong năm chương:

- **Chương 1 – Giới thiệu:** Trình bày bối cảnh, động lực, bài toán nghiên cứu, các thách thức, đóng góp và phạm vi của khóa luận.
- **Chương 2 – Các công trình liên quan và cơ sở lý thuyết:** Khảo sát phân đoạn ảnh y khoa tự động, phân đoạn tương tác và mô hình nền tảng dựa trên câu nhắc; trình bày cơ sở về U-Net, cơ chế chú ý, biểu diễn câu nhắc, điều biến đặc trưng và các độ đo đánh giá.
- **Chương 3 – Mô hình và hệ thống đề xuất:** Trình bày kiến trúc PGA-UNet, gồm bản đồ nhiệt câu nhắc dạng cao nguyên, PSG và CAD; đồng thời mô tả quy trình huấn luyện, suy luận và luồng xử lý hỗ trợ với Gatekeeper.
- **Chương 4 – Thực nghiệm và đánh giá:** Trình bày dữ liệu, cấu hình huấn luyện, kết quả so sánh với các mô hình cơ sở và SAM-Med2D, mức độ ổn định dưới sai lệch câu nhắc mô phỏng, tóm tắt các kết luận chính về đóng góp kiến trúc và tính nhất quán trên hai bộ dữ liệu, cùng tóm tắt thử nghiệm mở rộng với Gatekeeper. Toàn bộ bảng số liệu chi tiết của nghiên cứu loại bỏ thành phần, đánh giá chéo và phân tích theo đặc

tính tổn thương được trình bày tại Phụ lục A; số liệu chi tiết của luồng xử lý hai giai đoạn với Gatekeeper được trình bày tại Phụ lục B.

- **Chương 5 – Kết luận và hướng phát triển:** Tổng hợp các kết quả đạt được, chỉ ra hạn chế của nghiên cứu và đề xuất các hướng phát triển tiếp theo.

CHƯƠNG 2

CÁC CÔNG TRÌNH LIÊN QUAN VÀ CƠ SỞ LÝ THUYẾT

Chương này gồm hai phần chính. Phần đầu điểm lại các hướng nghiên cứu có liên quan đến phân đoạn ảnh y khoa, nhất là các mô hình tự động, các phương pháp phân đoạn tương tác dựa trên CNN và các mô hình nền tảng có dùng câu nhắc. Từ phần này, khóa luận rút ra khoảng trống mà khóa luận muốn đi vào. Phần sau trình bày các cơ sở lý thuyết cần dùng như U-Net, cơ chế chú ý, cách biểu diễn câu nhắc trực quan và các chỉ số đánh giá mô hình.

2.1

Các công trình liên quan

2.1.1

Phân đoạn ảnh y khoa tự động

Trước khi U-Net trở thành một kiến trúc gần như quen mặt trong phân đoạn ảnh y khoa, các phương pháp phân đoạn ngữ nghĩa bằng học sâu đã đi theo nhiều hướng khác nhau. Có thể kể đến các mạng tích chập thuần như FCN [5], các mô hình mã hóa–giải mã như SegNet [6], hoặc các kiến trúc khai thác ngữ cảnh đa tỉ lệ như DeepLabv3+ [7]. Có thể xem đây là những bước nền để các mô hình phân đoạn về sau phát triển mạnh hơn [4].

U-Net [9] là một trong những kiến trúc quan trọng nhất của phân đoạn ảnh y khoa. Mô hình có dạng mã hóa–giải mã đối xứng và dùng các kết nối tắt để giữ lại thông tin vị trí từ các tầng nông trong lúc vẫn học được đặc trưng ngữ nghĩa ở các tầng sâu. Thiết kế này hợp với dữ liệu y khoa, vốn thường không có quá nhiều ảnh được gán nhãn phân đoạn.

Attention U-Net [17] phát triển tiếp từ U-Net bằng cách thêm các Cổng chú ý ở các kết nối tắt. Ý tưởng ở đây là mô hình học cách ưu tiên những vùng quan trọng hơn trước khi đặc trưng được chuyển sang bộ giải mã. Nhờ vậy, mô hình có thể tập trung tốt hơn vào cấu trúc cần phân đoạn mà không cần thêm một mạng định vị riêng.

Tuy nhiên, ở dạng gốc thì cả U-Net lẫn Attention U-Net đều là các mô hình tự động, nghĩa là chỉ nhận ảnh đầu vào và phải tự tìm vùng cần phân đoạn. Với ảnh X-quang xương, đây là một yêu cầu không hề nhẹ vì tổn thương có thể nhỏ, mờ hoặc nằm trong vùng nhiễu cấu trúc chồng lấp. Ngoài ra, người dùng cũng khó can thiệp để hướng mô hình tập trung vào một vùng cụ thể tại thời điểm suy luận.

Sau U-Net, nhiều biến thể được đề xuất để cải thiện hiệu năng hoặc giảm công sức tinh chỉnh thủ công. Chẳng hạn, UNet++ [10] thiết kế lại các đường nối tắt theo dạng lồng nhau để thu hẹp khoảng cách ngữ nghĩa giữa bộ mã hóa và bộ giải mã, còn nnU-Net [11] nhấn mạnh rằng hiệu năng trong ảnh y khoa không chỉ đến từ kiến trúc mạng mà còn đến từ quy trình cấu hình, tiền xử lý và hậu xử lý. Điều này cũng nhắc rằng bài toán phân đoạn y khoa không phụ thuộc vào một mô-đun đơn lẻ.

2.1.2

Phân đoạn tương tác dựa trên CNN

Phân đoạn tương tác cho phép người dùng cung cấp thông tin bổ sung như điểm bấm [14], nét vẽ hoặc hộp giới hạn để hướng mô hình đến vùng cần xử lý. Thông tin tương tác thường được chuyển thành một hoặc nhiều bản đồ không gian và đưa vào CNN cùng với ảnh.

Các phương pháp tương tác ban đầu thường khai thác tín hiệu người dùng ở dạng điểm bấm hoặc nét vẽ. Deep Interactive Object Selection [14] là một ví dụ sớm cho thấy chỉ với những tương tác đơn giản, nếu mã hóa phù hợp thành bản đồ khoảng cách rồi đưa vào CNN thì chất lượng mặt nạ có thể tăng đáng kể. Trong ảnh y khoa, DeepIGeoS [15] là một ví dụ tiêu biểu. Cách làm của phương pháp này là tạo một phân đoạn ban đầu,

sau đó dùng thêm tương tác người dùng để tinh chỉnh lại những vùng còn sai.

Nhìn chung, các phương pháp này cho thấy tương tác của người dùng hoàn toàn có thể đổi thành bản đồ hai chiều và đưa trực tiếp vào CNN. Dù vậy, nếu chỉ ghép bản đồ đó ở đầu vào thì chưa chắc thông tin định hướng còn rõ ở các tầng sâu hơn của mạng. Đây cũng là một lý do để khóa luận đi tiếp theo hướng tích hợp câu nhắc sâu hơn vào quá trình mã hóa và giải mã đặc trưng.

2.1.3


Mô hình nền tảng dựa trên câu nhắc

Segment Anything Model (SAM) [12] là mô hình nền tảng cho phân đoạn ảnh tự nhiên, hỗ trợ nhiều dạng câu nhắc như điểm, hộp giới hạn và mặt nạ. Kiến trúc gồm bộ mã hóa ảnh, bộ mã hóa câu nhắc và bộ giải mã mặt nạ. Cách tổ chức này cho phép một mô hình thực hiện nhiều tác vụ phân đoạn mà không cần thiết kế lại kiến trúc cho từng loại đối tượng.

Do ban đầu được huấn luyện chủ yếu trên ảnh tự nhiên, SAM có thể gặp khó khi đem dùng trực tiếp cho ảnh y khoa. Vì vậy, SAM-Med2D [13] được phát triển để thích nghi SAM với ảnh y khoa 2D. Mô hình này bổ sung các lớp thích ứng và được huấn luyện trên một tập dữ liệu rất lớn gồm khoảng 4,6 triệu ảnh và 19,7 triệu mặt nạ. Một hướng tương tự là MedSAM [16]. Trong khóa luận này, SAM-Med2D được chọn làm mô hình đối sánh chính vì nó phù hợp hơn với dữ liệu 2D và hỗ trợ tinh chỉnh trực tiếp trên tập X-quang xương.

SAM-Med2D tiếp nhận câu nhắc thông qua bộ mã hóa riêng và kết hợp biểu diễn câu nhắc với đặc trưng ảnh để sinh mặt nạ. Trong khóa luận, hộp giới hạn được sử dụng làm câu nhắc nhằm bảo đảm điều kiện so sánh thống nhất với PGA-UNet.

SAM-Med2D có lợi thế là thừa hưởng kiến thức từ tiền huấn luyện trên lượng dữ liệu y khoa lớn, nhưng đổi lại kiến trúc cũng nặng hơn hẳn so với một CNN chuyên biệt. Trong thực nghiệm của khóa luận, SAM-Med2D



Hình 2.1: Kiến trúc SAM-Med2D với bộ mã hóa ảnh, bộ mã hóa câu nhắc, bộ giải mã mặt nạ và các lớp adapter thích ứng [13].

được chạy ở độ phân giải 256×256 , còn PGA-UNet được đánh giá ở cả 256×256 và 512×512 . Vì vậy, ở Chương 4, khóa luận có thêm các phép so sánh cùng độ phân giải để giảm bớt ảnh hưởng của khác biệt đầu vào.

Song song với SAM, nhiều công trình gần đây còn khảo sát khả năng kết hợp Transformer với phân đoạn y khoa. ViT [18] và Swin Transformer [19] mở ra hướng biểu diễn dựa trên cơ chế chú ý toàn cục hoặc phân cấp; từ đó, các mô hình như TransUNet [20], Medical Transformer [21], UNETR [22] và Swin-Unet [23] được đề xuất cho nhiều tác vụ phân đoạn y khoa. Dù thường đạt hiệu năng cạnh tranh, các mô hình này cũng có xu hướng đòi hỏi tài nguyên tính toán và cấu hình huấn luyện phức tạp hơn so với các CNN gọn nhẹ.

2.1.4

Khoảng trống nghiên cứu

Từ phần khảo sát ở trên có thể thấy mỗi hướng đều có điểm mạnh và điểm hạn chế riêng. U-Net và Attention U-Net gọn và quen thuộc nhưng ở dạng gốc thì không nhận câu nhắc. Các phương pháp tương tác dựa trên CNN có thể dùng bản đồ không gian, nhưng thường chỉ ghép tín hiệu này ở đầu vào hoặc ở một bước tinh chỉnh nào đó. Trong khi đó, SAM-Med2D nhận được nhiều loại câu nhắc và có lợi thế tiền huấn luyện quy mô lớn, nhưng chi phí tính toán cũng cao hơn.

Từ khoảng trống đó, khóa luận hướng đến một mô hình CNN tương đối nhẹ, có thể nhận trực tiếp hộp giới hạn và giữ được ảnh hưởng của câu nhắc xuyên qua cả bộ mã hóa lẫn bộ giải mã. Hướng này hợp hơn với những bài toán có dữ liệu vừa hoặc nhỏ, nơi mô hình cần dễ huấn luyện, dễ kiểm soát và phản hồi nhanh. PGA-UNet được đề xuất theo hướng đó với ba phần chính là bản đồ nhiệt câu nhắc dạng cao nguyên, PSG ở bộ mã hóa và CAD ở bộ giải mã. Thiết kế cụ thể sẽ được trình bày ở Chương 3.

2.2

Cơ sở kiến trúc nền tảng


2.2.1

Kiến trúc U-Net

U-Net [9] là mạng nơ-ron tích chập có cấu trúc đối xứng hình chữ U, gồm bộ mã hóa, bộ giải mã và các kết nối tắt.

Bộ mã hóa thực hiện các phép tích chập và giảm mẫu để tăng dần phạm vi tiếp nhận, qua đó trích xuất đặc trưng từ mức cục bộ đến mức ngữ nghĩa. Khi độ phân giải giảm, số kênh đặc trưng thường tăng để mô hình biểu diễn thông tin phức tạp hơn. Nguyên lý tăng chiều sâu biểu diễn này cũng là nền tảng chung của nhiều mạng thị giác hiện đại như ResNet [24], dù ResNet chủ yếu được thiết kế cho phân loại và nhận dạng tổng quát.

Bộ giải mã tăng dần độ phân giải của đặc trưng và kết hợp chúng với đặc trưng tương ứng từ bộ mã hóa. Các kết nối tắt giúp khôi phục thông tin vị trí bị mất trong quá trình giảm mẫu, đặc biệt hữu ích đối với bài toán phân đoạn yêu cầu dự đoán ở cấp độ điểm ảnh.



Hình 2.2: Kiến trúc U-Net với bốn cấp độ phân giải.

Kết nối tắt giúp bảo toàn thông tin không gian nhưng đồng thời có thể truyền cả đặc trưng ít liên quan hoặc nhiễu nền sang bộ giải mã. Attention U-Net giải quyết một phần hạn chế này bằng cách điều chỉnh đặc trưng tại kết nối tắt trước khi thực hiện phép ghép.

2.2.2

Kiến trúc Attention U-Net

Attention U-Net [17] chèn Cổng chú ý tại các kết nối tắt của U-Net. Mỗi cổng nhận đặc trưng $\mathbf{x}^l$ từ bộ mã hóa và tín hiệu cổng $\mathbf{g}^l$ từ tầng sâu hơn của bộ giải mã.

Hai đặc trưng được chiếu về cùng không gian trung gian và kết hợp để tạo bản đồ chú ý:

$$\mathbf{q}^l = \psi^l * \delta (\mathbf{W}_x^l * \mathbf{x}^l + \mathbf{W}_g^l * \mathbf{g}^l + \mathbf{b}^l), \quad (2.1)$$

trong đó δ là hàm ReLU, $\mathbf{W}_x^l$ và $\mathbf{W}_g^l$ là các phép chiếu học được. Hệ số chú ý được xác định bởi:


$$\boldsymbol{\alpha}^l = \sigma (\mathbf{q}^l), \quad (2.2)$$

với σ là hàm Sigmoid. Đặc trưng tại kết nối tắt được điều chỉnh theo:

$$\widehat{\mathbf{x}}^l = \boldsymbol{\alpha}^l \odot \mathbf{x}^l, \quad (2.3)$$

trong đó $\odot$ là phép nhân theo phần tử.

Cổng chú ý cho phép bộ giải mã điều chỉnh lượng thông tin nhận từ bộ mã hóa theo vị trí không gian. Tuy nhiên, cả $\mathbf{x}^l$ và $\mathbf{g}^l$ đều được hình thành từ ảnh đầu vào; cơ chế không nhận trực tiếp thông tin định hướng của người dùng. PGA-UNet mở rộng điểm này bằng cách điều kiện hóa tín hiệu cổng bằng đặc trưng câu nhắc.



Hình 2.3: Kiến trúc Attention U-Net với các cổng chú ý tại các kết nối tắt.

2.3

Biểu diễn và tích hợp câu nhắc trực quan

Câu nhắc trực quan là thông tin bổ sung do người dùng cung cấp để xác định đối tượng hoặc vùng cần phân đoạn. Các dạng câu nhắc phổ biến gồm điểm bấm, nét vẽ, hộp giới hạn và mặt nạ thô. Khóa luận lựa chọn hộp giới hạn vì thao tác này cung cấp đồng thời vị trí và phạm vi tương đối của vùng nghi ngờ nhưng không yêu cầu người dùng vẽ chính xác đường biên ở cấp độ điểm ảnh.

2.3.1

Biểu diễn không gian của câu nhắc

Hộp giới hạn được xác định bởi tọa độ hai góc đối diện:

$$\mathbf{B} = (x_1, y_1, x_2, y_2). \quad (2.4)$$

Để xử lý bằng CNN, hộp có thể được chuyển thành bản đồ không gian $\mathbf{H} \in [0, 1]^{H \times W}$ có cùng kích thước với ảnh đầu vào.

Một cách biểu diễn là phân phối Gaussian hai chiều có tâm tại tâm hình học của hộp:

$$\mu_x = \frac{x_1 + x_2}{2}, \quad \mu_y = \frac{y_1 + y_2}{2}. \quad (2.5)$$

Giá trị tại vị trí (x, y) được xác định bởi:

$$H(x, y) = \exp \left(-\frac{(x - \mu_x)^2}{2\sigma_x^2} - \frac{(y - \mu_y)^2}{2\sigma_y^2} \right), \quad (2.6)$$

trong đó σ_x và σ_y điều chỉnh độ phân tán theo hai trục. Bản đồ đạt giá trị lớn nhất tại tâm và giảm dần theo khoảng cách.

Một cách khác là mặt nạ hộp giới hạn nhị phân, trong đó toàn bộ vùng bên trong hộp được gán giá trị 1 và vùng bên ngoài được gán giá trị 0. Biểu diễn này duy trì tín hiệu đồng đều trong hộp nhưng tạo ra thay đổi đột ngột tại đường biên.

PGA-UNet sử dụng dạng kết hợp, gọi là bản đồ nhiệt dạng cao nguyên. Trước tiên, vùng bên trong hộp được gán giá trị 1; sau đó đường biên được làm mềm bằng bộ lọc Gaussian. Cách biểu diễn này duy trì tín hiệu trên toàn bộ vùng được chỉ định và tạo vùng chuyển tiếp liên tục tại đường biên. Công thức và cấu hình cụ thể được trình bày tại Mục 3.1.1, Chương 3.

So với vector tọa độ hoặc biểu diễn nhúng vị trí, bản đồ nhiệt giữ cấu trúc không gian hai chiều và có thể được thay đổi kích thước bằng nội suy để phù hợp với các mức đặc trưng của CNN. Đặc điểm này cho phép câu nhắc được sử dụng tại nhiều tầng thay vì chỉ tại đầu vào.

2.3.2

Điều biến đặc trưng theo tín hiệu điều kiện

Điều biến đặc trưng là cơ chế thay đổi đặc trưng trung gian dựa trên một tín hiệu điều kiện. Với đặc trưng ảnh $\mathbf{x}$ và điều kiện $\mathbf{z}$, dạng tổng quát có thể được biểu diễn bởi:

$$\tilde{\mathbf{x}} = \gamma(\mathbf{z}) \odot \mathbf{x} + \beta(\mathbf{z}), \quad (2.7)$$

trong đó γ điều chỉnh tỷ lệ và β điều chỉnh độ lệch của đặc trưng.

FiLM [25] sử dụng tín hiệu điều kiện để sinh các hệ số điều biến theo kênh. SPADE [26] mở rộng ý tưởng này bằng cách sinh tham số điều biến phụ thuộc vị trí không gian từ bản đồ ngữ nghĩa. Hai phương pháp cho thấy tín hiệu điều kiện không nhất thiết chỉ được ghép với đầu vào mà có thể tác động trực tiếp lên đặc trưng trung gian.

PSG trong PGA-UNet thuộc cùng hướng tiếp cận điều biến đặc trưng có điều kiện, nhưng sử dụng bản đồ nhiệt câu nhắc để sinh trọng số khuếch đại theo không gian. Kết nối dư trong PSG duy trì đường truyền đặc trưng gốc, trong khi mô-đun học mức tăng cường phù hợp tại từng tầng mã hóa. Với công thức triển khai của khóa luận, PSG không trực tiếp triệt tiêu đặc trưng nền mà ưu tiên tăng cường vùng được chỉ định bởi câu nhắc. Thiết kế chi tiết được trình bày tại Mục 3.1.2, Chương 3.

2.3.3

Cơ chế chú ý có điều kiện

Cách đơn giản nhất để tích hợp câu nhắc vào CNN là ghép bản đồ câu nhắc với ảnh như một kênh đầu vào bổ sung. Tuy nhiên, tín hiệu ghép tại tầng đầu có thể thay đổi hoặc suy giảm qua nhiều phép tích chập và giảm mẫu.

Cơ chế chú ý có điều kiện đưa thông tin câu nhắc trực tiếp vào quá trình tính trọng số chú ý. Về khái niệm, hệ số chú ý tại tầng thứ l được biểu diễn bởi:

$$\boldsymbol{\alpha}^l = f(\mathbf{x}^l, \mathbf{g}^l \mid \mathbf{H}^l), \quad (2.8)$$

trong đó $\mathbf{x}^l$ là đặc trưng bộ mã hóa, $\mathbf{g}^l$ là tín hiệu bộ giải mã và $\mathbf{H}^l$ là biểu diễn câu nhắc tại cùng mức không gian.

Khác với Cổng chú ý nguyên bản chỉ sử dụng đặc trưng nội bộ của mạng, cơ chế có điều kiện cho phép trọng số chú ý phụ thuộc đồng thời vào ảnh và tín hiệu định hướng bên ngoài. CAD trong PGA-UNet hiện thực hóa nguyên lý này bằng cách mã hóa bản đồ nhiệt và dung hợp đặc trưng câu nhắc vào tín hiệu cổng tại từng tầng giải mã. Cấu trúc cụ thể được trình bày tại Mục 3.1.3, Chương 3.

2.4

Các độ đo đánh giá

Không có một chỉ số nào có thể phản ánh đầy đủ chất lượng phân đoạn trong mọi khía cạnh. Vì vậy, khóa luận dùng kết hợp nhiều độ đo: Dice và IoU để xem mức độ chồng lấp, Precision và Recall để xem xu hướng dự đoán, HD95 để đánh giá sai lệch đường biên và CBL như một chỉ số bổ sung về độ lệch tâm.

2.4.1

Hệ số Dice và chỉ số IoU

Gọi Y là mặt nạ nhãn gốc và $\hat{Y}$ là mặt nạ dự đoán. Hệ số Dice được xác định bởi:

$$\text{Dice}(Y, \hat{Y}) = \frac{2|Y \cap \hat{Y}|}{|Y| + |\hat{Y}|}. \quad (2.9)$$

Chỉ số Giao trên Hợp (IoU) được xác định bởi:

$$\text{IoU}(Y, \hat{Y}) = \frac{|Y \cap \hat{Y}|}{|Y \cup \hat{Y}|}. \quad (2.10)$$

Cả hai chỉ số nhận giá trị trong khoảng $[0, 1]$; giá trị càng lớn biểu thị mức độ chồng lấp càng cao. So với Accuracy ở cấp độ điểm ảnh, Dice và IoU ít bị chi phối hơn bởi số lượng lớn điểm ảnh nền.

2.4.2

Precision và Recall

Gọi TP là số điểm ảnh tổn thương được dự đoán đúng, FP là số điểm ảnh nền bị dự đoán nhầm thành tổn thương và FN là số điểm ảnh tổn thương bị bỏ sót.

Precision biểu thị tỷ lệ dự đoán dương tính chính xác:

$$\text{Precision} = \frac{TP}{TP + FP}. \quad (2.11)$$

Recall biểu thị tỷ lệ vùng tổn thương được phát hiện:

$$\text{Recall} = \frac{TP}{TP + FN}. \quad (2.12)$$

Mặt nạ dự đoán quá rộng thường có Recall cao nhưng Precision thấp do bao gồm nhiều vùng nền. Ngược lại, mặt nạ quá nhỏ có thể đạt Precision cao nhưng Recall thấp do bỏ sót một phần tổn thương. Vì vậy, hai chỉ số được báo cáo song song với Dice và IoU.

2.4.3

Khoảng cách Hausdorff 95%

Dice và IoU đo mức độ chồng lấp diện tích nhưng chưa phản ánh đầy đủ sai lệch đường biên. HD95 đánh giá khoảng cách giữa đường biên dự đoán và đường biên nhãn gốc, đồng thời giảm ảnh hưởng của một số điểm ngoại lai so với khoảng cách Hausdorff cực đại.

Gọi X và Y lần lượt là tập điểm trên đường biên dự đoán và đường biên nhãn gốc. Tập khoảng cách biên hai chiều được xác định bởi:

$$\mathcal{D}(X, Y) = \left\{ \min_{y \in Y} d(x, y) \mid x \in X \right\} \cup \left\{ \min_{x \in X} d(y, x) \mid y \in Y \right\}, \quad (2.13)$$

trong đó $d(\cdot, \cdot)$ là khoảng cách Euclidean. HD95 là phân vị thứ 95 của tập khoảng cách trên:

$$\text{HD95}(X, Y) = \text{Percentile}_{95}(\mathcal{D}(X, Y)). \quad (2.14)$$

HD95 được báo cáo theo đơn vị điểm ảnh trong khóa luận. Giá trị càng nhỏ cho thấy đường biên dự đoán càng gần đường biên tham chiếu.

2.4.4

Chỉ số định vị tâm CBL

Bên cạnh các độ đo tiêu chuẩn, khóa luận sử dụng CBL (*Center-Based Localization*) như một chỉ số bổ sung để khảo sát độ lệch tâm giữa mặt nạ dự đoán và nhãn gốc. Chỉ số này đặc biệt hữu ích khi đánh giá mô hình trong kịch bản câu nhắc bị lệch tâm, nhưng không thay thế Dice hoặc HD95.

Với mặt nạ nhị phân không rỗng M , tọa độ tâm được xác định bởi:

$$x_M = \frac{\sum_{x,y} xM(x,y)}{\sum_{x,y} M(x,y)}, \quad y_M = \frac{\sum_{x,y} yM(x,y)}{\sum_{x,y} M(x,y)}. \quad (2.15)$$

Gọi (x_p, y_p) là tâm mặt nạ dự đoán, (x_g, y_g) là tâm nhãn gốc và D_{GT} là độ dài đường chéo của hộp bao nhỏ nhất quanh nhãn gốc. CBL được xác định bởi:

$$\text{CBL} = \max \left(0, 1 - \frac{\sqrt{(x_p - x_g)^2 + (y_p - y_g)^2}}{D_{GT}} \right). \quad (2.16)$$

CBL bằng 1 khi hai tâm trùng nhau và giảm dần khi khoảng cách tâm tăng. Việc chuẩn hóa theo D_{GT} giúp diễn giải sai lệch tương đối theo kích thước tổn thương. Khi mặt nạ dự đoán rỗng, CBL được quy ước bằng 0. Với ảnh có nhiều vùng tổn thương, tâm được tính trên mặt nạ hợp nhất theo phương pháp đánh giá cấp độ ảnh tại Chương 4.

Do CBL là chỉ số bổ sung được sử dụng trong phạm vi khóa luận, kết luận chính về chất lượng phân đoạn vẫn dựa trên các độ đo tiêu chuẩn gồm Dice, IoU, Precision, Recall và HD95.

2.5

Tổng kết chương

Chương này đã đi qua các phương pháp phân đoạn tự động, phân đoạn tương tác dựa trên CNN và mô hình nền tảng dựa trên câu nhắc. Từ đó, khóa luận thấy rõ hơn khoảng trống nghiên cứu mà mình nhắm tới: nhu cầu về một kiến trúc CNN hạng nhẹ có thể tiếp nhận và giữ thông tin câu nhắc trong suốt quá trình phân đoạn.

Các cơ sở lý thuyết về U-Net, Cổng chú ý, bản đồ nhiệt, điều biến đặc trưng và chú ý có điều kiện là nền để đi đến thiết kế PGA-UNet ở Chương 3. Chương này cũng chốt các độ đo sẽ dùng để đánh giá định lượng mô hình ở Chương 4.

CHƯƠNG 3

MÔ HÌNH VÀ HỆ THỐNG ĐỀ XUẤT

3.1

Mô hình phân đoạn PGA-UNet

PGA-UNet (*Prompt-Guided Attention U-Net*) là mô hình phân đoạn tương tác nhận đồng thời ảnh X-quang và hộp giới hạn vùng nghi ngờ. Mô hình này được xây dựng dựa trên khung mã hóa–giải mã của U-Net [9] và ý tưởng chú ý ở kết nối tắt của Attention U-Net [17]. Từ đó, khóa luận bổ sung ba thành phần chính là bản đồ nhiệt câu nhắc dạng cao nguyên, Cổng không gian tại bộ mã hóa (PSG) và Cơ chế chú ý có điều kiện ở các kết nối tắt của nhánh giải mã (CAD).


Bảng 3.1 phân biệt các thành phần kế thừa với thiết kế được sử dụng trong PGA-UNet.

Bảng 3.1: Các thành phần kế thừa và thiết kế trong PGA-UNet

Thành phần	Cơ sở kế thừa	Thiết kế trong PGA-UNet
Khung mạng	U-Net [9]: cấu trúc mã hóa–giải mã và kết nối tắt	Sử dụng làm kiến trúc nền cho mô hình phân đoạn hạng nhẹ
Biểu diễn câu nhắc	Các phương pháp phân đoạn có hướng dẫn bằng hộp giới hạn	Chuyển hộp giới hạn thành bản đồ nhiệt dạng cao nguyên có biên được làm mềm bằng bộ lọc Gaussian
PSG	Các phương pháp tích hợp bản đồ không gian vào CNN, chẳng hạn DeepIGeoS [15]	Điều biến đặc trưng tại bộ mã hóa bằng cơ chế cổng nhân có kết nối dư
CAD	Cổng chú ý tại kết nối tắt của Attention U-Net [17]	Điều kiện hóa tín hiệu chú ý tại bộ giải mã bằng đặc trưng câu nhắc

Hình 3.1 cho thấy kiến trúc tổng thể của mô hình. Nói ngắn gọn, PSG giúp đưa câu nhắc vào phần trích xuất đặc trưng, còn CAD giữ ảnh hưởng

của câu nhắc khi mô hình khôi phục lại mặt nạ. Nhờ vậy, thông tin định vị không chỉ xuất hiện ở đầu vào rồi yếu dần đi, mà còn được dùng lại ở nhiều tầng bên trong mạng.



Hình 3.1: Kiến trúc PGA-UNet với PSG tại bộ mã hóa và CAD trên các kết nối tắt của nhánh giải mã.

3.1.1

Biểu diễn câu nhắc trực quan

Đầu vào tương tác của PGA-UNet là hộp giới hạn $\mathbf{B} = (x_1, y_1, x_2, y_2)$ do người dùng cung cấp quanh vùng nghi ngờ. Các nghiên cứu phân đoạn tương tác khác còn sử dụng điểm nhấp chuột [14] hoặc nét vẽ tự do [15] làm câu nhắc; khóa luận chọn hộp giới hạn vì đây là thao tác đơn giản, không đòi hỏi người dùng ước lượng chính xác tâm hay đường biên tổn thương, đồng thời thống nhất với dạng câu nhắc mà SAM và SAM-Med2D hỗ trợ, thuận lợi cho việc so sánh trực tiếp tại Chương 4. Thay vì sử dụng trực tiếp bốn tọa độ rời rạc, hộp được chuyển thành bản đồ nhiệt câu nhắc $\mathbf{H}_{\text{prompt}} \in [0, 1]^{H \times W}$ có cùng kích thước không gian với ảnh đầu vào.

Trước tiên, hộp giới hạn được biểu diễn thành mặt nạ nhị phân:

$$\mathbf{B}_{\text{mask}}(x, y) = \begin{cases} 1, & (x, y) \in \mathbf{B}, \\ 0, & \text{ngược lại.} \end{cases} \quad (3.1)$$

Biên của mặt nạ sau đó được làm mềm bằng bộ lọc Gaussian:

$$\mathbf{H}_{\text{prompt}} = \mathbf{B}_{\text{mask}} * \mathbf{K}_{\text{Gaussian}}(k), \quad k = 31, \quad (3.2)$$

trong đó $*$ là phép tích chập và $\mathbf{K}_{\text{Gaussian}}(k)$ là nhân Gaussian có kích thước $k \times k$. Hộp giới hạn được mở rộng thêm 5 điểm ảnh ở mỗi cạnh trước khi tạo mặt nạ nhằm hạn chế việc cắt sát đường biên tổn thương.

Cách biểu diễn này tạo ra một vùng có giá trị cao tương đối đều ở bên trong hộp và mềm hơn ở phần biên. So với mặt nạ nhị phân, tín hiệu này bớt gắt hơn và có thể giúp mô hình đỡ phụ thuộc vào đường biên cứng của hộp. So với một phân phối Gaussian chỉ nhấn vào vùng tâm, dạng cao nguyên vẫn giữ thông tin trên gần như toàn bộ vùng được khoanh.

Bản đồ nhiệt được dùng như một nhánh dữ liệu riêng song song với ảnh X-quang. Vì có cùng cấu trúc không gian $H \times W$ với ảnh, nó có thể được giảm mẫu để phù hợp với nhiều tầng đặc trưng khác nhau trong CNN.

Khác với các mô hình nền tảng như SAM và SAM-Med2D [12], [13], nơi hộp giới hạn thường được mã hóa thành biểu diễn nhúng phù hợp với Transformer, PGA-UNet giữ câu nhắc dưới dạng bản đồ hai chiều. Cách làm này hợp với CNN hơn và thuận tiện cho việc điều biến đặc trưng theo từng vị trí không gian.

3.1.2

Cổng không gian tại bộ mã hóa

Trong U-Net thông thường, bộ mã hóa trích xuất đặc trưng trên toàn bộ ảnh mà không biết người dùng đang quan tâm vùng nào. Với ảnh X-quang, điều này có thể làm mô hình bị phân tán bởi nền ảnh, vùng xương chồng lấp hoặc các khu vực có tương phản mạnh nhưng không liên quan trực tiếp đến tổn thương.

Vì vậy, PGA-UNet thêm Cổng không gian PSG (*Prompt Spatial Gate*) vào các tầng mã hóa. Vai trò của PSG là dùng bản đồ nhiệt để điều chỉnh đặc trưng theo không gian, giúp mô hình chú ý sớm hơn đến vùng được khoanh.

Tại tầng mã hóa thứ l , bản đồ nhiệt được giảm mẫu bằng nội suy song tuyến tính về cùng độ phân giải với đặc trưng $\mathbf{x}^l$:

$$\mathbf{H}^l = \text{Bilinear} \left(\mathbf{H}_{\text{prompt}}, \frac{H}{2^l}, \frac{W}{2^l} \right). \quad (3.3)$$

Bản đồ sau khi giảm mẫu được đưa qua phép tích chập 1×1 và hàm Sigmoid để sinh trọng số điều biến:

$$\mathbf{A}_{\text{PSG}}^l = \sigma \left(\mathbf{W}_{\text{gate}}^l * \mathbf{H}^l \right), \quad (3.4)$$

trong đó $\mathbf{W}_{\text{gate}}^l$ ánh xạ bản đồ một kênh sang cùng số kênh với đặc trưng $\mathbf{x}^l$. Đặc trưng đầu ra của PSG được xác định bởi:

$$\tilde{\mathbf{x}}^l = \mathbf{x}^l \odot (1 + \alpha_{\text{PSG}}^l \mathbf{A}_{\text{PSG}}^l), \quad (3.5)$$

với $\odot$ là phép nhân theo phần tử và $\alpha_{\text{PSG}}^l \in [0, 1]$ là hệ số học được, được khởi tạo bằng 0,1.

Thành phần $1 +$ trong Phương trình (3.5) tạo ra kết nối dư, giúp đặc trưng gốc không bị mất đi. Nói cách khác, PSG trong khóa luận không được thiết kế để triệt hẳn phần nền, mà thiên về việc tăng cường vùng đã được câu nhắc chỉ ra trong khi vẫn giữ lại ngữ cảnh chung của ảnh.

So với cách chỉ ghép câu nhắc ở đầu vào, PSG giúp tín hiệu định hướng đi vào nhiều mức đặc trưng khác nhau của bộ mã hóa. Tác dụng riêng của PSG và tác dụng khi phối hợp với CAD sẽ được kiểm tra ở phần thực nghiệm loại bỏ thành phần trong Chương 4.

3.1.3

Cơ chế chú ý có điều kiện trên kết nối tắt của nhánh giải mã

PSG giúp đưa câu nhắc vào bộ mã hóa, nhưng khi đặc trưng đi qua nhiều tầng sâu thì ảnh hưởng của tín hiệu định vị vẫn có thể yếu dần. Vì vậy, PGA-UNet tiếp tục bổ sung CAD (*Conditional Attention Decoder*) ở các kết nối tắt của nhánh giải mã để giữ lại ảnh hưởng của câu nhắc trong quá trình khôi phục mặt nạ.

Trong Attention U-Net [17], hệ số chú ý tại kết nối tắt được tính từ đặc trưng bộ mã hóa $\mathbf{x}^l$ và tín hiệu cổng $\mathbf{g}^l$ của bộ giải mã. Tín hiệu này được hình thành hoàn toàn từ đặc trưng nội bộ của mạng và không nhận trực tiếp thông tin từ câu nhắc.

Trong CAD, bản đồ nhiệt được giảm mẫu về cùng độ phân giải với tín hiệu cổng và đưa qua bộ mã hóa câu nhắc:

$$\mathbf{p}_{\text{enc}}^l = f_{\text{enc}}^l \left(\text{Resize} \left(\mathbf{H}_{\text{prompt}}, \text{size}(\mathbf{g}^l) \right) \right), \quad (3.6)$$

trong đó f_{enc}^l gồm hai lớp tích chập 3×3 liên tiếp, mỗi lớp theo sau bởi phép chuẩn hóa theo từng mẫu (*Instance Normalization*) và hàm ReLU. Trong triển khai hiện tại, khối này ánh xạ bản đồ một kênh thành biểu diễn có cùng số kênh với tín hiệu cổng tại tầng giải mã thứ l : lớp thứ nhất tạo số kênh bằng một nửa số kênh của tín hiệu cổng, lớp thứ hai nâng lên đúng số kênh của tín hiệu cổng.

Từ biểu diễn này, một hệ số điều chế câu nhắc được xác định:

$$c^l = \sigma \left(\text{GAP} \left(\mathbf{p}_{\text{enc}}^l \right) \right), \quad (3.7)$$

trong đó GAP là phép gộp trung bình toàn cục. Trong triển khai, c^l là một hệ số vô hướng theo từng mẫu (dạng bản đồ $1 \times 1 \times 1$ sau phép tích chập 1×1 và hàm Sigmoid), dùng để điều chỉnh mức ảnh hưởng tổng thể của đặc trưng câu nhắc tại tầng tương ứng; nó không được diễn giải là xác suất tin cậy đã hiệu chỉnh.

Tín hiệu cổng được điều kiện hóa bởi đặc trưng câu nhắc:

$$\mathbf{g}'^l = \mathbf{g}^l + c^l \alpha_{\text{CAD}}^l w_l \mathbf{p}_{\text{enc}}^l, \quad (3.8)$$

trong đó α_{CAD}^l là hệ số pha trộn học được và w_l điều chỉnh mức ảnh hưởng của câu nhắc tại từng tầng giải mã. Trong mã nguồn thực nghiệm, mỗi tầng giải mã có một tham số vô hướng riêng $\alpha_{\text{CAD}}^l = \sigma(\alpha_{\text{raw}}^l)$ và bộ trọng số cố định $w_l = \{1,0; 0,7; 0,4; 0,2\}$ theo thứ tự từ tầng sâu đến tầng nông.

Hệ số chú ý tại kết nối tắt được tính bởi:

$$\mathbf{A}_{\text{CAD}}^l = \sigma [\boldsymbol{\psi}^l * \delta (\mathbf{W}_x^l * \tilde{\mathbf{x}}^l + \mathbf{W}_g^l * \mathbf{g}'^l)], \quad (3.9)$$

trong đó δ là hàm ReLU, $\mathbf{W}_x^l$ và $\mathbf{W}_g^l$ là các phép chiếu đặc trưng, còn $\boldsymbol{\psi}^l$ ánh xạ kết quả về bản đồ chú ý một kênh. Đặc trưng kết nối tắt sau chú ý được xác định bởi:

$$\hat{\mathbf{x}}^l = \tilde{\mathbf{x}}^l \odot \mathbf{A}_{\text{CAD}}^l. \quad (3.10)$$

Điểm khác chính của CAD so với cổng chú ý nguyên bản là tín hiệu điều khiển ở đây được điều kiện hóa trực tiếp bởi câu nhắc từ bên ngoài. Có thể xem PSG là phần dẫn hướng ở bước mã hóa, còn CAD là phần nhắc lại định hướng đó ở bước giải mã. Hai thành phần này đi cùng nhau để câu nhắc có ảnh hưởng xuyên suốt mạng, thay vì chỉ xuất hiện ở một chỗ.

Chi tiết triển khai theo tầng.

Với hệ số thu gọn `feature_scale=4`, PGA-UNet sử dụng số kênh $\{16, 32, 64, 128, 256\}$ từ tầng mã hóa nông nhất đến nút cổ chai. Bốn tầng giải mã lần lượt nhận cặp kênh bỏ qua/tín hiệu cổng là $(128, 256)$, $(64, 128)$, $(32, 64)$ và $(16, 32)$. Ở mỗi tầng giải mã, f_{enc}^l mã hóa prompt theo chuỗi $1 \rightarrow g_l/2 \rightarrow g_l$, trong đó g_l là số kênh của tín hiệu cổng tại tầng đó. Cấu hình này được dùng thống nhất trong toàn bộ thực nghiệm của khóa luận.

Các hệ số w_l , tham số khởi tạo và các thiết lập thực nghiệm được sử dụng thống nhất trong các phép đánh giá của khóa luận. Giá trị cụ thể được trình bày tại Chương 4.

3.2

Quy trình huấn luyện và suy luận

Phần này tóm tắt hai quy trình chính của PGA-UNet là huấn luyện và suy luận. Khi huấn luyện, hộp giới hạn được tạo từ mặt nạ nhãn gốc rồi điều chỉnh để mô phỏng sai lệch thao tác. Khi suy luận, mô hình nhận trực tiếp hộp giới hạn từ người dùng.

3.2.1

Quy trình huấn luyện

Đầu vào huấn luyện gồm ảnh X-quang và mặt nạ phân đoạn. Với mỗi mẫu, hộp giới hạn được trích từ mặt nạ, sau đó biến đổi theo kịch bản câu nhắc Bao tròn hoặc Lệch tâm. **Mô phỏng câu nhắc.** Gọi $w = x_2 - x_1$ và $h = y_2 - y_1$ lần lượt là chiều rộng và chiều cao của hộp bao sát tổn thương. Ba kịch bản câu nhắc được xây dựng như sau:

- **Bao tròn:** Hộp bao sát được mở rộng với tỷ lệ $r \in [0,15; 0,45]$ theo kích thước ban đầu, nhằm mô phỏng thao tác khoanh rộng hơn vùng tổn thương.
- **Lệch tâm:** Hộp được dịch khỏi vị trí ban đầu theo hướng ngẫu nhiên với hệ số dịch bằng 0,30 kích thước hộp (`shift_ratio=0.30`). Tọa độ sau biến đổi được giới hạn trong phạm vi ảnh.
- **Hỗn hợp:** Mỗi mẫu sử dụng câu nhắc Bao tròn với xác suất 70% hoặc câu nhắc Lệch tâm với xác suất 30%.

Các phép biến đổi này chỉ tác động lên hộp giới hạn, còn ảnh X-quang và mặt nạ nhãn gốc vẫn được giữ nguyên. Thiết lập này được áp dụng thống nhất trong các thí nghiệm của PGA-UNet. Từ hộp giới hạn, bản đồ nhiệt câu nhắc được tạo ra và đưa cùng với ảnh vào mô hình. Hàm mất mát dùng để tối ưu là tổ hợp Binary Cross-Entropy và Dice Loss.

Algorithm 1 Quy trình huấn luyện PGA-UNet

Require: Tập dữ liệu $\mathcal{D} = \{(\mathbf{I}_i, \mathbf{M}_i)\}_{i=1}^N$

Ensure: Bộ tham số đã huấn luyện θ^*

- 1: Khởi tạo tham số PGA-UNet θ
 - 2: **while** chưa thỏa tiêu chí dừng trên tập xác thực **do**
 - 3: **for** mỗi lô nhỏ $(\mathbf{I}, \mathbf{M})$ **do**
 - 4: Cố giãn ảnh và mặt nạ theo cùng hệ số, giữ tỷ lệ rồi đem về kích thước đầu vào
 - 5: Trích hộp giới hạn $\mathbf{B}$ từ mặt nạ $\mathbf{M}$
 - 6: Điều chỉnh $\mathbf{B}$ theo kích bản câu nhắc được chọn
 - 7: Tạo bản đồ nhiệt $\mathbf{H}_{\text{prompt}}$ từ $\mathbf{B}$
 - 8: Dự đoán $\hat{\mathbf{Y}} \leftarrow f_{\text{PGA}}(\mathbf{I}, \mathbf{H}_{\text{prompt}}; \theta)$
 - 9: Tính $\mathcal{L} \leftarrow \mathcal{L}_{\text{BCE}} + \mathcal{L}_{\text{Dice}}$
 - 10: Cập nhật θ bằng bộ tối ưu AdamW
 - 11: Đánh giá mô hình trên tập xác thực
 - 12: **if** thỏa tiêu chí dừng trên tập xác thực **then**
 - 13: Kết thúc vòng lặp huấn luyện
 - 14: **return** $\theta^* \leftarrow$ tham số của mô hình được chọn cho đánh giá
-

Mô hình được huấn luyện riêng trên từng bộ dữ liệu. Các cấu hình cụ thể hơn sẽ được nêu ở Chương 4.

3.2.2

Quy trình suy luận

Trong giai đoạn suy luận, người dùng cung cấp ảnh X-quang và hộp giới hạn vùng nghi ngờ. Hộp được chuyển thành bản đồ nhiệt theo cùng phương pháp sử dụng khi huấn luyện. Mô hình trả về bản đồ xác suất, sau đó được nhị phân hóa tại ngưỡng 0,5 để tạo mặt nạ cuối cùng.

Algorithm 2 Quy trình suy luận PGA-UNet

Require: Ảnh X-quang $\mathbf{I}$ và hộp giới hạn $\mathbf{B} = (x_1, y_1, x_2, y_2)$

Ensure: Mặt nạ phân đoạn $\widehat{\mathbf{M}}$

- 1: **if** $\mathbf{B} = \emptyset$ **then**
 - 2: **return** thông báo yêu cầu cung cấp hộp giới hạn
 - 3: Co giãn ảnh $\mathbf{I}$ giữ tỷ lệ rồi đệm về kích thước đầu vào
 - 4: Tạo mặt nạ hộp giới hạn $\mathbf{B}_{\text{mask}}$
 - 5: Tạo bản đồ nhiệt $\mathbf{H}_{\text{prompt}} \leftarrow \mathbf{B}_{\text{mask}} * \mathbf{K}_{\text{Gaussian}}(31)$
 - 6: Tính xác suất phân đoạn $\widehat{\mathbf{Y}} \leftarrow f_{\text{PGA}}(\mathbf{I}, \mathbf{H}_{\text{prompt}}; \boldsymbol{\theta}^*)$
 - 7: Tạo mặt nạ $\widehat{\mathbf{M}} \leftarrow \mathbf{1}[\widehat{\mathbf{Y}} \geq 0,5]$
 - 8: **return** $\widehat{\mathbf{M}}$
-

Nếu người dùng chưa cung cấp hộp giới hạn thì hệ thống sẽ không phân đoạn. Lý do là bản đồ nhiệt toàn giá trị 0 không mang thông tin định vị, nên không đúng với cách PGA-UNet được thiết kế và huấn luyện.

Quy trình suy luận chỉ cần một lượt truyền xuôi qua mô hình. Với kiến trúc CNN và số kênh cố định, chi phí tính toán của PGA-UNet tăng theo kích thước ảnh đầu vào. Theo thống kê kiến trúc, mô hình có khoảng 3 triệu tham số. Trong khóa luận, số tham số, FLOPs, bộ nhớ đỉnh, độ trễ suy luận và dung lượng checkpoint của PGA-UNet và SAM-Med2D cũng được đo trong cùng môi trường thực nghiệm; kết quả được trình bày ở Mục 4.2.3, Chương 4. Các con số này chỉ nên hiểu là so sánh tương đối trong cùng môi trường đo.

3.3

Mở rộng luồng xử lý với mô-đun sàng lọc

PGA-UNet được huấn luyện cho trường hợp ảnh đã có vùng nghi ngờ và người dùng đã cung cấp hộp giới hạn. Trong thực tế, luồng ảnh đầu vào có thể lẫn cả ảnh bình thường và ảnh bệnh lý. Vì vậy, để minh họa cách PGA-UNet có thể đặt trong một quy trình lớn hơn, khóa luận bổ sung Gatekeeper dùng EfficientNet-B3 trước bước phân đoạn.

Gatekeeper chỉ là phần hỗ trợ thêm, không phải đóng góp kiến trúc chính của khóa luận. Mô-đun này trả về xác suất bất thường để người dùng tham khảo, chứ không tự động loại bỏ ảnh hay thay cho quyết định của người dùng chuyên môn.

3.3.1

Sàng lọc ảnh đầu vào

Gatekeeper phân loại ảnh thành bình thường hoặc nghi ngờ có bất thường. Với ảnh được gợi ý có bất thường, người dùng kiểm tra và cung cấp hộp giới hạn để chuyển sang PGA-UNet. Với ảnh được gợi ý bình thường, người dùng vẫn có thể xác nhận lại hoặc chủ động khoanh vùng nếu phát hiện dấu hiệu nghi ngờ.

Cơ chế này được thiết kế theo hướng *triage mềm*, tức là Gatekeeper chỉ gợi ý ảnh nào đáng chú ý hơn, còn việc có chuyển sang bước phân đoạn hay không vẫn do người dùng quyết định. Cách làm này giúp hạn chế rủi ro ảnh bệnh lý bị bỏ qua hoàn toàn chỉ vì mô-đun phân loại đoán sai.

Cấu hình và kết quả thực nghiệm của Gatekeeper trên BTXRD và FracAtlas được tóm tắt tại Mục 4.4, Chương 4, với số liệu chi tiết tại Phụ lục B.


3.3.2

Phân đoạn có hướng dẫn

Sau khi xác định vùng nghi ngờ, người dùng vẽ hộp giới hạn trên ảnh X-quang. Hệ thống chuyển hộp thành bản đồ nhiệt và đưa đồng thời ảnh với bản đồ câu nhắc vào PGA-UNet. Mặt nạ dự đoán được hiển thị chồng lên ảnh gốc để hỗ trợ quan sát.

Nếu kết quả chưa phù hợp, người dùng có thể điều chỉnh hộp giới hạn và thực hiện lại suy luận. Quá trình hiệu chỉnh chỉ thay đổi câu nhắc đầu vào, không cập nhật kiến trúc hoặc tham số mô hình.

Luồng trên chỉ nhằm minh họa một cách tích hợp PGA-UNet vào quy trình xử lý ảnh hỗn hợp. Vì khóa luận chưa có thử nghiệm với bác sĩ hoặc người dùng chuyên môn trong điều kiện thực tế, nên đây chưa thể xem là một quy trình lâm sàng đã được xác nhận.



3.4

Tổng kết chương

Chương này đã trình bày mô hình PGA-UNet với ba phần chính là bản đồ nhiệt câu nhắc dạng cao nguyên, PSG ở bộ mã hóa và CAD ở các kết nối tắt của nhánh giải mã. PSG giúp đưa thông tin không gian của câu nhắc vào phần trích xuất đặc trưng, còn CAD giúp duy trì ảnh hưởng đó trong lúc mô hình khôi phục mặt nạ.

Ngoài kiến trúc mô hình, chương này cũng mô tả quy trình huấn luyện, suy luận và phần mở rộng với Gatekeeper trong một luồng xử lý hỗ trợ. Hiệu quả của các thành phần này sẽ được kiểm tra bằng thực nghiệm trên BTXRD và FracAtlas ở Chương 4.

CHƯƠNG 4

THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ

Chương này trình bày phần thực nghiệm của khóa luận trên hai bộ dữ liệu BTXRD và FracAtlas. Để dễ theo dõi hơn, nội dung được chia theo từng nhóm vấn đề. Mục 4.1 nói về dữ liệu và cấu hình thực nghiệm. Mục 4.2 trình bày các kết quả phân đoạn chính, gồm so sánh với U-Net, Attention U-Net, SAM-Med2D, ảnh hưởng của độ phân giải và độ ổn định khi câu nhắc bị sai lệch. Mục 4.3 tóm tắt các kết luận quan trọng từ nghiên cứu loại bỏ thành phần, đánh giá chéo và phân tích theo đặc tính tổn thương; phần số liệu đầy đủ được để ở Phụ lục A. Cuối cùng, Mục 4.4 trình bày thử nghiệm mở rộng với Gatekeeper và luồng xử lý hai giai đoạn; các bảng chi tiết nằm ở Phụ lục B.

4.1

Thiết lập môi trường thực nghiệm

Để các phần sau dễ theo dõi hơn, mục này trình bày trước về dữ liệu, cách chia tập, cấu hình phần cứng và các siêu tham số huấn luyện. Đây là phần hơi khô nhưng cần thiết, vì nếu thiếu thì phần kết quả phía sau sẽ khó hiểu hơn.

4.1.1

Hai bộ dữ liệu ảnh X-quang và tiền xử lý đầu vào

Khóa luận sử dụng hai bộ dữ liệu X-quang xương công khai và độc lập là BTXRD [27] (*Bone Tumor X-Ray Dataset*) và FracAtlas [28]. BTXRD tập trung vào khối u xương, còn FracAtlas tập trung vào gãy xương ở nhiều vị trí khác nhau. Việc dùng cả hai bộ dữ liệu giúp mô hình được kiểm tra trên hai dạng tổn thương khác nhau: một bên là vùng tổn thương có hình dạng phức tạp hơn, một bên là các đường gãy thường nhỏ và mảnh hơn.

Dữ liệu dùng cho bài toán phân đoạn chỉ gồm ảnh bệnh lý có mặt nạ ở cấp độ điểm ảnh.

Bảng 4.1: Thống kê phân bố hai bộ dữ liệu dùng trong thực nghiệm

Bộ dữ liệu	Phân chia	Số ảnh	Số mẫu đa giác	Ghi chú
BTXRD	Huấn luyện	1 493	1848	Ảnh khối u xương có mặt nạ phân đoạn.
	Xác thực	187	238	Dùng để lựa chọn mô hình.
	Kiểm thử	187	232	Một số ảnh chứa từ hai vùng tổn thương trở lên.
FracAtlas	Huấn luyện	573	730	Ảnh gãy xương có mặt nạ phân đoạn.
	Xác thực	72	95	Dùng để lựa chọn mô hình.
	Kiểm thử	72	92	Trung bình khoảng 1,28 vùng tổn thương trên mỗi ảnh.

FracAtlas có 917 mẫu đa giác được dùng trong thực nghiệm, khá gần với 922 vùng gãy xương được công bố trong bộ dữ liệu gốc [28]. Phần chênh lệch nhỏ hơn 1% chủ yếu do một số đa giác quá nhỏ hoặc lỗi định dạng bị loại ra khi chuẩn hóa dữ liệu. So với BTXRD, FracAtlas có ít dữ liệu huấn luyện hơn, nên cũng giúp kiểm tra thêm khả năng học của PGA-UNet trong điều kiện dữ liệu hạn chế hơn.

Phần tiền xử lý được áp dụng giống nhau cho cả hai bộ dữ liệu. Ảnh X-quang được đưa về kích thước 512×512 hoặc 256×256 bằng cách co giãn theo cùng hệ số để giữ nguyên tỉ lệ, sau đó đệm (*padding*) thành khung

vuông. Mặt nạ nhị phân được tạo từ tọa độ đa giác trong chú thích và cũng được biến đổi theo đúng quy trình đó. Bản đồ nhiệt câu nhắc được chuẩn hóa theo cùng cách để đồng bộ với ảnh đầu vào. Dữ liệu sau tiền xử lý được dùng thống nhất trong huấn luyện, suy luận và lúc trực quan hóa kết quả.

Việc phân chia tập huấn luyện, xác thực và kiểm thử được thực hiện ở cấp độ ảnh: các đa giác thuộc cùng một ảnh luôn được giữ trong cùng một tập để tránh rò rỉ dữ liệu ở cấp độ vùng tổn thương. Khóa luận chưa xác nhận việc phân chia ở cấp độ bệnh nhân hoặc lượt chụp (nhiều ảnh của cùng một bệnh nhân, nếu có, có thể rơi vào các tập khác nhau), do siêu dữ liệu công khai của BTXRD và FracAtlas không cung cấp mã định danh bệnh nhân đầy đủ để kiểm tra. Đây là một giới hạn về khả năng kiểm chứng rò rỉ dữ liệu, được nêu lại tại Mục 5.2, Chương 5.

4.1.2

Mô hình so sánh và cấu hình huấn luyện

PGA-UNet được so sánh với U-Net, Attention U-Net và SAM-Med2D. Trong đó, U-Net [9] và Attention U-Net [17] đóng vai trò mô hình cơ sở tự động, không nhận câu nhắc không gian. SAM-Med2D [13] là mô hình nền tảng có thể nhận hộp giới hạn và được đánh giá ở hai chế độ là chưa tinh chỉnh và đã tinh chỉnh trên từng bộ dữ liệu. PGA-UNet là mô hình đề xuất của khóa luận, sử dụng bản đồ nhiệt Gaussian kết hợp với PSG và CAD.

U-Net, Attention U-Net và PGA-UNet được huấn luyện từ đầu riêng biệt trên BTXRD và FracAtlas. SAM-Med2D ở chế độ chưa tinh chỉnh sử dụng trực tiếp trọng số tiền huấn luyện; ở chế độ đã tinh chỉnh, lớp thích ứng và bộ giải mã được cập nhật trên từng bộ dữ liệu. Kết quả so sánh với SAM-Med2D được trình bày tại Mục 4.2.2; ảnh hưởng của độ phân giải và sai lệch câu nhắc được phân tích tại Mục 4.2.4.

Cấu hình huấn luyện.

Các mô hình được triển khai bằng PyTorch và huấn luyện trong môi trường Kaggle sử dụng GPU NVIDIA Tesla T4 với 16 GB bộ nhớ. Các thực nghiệm trên hai bộ dữ liệu sử dụng cùng quy trình tiền xử lý và hàm mất mát. Đối với các mô hình huấn luyện từ đầu, hàm mất mát kết hợp entropy chéo nhị phân và Dice được sử dụng để xử lý sự mất cân bằng giữa vùng tổn thương và vùng nền:

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{BCE}} + \mathcal{L}_{\text{Dice}}. \quad (4.1)$$

Các mô hình sử dụng kích thước lô 4, bộ tối ưu AdamW, tốc độ học ban đầu 10^{-4} và hệ số suy giảm trọng số 10^{-4} . Việc huấn luyện và lựa chọn mô hình được thực hiện nhất quán trên toàn bộ thực nghiệm.

Đối với PGA-UNet, hệ số điều biến tại bốn tầng giải mã là $w_l = \{1,0; 0,7; 0,4; 0,2\}$, hệ số pha trộn học được của CAD được khởi tạo bằng $\alpha_{\text{CAD}} = 0,3$ (tương ứng đại lượng α_{CAD}^l tại Phương trình (3.8), Chương 3) và tham số cổng PSG được khởi tạo với $\alpha_{\text{gate}} = 0,1$. Bản đồ nhiệt Gaussian sử dụng cửa sổ lọc $k = 31$; hộp giới hạn được mở rộng thêm 5 điểm ảnh ở mỗi cạnh. Các giá trị này được áp dụng thống nhất trong các phép đánh giá của khóa luận. Do chúng được giữ theo đơn vị điểm ảnh cho cả ảnh 256×256 và 512×512 , mức độ làm mềm và biên mở rộng tương đối không hoàn toàn giống nhau giữa hai độ phân giải; điểm này cần được lưu ý khi diễn giải kết quả tại Mục 4.2.4.

4.1.3

Phương pháp đánh giá cấp độ ảnh

Một ảnh kiểm thử có thể chứa nhiều vùng tổn thương, và mỗi vùng được chú thích bằng một đa giác riêng.

1. **Hợp nhất nhãn gốc:** Với ảnh chứa $K \geq 1$ vùng tổn thương, các mặt nạ nhị phân $\{G_1, G_2, \dots, G_K\}$ được hợp nhất thành một mặt nạ duy nhất:

$$M_{\text{GT}} = \bigcup_{k=1}^K G_k. \quad (4.2)$$

2. **Kết hợp dự đoán:** Mô hình suy luận riêng với từng hộp giới hạn $\mathbf{B}_k$ để sinh các mặt nạ xác suất $\{\hat{P}_1, \hat{P}_2, \dots, \hat{P}_K\}$. Các kết quả được kết hợp bằng giá trị lớn nhất tại mỗi pixel:

$$\hat{M}_{\text{max}}(x, y) = \max_{1 \leq k \leq K} \hat{P}_k(x, y). \quad (4.3)$$

Mặt nạ nhị phân cuối cùng được xác định bởi $\hat{M}_{\text{pred}} = \mathbf{1}[\hat{M}_{\text{max}} \geq 0.5]$.

3. **Tính chỉ số cấp độ ảnh:** Các chỉ số đánh giá được tính một lần giữa $\hat{M}_{\text{pred}}$ và M_{GT} . Chẳng hạn, Dice cấp độ ảnh được xác định bởi:

$$\text{Dice}_{\text{img}} = \frac{2|M_{\text{GT}} \cap \hat{M}_{\text{pred}}|}{|M_{\text{GT}}| + |\hat{M}_{\text{pred}}|}. \quad (4.4)$$

Kết quả cuối cùng được lấy trung bình trên toàn bộ ảnh kiểm thử của từng bộ dữ liệu. Cách đánh giá này bảo đảm mỗi ảnh chỉ đóng góp một lần vào kết quả tổng hợp, không phụ thuộc vào số vùng tổn thương.

Đối với ảnh có nhiều vùng tổn thương, số lượng và vị trí hộp giới hạn $\mathbf{B}_k$ được suy ra trực tiếp từ số vùng và tọa độ của mặt nạ nhãn gốc. Nói cách khác, các kết quả ở mục này không đánh giá một hệ thống phát hiện–phân đoạn hoàn chỉnh phải tự xác định số lượng và vị trí tổn thương trên

ảnh chưa có nhãn, mà đánh giá chất lượng phân đoạn khi thông tin định vị sơ bộ đã được cung cấp.

HD95 không xác định về mặt toán học khi M_{GT} hoặc $\hat{M}_{pred}$ rỗng, tình huống có thể xảy ra với các mô hình có tỷ lệ dự đoán rỗng cao, chẳng hạn U-Net trên một số nhóm phụ tại Phụ lục A. Vì vậy, các giá trị HD95 trong khóa luận được tính theo một quy ước bổ sung thay vì công thức chuẩn áp dụng trực tiếp cho mọi trường hợp: nếu cả hai mặt nạ đều rỗng, HD95 được gán giá trị 0; nếu chỉ một trong hai mặt nạ rỗng, HD95 được gán giá trị phạt cố định bằng kích thước cạnh ảnh (256 hoặc 512 điểm ảnh, tùy độ phân giải đánh giá). Không có mẫu nào bị loại khỏi phép tính trung bình.

4.2

Đánh giá hiệu năng kiến trúc PGA-UNet

Mục này đánh giá hiệu năng của PGA-UNet theo ba hướng chính: so với các mô hình phân đoạn tự động, so với mô hình nền tảng SAM-Med2D và theo ảnh hưởng của độ phân giải đầu vào. Ngoài độ chính xác phân đoạn, phần này cũng xem mức độ ổn định của mô hình khi câu nhắc bị sai lệch. Trừ khi có nói khác đi, các kết quả ở đây đều phải hiểu trong bối cảnh phân đoạn có hướng dẫn bằng hộp giới hạn, chứ không phải một hệ thống tự động phát hiện và phân đoạn đầy đủ.

4.2.1

So sánh với các mô hình cơ sở

Thực nghiệm đầu tiên so sánh PGA-UNet với U-Net và Attention U-Net trên cả BTXRD và FracAtlas. Trong so sánh này, U-Net và Attention U-Net hoạt động hoàn toàn tự động, còn PGA-UNet nhận thêm câu nhắc là hộp giới hạn Bao trọn.

Cả ba mô hình được huấn luyện từ đầu riêng biệt trên từng bộ dữ liệu với kích thước đầu vào khác nhau và được đánh giá ở cấp độ ảnh. So sánh này nhằm xác định lợi ích tổng thể của phương pháp phân đoạn có hướng dẫn bằng câu nhắc so với các mô hình cơ sở không sử dụng câu nhắc; đây không phải phép so sánh cùng điều kiện đầu vào, nên không được dùng để kết luận về tính mới của riêng kiến trúc PGA-UNet. Đóng góp cụ thể của PSG và CAD, tách biệt khỏi lợi ích của việc có câu nhắc, được kiểm chứng bằng các cấu hình đối sánh cùng nhận câu nhắc (U-Net+Concat, U-Net+PSG, U-Net+CAD) tại Mục 4.3 và Phụ lục A.

Bảng 4.2: So sánh PGA-UNet với các mô hình cơ sở trên BTXRD ở độ phân giải 512×512 (N=187 ảnh)

Mô hình	Dice $\uparrow$	IoU $\uparrow$	Precision $\uparrow$	Recall $\uparrow$	HD95 $\downarrow$ (px)	CBL $\uparrow$
U-Net	0.4740	0.3741	0.5847	0.5341	144.37	0.5709
Attention U-Net	0.4122	0.3291	0.5988	0.4065	136.75	0.5701
PGA-UNet (Bao trọn)	0.8607	0.7630	0.8476	0.8882	12.12	0.9564


Bảng 4.3: So sánh PGA-UNet với các mô hình cơ sở trên FracAtlas ở độ phân giải 512×512 (N=72 ảnh)

Mô hình	Dice $\uparrow$	IoU $\uparrow$	Precision $\uparrow$	Recall $\uparrow$	HD95 $\downarrow$ (px)	CBL $\uparrow$
U-Net	0.3831	0.2836	0.4387	0.4642	136.82	0.4628
Attention U-Net	0.2467	0.1816	0.4754	0.3006	186.46	0.3902
PGA-UNet (Bao trọn)	0.8169	0.6953	0.7645	0.8975	7.45	0.9546

Trong thiết lập phân đoạn có hướng dẫn bằng hộp giới hạn, PGA-UNet cho kết quả cao hơn các mô hình cơ sở trên cả hai bộ dữ liệu. So với U-Net, Dice tăng 0,3867 trên BTXRD và 0,4338 trên FracAtlas; HD95 cũng giảm

mạnh từ 144,37 xuống 12,12 và từ 136,82 xuống 7,45 điểm ảnh. CBL ở cả hai bộ dữ liệu đều lớn hơn 0,95. Tóm lại, khi đã có thông tin định vị sơ bộ thì mô hình chạy ổn hơn hẳn và không còn lệch nhiều như các mô hình tự động.

Attention U-Net trong thí nghiệm này không cải thiện được Dice so với U-Net. Còn PGA-UNet thì tăng cùng lúc nhiều chỉ số như Dice, IoU, Recall, HD95 và CBL trong so sánh giữa mô hình có câu nhắc và mô hình không dùng câu nhắc. Chỗ này chủ yếu cho thấy việc có thêm thông tin định vị từ hộp giới hạn là hữu ích với bài toán đang xét. Phần đóng góp riêng của từng thành phần kiến trúc sẽ được tách ra phân tích kỹ hơn ở Mục 4.3 và Phụ lục A. Hình 4.1 minh họa một số kết quả phân đoạn của PGA-UNet trong kịch bản Bao trọn.



Hình 4.1: Kết quả phân đoạn của PGA-UNet trong kịch bản Bao trọn. Từ trái sang phải: ảnh X-quang, hộp giới hạn câu nhắc, mặt nạ dự đoán, mặt nạ nhãn gốc và lớp phủ biểu diễn TP, FP và FN.

4.2.2

So sánh với mô hình nền tảng SAM-Med2D

Trong cấu hình thực nghiệm, SAM-Med2D [13] tiếp nhận ảnh ở kích thước 256×256 . Để bảo đảm so sánh tại cùng độ phân giải, PGA-UNet được huấn luyện lại từ đầu với kích thước tương ứng trên từng bộ dữ liệu, độc lập với phiên bản 512×512 tại Mục 4.2.1.

SAM-Med2D được đánh giá ở hai chế độ: chưa tinh chỉnh, sử dụng trực tiếp trọng số tiền huấn luyện; và đã tinh chỉnh, cập nhật lớp thích ứng cùng bộ giải mã trên từng bộ dữ liệu. Các cấu hình sử dụng cùng tập kiểm thử, kịch bản câu nhắc và phương pháp đánh giá cấp độ ảnh tại Mục 4.1.3.

Bảng 4.4: So sánh PGA-UNet với SAM-Med2D trên BTXRD ở độ phân giải 256×256 (N=187 ảnh)

Mô hình	Kịch bản	Dice $\uparrow$	IoU $\uparrow$	Precision $\uparrow$	Recall $\uparrow$	HD95 $\downarrow$ (px)	CBL $\uparrow$
PGA-UNet	Bao trọn	0.8433	0.7381	0.8112	0.8937	6.34	0.9488
PGA-UNet	Lệch tâm	0.8150	0.6982	0.7929	0.8574	7.59	0.9267
PGA-UNet	Hỗn hợp	0.8344	0.7255	0.8061	0.8809	6.73	0.9419
SAM-Med2D (đã tinh chỉnh)	Bao trọn	0.7541	0.6385	0.7504	0.7932	11.33	0.8949
SAM-Med2D (đã tinh chỉnh)	Lệch tâm	0.6912	0.5645	0.6987	0.7192	12.64	0.8564
SAM-Med2D (đã tinh chỉnh)	Hỗn hợp	0.7334	0.6150	0.7338	0.7687	11.79	0.8819
SAM-Med2D (chưa tinh chỉnh)	Bao trọn	0.5418	0.4002	0.4852	0.6808	17.50	0.8409
SAM-Med2D (chưa tinh chỉnh)	Lệch tâm	0.5266	0.3853	0.4755	0.6591	21.12	0.8014
SAM-Med2D (chưa tinh chỉnh)	Hỗn hợp	0.5432	0.4002	0.4859	0.6796	17.96	0.8318


Bảng 4.5: So sánh PGA-UNet với SAM-Med2D trên FracAtlas ở độ phân giải 256×256 (N=72 ảnh)

Mô hình	Kịch bản	Dice $\uparrow$	IoU $\uparrow$	Precision $\uparrow$	Recall $\uparrow$	HD95 $\downarrow$ (px)	CBL $\uparrow$
PGA-UNet	Bao trọn	0.8110	0.6886	0.7790	0.8628	3.57	0.9456
PGA-UNet	Lệch tâm	0.7842	0.6531	0.7566	0.8333	4.02	0.9260
PGA-UNet	Hỗn hợp	0.8088	0.6864	0.7801	0.8581	3.57	0.9431
SAM-Med2D (đã tinh chỉnh)	Bao trọn	0.7339	0.5897	0.7358	0.7508	4.33	0.9040
SAM-Med2D (đã tinh chỉnh)	Lệch tâm	0.6743	0.5227	0.6715	0.6925	5.19	0.8606
SAM-Med2D (đã tinh chỉnh)	Hỗn hợp	0.7209	0.5745	0.7185	0.7396	4.57	0.8916
SAM-Med2D (chưa tinh chỉnh)	Bao trọn	0.5278	0.3720	0.4854	0.6519	8.53	0.8514
SAM-Med2D (chưa tinh chỉnh)	Lệch tâm	0.4983	0.3460	0.4503	0.6195	9.72	0.8098
SAM-Med2D (chưa tinh chỉnh)	Hỗn hợp	0.5242	0.3691	0.4858	0.6436	8.86	0.8402

Ở cùng độ phân giải 256×256 , PGA-UNet cho kết quả cao hơn SAM-Med2D ở cả ba kịch bản trên cả hai bộ dữ liệu. Với câu nhắc Bao trọn, Dice của PGA-UNet cao hơn SAM-Med2D đã tinh chỉnh 0,0892 trên BTXRD và 0,0771 trên FracAtlas. So với SAM-Med2D chưa tinh chỉnh thì khoảng cách còn lớn hơn nữa, lên tới 0,3015 trên BTXRD và 0,2832 trên FracAtlas. Ngoài ra, PGA-UNet cũng có HD95 thấp hơn và CBL lớn hơn 0,94, nghĩa là mặt nạ dự đoán có xu hướng bám vị trí tổn thương tốt hơn trong thiết lập có câu nhắc được kiểm soát. Dù vậy, đây vẫn là kết quả so sánh của hai hệ thống hoàn chỉnh, chưa tách riêng đóng góp của từng thành phần kiến trúc.

Khi chuyển từ câu nhắc Bao trọn sang Lệch tâm, Dice của PGA-UNet giảm 0,0283 trên BTXRD và 0,0268 trên FracAtlas. Mức giảm này nhỏ hơn mức giảm tương ứng của SAM-Med2D đã tinh chỉnh (0,0629 trên BTXRD và 0,0596 trên FracAtlas). Có thể hiểu là trong các kịch bản mô phỏng của khóa luận, PGA-UNet giữ độ ổn định tốt hơn khi câu nhắc không còn lý tưởng nữa.

PGA-UNet được huấn luyện từ đầu trên từng bộ dữ liệu, trong khi SAM-Med2D kế thừa trọng số tiền huấn luyện trên tập ảnh y tế quy mô lớn. Vì vậy, kết quả trên phản ánh hiệu năng của các hệ thống hoàn chỉnh, không tách riêng đóng góp của từng thành phần kiến trúc. Vai trò của PSG và CAD được phân tích tại Mục 4.3 và Phụ lục A.



Hình 4.2: So sánh Dice của PGA-UNet và SAM-Med2D trong kịch bản Bao trộn trên BTXRD và FracAtlas. Các cấu hình đều sử dụng độ phân giải 256×256 và được đánh giá ở cấp độ ảnh.

4.2.3

Hiệu quả tính toán

Để phần so sánh không chỉ dừng ở độ chính xác, khóa luận còn đo thêm hiệu quả tính toán của PGA-UNet và SAM-Med2D trong cùng môi trường thực nghiệm. Các chỉ số được ghi nhận gồm số tham số, FLOPs, dung lượng checkpoint, bộ nhớ GPU đỉnh và độ trễ suy luận trung bình. PGA-UNet được đo ở cả 256×256 và 512×512 , còn SAM-Med2D được đo ở 256×256 , là độ phân giải dùng để đối sánh trực tiếp ở Mục 4.2.2. Các con số này chỉ mang ý nghĩa so sánh tương đối trong cùng môi trường đo.

Ở cùng độ phân giải 256×256 , PGA-UNet nhỏ hơn SAM-Med2D khoảng 92 lần về số tham số (2,95M so với 271,24M), khoảng 11,9 lần về FLOPs và nhanh hơn khoảng 7,2 lần trên GPU trong cùng môi trường thực nghiệm. Dung lượng điểm lưu trọng số cũng chênh lệch rất lớn, khoảng 215 lần (11,3 MB so với 2443,2 MB), cho thấy PGA-UNet có chi phí tính toán thấp hơn trong điều kiện đo của khóa luận.

Khi tăng độ phân giải của PGA-UNet lên 512×512 , FLOPs và độ trễ tăng như kỳ vọng, nhưng mô hình vẫn có độ trễ thấp hơn và dung lượng

nhỏ hơn rất nhiều so với SAM-Med2D ở 256×256 trong cùng môi trường đo. Bảng số liệu rút gọn và biểu đồ tổng hợp của phép đo này được đưa xuống Phụ lục A, Mục A.1, nhằm giữ cho phần thân bài tập trung vào hai ý chính: trong điều kiện thực nghiệm đã khảo sát, PGA-UNet có chi phí tính toán thấp hơn, trong khi SAM-Med2D đòi hỏi tài nguyên lớn hơn.

4.2.4

Ảnh hưởng của độ phân giải và sai lệch câu nhắc

Mục này khảo sát ảnh hưởng của độ phân giải đầu vào và sai lệch câu nhắc đối với PGA-UNet. Hai phiên bản ở kích thước 256×256 và 512×512 được huấn luyện độc lập trên từng bộ dữ liệu, sau đó đánh giá trong ba kịch bản Bao trọn, Lệch tâm và Hỗn hợp. Cách tạo các kịch bản câu nhắc được định nghĩa tại Mục 3.2.1 và giữ cố định trong toàn bộ thực nghiệm.

Như đã lưu ý tại Mục 4.1.2, kích thước cửa sổ Gaussian ($k = 31$) và biên mở rộng hộp giới hạn (5 điểm ảnh) được giữ cố định theo số điểm ảnh tuyệt đối cho cả hai độ phân giải. Vì vậy, so với kích thước ảnh, câu nhắc ở 256×256 được làm mềm và mở rộng tương đối nhiều hơn so với câu nhắc ở 512×512 . Đây là một yếu tố có thể ảnh hưởng đồng thời cùng với độ phân giải khi so sánh hai cấu hình dưới đây, nên chênh lệch Dice giữa hai độ phân giải không được xem là chỉ phản ánh riêng lượng thông tin không gian của ảnh.

Bảng 4.6: Kết quả PGA-UNet tại hai độ phân giải trên BTXRD (N=187 ảnh)

Độ phân giải	Kịch bản	Dice $\uparrow$	IoU $\uparrow$	Precision $\uparrow$	Recall $\uparrow$	HD95 $\downarrow$ (px)	CBL $\uparrow$
256×256	Bao trọn	0.8433	0.7381	0.8112	0.8937	6.34	0.9488
256×256	Lệch tâm	0.8150	0.6982	0.7929	0.8574	7.59	0.9267
256×256	Hỗn hợp	0.8344	0.7255	0.8061	0.8809	6.73	0.9419
512×512	Bao trọn	0.8607	0.7630	0.8476	0.8882	12.12	0.9564
512×512	Lệch tâm	0.8423	0.7381	0.8405	0.8621	14.14	0.9433
512×512	Hỗn hợp	0.8560	0.7567	0.8477	0.8803	12.62	0.9537


Bảng 4.7: Kết quả PGA-UNet tại hai độ phân giải trên FracAtlas (N=72 ảnh)

Độ phân giải	Kịch bản	Dice $\uparrow$	IoU $\uparrow$	Precision $\uparrow$	Recall $\uparrow$	HD95 $\downarrow$ (px)	CBL $\uparrow$
256×256	Bao trọn	0.8110	0.6886	0.7790	0.8628	3.57	0.9456
256×256	Lệch tâm	0.7842	0.6531	0.7566	0.8333	4.02	0.9260
256×256	Hỗn hợp	0.8088	0.6864	0.7801	0.8581	3.57	0.9431
512×512	Bao trọn	0.8169	0.6953	0.7645	0.8975	7.45	0.9546
512×512	Lệch tâm	0.7850	0.6537	0.7349	0.8618	8.88	0.9308
512×512	Hỗn hợp	0.8129	0.6904	0.7614	0.8913	7.80	0.9499

Lưu ý: HD95 được tính theo đơn vị điểm ảnh tại từng độ phân giải nên không thể so sánh trực tiếp giữa ảnh 256×256 và 512×512 . Vì vậy, các giá trị HD95 không được in đậm trong hai bảng trên.

Khi tăng độ phân giải từ 256×256 lên 512×512 , Dice đều tăng ở cả ba kịch bản trên hai bộ dữ liệu, nhưng mức tăng không giống nhau. Trên BTXRD, chênh lệch tăng rõ hơn; còn trên FracAtlas, mức tăng nhỏ hơn nhiều. Một số chỉ số như Precision trên FracAtlas còn giảm nhẹ ở độ phân giải cao hơn. Vì bản đồ câu nhắc cũng thay đổi theo tỉ lệ tương đối giữa hai độ phân giải, nên kết quả này không nên hiểu đơn giản là chỉ do ảnh lớn hơn, mà là tác động tổng hợp của cả độ phân giải ảnh và cách chuẩn hóa câu nhắc.


PGA-UNet duy trì mức suy giảm Dice tương đối nhỏ khi chuyển từ câu nhắc Bao trọn sang Lệch tâm. Mức giảm nằm trong khoảng từ 0,0184 đến



Hình 4.3: Kết quả PGA-UNet tại hai độ phân giải trong ba kịch bản câu nhắc trên BTXRD và FracAtlas.

0,0319 trên hai độ phân giải và hai bộ dữ liệu. Kết quả này cần được hiểu là độ ổn định đối với dạng sai lệch câu nhắc mô phỏng đã khảo sát, không phải khẳng định tổng quát về độ bền vững trước mọi dạng prompt sai lệch trong thực tế. Khả năng này vẫn cần được kiểm chứng với câu nhắc do bác sĩ cung cấp trong thực tế. Cần lưu ý thêm rằng hộp giới hạn Lệnh tâm dùng để đánh giá được sinh bằng cùng quy tắc (dịch ngẫu nhiên bằng 0,30 kích thước hộp) đã sử dụng khi huấn luyện, nên kết quả phản ánh độ ổn định của mô hình đối với đúng dạng nhiễu đã học, chưa phải bằng chứng về mức độ sai lệch chưa từng thấy hoặc do người dùng thực tế tạo ra.

Hình 4.4 minh họa phản ứng của PGA-UNet trước câu nhắc Lệch tâm trên một ảnh thuộc mỗi bộ dữ liệu. Trong ví dụ BTXRD, Dice giảm từ 0,922 xuống 0,917; trong ví dụ FracAtlas, Dice giảm từ 0,781 xuống 0,643. Đây là các trường hợp minh họa và không thay thế kết quả trung bình trên toàn bộ tập kiểm thử.



Hình 4.4: Kết quả PGA-UNet với câu nhắc Bao tròn và Lệch tâm trên BTXRD (hàng trên) và FracAtlas (hàng dưới).

4.3

Tổng hợp đóng góp kiến trúc và tính nhất quán trên hai bộ dữ liệu

Bên cạnh các phép so sánh chính, khóa luận còn làm thêm ba nhóm thực nghiệm bổ sung để xem đóng góp của từng thành phần kiến trúc rõ đến đâu. Ba nhóm đó gồm nghiên cứu loại bỏ thành phần, đánh giá chéo 4-fold và phân tích theo đặc tính tổn thương. Các thí nghiệm này được thực hiện độc lập trên cả BTXRD và FracAtlas. Trong mục này chỉ tóm tắt các kết luận quan trọng nhất; số liệu đầy đủ và hình minh họa bổ sung được để ở Phụ lục A.

4.3.1

Đóng góp của PSG, CAD và bản đồ nhiệt Gaussian

Tám cấu hình, tổ hợp giữa có/không PSG, ba lựa chọn cho cơ chế chú ý trên các kết nối tắt của nhánh giải mã (không cổng chú ý, cổng chú ý nguyên bản của Attention U-Net [17], hoặc CAD) và hai cách biểu diễn câu nhắc (nhị phân hoặc Gaussian), được huấn luyện lại từ đầu trên cùng dữ liệu và cùng điều kiện huấn luyện của BTXRD và FracAtlas. U-Net+Concat, chỉ nối câu nhắc vào ảnh đầu vào, đóng vai trò cấu hình cơ sở cùng nhận câu nhắc như PGA-UNet.

Bảng 4.8: Tổng hợp Dice của ba cấu hình chính trong nghiên cứu loại bỏ thành phần trên BTXRD và FracAtlas (ba kịch bản câu nhắc)

Cấu hình	BTXRD			FracAtlas		
	Bao trọn↑	Lệch tâm↑	Hỗn hợp↑	Bao trọn↑	Lệch tâm↑	Hỗn hợp↑
U-Net+Concat (Gaussian, cơ sở có câu nhắc)	0.8763	0.7364	0.8216	0.8131	0.6579	0.7573
Cấu hình tốt nhất ở Bao trọn*	0.8861	0.7406	0.8292	0.8351	0.6927	0.7838
PGA-UNet	0.8607	0.8423	0.8560	0.8169	0.7850	0.8129

*Cấu hình đạt Dice cao nhất ở kịch bản Bao trọn trong tám cấu hình khảo sát: U-Net+CAD trên BTXRD, U-Net+PSG+Cổng chú ý nguyên bản trên FracAtlas. Toàn bộ tám cấu hình được trình bày tại Bảng A.2 và A.8, Phụ lục A.

Bảng 4.8 cho thấy một xu hướng rõ ràng trên cả hai bộ dữ liệu. PGA-UNet không phải cấu hình có Dice cao nhất trong kịch bản Bao trọn (thấp hơn cấu hình tốt nhất 0,0254 trên BTXRD và 0,0182 trên FracAtlas), nhưng lại là cấu hình tốt nhất ở hai kịch bản Lệch tâm và Hỗn hợp. Nói ngắn gọn, điểm mạnh chính của mô hình không nằm ở trường hợp câu nhắc quá đẹp, mà nằm ở khả năng giữ kết quả ổn hơn khi câu nhắc có sai lệch như trong các tình huống mô phỏng của khóa luận.

Để kiểm tra độ tin cậy của xu hướng trên ở cấp độ ảnh, sáu cặp cấu hình được kiểm định bằng Wilcoxon signed-rank trên Dice bắt cặp theo từng ảnh, thực hiện riêng trên hai bộ dữ liệu và ba kịch bản (36 kết quả, giá trị p thô, chưa hiệu chỉnh cho so sánh nhiều lần). Hai phát hiện có bằng chứng mạnh và nhất quán nhất trên cả hai bộ dữ liệu đều thuộc kịch bản Lệch tâm:

- Thay cổng chú ý nguyên bản (đã có PSG) bằng CAD làm Dice tăng 0,1065 trên BTXRD và 0,0924 trên FracAtlas, cả hai đều đạt $p < 0,001$.
- Thay câu nhắc nhị phân bằng bản đồ nhiệt Gaussian (trong cấu hình đầy đủ PSG+CAD) làm Dice tăng 0,0990 trên BTXRD và 0,1005 trên FracAtlas, cả hai đều đạt $p < 0,001$.

Đây là hai bằng chứng thống kê nhất quán và mạnh nhất cho vai trò của CAD và bản đồ nhiệt Gaussian đối với khả năng duy trì hiệu năng dưới sai lệch câu nhắc mô phỏng. Ngược lại, khi PSG hoặc CAD được sử dụng riêng lẻ (không kết hợp với thành phần còn lại), mức cải thiện so với

U-Net+Concat đều nhỏ hơn 0,02 Dice và không nhất quán chiều giữa hai bộ dữ liệu; các thành phần riêng lẻ vì vậy không được xem là quy luật kiến trúc chung. Toàn bộ tám cấu hình, phân tích theo từng thành phần trên từng bộ dữ liệu và bảng kiểm định Wilcoxon đầy đủ (36 kết quả) được trình bày tại Mục A.2.1, A.3.1 và A.4, Phụ lục A.

4.3.2

Độ ổn định qua các phân vùng dữ liệu

PGA-UNet cũng được đánh giá bằng 4-fold cross-validation trên cả BTXRD và FracAtlas, trong đó các đa giác thuộc cùng một ảnh luôn được giữ trong cùng một phân vùng. Trên BTXRD, độ lệch chuẩn của Dice qua bốn phân vùng nằm trong khoảng 0,0087 đến 0,0119; còn trên FracAtlas là 0,0064 đến 0,0084. Giá trị Dice trung bình giữa các phân vùng cũng sát với kết quả trên tập kiểm thử độc lập.

Độ lệch chuẩn tương đối thấp trên cả hai bộ dữ liệu cho thấy PGA-UNet tương đối ổn định trước các cách chia dữ liệu đã khảo sát. Dù vậy, kết quả này chưa thay cho việc đánh giá qua nhiều lần khởi tạo ngẫu nhiên khác nhau. Các bảng chi tiết hơn được để ở Phụ lục A.

4.3.3

Hiệu năng theo đặc tính tổn thương

PGA-UNet được đối chiếu với U-Net và SAM-Med2D trên các nhóm ảnh phân theo đặc tính tổn thương (kích thước, độ rõ đường biên) trên cả hai bộ dữ liệu. Trong các nhóm được khảo sát, khoảng cách Dice giữa PGA-UNet và mô hình đối sánh lớn nhất ở nhóm tổn thương nhỏ (BTXRD: PGA-UNet cao hơn SAM-Med2D 0,5514 Dice; FracAtlas: cao hơn khoảng 0,319), thu hẹp dần và gần bằng nhau hơn ở nhóm tổn thương có hình thái rõ ràng (BTXRD: chênh lệch còn 0,0131; FracAtlas: còn khoảng 0,068). Khi so sánh với U-Net trên các ảnh mà U-Net hoạt động kém, xu hướng tương tự cũng xuất hiện trên cả hai bộ dữ liệu: ở nhóm

BOTTOM-DICE (ảnh U-Net dự đoán kém nhất), U-Net đạt Dice rất thấp ($\text{BTXRD} = 0,0211$; $\text{FracAtlas} = 0,1130$), trong khi PGA-UNet vẫn đạt trên 0,80 ở cả hai bộ dữ liệu ($\text{BTXRD} 0,8261$; $\text{FracAtlas} 0,8015$).

Một trong ba nhóm phân tích (“Biên mờ”) được xác định dựa trên chính Dice thấp của SAM-Med2D trên từng bộ dữ liệu, nên chỉ mang tính mô tả, không phải một phép kiểm định độc lập về độ khó của tổn thương. Toàn bộ bảng số liệu, biểu đồ và hình ảnh định tính theo từng nhóm được trình bày tại Mục A.2.3 và A.3.3, Phụ lục A.

Các trường hợp còn hạn chế. Qua quan sát định tính trên tập kiểm thử, PGA-UNet vẫn đạt Dice thấp trên một số tổn thương có hình dạng kéo dài hoặc phân nhánh, tổn thương nằm tại vùng giải phẫu chồng lấp (vai, xương đòn, cổ chân), hoặc trên ảnh có độ tương phản thấp. Hình 4.5 minh họa một trường hợp tổn thương tại vùng vai, xương đòn và lồng ngực chồng lấp, nơi mô hình chỉ đạt Dice 0,762 dù hộp giới hạn đã bao phủ đúng vùng tổn thương.



Hình 4.5: Trường hợp tổn thương tại vùng giải phẫu chồng lấp ở vai, xương đòn và lồng ngực, với Dice đạt 0,762.

Các nhóm khó nêu trên được nhận diện bằng quan sát định tính, chưa được bác sĩ xác nhận hoặc kiểm định thống kê độc lập; chúng chỉ mô tả những tình huống mô hình còn gặp khó khăn, phù hợp với các hạn chế được tổng hợp tại Chương 5.

4.3.4

Kết luận về phạm vi đóng góp kiến trúc

Kết quả nhất quán nhất trên cả BTXRD và FracAtlas là vai trò của CAD và bản đồ nhiệt Gaussian đối với khả năng duy trì hiệu năng khi câu nhắc bị lệch tâm, được xác nhận bằng kiểm định Wilcoxon với $p < 0,001$ trên cả hai bộ dữ liệu. PGA-UNet được huấn luyện lại độc lập trên từng bộ dữ liệu và duy trì cùng xu hướng trên cả tổn thương khối u xương lẫn đường gãy xương, cung cấp bằng chứng về khả năng tái lập của thiết kế trên hai miền dữ liệu độc lập; đây chưa phải tổng quát hóa liên miền theo nghĩa huấn luyện trên một bộ dữ liệu rồi suy luận trực tiếp trên miền chưa từng thấy.

Các thành phần riêng lẻ (PSG hoặc CAD khi đứng một mình) có biên độ ảnh hưởng nhỏ và không nhất quán giữa hai bộ dữ liệu, nên không được diễn giải như một quy luật kiến trúc tổng quát. Phạm vi kết luận của mục này giới hạn ở mô-đun phân đoạn; khả năng hoạt động của toàn bộ hệ thống, bao gồm tầng sàng lọc đầu vào, được đánh giá riêng tại Mục 4.4. Phần chứng minh đầy đủ cho các kết luận trên, bao gồm bảng Wilcoxon 36 kết quả và toàn bộ số liệu theo từng cấu hình, được trình bày tại Mục A.4, Phụ lục A.

4.4

Đánh giá luồng xử lý hỗ trợ hai giai đoạn

Để minh họa cách PGA-UNet có thể được dùng trong một quy trình lớn hơn, khóa luận thực hiện một thử nghiệm mở rộng bằng cách đặt Gatekeeper (EfficientNet-B3 [29]) trước PGA-UNet. Vai trò của Gatekeeper là phân loại ảnh thành bình thường hoặc nghi ngờ có bất thường trước khi đi tiếp sang bước phân đoạn. Thử nghiệm này không nhằm giới thiệu một hệ thống lâm sàng hoàn chỉnh, mà chỉ muốn cho thấy lỗi sàng lọc ở bước đầu có thể ảnh hưởng thế nào đến mô-đun phân đoạn ở bước sau. Toàn bộ số liệu chi tiết được để ở Phụ lục B.

Trên BTXRD, Gatekeeper đạt AUC-ROC 0,9421, Sensitivity 89,30% và Specificity 86,17%. Khi kết quả Gatekeeper được sử dụng trực tiếp không qua hiệu chỉnh của người dùng, 20/187 ảnh bệnh lý bị loại nhầm; Dice toàn luồng có phạt lỗi định tuyến giảm từ 0,8626 (trên ảnh được định tuyến đúng) xuống 0,6763. Trên FracAtlas, do dữ liệu mất cân bằng hơn (72/409 ảnh bệnh lý), Gatekeeper chỉ đạt Sensitivity 70,83% dù Specificity vẫn cao (91,99%); Dice toàn luồng giảm còn 0,4230, thấp hơn nhiều so với Dice 0,8169 của PGA-UNet khi được đánh giá độc lập trên toàn bộ tập kiểm thử bệnh lý.

Kết quả trên cả hai bộ dữ liệu cho thấy sai số tại bước sàng lọc có thể làm giảm đáng kể hiệu năng toàn luồng, đặc biệt khi dữ liệu mất cân bằng. Vì vậy, Gatekeeper chỉ nên đóng vai trò hỗ trợ ưu tiên ca nghi ngờ; quyết định chuyển bước và cung cấp câu nhắc vẫn cần sự xác nhận của người dùng chuyên môn, đúng theo cơ chế *triage mềm* đã trình bày tại Mục 3.3.1, Chương 3.

4.5

Tổng kết chương

Chương này đã trình bày toàn bộ phần thực nghiệm của PGA-UNet trên BTXRD và FracAtlas, gồm so sánh với các mô hình cơ sở, so sánh với SAM-Med2D, khảo sát ảnh hưởng của độ phân giải và tổng hợp kết quả từ nghiên cứu loại bỏ thành phần, đánh giá chéo và phân tích theo đặc tính tổn thương. Trong phạm vi phân đoạn có hướng dẫn bằng hộp giới hạn, PGA-UNet cho kết quả tốt hơn các mô hình cơ sở không dùng câu nhắc và cũng cao hơn SAM-Med2D trong phép so sánh cùng điều kiện ở độ phân giải 256×256 . Mô hình cũng giữ được độ ổn định tốt hơn dưới các sai lệch câu nhắc đã mô phỏng.

Kết quả nghiên cứu loại bỏ thành phần cho thấy hiệu quả của mô hình đến từ sự phối hợp giữa PSG, CAD và bản đồ nhiệt Gaussian, trong đó CAD và bản đồ nhiệt Gaussian là hai phần nổi bật hơn ở khả năng chịu lệch câu nhắc. Khi huấn luyện lại trên FracAtlas, xu hướng kết quả chính vẫn được giữ, nghĩa là thiết kế của PGA-UNet giữ được sự nhất quán nhất định trên hai bộ dữ liệu khảo sát. Các bảng số liệu chi tiết hơn được trình bày ở Phụ lục A.

Thử nghiệm mở rộng với Gatekeeper cho thấy bước sàng lọc có thể hữu ích nếu muốn đặt PGA-UNet trong một luồng xử lý ảnh hỗn hợp. Tuy nhiên, sai số ở bước này cũng có thể kéo hiệu năng toàn luồng giảm đáng kể. Vì vậy, Gatekeeper chỉ nên được dùng như công cụ hỗ trợ, còn việc chuyển bước và cung cấp câu nhắc vẫn cần người dùng xác nhận.

Nhìn chung, phần thực nghiệm làm rõ thêm rằng đóng góp chính của khóa luận nằm ở kiến trúc PGA-UNet và cách khai thác câu nhắc thông qua PSG, CAD và bản đồ nhiệt Gaussian. Những hạn chế còn lại và hướng phát triển tiếp theo được trình bày ở Chương 5.

CHƯƠNG 5

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1

Kết luận và đóng góp đạt được

Khóa luận này xây dựng PGA-UNet, là một mô hình phân đoạn tương tác cho ảnh X-quang xương có dùng hộp giới hạn làm câu nhắc. Ý của khóa luận là không để mô hình tự làm hết bước tìm tổn thương, mà để người dùng khoanh sơ bộ vùng nghi ngờ trước, sau đó mô hình mới làm tiếp phần phân đoạn chi tiết hơn. Với bài toán ảnh X-quang xương, cách làm như vậy được xem là hợp lý hơn, vì tổn thương thường khó thấy rõ và cũng dễ bị nhiễu bởi các cấu trúc xung quanh.

Về mặt kỹ thuật, phần chính của khóa luận nằm ở cách đưa câu nhắc vào sâu trong mạng. PSG được dùng ở bộ mã hóa để điều biến đặc trưng theo vùng mà người dùng đang quan tâm. CAD thì được dùng ở nhánh giải mã để tiếp tục tận dụng thông tin câu nhắc trong lúc khôi phục mặt nạ. Ngoài ra, hộp giới hạn cũng không được dùng trực tiếp dưới dạng tọa độ rời rạc, mà được đổi thành bản đồ nhiệt Gaussian dạng cao nguyên để tín hiệu không gian liên tục và mềm hơn.

Trong thực nghiệm, PGA-UNet cho kết quả cao hơn U-Net và Attention U-Net trong thiết lập so sánh giữa mô hình có câu nhắc và mô hình không có câu nhắc. Khi so sánh cùng điều kiện đầu vào với SAM-Med2D ở độ phân giải 256×256 , PGA-UNet cũng tốt hơn trên cả hai bộ dữ liệu được khảo sát. Mô hình này cũng giữ được độ ổn định tốt hơn trong các kịch bản câu nhắc bị lệch tâm mà khóa luận đã mô phỏng. Phần nghiên cứu loại bỏ thành phần cho thấy hiệu quả của mô hình không đến từ một thành phần riêng lẻ, mà chủ yếu đến từ việc PSG, CAD và bản đồ nhiệt Gaussian đi cùng nhau.

Khi mô hình được huấn luyện lại độc lập trên FracAtlas, xu hướng kết quả chính vẫn được giữ. Nói vậy không có nghĩa là mô hình đã tổng quát hóa rộng. Ít nhất, kết quả này cho thấy thiết kế của PGA-UNet không chỉ phù hợp với một bộ dữ liệu duy nhất. Dù vậy, chỗ này vẫn chưa thể xem là bằng chứng cho khả năng tổng quát hóa liên miền theo nghĩa chặt, vì

mô hình vẫn được huấn luyện riêng trên từng bộ dữ liệu trước khi đánh giá.

Khóa luận cũng làm thêm một thử nghiệm mở rộng với Gatekeeper dùng EfficientNet-B3 để xem PGA-UNet có thể đặt trong một luồng xử lý gồm cả ảnh bình thường và ảnh bệnh lý như thế nào. Chỗ này cho thấy nếu bước sàng lọc bỏ sót ảnh bệnh lý thì hiệu năng toàn luồng giảm mạnh. Vì thế, Gatekeeper chỉ nên đóng vai trò hỗ trợ sàng lọc hoặc ưu tiên ảnh nghi ngờ. Quyết định cuối cùng thì vẫn cần người dùng chuyên môn xác nhận.

Về hiệu quả tính toán, PGA-UNet cũng có lợi thế rõ rệt trong môi trường thực nghiệm của khóa luận. Ở độ phân giải 256×256 , mô hình nhỏ hơn SAM-Med2D khoảng 92 lần về số tham số, 11,9 lần về FLOPs và có độ trễ suy luận thấp hơn trên cả GPU lẫn CPU. Nói ngắn gọn thì PGA-UNet hợp hơn với hướng làm gọn nhẹ và phản hồi nhanh.

Phần quan trọng nhất trong khóa luận này vẫn là mô hình PGA-UNet và cách khai thác câu nhắc trực quan thông qua PSG, CAD cùng bản đồ nhiệt Gaussian. Dù kết quả thực nghiệm nhìn chung là tốt, mô hình hiện vẫn mới dừng ở mức nghiên cứu trong điều kiện câu nhắc được kiểm soát. Vì vậy, nói đến chuyện triển khai trong môi trường lâm sàng thực tế thì còn sớm.

5.2

Hạn chế của nghiên cứu

Bên cạnh các kết quả đạt được, nghiên cứu này vẫn còn một số hạn chế. Nếu không nói rõ các điểm này thì phần kết luận rất dễ bị hiểu quá lên:

- **Câu nhắc được mô phỏng từ nhãn gốc, kể cả khi ảnh có nhiều vùng tổn thương:** Hộp giới hạn trong thực nghiệm được tạo tự động từ mặt nạ nhãn gốc và điều chỉnh theo các kịch bản Bao trọn, Lềch tâm và Hỗn hợp; đối với ảnh có nhiều vùng tổn thương, số lượng và vị trí gần đúng của từng vùng cũng được lấy trực tiếp từ nhãn gốc (Mục 4.1.3, Chương 4). Cách thiết lập này giúp kiểm soát thí nghiệm và đo đúng chất lượng phân đoạn khi đã có hộp đúng, nhưng chưa phản ánh đầy đủ sự khác biệt về vị trí, kích thước và thao tác giữa những người dùng trong thực tế, cũng như chưa đánh giá một hệ thống phải tự phát hiện số lượng và vị trí tổn thương.

Ngoài ra, quy tắc sinh sai lệch Lềch tâm (dịch ngẫu nhiên bằng 0,30 kích thước hộp) được dùng thống nhất trong cả huấn luyện và đánh giá. Vì vậy, kết quả về độ ổn định phản ánh khả năng thích nghi của mô hình với đúng dạng nhiễu đã học, chưa phải bằng chứng về mức độ sai lệch chưa từng thấy khi huấn luyện hoặc về hành vi khi câu nhắc không giao với tổn thương hoặc khi ảnh không có tổn thương nhưng vẫn được cung cấp hộp giới hạn, do dữ liệu huấn luyện phân đoạn hiện chỉ gồm ảnh bệnh lý với hộp luôn chứa đúng tổn thương.

- **Phạm vi dữ liệu còn hạn chế:** PGA-UNet được huấn luyện và đánh giá riêng trên BTXRD và FracAtlas. Cả hai đều là bộ dữ liệu công khai đã được chuẩn hóa; nghiên cứu chưa đánh giá trên dữ liệu X-quang thô từ cơ sở y tế, dữ liệu từ thiết bị chụp khác hoặc phép thử liên miền không tinh chỉnh. Việc phân chia tập huấn luyện, xác thực và kiểm thử được thực hiện ở cấp độ ảnh (Mục 4.1.1, Chương 4); do siêu dữ liệu công khai không cung cấp mã định danh bệnh nhân đầy đủ, khóa luận chưa

xác nhận được liệu có ảnh của cùng một bệnh nhân xuất hiện ở nhiều tập khác nhau hay không.

- **Một số chi tiết tái lập chưa được mô tả đầy đủ:** Một số chi tiết triển khai của SAM-Med2D (tinh chỉnh) và Gatekeeper chưa được trình bày đầy đủ trong thân bài khóa luận dù đã được áp dụng nhất quán trong mã nguồn thực nghiệm. Ngoài ra, hai mô-đun này không cố định giá trị khởi tạo ngẫu nhiên và mỗi cấu hình chỉ được chạy một lần, nên khóa luận chưa có ước lượng phương sai giữa các lần chạy độc lập.
- **Thông tin không gian chỉ ở dạng hai chiều:** Ảnh X-quang là hình chiếu hai chiều của cấu trúc giải phẫu ba chiều. Hiện tượng chồng lấp giữa các cấu trúc xương có thể làm mờ ranh giới tổn thương. Bản đồ nhiệt Gaussian chỉ cung cấp vùng định hướng tương đối và không biểu diễn trực tiếp hình dạng phức tạp của tổn thương kéo dài, phân nhánh hoặc không liên tục.
- **Giới hạn về độ phân giải đầu vào:** Ảnh được chuẩn hóa về 512×512 hoặc 256×256 bằng cách co giãn giữ tỷ lệ khung hình gốc rồi đệm (*padding*) về khung vuông để phù hợp với tài nguyên huấn luyện. Quy trình này tránh làm méo hình dạng tổn thương do ép ảnh về tỉ lệ 1:1, nhưng vẫn có thể làm mất chi tiết của đường gãy hoặc tổn thương rất nhỏ so với ảnh gốc do giới hạn độ phân giải đầu vào và do vùng đệm làm giảm phần diện tích hữu ích của ảnh trong khung chuẩn hóa.
- **Chưa có đánh giá với người dùng chuyên môn:** Nghiên cứu chưa đo thời gian thao tác, mức độ thuận tiện, độ biến thiên giữa người dùng hoặc khả năng hiệu chỉnh kết quả trong một quy trình đọc ảnh thực tế. Vì vậy, hiệu quả hỗ trợ bác sĩ mới được suy luận từ kết quả kỹ thuật, chưa được xác nhận bằng nghiên cứu người dùng.
- **Sai số tại mô-đun sàng lọc:** Gatekeeper và PGA-UNet được huấn luyện độc lập nên ảnh bệnh lý bị Gatekeeper bỏ sót sẽ không đến được

bước phân đoạn trong kịch bản không có người dùng xác nhận. Hạn chế này thể hiện rõ hơn trên FracAtlas, nơi Gatekeeper có Sensitivity thấp hơn BTXRD. Tuy nhiên, Gatekeeper chỉ là thử nghiệm mở rộng và không thuộc đóng góp kiến trúc chính của PGA-UNet.

5.3

Định hướng phát triển

Từ các hạn chế trên, khóa luận có thể đi tiếp theo một số hướng sau:

- **Đánh giá với câu nhắc do người dùng cung cấp:** Thực hiện thử nghiệm với bác sĩ hoặc người có chuyên môn trực tiếp vẽ hộp giới hạn trên ảnh X-quang. Kết quả cần được đánh giá theo độ chính xác phân đoạn, thời gian thao tác, mức độ khác biệt giữa người dùng và số lần hiệu chỉnh cần thiết. Đây là bước quan trọng để kiểm chứng độ ổn định thực tế của PGA-UNet ngoài các kịch bản câu nhắc mô phỏng.
- **Mở rộng đánh giá trên dữ liệu ngoài:** Kiểm định mô hình trên dữ liệu thu thập từ nhiều cơ sở y tế, thiết bị và điều kiện chụp khác nhau. Ngoài việc huấn luyện lại trên từng bộ dữ liệu, cần bổ sung thí nghiệm huấn luyện trên một miền và suy luận trực tiếp trên miền khác để đánh giá khả năng tổng quát hóa liên miền theo nghĩa chặt.
- **Xử lý ảnh có độ phân giải cao:** Phát triển cơ chế xử lý theo vùng quan tâm hoặc cửa sổ trượt có điều kiện theo câu nhắc, qua đó giữ lại chi tiết của tổn thương nhỏ mà không làm tăng quá mức chi phí tính toán. Các bộ mã hóa phân cấp cũng có thể được khảo sát, nhưng cần bảo đảm kiến trúc vẫn duy trì ưu điểm gọn nhẹ.
- **Học từ nhãn thưa:** Kết hợp một tập nhỏ có mặt nạ phân đoạn đầy đủ với tập lớn hơn chỉ có hộp giới hạn. PGA-UNet có thể được mở rộng theo hướng học bán giám sát hoặc sinh nhân giả, qua đó giảm chi phí tạo chú thích đa giác ở cấp độ pixel.

- **Kết hợp thông tin lâm sàng:** Khảo sát cơ chế dung hợp đặc trưng hình ảnh với các thông tin như tuổi, giới tính, vị trí đau hoặc tiền sử bệnh. Thông tin bổ sung có thể hỗ trợ phân biệt các trường hợp khó, nhưng cần được đánh giá trên dữ liệu lâm sàng được thu thập và ẩn danh đúng quy trình.

Việc cần làm trước vẫn là kiểm tra PGA-UNet với câu nhắc do người dùng thật cung cấp và trên dữ liệu ngoài môi trường công khai. Làm xong bước đó rồi mới nên tính tiếp đến các hướng như xử lý ảnh độ phân giải cao, học từ nhãn thừa, kết hợp thêm thông tin lâm sàng hoặc cải tiến Gatekeeper để hệ thống có khả năng dùng thực tế tốt hơn.

TÀI LIỆU THAM KHẢO

- [1] Cambridge University Hospitals NHS Foundation Trust. “X-ray – Imaging & Radiology.” (), [Online]. Available: <https://www.cuh.nhs.uk/our-services/imaging-radiology/x-ray/> (visited on 07/15/2026).
- [2] G. Litjens, T. Kooi, B. E. Bejnordi, *et al.*, “A Survey on Deep Learning in Medical Image Analysis,” *Medical Image Analysis*, vol. 42, pp. 60–88, 2017. DOI: 10.1016/j.media.2017.07.005. [Online]. Available: <https://doi.org/10.1016/j.media.2017.07.005>.
- [3] D. Shen, G. Wu, and H.-I. Suk, “Deep Learning in Medical Image Analysis,” *Annual Review of Biomedical Engineering*, vol. 19, pp. 221–248, 2017. DOI: 10.1146/annurev-bioeng-071516-044442. [Online]. Available: <https://doi.org/10.1146/annurev-bioeng-071516-044442>.
- [4] S. Minaee, Y. Boykov, F. Porikli, A. Plaza, N. Kehtarnavaz, and D. Terzopoulos, “Image Segmentation Using Deep Learning: A Survey,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 44, no. 7, pp. 3523–3542, 2022. DOI: 10.1109/TPAMI.2021.3059968. [Online]. Available: <https://doi.org/10.1109/TPAMI.2021.3059968>.
- [5] J. Long, E. Shelhamer, and T. Darrell, “Fully Convolutional Networks for Semantic Segmentation,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2015, pp. 3431–3440. DOI: 10.1109/CVPR.2015.7298965. [Online]. Available: <https://doi.org/10.1109/CVPR.2015.7298965>.

- [6] V. Badrinarayanan, A. Kendall, and R. Cipolla, “SegNet: A Deep Convolutional Encoder-Decoder Architecture for Image Segmentation,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 39, no. 12, pp. 2481–2495, 2017. DOI: 10.1109/TPAMI.2016.2644615. [Online]. Available: <https://doi.org/10.1109/TPAMI.2016.2644615>.
- [7] L.-C. Chen, Y. Zhu, G. Papandreou, F. Schroff, and H. Adam, “Encoder-Decoder with Atrous Separable Convolution for Semantic Image Segmentation,” *Proceedings of the European Conference on Computer Vision*, pp. 801–818, 2018. DOI: 10.1007/978-3-030-01234-2_49. [Online]. Available: https://doi.org/10.1007/978-3-030-01234-2_49.
- [8] F. Milletari, N. Navab, and S.-A. Ahmadi, “V-Net: Fully Convolutional Neural Networks for Volumetric Medical Image Segmentation,” *arXiv preprint arXiv:1606.04797*, 2016. DOI: 10.48550/arXiv.1606.04797. arXiv: 1606.04797 [cs.CV]. [Online]. Available: <https://arxiv.org/abs/1606.04797>.
- [9] O. Ronneberger, P. Fischer, and T. Brox, “U-Net: Convolutional Networks for Biomedical Image Segmentation,” in *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015*, ser. Lecture Notes in Computer Science, vol. 9351, Springer, 2015, pp. 234–241. DOI: 10.1007/978-3-319-24574-4_28. [Online]. Available: https://doi.org/10.1007/978-3-319-24574-4_28.
- [10] Z. Zhou, M. M. R. Siddiquee, N. Tajbakhsh, and J. Liang, “UNet++: A Nested U-Net Architecture for Medical Image Segmentation,” *Deep Learning in Medical Image Analysis and Multimodal Learning for Clinical Decision Support*, pp. 3–11, 2018. DOI: 10.1007/978-3-030-00889-5_1. [Online]. Available: https://doi.org/10.1007/978-3-030-00889-5_1.

- [11] F. Isensee, P. F. Jäger, S. A. A. Kohl, J. Petersen, and K. H. Maier-Hein, “nnU-Net: A Self-configuring Method for Deep Learning-Based Biomedical Image Segmentation,” *Nature Methods*, vol. 18, no. 2, pp. 203–211, 2021. DOI: 10.1038/s41592-020-01008-z. [Online]. Available: <https://doi.org/10.1038/s41592-020-01008-z>.
- [12] A. Kirillov, E. Mintun, N. Ravi, *et al.*, “Segment Anything,” in *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2023, pp. 4015–4026. DOI: 10.1109/ICCV51070.2023.00371. [Online]. Available: https://openaccess.thecvf.com/content/ICCV2023/html/Kirillov_Segment_Anything_ICCV_2023_paper.html.
- [13] J. Cheng, J. Ye, Z. Deng, *et al.*, “SAM-Med2D,” *arXiv preprint arXiv:2308.16184*, 2023. DOI: 10.48550/arXiv.2308.16184. arXiv: 2308.16184 [cs.CV]. [Online]. Available: <https://arxiv.org/abs/2308.16184>.
- [14] N. Xu, B. Price, S. Cohen, J. Yang, and T. S. Huang, “Deep Interactive Object Selection,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2016, pp. 373–381. DOI: 10.48550/arXiv.1603.04042. arXiv: 1603.04042 [cs.CV]. [Online]. Available: <https://arxiv.org/abs/1603.04042>.
- [15] G. Wang, M. A. Zuluaga, W. Li, *et al.*, “DeepIGeoS: A Deep Interactive Geodesic Framework for Medical Image Segmentation,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 41, no. 7, pp. 1559–1572, 2019. DOI: 10.1109/TPAMI.2018.2840695. [Online]. Available: <https://doi.org/10.1109/TPAMI.2018.2840695>.
- [16] J. Ma, Y. He, F. Li, L. Han, C. You, and B. Wang, “Segment Anything in Medical Images,” *Nature Communications*, vol. 15,

- no. 1, 654, 2024. DOI: 10.1038/s41467-024-44824-z. [Online]. Available:
<https://www.nature.com/articles/s41467-024-44824-z>.
- [17] O. Oktay, J. Schlemper, L. L. Folgoc, *et al.*, “Attention U-Net: Learning Where to Look for the Pancreas,” in *Medical Imaging with Deep Learning*, 2018. DOI: 10.48550/arXiv.1804.03999. arXiv: 1804.03999 [cs.CV]. [Online]. Available:
<https://arxiv.org/abs/1804.03999>.
- [18] A. Dosovitskiy, L. Beyer, A. Kolesnikov, *et al.*, “An Image Is Worth 16x16 Words: Transformers for Image Recognition at Scale,” in *International Conference on Learning Representations*, 2021. [Online]. Available:
<https://openreview.net/forum?id=YicbFdNTTy>.
- [19] Z. Liu, Y. Lin, Y. Cao, *et al.*, “Swin Transformer: Hierarchical Vision Transformer Using Shifted Windows,” in *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2021, pp. 10 012–10 022. DOI: 10.1109/ICCV48922.2021.00986. [Online]. Available: <https://doi.org/10.1109/ICCV48922.2021.00986>.
- [20] J. Chen, Y. Lu, Q. Yu, *et al.*, “TransUNet: Transformers Make Strong Encoders for Medical Image Segmentation,” *arXiv preprint arXiv:2102.04306*, 2021. DOI: 10.48550/arXiv.2102.04306. arXiv: 2102.04306 [cs.CV]. [Online]. Available:
<https://arxiv.org/abs/2102.04306>.
- [21] J. M. J. Valanarasu, I. Hacıhaliloglu, and V. M. Patel, “Medical Transformer: Gated Axial-Attention for Medical Image Segmentation,” *Medical Image Analysis*, vol. 74, 102138, 2021. DOI: 10.1016/j.media.2021.102138. [Online]. Available:
<https://doi.org/10.1016/j.media.2021.102138>.

- [22] A. Hatamizadeh, D. Yang, H. Roth, and D. Xu, “UNETR: Transformers for 3D Medical Image Segmentation,” in *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision*, 2022, pp. 574–584. DOI: 10.1109/WACV51458.2022.00066. [Online]. Available: <https://doi.org/10.1109/WACV51458.2022.00066>.
- [23] H. Cao, Y. Wang, J. Chen, *et al.*, “Swin-Unet: Unet-Like Pure Transformer for Medical Image Segmentation,” *arXiv preprint arXiv:2105.05537*, 2022. DOI: 10.48550/arXiv.2105.05537. arXiv: 2105.05537 [cs.CV]. [Online]. Available: <https://arxiv.org/abs/2105.05537>.
- [24] K. He, X. Zhang, S. Ren, and J. Sun, “Deep Residual Learning for Image Recognition,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2016, pp. 770–778. DOI: 10.1109/CVPR.2016.90. [Online]. Available: <https://doi.org/10.1109/CVPR.2016.90>.
- [25] E. Perez, F. Strub, H. de Vries, V. Dumoulin, and A. Courville, “FiLM: Visual Reasoning with a General Conditioning Layer,” in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 32, 2018, pp. 3942–3951. DOI: 10.1609/aaai.v32i1.11671. [Online]. Available: <https://ojs.aaai.org/index.php/AAAI/article/view/11671>.
- [26] T. Park, M.-Y. Liu, T.-C. Wang, and J.-Y. Zhu, “Semantic Image Synthesis with Spatially-Adaptive Normalization,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2019, pp. 2337–2346. DOI: 10.1109/CVPR.2019.00244. [Online]. Available: https://openaccess.thecvf.com/content_CVPR_2019/html/Park_Semantic_Image_Synthesis_With_Spatially-Adaptive_Normalization_CVPR_2019_paper.html.

- [27] S. Yao, Y. Huang, X. Wang, *et al.*, “A Radiograph Dataset for the Classification, Localization, and Segmentation of Primary Bone Tumors,” *Scientific Data*, vol. 12, no. 1, 88, 2025. DOI: 10.1038/s41597-024-04311-y. [Online]. Available: <https://www.nature.com/articles/s41597-024-04311-y>.
- [28] I. Abedeen, M. A. Rahman, F. Z. Protyasha, T. Ahmed, T. M. Chowdhury, and S. Shatabda, “FracAtlas: A Dataset for Fracture Classification, Localization and Segmentation of Musculoskeletal Radiographs,” *Scientific Data*, vol. 10, no. 1, 521, 2023. DOI: 10.1038/s41597-023-02432-4. [Online]. Available: <https://www.nature.com/articles/s41597-023-02432-4>.
- [29] M. Tan and Q. V. Le, “EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks,” in *Proceedings of the 36th International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, vol. 97, PMLR, 2019, pp. 6105–6114. [Online]. Available: <https://proceedings.mlr.press/v97/tan19a.html>.

PHỤ LỤC

PHỤ LỤC A

PHÂN TÍCH CHUYÊN SÂU KIẾN TRÚC VÀ KHẢ NĂNG TỔNG QUÁT HÓA

Phụ lục này trình bày đầy đủ các thực nghiệm bổ sung đã được tóm tắt ngắn ở Chương 4. Nội dung gồm bốn phần chính: đo hiệu quả tính toán của PGA-UNet và SAM-Med2D (Mục A.1); nghiên cứu loại bỏ thành phần để so sánh các cấu hình PSG/CAD; đánh giá chéo 4-fold để xem độ ổn định; và phân tích theo đặc tính tổn thương trên BTXRD (Mục A.2) và FracAtlas (Mục A.3). Cuối phụ lục có một phần tổng hợp chung để rút ra kết luận trên cả hai bộ dữ liệu (Mục A.4). Phụ lục được tách riêng như vậy để phần thân bài đỡ nặng số liệu hơn và người đọc cũng dễ theo dõi từng nhóm thí nghiệm hơn.

A.1


Hiệu quả tính toán của PGA-UNet và SAM-Med2D

Mục này lưu lại đầy đủ số liệu của phần đo hiệu quả tính toán đã được tóm tắt ở Chương 4. Các phép đo được thực hiện trong cùng môi trường chạy, với cùng thiết bị và cùng cách đo cho từng mô hình. Những chỉ số được ghi nhận gồm số tham số, số tham số có thể huấn luyện, FLOPs, dung lượng checkpoint, bộ nhớ GPU đỉnh và độ trễ suy luận trung bình trên GPU và CPU. PGA-UNet được đo ở hai cấu hình 256×256 và 512×512 , còn SAM-Med2D được đo ở 256×256 để tiện đối sánh trực tiếp. Các con số trong mục này chỉ nên hiểu là để so sánh tương đối trong cùng môi trường thực nghiệm.

Bảng A.1: Bảng rút gọn từ `efficiency_comparison.csv`: so sánh hiệu quả tính toán giữa PGA-UNet và SAM-Med2D trong cùng môi trường thực nghiệm

Mô hình	Tham số tổng (M)	Tham số học (M)	FLOPs (G)	Checkpoint (MB)	Bộ nhớ GPU đỉnh (MB)	Độ trễ GPU (ms/ảnh)	Độ trễ CPU (ms/ảnh)
PGA-UNet (256 × 256)	2.950	2.950	7.742	11.3	3300.8	8.46 ± 0.83	83.87 ± 2.08
PGA-UNet (512 × 512)	2.950	2.950	30.968	11.3	3429.8	21.83 ± 0.23	309.84 ± 8.24
SAM-Med2D (256 × 256)	271.242	184.569	92.024	2443.2	3332.8	60.70 ± 1.54	769.40 ± 11.36

Ở cùng độ phân giải 256×256 , SAM-Med2D lớn hơn PGA-UNet khoảng 92 lần về số tham số tổng, 11,9 lần về FLOPs, 215 lần về dung lượng checkpoint và chậm hơn khoảng 7,2 lần trên GPU. Độ trễ khi ép chạy trên CPU cũng chênh lệch khoảng 9,2 lần, củng cố nhận định rằng PGA-UNet phù hợp hơn cho các kịch bản triển khai tương tác trên phần cứng hạn chế.



Hình A.1: Biểu đồ tổng hợp sáu chỉ số hiệu quả tính toán giữa PGA-UNet và SAM-Med2D, trích từ notebook đo lường `measure_efficiency.ipynb`.

Bộ nhớ GPU đỉnh tại cùng độ phân giải 256×256 không chênh lệch nhiều trong phép đo hiện tại, cho thấy chỉ số này còn chịu ảnh hưởng của khung chạy, bộ nhớ đệm và cách cấp phát của thư viện thực thi. Vì vậy, trong diễn giải chính của khóa luận, số tham số, FLOPs, dung lượng checkpoint và độ trễ suy luận được xem là các chỉ báo đáng tin cậy hơn để so sánh chi phí triển khai giữa PGA-UNet và SAM-Med2D.

A.2

Phân tích trên BTXRD

Trên BTXRD, PGA-UNet được phân tích theo ba hướng là đóng góp của từng thành phần kiến trúc, độ ổn định giữa các cách chia dữ liệu và hiệu năng theo đặc tính tổn thương. Trong từng nhóm thí nghiệm, các cấu hình đều được đánh giá trên cùng dữ liệu, cùng kịch bản câu nhắc và cùng cách tính chỉ số ở cấp độ ảnh.

A.2.1

Đóng góp của kiến trúc và câu nhắc

Thiết kế thí nghiệm.

Tám cấu hình được huấn luyện lại từ đầu trên cùng tập BTXRD và giữ nguyên các điều kiện huấn luyện. Thực nghiệm chỉ thay đổi ba yếu tố: PSG tại bộ mã hóa, cơ chế chú ý trên các kết nối tắt của nhánh giải mã và cách biểu diễn câu nhắc.

Trong đó, sáu cấu hình cùng sử dụng bản đồ nhiệt Gaussian để khảo sát đóng góp kiến trúc. Mỗi cấu hình là một tổ hợp giữa hai lựa chọn tại bộ mã hóa (không hoặc có PSG) và ba lựa chọn cho cơ chế chú ý trên các kết nối tắt của nhánh giải mã (không dùng cổng chú ý, dùng cổng chú ý nguyên bản hoặc dùng CAD). Nhờ đó, xác định PSG và CAD có hiệu quả khi hoạt động riêng lẻ hay chỉ phát huy khi được kết hợp.

Hai cấu hình còn lại thay bản đồ nhiệt Gaussian bằng mặt nạ hộp giới hạn nhị phân. Chúng được dùng để so sánh hai cách biểu diễn câu nhắc trong cả cấu hình nối kênh cơ sở và cấu hình đầy đủ PSG+CAD.

U-Net+Concat là cấu hình cơ sở, trong đó câu nhắc chỉ được nối vào ảnh như một kênh đầu vào. U-Net+PSG và U-Net+CAD lần lượt bổ sung riêng PSG hoặc CAD. Các cấu hình dùng cổng chú ý nguyên bản kế thừa Attention U-Net [17] và không nhận trực tiếp đặc trưng câu nhắc trong cơ

chế chú ý trên các kết nối tắt của nhánh giải mã. PGA-UNet kết hợp cả PSG, CAD và bản đồ nhiệt Gaussian.

Bảng A.2: Kết quả nghiên cứu loại bỏ thành phần trên BTXRD trong ba kịch bản câu nhắc (N=187 ảnh)

Cấu hình	PSG	Chú ý trên kết nối tắt	Câu nhắc	Bao trọn $\uparrow$	Lệch tâm $\uparrow$	Hỗn hợp $\uparrow$
U-Net+Concat (Gaussian)	×	Không	Gaussian	0.8763	0.7364	0.8216
U-Net+PSG	✓	Không	Gaussian	0.8673	0.7388	0.8162
U-Net+CAD	×	CAD	Gaussian	0.8861	0.7406	0.8292
PGA-UNet (nhị phân)	✓	CAD	Nhị phân	0.8780	0.7434	0.8267
U-Net+Concat (nhị phân)	×	Không	Nhị phân	0.8781	0.7312	0.8202
PGA-UNet	✓	CAD	Gaussian	0.8607	0.8423	0.8560
U-Net+PSG+Cổng chú ý nguyên bản	✓	Nguyên bản	Gaussian	0.8680	0.7359	0.8173
U-Net+Cổng chú ý nguyên bản	×	Nguyên bản	Gaussian	0.8738	0.7314	0.8193

Vai trò của thông tin câu nhắc. U-Net không sử dụng câu nhắc chỉ đạt Dice 0,4740 trên BTXRD, trong khi U-Net+Concat sử dụng bản đồ nhiệt Gaussian đạt 0,8763 ở kịch bản Bao trọn. Chỉ riêng chỗ này cũng đã cho thấy ngay cả cách tích hợp đơn giản bằng phép nối kênh cũng giúp mô hình định vị vùng tổn thương tốt hơn hẳn. Nhưng Dice của U-Net+Concat giảm xuống 0,7364 khi câu nhắc bị lệch tâm, nên việc đưa câu nhắc trực tiếp vào đầu vào vẫn chưa đủ để giữ ổn định tốt khi vị trí bị lệch.

Attention U-Net không có câu nhắc đạt kết quả thấp hơn U-Net không câu nhắc. Nhìn vào đây có thể thấy cổng chú ý nguyên bản không tự cải thiện hiệu năng trong thiết lập hiện tại khi thiếu thông tin định hướng. Tuy nhiên, số liệu này không phải là nguyên nhân gây suy giảm mà chỉ được sử dụng làm điểm tham chiếu cho các cấu hình chú ý có câu nhắc.

Đóng góp của PSG tại bộ mã hóa. Khi được sử dụng riêng lẻ, PSG tạo ra mức thay đổi nhỏ so với phép nối kênh. Trong kịch bản Lệch tâm, Dice tăng từ 0,7364 của U-Net+Concat lên 0,7388 của U-Net+PSG, tương ứng mức tăng 0,0024. Ngược lại, Dice giảm nhẹ 0,0090 ở kịch bản Bao trọn và 0,0054 ở kịch bản Hỗn hợp.

Nhìn riêng thì PSG chưa đủ để tạo ra cải thiện rõ rệt ở đầu ra phân đoạn. Vai trò chính của PSG không phải là thay thế quá trình tái tạo mặt nạ, mà là đưa tín hiệu không gian của câu nhắc vào quá trình mã hóa đặc

trung. Phần lợi của tín hiệu này chỉ lộ ra rõ hơn khi nhánh giải mã tiếp tục khai thác nó thông qua CAD trên các kết nối tắt.

Đóng góp của CAD trên các kết nối tắt của nhánh giải mã. Khi không có PSG, U-Net+CAD đạt Dice 0,8861 ở kịch bản Bao trọn, cao nhất trong tám cấu hình. So với U-Net+Concat, CAD cải thiện Dice 0,0098 ở Bao trọn, 0,0042 ở Lệch tâm và 0,0076 ở Hỗn hợp. Như vậy, CAD riêng lẻ giúp cơ chế chú ý trên các kết nối tắt khai thác câu nhắc tốt hơn phép nối kênh, nhưng mức cải thiện trong kịch bản Lệch tâm vẫn còn nhỏ.

Vai trò của việc điều kiện hóa chú ý thể hiện rõ hơn khi so sánh CAD với cổng chú ý nguyên bản. Không có PSG, U-Net+CAD cao hơn U-Net+Cổng chú ý nguyên bản 0,0123 ở Bao trọn, 0,0092 ở Lệch tâm và 0,0099 ở Hỗn hợp. Khi có PSG, PGA-UNet cao hơn U-Net+PSG+Cổng chú ý nguyên bản 0,1064 ở Lệch tâm và 0,0387 ở Hỗn hợp, mặc dù thấp hơn 0,0073 ở Bao trọn. Nói cách khác, lợi ích chính không đến từ việc bổ sung một cổng chú ý bất kỳ, mà từ việc điều kiện hóa quá trình chú ý bằng đặc trưng câu nhắc thông qua CAD.

Đóng góp của bản đồ nhiệt Gaussian. Ở cấu hình nối kênh cơ sở, cách biểu diễn câu nhắc chỉ tạo ra khác biệt nhỏ. So với U-Net+Concat dùng mặt nạ nhị phân, U-Net+Concat dùng Gaussian thấp hơn 0,0018 ở Bao trọn, nhưng cao hơn 0,0052 ở Lệch tâm và 0,0014 ở Hỗn hợp. Những chênh lệch này đều nhỏ hơn 0,006.

Ảnh hưởng của Gaussian trở nên rõ rệt khi câu nhắc được xử lý bởi đầy đủ PSG và CAD. So với PGA-UNet dùng câu nhắc nhị phân, PGA-UNet dùng Gaussian cao hơn 0,0989 Dice ở kịch bản Lệch tâm và 0,0293 ở Hỗn hợp, nhưng thấp hơn 0,0173 ở Bao trọn. Có thể thấy mặt nạ nhị phân phù hợp hơn một chút khi hộp giới hạn hoàn toàn chính xác, trong khi bản đồ nhiệt Gaussian giúp mô hình duy trì hiệu năng tốt hơn khi vị trí câu nhắc bị sai lệch.


Có thể hiểu rằng sự chuyển tiếp mềm của bản đồ nhiệt Gaussian làm mô hình bớt phụ thuộc vào đường biên cứng của hộp giới hạn. Dù vậy, đây

vẫn chỉ là cách giải thích dựa trên thiết kế và kết quả thực nghiệm, chưa phải bằng chứng trực tiếp về cách mô hình tổ chức đặc trưng bên trong. **Sự hỗ trợ giữa PSG, CAD và bản đồ nhiệt Gaussian.** Trong kịch bản Lệch tâm, PSG riêng lẻ cải thiện 0,0024 và CAD riêng lẻ cải thiện 0,0042 so với U-Net+Concat. Trong khi đó, cấu hình kết hợp PSG, CAD và Gaussian cải thiện 0,1059. Chênh lệch này cho thấy hiệu quả của mô hình không phải là tổng đơn giản của hai thành phần hoạt động độc lập, mà xuất hiện khi tín hiệu câu nhắc được duy trì xuyên suốt cả bộ mã hóa và các kết nối tắt có chú ý của nhánh giải mã.

Theo cơ chế thiết kế, PSG đưa thông tin không gian của câu nhắc vào các đặc trưng mã hóa, CAD sử dụng đặc trưng câu nhắc để điều chỉnh các kết nối tắt của nhánh giải mã, còn bản đồ nhiệt Gaussian cung cấp tín hiệu không gian có chuyển tiếp mềm. Ba thành phần vì vậy đảm nhận các vai trò khác nhau nhưng liên kết trong cùng một quá trình dẫn hướng phân đoạn. Nhận xét này dựa trên chênh lệch Dice trung bình và được xem là bằng chứng về xu hướng hỗ trợ, không phải một kiểm định tương tác chính thức.

Kết luận từ nghiên cứu loại bỏ thành phần. PGA-UNet không đạt Dice cao nhất trong kịch bản Bao trọn: U-Net+CAD đạt 0,8861, trong khi PGA-UNet đạt 0,8607. Ngược lại, PGA-UNet đạt kết quả cao nhất trong hai kịch bản, gồm 0,8423 ở Lệch tâm và 0,8560 ở Hỗn hợp. So với U-Net+Concat, mức cải thiện tương ứng là 0,1059 và 0,0344.

Đóng góp chính của PGA-UNet không nằm ở chỗ đẩy hiệu năng lên cao nhất khi câu nhắc hoàn toàn lý tưởng, mà ở khả năng giữ kết quả đỡ rơi hơn khi câu nhắc không chính xác tuyệt đối. PSG riêng lẻ giúp đưa thông tin không gian vào bộ mã hóa nhưng chưa tạo ra cải thiện rõ rệt; CAD cho phép cơ chế chú ý trên các kết nối tắt khai thác trực tiếp đặc trưng câu nhắc; còn bản đồ nhiệt Gaussian làm tăng độ ổn định trước sai lệch vị trí. Ba phần này đi cùng nhau mới tạo ra ưu thế của PGA-UNet trong các kịch bản gần với sai số thao tác có thể xuất hiện khi người dùng cung cấp hộp giới hạn.



Hình A.2: Dice của tám cấu hình trong nghiên cứu loại bỏ thành phần trên BTXRD. PGA-UNet đạt kết quả cao nhất trong hai kịch bản Lệch tâm và Hỗn hợp.

Các nhận xét trên dựa trên chênh lệch Dice trung bình. Kiểm định Wilcoxon signed-rank trên Dice bất cặp theo từng ảnh được trình bày tại Mục A.4 để đánh giá độ tin cậy thống kê của các cặp so sánh chính.

A.2.2

Đánh giá độ ổn định bằng đánh giá chéo

PGA-UNet được đánh giá trên bốn phân vùng dữ liệu nhằm khảo sát mức độ biến động của kết quả khi thay đổi cách phân chia tập huấn luyện và tập xác thực. Việc phân chia được thực hiện ở cấp độ ảnh; các đa giác thuộc cùng một ảnh phải được giữ trong cùng một phân vùng để tránh rò rỉ dữ liệu. Bảng A.3 trình bày Dice trên từng phân vùng, trong khi Bảng A.4 tổng hợp kết quả trung bình của sáu chỉ số đánh giá.

Bảng A.3: Dice Score từng Phân vùng trong đánh giá chéo 4-fold PGA-UNet (kịch bản Bao trọn / Lệch tâm / Hỗn hợp)

Phân vùng	Bao trọn $\uparrow$	Lệch tâm $\uparrow$	Hỗn hợp $\uparrow$
Phân vùng 1	0.8514	0.8206	0.8424
Phân vùng 2	0.8755	0.8534	0.8677
Phân vùng 3	0.8602	0.8414	0.8533
Phân vùng 4	0.8646	0.8426	0.8610
Trung bình $\pm$ độ lệch chuẩn	0.8629 $\pm$ 0.0087	0.8395 $\pm$ 0.0119	0.8561 $\pm$ 0.0094

Dice thay đổi không nhiều giữa bốn phân vùng. Độ lệch chuẩn lần lượt là 0,0087 ở kịch bản Bao trọn, 0,0119 ở Lệch tâm và 0,0094 ở Hỗn hợp. Trong phạm vi bốn cách chia dữ liệu này, có thể xem PGA-UNet là ổn định; trong đó kịch bản Lệch tâm dao động nhiều hơn một chút. Bảng A.4 bổ sung các chỉ số còn lại (IoU, Precision, Recall, HD95, CBL) cho ba hàng trung bình trên.

Bảng A.4: Kết quả đánh giá chéo 4-fold PGA-UNet trên 3 kịch bản câu nhắc (trung bình 4 fold)

Kịch bản	Dice $\uparrow$	IoU $\uparrow$	Precision $\uparrow$	Recall $\uparrow$	HD95 $\downarrow$	CBL $\uparrow$
Bao trọn	0.8629	0.7672	0.8506	0.8910	11.14	0.9548
Lệch tâm	0.8395	0.7332	0.8393	0.8574	13.25	0.9381
Hỗn hợp (70% Bao trọn + 30% Lệch tâm)	0.8561	0.7573	0.8466	0.8820	11.90	0.9501

Giá trị Dice trung bình của đánh giá chéo khá gần với kết quả trên tập kiểm thử chính. Ví dụ, Dice ở kịch bản Bao trọn đạt 0,8629 qua bốn phân vùng, so với 0,8607 trên tập kiểm thử độc lập. Nói cách khác, kết quả không thay đổi nhiều theo cách chia dữ liệu đã khảo sát, nhưng dĩ nhiên không thay cho tập kiểm thử giữ lại độc lập.

Kiểm định Wilcoxon trên Dice bắt cặp theo từng ảnh được trình bày riêng tại Mục A.4; kiểm định này không được kết hợp với độ lệch chuẩn qua phân vùng để tạo một tỷ lệ tín hiệu trên nhiễu.

A.2.3

Phân tích theo đặc tính tổn thương

Mục này khảo sát sự thay đổi hiệu năng của PGA-UNet trên các nhóm ảnh có đặc điểm khác nhau. Ba phân tích được thực hiện gồm: so sánh với U-Net trên các ảnh mà U-Net hoạt động tốt hoặc kém; so sánh với SAM-Med2D theo kích thước và mức độ rõ của tổn thương; và lặp lại phép so sánh với SAM-Med2D ở cùng độ phân giải 256×256 .

Các kết quả phân nhóm có vai trò bổ sung cho đánh giá trên toàn bộ tập kiểm thử. Do mỗi nhóm chỉ gồm một phần dữ liệu và được xác định theo tiêu chí riêng, kết quả không thay thế cho các chỉ số trung bình được báo cáo ở Mục 4.2, Chương 4.

So sánh với U-Net theo mức hiệu năng của mô hình cơ sở. Từ tập kiểm thử BTXRD, 50 ảnh có Dice U-Net cao nhất được xếp vào nhóm U-Net hoạt động tốt, trong khi 50 ảnh có Dice thấp nhất được xếp vào nhóm U-Net hoạt động kém. Cách phân nhóm này nhằm khảo sát liệu PGA-UNet chỉ cải thiện trên những ảnh U-Net đã xử lý tốt hay vẫn duy trì kết quả trên các trường hợp U-Net gặp nhiều khó khăn.

Do nhóm được xác định trực tiếp từ kết quả của U-Net, đây là phân tích mô tả theo hai cực hiệu năng của mô hình cơ sở, không phải cách phân loại độ khó độc lập của dữ liệu.


Bảng A.5: So sánh PGA-UNet với U-Net theo mức hiệu năng của U-Net trên BTXRD (50 ảnh/nhóm)

Nhóm	Mô hình	Dice $\uparrow$	IoU $\uparrow$	Precision $\uparrow$	Recall $\uparrow$	HD95 $\downarrow$ (px)	CBL $\uparrow$
U-Net hoạt động tốt	U-Net	0.8488	0.7403	0.8481	0.8618	51.34	0.9194
	PGA-UNet	0.8972	0.8160	0.8656	0.9368	13.20	0.9666
U-Net hoạt động kém	U-Net	0.0211	0.0111	0.0396	0.1063	284.72	0.0708
	PGA-UNet	0.8261	0.7168	0.8313	0.8429	7.75	0.9456

Trong nhóm U-Net hoạt động tốt, PGA-UNet cải thiện Dice từ 0,8488 lên 0,8972, tương ứng mức tăng 0,0484. Các chỉ số IoU, Precision, Recall và CBL cũng tăng, trong khi HD95 giảm từ 51,34 xuống 13,20 điểm ảnh. Có thể thấy câu nhắc vẫn có ích ngay cả trên những ảnh mà mô hình tự động đã phân đoạn tương đối tốt.

Ở nhóm U-Net hoạt động kém, Dice của U-Net chỉ đạt 0,0211, trong khi PGA-UNet đạt 0,8261. Recall tăng từ 0,1063 lên 0,8429 và HD95 giảm từ 284,72 xuống 7,75 điểm ảnh. Tức là PGA-UNet vẫn định vị và phân đoạn được tổn thương trên nhiều ảnh mà U-Net gần như bỏ trống.

Mức chênh lệch rất lớn ở nhóm thứ hai cần được diễn giải cùng tiêu chí lựa chọn nhóm: đây chính là 50 ảnh có Dice U-Net thấp nhất. Do đó, kết quả không được dùng để ước lượng mức cải thiện trung bình trên toàn bộ tập kiểm thử, mà cho thấy PGA-UNet có khả năng khắc phục một phần các trường hợp thất bại nghiêm trọng của mô hình tự động.




Hình A.3: Dice của U-Net và PGA-UNet trên nhóm U-Net hoạt động tốt và nhóm U-Net hoạt động kém.

Hình A.4 minh họa một ảnh thuộc mỗi nhóm. Ở ví dụ thuộc nhóm U-Net hoạt động tốt, Dice của U-Net và PGA-UNet lần lượt đạt 0,903 và 0,958. Ở ví dụ thuộc nhóm U-Net hoạt động kém, U-Net không xác định được vùng tổn thương, trong khi PGA-UNet đạt Dice 0,901. Hai trường hợp này chỉ có vai trò minh họa cho xu hướng trong Bảng A.5, không thay thế kết quả trên toàn bộ nhóm.

So sánh với SAM-Med2D theo đặc tính tổn thương. Để so sánh công bằng giữa hai kiến trúc, PGA-UNet và SAM-Med2D đều được đánh


U-Net -- Nhóm TOP-DICE/dễ (Dice=0.903, IoU=0.823)



PGA-UNet -- Nhóm TOP-DICE/dễ (Dice=0.958, IoU=0.919)



U-Net -- Nhóm BOTTOM-DICE/khó (Dice=0.000, IoU=0.000)



PGA-UNet -- Nhóm BOTTOM-DICE/khó (Dice=0.901, IoU=0.819)



Hình A.4: Kết quả định tính của U-Net và PGA-UNet trên một ảnh thuộc mỗi nhóm hiệu năng của U-Net.

giá ở độ phân giải 256×256 , trên cùng ba nhóm ảnh và cùng câu nhắc Bao trọn. Ba nhóm gồm Tổn thương nhỏ, Biên mờ và Tổn thương rõ, mỗi nhóm có 50 ảnh. Phép so sánh này chỉ thay đổi kiến trúc mô hình, không bị ảnh hưởng bởi sự khác biệt về độ phân giải đầu vào.

Bảng A.6: So sánh PGA-UNet với SAM-Med2D theo đặc tính tổn thương ở cùng độ phân giải 256×256 trên BTXRD (Bao trọn, 50 ảnh/nhóm)


Nhóm	Mô hình	Dice $\uparrow$	IoU $\uparrow$	Precision $\uparrow$	Recall $\uparrow$	HD95 $\downarrow$ (px)	CBL $\uparrow$
Tổn thương nhỏ	SAM-Med2D (256×256)	0.1356	0.0909	0.4331	0.0932	265.55	0.4257
	PGA-UNet (256×256)	0.6870	0.5383	0.5687	0.9354	5.98	0.9092
Biên mờ	SAM-Med2D (256×256)	0.5759	0.4260	0.8866	0.4616	28.74	0.9000
	PGA-UNet (256×256)	0.7970	0.6715	0.7317	0.8977	18.84	0.9397
Tổn thương rõ	SAM-Med2D (256×256)	0.8529	0.7469	0.8807	0.8342	24.33	0.9587
	PGA-UNet (256×256)	0.8660	0.7669	0.8050	0.9455	23.08	0.9599

Mức chênh lệch giữa hai mô hình phụ thuộc rõ rệt vào đặc tính tổn thương. Ở nhóm Tổn thương nhỏ, PGA-UNet đạt Dice 0,6870, cao hơn 0,5514 so với SAM-Med2D. Recall của PGA-UNet đạt 0,9354, trong khi SAM-Med2D chỉ đạt 0,0932; đây cũng là nhóm tạo ra khoảng cách lớn nhất giữa hai mô hình.

Ở nhóm Biên mờ, PGA-UNet cao hơn SAM-Med2D 0,2211 Dice và 0,4361 Recall. SAM-Med2D đạt Precision cao hơn, nhưng Recall thấp cho thấy mô hình dự đoán thận trọng và bỏ sót nhiều điểm ảnh tổn thương hơn. PGA-UNet đạt sự cân bằng tốt hơn giữa khả năng bao phủ tổn thương và độ chính xác tổng thể.

Ở nhóm Tổn thương rõ, khoảng cách Dice thu hẹp còn 0,0131. Hai mô hình đều đạt kết quả cao khi vùng tổn thương dễ nhận biết; PGA-UNet cao hơn về Dice, IoU và Recall, trong khi SAM-Med2D cao hơn về Precision. Nhìn chung, ưu thế của PGA-UNet thể hiện rõ nhất trên tổn thương nhỏ và biên mờ, còn ở tổn thương rõ ràng thì hai mô hình gần nhau hơn.

Hình A.6 minh họa một ảnh đại diện cho mỗi nhóm, đối chiếu cả ba cấu hình SAM-Med2D, PGA-UNet₂₅₆ và PGA-UNet₅₁₂. Các ảnh được chọn theo tiêu chí Dice và IoU tăng dần đơn điệu qua ba cấu hình (SAM-Med2D < PGA-UNet₂₅₆ < PGA-UNet₅₁₂), nhằm minh họa trực quan đồng



Hình A.5: So sánh Dice của PGA-UNet và SAM-Med2D theo đặc tính tổn thương ở cùng độ phân giải 256×256 trên BTXRD.

thời cả lợi thế kiến trúc so với SAM-Med2D lẫn lợi ích của độ phân giải cao hơn được phân tích tại Mục 4.3.3, Chương 4 và ngay bên dưới.

Ảnh hưởng của độ phân giải theo đặc tính tổn thương. Sau khi kiểm soát độ phân giải trong phép so sánh với SAM-Med2D, hai phiên bản PGA-UNet được đối chiếu trên cùng ba nhóm ảnh để xác định nhóm tổn thương nào hưởng lợi nhiều nhất khi tăng kích thước đầu vào từ 256×256 lên 512×512 . Hai cấu hình sử dụng cùng kiến trúc, cùng nhóm mẫu và cùng câu nhắc Bao trọn; yếu tố thay đổi duy nhất là độ phân giải đầu vào và điểm lưu trọng số tương ứng.

Lưu ý: HD95 được tính theo đơn vị điểm ảnh tại từng độ phân giải nên không được dùng để so sánh trực tiếp giữa ảnh 256×256 và 512×512 . Vì vậy, các giá trị HD95 trong Bảng A.7 không được in đậm.

Tăng độ phân giải giúp PGA-UNet cải thiện Dice trên cả ba nhóm, nhưng mức cải thiện không đồng đều. Nhóm Tổn thương nhỏ hưởng lợi nhiều nhất, với Dice tăng từ 0,6870 lên 0,8301, tương ứng 0,1431. Precision

Ảnh gốc | Bbox/Prompt | Dự đoán | GT (union) | TP (xanh lá) / FP (đỏ) / FN (xanh dương)

SAM-Med2D -- Tổn thương nhỏ (Dice=0.000, IoU=0.000)



PGA-UNet (256) -- Tổn thương nhỏ (Dice=0.632, IoU=0.462)



PGA-UNet (512) -- Tổn thương nhỏ (Dice=0.819, IoU=0.694)



SAM-Med2D -- Biên giới mờ (Dice=0.738, IoU=0.585)



PGA-UNet (256) -- Biên giới mờ (Dice=0.914, IoU=0.841)



PGA-UNet (512) -- Biên giới mờ (Dice=0.956, IoU=0.916)



SAM-Med2D -- Tổn thương rõ nét (Dice=0.837, IoU=0.720)



PGA-UNet (256) -- Tổn thương rõ nét (Dice=0.908, IoU=0.831)



PGA-UNet (512) -- Tổn thương rõ nét (Dice=0.929, IoU=0.868)



Hình A.6: Kết quả định tính của SAM-Med2D, PGA-UNet₂₅₆ và PGA-UNet₅₁₂ trên một ảnh đại diện mỗi nhóm đặc tính tổn thương, BTXRD.

Bảng A.7: Ảnh hưởng của độ phân giải đối với PGA-UNet theo đặc tính tổn thương trên BTXRD (Bao trọn, 50 ảnh/nhóm)


Nhóm	Độ phân giải	Dice↑	IoU↑	Precision↑	Recall↑	HD95 (px)	CBL↑
Tổn thương nhỏ	256×256	0.6870	0.5383	0.5687	0.9354	5.98	0.9092
	512×512	0.8301	0.7212	0.8285	0.8553	3.06	0.9408
Biên mờ	256×256	0.7970	0.6715	0.7317	0.8977	18.84	0.9397
	512×512	0.8448	0.7421	0.8527	0.8552	13.87	0.9546
Tổn thương rõ	256×256	0.8660	0.7669	0.8050	0.9455	23.08	0.9599
	512×512	0.8826	0.7925	0.8477	0.9261	22.79	0.9629

đồng thời tăng từ 0,5687 lên 0,8285, cho thấy độ phân giải cao giúp mô hình hạn chế các vùng dự đoán dương tính sai quanh tổn thương nhỏ.

Ở nhóm Biên mờ, Dice tăng 0,0478 và Precision tăng 0,1210. Đối với nhóm Tổn thương rõ, Dice chỉ tăng 0,0166 vì cả hai độ phân giải đều đã đạt hiệu năng cao. Xu hướng này cho thấy độ phân giải cao đặc biệt hữu ích đối với các tổn thương nhỏ và khó phân biệt, trong khi lợi ích giảm dần khi vùng tổn thương đã rõ ràng.


Recall của phiên bản 256×256 cao hơn trong cả ba nhóm, trong khi phiên bản 512×512 đạt Precision, Dice và CBL cao hơn. Kết quả gợi ý rằng phiên bản độ phân giải thấp có xu hướng bao phủ rộng hơn, còn phiên bản độ phân giải cao tạo mặt nạ chọn lọc và cân bằng hơn. Đây là xu hướng quan sát từ các chỉ số, không phải kết luận trực tiếp về cơ chế bên trong của mô hình.

Kết luận. Khi kiểm soát độ phân giải ở 256×256 , PGA-UNet vẫn cao hơn SAM-Med2D trên cả ba nhóm, đặc biệt ở Tổn thương nhỏ và Biên mờ. Còn khi chỉ thay đổi độ phân giải của PGA-UNet, mức cải thiện lớn nhất vẫn rơi vào nhóm Tổn thương nhỏ. Ghép hai phần này lại thì có thể hiểu rằng lợi thế của PGA-UNet trên nhóm này không chỉ đến từ độ phân giải 512×512 , dù đúng là độ phân giải cao vẫn mang lại thêm cải thiện.



Hai cấu hình PGA-UNet được đánh giá trên cùng nhóm ảnh và cùng cấu trúc Bao trọn.

Hình A.7: Ảnh hưởng của độ phân giải đến Dice của PGA-UNet theo ba nhóm đặc tính tổn thương trên BTXRD.



Hình A.8: Tổng hợp Dice của SAM-Med2D và PGA-UNet (256×256, 512×512) theo ba nhóm đặc tính tổn thương trên BTXRD.

A.3

Phân tích trên FracAtlas

Ba nhóm thực nghiệm đã thực hiện trên BTXRD được lặp lại trên FracAtlas, gồm nghiên cứu loại bỏ thành phần, đánh giá chéo 4-fold và phân tích theo đặc tính tổn thương. Tất cả mô hình được huấn luyện lại từ đầu trên FracAtlas, không sử dụng trực tiếp trọng số đã học từ BTXRD.

Thiết lập này nhằm kiểm tra liệu các đặc điểm thiết kế của PGA-UNet có tiếp tục phát huy trên dữ liệu gãy xương với hình thái tổn thương khác BTXRD hay không. Đây là phép đánh giá khả năng tái lập của thiết kế trên hai miền dữ liệu độc lập, không phải tổng quát hóa liên miền theo nghĩa huấn luyện trên một bộ dữ liệu và suy luận trực tiếp trên bộ còn lại.

A.3.1

Đóng góp của kiến trúc và câu nhắc

Thiết kế thí nghiệm. Tám cấu hình trong Mục A.2.1 được huấn luyện lại từ đầu trên FracAtlas với cùng cách phân chia dữ liệu và cấu hình huấn luyện. Các cấu hình chỉ khác nhau ở sự hiện diện của PSG, cơ chế chú ý trên các kết nối tắt của nhánh giải mã và biểu diễn câu nhắc. Kết quả trong ba kịch bản được trình bày tại Bảng A.8.

Bảng A.8: Kết quả nghiên cứu loại bỏ thành phần trên FracAtlas trong ba kịch bản câu nhắc (N=72 ảnh)

Cấu hình	PSG	Chú ý trên kết nối tắt	Câu nhắc	Bao trọn $\uparrow$	Lệch tâm $\uparrow$	Hỗn hợp $\uparrow$
U-Net+Concat (Gaussian)	×	Không	Gaussian	0.8131	0.6579	0.7573
U-Net+PSG	✓	Không	Gaussian	0.8211	0.6760	0.7700
U-Net+CAD	×	CAD	Gaussian	0.7806	0.6551	0.7271
PGA-UNet (nhị phân)	✓	CAD	Nhị phân	0.7907	0.6845	0.7474
U-Net+Concat (nhị phân)	×	Không	Nhị phân	0.8203	0.6630	0.7658
PGA-UNet	✓	CAD	Gaussian	0.8169	0.7850	0.8129
U-Net+PSG+Cổng chú ý nguyên bản	✓	Nguyên bản	Gaussian	0.8351	0.6927	0.7838
U-Net+Cổng chú ý nguyên bản	×	Nguyên bản	Gaussian	0.7896	0.6630	0.7378

Đối chiếu với các mô hình không sử dụng câu nhắc. Trên FracAtlas, U-Net và Attention U-Net không sử dụng câu nhắc lần lượt đạt Dice 0,3831

và 0,2467. Trong khi đó, cấu hình nối kênh đơn giản U-Net+Concat đạt 0,8131 ở kịch bản Bao trọn. Nói đơn giản, thông tin vị trí từ câu nhắc đóng vai trò khá quan trọng khi phân đoạn đường gãy xương.

Attention U-Net thấp hơn U-Net 0,1364 Dice, cùng chiều với chênh lệch 0,0618 trên BTXRD. Kết quả này chỉ cho thấy công chú ý nguyên bản không tự cải thiện hiệu năng trong thiết lập thiếu câu nhắc; nó không trực tiếp xác định nguyên nhân gây suy giảm.

Đóng góp của PSG tại bộ mã hóa. So với U-Net+Concat, U-Net+PSG cải thiện Dice trong cả ba kịch bản: tăng 0,0080 ở Bao trọn, 0,0181 ở Lệch tâm và 0,0127 ở Hỗn hợp. Mức cải thiện này lớn hơn xu hướng quan sát trên BTXRD, cho thấy việc đưa thông tin không gian vào bộ mã hóa có lợi đối với các vùng gãy xương nhỏ và mảnh.

Tuy nhiên, U-Net+PSG vẫn thấp hơn PGA-UNet 0,1090 ở Lệch tâm và 0,0429 ở Hỗn hợp. Nói đơn giản thì PSG giúp cải thiện đặc trưng mã hóa, nhưng như vậy vẫn chưa đủ nếu các kết nối tắt của nhánh giải mã không tiếp tục dùng thông tin câu nhắc.

Đóng góp của CAD và sự khác biệt với công chú ý nguyên bản. Khi hoạt động không có PSG, U-Net+CAD không cải thiện so với U-Net+Concat. Dice giảm 0,0325 ở Bao trọn, 0,0028 ở Lệch tâm và 0,0302 ở Hỗn hợp. Có thể thấy CAD một mình chưa phát huy hiệu quả khi đặc trưng mã hóa chưa được PSG điều biến theo câu nhắc.

Công chú ý nguyên bản cũng phụ thuộc vào PSG. Khi không có PSG, U-Net+Công chú ý nguyên bản thấp hơn U-Net+Concat 0,0235 ở Bao trọn và 0,0195 ở Hỗn hợp, còn Lệch tâm chỉ tăng 0,0051. Khi bổ sung PSG, U-Net+PSG+Công chú ý nguyên bản đạt 0,8351 ở Bao trọn, 0,6927 ở Lệch tâm và 0,7838 ở Hỗn hợp, cao hơn cấu hình chỉ có PSG trong cả ba trường hợp.

So với công chú ý nguyên bản có PSG, PGA-UNet sử dụng CAD thấp hơn 0,0182 ở Bao trọn nhưng cao hơn 0,0923 ở Lệch tâm và 0,0291 ở Hỗn hợp. Hiểu đơn giản thì công chú ý nguyên bản có vẻ hợp hơn khi hộp giới hạn lý tưởng, còn CAD lại có ích rõ hơn khi câu nhắc bị sai lệch.

Đóng góp của bản đồ nhiệt Gaussian. Ở cấu hình nổi kênh cơ sở, mặt nạ nhị phân cao hơn bản đồ Gaussian 0,0072 ở Bao trọn, 0,0051 ở Lệch tâm và 0,0085 ở Hỗn hợp. Các mức chênh lệch đều nhỏ hơn 0,01, cho thấy cách biểu diễn câu nhắc ít ảnh hưởng khi câu nhắc chỉ được nối trực tiếp vào đầu vào.

Khi kết hợp đầy đủ PSG và CAD, xu hướng thay đổi rõ rệt. PGA-UNet sử dụng Gaussian cao hơn phiên bản dùng câu nhắc nhị phân 0,0262 ở Bao trọn, 0,1005 ở Lệch tâm và 0,0655 ở Hỗn hợp. Qua đó có thể thấy lợi ích của Gaussian chỉ thực sự rõ khi thông tin câu nhắc được đưa vào cả bộ mã hóa qua PSG lẫn các kết nối tắt của nhánh giải mã qua CAD.


Sự bổ trợ giữa PSG, CAD và bản đồ nhiệt Gaussian. Trong kịch bản Lệch tâm, PSG riêng lẻ cải thiện 0,0181 so với U-Net+Concat, trong khi CAD riêng lẻ giảm 0,0028. Ngược lại, cấu hình đầy đủ PSG+CAD+Gaussian cải thiện 0,1271, từ 0,6579 lên 0,7850. Nhìn vào số này thì CAD không hoạt động hiệu quả như một thành phần độc lập, mà cần đặc trưng đã được PSG điều biến tại bộ mã hóa từ trước.

Theo thiết kế của PGA-UNet, PSG đưa thông tin vị trí vào quá trình trích xuất đặc trưng, CAD tiếp tục sử dụng đặc trưng câu nhắc trên các kết nối tắt của nhánh giải mã, còn Gaussian cung cấp tín hiệu không gian có chuyển tiếp mềm. Kết quả trên FracAtlas cho thấy hiệu quả của mô hình xuất hiện từ sự phối hợp giữa ba yếu tố thay vì từ một thành phần riêng lẻ.


Kết luận từ nghiên cứu loại bỏ thành phần. PGA-UNet không đạt Dice cao nhất trong kịch bản Bao trọn; U-Net+PSG+Cổng chú ý nguyên bản đạt 0,8351, trong khi PGA-UNet đạt 0,8169. Ngược lại, PGA-UNet đạt kết quả cao nhất ở Lệch tâm với 0,7850 và Hỗn hợp với 0,8129. So với U-Net+Concat, mức cải thiện tương ứng là 0,1271 và 0,0556.

Kết quả này nhất quán với xu hướng chính trên BTXRD: kiến trúc đề xuất chấp nhận giảm nhẹ hiệu năng trong điều kiện câu nhắc lý tưởng để duy trì hiệu năng tốt hơn khi câu nhắc bị sai lệch. Trên FracAtlas, đóng góp riêng của PSG thể hiện rõ hơn, CAD riêng lẻ không tạo cải thiện,


nhưng sự kết hợp PSG+CAD cùng câu nhắc Gaussian mang lại mức tăng lớn nhất trong hai kịch bản có sai lệch. Điều này củng cố nhận định rằng ưu thế của PGA-UNet đến từ sự phối hợp giữa các thành phần, không phải từ PSG, CAD hoặc Gaussian khi được sử dụng độc lập.



Hình A.9: Dice của tám cấu hình trong nghiên cứu loại bỏ thành phần trên FracAtlas. PGA-UNet đạt kết quả cao nhất trong hai kịch bản Lệch tâm và Hỗn hợp.



Hình A.10: Minh họa định tính so sánh cấu hình PGA-UNet (Gaussian) với cấu hình dùng câu nhắc nhị phân trên BTXRD, tương ứng hai hàng cuối của Bảng A.2.



Hình A.11: Minh họa định tính so sánh cấu hình PGA-UNet (Gaussian) với cấu hình dùng câu nhắc nhị phân trên FracAtlas, tương ứng hai hàng cuối của Bảng A.8.

Các nhận xét trên dựa trên chênh lệch Dice trung bình. Kiểm định Wilcoxon signed-rank trên Dice bất cặp theo từng ảnh và phân đối chiếu chính thức giữa BTXRD với FracAtlas được trình bày tại Mục A.4.

A.3.2

Đánh giá độ ổn định bằng đánh giá chéo

PGA-UNet ở độ phân giải 512×512 được đánh giá trên FracAtlas bằng cùng quy trình đánh giá chéo 4-fold đã áp dụng cho BTXRD tại Mục A.2.2. Thực nghiệm này nhằm khảo sát mức độ ổn định của mô hình trước sự thay đổi cách phân chia dữ liệu. Do số vùng gãy xương trên mỗi ảnh không đồng đều, số mẫu đa giác trong tập đánh giá của từng Phân vùng dao động từ 89 đến 95.

Bảng A.9 trình bày Dice của từng Phân vùng trong ba kịch bản câu nhắc. Kết quả trung bình trên bốn Phân vùng đối với đầy đủ sáu chỉ số được tổng hợp trong Bảng A.10.

Dice trung bình đạt 0,8144 ở kịch bản Bao trọn, 0,7904 ở Lệnh tâm và 0,8071 ở Hỗn hợp. Độ lệch chuẩn dao động từ 0,0064 đến 0,0084, cho thấy kết quả ít biến động giữa bốn phân vùng mặc dù số mẫu đa giác trong mỗi

Bảng A.9: Dice của PGA-UNet trên từng Phân vùng của FracAtlas trong ba kịch bản câu nhắc

Phân vùng	Số mẫu đa giác	Bao trọn $\uparrow$	Lệch tâm $\uparrow$	Hỗn hợp $\uparrow$
Phân vùng 1	89	0.8127	0.8025	0.8060
Phân vùng 2	93	0.8026	0.7862	0.7981
Phân vùng 3	95	0.8200	0.7930	0.8161
Phân vùng 4	90	0.8222	0.7798	0.8082
Trung bình $\pm$ độ lệch chuẩn	91.75 $\pm$ 2.38	0.8144 $\pm$ 0.0077	0.7904 $\pm$ 0.0084	0.8071 $\pm$ 0.0064

Phân vùng không hoàn toàn bằng nhau. Kịch bản Lệch tâm có độ lệch chuẩn cao nhất, phản ánh mức biến động lớn hơn khi vị trí hộp giới hạn bị sai lệch.

Bảng A.10: Kết quả trung bình của đánh giá chéo 4-fold trên FracAtlas

Kịch bản	Dice $\uparrow$	IoU $\uparrow$	Precision $\uparrow$	Recall $\uparrow$	HD95 $\downarrow$ (px)	CBL $\uparrow$
Bao trọn	0.8144	0.6955	0.7735	0.8809	8.28	0.9541
Lệch tâm	0.7904	0.6627	0.7589	0.8460	9.57	0.9337
Hỗn hợp	0.8071	0.6859	0.7671	0.8723	8.84	0.9476

Các chỉ số trong Bảng A.10 thể hiện cùng xu hướng trên cả bốn fold: kịch bản Bao trọn đạt kết quả cao nhất, Lệch tâm thấp nhất và Hỗn hợp nằm giữa hai trường hợp. So với kết quả trên tập kiểm thử chính tại Bảng 4.7, Dice trung bình chênh lệch 0,0025 ở Bao trọn, 0,0054 ở Lệch tâm và 0,0058 ở Hỗn hợp.

Độ lệch chuẩn thấp cùng sự tương đồng với kết quả trên tập kiểm thử chính cho thấy PGA-UNet tương đối ổn định trước các cách phân chia dữ liệu khác nhau trên FracAtlas. Xu hướng này nhất quán với kết quả đánh giá chéo trên BTXRD, cho thấy độ ổn định của mô hình được duy trì trên cả dữ liệu khối u xương và dữ liệu gãy xương.

A.3.3

Phân tích theo đặc tính tổn thương


Tương tự Mục A.2.3, mục này phân tích hiệu năng của PGA-UNet trên FracAtlas theo các nhóm ảnh có đặc điểm tổn thương khác nhau. Ba phép so sánh được thực hiện: so sánh với U-Net trên các ảnh mà U-Net hoạt động tốt hoặc kém; so sánh PGA-UNet với SAM-Med2D ở cùng độ phân giải 256×256 ; và so sánh hai phiên bản PGA-UNet tại 256×256 và 512×512 . Các kết quả phân nhóm chỉ có ý nghĩa mô tả và không thay thế kết quả trung bình trên toàn bộ tập kiểm thử.

So sánh với U-Net theo mức hiệu năng của mô hình cơ sở. Theo cùng tiêu chí phân nhóm đã dùng trên BTXRD (Mục A.2.3), tập kiểm thử FracAtlas được chia thành hai nhóm hậu nghiệm theo chính Dice của U-Net: nhóm Dice cao nhất của U-Net (TOP-DICE) và nhóm Dice thấp nhất của U-Net (BOTTOM-DICE). Do FracAtlas chỉ có 72 ảnh kiểm thử (ít hơn nhiều so với 187 ảnh của BTXRD), quy mô mỗi nhóm được điều chỉnh còn $N=36$ ảnh/nhóm để hai nhóm không chồng lấp nhau ($2 \times 36 = 72 = 72$).

Bảng A.11: So sánh PGA-UNet với U-Net theo mức hiệu năng của U-Net trên FracAtlas (36 ảnh/nhóm)


Nhóm	Mô hình	Dice $\uparrow$	IoU $\uparrow$	Precision $\uparrow$	Recall $\uparrow$	HD95 $\downarrow$ (px)	CBL $\uparrow$
TOP-DICE (N=36)	U-Net	0.6532	0.5018	0.6266	0.7500	82.10	0.7595
	PGA-UNet	0.8324	0.7179	0.7920	0.8975	8.04	0.9600
BOTTOM-DICE (N=36)	U-Net	0.1130	0.0654	0.1397	0.1784	191.54	0.1662
	PGA-UNet	0.8015	0.6726	0.7370	0.8974	6.85	0.9493

Xu hướng từ BTXRD (Bảng A.5) được tái khẳng định trên FracAtlas. Ở nhóm TOP-DICE, U-Net đạt Dice khá (0,6532) vì đây là những ca dễ nhất theo chính đánh giá của nó; PGA-UNet vẫn cao hơn 0,1791. Ở nhóm BOTTOM-DICE, U-Net suy giảm nghiêm trọng (Dice= 0,1130, HD95= 191,54 điểm ảnh), trong khi PGA-UNet gần như không đổi so với nhóm TOP-DICE (0,8015 so với 0,8324). Tương tự nhận định trên BTXRD, cách phân nhóm này lấy trực tiếp từ kết quả của U-Net nên chỉ mang tính mô tả hai cực hiệu năng của mô hình cơ sở, không phải phân loại độ khó độc lập.



Hình A.12: Dice của U-Net và PGA-UNet trên nhóm TOP-DICE và BOTTOM-DICE, FracAtlas.

Hình A.13 minh họa cùng khuôn mẫu trên FracAtlas: ở nhóm TOP-DICE, PGA-UNet (Dice= 0,909) và U-Net (Dice= 0,872) đều phân đoạn tốt; ở nhóm BOTTOM-DICE (một ca cổ chân nhiều điểm nhiễu), U-Net không phân đoạn được vùng mục tiêu (Dice= 0,000) trong khi PGA-UNet vẫn giữ Dice= 0,848.



Hình A.13: Kết quả định tính của U-Net và PGA-UNet trên một ảnh thuộc mỗi nhóm hiệu năng của U-Net, FracAtlas.

So sánh với SAM-Med2D theo đặc tính tổn thương. Tập kiểm thử FracAtlas được chia thành ba nhóm không chồng lấp, mỗi nhóm gồm 24 ảnh. Nhóm Tổn thương nhỏ gồm các ảnh có tổng diện tích nhãn nhỏ nhất. Trong số ảnh còn lại, 24 ảnh có Dice SAM-Med2D thấp nhất được xếp vào nhóm Biên mờ; 24 ảnh còn lại có diện tích tổn thương lớn nhất được xếp vào nhóm Tổn thương rõ. Phân tích chỉ sử dụng kịch bản Bao trọn và các chỉ số đều được tính trong hệ tọa độ 512×512 .

Tên nhóm Biên mờ được sử dụng như một quy ước mô tả cho những ảnh SAM-Med2D gặp khó khăn. Do nhóm này được xác định dựa trên

chính Dice của SAM-Med2D, kết quả có tính mô tả và không được xem là một phép kiểm định độc lập về độ khó của tổn thương.

Để bảo đảm so sánh công bằng, PGA-UNet và SAM-Med2D trước hết được đối chiếu ở cùng độ phân giải 256×256 , trên cùng nhóm ảnh và cùng hộp giới hạn. Kết quả được trình bày trong Bảng A.12.

Bảng A.12: So sánh PGA-UNet với SAM-Med2D theo đặc tính tổn thương ở cùng độ phân giải 256×256 trên FracAtlas (Bao trọn, 24 ảnh/nhóm)


Nhóm	Mô hình	Dice $\uparrow$	IoU $\uparrow$	Precision $\uparrow$	Recall $\uparrow$	HD95 $\downarrow$ (px)	CBL $\uparrow$
Tổn thương nhỏ	SAM-Med2D (256×256)	0.4395	0.3141	0.7793	0.3507	30.94	0.8210
	PGA-UNet (256×256)	0.7584	0.6178	0.6652	0.9006	6.04	0.9125
Biên mờ	SAM-Med2D (256×256)	0.5787	0.4132	0.7814	0.4953	14.80	0.9005
	PGA-UNet (256×256)	0.7926	0.6627	0.7118	0.9060	9.41	0.9566
Tổn thương rõ	SAM-Med2D (256×256)	0.7677	0.6253	0.8451	0.7178	9.86	0.9373
	PGA-UNet (256×256)	0.8358	0.7213	0.8105	0.8801	8.17	0.9563

Ở cùng độ phân giải, PGA-UNet đạt Dice cao hơn SAM-Med2D trong cả ba nhóm. Mức chênh lệch xấp xỉ 0,319 ở Tổn thương nhỏ, 0,214 ở Biên mờ và 0,068 ở Tổn thương rõ. Khoảng cách giảm dần khi tổn thương có kích thước lớn và hình thái rõ hơn.

Ở nhóm Tổn thương nhỏ, PGA-UNet đạt Recall 0,9006, trong khi SAM-Med2D chỉ đạt 0,3507. Tuy nhiên, Precision của SAM-Med2D cao hơn, đạt 0,7793 so với 0,6652. Xu hướng tương tự xuất hiện ở hai nhóm còn lại: SAM-Med2D có Precision cao hơn, còn PGA-UNet đạt Recall, Dice và CBL cao hơn. Có thể hiểu là SAM-Med2D dự đoán thận trọng hơn, còn PGA-UNet bao phủ được nhiều điểm ảnh tổn thương hơn.

Ở nhóm Tổn thương rõ, khoảng cách Dice thu hẹp còn khoảng 0,068, tức là hai mô hình gần nhau hơn khi vùng tổn thương dễ xác định. Riêng kết quả ở nhóm Biên mờ cần được diễn giải thận trọng vì nhóm được lựa chọn dựa trên Dice thấp của SAM-Med2D.

Ảnh hưởng của độ phân giải theo đặc tính tổn thương. Hai phiên bản PGA-UNet được tiếp tục đối chiếu trên cùng ba nhóm ảnh để xác định ảnh hưởng của việc tăng độ phân giải từ 256×256 lên 512×512 . Ngoài độ phân giải và điểm lưu trọng số tương ứng, các điều kiện đánh giá được



Hình A.14: So sánh Dice của PGA-UNet và SAM-Med2D theo đặc tính tổn thương ở cùng độ phân giải 256×256 trên FracAtlas.

giữ nguyên. Dự đoán của cả hai phiên bản được đánh giá trong cùng hệ tọa độ 512×512 .

Bảng A.13: Ảnh hưởng của độ phân giải đối với PGA-UNet theo đặc tính tổn thương trên FracAtlas (Bao trọn, 24 ảnh/nhóm)

Nhóm	Độ phân giải	Dice↑	IoU↑	Precision↑	Recall↑	HD95↓ (px)	CBL↑
Tổn thương nhỏ	256×256	0.7584	0.6178	0.6652	0.9006	6.04	0.9125
	512×512	0.8028	0.6756	0.7269	0.9150	5.05	0.9400
Biên mờ	256×256	0.7926	0.6627	0.7118	0.9060	9.41	0.9566
	512×512	0.8039	0.6775	0.7439	0.8925	9.29	0.9552
Tổn thương rõ	256×256	0.8358	0.7213	0.8105	0.8801	8.17	0.9563
	512×512	0.8404	0.7280	0.8203	0.8786	8.09	0.9626

Tăng độ phân giải cải thiện Dice trên cả ba nhóm, nhưng mức tăng lớn nhất xuất hiện ở Tổn thương nhỏ. Dice của nhóm này tăng 0,0444, từ 0,7584 lên 0,8028; Precision tăng 0,0617 và CBL tăng 0,0275. Có thể thấy tổn thương nhỏ hưởng lợi rõ nhất từ việc giữ được nhiều chi tiết không gian hơn ở đầu vào.

SAM-Med2D -- Tổn thương nhỏ (Dice=0.211, IoU=0.118)



PGA-UNet -- Tổn thương nhỏ (Dice=0.812, IoU=0.684)



SAM-Med2D -- Biên giới mờ (Dice=0.689, IoU=0.525)



PGA-UNet -- Biên giới mờ (Dice=0.755, IoU=0.607)



SAM-Med2D -- Tổn thương rõ nét (Dice=0.748, IoU=0.597)




PGA-UNet -- Tổn thương rõ nét (Dice=0.837, IoU=0.719)



Hình A.15: Kết quả định tính của SAM-Med2D và PGA-UNet trên các ảnh đại diện thuộc ba nhóm đặc tính tổn thương trên FracAtlas.

Ở nhóm Biên mờ, Dice chỉ tăng 0,0113; ở nhóm Tổn thương rõ, mức tăng còn 0,0046. Hai nhóm này ít nhạy với độ phân giải hơn Tổn thương nhỏ. Recall của phiên bản 256 cao hơn nhẹ trong hai nhóm, trong khi phiên bản 512 đạt Dice, IoU và Precision cao hơn.

Do các dự đoán đều được quy đổi về cùng hệ tọa độ 512×512 trước khi tính chỉ số, HD95 có thể được so sánh trực tiếp trong Bảng A.13. Tuy nhiên, mức chênh lệch HD95 giữa hai độ phân giải ở nhóm Biên mờ và Tổn thương rõ rất nhỏ.



Hai cấu hình dùng cùng nhóm ảnh và câu nhắc Bao trọn; chỉ số được tính trong hệ tọa độ 512×512 .

Hình A.16: Ảnh hưởng của độ phân giải đến Dice của PGA-UNet theo ba nhóm đặc tính tổn thương trên FracAtlas.

Kết luận. Khi kiểm soát độ phân giải ở 256×256 , PGA-UNet vẫn đạt Dice cao hơn SAM-Med2D trên cả ba nhóm, đặc biệt ở Tổn thương nhỏ và nhóm ảnh SAM-Med2D gặp khó khăn. Khi chỉ thay đổi độ phân giải của PGA-UNet, nhóm Tổn thương nhỏ tiếp tục nhận được mức cải thiện lớn nhất. Hai kết quả cho thấy ưu thế của PGA-UNet trên tổn thương nhỏ không chỉ đến từ việc sử dụng ảnh 512×512 , mặc dù độ phân giải cao vẫn giúp cải thiện thêm hiệu năng.

A.4

Kết luận đóng góp kiến trúc trên hai miền dữ liệu

Các nghiên cứu loại bỏ thành phần trên BTXRD tại Mục A.2.1 và FracAtlas tại Mục A.3.1 trước hết dựa trên chênh lệch Dice trung bình. Để đánh giá độ tin cậy của các chênh lệch này ở cấp độ ảnh, sáu cặp cấu hình tương ứng với các câu hỏi kiến trúc chính được kiểm tra bằng kiểm định hạng có dấu Wilcoxon trên Dice bất cặp theo từng ảnh.

Kiểm định được thực hiện riêng trên BTXRD và FracAtlas trong ba kịch bản câu nhắc, tạo thành 36 kết quả. Bảng A.14 báo cáo giá trị p thô, chưa hiệu chỉnh cho việc thực hiện nhiều phép so sánh. Vì vậy, các kết quả có $p < 0,001$ được xem là bằng chứng mạnh hơn, còn các giá trị gần ngưỡng 0,05 chỉ được diễn giải theo hướng thăm dò.

Bảng A.14: Kiểm định Wilcoxon cho sáu cặp cấu hình trên BTXRD và FracAtlas. Δ Dice được tính bằng Dice của cấu hình thứ nhất trừ cấu hình thứ hai; các giá trị p chưa được hiệu chỉnh cho so sánh nhiều lần

Cặp cấu hình	Kịch bản	Δ Dice BTXRD	p BTXRD	Δ Dice FracAtlas	p FracAtlas
U-Net + Cổng chú ý nguyên bản – U-Net+Concat(Gaussian)	Bao trộn	−0.0024	0,255	−0.0235	< 0,001
	Lệch tâm	−0.0050	0,607	+0.0050	0,255
	Hỗn hợp	−0.0023	0,395	−0.0195	< 0,001
U-Net + CAD – U-Net+Cổng chú ý nguyên bản	Bao trộn	+0.0122	< 0,001	−0.0089	0,025
	Lệch tâm	+0.0092	0,152	−0.0079	0,141
	Hỗn hợp	+0.0098	0,003	−0.0107	0,023
U-Net + PSG + Cổng chú ý nguyên bản – U-Net + PSG	Bao trộn	+0.0007	0,129	+0.0140	0,009
	Lệch tâm	−0.0030	0,376	+0.0167	0,005
	Hỗn hợp	+0.0011	0,074	+0.0138	0,002
PGA - UNet (Gaussian) – U-Net + PSG + Cổng chú ý nguyên bản	Bao trộn	−0.0073	0,025	−0.0182	< 0,001
	Lệch tâm	+0.1065	< 0,001	+0.0924	< 0,001
	Hỗn hợp	+0.0388	0,001	+0.0291	0,161
U-Net + Concat (Gaussian) – U-Net + Concat (nhị phân)	Bao trộn	−0.0018	0,896	−0.0072	0,007
	Lệch tâm	+0.0052	0,013	−0.0050	0,284
	Hỗn hợp	+0.0015	0,226	−0.0085	0,006
PGA-UNet (Gaussian) – PGA-UNet (nhị phân)	Bao trộn	−0.0173	< 0,001	+0.0262	< 0,001
	Lệch tâm	+0.0990	< 0,001	+0.1005	< 0,001
	Hỗn hợp	+0.0293	0,012	+0.0655	< 0,001

Vai trò của CAD đối với khả năng duy trì hiệu năng dưới sai lệch câu nhắc mô phỏng. Kết quả nhất quán nhất giữa hai bộ dữ liệu xuất hiện khi so sánh PGA-UNet với cấu hình dùng PSG và công chú ý nguyên bản. Trong kịch bản Lệch tâm, việc thay công chú ý nguyên bản bằng CAD làm Dice tăng 0,1065 trên BTXRD và 0,0924 trên FracAtlas; cả hai phép kiểm định đều đạt $p < 0,001$.

Ở kịch bản Hỗn hợp, mức tăng đạt 0,0388 trên BTXRD và 0,0291 trên FracAtlas, nhưng chỉ kết quả BTXRD đạt giá trị p nhỏ dưới 0,05. Trong kịch bản Bao trọn, PGA-UNet thấp hơn cấu hình dùng công chú ý nguyên bản 0,0073 trên BTXRD và 0,0182 trên FracAtlas.

Như vậy, bằng chứng mạnh và nhất quán nhất của CAD nằm ở kịch bản Lệch tâm. CAD không tối đa hóa Dice khi hộp giới hạn hoàn toàn lý tưởng, nhưng giúp mô hình duy trì hiệu năng tốt hơn khi vị trí câu nhắc bị sai lệch. Kết quả này phù hợp với mục tiêu thiết kế PGA-UNet là tăng mức ổn định dưới sai số hộp giới hạn đã được mô phỏng trong thực nghiệm.

Vai trò của bản đồ nhiệt Gaussian. Khi câu nhắc chỉ được nối vào

đầu vào, chênh lệch giữa Gaussian và mặt nạ nhị phân đều nhỏ hơn 0,01 Dice và không nhất quán về chiều giữa hai bộ dữ liệu. Nói cách khác, tự riêng cách biểu diễn câu nhắc thì chưa đủ để tạo khác biệt lớn nếu kiến trúc không có cơ chế khai thác câu nhắc ở nhiều tầng.

Trong cấu hình đầy đủ PSG+CAD, Gaussian tạo ra mức cải thiện rõ rệt ở các kịch bản có sai lệch. So với PGA-UNet dùng câu nhắc nhị phân, phiên bản Gaussian tăng 0,0990 Dice trên BTXRD và 0,1005 trên FracAtlas ở kịch bản Lệch tâm, với $p < 0,001$ trên cả hai bộ dữ liệu. Trong kịch bản Hỗn hợp, mức tăng tương ứng là 0,0293 và 0,0655.

Riêng kịch bản Bao trọn có kết quả khác nhau giữa hai miền: Gaussian thấp hơn nhị phân 0,0173 trên BTXRD nhưng cao hơn 0,0262 trên

FracAtlas. Vì vậy, đóng góp nhất quán của Gaussian không nằm ở kích bản lý tưởng mà ở khả năng hỗ trợ mô hình khi câu nhắc bị sai lệch, đặc biệt khi được kết hợp với PSG và CAD.

Đóng góp riêng lẻ của PSG và cơ chế chú ý. Các thành phần riêng lẻ có biên độ ảnh hưởng nhỏ và thay đổi giữa hai bộ dữ liệu. Khi không có PSG, CAD cao hơn công chú ý nguyên bản trên BTXRD ở Bao trọn và Hỗn hợp, nhưng thấp hơn trên FracAtlas trong cùng hai kịch bản. Khi có PSG, công chú ý nguyên bản gần như không cải thiện so với PSG đơn độc trên BTXRD, nhưng tạo ra mức tăng từ 0,0138 đến 0,0167 trên FracAtlas.

Những kết quả này cho thấy tác dụng của PSG, CAD hoặc công chú ý khi đứng riêng phụ thuộc vào đặc điểm dữ liệu. Do biên độ đều dưới 0,02 Dice và không nhất quán về chiều, chúng không được xem là quy luật kiến trúc chung. Hơn nữa, các kiểm định trong từng bộ dữ liệu không trực tiếp kiểm tra sự khác biệt hiệu ứng giữa hai miền, nên chưa thể kết luận đây là tương tác có ý nghĩa thống kê giữa kiến trúc và bộ dữ liệu.

Sự bổ trợ giữa PSG, CAD và Gaussian. Ở kịch bản Lệch tâm trên BTXRD, PSG và CAD khi sử dụng riêng chỉ cải thiện lần lượt 0,0024 và 0,0042 so với U-Net+Concat, trong khi cấu hình đầy đủ cải thiện 0,1059. Trên FracAtlas, PSG riêng lẻ tăng 0,0181, CAD riêng lẻ giảm 0,0028, nhưng cấu hình đầy đủ tăng 0,1271.

Các chênh lệch trung bình cho thấy hiệu quả của PGA-UNet không phải là tổng đơn giản của những cải thiện do từng thành phần riêng lẻ. PSG đưa thông tin câu nhắc vào bộ mã hóa, CAD tiếp tục sử dụng đặc trưng câu nhắc trên các kết nối tắt của nhánh giải mã và Gaussian cung cấp tín hiệu không gian có chuyển tiếp mềm. Ba thành phần này có vẻ bổ trợ cho nhau trong việc giữ thông tin câu nhắc xuyên suốt mạng. Dù vậy, đây vẫn là nhận xét đi ra từ thiết kế ablation, chưa phải kết quả của một kiểm định tương tác thống kê riêng.

Độ ổn định qua các phân vùng dữ liệu. Kiểm định chéo 4-fold cho thấy Dice ít biến động giữa các phân vùng trên cả hai bộ dữ liệu. Độ lệch chuẩn Dice dao động từ 0,0087 đến 0,0119 trên BTXRD và từ 0,0064 đến

0,0084 trên FracAtlas. Giá trị trung bình qua các Phân vùng cũng gần với kết quả trên tập kiểm thử chính.

Nhìn chung, hiệu năng của PGA-UNet tương đối ổn định trước thay đổi cách phân chia dữ liệu. Tuy nhiên, độ lệch chuẩn qua Phân vùng và chênh lệch giữa các cấu hình đo hai nguồn biến động khác nhau, nên không được kết hợp thành một tỷ lệ tín hiệu trên nhiễu.

Các trường hợp còn hạn chế. Các dạng tổn thương còn gây khó khăn cho PGA-UNet (hình dạng kéo dài hoặc phân nhánh, vùng giải phẫu chồng lấp, ảnh có độ tương phản thấp) cùng minh họa định tính tương ứng được tổng hợp tại Mục 4.3.3, Chương 4.

Kết luận về phạm vi đóng góp kiến trúc. Nếu nhìn trên cả hai bộ dữ liệu thì phần đóng góp nhất quán nhất của PGA-UNet nằm ở khả năng duy trì hiệu năng khi câu nhắc bị sai lệch. Ở kịch bản Lệch tâm, CAD cao hơn công chú ý nguyên bản và bản đồ nhiệt Gaussian cao hơn câu nhắc nhị phân với biên độ lớn, cùng giá trị $p < 0,001$ trên cả BTRD và FracAtlas. Đây là bằng chứng mạnh nhất cho vai trò phối hợp của PSG, CAD và Gaussian trong thiết kế đề xuất, nhưng cũng chỉ mới nằm trong phạm vi các sai lệch câu nhắc mô phỏng đã được khảo sát.

PGA-UNet được huấn luyện lại độc lập trên từng bộ dữ liệu và duy trì xu hướng chính trên cả tổn thương khối u xương lẫn đường gãy xương. Kết quả này cung cấp bằng chứng về khả năng tái lập của thiết kế trên hai miền dữ liệu, nhưng không phải tổng quát hóa liên miền theo nghĩa huấn luyện trên một bộ dữ liệu rồi suy luận trực tiếp trên miền chưa từng thấy.

Các thành phần riêng lẻ có biên độ ảnh hưởng nhỏ và không nhất quán giữa hai miền, nên không được diễn giải như đóng góp tổng quát khi đứng độc lập. Phạm vi kết luận của mục này giới hạn ở mô-đun phân đoạn; khả năng hoạt động của toàn bộ hệ thống, bao gồm tầng sàng lọc đầu vào, được đánh giá riêng tại Mục 4.4, Chương 4 và Phụ lục B.

PHỤ LỤC B

ĐÁNH GIÁ LUỒNG XỬ LÝ HAI GIAI ĐOẠN

Phụ lục này trình bày chi tiết thực nghiệm mở rộng đã được tóm tắt ở Mục 4.4, Chương 4. Nội dung chính là khảo sát mô-đun sàng lọc Gatekeeper (EfficientNet-B3 [29]) khi được đặt trước PGA-UNet trong một luồng xử lý gồm cả ảnh bình thường lẫn ảnh bệnh lý.

PGA-UNet vốn được thiết kế cho bài toán phân đoạn khi người dùng đã chỉ ra vùng nghi ngờ bằng hộp giới hạn. Để hình dung rõ hơn cách mô hình này có thể đặt vào một quy trình thực tế hơn, khóa luận bổ sung Gatekeeper để làm bước sàng lọc ban đầu. Mô-đun này có nhiệm vụ phân loại ảnh thành bình thường hoặc nghi ngờ có bất thường trước khi người dùng xác nhận và chuyển sang bước phân đoạn.

Cần nhắc lại rằng Gatekeeper chỉ là thành phần hỗ trợ thêm, không phải đóng góp kiến trúc chính của khóa luận. Phụ lục này chỉ xem ảnh hưởng của bước sàng lọc đối với luồng phân đoạn, chứ không đánh giá một hệ thống chẩn đoán tự động hoàn chỉnh.

B.1

Kết quả trên BTXRD

B.1.1

Hiệu năng của Gatekeeper

Gatekeeper sử dụng EfficientNet-B3 được tiền huấn luyện trên ImageNet-1K và tinh chỉnh cho bài toán phân loại nhị phân. Mô hình nhận ảnh kích thước 300×300 và trả về xác suất bất thường; ngưỡng phân loại mặc định được đặt tại 0,5.

Mô hình được đánh giá trên tập `dataset_online` gồm 375 ảnh kiểm thử BTXRD, trong đó có 187 ảnh bệnh lý và 188 ảnh bình thường. Kết quả được trình bày trong Bảng B.1.

Bảng B.1: Kết quả phân loại của Gatekeeper trên BTXRD

Chỉ số	Kết quả
Accuracy	87,73%
Precision	86,53%
Sensitivity	89,30%
Specificity	86,17%
F1-score	87,90%
AUC-ROC	0,9421

Gatekeeper đạt AUC-ROC 0,9421 và Accuracy 87,73%, tức là mô hình phân biệt ảnh bệnh lý và ảnh bình thường trên BTXRD khá tốt. Ở ngưỡng 0,5, mô hình phát hiện đúng 167/187 ảnh bệnh lý, tương ứng Sensitivity 89,30%, và đồng thời phân loại đúng 162/188 ảnh bình thường, tương ứng Specificity 86,17%. Dù vậy, vẫn còn 20 ảnh bệnh lý bị bỏ sót. Vì vậy, kết quả này chưa đủ để dùng Gatekeeper như một bước loại ảnh âm tính hoàn toàn tự động.

B.1.2

Ảnh hưởng đến luồng phân đoạn

Để khảo sát ảnh hưởng của lỗi sàng lọc, thực nghiệm mô phỏng trường hợp kết quả Gatekeeper được sử dụng trực tiếp mà không có bước sửa lại của người dùng. Trong 187 ảnh bệnh lý, 167 ảnh được chuyển đúng sang PGA-UNet và 20 ảnh bị loại nhầm. Hộp giới hạn của các ảnh được chuyển xuống được tạo từ chú thích gốc nhằm giữ cố định chất lượng câu nhắc; do đó, thực nghiệm tập trung vào lỗi định tuyến của Gatekeeper, không đánh giá khả năng tự động tạo hộp giới hạn.

Trên 167 ảnh bệnh lý được chuyển đúng, PGA-UNet đạt Dice trung bình 0,8626. Để biểu diễn ảnh hưởng của sai số tích lũy, khóa luận sử dụng Dice toàn luồng có phạt lỗi định tuyến: ảnh được chuyển đúng đóng góp Dice phân đoạn thực tế, trong khi ảnh bệnh lý bị bỏ sót và ảnh bình thường bị chuyển nhầm được gán giá trị 0. Chỉ số này được xác định bởi:

$$\text{Dice}_{\text{pipeline}} = \frac{\sum_{i \in \text{TP}} \text{Dice}_{\text{img}}(i)}{N_{\text{TP}} + N_{\text{FP}} + N_{\text{FN}}}. \quad (\text{B.1})$$

Với 167 TP, 26 FP và 20 FN, Dice toàn luồng đạt 0,6763. Bảng B.2 tóm tắt kết quả.


Bảng B.2: Kết quả mô phỏng luồng xử lý hai giai đoạn trên BTXRD

Thống kê	Giá trị
Tổng số ảnh	375
TP / FP / FN / TN	167 / 26 / 20 / 162
Dice của PGA-UNet trên ảnh TP	0,8626
Dice toàn luồng có phạt lỗi định tuyến	0,6763
IoU toàn luồng có phạt lỗi định tuyến	0,6003

Kết quả cho thấy hiệu năng toàn luồng phụ thuộc nhiều vào bước sàng lọc. Dice giảm từ 0,8626 trên các ảnh được chuyển đúng xuống còn 0,6763 khi tính cả lỗi FP và FN. Trong đó, trường hợp đáng ngại nhất vẫn là FN vì ảnh bệnh lý bị dừng lại trước khi đến PGA-UNet.

Trong quy trình đề xuất tại Chương 3, Gatekeeper chỉ cung cấp gợi ý sàng lọc và người dùng vẫn xác nhận trước khi chuyển bước. Vì chưa thực hiện thử nghiệm có sự tham gia của bác sĩ, kết quả trên chỉ phản ánh kịch bản mô phỏng không có hiệu chỉnh của người dùng, không đại diện cho hiệu năng lâm sàng của hệ thống hoàn chỉnh.

Hình B.1 minh họa một số ảnh bệnh lý được Gatekeeper phát hiện đúng và chuyển sang PGA-UNet. Các trường hợp này cho thấy mô hình có thể tiếp tục phân đoạn tổn thương tại nhiều vị trí giải phẫu khi ảnh được định tuyến đúng và cung cấp câu nhắc phù hợp.



Hình B.1: Một số kết quả phân đoạn của ảnh được Gatekeeper chuyển đúng sang PGA-UNet trên BTXRD. Từ trái sang phải: ảnh X-quang, hộp giới hạn, mặt nạ dự đoán, mặt nạ nhãn gốc và lớp phủ TP, FP, FN.

Kết luận. Gatekeeper cho thấy khả năng hỗ trợ sàng lọc ảnh đầu vào, nhưng sai số tại bước này có thể làm giảm hiệu năng của toàn bộ luồng xử lý. Vì vậy, kết quả không làm thay đổi vai trò trung tâm của PGA-UNet mà cho thấy điều kiện cần để triển khai mô hình trong thực tế: Gatekeeper nên được sử dụng như công cụ hỗ trợ, còn quyết định chuyển bước và cung cấp câu nhắc vẫn cần sự xác nhận của người dùng chuyên môn.

B.2

Kết quả trên FracAtlas

Gatekeeper giữ nguyên kiến trúc EfficientNet-B3 và quy trình huấn luyện như trên BTXRD, nhưng được huấn luyện lại hoàn toàn trên FracAtlas. Thực nghiệm nhằm kiểm tra khả năng tích hợp PGA-UNet vào cùng một luồng xử lý trên dữ liệu gãy xương, không đánh giá khả năng suy luận trực tiếp giữa hai miền dữ liệu.

B.2.1

Hiệu năng của Gatekeeper

Gatekeeper được đánh giá trên 409 ảnh kiểm thử FracAtlas, gồm 72 ảnh gãy xương và 337 ảnh bình thường. Tỷ lệ này gần với phân bố của bộ dữ liệu gốc và mất cân bằng hơn rõ rệt so với tập kiểm thử BTXRD.

Bảng B.3: Kết quả phân loại của Gatekeeper trên FracAtlas

Chỉ số	Kết quả
Accuracy	88,26%
Precision	65,38%
Sensitivity	70,83%
Specificity	91,99%
F1-score	68,00%
AUC-ROC	0,9132

Gatekeeper đạt Accuracy 88,26% và AUC-ROC 0,9132 trên FracAtlas, tức là nhìn chung vẫn phân biệt được ảnh gãy xương và ảnh bình thường khá tốt. Tuy nhiên, tại ngưỡng 0,5, mô hình chỉ phát hiện đúng 51/72 ảnh bệnh lý, tương ứng Sensitivity 70,83%, trong khi có tới 21 ảnh bị bỏ sót. Ngược lại, 310/337 ảnh bình thường được phân loại đúng, tương ứng Specificity 91,99%.

So với BTXRD, Gatekeeper trên FracAtlas có Sensitivity thấp hơn rõ rệt nhưng Specificity lại cao hơn. Có thể thấy mô hình có xu hướng nghiêng

về lớp bình thường hơn trên bộ dữ liệu mất cân bằng này, đồng thời cũng gặp khó hơn khi phải nhận diện các đường gãy nhỏ và mảnh từ toàn bộ ảnh.

Thử nghiệm ngưỡng cho thấy giảm ngưỡng xuống 0,3 có thể tăng Sensitivity lên 84,72%, nhưng Specificity giảm còn 84,87%. Vì vậy, điều chỉnh ngưỡng có thể cải thiện khả năng phát hiện ảnh bệnh lý nhưng không loại bỏ được sự đánh đổi giữa bỏ sót và báo động nhầm. Tương tự kết quả trên BTXRD, Gatekeeper chỉ nên đóng vai trò hỗ trợ sàng lọc và không tự động loại bỏ ảnh âm tính khỏi quy trình.

B.2.2

Ảnh hưởng đến luồng phân đoạn

Luồng xử lý được đánh giá trên toàn bộ 409 ảnh kiểm thử theo cùng thiết lập tại Mục B.1.2. Kết quả của Gatekeeper được sử dụng trực tiếp mà không có bước sửa lại của người dùng. Đối với ảnh bệnh lý được chuyển đúng sang PGA-UNet, hộp giới hạn được tạo từ chú thích gốc nhằm giữ cố định chất lượng câu nhắc và tập trung đánh giá ảnh hưởng của lỗi định tuyến.

Trong 72 ảnh bệnh lý, Gatekeeper chuyển đúng 51 ảnh sang PGA-UNet và bỏ sót 21 ảnh. PGA-UNet đạt Dice trung bình 0,8211 trên 51 ảnh được định tuyến đúng. Dice toàn luồng có phạt lỗi định tuyến được tính theo Công thức B.1, trong đó ảnh FN và FP được quy ước đóng góp giá trị 0.

Bảng B.4: Kết quả mô phỏng luồng xử lý hai giai đoạn trên FracAtlas

Thống kê	Giá trị
Tổng số ảnh	409
Ảnh bệnh lý / ảnh bình thường	72 / 337
TP / FP / FN / TN	51 / 27 / 21 / 310
Dice của PGA-UNet trên ảnh TP	0,8211
Dice toàn luồng có phạt lỗi định tuyến	0,4230
IoU toàn luồng có phạt lỗi định tuyến	0,3611

Dice toàn luồng trên FracAtlas chỉ đạt 0,4230, thấp hơn hẳn so với mức 0,6763 trên BTXRD. Lý do chính là Gatekeeper bỏ sót 21/72 ảnh bệnh lý, tương ứng 29,17%, cao hơn đáng kể so với BTXRD. Trong khi đó, PGA-UNet vẫn đạt Dice 0,8211 trên các ảnh được chuyển đúng, tức là bản thân mô hình phân đoạn vẫn hoạt động tốt nếu ảnh đi đúng luồng.

Sự khác biệt giữa hai giá trị cho thấy hiệu năng phân đoạn của PGA-UNet được duy trì khi ảnh đến đúng bước xử lý, còn suy giảm của chỉ số toàn luồng chủ yếu xuất phát từ lỗi sàng lọc phía trước. Tuy nhiên, Dice 0,8211 được tính trên nhóm ảnh do Gatekeeper phát hiện đúng nên chỉ mang ý nghĩa có điều kiện, không thay thế kết quả đánh giá độc lập của PGA-UNet trên toàn bộ tập kiểm thử.

Kết luận. Kết quả trên FracAtlas tiếp tục cho thấy Gatekeeper có thể hữu ích ở vai trò hỗ trợ sàng lọc, nhưng chưa đủ tin cậy để tự động quyết định ảnh nào được đưa sang PGA-UNet. Tác động của lỗi sàng lọc ở đây thể hiện rõ do Sensitivity thấp và dữ liệu mất cân bằng. Vì vậy, trong luồng đề xuất, Gatekeeper chỉ nên đóng vai trò gợi ý ưu tiên; người dùng chuyên môn vẫn cần xác nhận và cung cấp hộp giới hạn trước khi phân đoạn.