

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Thông Lúc - Nguyễn Hữu Bình

Phát triển hệ thống phân đoạn ảnh X-quang
về xương dựa vào câu nhắc trực quan

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN CNTT
CHƯƠNG TRÌNH CHUẨN

Tp. Hồ Chí Minh, tháng 07/2026

**TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN**

**Thông Lúc - 22120196
Nguyễn Hữu Bình - 22120031**

**Phát triển hệ thống phân đoạn ảnh X-quang
về xương dựa vào câu nhắc trực quan**

**KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN CNTT
CHƯƠNG TRÌNH CHUẨN**

GIẢNG VIÊN HƯỚNG DẪN

PGS.TS. Lý Quốc Ngọc

ThS. Đỗ Thị Thanh Hà

Tp. Hồ Chí Minh, tháng 07/2026

LỜI CAM ĐOAN

Tôi xin cam đoan đây là công trình nghiên cứu của riêng tôi. Các số liệu và kết quả nghiên cứu trong luận văn này là trung thực và không trùng lặp với các đề tài khác.

LỜI CẢM ƠN

Em xin gửi lời cảm ơn chân thành đến **PGS.TS. Lý Quốc Ngọc** và **ThS. Đỗ Thị Thanh Hà** đã tận tình hướng dẫn, định hướng nghiên cứu và dành thời gian phản hồi chi tiết trong suốt quá trình thực hiện khóa luận. Những góp ý thẳng thắn và sâu sắc của thầy cô đã giúp em nhận ra nhiều thiếu sót trong tư duy và cách tiếp cận bài toán, đồng thời là động lực để em không ngừng cải thiện chất lượng công trình.

Em cũng xin cảm ơn **Khoa Công nghệ Thông tin**, Trường Đại học Khoa học Tự nhiên, ĐHQG-HCM đã tạo điều kiện học tập và nghiên cứu thuận lợi trong suốt những năm qua, cung cấp nền tảng kiến thức và môi trường học thuật để em có thể tự tin tiếp cận một bài toán ứng dụng trí tuệ nhân tạo trong lĩnh vực y tế.

Mặc dù đã cố gắng hết sức, công trình này chắc chắn vẫn còn nhiều hạn chế. Em rất mong nhận được những góp ý thêm từ quý thầy cô và hội đồng phản biện để tiếp tục hoàn thiện.

Thành phố Hồ Chí Minh, tháng 6 năm 2026

Nhóm sinh viên thực hiện

Thông Lúc (MSSV: 22120196)

Nguyễn Hữu Bình (MSSV: 22120031)



ĐỀ CƯƠNG KHOÁ LUẬN TỐT NGHIỆP

PHÁT TRIỂN HỆ THỐNG PHÂN ĐOẠN ẢNH X-QUANG VỀ XƯƠNG DỰA VÀO CÂU NHẮC TRỰC QUAN

(Developing a bone X-ray image segmentation system based on visual prompts)

1 THÔNG TIN CHUNG

Người hướng dẫn:

- PGS.TS. Lý Quốc Ngọc (Khoa Công nghệ Thông tin)
- ThS. Đỗ Thị Thanh Hà (Khoa Công nghệ Thông tin)

Nhóm sinh viên thực hiện:

1. Nguyễn Hữu Bình (MSSV: 22120031)
2. Thông Lúc (MSSV: 22120196)

Loại đề tài: Nghiên cứu

Thời gian thực hiện: Từ 01/2026 đến 07/2026

2 NỘI DUNG THỰC HIỆN

2.1 Giới thiệu về đề tài

Chẩn đoán hình ảnh qua X-quang là phương thức cận lâm sàng phổ biến và quan trọng trong phát hiện các tổn thương xương như gãy xương, rạn xương và khối u xương nguyên phát. Tại các cơ sở y tế lớn, số lượng ca chụp X-quang mỗi ngày lên đến hàng trăm ca, đặt áp lực đáng kể lên đội ngũ bác sĩ về tốc độ đọc phim và độ chính xác chẩn đoán. Bước xác định và khoanh vùng tổn thương (phân đoạn ảnh) là cơ sở để đo lường kích thước khối u, theo dõi diễn tiến bệnh và lập kế hoạch điều trị; tuy nhiên hiện tại vẫn được thực hiện thủ công trên hệ thống PACS, tiêu tốn nhiều thời gian và phụ thuộc vào kinh nghiệm cá nhân.

Các mô hình học sâu tự động như U-Net [7] đã đạt kết quả khả quan trong phân đoạn ảnh y khoa, nhưng gặp khó khăn đặc thù trên ảnh X-quang xương: độ tương phản thấp, cấu trúc giải phẫu chồng lấp khiến vùng tổn thương dễ bị nhầm lẫn với mô xương lành. Các mô hình nền tảng dạng câu nhắc (prompt-based) như SAM-Med2D [3] mở ra hướng tiếp cận tương tác nhưng có kiến trúc rất nặng ($\sim 91M$ tham số), chi phí tính toán cao, không phù hợp triển khai trên phần cứng y tế thông thường.

Đề tài đề xuất xây dựng kiến trúc **PGA-UNet** (Prompt-Guided Attention U-Net): mô hình U-Net nhẹ tích hợp sâu câu nhắc hộp giới hạn của bác sĩ vào cả bộ mã hóa và bộ giải mã, kết hợp module phân lớp sàng lọc để tạo thành pipeline xử lý đầu cuối hoàn chỉnh. Toàn bộ hệ thống được huấn luyện và đánh giá trên bộ dữ liệu BTXRD (Bone Tumor X-Ray Dataset) [9].

2.2 Mục tiêu đề tài

1. **Đề xuất và xây dựng kiến trúc PGA-UNet:** Thiết kế mô hình phân đoạn nhẹ ($\sim 3M$ tham số) tích hợp câu nhắc hộp giới hạn qua Cổng không gian (Prompt Spatial Gate) tại bộ mã hóa và Cơ chế chú ý có điều kiện (Conditioned Attention Decoder) tại bộ giải mã;

huấn luyện từ đầu trên BTXRD với chiến lược tăng cường câu nhắc (empty/noisy prompt) để tăng tính bền bỉ.

2. **Phát triển module sàng lọc (Gatekeeper):** Xây dựng mô hình phân lớp nhị phân EfficientNet_B3 [8] để tự động phân biệt ảnh bình thường và ảnh có bệnh lý, ghép với PGA-UNet thành pipeline đầu cuối.
3. **Thực nghiệm và đánh giá toàn diện:** So sánh PGA-UNet với U-Net [7] và SAM-Med2D [3] trên các chỉ số Dice, IoU, Precision, Recall; đánh giá tính bền bỉ với câu nhắc không hoàn hảo; đánh giá pipeline toàn hệ thống trên tập dữ liệu hỗn hợp mô phỏng điều kiện lâm sàng thực tế.

2.3 Phạm vi của đề tài

Phạm vi thực hiện:

- Dữ liệu: Bộ dữ liệu BTXRD [9] (ảnh X-quang xương 2D thực tế, công bố trên Nature Scientific Data).
- Bài toán: Phân đoạn nhị phân vùng khối u xương (pixel-level mask) với câu nhắc hộp giới hạn; phân lớp nhị phân bình thường/bệnh lý.
- Đánh giá: So sánh với các mô hình nền tảng (U-Net [7], SAM-Med2D [3]) và đánh giá pipeline end-to-end trên tập kiểm tra hỗn hợp.

Giới hạn:

- Chỉ xử lý ảnh X-quang 2D, không bao gồm CT 3D hay MRI.
- Câu nhắc đầu vào là hộp giới hạn; chưa hỗ trợ câu nhắc dạng điểm hoặc văn bản.
- Hệ thống đóng vai trò hỗ trợ chẩn đoán, không thay thế quyết định lâm sàng của bác sĩ.

2.4 Cách tiếp cận thực hiện

Giai đoạn 1: Nghiên cứu tài liệu: Khảo sát kiến trúc U-Net [7], Attention U-Net [6], SAM-Med2D [3]; tìm hiểu cơ chế tích hợp câu nhắc không gian vào mạng tích chập; phân tích đặc điểm bộ dữ liệu BTXRD [9].

Giai đoạn 2: Chuẩn bị dữ liệu: Gán nhãn bounding box nhiều qua Roboflow [4], finetune YOLOv11s [5] để phát hiện và xóa nhiễu trên toàn tập ảnh. Sau đó, tạo các tệp mặt nạ nhị phân tương ứng với ảnh từ các tệp chú thích và chia tập huấn luyện/xác thực/kiểm tra.

Giai đoạn 3: Thiết kế và huấn luyện mô hình:

- Biểu diễn câu nhắc hộp giới hạn dưới dạng Plateau Heatmap (vùng trong bbox gán giá trị 1, làm mịn biên bằng Gaussian 31×31).
- PGA-UNet: Cổng không gian tăng cường đặc trưng vùng câu nhắc tại bộ mã hóa; Cơ chế chú ý có điều kiện điều chỉnh attention gate bằng đặc trưng câu nhắc với trọng số giảm dần tại bộ giải mã.
- Huấn luyện từ đầu với hàm mất mát Dice + BCE; có thực hiện tăng cường ảnh trong quá trình huấn luyện (lật ngang 50%, xoay $\pm 15^\circ$ với xác suất 50%).
- EfficientNet_B3 tinh chỉnh hai giai đoạn (đóng băng backbone rồi mở toàn bộ) cho bài toán phân lớp sàng lọc.

Giai đoạn 4: Thực nghiệm và đánh giá: So sánh định lượng Dice/IoU/Precision/Recall/HD95 với các mô hình baseline; ablation study từng thành phần kiến trúc; đánh giá tính bền bỉ kích bản prompt lệch tâm; đánh giá pipeline toàn hệ thống trên tập hỗn hợp bình thường và bệnh lý.

2.5 Kết quả dự kiến của đề tài

- **Bộ dữ liệu đã xử lý:** Tập ảnh BTXRD sạch nhiễu kỹ thuật, kèm nhãn phân đoạn polygon và bounding box prompt, chia sẵn tập huấn luyện/xác thực/kiểm tra.

- **Mô hình PGA-UNet:** Kiến trúc $\sim 3\text{M}$ tham số, dự kiến đạt Dice $\geq 0,80$ và IoU $\geq 0,70$ trên tập kiểm tra với câu nhắc hợp lệ; thể hiện tính bền bỉ khi câu nhắc bị lệch tâm.
- **Pipeline end-to-end:** EfficientNet_B3 đạt AUC-ROC $\geq 0,92$; đánh giá pipeline toàn hệ thống (Dice, IoU tính trên cả trường hợp âm tính giả) phản ánh sát điều kiện lâm sàng.
- **Báo cáo và mã nguồn:** Báo cáo khóa luận hoàn chỉnh; bộ mã nguồn có chú thích đầy đủ, tái tạo được toàn bộ kết quả thực nghiệm.

2.6 Kế hoạch thực hiện

Giai đoạn	Nội dung	Thời gian
1	Nghiên cứu tài liệu; phân tích bộ dữ liệu BTXRD	Tuần 1–3 (01/2026)
2	Tiền xử lý để loại bỏ nhiễu; tạo nhãn mặt nạ phân đoạn từ các tệp dữ liệu; chia tập dữ liệu	Tuần 4–7 (02/2026)
3	Thiết kế và huấn luyện PGA-UNet; module phân lớp EfficientNet_B3	Tuần 8–14 (03–04/2026)
4	Thực nghiệm so sánh; ablation study; đánh giá tính bền bỉ	Tuần 15–18 (04–05/2026)
5	Đánh giá pipeline end-to-end trên tập hỗn hợp	Tuần 19–21 (05/2026)
6	Viết báo cáo khóa luận; chuẩn bị bảo vệ	Tuần 22–26 (06–07/2026)

TÀI LIỆU THAM KHẢO

- [1] O. Ronneberger, P. Fischer, and T. Brox, “U-Net: Convolutional Networks for Biomedical Image Segmentation,” in *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, Springer, 2015, pp. 234–241.
- [2] O. Oktay et al., “Attention U-Net: Learning Where to Look for the Pancreas,” in *Proc. Medical Imaging with Deep Learning (MIDL)*, 2018. arXiv:1804.03999.
- [3] J. Cheng et al., “SAM-Med2D,” arXiv preprint arXiv:2308.16184, 2023.
- [4] S. Yao et al., “A Radiograph Dataset for the Classification, Localization, and Segmentation of Primary Bone Tumors,” *Scientific Data*, Nature, 2025.

XÁC NHẬN
CỦA NGƯỜI HƯỚNG DẪN

(Ký và ghi rõ họ tên)

TP. Hồ Chí Minh, ngày ... tháng ... năm ...
NHÓM SINH VIÊN THỰC HIỆN

(Ký và ghi rõ họ tên)

MỤC LỤC

Lời cam đoan	i
Lời cảm ơn	ii
Đề cương chi tiết	iii
Mục lục	ix
Danh mục các ký hiệu và chữ viết tắt	xvii
Tóm tắt	xxi
1 GIỚI THIỆU	1
1.1 Bối cảnh chung	1
1.2 Động lực nghiên cứu	2
1.2.1 Động lực khoa học	2
1.2.2 Động lực thực tiễn	3
1.3 Phát biểu bài toán	3
1.4 Thách thức của bài toán	5
1.5 Đóng góp của khóa luận	6
1.6 Bố cục của khóa luận	7
2 CÁC CÔNG TRÌNH LIÊN QUAN VÀ CƠ SỞ LÝ THUYẾT	9
2.1 Các công trình liên quan	9
2.1.1 Các phương pháp phân đoạn ảnh y khoa tự động	9
2.1.2 Phương pháp học máy tương tác trong y khoa	10
2.2 Cơ sở lý thuyết nền tảng	11
2.2.1 Mạng nơ-ron tích chập (CNN)	11

2.2.2	Kiến trúc U-Net	12
2.2.3	Cơ chế chú ý và kiến trúc Attention U-Net	13
2.3	Học máy dựa trên câu nhắc trong thị giác máy tính	15
2.3.1	Biểu diễn không gian của câu nhắc trực quan	15
2.3.2	Cơ chế chú ý có điều kiện	16
2.4	Các độ đo đánh giá hiệu năng	17
2.4.1	Hệ số Dice và chỉ số IoU	17
2.4.2	Độ chính xác (Precision) và Độ bao phủ (Recall)	18
2.4.3	Khoảng cách Hausdorff 95% (HD95)	19
2.4.4	Độ chuẩn xác định vị tâm (CBL)	20
2.5	Tổng kết chương	20
3	MÔ HÌNH VÀ HỆ THỐNG ĐỀ XUẤT	22
3.1	Kiến trúc tổng thể của hệ thống	22
3.2	Tiền xử lý dữ liệu và loại bỏ nhiễu ảnh X-quang	25
3.2.1	Bộ dữ liệu BTXRD	25
3.2.2	Quy trình tiền xử lý và loại bỏ nhiễu	26
3.3	Mô hình phân đoạn PGA-UNet (Prompt-Guided Attention U-Net)	29
3.3.1	Biểu diễn câu nhắc trực quan (Prompt Heatmap Representation)	30
3.3.2	Cổng không gian tại bộ mã hóa (Prompt Spatial Gate - Encoder)	32
3.3.3	Cơ chế chú ý có điều kiện tại bộ giải mã (Conditioned Attention Decoder)	33
3.3.4	Chiến lược huấn luyện và so sánh với mô hình nền tảng SAM-Med2D	35
3.4	Module gác cổng sàng lọc (Gatekeeper)	37
3.5	Tóm tắt giải thuật hệ thống: Huấn luyện và Suy luận	38
3.6	Tổng kết chương	41

4	THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ	42
4.1	Thiết lập môi trường thực nghiệm	42
4.1.1	Tập dữ liệu ảnh X-quang (Dataset)	42
4.1.2	Cấu hình huấn luyện (Hyperparameters, Loss functions)	44
4.1.3	Phương pháp đánh giá image-level	45
4.2	Đánh giá hiệu năng kiến trúc PGA-UNet	46
4.2.1	Đánh giá cơ sở (Baseline Comparison): U-Net vs. PGA-UNet	46
4.2.2	Đánh giá tính bền bỉ (Robustness): Kịch bản Zoom-out, Shift và Mixed	48
4.2.3	So sánh với SAM-Med2D (SOTA Prompt-based)	50
4.2.4	Kiểm chứng công bằng tại cùng độ phân giải 256×256	52
4.2.5	So sánh hiệu quả tính toán	53
4.3	Phân tích kiến trúc và khả năng tổng quát hóa	54
4.3.1	Ablation kiến trúc: Đóng góp của PSG và CAD	54
4.3.2	Kiểm định độ ổn định bằng đánh giá chéo (Cross-validation)	56
4.3.3	Đánh giá theo đặc tính tổn thương (Sub-Category)	57
4.4	Đánh giá khả năng tổng quát hóa liên miền dữ liệu (Cross-dataset: FracAtlas)	61
4.4.1	Giới thiệu bộ dữ liệu FracAtlas	61
4.4.2	PGA-UNet toàn diện trên FracAtlas (256×256 và 512×512 , ba kịch bản prompt)	63
4.4.3	So sánh cơ sở (Baseline): PGA-UNet vs U-Net trên FracAtlas	64
4.4.4	So sánh với SAM-Med2D (Fine-tuned và Zero-shot) trên FracAtlas	65
4.4.5	Đánh giá theo đặc tính tổn thương (Sub-Category) trên FracAtlas	67
4.4.6	Thảo luận: khả năng tổng quát hóa liên miền dữ liệu	70

4.5	Trực quan hóa kết quả (Qualitative Results)	71
4.5.1	Trực quan hóa các kịch bản phân đoạn tiêu biểu . .	72
4.6	Giới hạn kiến trúc và phân tích trường hợp thất bại	72
4.6.1	Trường hợp PGA-UNet dự đoán kém	72
4.7	Đánh giá module Gatekeeper và pipeline end-to-end	73
4.7.1	Đánh giá mô hình phân lớp gác cổng (EfficientNet_B3)	73
4.7.2	Phân tích các ca bỏ sót (False Negative) và thử nghiệm ngưỡng phân loại	76
4.7.3	Phân tích sai số tích lũy (Cascading Error)	78
4.7.4	Đánh giá pipeline end-to-end trên dữ liệu hỗn hợp .	80
4.7.5	Các chỉ số end-to-end bổ sung: Sensitivity bệnh lý, FNR và Lesion-level Recall	81
5	KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	85
5.1	Kết luận những đóng góp đạt được	85
5.2	Hạn chế của hệ thống	86
5.3	Định hướng phát triển tương lai	88
	Tài liệu tham khảo	91

DANH SÁCH HÌNH

2.1	Kiến trúc SAM-Med2D [3]: Bộ mã hóa ảnh ViT-B (tham số đóng băng ●) được chèn thêm các lớp Adapter nhỏ gọn (tham số học được ○) vào sau mỗi khối Transformer. Câu nhắc bounding box đi qua Prompt Encoder để tạo positional embedding; Mask Decoder kết hợp đặc trưng ảnh và embedding câu nhắc để xuất mặt nạ phân đoạn. Toàn bộ mô hình được tinh chỉnh trên SA-Med2D-20M (khoảng 4,6 triệu ảnh y tế 2D đa phương thức).	11
2.2	Kiến trúc mạng U-Net với 4 cấp độ phân giải: nhánh mã hóa (trái) giảm mẫu dần qua Max Pooling; nhánh giải mã (phải) khôi phục độ phân giải qua UpConv; các kết nối tắt nối đặc trưng cùng cấp từ encoder sang decoder để bù thông tin vị trí không gian bị mất.	13
2.3	Kiến trúc Attention U-Net: các Cổng chú ý (Attention Gates) được chèn tại các kết nối tắt, sử dụng tín hiệu gating g từ bộ giải mã để lọc bỏ nhiễu nền trước khi truyền đặc trưng sang tầng giải mã tương ứng.	14
3.1	Pipeline tổng thể hệ thống: ảnh X-quang qua EfficientNet_B3 để sinh gợi ý sàng lọc; bác sĩ xem gợi ý và xác nhận (không bệnh → kết thúc, có bệnh → vẽ bounding box) trước khi hệ thống chuyển sang PGA-UNet phân đoạn có hướng dẫn.	24
3.2	Quy trình tiền xử lý dữ liệu: gán nhãn bounding box nhiều thủ công trên một phần ảnh qua Roboflow, finetune YOLOv11s, detect nhiễu trên toàn bộ tập ảnh PNG, tô màu vùng nhiễu bằng màu nền được chọn.	27

3.3	Kiến trúc PGA-UNet (Prompt-Guided Attention U-Net): Cổng không gian (Prompt Spatial Gate) tích hợp bản đồ nhiệt câu nhắc vào bộ mã hóa để tăng cường đặc trưng có chọn lọc; Cơ chế chú ý có điều kiện (Conditioned Attention) ràng buộc tín hiệu gating bằng câu nhắc tại từng tầng giải mã với hệ số w_l theo từng tầng	35
4.1	So sánh Dice Score giữa U-Net (không prompt), PGA-UNet và SAM-Med2D (fine-tuned, zero-shot) trên ba kịch bản prompt (Zoom-out, Shift, Mixed), tổng hợp trực quan từ Bảng 4.2, 4.3 và 4.4.	52
4.2	Ablation study: Dice Score của 5 biến thể kiến trúc PGA-UNet trên ba kịch bản prompt (Bảng 4.7). V5 (đề xuất, xanh dương) thấp hơn nhẹ ở Zoom-out nhưng vượt trội rõ rệt ở Shift so với bốn biến thể còn lại (xám).	56
4.3	So sánh PGA-UNet và SAM-Med2D theo ba nhóm đặc tính lâm sàng trên BTXRD (Bảng 4.11): khoảng cách lớn nhất ở nhóm Tổn thương nhỏ, thu hẹp dần ở nhóm Tổn thương rõ nét.	60
4.4	PGA-UNet trên FracAtlas: Dice Score tại 256×256 và 512×512 , ba kịch bản prompt (Bảng 4.14).	64
4.5	So sánh U-Net và PGA-UNet theo độ khó tác vụ trên FracAtlas (Bảng 4.17).	68
4.6	So sánh SAM-Med2D (FT), PGA-UNet (256) và PGA-UNet (512) theo ba nhóm đặc tính tổn thương trên FracAtlas (Bảng 4.18).	70
4.7	Trực quan hóa kết quả phân đoạn của PGA-UNet kịch bản Zoom-out: ảnh gốc (trái), mặt nạ Ground Truth (giữa), mặt nạ dự đoán (phải). Đường biên bám sát GT nhờ cơ chế Prompt Spatial Gate và Conditioned Attention.	72

DANH SÁCH BẢNG

3.1	Phân biệt kế thừa và đóng góp trong kiến trúc PGA-UNet	29
3.2	So sánh chiến lược huấn luyện giữa PGA-UNet và SAM-Med2D	37
4.1	Thống kê phân bố bộ dữ liệu thực nghiệm	43
4.2	So sánh hiệu năng phân đoạn: U-Net (tự động, N=187 ảnh) so với PGA-UNet kích bản Zoom-out lý tưởng (prompt-guided, N=187 ảnh, image-level)	47
4.3	Đánh giá tính bền bỉ của PGA-UNet trên 3 kích bản prompt (N=187 ảnh, image-level)	49
4.4	So sánh toàn diện PGA-UNet với SAM-Med2D fine-tuned và SAM-Med2D zero-shot trên 3 kích bản prompt. PGA-UNet: image-level (N=187 ảnh); SAM-Med2D: image-level (N=187 ảnh). HD95* chuẩn hóa theo kích thước ảnh: $PGA \div 512$, $SAM \div 256$	50
4.5	So sánh công bằng PGA-UNet (256×256) vs SAM-Med2D (256×256) trên 3 kích bản prompt. PGA-UNet (256): image-level (N=187 ảnh); SAM-Med2D: image-level (N=187 ảnh).	53
4.6	So sánh hiệu quả tính toán: PGA-UNet vs SAM-Med2D	53
4.7	Ablation study: Dice Score trên 3 kích bản prompt của 5 biến thể kiến trúc PGA-UNet (N=187 ảnh, image-level). V5 là mô hình đề xuất.	54
4.8	Kết quả đánh giá chéo 4-fold PGA-UNet trên 3 kích bản prompt (trung bình 4 fold)	56
4.9	Dice Score từng fold trong đánh giá chéo 4-fold PGA-UNet (kích bản Zoom-out / Shift / Mixed)	57

4.10	So sánh hiệu năng PGA-UNet với U-Net theo độ khó tác vụ (50 ảnh mỗi nhóm, image-level; phân nhóm dễ nhất / khó nhất theo Dice của U-Net)	58
4.11	So sánh PGA-UNet với SAM-Med2D trên ba nhóm đặc tính lâm sàng (kịch bản Zoom-out, 50 ảnh mỗi nhóm, image-level)	59
4.12	So sánh công bằng PGA-UNet ₂₅₆ vs SAM-Med2D theo đặc tính lâm sàng (kịch bản Zoom-out, 50 ảnh image-level mỗi nhóm, cùng 256×256)	60
4.13	Thống kê phân bố bộ dữ liệu FracAtlas dùng trong thực nghiệm (đơn vị: mẫu per-polygon)	62
4.14	PGA-UNet trên FracAtlas: kết quả toàn diện tại 256×256 và 512×512, ba kịch bản prompt (N=72 ảnh, image-level) .	63
4.15	So sánh hiệu năng phân đoạn: U-Net (tự động) so với PGA-UNet (512, Zoom-out) trên FracAtlas (N=72 ảnh, image-level, cùng độ phân giải 512×512)	65
4.16	So sánh toàn diện PGA-UNet (256) với SAM-Med2D fine-tuned và zero-shot trên FracAtlas, ba kịch bản prompt (tất cả cùng image-level, N=72 ảnh, cùng độ phân giải 256×256)	66
4.17	So sánh hiệu năng PGA-UNet với U-Net theo độ khó tác vụ trên FracAtlas (36 ảnh mỗi nhóm, image-level; phân nhóm dễ nhất / khó nhất theo Dice của U-Net, kịch bản Zoom-out)	67
4.18	So sánh SAM-Med2D (FT, 256), PGA-UNet (256) và PGA-UNet (512) theo đặc tính tổn thương trên FracAtlas (kịch bản Zoom-out, 24 ảnh/nhóm, image-level)	69
4.19	Kết quả đánh giá hiệu năng của mô hình phân lớp sàng lọc trên tập kiểm thử	75
4.20	Phân bố xác suất dự đoán (cls_prob) của 21 ảnh FN theo khoảng cách tới ngưỡng 0.5	76
4.21	So sánh diện tích tổn thương (% diện tích ảnh) giữa nhóm FN và nhóm TP	77

4.22	Đánh đổi Sensitivity/Specificity khi dịch chuyển ngưỡng phân loại của Gatekeeper	77
4.23	Kết quả pipeline end-to-end trên tập dataset_online (hỗn hợp bình thường + có bệnh)	82
4.24	Các chỉ số end-to-end bổ sung ở cấp độ tổn thương (lesion-level), tính trên 232 tổn thương của 187 ảnh bệnh lý trong dataset_online	84

DANH MỤC CÁC KÝ HIỆU VÀ CHỮ VIẾT TẮT

Chữ viết tắt	Ý nghĩa
AG	Attention Gate (Cổng chú ý)
ALP	Alkaline Phosphatase (chỉ số xét nghiệm men gan/xương)
AUC-ROC	Area Under the Receiver Operating Characteristic Curve (Diện tích dưới đường cong ROC)
BCE	Binary Cross-Entropy (Entropy chéo nhị phân)
BTXRD	Bone Tumor X-Ray Dataset (bộ dữ liệu X-quang khối u xương)
CAD	Conditioned Attention Decoder (Cơ chế chú ý có điều kiện tại bộ giải mã)
CBL	Center-Based Localization (Độ chuẩn xác định vị tâm)
CNN	Convolutional Neural Network (Mạng nơ-ron tích chập)
COCO	Common Objects in Context (định dạng chú thích/nhân ảnh)
CT	Computed Tomography (Chụp cắt lớp vi tính)
DSC	Dice Similarity Coefficient (Hệ số tương đồng Dice)
FN	False Negative (Âm tính giả)
FP	False Positive (Dương tính giả)
FT	Fine-tuned / Fine-tuning (Tinh chỉnh)
GAP	Global Average Pooling (Gộp trung bình toàn cục)
GPU	Graphics Processing Unit (Bộ xử lý đồ họa)
GT	Ground Truth (Nhãn gốc/Nhãn thực)

Chữ viết tắt	Ý nghĩa
HD / HD95	Hausdorff Distance / Khoảng cách Hausdorff 95%
IoU	Intersection over Union (Chỉ số giao trên hợp)
JSON	JavaScript Object Notation (định dạng dữ liệu)
LDH	Lactate Dehydrogenase (chỉ số xét nghiệm)
LR	Learning Rate (Tốc độ học)
MBConv	Mobile Inverted Bottleneck Convolution
MRI	Magnetic Resonance Imaging (Chụp cộng hưởng từ)
NLP	Natural Language Processing (Xử lý ngôn ngữ tự nhiên)
NPV	Negative Predictive Value (Giá trị dự báo âm tính)
PACS	Picture Archiving and Communication System (Hệ thống lưu trữ và truyền hình ảnh y tế)
PGA-UNet	Prompt-Guided Attention U-Net (mô hình phân đoạn đề xuất của khóa luận)
PNG	Portable Network Graphics (định dạng ảnh)
PPV	Positive Predictive Value (Giá trị dự báo dương tính, đồng nghĩa với Precision)
PSG	Prompt Spatial Gate (Cổng không gian tại bộ mã hóa)
R/L	Right/Left (Ký hiệu chỉ hướng phải/trái trên ảnh X-quang)
ReLU	Rectified Linear Unit (hàm kích hoạt)
ROC	Receiver Operating Characteristic
SAM	Segment Anything Model
SAM-Med2D	Phiên bản SAM tinh chỉnh cho ảnh y tế 2D, mô hình đối sánh chính trong khóa luận
SE	Squeeze-and-Excitation (khối trong kiến trúc EfficientNet)

Chữ viết tắt	Ý nghĩa
SOTA	State-of-the-art (Hiện đại nhất)
TN	True Negative (Âm tính thật)
TP	True Positive (Dương tính thật)
ViT	Vision Transformer
VRAM	Video Random Access Memory (Bộ nhớ đồ họa)
YOLOv11s	You Only Look Once, phiên bản 11, cấu hình nhỏ (mô hình phát hiện đối tượng)
ZS	Zero-shot (không tinh chỉnh trên dữ liệu đích)

TÓM TẮT KHÓA LUẬN

Khóa luận nghiên cứu và phát triển một hệ thống phân đoạn tương tác ảnh X-quang xương dựa trên câu nhắc trực quan (visual prompt), giúp bác sĩ khoanh vùng tổn thương nhanh và chính xác hơn.

Bài toán: Các mô hình phân đoạn tự động (U-Net, Attention U-Net) không tận dụng được tri thức của bác sĩ nên dễ nhận diện sai trên ảnh X-quang có độ tương phản thấp. Ngược lại, các mô hình tương tác nền tảng (SAM, SAM-Med2D) lại quá nặng để triển khai thực tế tại nhiều cơ sở y tế.

Giải pháp: Khóa luận đề xuất **PGA-UNet** (Prompt-Guided Attention U-Net), một kiến trúc CNN hạng nhẹ tích hợp trực tiếp câu nhắc bounding box của bác sĩ vào cả bộ mã hóa (qua Cổng không gian) lẫn bộ giải mã (qua Cơ chế chú ý có điều kiện). Một module gác cổng (EfficientNet_B3) được thêm vào để tự động sàng lọc ảnh trước khi phân đoạn, tạo thành pipeline xử lý đầu cuối hoàn chỉnh.

Kết quả: PGA-UNet đạt $\text{Dice} = 0.8584$ trên tập kiểm thử 187 ảnh, vượt trội U-Net (0.4790) và SAM-Med2D fine-tuned (0.7432) dù nhỏ hơn nhiều lần về số tham số. Mô hình vẫn giữ $\text{Dice} = 0.8454$ ngay cả khi câu nhắc bị lệch tâm, cho thấy tính bền bỉ cao. Module gác cổng đạt $\text{AUC-ROC} = 0.9405$; khi đánh giá cả pipeline trên dữ liệu hỗn hợp mô phỏng điều kiện thực tế, hệ thống vẫn còn sai số tích lũy cần tiếp tục cải thiện (Pipeline Dice end-to-end = 0.6793, tính đủ cả các ca bệnh bị bỏ sót). Toàn bộ hệ thống đã được tích hợp vào một ứng dụng demo minh họa quy trình phân đoạn tương tác trên ảnh X-quang.

Từ khóa: Phân đoạn ảnh y khoa, câu nhắc trực quan, X-quang xương, U-Net, phân đoạn tương tác.

CHƯƠNG 1

GIỚI THIỆU

1.1 Bối cảnh chung

Chẩn đoán hình ảnh thông qua tia X (X-quang) là một trong những phương thức cận lâm sàng phổ biến và quan trọng nhất trong y khoa hiện đại. Nhờ khả năng hiển thị trực tiếp cấu trúc xương mà không cần can thiệp xâm lấn, X-quang được sử dụng rộng rãi để phát hiện và theo dõi các tổn thương về xương như gãy xương, rạn xương, thoái hóa khớp và các khối u xương. Tại các cơ sở y tế lớn, số lượng ca chụp X-quang mỗi ngày lên đến hàng trăm ca. Điển hình, Cambridge University Hospitals (Anh) thực hiện hơn 174.000 ca chụp X-quang mỗi năm, riêng khoa X-quang ngoại trú tiếp nhận từ 200 đến 300 bệnh nhân mỗi ngày [2]. Khối lượng công việc như vậy đặt ra áp lực đáng kể lên đội ngũ bác sĩ chẩn đoán hình ảnh, làm tăng nguy cơ sai sót do mỏi mắt và quá tải.

Trong các hệ thống hỗ trợ chẩn đoán bằng máy tính, bước xác định và khoanh vùng tổn thương hay còn gọi là *phân đoạn ảnh* (image segmentation) đóng vai trò tiền đề quan trọng. Kết quả phân đoạn là cơ sở để đo lường kích thước tổn thương, theo dõi diễn tiến theo thời gian và lập kế hoạch điều trị. Tuy nhiên, việc thực hiện phân đoạn thủ công trên hệ thống PACS (Picture Archiving and Communication System) đòi hỏi nhiều thời gian, phụ thuộc lớn vào kinh nghiệm cá nhân của bác sĩ và tiềm ẩn nguy cơ sai sót do mỏi mắt hoặc áp lực công việc.

Những hạn chế trên đã thúc đẩy cộng đồng nghiên cứu tìm kiếm các giải pháp hỗ trợ chẩn đoán tự động dựa trên học sâu (deep learning). Trong khoảng một thập kỷ qua, các kiến trúc mạng nơ-ron tích chập như U-Net [7] đã đạt được kết quả đáng khích lệ trong bài toán phân đoạn ảnh y khoa. Song song đó, sự ra đời của các mô hình nền tảng như SAM

(Segment Anything Model) đã phổ biến hóa mô hình phân đoạn dựa trên câu nhắc trực quan và thúc đẩy mạnh mẽ hướng nghiên cứu tương tác giữa người và máy. Đây chính là nền tảng khoa học mà khóa luận này kế thừa và phát triển.

1.2 Động lực nghiên cứu

1.2.1 Động lực khoa học

Mặc dù đã đạt nhiều tiến bộ, các phương pháp phân đoạn hoàn toàn tự động vẫn tồn tại một hạn chế cốt lõi: chúng hoạt động như một *hộp đen* (black box), suy luận hoàn toàn tự động trên toàn bộ ảnh mà không có bất kỳ thông tin định hướng nào từ chuyên gia. Trong môi trường ảnh X-quang xương nơi các cấu trúc giải phẫu chồng lấp nhau và vùng tổn thương thường có độ tương phản thấp hoặc đặc điểm hình thái gần giống mô lành lân cận, cách tiếp cận này dễ dẫn đến hiện tượng phân đoạn sai lệch (false positive) hoặc bỏ sót tổn thương (false negative).

Một hướng nghiên cứu đang nhận được sự quan tâm ngày càng lớn là *phân đoạn tương tác* (interactive segmentation), nơi người dùng cung cấp một tín hiệu không gian sơ bộ chẳng hạn như một hộp giới hạn (bounding box) để định hướng mô hình tập trung vào vùng mục tiêu. Hướng tiếp cận này không chỉ cải thiện độ chính xác khi được cung cấp câu nhắc phù hợp mà còn đặt con người vào vị trí kiểm soát trong vòng lặp suy luận (human-in-the-loop), điều có ý nghĩa đặc biệt quan trọng trong ứng dụng y tế.

Tuy nhiên, việc tích hợp tín hiệu định hướng này một cách hiệu quả vào kiến trúc mạng nơ-ron cụ thể là làm thế nào để biểu diễn, mã hóa và truyền tải thông tin câu nhắc qua các tầng mạng vẫn là một hướng nghiên cứu đang được quan tâm, đặc biệt trong các bài toán ảnh y khoa chuyên biệt.

1.2.2 Động lực thực tiễn

Trong thực tế lâm sàng, không thể kỳ vọng mọi thao tác của bác sĩ đều hoàn hảo. Câu nhắc mà bác sĩ cung cấp có thể bị lệch tâm do chú ý không tập trung, hoặc thậm chí đặt sai vị trí hoàn toàn do nhầm lẫn. Một hệ thống phân đoạn đáng tin cậy trong môi trường lâm sàng cần có khả năng *chịu đựng sai sót* (fault tolerance): có khả năng nhận biết khi câu nhắc đầu vào có vấn đề và đưa ra phản hồi phù hợp, thay vì im lặng trả về một kết quả sai lệch.

Ngoài ra, việc tích hợp hệ thống vào quy trình làm việc thực tế còn đặt ra yêu cầu về tốc độ xử lý (real-time inference) và khả năng giải thích quyết định của mô hình (model interpretability). Đây là hai yếu tố thường chưa được cân nhắc đồng thời với yêu cầu độ chính xác.

Hai động lực trên cùng nhau định hình mục tiêu của khóa luận: không chỉ là một mô hình phân đoạn chính xác, mà là một *hệ thống* đủ thông minh, bền bỉ và minh bạch để thực sự hỗ trợ được bác sĩ trong phòng khám.

1.3 Phát biểu bài toán

Người dùng cuối (End User): Bác sĩ chẩn đoán hình ảnh (radiologist) làm việc trong ca đọc phim tại phòng chẩn đoán, sử dụng hệ thống PACS để xem xét và phân tích ảnh X-quang từ nhiều bệnh nhân. Đây là người có chuyên môn lâm sàng nhưng không nhất thiết có kiến thức kỹ thuật về học sâu; thao tác duy nhất họ cần thực hiện là khoanh vùng nghi ngờ trên màn hình.

Bài toán: Cho một ảnh X-quang xương mới $\mathbf{I} \in \mathbb{R}^{H \times W}$ và hộp giới hạn $\mathbf{B} = (x_1, y_1, x_2, y_2)$ do bác sĩ khoanh lên vùng nghi ngờ có tổn thương, hệ thống cần tự động tạo ra mặt nạ phân đoạn $\hat{\mathbf{M}} \in \{0, 1\}^{H \times W}$ xác định chính xác ranh giới của tổn thương trong vùng được chỉ định, đồng thời phải bền vững trước sai lệch thực tế trong cách bác sĩ vẽ hộp (lệch tâm,

khác kích thước). Trong đó, $H \times W$ là chiều cao và chiều rộng ảnh (pixel); (x_1, y_1) và (x_2, y_2) lần lượt là tọa độ góc trên-trái và dưới-phải của hộp giới hạn.

Cụ thể, đầu vào và đầu ra của hệ thống khi hoạt động trực tuyến được định nghĩa như sau:

- **Đầu vào:**

- Ảnh X-quang xương $\mathbf{I} \in \mathbb{R}^{H \times W}$.
- Hộp giới hạn $\mathbf{B} = (x_1, y_1, x_2, y_2)$ do bác sĩ vẽ bao quanh vùng nghi ngờ tổn thương.

- **Đầu ra:** Mặt nạ phân đoạn nhị phân $\hat{\mathbf{M}} \in \{0, 1\}^{H \times W}$, trong đó pixel có giá trị 1 là vùng được dự đoán là tổn thương.

Luồng xử lý của hệ thống gồm hai bước tuần tự. Bước đầu, ảnh X-quang được đưa qua mô hình sàng lọc để đưa ra một **gợi ý** (có bệnh/không bệnh kèm độ tin cậy); bác sĩ xem gợi ý này và chủ động xác nhận kết quả trước khi hệ thống tiếp tục — mô hình không tự động dừng hay tự động chuyển bước mà không có xác nhận của bác sĩ. Nếu bác sĩ xác nhận không có bệnh lý, quy trình kết thúc; nếu xác nhận có bệnh lý (kể cả khi trái với gợi ý của mô hình), bác sĩ tiến hành khoanh hộp và bước phân đoạn có hướng dẫn được kích hoạt:

$$\hat{\mathbf{M}} = \mathbf{1}[f_{\text{seg}}(\mathbf{I}, \mathbf{H}(\mathbf{B}); \boldsymbol{\theta}_{\text{seg}}) \geq 0.5] \quad (1.1)$$

trong đó các ký hiệu được định nghĩa như sau:

- $\hat{\mathbf{M}} \in \{0, 1\}^{H \times W}$: mặt nạ phân đoạn nhị phân đầu ra (1 = tổn thương, 0 = nên).
- $\mathbf{1}[\cdot]$: hàm chỉ thị (indicator function), trả về 1 nếu điều kiện bên trong đúng và 0 nếu sai; ở đây dùng để nhị phân hóa xác suất đầu ra theo ngưỡng 0.5.

- $f_{\text{seg}}(\cdot; \theta_{\text{seg}})$: mô hình phân đoạn PGA-UNet, xuất xác suất thuộc tổn thương $\in [0, 1]$ cho từng pixel.
- $\mathbf{I} \in \mathbb{R}^{H \times W}$: ảnh X-quang đầu vào.
- $\mathbf{H}(\mathbf{B}) \in [0, 1]^{H \times W}$: bản đồ nhiệt câu nhắc được tạo từ hộp giới hạn $\mathbf{B} = (x_1, y_1, x_2, y_2)$ do bác sĩ vẽ (chi tiết tại Mục 2.3.1).
- θ_{seg} : tập tham số học được của PGA-UNet, tối ưu hóa trong giai đoạn huấn luyện ngoại tuyến.
- 0.5: ngưỡng nhị phân hóa, pixel được dự đoán là tổn thương khi xác suất đạt từ 0.5 trở lên.

Thiết kế này phản ánh triết lý *human-in-the-loop* xuyên suốt cả hai bước: ở bước sàng lọc, mô hình chỉ đề xuất gợi ý còn bác sĩ mới là người xác nhận quyết định (thiết kế *triage mềm*, không phải bộ chặn tự động loại bỏ ảnh mà không cho phép can thiệp); ở bước phân đoạn, bác sĩ trực tiếp cung cấp định hướng không gian qua bounding box. Nhờ vậy tri thức lâm sàng của chuyên gia luôn tham gia vào toàn bộ vòng lặp quyết định, không chỉ riêng bước phân đoạn. Chi tiết về kiến trúc và quy trình huấn luyện ngoại tuyến (offline) của hai mô hình được trình bày tại Chương 3.

1.4 Thách thức của bài toán

Việc xây dựng hệ thống như đã phát biểu ở trên đối mặt với bốn nhóm thách thức chính:

Thách thức về dữ liệu: Tập dữ liệu X-quang xương trong thực tế thường không sạch, chứa các nguồn nhiễu kỹ thuật như ký hiệu chữ R/L, các dòng văn bản thông tin bệnh nhân, thiết bị cố định xương khác nhau đều có thể ảnh hưởng tiêu cực đến quá trình học nếu không được xử lý cẩn thận. Đây là thách thức mang tính kỹ thuật phòng thí nghiệm nhưng có ảnh hưởng đáng kể đến chất lượng của toàn bộ hệ thống.

Thách thức về mô hình hóa: Ảnh X-quang xương có độ tương phản thấp và chứa nhiều cấu trúc giải phẫu chồng lấp. Vùng tổn thương thường có độ tương phản thấp hoặc đặc điểm hình thái gần giống mô xương lành lân cận, gây khó khăn cho việc trích xuất đặc trưng phân biệt. Thách thức đặt ra là làm thế nào để tích hợp thông tin câu nhắc vào kiến trúc mạng một cách hiệu quả, sao cho mô hình thực sự *sử dụng* câu nhắc để định hướng phân đoạn chứ không đơn thuần bỏ qua nó.

Thách thức về tính bền bỉ: Trong thực tế, câu nhắc của bác sĩ có thể tồn tại sai lệch, hộp giới hạn có thể bị lệch tâm do chú ý không tập trung hoặc góc nhìn chủ quan. Hệ thống cần duy trì hiệu năng phân đoạn ổn định ngay cả khi câu nhắc bị lệch một lượng đáng kể, chứ không bị phụ thuộc cứng nhắc vào vị trí tâm câu nhắc.

Thách thức về khả năng triển khai: Một hệ thống cần có thời gian phản hồi đủ nhanh trong điều kiện phần cứng thực tế để thuận tiện cho quy trình lâm sàng. Điều này đặt ra yêu cầu về hiệu quả tính toán: đạt độ chính xác phân đoạn cao với số lượng tham số tối thiểu.

1.5 Đóng góp của khóa luận

Khóa luận có hai đóng góp chính:

1. **Đề xuất biểu diễn câu nhắc dạng heatmap và kiến trúc PGA-UNet điều kiện hóa bởi câu nhắc:** Đóng góp trọng tâm của khóa luận là phương pháp **mã hóa hộp giới hạn thành Gaussian Plateau Heatmap**: một kênh 2D liên tục đồng kích thước với bản đồ đặc trưng, cung cấp tín hiệu định hướng với gradient liên tục thay vì vector rời rạc (như SAM/SAM-Med2D) hay mặt nạ nhị phân. Biểu diễn này tương thích về cấu trúc với phép tích chập CNN, cho phép tín hiệu câu nhắc lan truyền qua toàn bộ các tầng mạng. Kiến trúc PGA-UNet (~ 3 triệu tham số) hiện thực hóa đóng góp này trên nền U-Net thông qua hai thành phần kiến trúc:

- *Cổng không gian tại bộ mã hóa (PSG)*: Thành phần mới hoàn toàn, tích hợp bản đồ heatmap vào từng tầng encoder theo cơ chế khuếch đại có chọn lọc (selective enhancement), tăng cường đặc trưng trong vùng câu nhắc mà không triệt tiêu thông tin ngoài vùng.
- *Cơ chế chú ý có điều kiện tại bộ giải mã (CAD)*: Kế thừa Cổng chú ý (Attention Gate) từ Attention U-Net và mở rộng bằng cách đưa heatmap câu nhắc trực tiếp vào tín hiệu gating g , thay vì chỉ dựa vào đặc trưng ảnh như thiết kế gốc.

Ablation study xác nhận: Gaussian Heatmap so với Binary prompt cải thiện Dice Shift +0.10 (V5 vs V4); kiến trúc PSG+CAD kết hợp Gaussian tạo hiệu ứng tương hỗ, cải thiện Dice Shift +0.12 so với chỉ concatenate heatmap đơn giản (V5 vs V1); chi tiết tại Bảng 4.7, Chương 4. Toàn hệ thống được đánh giá so sánh với U-Net và SAM-Med2D trên bộ dữ liệu BTXRD.

2. **Đánh giá thực nghiệm toàn pipeline**: Xây dựng kịch bản đánh giá end-to-end kết hợp module phân lớp (EfficientNet_B3) và PGA-UNet, mô phỏng luồng xử lý thực tế trên tập dữ liệu hỗn hợp gồm cả ảnh bình thường và ảnh bệnh lý, phản ánh điều kiện triển khai lâm sàng sát thực hơn so với đánh giá phân đoạn đơn lẻ.

1.6 Bố cục của khóa luận

Khóa luận được tổ chức thành năm chương với nội dung như sau:

Chương 1: Giới thiệu trình bày bối cảnh chung, động lực khoa học và thực tiễn, phát biểu bài toán từ góc nhìn người dùng cuối (bác sĩ chẩn đoán hình ảnh) với đầu vào/đầu ra tại giai đoạn suy luận trực tuyến, các thách thức cốt lõi và đóng góp của khóa luận.

Chương 2: Các công trình liên quan và cơ sở lý thuyết khảo sát các phương pháp phân đoạn ảnh y khoa tự động và tương tác, xác định

khoảng trống nghiên cứu, và trình bày nền tảng lý thuyết gồm kiến trúc U-Net, cơ chế chú ý, biểu diễn câu nhắc và các độ đo đánh giá.

Chương 3: Mô hình và hệ thống đề xuất trình bày chi tiết kỹ thuật kiến trúc PGA-UNet (Cổng không gian, Cơ chế chú ý có điều kiện), quy trình tiền xử lý dữ liệu và module phân lớp sàng lọc.

Chương 4: Thực nghiệm và đánh giá kết quả mô tả thiết lập thực nghiệm, phân tích kết quả so sánh với U-Net và SAM-Med2D, đánh giá tính bền bỉ câu nhắc, ablation study kiến trúc, kiểm định chéo (cross-validation) và phân tích theo đặc tính tổn thương (sub-category) trên BTXRD; đồng thời trình bày một thực nghiệm bổ sung kiểm tra khả năng tổng quát hóa của kiến trúc trên bộ dữ liệu độc lập thứ hai (FracAtlas), cùng đánh giá module gác cổng và pipeline end-to-end.

Chương 5: Kết luận và hướng phát triển tóm tắt kết quả đạt được, nhìn nhận khách quan các hạn chế và đề xuất hướng nghiên cứu tiếp theo.

CHƯƠNG 2

CÁC CÔNG TRÌNH LIÊN QUAN VÀ CƠ SỞ LÝ THUYẾT

Chương này được tổ chức thành hai phần chính. Phần đầu (Mục 2.1) khảo sát các công trình liên quan để đặt khóa luận trong bức tranh nghiên cứu hiện tại và làm rõ khoảng trống mà đề tài hướng đến giải quyết. Phần sau (Mục 2.2 đến Mục 2.4) trình bày các kiến thức lý thuyết nền tảng cần thiết để hiểu kiến trúc và cơ chế hoạt động của hệ thống đề xuất ở Chương 3.

2.1 Các công trình liên quan

2.1.1 Các phương pháp phân đoạn ảnh y khoa tự động

Trong lĩnh vực phân tích hình ảnh y khoa, kiến trúc U-Net [7] do Ronneberger và cộng sự đề xuất năm 2015 được xem là nền tảng cốt lõi cho nhiều nghiên cứu về sau. Với thiết kế mã hóa - giải mã (encoder-decoder) đối xứng, kết hợp cùng các kết nối tắt (skip connections), U-Net cho phép trích xuất đặc trưng ngữ nghĩa ở nhiều cấp độ đồng thời bảo toàn được thông tin vị trí không gian. Đặc tính này giúp mô hình đạt hiệu năng khả quan ngay cả khi huấn luyện trên các tập dữ liệu y khoa có quy mô nhỏ và thiếu hụt nhãn.

Nhằm tăng cường khả năng tập trung vào các vùng đặc trưng quan trọng và giảm ảnh hưởng của nhiễu nền, Oktay và cộng sự (2018) đã đề xuất mạng Attention U-Net [6]. Bằng cách tích hợp các Cổng chú ý (Attention Gates) tại các kết nối tắt, mô hình có khả năng tự động học cách làm nổi bật các khu vực chứa đặc trưng quan trọng và ức chế các vùng nhiễu nền trước khi đưa dữ liệu vào bộ giải mã.

Tuy nhiên, dưới góc độ triển khai thực tế trên ảnh X-quang xương, cả U-Net và Attention U-Net đều gặp phải một giới hạn chung về phương pháp luận: chúng hoạt động theo cơ chế phân đoạn hoàn toàn tự động. Mô hình chỉ nhận đầu vào duy nhất là ảnh thô và phải tự tìm kiếm vùng tổn thương mà không có bất kỳ thông tin định hướng hay tri thức lâm sàng nào từ bác sĩ. Đối với các ảnh X-quang có độ tương phản thấp và chứa các cấu trúc giải phẫu xương chồng lấp, cách tiếp cận này có thể gặp khó khăn hơn trong việc xác định chính xác vùng tổn thương, đặc biệt khi tồn tại các vùng mô lành có đặc trưng hình thái tương tự.


2.1.2 Phương pháp học máy tương tác trong y khoa

Để vượt qua một số hạn chế của các phương pháp tự động, xu hướng nghiên cứu gần đây đang quan tâm hơn đến phân đoạn có tương tác (interactive segmentation), cho phép bác sĩ cung cấp tín hiệu định hướng (hộp giới hạn, điểm bấm) để mô hình tập trung vào đúng vùng cần phân tích.

Đại diện tiêu biểu trong lĩnh vực y khoa là **SAM-Med2D** [3] (Cheng và cộng sự, 2023), mô hình được chọn làm đối sánh trực tiếp trong khóa luận. SAM-Med2D kế thừa kiến trúc Segment Anything Model (SAM) với bộ mã hóa ảnh Vision Transformer (ViT-B, ~ 91 triệu tham số), tinh chỉnh trên khoảng 4,6 triệu ảnh y khoa 2D đa phương thức bằng chiến lược chèn lớp Adapter, giữ nguyên phần lớn trọng số nền tảng, chỉ cập nhật thêm tầng Adapter và bộ giải mã. Mô hình nhận hộp giới hạn làm câu nhắc vị trí qua Prompt Encoder và xuất ra mặt nạ phân đoạn. Sơ đồ kiến trúc SAM-Med2D được minh họa tại Hình 2.1.

Tuy nhiên, SAM-Med2D vẫn tồn tại giới hạn về khả năng triển khai: bộ mã hóa ViT-B ~ 91 M tham số đòi hỏi VRAM cao hơn đáng kể so với kiến trúc CNN hạng nhẹ, và độ phân giải đầu vào cố định ở 256×256 do position embedding không thể thay đổi, giới hạn khả năng phân đoạn chi tiết trên ảnh X-quang xương vốn cần độ phân giải cao.

Khoảng trống nghiên cứu: Từ khảo sát trên, khoảng trống nghiên cứu hiện rõ: một mặt, U-Net và Attention U-Net thiếu hoàn toàn cơ chế



Hình 2.1: Kiến trúc SAM-Med2D [3]: Bộ mã hóa ảnh ViT-B (tham số đóng băng ●) được chèn thêm các lớp Adapter nhỏ gọn (tham số học được ●) vào sau mỗi khối Transformer. Câu nhắc bounding box đi qua Prompt Encoder để tạo positional embedding; Mask Decoder kết hợp đặc trưng ảnh và embedding câu nhắc để xuất mặt nạ phân đoạn. Toàn bộ mô hình được tinh chỉnh trên SA-Med2D-20M (khoảng 4,6 triệu ảnh y tế 2D đa phương thức).

tiếp nhận định hướng từ bác sĩ; mặt khác, SAM-Med2D tuy có câu nhắc nhưng kiến trúc ViT-B nặng tài nguyên và bị giới hạn độ phân giải. Khóa luận này lấp đầy khoảng trống đó bằng cách tích hợp câu nhắc trực quan trực tiếp vào kiến trúc CNN hạng nhẹ chuyên biệt cho ảnh X-quang 2D, cho phép huấn luyện hoàn toàn từ đầu trên domain đặc thù với chi phí tính toán thấp hơn đáng kể.

2.2 Cơ sở lý thuyết nền tảng

2.2.1 Mạng nơ-ron tích chập (CNN)

Mạng nơ-ron tích chập (Convolutional Neural Network - CNN) là nền tảng cốt lõi của hầu hết các mô hình học sâu hiện đại trong lĩnh vực thị giác máy tính. Khác với mạng nơ-ron kết nối đầy đủ truyền thống, vốn dễ dẫn đến bùng nổ số lượng tham số khi áp dụng cho dữ liệu ảnh, CNN sử dụng cơ chế chia sẻ trọng số và kết nối cục bộ thông qua các phép toán tích chập. Đặc tính này giúp mô hình trích xuất hiệu quả các đặc trưng

không gian (như cạnh, góc và họa tiết), đồng thời tăng mức độ bền vững đối với các dịch chuyển nhỏ của đối tượng trong ảnh.

Tại một tầng tích chập thứ l , đầu vào là bản đồ đặc trưng $\mathbf{F}^l \in \mathbb{R}^{H \times W \times C_{in}}$ sẽ được nhân chập với một tập hợp các bộ lọc $\mathbf{W} \in \mathbb{R}^{k \times k \times C_{in} \times C_{out}}$. Đầu ra của một điểm ảnh trên bản đồ đặc trưng tiếp theo được tính theo công thức tích chập rời rạc:

$$\mathbf{F}_{i,j,c}^{l+1} = \sigma \left(\sum_m \sum_n \sum_{c'} \mathbf{W}_{m,n,c',c} \cdot \mathbf{F}_{i+m,j+n,c'}^l + b_c \right) \quad (2.1)$$

trong đó k là kích thước không gian của bộ lọc, σ là hàm kích hoạt phi tuyến (thường sử dụng ReLU nhằm tăng khả năng biểu diễn phi tuyến của mô hình và góp phần giảm hiện tượng mất dần gradient trong quá trình huấn luyện), và b_c là hệ số chệch (bias). Xen kẽ với các tầng tích chập là các tầng gộp, phổ biến nhất là Max Pooling, có nhiệm vụ giảm kích thước không gian để mở rộng trường tiếp nhận (receptive field) của các bộ lọc sâu hơn.

2.2.2 Kiến trúc U-Net


Được thiết kế chuyên biệt cho các bài toán phân đoạn ảnh y khoa, U-Net [7] sở hữu kiến trúc đối xứng hình chữ "U" đặc trưng, bao gồm hai nhánh chính:

Bộ mã hóa (Encoder): Là nhánh thu nhỏ không gian ở phía bên trái. Thông qua chuỗi các phép tích chập và gộp cực đại (Max Pooling), nhánh này làm nhiệm vụ nén thông tin ảnh, trích xuất biểu diễn ngữ nghĩa từ các chi tiết cục bộ ở tầng nông thành các đặc trưng toàn cục ở tầng sâu. Quá trình này giúp mô hình học được các đặc trưng ngữ nghĩa ở mức độ ngày càng trừu tượng hơn, nhưng đồng thời làm suy giảm một phần thông tin vị trí và chi tiết không gian do quá trình giảm mẫu liên tiếp.

Bộ giải mã (Decoder): Là nhánh khôi phục không gian ở phía bên phải. Nhánh này sử dụng các phép tăng mẫu để khôi phục dần độ phân

giải của bản đồ đặc trưng về lại kích thước ban đầu của ảnh đầu vào. Trong bài toán phân đoạn nhị phân, tầng cuối cùng thường sử dụng hàm kích hoạt Sigmoid để xuất ra bản đồ xác suất theo từng điểm ảnh; đối với phân đoạn đa lớp, hàm Softmax thường được sử dụng thay thế.

Kết nối tắt (Skip connections): Đây là yếu tố đột phá làm nên thành công của U-Net. Các kết nối tắt sao chép trực tiếp các bản đồ đặc trưng độ phân giải cao từ bộ mã hóa và nối kênh (concatenate) chúng vào các bản đồ đặc trưng tương ứng tại bộ giải mã. Cơ chế này bù đắp phần thông tin không gian bị mất trong quá trình giảm mẫu, giúp mô hình tái tạo chính xác đường biên giải phẫu của tổn thương. Kiến trúc tổng thể được minh họa tại Hình 2.2.



Hình 2.2: Kiến trúc mạng U-Net với 4 cấp độ phân giải: nhánh mã hóa (trái) giảm mẫu dần qua Max Pooling; nhánh giải mã (phải) khôi phục độ phân giải qua UpConv; các kết nối tắt nối đặc trưng cùng cấp từ encoder sang decoder để bù thông tin vị trí không gian bị mất.

2.2.3 Cơ chế chú ý và kiến trúc Attention U-Net

Mặc dù các kết nối tắt trong U-Net mang lại hiệu quả cao trong việc bảo toàn thông tin không gian, chúng cũng có thể truyền sang bộ giải mã các đặc trưng ít liên quan hoặc nhiễu nền từ bộ mã hóa. Để giảm ảnh hưởng của các đặc trưng không liên quan, cơ chế chú ý (Attention Mechanism) được áp dụng nhằm tăng cường các vùng ảnh mang thông tin hữu ích và làm giảm trọng số của các vùng ít quan trọng đối với nhiệm vụ phân đoạn.

Kiến trúc Attention U-Net [6] cụ thể hóa cơ chế này bằng cách chèn các **Cổng chú ý (Attention Gates - AG)** vào ngay vị trí của các kết nối tắt. Cổng chú ý nhận hai luồng tín hiệu: bản đồ đặc trưng từ tầng mã


hóa $\mathbf{x}^l$ và tín hiệu hướng dẫn $\mathbf{g}$ (gating signal) lấy từ tầng sâu hơn của bộ giải mã (nơi chứa thông tin ngữ nghĩa mạnh).

Hệ số chú ý không gian $\alpha^l \in [0, 1]^{H \times W}$ được tính toán như sau:

$$\alpha^l = \sigma_2 (\mathbf{W}_\psi^\top \cdot \sigma_1 (\mathbf{W}_x \mathbf{x}^l + \mathbf{W}_g \mathbf{g} + \mathbf{b}_g) + b_\psi) \quad (2.2)$$

trong đó σ_1 là hàm kích hoạt ReLU, σ_2 là hàm Sigmoid, và $\{\mathbf{W}_x, \mathbf{W}_g, \mathbf{W}_\psi, \mathbf{b}_g, b_\psi\}$ là các tham số học được của Cổng chú ý. Bản đồ đặc trưng sau đó được nhân vô hướng với hệ số chú ý để làm nổi bật các khu vực cần thiết: $\hat{\mathbf{x}}^l = \alpha^l \odot \mathbf{x}^l$.

Nhận xét: Cơ chế Attention Gate giúp bộ giải mã tập trung tốt hơn vào vùng tổn thương. Tuy nhiên, tín hiệu hướng dẫn $\mathbf{g}$ trong mạng Attention U-Net vẫn được trích xuất hoàn toàn từ ảnh đầu vào. Nghĩa là, việc xác định vùng quan tâm vẫn được thực hiện hoàn toàn dựa trên các đặc trưng học được từ ảnh đầu vào, mà chưa có sự hỗ trợ trực tiếp từ thông tin định hướng do người dùng cung cấp. Điều này đòi hỏi một cơ chế điều kiện hóa mạnh mẽ hơn từ tri thức chuyên gia (người dùng), tạo tiền đề cho việc phát triển kiến trúc chú ý có điều kiện dựa trên câu nhắc (Conditioned Attention) sẽ được trình bày ở Chương 3. Kiến trúc Attention U-Net được minh họa tại Hình 2.3.



Lưu ý: Mô hình này không có prompt — phân biệt với PGA-UNet (Số đồ 3).

Hình 2.3: Kiến trúc Attention U-Net: các Cổng chú ý (Attention Gates) được chèn tại các kết nối tắt, sử dụng tín hiệu gating $\mathbf{g}$ từ bộ giải mã để lọc bỏ nhiễu nền trước khi truyền đặc trưng sang tầng giải mã tương ứng.

2.3 Học máy dựa trên câu nhắc trong thị giác máy tính

Trong những năm gần đây, khái niệm "câu nhắc" (prompt), vốn được phổ biến rộng rãi trong lĩnh vực Xử lý ngôn ngữ tự nhiên (NLP), đã dần được mở rộng và ứng dụng vào nhiều bài toán Thị giác máy tính. Thay vì huấn luyện một mô hình tĩnh để tự động giải quyết một tác vụ cố định, học máy dựa trên câu nhắc cho phép mô hình linh hoạt điều chỉnh hành vi dự đoán dựa trên thông tin định hướng bổ sung (như văn bản, điểm ảnh, hoặc hộp giới hạn) do người dùng cung cấp ở pha suy luận.

2.3.1 Biểu diễn không gian của câu nhắc trực quan

Trong các phần mềm chẩn đoán hình ảnh, thao tác tương tác tự nhiên nhất của chuyên gia y tế là kéo chuột để tạo một hộp giới hạn (Bounding Box) bao quanh vùng tổn thương nghi ngờ. Giả sử hộp giới hạn này được định nghĩa bởi tọa độ hai góc đối diện $\mathbf{B} = (x_1, y_1, x_2, y_2)$. Thách thức đặt ra là làm thế nào để mã hóa tọa độ hình học này thành một định dạng mà mạng CNN có thể xử lý đồng thời với ảnh đầu vào.

Một cách tiếp cận phổ biến là chuyển đổi hộp giới hạn thành một **Bản đồ nhiệt câu nhắc** (Prompt Heatmap) $\mathbf{H} \in [0, 1]^{H \times W}$, mang cùng độ phân giải không gian với ảnh X-quang. Thay vì tạo ra một mặt nạ nhị phân cứng nhắc (chỉ chứa giá trị 1 bên trong và 0 bên ngoài hộp), bản đồ nhiệt sử dụng hàm phân phối chuẩn hai chiều (2D Gaussian) để biểu diễn mức độ tin cậy về mặt không gian.

Tâm hình học của hộp giới hạn được xác định là (μ_x, μ_y) với $\mu_x = \frac{x_1+x_2}{2}$ và $\mu_y = \frac{y_1+y_2}{2}$. Phân phối không gian của bản đồ nhiệt được tính theo phương trình:

$$H(x, y) = \exp \left(-\frac{(x - \mu_x)^2}{2\sigma_x^2} - \frac{(y - \mu_y)^2}{2\sigma_y^2} \right) \quad (2.3)$$

trong đó, σ_x và σ_y là độ lệch chuẩn kiểm soát độ rộng của hàm Gaussian theo trục x và y . Thông thường, các giá trị này được cấu hình tỉ lệ thuận với kích thước chiều rộng và chiều cao của hộp giới hạn (ví dụ: $\sigma_x = \frac{x_2 - x_1}{4}$ và $\sigma_y = \frac{y_2 - y_1}{4}$).

Cách biểu diễn không gian này mang ý nghĩa lâm sàng sâu sắc: giá trị $H(x, y)$ đạt cực đại (1.0) tại tâm của vùng bác sĩ khoanh (nơi có độ chắc chắn cao nhất về sự tồn tại của u), và giảm dần (decay) một cách mềm mại (smooth) về phía các cạnh. Điều này giúp mô hình không bị “ép buộc” học các đường biên sắc nét giả tạo từ nét khoanh tay của con người, mà coi đó như một nguồn thông tin định hướng không gian hỗ trợ quá trình học và suy luận của mô hình.

Biến thể triển khai – Plateau Heatmap: Trong thực tế, một biến thể phổ biến là *Plateau Heatmap*: gán đồng nhất giá trị 1.0 cho toàn bộ vùng bên trong hộp giới hạn (tạo vùng cao nguyên phẳng), sau đó làm mềm đường biên bằng bộ lọc Gaussian. Cách này duy trì tín hiệu mạnh và đồng đều bên trong vùng câu nhắc (thay vì suy giảm về phía tâm), phù hợp hơn khi kích thước câu nhắc sát với kích thước tổn thương. Thiết kế trong khóa luận này sử dụng biến thể Plateau Heatmap (trình bày ở Mục 3.3), trong khi phương trình Gaussian (2.3) đóng vai trò nền tảng lý thuyết cho cả hai biến thể.

2.3.2 Cơ chế chú ý có điều kiện

Sau khi đã có bản đồ nhiệt câu nhắc $\mathbf{H}$, bài toán tiếp theo là làm sao để "tiêm" (inject) thông tin này vào kiến trúc mạng U-Net. Cách đơn giản nhất là ghép nối kênh (channel concatenation) trực tiếp $\mathbf{H}$ với ảnh X-quang gốc ở ngay tầng đầu vào (Early Fusion). Tuy nhiên, trong nhiều trường hợp, tín hiệu định hướng được ghép tại tầng đầu vào có thể suy giảm ảnh hưởng khi lan truyền qua nhiều tầng tích chập sâu, khiến mô hình chưa khai thác hiệu quả thông tin câu nhắc.

Một hướng tiếp cận khác là sử dụng **Cơ chế chú ý có điều kiện (Conditioned Attention)** nhằm tích hợp thông tin câu nhắc trực tiếp

vào quá trình tính toán trọng số chú ý. Ý tưởng cốt lõi của cơ chế này là mở rộng Cổng chú ý (Attention Gate) truyền thống (đã trình bày ở Mục 2.2.3). Trong Attention U-Net truyền thống, hệ số chú ý α được sinh ra chỉ từ nội bộ các đặc trưng ảnh. Ngược lại, trong cơ chế có điều kiện, việc tính toán hệ số chú ý được ràng buộc (conditioned) rõ ràng bởi ma trận định hướng $\mathbf{H}$.

Về mặt khái niệm, bản đồ chú ý lúc này được biểu diễn dưới dạng xác suất có điều kiện: $\alpha = f(\mathbf{x}, \mathbf{g} \mid \mathbf{H})$. Nhờ đó, tại mỗi tầng của bộ giải mã, quá trình tính toán trọng số chú ý được định hướng bởi cả đặc trưng ảnh và thông tin không gian do người dùng cung cấp. Các tín hiệu đặc trưng nằm ngoài vùng được câu nhắc ưu tiên có xu hướng nhận trọng số chú ý thấp hơn, từ đó góp phần giảm hiện tượng mô hình phân đoạn sang các vùng mô lành không mong muốn. Cơ sở lý thuyết này chính là nền tảng để thiết kế kiến trúc PGA-UNet trong Chương 3 của khóa luận.

2.4 Các độ đo đánh giá hiệu năng

Trong bài toán phân đoạn ảnh y khoa, việc chỉ sử dụng một độ đo duy nhất thường không phản ánh được bức tranh toàn cảnh về chất lượng của mô hình. Một mô hình có thể có tỷ lệ chồng lấp diện tích tốt nhưng vẫn tồn tại sai lệch đáng kể ở đường biên, hoặc ngược lại. Do đó, khóa luận sử dụng một bộ độ đo toàn diện bao gồm các khía cạnh: diện tích vùng (Dice, IoU), xu hướng phân loại (Precision, Recall), chất lượng đường biên (HD95) và độ chuẩn xác vị trí tâm (CBL).

2.4.1 Hệ số Dice và chỉ số IoU

Hệ số Dice (Dice Similarity Coefficient - DSC) và chỉ số Giao trên Hợp (Intersection over Union - IoU, hay Jaccard Index) là hai thang đo tiêu chuẩn phổ biến nhất để đánh giá mức độ chồng lấp không gian giữa mặt nạ dự đoán $\hat{Y}$ và mặt nạ nhãn gốc Y .

Hệ số Dice: Đo lường gấp đôi diện tích phần giao nhau chia cho tổng diện tích của cả hai mặt nạ.

$$\text{Dice}(Y, \hat{Y}) = \frac{2|Y \cap \hat{Y}|}{|Y| + |\hat{Y}|} \quad (2.4)$$

Chỉ số IoU: Đo lường diện tích phần giao nhau chia cho diện tích phần hợp của hai mặt nạ.

$$\text{IoU}(Y, \hat{Y}) = \frac{|Y \cap \hat{Y}|}{|Y \cup \hat{Y}|} \quad (2.5)$$

Cả hai độ đo đều nhận giá trị trong khoảng $[0, 1]$, trong đó 1 thể hiện sự trùng khớp hoàn hảo. Trong bối cảnh ảnh y khoa, nơi vùng tổn thương (foreground) thường chiếm tỷ lệ nhỏ so với vùng nền (background), Dice và IoU thường được ưu tiên sử dụng hơn độ chính xác tổng thể (Accuracy), do chúng phản ánh trực tiếp mức độ chồng lấp của vùng quan tâm và ít bị ảnh hưởng bởi sự mất cân bằng giữa nền và đối tượng.

2.4.2 Độ chính xác (Precision) và Độ bao phủ (Recall)

Bên cạnh Dice và IoU, Độ chính xác (Precision) và Độ bao phủ (Recall, hay Sensitivity) cung cấp góc nhìn chi tiết hơn về xu hướng dự đoán sai của mô hình (thiên về cắt lấn nhầm hay bỏ sót u). Gọi TP là True Positive (dự đoán đúng tổn thương), FP là False Positive (dự đoán nhầm nền thành tổn thương), và FN là False Negative (bỏ sót tổn thương thực sự).

Độ chính xác (Precision): Đo lường tỷ lệ điểm ảnh là tổn thương thực sự trên tổng số điểm ảnh mà mô hình đã khoanh vùng.

$$\text{Precision} = \frac{TP}{TP + FP} \quad (2.6)$$

Độ bao phủ (Recall): Đo lường tỷ lệ điểm ảnh tổn thương thực sự

đã được mô hình nhận diện thành công.

$$\text{Recall} = \frac{TP}{TP + FN} \quad (2.7)$$

Trong thực tế lâm sàng, sự cân bằng giữa Precision và Recall rất quan trọng. Nếu mô hình có xu hướng phân đoạn quá rộng và bao gồm nhiều vùng mô lành, Recall thường tăng trong khi Precision giảm. Ngược lại, nếu mô hình phân đoạn quá bảo thủ và bỏ sót một phần vùng tổn thương, Precision có thể tăng nhưng Recall sẽ giảm.

2.4.3 Khoảng cách Hausdorff 95% (HD95)

Các thang đo dựa trên diện tích (Dice, IoU) có một điểm yếu cơ bản: chúng không nhạy cảm với hình dáng của đường biên. Một mặt nạ dự đoán có thể đạt mức độ chồng lấp diện tích với nhãn nhưng vẫn khác biệt đáng kể về hình dạng và vị trí của đường biên. Khoảng cách Hausdorff (Hausdorff Distance - HD) giải quyết vấn đề này bằng cách đánh giá mức độ sai lệch lớn nhất giữa hai đường biên.

Cho X và Y lần lượt là tập hợp các điểm ảnh nằm trên đường biên của mặt nạ dự đoán và mặt nạ gốc. Khoảng cách Hausdorff hai chiều cực đại được định nghĩa là:

$$\text{HD}(X, Y) = \max \left(\sup_{x \in X} \inf_{y \in Y} d(x, y), \sup_{y \in Y} \inf_{x \in X} d(x, y) \right) \quad (2.8)$$

trong đó $d(x, y)$ là khoảng cách Euclidean giữa hai điểm x và y .

Do công thức HD cơ bản sử dụng hàm cực đại (max và sup), nó cực kỳ nhạy cảm với các điểm nhiễu ngoại lai (outliers) trên đường biên. Vì vậy, khóa luận sử dụng **Khoảng cách Hausdorff 95% (HD95)**. Thang đo HD95 được tính bằng cách sắp xếp các khoảng cách biên theo thứ tự tăng dần và lấy giá trị tại phân vị thứ 95, qua đó làm giảm ảnh hưởng của một số điểm ngoại lai trên đường biên. Đơn vị của HD95 phụ thuộc vào hệ tọa

độ sử dụng (là pixel trong phạm vi khóa luận này); giá trị càng nhỏ cho thấy mức độ sai lệch biên giữa kết quả dự đoán và nhãn tham chiếu càng thấp.

2.4.4 Độ chuẩn xác định vị tâm (CBL)

Hệ số Dice và HD95 đánh giá chất lượng phân đoạn đầu ra nhưng không phản ánh được độ lệch vị trí giữa tâm dự đoán và tâm tổn thương thực tế, thông tin đặc biệt quan trọng khi câu nhắc bị lệch. Các độ đo định vị phổ biến trong computer vision (như DIoU, GIoU) đo lệch tâm giữa hai bounding box, không phải giữa hai mặt nạ phân đoạn pixel-level, và không chuẩn hóa theo kích thước tổn thương.

Vì vậy, khóa luận định nghĩa độ đo **Độ chuẩn xác định vị tâm (Center-Based Localization, CBL)** để đo sai lệch tâm giữa mặt nạ dự đoán và mặt nạ gốc, được chuẩn hóa theo kích thước tổn thương:

$$\text{CBL} = \max \left(0, 1 - \frac{\sqrt{(x_p - x_g)^2 + (y_p - y_g)^2}}{D_{gt}} \right) \quad (2.9)$$

trong đó (x_p, y_p) là tâm mặt nạ dự đoán, (x_g, y_g) là tâm nhãn gốc, và D_{gt} là đường chéo hộp bao nhỏ nhất quanh nhãn gốc (làm đơn vị chuẩn hóa theo kích thước tổn thương). $\text{CBL} = 1.0$ khi tâm dự đoán trùng khớp hoàn toàn; $\text{CBL} \rightarrow 0$ khi sai lệch vượt quá kích thước đường chéo tổn thương. Chuẩn hóa theo D_{gt} đảm bảo tính công bằng khi so sánh các tổn thương có kích thước khác nhau, một sai lệch 10 pixel có ý nghĩa rất khác nhau đối với khối u nhỏ so với khối u lớn.

2.5 Tổng kết chương

Chương 2 đã cung cấp bức tranh toàn cảnh và các cơ sở lý thuyết toán học vững chắc làm nền tảng cho khóa luận. Khảo sát U-Net và SAM-Med2D (hai mô hình đối sánh định lượng trong thực nghiệm) cùng phân

tích cơ chế Attention Gate của Attention U-Net (nền tảng lý thuyết được PGA-UNet kế thừa) làm nổi bật khoảng trống nghiên cứu: cần một kiến trúc CNN hạng nhẹ tích hợp câu nhắc trực quan từ bác sĩ, đạt hiệu năng phân đoạn cao và có tính bền bỉ trước câu nhắc không hoàn hảo.

Các lý thuyết về biểu diễn hộp giới hạn thành bản đồ nhiệt và Cổng chú ý có điều kiện là những nền tảng cốt lõi được tích hợp trực tiếp vào kiến trúc PGA-UNet trình bày ở Chương 3.

CHƯƠNG 3

MÔ HÌNH VÀ HỆ THỐNG ĐỀ XUẤT

3.1 Kiến trúc tổng thể của hệ thống

Hệ thống phân đoạn tương tác đề xuất trong khóa luận được thiết kế dưới dạng một luồng xử lý đầu cuối (end-to-end pipeline) **bán tự động**, trong đó bác sĩ luôn giữ vai trò xác nhận trước mỗi lần chuyển giai đoạn — đây là thiết kế *triage mềm* (soft triage), không phải một bộ chặn cứng tự động loại bỏ ảnh mà không cho phép con người can thiệp. Đầu vào của hệ thống là ảnh X-quang; bounding box lên vùng nghi ngờ chỉ được bác sĩ vẽ sau khi đã xác nhận ảnh có bệnh lý ở bước sàng lọc. Kiến trúc tổng thể được chia thành các module liên hoàn qua hai giai đoạn cốt lõi:

1. Giai đoạn sàng lọc bệnh lý (Mô hình góc cổng): Ảnh X-quang đầu vào đi qua một mạng nơ-ron tích chập đóng vai trò phân loại nhị phân. Hệ thống tính toán xác suất tồn tại của khối u hoặc các tổn thương bất thường và **hiển thị kết quả này cho bác sĩ dưới dạng một gợi ý** (ví dụ: "AI dự đoán: CÓ BỆNH, độ tin cậy 0.87"), chứ không tự động hành động dựa trên gợi ý đó. Bác sĩ xem gợi ý rồi chủ động xác nhận một trong hai lựa chọn:


- **Xác nhận không bệnh:** quy trình kết thúc cho ảnh này.
- **Xác nhận có bệnh lý:** hệ thống chuyển sang giai đoạn phân đoạn, sử dụng bounding box do bác sĩ vẽ làm prompt hướng dẫn.

Vì quyết định cuối cùng luôn do bác sĩ đưa ra, hệ thống **không bao giờ tự động loại một ca nghi ngờ mà không có xác nhận của con người**: ngay cả khi mô hình gợi ý "không bệnh", bác sĩ vẫn có thể bác bỏ gợi ý và chủ động yêu cầu chuyển sang bước phân đoạn nếu có nghi ngờ lâm sàng

riêng. Thiết kế này khác với một bộ chặn cứng tự động (nơi ảnh bị gán nhãn âm tính sẽ bị loại bỏ hoàn toàn khỏi luồng xử lý), và giữ đúng triết lý human-in-the-loop trong toàn bộ luồng xử lý — kể cả ở bước sàng lọc, không chỉ ở bước phân đoạn. Đánh giá định lượng ở Chương 4 (Mục 4.7.4) mô phỏng kịch bản thận trọng nhất — giả định gợi ý của Gatekeeper được làm theo tuyệt đối không có xác nhận của bác sĩ — nhằm đo lường cận dưới của hiệu năng hệ thống trong trường hợp xấu nhất.

2. Giai đoạn phân đoạn có hướng dẫn (PGA-UNet): Ở giai đoạn này, hệ thống hoạt động theo cơ chế học máy tương tác. Bác sĩ thực hiện thao tác khoanh một hộp giới hạn (Bounding Box) bao quanh vị trí nghi ngờ trên giao diện. Tọa độ của hộp giới hạn ngay lập tức được hệ thống chuyển đổi thành một bản đồ nhiệt không gian (Prompt Heatmap). Ảnh X-quang sạch và bản đồ nhiệt câu nhắc được đưa song song vào mô hình PGA-UNet (Prompt-Guided Attention U-Net). Bằng việc kích hoạt các cổng không gian và cơ chế chú ý có điều kiện, mô hình bị ép buộc phải hội tụ sự tập trung vào vùng được chỉ định để trích xuất hình dáng chính xác của khối u, tạo ra một mặt nạ phân đoạn thô.

Sự phân chia module rõ ràng trong kiến trúc không chỉ giúp hệ thống hoạt động linh hoạt, dễ dàng cô lập và xử lý lỗi, mà còn tạo điều kiện thuận lợi cho việc nâng cấp, thay thế từng thành phần độc lập trong tương lai. Chi tiết về cơ sở kỹ thuật, thiết kế cấu trúc mạng và công thức toán học của từng module sẽ được trình bày cụ thể trong các mục tiếp theo của chương này.



Hình 3.1: Pipeline tổng thể hệ thống: ảnh X-quang qua EfficientNet_B3 để sinh gợi ý sàng lọc; bác sĩ xem gợi ý và xác nhận (không bệnh → kết thúc, có bệnh → vẽ bounding box) trước khi hệ thống chuyển sang PGA-UNet phân đoạn có hướng dẫn.

3.2 Tiền xử lý dữ liệu và loại bỏ nhiễu ảnh X-quang

Chất lượng dữ liệu đầu vào ảnh hưởng trực tiếp đến năng lực học của bất kỳ mô hình học sâu nào. Trong bài toán phân đoạn ảnh X-quang y khoa, những nhiễu kỹ thuật tuy không liên quan đến bệnh lý nhưng lại có độ tương phản rất cao, dễ khiến mạng nơ-ron học nhầm đặc trưng, từ đó tạo ra kết quả phân đoạn không đáng tin cậy. Mục này trình bày đặc điểm của bộ dữ liệu BTXRD được sử dụng trong khóa luận, các vấn đề nhiễu đặc thù và quy trình tiền xử lý đã được xây dựng để đảm bảo đầu vào sạch, chuẩn hóa cho toàn bộ quá trình huấn luyện.

3.2.1 Bộ dữ liệu BTXRD

Bộ dữ liệu được sử dụng trong khóa luận là **BTXRD** (*Bone Tumor X-Ray Dataset*), một tập ảnh X-quang xương thực tế được công bố dưới dạng tài nguyên khoa học mở trên tạp chí *Nature Scientific Data* [9]. Đây là bộ dữ liệu hiếm hoi trong lĩnh vực y tế cung cấp đồng thời ba cấp độ nhãn: nhãn phân lớp (classification label), nhãn định vị đối tượng (localization label) và mặt nạ phân đoạn ở cấp độ điểm ảnh (pixel-level segmentation mask).

Đặc điểm nổi bật của BTXRD:

- Ảnh X-quang xương thực tế thu thập từ cơ sở lâm sàng, tập trung vào các cấu trúc có độ tương phản thấp và dễ gây nhầm lẫn trên lâm sàng (điển hình: X-quang gót chân, cổ chân, chi trên).
- Bao gồm cả ảnh có khối u xương (nhãn 1 - *bệnh lý*) và ảnh xương bình thường (nhãn 0 - *lành lặn*), phản ánh đúng phân phối thực tế trong môi trường sàng lọc lâm sàng.
- Dữ liệu thô chứa nhiều loại nhiễu kỹ thuật đặc thù của thiết bị chụp X-quang: ký tự chỉ hướng R/L (Right/Left), các nhãn metadata, và đôi khi là dị vật cản quang xuất hiện trên ảnh.


Bộ dữ liệu này phục vụ hai mục đích song song trong kiến trúc hệ thống: (1) toàn bộ ảnh (cả lành lặn và bệnh lý) được sử dụng để huấn luyện **mô hình phân lớp** sàng lọc ban đầu; (2) chỉ ảnh có bệnh lý kèm theo mặt nạ phân đoạn được sử dụng để huấn luyện **mô hình phân đoạn PGA-UNet**.

3.2.2 Quy trình tiền xử lý và loại bỏ nhiễu

Ảnh X-quang BTRD trong thực tế chứa một số loại nhiễu kỹ thuật phổ biến như ký tự chỉ hướng R/L và nhãn kỹ thuật được nhúng trực tiếp vào ảnh, những vùng sáng bất thường này có thể bị mạng nơ-ron nhận nhầm là tổn thương nếu không được xử lý. Quy trình tiền xử lý được tóm tắt tại Hình 3.2.

Để xóa nhiễu tự động, nhóm tác giả tiến hành gán nhãn hộp giới hạn vùng nhiễu thủ công trên một tập con ảnh thông qua nền tảng **Roboflow** [4], sau đó tinh chỉnh **YOLOv11s** [5] trên tập nhãn thu được. Mô hình sau khi huấn luyện được dùng để detect vùng nhiễu trên toàn bộ 3.746 ảnh PNG; các vùng phát hiện được xử lý bằng cách xác định giá trị màu xuất hiện nhiều nhất dọc theo biên hộp phát hiện; nếu giá trị đó nhỏ hơn 180 (không quá sáng) thì tô bằng màu đỏ, ngược lại tô bằng màu đen. Phương pháp này đảm bảo vùng được lấp đầy đồng nhất với nền xung quanh thay vì dùng màu cố định, loại bỏ hoàn toàn ký tự R/L và nhãn kỹ thuật.

Lưu ý về ký hiệu R/L trong triển khai: Bước xóa R/L chỉ áp dụng cho bản sao ảnh đưa vào mô hình học máy, không áp dụng lên ảnh hiển thị. Trong hệ thống triển khai thực tế, giao diện người dùng hiển thị *ảnh gốc còn ký hiệu R/L* để bác sĩ tra cứu thông tin định hướng trái/phải, thông tin có ý nghĩa lâm sàng quan trọng (nhằm bên là nguy hiểm tính mạng). Mặt nạ phân đoạn từ PGA-UNet sau đó được chồng lên ảnh gốc này để bác sĩ đọc kết quả trong đúng ngữ cảnh định hướng. Lý do loại bỏ R/L khỏi đầu vào mô hình là để tránh mạng nơ-ron nhận nhầm các vùng



Hình 3.2: Quy trình tiền xử lý dữ liệu: gán nhãn bounding box nhiều thủ công trên một phần ảnh qua Roboflow, finetune YOLOv11s, detect nhiều trên toàn bộ tập ảnh PNG, tô màu vùng nhiều bằng màu nền được chọn.

sáng của ký tự R/L là tổn thương xương.

3.3 Mô hình phân đoạn PGA-UNet (Prompt-Guided Attention U-Net)

Kiến trúc mạng PGA-UNet được xây dựng trên nền tảng kế thừa và cải tiến có chủ đích. Bảng 3.1 tóm tắt rõ ranh giới giữa những gì được kế thừa từ các công trình trước và những gì là đề xuất mới của khóa luận.

Bảng 3.1: Phân biệt kế thừa và đóng góp trong kiến trúc PGA-UNet

Thành phần	Kế thừa từ	Đóng góp mới
Khung encoder-decoder	U-Net [7]: khối tích chập, max pooling, kết nối tắt	Không có
Cổng chú ý không gian mềm (Soft Spatial Attention Gate)	Attention U-Net [6]: cổng chú ý không gian mềm tại skip connections (Attention U-Net bổ sung cơ chế này lên nền U-Net)	Mở rộng thành CAD: bổ sung tri thức câu nhắc vào tín hiệu gating g
Mã hóa câu nhắc	SAM-Med2D [3]: ý tưởng prompt dẫn đường	Thay token/binary bằng Gaussian Plateau Heatmap 2D
Cổng không gian (PSG)	Không có	Hoàn toàn mới: tăng cường đặc trưng encoder có chọn lọc theo vùng câu nhắc

Chuỗi kế thừa tuyến tính: U-Net [7] (nền encoder-decoder) → **Attention U-Net** [6] (bổ sung Soft Spatial Attention Gate vào skip connections của U-Net) → **PGA-UNet** (thêm PSG vào encoder, mở rộng Attention Gate thành CAD, thay mặt nạ nhị phân bằng Gaussian Plateau Heatmap). Attention U-Net là điểm xuất phát trực tiếp mà khóa luận mở rộng, không phải hai baseline độc lập song song.

Dựa trên ranh giới này, ba thành phần cốt lõi sau đây lần lượt hiện thực hóa đóng góp của khóa luận.

3.3.1 Biểu diễn câu nhắc trực quan (Prompt Heatmap Representation)

Nhằm chuyển đổi thao tác không gian của người dùng thành một định dạng số học mang tính chất dẫn đường mềm dẻo, tọa độ hộp giới hạn $\mathbf{B} = (x_1, y_1, x_2, y_2)$ do bác sĩ cung cấp sẽ được biểu diễn dưới dạng Bản đồ nhiệt câu nhắc $\mathbf{H}_{prompt} \in [0, 1]^{H \times W}$.

Trong thiết kế lý thuyết, bản đồ nhiệt câu nhắc có thể xây dựng theo phân phối Gaussian 2D thuần túy như đã trình bày tại Phương trình (2.3), với cường độ đạt cực đại tại tâm và phân rã dần về biên. Tuy nhiên, trong thực tế triển khai, nhóm sử dụng phương pháp **Plateau Heatmap**: vùng bên trong hộp giới hạn được gán đồng nhất giá trị 1.0 (tạo vùng cao nguyên phẳng - plateau), sau đó làm mềm đường biên bằng bộ lọc Gaussian (kernel 31×31):

$$\mathbf{H}_{prompt} = \text{GaussianBlur}(\mathbf{B}_{\text{mask}}, k = 31) \quad (3.1)$$

trong đó $\mathbf{B}_{\text{mask}} \in \{0, 1\}^{H \times W}$ là mặt nạ nhị phân của hộp giới hạn (có đệm 5 px mỗi phía). Cách tiếp cận này giữ được tín hiệu dẫn đường mạnh và đồng đều bên trong vùng câu nhắc (không bị suy giảm về phía tâm như Gaussian thuần), đồng thời tạo ra đường chuyển tiếp mượt mà ở viền hộp để mạng không học các gradient giả tạo từ đường viền sắc nét. Bản đồ nhiệt $\mathbf{H}_{prompt}$ này đóng vai trò như một kênh dữ liệu độc lập, song hành cùng ảnh X-quang đi vào mạng.

Lý do chọn $k = 31$: Kích thước kernel được lựa chọn để cân bằng hai yêu cầu đối lập: đủ lớn để tạo vùng chuyển tiếp mịn kéo dài ≈ 15 px mỗi bên, phủ vùng biên tổn thương điển hình trên ảnh 512×512 , đồng thời đủ nhỏ để tín hiệu câu nhắc không "tràn" sang các cấu trúc xương lân cận. Thực nghiệm với $k \in \{15, 21, 31, 51\}$ cho thấy $k < 21$ tạo đường chuyển tiếp quá đột ngột (gần mặt nạ nhị phân), trong khi $k > 51$ làm tín hiệu

lan quá rộng ra ngoài vùng tổn thương. $k = 31$ (số lẻ, đảm bảo tâm kernel đối xứng) cho kết quả Dice tốt nhất trên tập xác thực và được giữ cố định trong toàn bộ thực nghiệm.

Cơ sở lý thuyết: Tại sao chọn biểu diễn liên tục có gradient thay vì mặt nạ nhị phân? Câu hỏi đặt ra là tại sao không dùng mặt nạ nhị phân phẳng, trong đó mọi điểm ảnh bên trong hộp giới hạn nhận giá trị 1 và bên ngoài là 0, thay vì bản đồ nhiệt liên tục. Câu trả lời nằm ở bản chất của phép tích chập và cơ chế dung hợp đặc trưng trong U-Net. Khi một mặt nạ nhị phân đi qua tầng tích chập, đường biên sắc nét tại viền hộp giới hạn tạo ra các gradient giả tạo (pseudo-gradients), mạng có thể học cạnh của hộp bao thay vì đặc trưng thực của tổn thương. Ngược lại, Plateau Heatmap cung cấp tín hiệu mạnh và đồng đều bên trong (đảm bảo câu nhắc rõ nét), nhưng chuyển tiếp mượt mà ở viền thông qua bộ lọc Gaussian. Thiết kế này phù hợp với bản chất tự nhiên của attention bias: cổng không gian tại phương trình (3.2) cần một tín hiệu liên tục để thực hiện phép nhân theo phần tử trên feature map mà không tạo ra hiệu ứng ringing.

Ngoài ra, các nghiên cứu về cơ chế chú ý trong học sâu cho thấy mạng nơ-ron tự nhiên tạo ra các vùng kích hoạt có dạng phân phối liên tục, với cường độ cao nhất tại vùng trung tâm đặc trưng nhất và giảm dần ra biên. Biểu diễn Plateau Heatmap của câu nhắc bắt chước đặc tính này, tạo ra sự tương thích tự nhiên với cơ chế học của mạng.

So sánh với cách mã hóa prompt của SAM và SAM-Med2D. SAM và SAM-Med2D [3] mã hóa hộp giới hạn dưới dạng *positional embedding rời rạc*: tọa độ hai góc của hộp (trên-trái và dưới-phải) được ánh xạ thành hai vector nhúng 256 chiều thông qua bảng tra vị trí sinusoidal. Cách tiếp cận này phù hợp với kiến trúc Transformer của SAM vì Transformer xử lý một tập token rời rạc và tích hợp thông tin vị trí qua phép cộng vector embedding. Tuy nhiên, PGA-UNet sử dụng kiến trúc U-Net

với feature map 2D liên tục có cùng cấu trúc không gian $H \times W$ với ảnh đầu vào.

Việc kết hợp một vector embedding rời rạc (256 chiều, không có cấu trúc không gian) vào feature map 2D đòi hỏi phép chiếu phức tạp và dễ mất thông tin vị trí. Biểu diễn bản đồ nhiệt 2D ($H \times W$, cùng không gian với feature map) cho phép Cổng không gian thực hiện phép nhân theo phần tử trực tiếp tại phương trình (3.2), một phép toán đơn giản, hiệu quả về tính toán và bảo toàn toàn vẹn thông tin vị trí không gian. Đây là lý do cốt lõi nhóm chọn biểu diễn heatmap 2D thay vì vector embedding rời rạc theo cách SAM: hai kiến trúc khác nhau đòi hỏi hai cách mã hóa prompt khác nhau để phù hợp nhất với cơ chế dung hợp đặc trưng nội tại.

3.3.2 Cổng không gian tại bộ mã hóa (Prompt Spatial Gate - Encoder)

Trong kiến trúc U-Net truyền thống, bộ mã hóa (Encoder) chịu trách nhiệm trích xuất các đặc trưng ngữ nghĩa. Tuy nhiên, nếu thiếu định hướng, nó có xu hướng học mọi thứ xuất hiện trên ảnh X-quang, dẫn đến việc lãng phí tài nguyên tính toán vào các vùng nền không liên quan.

PGA-UNet khắc phục điều này bằng cách tích hợp cấu kiện **Cổng không gian (Prompt Spatial Gate, PSG)** trực tiếp vào nhánh mã hóa; đây là thành phần hoàn toàn mới, không tồn tại trong U-Net hay Attention U-Net gốc, được đề xuất để đưa tín hiệu câu nhắc vào ngay từ giai đoạn trích xuất đặc trưng. Tại tầng mã hóa thứ l , bản đồ nhiệt $\mathbf{H}^l$ được giảm mẫu về cùng độ phân giải với đặc trưng $\mathbf{x}^l$, sau đó đưa qua một bộ lọc cổng để sinh ra tín hiệu khuếch đại không gian:

$$\tilde{\mathbf{x}}^l = \mathbf{x}^l \odot (1 + \alpha \cdot \sigma(\mathbf{W}_{gate} * \mathbf{H}^l)) \quad (3.2)$$

trong đó $\mathbf{W}_{gate}$ là phép tích chập 1×1 ánh xạ bản đồ nhiệt (1 kênh) sang không gian kênh đặc trưng C^l ; σ là hàm Sigmoid; $\alpha \in [0, 1]$ là tham số học được (khởi tạo nhỏ tại 0.1 để không làm xáo trộn huấn luyện ban đầu); và

⊙ là phép nhân theo phần tử.

Thiết kế này hoạt động theo nguyên lý *tăng cường có chọn lọc* (selective enhancement) thay vì ức chế: các đặc trưng nằm trong vùng câu nhắc được nhân thêm một hệ số > 1 (tăng lên), trong khi các đặc trưng ngoài vùng câu nhắc (nơi $\mathbf{H}^l \approx 0$) vẫn giữ nguyên giá trị ban đầu (nhân với ≈ 1). Nhờ đó, bộ mã hóa không bị mất thông tin toàn cục nhưng vẫn ưu tiên truyền tải các đặc trưng trong vùng mục tiêu xuống các tầng sâu hơn.

3.3.3 Cơ chế chú ý có điều kiện tại bộ giải mã (Conditioned Attention Decoder)

Dù Cổng không gian ở bộ mã hóa đã giúp loại bỏ nhiều nền đáng kể, nhưng tại bộ giải mã (Decoder) – nơi mạng thực hiện phép tăng mẫu để khôi phục ranh giới xương – tín hiệu định vị vẫn có nguy cơ bị phân tán. Để thiết lập sự dẫn đường xuyên suốt, khóa luận đề xuất **Cơ chế chú ý có điều kiện (Conditioned Attention Decoder, CAD)**, thay thế trực tiếp Cổng chú ý (Attention Gate) cơ sở của Attention U-Net tại từng tầng giải mã.

Điểm khác biệt cốt lõi so với Attention Gate gốc [6]: Attention Gate cơ sở tính tín hiệu gating $\mathbf{g}$ hoàn toàn từ đặc trưng tầng decoder bên dưới, nghĩa là quyết định “nên chú ý chỗ nào” phụ thuộc hoàn toàn vào những gì mạng tự học từ ảnh, không có thông tin định hướng từ bác sĩ. CAD mở rộng thiết kế này bằng cách bổ sung câu nhắc trực tiếp vào $\mathbf{g}$: cấu kiện `unetUp_PromptAttention` tích hợp tri thức câu nhắc vào tín hiệu gating thông qua **cơ chế dung hợp cộng có trọng số tin cậy** (confidence-weighted additive fusion). Cụ thể, bản đồ câu nhắc $\mathbf{H}_{prompt}$ được giảm mẫu về kích thước của $\mathbf{g}$ và đưa qua một bộ mã hóa hai tầng tích chập (3×3 , InstanceNorm, ReLU) để trích xuất biểu diễn đặc trưng câu nhắc $\mathbf{p}_{enc}$. Từ đó, một điểm số tin cậy vô hướng $c \in (0, 1)$ được tính bằng cách áp dụng GAP (Global Average Pooling) lên $\mathbf{p}_{enc}$:


$$\mathbf{p}_{enc} = f_{enc}(\mathbf{H}_{prompt}), \quad c = \sigma(\text{GAP}(\mathbf{p}_{enc})) \quad (3.3)$$

Tín hiệu gating được điều kiện hóa bằng phép cộng có trọng số:

$$\mathbf{g}' = \mathbf{g} + c \cdot \alpha \cdot w_l \cdot \mathbf{p}_{\text{enc}} \quad (3.4)$$

trong đó $\alpha = \sigma(\alpha_{\text{raw}})$ là tham số học được (blend weight), và w_l là hệ số tỷ lệ theo tầng giải mã l , được xác định qua thực nghiệm trên tập xác thực (lịch trình cụ thể tại Chương 4), điều tiết mức độ ảnh hưởng của câu nhắc tại mỗi tầng.

Tín hiệu $\mathbf{g}'$ sau đó được đưa vào Cổng chú ý (GridAttentionBlock2D) tiêu chuẩn để tính hệ số chú ý α_{cond} điều chỉnh đặc trưng skip connection $\mathbf{x}^l$, kết hợp cùng kết nối dư tắt và tín hiệu dư câu nhắc tại đầu ra ($+\beta \cdot \mathbf{H}_{\text{prompt}}$, β học được). Thiết kế đa lớp này đảm bảo câu nhắc không chỉ ảnh hưởng qua một điểm duy nhất mà được duy trì xuyên suốt toàn bộ bộ giải mã thông qua hệ số w_l theo từng tầng. Các siêu tham số cụ thể của PSG và CAD (lịch trình w_l , hệ số kết nối dư) là chi tiết triển khai được xác định qua thực nghiệm trên tập xác thực, không phải đóng góp kỹ thuật cốt lõi; giá trị chi tiết được liệt kê tại mục cấu hình huấn luyện (Mục 4.1.2, Chương 4). Sự kết hợp giữa “Cổng không gian tại bộ mã hóa” và “Cơ chế chú ý có điều kiện tại bộ giải mã” là yếu tố chính mang lại sự cải thiện đáng kể về hiệu năng Dice so với các mạng cơ sở hoạt động theo hướng tiếp cận tự động (chi tiết tại Chương 4).



Hình 3.3: Kiến trúc PGA-UNet (Prompt-Guided Attention U-Net): Cổng không gian (Prompt Spatial Gate) tích hợp bản đồ nhiệt câu nhắc vào bộ mã hóa để tăng cường đặc trưng có chọn lọc; Cơ chế chú ý có điều kiện (Conditioned Attention) ràng buộc tín hiệu gating bằng câu nhắc tại từng tầng giải mã với hệ số w_l theo từng tầng

3.3.4 Chiến lược huấn luyện và so sánh với mô hình nền tảng SAM-Med2D

Hàm mất mát huấn luyện PGA-UNet kết hợp Dice Loss và Binary Cross-Entropy với trọng số bằng nhau:

$$\mathcal{L}_{\text{seg}} = \mathcal{L}_{\text{Dice}} + \mathcal{L}_{\text{BCE}} \quad (3.5)$$

Dice Loss tối ưu trực tiếp độ tương đồng vùng giữa mặt nạ dự đoán và nhãn gốc; BCE phạt sai lệch tại từng điểm ảnh riêng lẻ và ổn định gradient. Hai thành phần bổ sung cho nhau, giúp mô hình cân bằng giữa hình dạng tổng thể và độ chính xác đường biên.

Vai trò của câu nhắc đối với hàm mất mát: Việc tích hợp câu nhắc trực quan được thực hiện hoàn toàn ở *cấp độ kiến trúc* (thông qua Cổng không gian PSG và Cơ chế chú ý có điều kiện CAD), chứ *không* thay đổi cấu trúc hàm mất mát. $\mathcal{L}_{\text{seg}}$ vẫn giữ nguyên dạng BCE + Dice tính trên mặt nạ đầu ra $\hat{\mathbf{y}}$ so với nhãn ground-truth $\mathbf{M}$, bất kể câu nhắc đầu vào là heatmap Gaussian, mặt nạ nhị phân hay bất kỳ dạng biểu diễn nào. Ảnh hưởng của câu nhắc lên quá trình học được truyền ngầm qua gradient

của PSG và CAD trong lan truyền ngược (backpropagation), không cần thêm số hạng phạt hay trọng số nào vào $\mathcal{L}_{\text{seg}}$.

Để tránh hiểu nhầm khi so sánh kết quả thực nghiệm, cần làm rõ sự khác biệt căn bản về chiến lược huấn luyện giữa PGA-UNet và SAM-Med2D.

PGA-UNet, Huấn luyện từ đầu hoàn toàn: Toàn bộ kiến trúc PGA-UNet, bao gồm bộ mã hóa U-Net, các Cổng không gian, khối dung hợp và bộ giải mã có điều kiện, được khởi tạo ngẫu nhiên và học trực tiếp từ tập dữ liệu BTXRD qua tối đa 100 vòng lặp với cơ chế dừng sớm (patience = 15). **Không có thành phần nào được đóng băng** trong quá trình huấn luyện; toàn bộ ~ 3 triệu tham số (đo từ kiến trúc thực nghiệm với `feature_scale=4`, bộ lọc [16, 32, 64, 128, 256]) đều tham gia lan truyền ngược (backpropagation) từ vòng lặp đầu tiên. Lý do cho lựa chọn này: bộ mã hóa U-Net của PGA-UNet là kiến trúc tích chập đơn giản, không có trọng số tiền huấn luyện quy mô lớn tương thích với ảnh X-quang xương. Việc huấn luyện từ đầu trên domain data cụ thể (BTXRD) cho phép bộ mã hóa học được các đặc trưng thấp (low-level features) như kết cấu xương, biên tổn thương đặc thù của X-quang chi, không bị ràng buộc bởi các đặc trưng từ domain khác.

SAM-Med2D, Tinh chỉnh từ mô hình nền tảng: SAM-Med2D [3] kế thừa toàn bộ trọng số tiền huấn luyện của bộ mã hóa ViT-B đã được học trên khoảng 4.6 triệu ảnh y tế 2D đa dạng (tập SA-Med2D-20M). Trong quá trình tinh chỉnh trên BTXRD, bộ mã hóa ViT-B được đóng băng một phần và chỉ cập nhật qua các lớp Adapter (adapter tuning) nhẹ; bộ giải mã mặt nạ và bộ mã hóa prompt được cập nhật đầy đủ. Chính nhờ xuất phát từ trọng số đã hội tụ trên dữ liệu y tế quy mô lớn, SAM-Med2D chỉ cần 4 vòng lặp tinh chỉnh để đạt Val Dice tốt nhất (dừng sớm tại epoch 14), nhanh hơn đáng kể so với PGA-UNet (best epoch 79, dừng sớm tại epoch 94). Tuy nhiên, quy mô tham số của SAM-Med2D (~ 91 triệu theo kiến trúc ViT-B gốc [3], cộng thêm các lớp Adapter) lớn hơn PGA-UNet khoảng 30 lần (~ 3 triệu).

Sự khác biệt về chiến lược này có ý nghĩa quan trọng khi diễn giải kết

Bảng 3.2: So sánh chiến lược huấn luyện giữa PGA-UNet và SAM-Med2D

Thuộc tính	PGA-UNet (đề xuất)	SAM-Med2D (so sánh)
Chiến lược	Huấn luyện từ đầu (từ ngẫu nhiên)	Tinh chỉnh từ pre-trained ViT-B
Bộ mã hóa	U-Net CNN, học toàn bộ từ đầu	ViT-B, pretrained trên 4.6M ảnh y tế 2D
Thành phần bị đóng băng	Không có	ViT-B backbone (cập nhật qua Adapter)
Tổng tham số	~3 triệu	~91 triệu (ViT-B gốc) + Adapter
Số epoch hội tụ (best val)	79	4

quả ở Chương 4: PGA-UNet đạt hiệu năng Dice cao hơn SAM-Med2D mặc dù nhỏ hơn ~30 lần về tổng tham số (~3 triệu so với ~91 triệu của ViT-B) và không có bất kỳ trọng số tiền huấn luyện nào. Kết quả này phản ánh hiệu quả của cơ chế tích hợp câu nhắc sâu sát vào kiến trúc nhẹ, chứ không phải ưu thế từ quy mô mô hình hay dữ liệu tiền huấn luyện.

3.4 Module gác cổng sàng lọc (Gatekeeper)

Mô hình PGA-UNet được huấn luyện hoàn toàn trên tập ảnh **chỉ chứa các ca bệnh lý**. Trong môi trường lâm sàng thực tế, luồng đầu vào hỗn hợp cả ảnh bình thường lẫn bệnh lý. Nếu đưa trực tiếp ảnh xương bình thường vào PGA-UNet, mô hình sẽ tạo ra mặt nạ sai lệch (False Positive), gây hiểu nhầm nghiêm trọng cho bác sĩ và lãng phí tài nguyên tính toán.

Giải pháp: Một module phân lớp nhị phân (**Gatekeeper**) đặt trước pipeline phân đoạn, đưa ra gợi ý sàng lọc: ảnh nghi ngờ bình thường hay có bệnh lý. Module này **không tự động loại bỏ ảnh** — kết quả luôn được hiển thị cho bác sĩ dưới dạng gợi ý kèm độ tin cậy, và bác sĩ là người

xác nhận bước tiếp theo (Mục 3.1). Thiết kế *triage mềm* này được lựa chọn thay vì một bộ chặn cứng tự động vì hai lý do: (1) giữ đúng triết lý human-in-the-loop xuyên suốt toàn hệ thống, không riêng bước phân đoạn; (2) tránh rủi ro một ca bệnh thực sự bị loại bỏ vĩnh viễn khỏi luồng xử lý chỉ vì một dự đoán sai của mô hình phân lớp (false negative) mà không có cơ hội con người can thiệp — rủi ro này càng đáng lưu ý khi Gatekeeper đạt Sensitivity dưới 90% (chi tiết tại Mục 4.7.1, Chương 4). Module này **không phải đóng góp kỹ thuật trọng tâm** của khóa luận mà là thành phần hỗ trợ lấp đầy khoảng trống giữa điều kiện huấn luyện và triển khai thực tế. Kiến trúc cụ thể (EfficientNet_B3, chiến lược tinh chỉnh hai giai đoạn) và kết quả định lượng được trình bày đầy đủ tại Mục 4.7.1 (Chương 4).

Module này được tối ưu bằng hàm mất mát Entropy chéo nhị phân:

$$\mathcal{L}_{\text{cls}} = -\frac{1}{N} \sum_{i=1}^N \left[y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i) \right] \quad (3.6)$$

trong đó $y_i \in \{0, 1\}$ là nhãn thực và $\hat{p}_i \in [0, 1]$ là xác suất dự đoán của ảnh thứ i .

Trong luồng xử lý hệ thống (Mục 3.1), module Gatekeeper chạy tự động ngay khi ảnh được tải lên và hiển thị gợi ý sàng lọc cho bác sĩ; bác sĩ xác nhận "không bệnh" (pipeline kết thúc) hoặc "có bệnh" (hệ thống chuyển sang Giai đoạn 2 — PGA-UNet phân đoạn với prompt bounding box do bác sĩ vẽ). Quá trình chuyển giai đoạn luôn cần xác nhận của bác sĩ, kể cả khi bác sĩ không đồng ý với gợi ý của mô hình.

3.5 Tóm tắt giải thuật hệ thống: Huấn luyện và Suy luận

Để làm rõ toàn bộ thiết kế đã trình bày trong chương này, mục này phát biểu chính thức hai giải thuật cốt lõi của hệ thống: quy trình huấn luyện

ngoại tuyến (Algorithm 1) và quy trình suy luận trực tuyến (Algorithm 2). Hai giải thuật này làm rõ sự phân tách giữa **giai đoạn ngoại tuyến** (tiền xử lý dữ liệu, sinh heatmap từ ground-truth mask, tối ưu tham số) và **giai đoạn trực tuyến** (nhận đầu vào từ bác sĩ, sinh heatmap từ bounding box người dùng vẽ, trả mặt nạ phân đoạn), tương ứng với hai sơ đồ ngoại tuyến/trực tuyến của hệ thống.

Algorithm 1 Quy trình huấn luyện ngoại tuyến (Offline Training)

Require: Tập dữ liệu $\mathcal{D} = \{(\mathbf{I}_i, \mathbf{M}_i)\}_{i=1}^N$ (ảnh X-quang và mặt nạ phân đoạn pixel-level)

Ensure: Bộ tham số θ^* của PGA-UNet đã hội tụ

- 1: **Tiền xử lý:** Dùng YOLOv11s xóa ký hiệu R/L và nhiễu kỹ thuật khỏi toàn bộ ảnh trong $\mathcal{D}$; resize về 512×512
 - 2: **for** mỗi epoch $e = 1, 2, \dots, E_{\max}$ **do**
 - 3: **for** mỗi mini-batch $(\mathbf{I}_i, \mathbf{M}_i)$ **do**
 - 4: Trích hộp giới hạn $\mathbf{B}_i$ từ $\mathbf{M}_i$ (bounding box bao sát mask + đệm 5 px)
 - 5: Chọn kích bản câu nhắc ngẫu nhiên: *zoom-out* (70%) hoặc *shift* (30%)
 - 6: Sinh bản đồ nhiệt: $\mathbf{H}_i = \text{GaussianBlur}(\mathbf{B}_{i,\text{mask}}, k=31)$ (Phương trình (3.1))
 - 7: Tính đầu ra dự đoán: $\hat{\mathbf{y}}_i = f_{\text{PGA}}(\mathbf{I}_i, \mathbf{H}_i; \theta)$
 - 8: Tính hàm mất mát: $\mathcal{L} = \mathcal{L}_{\text{BCE}} + \mathcal{L}_{\text{Dice}}$ (Phương trình (3.5))
 - 9: Cập nhật: $\theta \leftarrow \theta - \eta \nabla_{\theta} \mathcal{L}$ (AdamW, gradient clip ≤ 1.0)
 - 10: Tính Dice xác thực trên tập val; cập nhật **ReduceLROnPlateau**
 - 11: **if** Dice xác thực không cải thiện sau 15 epoch liên tiếp **then**
 - 12: **break** (Early Stopping)
 - 13: **return** $\theta^* \leftarrow$ tham số tại epoch có Dice xác thực cao nhất
-

Xử lý câu nhắc rỗng (bước kiểm tra $\mathbf{B} = \emptyset$ của Algorithm 2, chỉ xảy ra sau khi bác sĩ đã xác nhận có bệnh lý): Khi bác sĩ chưa vẽ bounding box, hệ thống từ chối thực hiện phân đoạn và yêu cầu người dùng cung cấp vùng nghi ngờ. Lý do: bản đồ nhiệt tương ứng sẽ là ma trận không ($\mathbf{H} = \mathbf{0}$), không mang thông tin định hướng nào; Cổng không gian tại bộ mã hóa (Phương trình (3.2)) sẽ không khuếch đại vùng nào,

Algorithm 2 Quy trình suy luận trực tuyến (Online Inference)

Require: Ảnh X-quang đầu vào $\mathbf{I}$; hộp giới hạn $\mathbf{B} = (x_1, y_1, x_2, y_2)$ do bác sĩ vẽ **sau khi xác nhận có bệnh lý** (có thể rỗng nếu bác sĩ chưa vẽ)

Ensure: Mặt nạ phân đoạn $\hat{\mathbf{M}}$, hoặc thông báo phù hợp

- 1: **Tiền xử lý:** Loại bỏ R/L và nhiễu từ bản sao $\mathbf{I}'$ của $\mathbf{I}$ (giữ $\mathbf{I}$ gốc để hiển thị)
 - 2: **Sàng lọc bệnh lý (gợi ý):** $p \leftarrow f_{\text{cls}}(\mathbf{I}'; \boldsymbol{\theta}_{\text{cls}})$; hiển thị gợi ý “CÓ BỆNH” nếu $p \geq 0.5$, ngược lại “KHÔNG BỆNH”, kèm độ tin cậy
 - 3: **Bác sĩ xác nhận:** $c \leftarrow$ lựa chọn của bác sĩ ($c=1$: có bệnh, $c=0$: không bệnh) $\triangleright c$ độc lập với p — bác sĩ có thể bác bỏ gợi ý của mô hình
 - 4: **if** $c = 0$ **then**
 - 5: **return** “Bác sĩ xác nhận không có bệnh lý: kết thúc quy trình”
 - 6: **if** $\mathbf{B} = \emptyset$ (bác sĩ đã xác nhận có bệnh nhưng chưa vẽ câu nhắc) **then**
 - 7: **return** “Vui lòng khoanh hộp giới hạn lên vùng nghi ngờ” $\triangleright$
Heatmap zero không xác định hành vi phân đoạn
 - 8: Sinh bản đồ nhiệt: $\mathbf{H} \leftarrow \text{GaussianBlur}(\mathbf{B}_{\text{mask}}, k=31)$
 - 9: Tính xác suất phân đoạn: $\hat{\mathbf{y}} \leftarrow f_{\text{PGA}}(\mathbf{I}', \mathbf{H}; \boldsymbol{\theta}^*)$
 - 10: Tạo mặt nạ nhị phân: $\hat{\mathbf{M}} \leftarrow \mathbf{1}[\hat{\mathbf{y}} \geq 0.5]$
 - 11: **return** $\hat{\mathbf{M}}$ (hiển thị chồng lên ảnh gốc $\mathbf{I}$ có ký hiệu R/L)
-

và Cơ chế chú ý có điều kiện (Phương trình (3.4)) sẽ dựa hoàn toàn vào tín hiệu decoder mà không có ràng buộc không gian, dẫn đến mất nà đầu ra thiếu độ tin cậy. Thiết kế từ chối tường minh (explicit rejection) này ưu tiên an toàn lâm sàng hơn là cố gắng phân đoạn với đầu vào không đủ thông tin.

3.6 Tổng kết chương

Chương này đã trình bày đầy đủ kiến trúc và quy trình vận hành của hệ thống đề xuất: từ bước tiền xử lý loại bỏ nhiễu kỹ thuật trên BTXRD, đến ba thành phần cốt lõi của PGA-UNet (biểu diễn câu nhắc dạng Plateau Heatmap, Cổng không gian tại bộ mã hóa, và Cơ chế chú ý có điều kiện tại bộ giải mã), module gác cổng sàng lọc, và hai giải thuật hình thức hóa toàn bộ luồng huấn luyện ngoại tuyến lẫn suy luận trực tuyến. Bảng 3.1 đã phân định rõ ranh giới giữa phần kế thừa (khung U-Net, Attention Gate) và phần đóng góp mới (PSG, CAD, biểu diễn heatmap liên tục). Đây là cơ sở kỹ thuật để Chương 4 tiến hành đo lường định lượng mức độ hiệu quả của từng đóng góp thông qua thực nghiệm baseline, ablation study và các phân tích so sánh chi tiết.

CHƯƠNG 4

THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ

Chương này tổ chức kết quả thực nghiệm thành hai phần. **Phần I** tập trung đánh giá kiến trúc PGA-UNet trên tập kiểm thử 187 ảnh (image-level): so sánh với các mô hình cơ sở và SAM-Med2D (đánh giá image-level, N=187 ảnh), ablation study (PSG/CAD), đánh giá tính bền bỉ (Robustness) và kiểm định xác thực chéo. **Phần II** trình bày đánh giá module Gatekeeper hỗ trợ (EfficientNet_B3) và pipeline end-to-end trên dữ liệu hỗn hợp thực tế.

4.1 Thiết lập môi trường thực nghiệm

Để đảm bảo tính khách quan và khả năng tái lập (reproducibility) của các kết quả nghiên cứu, mục này trình bày chi tiết về quy mô dữ liệu, phương pháp phân chia các tập đánh giá, cấu hình phần cứng cũng như các siêu tham số (hyperparameters) được thiết lập trong suốt quá trình huấn luyện mô hình.

4.1.1 Tập dữ liệu ảnh X-quang (Dataset)

Dữ liệu thực nghiệm được sử dụng trong khóa luận là bộ **BTXRD** (*Bone Tumor X-Ray Dataset*) [9], một tập ảnh X-quang xương công khai có đầy đủ ba cấp nhãn: phân lớp, định vị và phân đoạn pixel-level.

Lý do chọn BTXRD: Không giống các bộ dữ liệu X-quang công khai chỉ cung cấp nhãn phân lớp mà thiếu mặt nạ phân đoạn, BTXRD cung cấp đồng thời cả ba cấp nhãn (phân lớp, định vị, phân đoạn pixel-level), đáp ứng đầy đủ yêu cầu huấn luyện có giám sát. Ảnh X-quang thô chứa nhiều nhiễu kỹ thuật (ký tự R/L, metadata) và đã trải qua quy trình tiền

xử lý bằng YOLOv11s như mô tả ở Mục 3.2.

Hai phân vùng dữ liệu song song: Kiến trúc hệ thống sử dụng hai tập dữ liệu với mục đích khác nhau:

- **Dữ liệu phân đoạn** (cho PGA-UNet và baseline): Chỉ chứa các ảnh *có bệnh lý* kèm mặt nạ phân đoạn pixel-level. Đây là giới hạn tự nhiên của học có giám sát, chỉ ảnh có nhãn mới dùng được.
- **Dữ liệu phân lớp** (cho Gatekeeper): Chứa cả ảnh bệnh lý lẫn ảnh bình thường, phân chia theo tỷ lệ 80/10/10 (train/val/test), batch size = 16.

Thống kê dữ liệu: Bảng 4.1 tóm tắt phân bố dữ liệu sau khi phân chia.

Bảng 4.1: Thống kê phân bố bộ dữ liệu thực nghiệm

Tập dữ liệu	Số ảnh	Số mẫu (per-polygon)	Ghi chú
Huấn luyện (Train)	1 493	1848	Tất cả ca bệnh lý
Xác thực (Validation)	187	238	
Kiểm thử (Test)	187	232	Nhiều ảnh có ≥ 2 polygon $\rightarrow$ 232 mẫu per-polygon

Thống kê bộ dữ liệu phân lớp (Gatekeeper): Bộ BTXRD gồm 3.746 ảnh X-quang (cả lành lặn lẫn bệnh lý) được dùng toàn bộ để huấn luyện mô hình góc cổng, phân chia train/val/test theo tỷ lệ 80/10/10 ($\approx 2.996/375/375$ ảnh). Tập phân lớp và tập phân đoạn dùng chung ảnh bệnh lý nhưng độc lập về nhãn: nhãn nhị phân (lành/bệnh) cho Gatekeeper, nhãn mặt nạ pixel-level cho PGA-UNet.

4.1.2 Cấu hình huấn luyện (Hyperparameters, Loss functions)

Toàn bộ quá trình huấn luyện và suy luận thực nghiệm được triển khai trên môi trường Kaggle/Colab với GPU T4 nhằm tăng tốc độ tính toán. Các mô hình được cài đặt dựa trên thư viện PyTorch.

Hàm mất mát (Loss Function): Để xử lý mất cân bằng giữa foreground (vùng tổn thương) và background, hệ thống sử dụng hàm mất mát kết hợp:

$$\mathcal{L}_{total} = \mathcal{L}_{BCE} + \mathcal{L}_{Dice} \quad (4.1)$$

Thành phần $\mathcal{L}_{BCE}$ tối ưu phân loại từng pixel; $\mathcal{L}_{Dice}$ tối ưu độ chồng lấp diện tích tổng thể.

Siêu tham số huấn luyện: Tất cả mô hình (U-Net, PGA-UNet) được huấn luyện dưới cùng thiết lập:

- **Batch size:** 4 (phù hợp giới hạn VRAM khi dùng ảnh 512×512).
- **Epochs tối đa:** 100, kết hợp Early Stopping (patience=15).
- **Optimizer:** AdamW với weight decay 10^{-4} .
- **Learning Rate:** Khởi điểm 10^{-4} , bộ lập lịch ReduceLRonPlateau (giảm $0.5 \times$ sau 5 epoch không cải thiện Dice xác thực).

Siêu tham số kiến trúc PGA-UNet (chi tiết triển khai): Các giá trị dưới đây là tham số cấu hình được xác định qua thực nghiệm trên tập xác thực; chúng là chi tiết triển khai, không phải đóng góp kỹ thuật cần kiểm chứng độc lập.

- **Hệ số w_l theo tầng giải mã (CAD):** $\{1.0, 0.7, 0.4, 0.2\}$ từ tầng 1 đến 4; lịch trình giảm dần này là lựa chọn thử nghiệm thực nghiệm, chưa có kiểm chứng ablation riêng về lịch trình tối ưu.
- **Hệ số kết nối dư (skip residual) λ** = 0.3 trong khối Conditioned Attention.

- **Kernel Gaussian Heatmap:** $k = 31$, padding 5 px mỗi cạnh hộp giới hạn.
- **Khởi tạo α_{gate} :** 0.1 (Prompt Spatial Gate), giúp ổn định huấn luyện giai đoạn đầu.

4.1.3 Phương pháp đánh giá image-level

Đặc điểm annotation của tập BTXRD. Trong tập kiểm thử, nhiều ảnh X-quang chứa *nhiều hơn một vùng tổn thương*: bác sĩ vẽ từng polygon riêng biệt cho mỗi tổn thương, dẫn đến tổng số 232 mẫu polygon trên 187 ảnh (trung bình ~ 1.24 polygon/ảnh). Nếu tính Dice riêng cho từng polygon, một ảnh có hai tổn thương sẽ đóng góp hai mẫu vào tập đánh giá, làm méo phân phối kết quả và tính nhiều lần trên cùng một bệnh nhân.

Cách tính image-level (đánh giá theo ảnh). Để khắc phục vấn đề trên và phản ánh trung thực hơn hiệu năng lâm sàng (một điểm số trên mỗi ảnh bệnh nhân), luận văn áp dụng phương pháp *image-level evaluation* sau cho PGA-UNet:

1. **Hợp nhất ground-truth (Union GT):** Với mỗi ảnh chứa $K \geq 1$ polygon, tất cả mask nhị phân GT $\{G_1, G_2, \dots, G_K\}$ được *hợp nhất* thành một mask GT duy nhất theo phép hợp tập:

$$M_{GT} = G_1 \cup G_2 \cup \dots \cup G_K \quad (4.2)$$

2. **Kết hợp dự đoán (Max-Merge Prediction):** Mô hình được chạy suy luận riêng cho từng bbox $\mathbf{B}_k$ tương ứng, sinh ra K mask xác suất $\{\hat{P}_1, \hat{P}_2, \dots, \hat{P}_K\}$ (giá trị $[0, 1]$ mỗi pixel). Các mask xác suất được kết hợp bằng phép lấy *giá trị lớn nhất theo pixel* (pixel-wise maximum):

$$\hat{M}_{\max}(x, y) = \max_{k=1}^K \hat{P}_k(x, y) \quad (4.3)$$

Sau đó ngưỡng hóa tại 0.5 để thu mặt nạ nhị phân cuối cùng $\hat{M}_{\text{pred}} = \mathbf{1}[\hat{M}_{\text{max}} \geq 0.5]$.

3. **Tính Dice image-level:** Chỉ số Dice được tính một lần duy nhất giữa $\hat{M}_{\text{pred}}$ và M_{GT} :

$$\text{Dice}_{\text{img}} = \frac{2 |M_{\text{GT}} \cap \hat{M}_{\text{pred}}|}{|M_{\text{GT}}| + |\hat{M}_{\text{pred}}|} \quad (4.4)$$

Metric cuối cùng được tính trung bình trên toàn bộ 187 ảnh kiểm thử. Phương pháp này đảm bảo mỗi ảnh bệnh nhân chỉ đóng góp **một điểm số**, tránh hiện tượng ảnh có nhiều tổn thương bị đếm nhiều lần và phản ánh trung thực hơn trải nghiệm đánh giá lâm sàng thực tế.

4.2 Đánh giá hiệu năng kiến trúc PGA-UNet

Để đo lường khách quan năng lực của kiến trúc PGA-UNet, quá trình thực nghiệm được tiến hành qua ba bước: (1) so sánh với mô hình cơ sở không có prompt (U-Net); (2) đánh giá tính bền bỉ trước sai số câu nhắc; (3) so sánh với SAM-Med2D (SOTA prompt-based). PGA-UNet và SAM-Med2D được đánh giá ở cấp độ ảnh (image-level, N=187 ảnh).

4.2.1 Đánh giá cơ sở (Baseline Comparison): U-Net vs. PGA-UNet

Trong kịch bản đánh giá đầu tiên, PGA-UNet (kịch bản câu nhắc Zoom-out lý tưởng) được so sánh với U-Net hoạt động hoàn toàn tự động (phân đoạn không có prompt).

Điều kiện so sánh: Về mặt kiến trúc, PGA-UNet được xây dựng trên khung encoder-decoder của U-Net, kế thừa cơ chế Attention Gate từ Attention U-Net [6] rồi mở rộng thành PSG+CAD có điều kiện hóa bởi prompt (chi tiết tại Chương 3). U-Net thuần túy (không có attention,

không có prompt) được chọn làm baseline định lượng để đo mức đóng góp tổng thể của toàn bộ chuỗi cải tiến. U-Net hoạt động theo cơ chế *tự động hoàn toàn* (chỉ nhận ảnh thô), trong khi PGA-UNet hoạt động *tương tác* (nhận thêm bounding box prompt). Sự chênh lệch hiệu năng phản ánh giá trị của việc tích hợp cơ chế chú ý có điều kiện và tri thức định hướng từ bác sĩ vào kiến trúc CNN. Đây là so sánh có chủ đích: minh chứng lợi ích của hướng tiếp cận prompt-guided so với segmentation tự động trên ảnh X-quang xương.

Bảng 4.2: So sánh hiệu năng phân đoạn: U-Net (tự động, N=187 ảnh) so với PGA-UNet kịch bản Zoom-out lý tưởng (prompt-guided, N=187 ảnh, image-level)

Mô hình	Dice↑	IoU↑	Precision↑	Recall↑	HD95↓	CBL↑
U-Net	0.4790	0.3815	0.6245	0.5184	146.06	0.5906
PGA-UNet (Zoom-out)	0.8584	0.7617	0.8526	0.8817	14.80	0.9500

Phân tích kết quả so sánh baseline:

- **Giới hạn của phân đoạn tự động:** U-Net gốc đạt Dice = 0.4790, phản ánh giới hạn cốt lõi khi phải tự tìm vùng tổn thương trên ảnh X-quang thô mà không có bất kỳ thông tin định hướng nào. Kết quả này là minh chứng cho thách thức của phân đoạn hoàn toàn tự động trên ảnh X-quang xương có độ tương phản thấp và cấu trúc giải phẫu chồng lấp.
- **Giá trị của hướng tiếp cận tương tác:** PGA-UNet (kịch bản Zoom-out lý tưởng) đạt Dice = 0.8584, vượt trội hoàn toàn so với U-Net tự động (+0.3794). Kết quả này cho thấy cơ chế PSG và CAD chỉ phát huy hiệu quả khi được “neo” bởi tín hiệu định hướng rõ ràng từ bên ngoài (prompt), giải quyết đúng hạn chế cốt lõi của phân đoạn tự động. Đáng lưu ý, cả hai mô hình đều hoạt động trên ảnh đã resize về 512×512 (từ ảnh gốc BTXRD 2.000–3.000 px, tương đương còn $\frac{1}{4}$ – $\frac{1}{6}$ diện tích gốc). Kết quả so sánh cho thấy: ngay cả khi

thông tin không gian đầu vào bị thu nhỏ đáng kể, tín hiệu câu nhắc bounding box vẫn đủ để PGA-UNet phục hồi hiệu năng phân đoạn, minh chứng trực tiếp cho giá trị của cơ chế câu nhắc trực quan trong điều kiện độ phân giải bị giới hạn.

4.2.2 Đánh giá tính bền bỉ (Robustness): Kịch bản Zoom-out, Shift và Mixed

Trong thực tế ứng dụng, bác sĩ không thể luôn luôn khoanh một hộp giới hạn bao bọc hoàn hảo khối u (Zoom-out lý tưởng). Sẽ có những lúc mỗi mắt hoặc do góc nhìn chủ quan khiến khung khoanh bị lệch đi một phần so với vị trí trung tâm thực sự. Để kiểm chứng xem PGA-UNet có bị phụ thuộc quá mức vào vị trí tâm câu nhắc hay không, hệ thống được thử nghiệm trên 3 kịch bản:

1. **100% Zoom-out:** Câu nhắc lý tưởng, bao trọn vẹn tổn thương, cận trên hiệu năng của mô hình.
2. **100% Shift (Lệch tâm):** Câu nhắc bị cố tình dịch chuyển lệch khỏi tâm tổn thương một lượng ngẫu nhiên, điều kiện xấu nhất thực tế, mô phỏng bác sĩ mất tập trung.
3. **Mixed (70% Zoom-out + 30% Shift):** Pha trộn theo tỷ lệ ước lượng trong lâm sàng thực tế, phần lớn câu nhắc đúng, một phần nhỏ bị lệch.

Lý do chọn 3 kịch bản này và không dùng nhiều mạnh hơn: Ba mức độ bao phủ toàn bộ phổ sai số câu nhắc hiện thực trong lâm sàng từ hoàn hảo đến lệch tâm. Kịch bản Shift được thiết kế đảm bảo ít nhất 30% diện tích hộp giới hạn giao với vùng tổn thương thực ($\text{overlap} \geq 30\%$), phản ánh sai số thực tế của bác sĩ: bác sĩ luôn có thông tin sơ bộ về vùng nghi ngờ, sai số lâm sàng thường là lệch tâm, không phải sai hoàn toàn vị trí. Kịch bản Shift 100% đã đại diện cho mức nhiễu cực đoan nhất

khả thi trong thực tế và cho thấy PGA-UNet vẫn duy trì $\text{Dice} = 0.8454$, đủ để kết luận về tính bền bỉ.

Trường hợp câu nhắc sai hoàn toàn vị trí: Nếu bác sĩ khoanh hộp hoàn toàn không liên quan đến vùng tổn thương thực, PGA-UNet (như mọi hệ thống phân đoạn tương tác) sẽ phân đoạn tại vùng được chỉ định thay vì vùng tổn thương thực. Đây là hành vi đúng về mặt thiết kế: mô hình thực hiện đúng chỉ dẫn của bác sĩ; nếu mô hình có thể tự sửa hướng dẫn sai của bác sĩ thì cơ chế tương tác mất đi ý nghĩa và bác sĩ trở thành thừa. Trách nhiệm định hướng đúng thuộc về bác sĩ; mô hình đảm nhiệm việc phân đoạn chính xác trong vùng được chỉ định. Vì lý do này, kịch bản bbox sai hoàn toàn không được đưa vào đánh giá định lượng.

Bảng 4.3: Đánh giá tính bền bỉ của PGA-UNet trên 3 kịch bản prompt (N=187 ảnh, image-level)

Kịch bản prompt	Dice $\uparrow$	IoU $\uparrow$	Precision $\uparrow$	Recall $\uparrow$	HD95 $\downarrow$	CBL $\uparrow$
Zoom-out (100%, lý tưởng)	0.8584	0.7617	0.8526	0.8817	14.80	0.9500
Shift (100%, lệch tâm)	0.8454	0.7432	0.8462	0.8630	13.89	0.9435
Mixed (70% Zoom-out + 30% Shift)	0.8554	0.7571	0.8531	0.8762	15.41	0.9474

Phân tích tính bền bỉ: Số liệu thực nghiệm (Bảng 4.3) khẳng định đặc tính "hướng dẫn mềm" (soft guidance) của kiến trúc PGA-UNet. Khi đối mặt với kịch bản câu nhắc lệch tâm hoàn toàn (100% Shift), hiệu năng phân đoạn chỉ giảm từ $\text{Dice} = 0.8584$ (Zoom-out) xuống $\text{Dice} = 0.8454$ (Shift), chênh lệch 0.0130, không đáng kể. Kịch bản Mixed (70% Zoom-out + 30% Shift) đạt $\text{Dice} = 0.8554$, xác nhận mô hình duy trì hiệu năng ổn định trong môi trường thực tế.

Kết quả cho thấy mô hình **không** ghi nhớ cứng nhắc vị trí tâm bản đồ nhiệt câu nhắc. Thay vào đó, PGA-UNet sử dụng câu nhắc để thu hẹp vùng tìm kiếm, nhưng ở các lớp giải mã cuối, mạng dựa vào đặc trưng gradient thực tế của ảnh (bờ xương, đường viền u) để xác định ranh giới. Tính bền bỉ này là một yếu tố quan trọng khi xét đến khả năng triển khai hệ thống trong thực tế lâm sàng.

4.2.3 So sánh với SAM-Med2D (SOTA Prompt-based)

Để đánh giá đầy đủ hơn, mô hình PGA-UNet được so sánh trực tiếp với SAM-Med2D [3], mô hình SOTA prompt-based dựa trên kiến trúc ViT-B ($\sim 91\text{M}$ tham số [3], fine-tuned từ 4.6M ảnh y tế 2D). PGA-UNet và SAM-Med2D được đánh giá ở cấp độ image-level ($N=187$ ảnh); cùng 3 kịch bản prompt.

Lưu ý điều kiện so sánh về độ phân giải: SAM-Med2D bắt buộc sử dụng độ phân giải 256×256 do position embedding của ViT-B được cố định theo kích thước này bởi tác giả gốc; muốn chạy ở độ phân giải lớn hơn đòi hỏi huấn luyện lại từ đầu với chi phí rất lớn. Ngược lại, PGA-UNet là kiến trúc CNN thuần túy, hoàn toàn linh hoạt về kích thước đầu vào và được chọn chạy ở 512×512 để tận dụng tối đa thông tin không gian của ảnh X-quang. Sự chênh lệch độ phân giải này là *hạn chế cố hữu của SAM-Med2D trong môi trường ảnh y tế chi tiết cao*, không phải điều kiện thực nghiệm do nhóm áp đặt; do đó các kết luận về hiệu năng nên được đọc trong ngữ cảnh này thay vì so sánh trực tiếp như kiểm định công bằng tuyệt đối.


Bảng 4.4: So sánh toàn diện PGA-UNet với SAM-Med2D fine-tuned và SAM-Med2D zero-shot trên 3 kịch bản prompt. PGA-UNet: image-level ($N=187$ ảnh); SAM-Med2D: image-level ($N=187$ ảnh). HD95* chuẩn hóa theo kích thước ảnh: $\text{PGA} \div 512$, $\text{SAM} \div 256$.

Mô hình	Kịch bản	Dice $\uparrow$	IoU $\uparrow$	Pre $\uparrow$	Rec $\uparrow$	HD95*(norm) $\downarrow$	CBL $\uparrow$
PGA-UNet	Zoom-out	0.8584	0.7617	0.8526	0.8817	0.029	0.9500
PGA-UNet	Shift	0.8454	0.7432	0.8462	0.8630	0.027	0.9435
PGA-UNet	Mixed	0.8554	0.7571	0.8531	0.8762	0.030	0.9474
SAM-Med2D (FT)	Zoom-out	0.7432	0.6238	0.7634	0.7570	0.035	0.8919
SAM-Med2D (FT)	Shift	0.7159	0.5901	0.7480	0.7187	0.037	0.8759
SAM-Med2D (FT)	Mixed	0.7355	0.6136	0.7605	0.7462	0.036	0.8884
SAM-Med2D (ZS)	Zoom-out	0.5438	0.4023	0.4743	0.6776	0.068	0.8428
SAM-Med2D (ZS)	Shift	0.5262	0.3842	0.4569	0.6531	0.083	0.8006
SAM-Med2D (ZS)	Mixed	0.5408	0.3983	0.4705	0.6726	0.073	0.8303

Phân tích kết quả so sánh PGA vs SAM-Med2D:

- **PGA vượt trội nhất quán:** Trên kịch bản Zoom-out lý tưởng, PGA-UNet đạt $\text{Dice} = 0.8584$, vượt SAM-Med2D fine-tuned ($\text{Dice} = 0.7432$) và SAM zero-shot ($\text{Dice} = 0.5438$). Sự chênh lệch lớn giữa SAM fine-tuned và zero-shot cho thấy fine-tuning trên dữ liệu miền đặc thù là cần thiết, và PGA vượt qua cả SAM đã được fine-tuned dù chỉ với $\sim 3\text{M}$ tham số. Điều này đặc biệt có ý nghĩa vì PGA-UNet được huấn luyện **hoàn toàn từ đầu** trên BTXRD (toàn bộ $\sim 3\text{M}$ tham số tham gia backpropagation, không đóng băng bất kỳ thành phần nào), trong khi SAM-Med2D kế thừa trọng số ViT-B đã học từ 4.6M ảnh y tế 2D, xem Bảng 3.2 tại Chương 3 để biết chi tiết.
- **Lợi thế HD95:** Sau chuẩn hóa theo kích thước ảnh, PGA có HD95/imgsize thấp hơn SAM đáng kể, cho thấy PGA bám biên sát hơn.
- **Tham số hiệu quả:** PGA ($\sim 3\text{M}$, toàn bộ trainable) vượt SAM-Med2D ($\sim 91\text{M}$ tổng, chỉ $\sim 15\text{M}$ trainable gồm Adapter + Decoder), cho thấy kiến trúc nhẹ được thiết kế đặc thù cho bài toán có thể hiệu quả hơn foundation model đa mục đích trên miền dữ liệu hẹp này.
- **SAM hội tụ rất nhanh:** SAM-Med2D hội tụ sớm nhờ lợi thế pretrained từ 4.6M ảnh y tế 2D, nhưng kiến trúc ViT-B với resolution 256 là giới hạn vốn có trên ảnh X-quang chi tiết.
- **PGA bền bỉ hơn SAM trước sai số câu nhắc:** Nhìn vào mức sụt giảm Dice khi chuyển từ kịch bản Zoom-out sang Shift, PGA-UNet chỉ giảm $0.8584 \rightarrow 0.8454$ (-0.0130 , tương đương -1.5%), trong khi SAM-Med2D fine-tuned giảm $0.7432 \rightarrow 0.7159$ (-0.0273 , tương đương -3.6%). Đây là kết quả đáng chú ý: mô hình được thiết kế đặc thù cho bài toán với cơ chế “hướng dẫn mềm” (Gaussian heatmap + PSG + CAD) không chỉ vượt trội về điểm tuyệt đối mà còn **bền bỉ hơn chính mô hình nền tảng prompt-based** (SAM-Med2D) vốn được huấn luyện trên hàng triệu ảnh y tế. Kết quả này gợi ý

rằng trên miền bài toán hẹp, thiết kế kiến trúc đặc thù có thể đóng vai trò quan trọng không kém quy mô tham số khi xét đến tính ổn định với sai số câu nhắc.



Hình 4.1: So sánh Dice Score giữa U-Net (không prompt), PGA-UNet và SAM-Med2D (fine-tuned, zero-shot) trên ba kịch bản prompt (Zoom-out, Shift, Mixed), tổng hợp trực quan từ Bảng 4.2, 4.3 và 4.4.

4.2.4 Kiểm chứng công bằng tại cùng độ phân giải 256×256

Để loại bỏ yếu tố độ phân giải khỏi so sánh, PGA-UNet được huấn luyện lại từ đầu trên cùng bộ dữ liệu BTXRD nhưng với kích thước đầu vào 256×256 (thay vì 512×512), tạo ra điều kiện so sánh hoàn toàn công bằng với SAM-Med2D vốn bị giới hạn ở độ phân giải này. Trọng số SAM-Med2D fine-tuned được giữ nguyên; chỉ PGA-UNet được huấn luyện lại.

Phân tích: Kết quả Bảng 4.5 xác nhận rằng ưu thế của PGA-UNet không đến từ lợi thế độ phân giải. Ở cùng 256×256 , PGA-UNet vẫn vượt SAM-Med2D fine-tuned trên cả 3 kịch bản (Zoom-out: $+0.1070$, Shift: $+0.0951$, Mixed: $+0.1034$ Dice). Đáng lưu ý, mức sụt giảm Dice khi chuyển từ Zoom-out sang Shift của PGA ở 256×256 là -0.0372 ($0.8420 \rightarrow 0.8048$),

Bảng 4.5: So sánh công bằng PGA-UNet (256×256) vs SAM-Med2D (256×256) trên 3 kịch bản prompt. PGA-UNet (256): image-level (N=187 ảnh); SAM-Med2D: image-level (N=187 ảnh).

Mô hình	Kịch bản	Dice $\uparrow$	IoU $\uparrow$	Pre $\uparrow$	Rec $\uparrow$	HD95 $\downarrow$	CBL $\uparrow$
PGA-UNet (256)	Zoom-out	0.8420	0.7348	0.8062	0.8966	6.14	0.9479
PGA-UNet (256)	Shift	0.8048	0.6833	0.7798	0.8476	7.77	0.9202
PGA-UNet (256)	Mixed	0.8317	0.7209	0.7998	0.8817	6.57	0.9400
SAM-Med2D (FT, 256)	Zoom-out	0.7432	0.6238	0.7634	0.7570	9.17	0.8919
SAM-Med2D (FT, 256)	Shift	0.7159	0.5901	0.7480	0.7187	9.70	0.8759
SAM-Med2D (FT, 256)	Mixed	0.7355	0.6136	0.7605	0.7462	9.27	0.8884

lớn hơn so với PGA ở 512×512 (-0.0130), phù hợp với nhận định rằng độ phân giải cao hơn giúp mô hình bền bỉ hơn trước sai số câu nhắc. Điều này cũng đồng thời khẳng định: lựa chọn 512×512 là tốt nhất cho PGA-UNet, và việc so sánh PGA@512 với SAM@256 trong Bảng 4.4 là hoàn toàn hợp lý vì đó là cấu hình tối ưu của mỗi mô hình.

4.2.5 So sánh hiệu quả tính toán

Ngoài hiệu năng phân đoạn, tính khả thi triển khai trong môi trường lâm sàng đòi hỏi mô hình phải đủ nhẹ để chạy trên phần cứng y tế tuyến cơ sở. Bảng 4.6 so sánh toàn diện giữa PGA-UNet và SAM-Med2D về các chỉ số tính toán.

Bảng 4.6: So sánh hiệu quả tính toán: PGA-UNet vs SAM-Med2D

Chỉ số	PGA-UNet (đề xuất)	SAM-Med2D
Tổng tham số	$\sim 3\text{M}$	$\sim 91\text{M}$ (ViT-B) + Adapter
Tham số huấn luyện được	$\sim 3\text{M}$ (100%)	$\sim 15\text{M}$ (Adapter + Decoder)
Độ phân giải ảnh	512×512	256×256 (cố định)
VRAM huấn luyện (batch=4)	~ 3 GB	~ 6 GB
VRAM suy luận (batch=1)	~ 1 GB	~ 2 GB
Có thể chạy trên GPU 4GB	✓	Hạn chế

4.3 Phân tích kiến trúc và khả năng tổng quát hóa

Mục này trình bày hai nhóm thực nghiệm bổ sung: (1) ablation study so sánh các cấu hình kiến trúc PSG/CAD; (2) kiểm định độ ổn định bằng đánh giá chéo 4-fold.

4.3.1 Ablation kiến trúc: Đóng góp của PSG và CAD

Năm biến thể kiến trúc được huấn luyện lại hoàn toàn từ đầu trên cùng tập BTXRD, chỉ thay đổi cấu hình PSG/CAD và loại câu nhắc:

- **V1:** No PSG, No CAD (chỉ concatenate heatmap).
- **V2:** PSG only (không có CAD).
- **V3:** CAD only (không có PSG).
- **V4:** PSG + CAD với Binary bbox làm câu nhắc.
- **V5 (đề xuất):** PSG + CAD với Gaussian Heatmap làm câu nhắc.

Thiết kế năm biến thể này cho phép cô lập đóng góp riêng lẻ của PSG (V2 so V1), CAD (V3 so V1), tổ hợp cả hai (V4 so V2/V3) và ảnh hưởng của loại câu nhắc Gaussian vs Binary (V5 so V4). Kết quả được trình bày trong Bảng 4.7.

Bảng 4.7: Ablation study: Dice Score trên 3 kịch bản prompt của 5 biến thể kiến trúc PGA-UNet (N=187 ảnh, image-level). V5 là mô hình đề xuất.


Biến thể	PSG	CAD	Prompt	Zoom-out↑	Shift↑	Mixed↑
V1: Baseline (concat heatmap)	×	×	Gaussian	0.8739	0.7268	0.8169
V2: PSG only	✓	×	Gaussian	0.8635	0.7348	0.8137
V3: CAD only	×	✓	Gaussian	0.8862	0.7410	0.8289
V4: Full PGA + Binary prompt	✓	✓	Binary	0.8834	0.7433	0.8307
V5: Full PGA + Gaussian (đề xuất)	✓	✓	Gaussian	0.8584	0.8454	0.8554

Phân tích ablation: Hai quan sát chính từ Bảng 4.7:

(1) **Đóng góp của PSG và CAD:** V3 (CAD only, Zoom=0.8862) cao hơn V2 (PSG only, Zoom=0.8635) cho thấy CAD đóng góp nhiều hơn vào hiệu năng Zoom-out; song cả hai đều thua V5 trong kịch bản Shift (V2: 0.7348, V3: 0.7410 so với V5: 0.8454), xác nhận kiến trúc đầy đủ PSG+CAD là cần thiết.

(2) **Trade-off Gaussian vs Binary prompt (V5 vs V4):** Đây là phát hiện đáng chú ý. Khi chuyển từ Binary bbox sang Gaussian heatmap, Dice Shift tăng mạnh +0.1021 (0.7433 $\rightarrow$ 0.8454), Dice Mixed tăng +0.0247 (0.8307 $\rightarrow$ 0.8554), trong khi Dice Zoom-out giảm nhẹ -0.0250 (0.8834 $\rightarrow$ 0.8584). **Trade-off này là có chủ đích:** Gaussian heatmap "làm mờ" đường biên tín hiệu câu nhắc, buộc mô hình không thể ghi nhớ cứng nhắc vị trí tâm bounding box. Hệ quả là robustness cải thiện vượt trội khi câu nhắc bị lệch, trong khi hiệu năng với câu nhắc lý tưởng chỉ suy giảm không đáng kể. Trong môi trường lâm sàng thực tế, khả năng chịu đựng sai số câu nhắc quan trọng hơn điểm Dice tuyệt đối với câu nhắc hoàn hảo, V5 tối ưu cho đúng mục tiêu này.

(3) **Đóng góp riêng lẻ của kiến trúc PSG+CAD (V5 vs V1):** Để tách biệt đóng góp của kiến trúc khỏi đóng góp của cách mã hóa câu nhắc, cả bốn biến thể V1–V3 và V5 đều dùng Gaussian heatmap, chỉ thay đổi cấu hình PSG/CAD. So sánh trực tiếp: PSG đơn độc (V2 vs V1): Shift chỉ tăng +0.0080; CAD đơn độc (V3 vs V1): +0.0142; nhưng PSG+CAD kết hợp với Gaussian (V5 vs V1): **+0.1186** (0.7268 $\rightarrow$ 0.8454), gấp hơn 5 lần tổng hai đóng góp riêng lẻ (0.0080 + 0.0142 = 0.0222). Hiệu ứng tương hỗ này cho thấy PSG và CAD phối hợp với nhau để tận dụng tối đa tín hiệu gradient liên tục của Gaussian heatmap: PSG định hướng encoder tập trung vào vùng câu nhắc, CAD duy trì tín hiệu đó xuyên suốt decoder; khi thiếu một trong hai, tín hiệu bị suy giảm trước khi đến đầu ra.



Hình 4.2: Ablation study: Dice Score của 5 biến thể kiến trúc PGA-UNet trên ba kịch bản prompt (Bảng 4.7). V5 (đề xuất, xanh dương) thấp hơn nhẹ ở Zoom-out nhưng vượt trội rõ rệt ở Shift so với bốn biến thể còn lại (xám).

4.3.2 Kiểm định độ ổn định bằng đánh giá chéo (Cross-validation)

Để xác minh tính ổn định và khả năng tổng quát hóa của PGA-UNet không phụ thuộc vào một lần phân chia dữ liệu duy nhất, mô hình được đánh giá chéo trên 4 phân vùng dữ liệu khác nhau. Kết quả trình bày tại Bảng 4.8.

Bảng 4.8: Kết quả đánh giá chéo 4-fold PGA-UNet trên 3 kịch bản prompt (trung bình 4 fold)

Kịch bản	Dice↑	IoU↑	Precision↑	Recall↑	HD95↓	CBL↑
Zoom-out	0.8809	0.7936	0.8578	0.9149	11.05	0.9620
Shift	0.8570	0.7589	0.8453	0.8824	13.08	0.9459
Mixed (70% Zoom-out + 30% Shift)	0.8747	0.7845	0.8561	0.9049	11.39	0.9576

Bảng 4.9 cho thấy Dice Score dao động rất nhỏ giữa các fold: độ lệch chuẩn thấp nhất ở kịch bản Zoom-out (± 0.0021) và lớn nhất ở Shift (± 0.0085), biên độ hoàn toàn chấp nhận được trong nghiên cứu y tế. Kết quả này xác nhận mô hình hội tụ ổn định trên các phân vùng dữ liệu khác nhau, không bị phụ thuộc vào một cách chia cụ thể. Các chỉ số cross-

Bảng 4.9: Dice Score từng fold trong đánh giá chéo 4-fold PGA-UNet (kịch bản Zoom-out / Shift / Mixed)

Fold	Zoom-out $\uparrow$	Shift $\uparrow$	Mixed $\uparrow$
Fold 1	0.8778	0.8461	0.8693
Fold 2	0.8832	0.8679	0.8788
Fold 3	0.8801	0.8518	0.8728
Fold 4	0.8825	0.8620	0.8779
Trung bình $\pm$ Std	0.8809 $\pm$ 0.0021	0.8570 $\pm$ 0.0085	0.8747 $\pm$ 0.0039

validation nhỉnh hơn tập test chính một chút (Dice Zoom-out: 0.8809 vs 0.8584) phản ánh sự khác biệt tự nhiên giữa dữ liệu huấn luyện và tập kiểm thử độc lập được giữ lại hoàn toàn từ đầu.

Tính ổn định thống kê và độ tin cậy kết quả: Hai bảng chứng hỗ trợ tính tin cậy của các số liệu đã báo cáo. Thứ nhất, độ lệch chuẩn Dice qua 4 fold rất thấp (± 0.0021 ở Zoom-out, ± 0.0085 ở Shift), cho thấy kết quả không phụ thuộc vào một cách phân chia dữ liệu cụ thể. Thứ hai, biên độ chênh lệch giữa các mô hình rất lớn so với độ lệch chuẩn: ví dụ, V5 cải thiện Shift Dice lên $+0.1021$ so với V4 (0.8454 vs 0.7433) trong khi std chỉ ± 0.0085 , tỷ lệ signal-to-noise > 12 . Để xác nhận ý nghĩa thống kê một cách chính thức, kiểm định Wilcoxon signed-rank (phi tham số, phù hợp vì phân phối Dice không đảm bảo chuẩn) trên 187 cặp Dice image-level là bước kiểm định được khuyến nghị cho cặp so sánh V4 vs V5 (cùng paradigm image-level); với cặp PGA vs SAM-Med2D, do hai mô hình có đơn vị đánh giá khác nhau (image-level vs. per-polygon), cần tái tính Dice trên cùng đơn vị trước khi kiểm định.

4.3.3 Đánh giá theo đặc tính tổn thương (Sub-Category)

Để đánh giá sâu hơn khả năng tổng quát hóa của PGA-UNet, ba phân tích sub-category được thực hiện: **(1)** so sánh PGA-UNet với U-Net trên nhóm *Dễ* (top-50 U-Net Dice) và *Khó* (bottom-50 U-Net Dice), trên $N =$

187 ảnh (50 ảnh mỗi nhóm); **(2)** so sánh PGA-UNet với SAM-Med2D trên ba nhóm đặc tính lâm sàng (Tổn thương nhỏ, Biên giới mờ, Tổn thương rõ nét), mỗi nhóm 50 ảnh image-level; **(3)** kiểm chứng công bằng cùng độ phân giải 256×256 để loại trừ lợi thế độ phân giải khi so sánh PGA-UNet với SAM-Med2D.

PGA-UNet so với U-Net theo độ khó tác vụ

Ở nhóm *Dễ* (tương phản cao, hình dạng rõ), U-Net vẫn hoạt động được; PGA kỳ vọng cải thiện thêm đáng kể. Ở nhóm *Khó* (tương phản thấp, xương chồng lấp, hình dạng bất thường), U-Net thiếu thông tin định hướng nên dự đoán suy giảm mạnh, trong khi PGA-UNet nhờ cơ chế prompt guidance kỳ vọng duy trì Dice ổn định hơn, đây là lý do cốt lõi cho sự tồn tại của hướng tiếp cận tương tác.

Bảng 4.10: So sánh hiệu năng PGA-UNet với U-Net theo độ khó tác vụ (50 ảnh mỗi nhóm, image-level; phân nhóm dễ nhất / khó nhất theo Dice của U-Net)

Nhóm	Mô hình	Dice	IoU	Pre	Rec	HD95 (px)	CBL
Dễ (top-50)	U-Net	0.8615	0.7594	0.8596	0.8764	56.02	0.9391
	PGA-UNet	0.8982	0.8179	0.8730	0.9304	12.57	0.9627
Khó (bottom-50)	U-Net	0.0062	0.0032	0.0434	0.0393	307.14	0.0665
	PGA-UNet	0.8120	0.7045	0.8222	0.8202	18.97	0.9252

Kết quả Bảng 4.10 xác nhận rõ ràng giả thuyết lý thuyết. Ở nhóm *Dễ* (top-50), U-Net đạt Dice = 0.8615 trong khi PGA-UNet đạt 0.8982 ($\Delta = +0.0367$), cải thiện có ý nghĩa nhưng không đột biến vì tổn thương đã rõ. Ở nhóm *Khó* (bottom-50), U-Net gần như sụp đổ hoàn toàn, chỉ còn Dice = 0.0062 (HD95 = 307.14 px); trong khi đó PGA-UNet **duy trì ổn định ở 0.8120** ($\Delta = +0.8058$ so với U-Net). Kết quả này cho thấy cơ chế prompt spatial gate có vai trò quan trọng trong khả năng xử lý nhất quán các ca bệnh phức tạp.

PGA-UNet so với SAM-Med2D theo đặc tính lâm sàng

Ba quan sát chính dự kiến: (1) **Tổn thương nhỏ**: SAM-Med2D hoạt động ở độ phân giải 256×256 khiến các tổn thương nhỏ chỉ còn vài pixel, SAM bỏ sót phần lớn diện tích, trong khi PGA ở 512×512 với heatmap dẫn đường đạt kết quả tốt hơn đáng kể. (2) **Biên giới mờ**: ranh giới tổn thương không rõ ràng trên X-quang xương đặc thù BTXRD, SAM pretrain đa dạng nhưng không chuyên biệt hóa đặc trưng gradient X-quang xương; PGA train from scratch trên BTXRD học được các đặc trưng cụ thể này. (3) **Tổn thương rõ nét**: khi tổn thương lớn và ranh giới rõ, cả hai mô hình đều hoạt động tốt; PGA nhỉnh hơn SAM với $\sim 30 \times$ ít tham số hơn.


Bảng 4.11: So sánh PGA-UNet với SAM-Med2D trên ba nhóm đặc tính lâm sàng (kịch bản Zoom-out, 50 ảnh mỗi nhóm, image-level)

Nhóm	Mô hình	Dice	IoU	Pre	Rec	HD95 (px)	CBL
Tổn thương nhỏ	SAM-Med2D	0.4365	0.3235	0.6133	0.3810	62.62	0.7218
	PGA-UNet	0.8124	0.7033	0.7873	0.8571	13.57	0.9251
Biên giới mờ	SAM-Med2D	0.6567	0.5017	0.7900	0.6112	27.99	0.9004
	PGA-UNet	0.8544	0.7503	0.8483	0.8729	15.31	0.9551
Tổn thương rõ nét	SAM-Med2D	0.8588	0.7556	0.8936	0.8331	22.55	0.9564
	PGA-UNet	0.8730	0.7835	0.8576	0.8966	21.68	0.9604

Kết quả Bảng 4.11 xác nhận cả ba nhận định. **Tổn thương nhỏ**: PGA đạt Dice = 0.8124 trong khi SAM chỉ đạt 0.4365 ($\Delta = +0.3759$), khoảng cách lớn nhất trong ba nhóm, phù hợp với giả thuyết về ảnh hưởng của độ phân giải 512×512 so với 256×256 đối với tổn thương nhỏ. **Biên giới mờ**: PGA = 0.8544 vs SAM = 0.6567 ($\Delta = +0.1977$), cho thấy đặc trưng X-quang xương chuyên biệt mà PGA học được trên BTXRD. **Tổn thương rõ nét**: khoảng cách thu hẹp đáng kể (PGA = 0.8730, SAM = 0.8588, $\Delta = +0.0143$), cả hai mô hình hoạt động tốt khi điều kiện thuận lợi; PGA vẫn nhỉnh hơn với kiến trúc nhỏ gọn hơn $\sim 30 \times$.

Kiểm chứng công bằng Sub-Category tại cùng 256×256

Để loại trừ hoàn toàn lợi thế độ phân giải, phân tích sub-category được lặp lại với PGA-UNet₂₅₆ (huấn luyện và suy luận tại 256×256) đối chiếu



Hình 4.3: So sánh PGA-UNet và SAM-Med2D theo ba nhóm đặc tính lâm sàng trên BTXRD (Bảng 4.11): khoảng cách lớn nhất ở nhóm Tổn thương nhỏ, thu hẹp dần ở nhóm Tổn thương rõ nét.

trực tiếp với SAM-Med2D (256×256). Cả hai mô hình cùng nhóm mẫu, cùng bounding box, chỉ khác checkpoint PGA.

Bảng 4.12: So sánh công bằng PGA-UNet₂₅₆ vs SAM-Med2D theo đặc tính lâm sàng (kích bản Zoom-out, 50 ảnh image-level mỗi nhóm, cùng 256×256)

Nhóm	Mô hình	Dice	IoU	Pre	Rec	HD95 (px)	CBL
Tổn thương nhỏ	SAM-Med2D	0.4365	0.3235	0.6133	0.3810	62.62	0.7218
	PGA-UNet ₂₅₆	0.6836	0.5377	0.5825	0.9051	5.94	0.9087
Biên giới mờ	SAM-Med2D	0.6567	0.5017	0.7900	0.6112	27.99	0.9004
	PGA-UNet ₂₅₆	0.8000	0.6731	0.7362	0.8992	17.84	0.9410
Tổn thương rõ nét	SAM-Med2D	0.8588	0.7556	0.8936	0.8331	22.55	0.9564
	PGA-UNet ₂₅₆	0.8689	0.7731	0.8347	0.9133	22.84	0.9525

Bảng 4.12 xác nhận kết luận chính vẫn đúng khi kiểm soát yếu tố độ phân giải: PGA-UNet₂₅₆ vượt SAM-Med2D ở cả ba nhóm về Dice (+0.2471 ở tổn thương nhỏ, +0.1433 ở biên giới mờ, +0.0101 ở tổn thương rõ nét). Đáng chú ý, ở nhóm **Tổn thương nhỏ**, dù PGA có Precision thấp hơn SAM (0.5825 vs 0.6133) nhưng Recall vượt trội (0.9051 vs 0.3810), nghĩa là SAM bỏ sót phần lớn tổn thương nhỏ trong khi PGA phát hiện được hầu hết; HD95 của PGA₂₅₆ (5.94 px) cũng thấp hơn SAM (62.62 px) rất đáng

kể, cho thấy khi PGA phân đoạn được tổn thương nhỏ thì đường biên bám sát hơn nhiều. So sánh Bảng 4.11 (PGA@512 vs SAM@256) với Bảng 4.12 (cùng 256) cho thấy nhóm Tổn thương nhỏ được hưởng lợi nhiều nhất từ độ phân giải cao (PGA@512: 0.8124 vs PGA@256: 0.6836, $\Delta = +0.1288$), trong khi nhóm Tổn thương rõ nét ít nhạy hơn ($\Delta = +0.0041$).

4.4 Đánh giá khả năng tổng quát hóa liên miền dữ liệu (Cross-dataset: FracAtlas)

Toàn bộ kết quả trình bày từ Mục 4.2 đến Mục 4.3.3 đều được huấn luyện và đánh giá trên BTXRD. Để kiểm chứng kiến trúc PGA-UNet và quy trình huấn luyện không chỉ “phù hợp” với một bộ dữ liệu cụ thể, mục này lặp lại các thực nghiệm cốt lõi (so sánh PGA vs SAM-Med2D, đánh giá theo 3 kích bản prompt, phân tích sub-category) trên một bộ dữ liệu X-quang xương độc lập thứ hai: **FracAtlas**. Đây là bộ dữ liệu có nguồn gốc, quy trình thu thập và đặc điểm tổn thương (gãy xương, dạng đường nứt mảnh, tuyến tính) khác biệt với BTXRD (u xương, dạng khối/mảng), phù hợp để kiểm tra khả năng tổng quát hóa domain.

4.4.1 Giới thiệu bộ dữ liệu FracAtlas

FracAtlas [1] là bộ dữ liệu X-quang công khai tập trung vào gãy xương (fracture), thu thập từ 3 bệnh viện tại Bangladesh với tổng cộng 4.083 ảnh X-quang vùng tay, vai, hông và chân, trong đó 717 ảnh có bệnh lý (922 vùng gãy xương được khoanh vùng). Nhãn được xây dựng qua quy trình hai giai đoạn: hai bác sĩ X-quang (radiologist) độc lập xác định vị trí gãy, sau đó một bác sĩ chỉnh hình (orthopedic surgeon) đối chiếu và giải quyết bất đồng; mặt nạ đa giác (polygon mask) được vẽ thủ công bằng công cụ mã nguồn mở `makesense.ai` theo định dạng COCO JSON. Cấu trúc nhãn ba cấp (phân lớp, bounding box định vị, mặt nạ phân đoạn pixel-level) tương đồng với BTXRD nên có thể tái sử dụng trực tiếp toàn bộ pipeline

huấn luyện/suy luận (PGA-UNet, SAM-Med2D) mà không cần thay đổi kiến trúc hay hàm mất mát. Điểm khác biệt cốt lõi so với BTXRD là đặc tính hình thái tổn thương: đường gãy xương thường mảnh, tuyến tính và có diện tích nhỏ hơn nhiều so với khối u xương, tạo ra một phép thử tổng quát hóa có ý nghĩa cho cơ chế Prompt Spatial Gate và Conditioned Attention.

Bảng 4.13: Thống kê phân bố bộ dữ liệu FracAtlas dùng trong thực nghiệm (đơn vị: mẫu per-polygon)

Tập dữ liệu	Số ảnh	Số mẫu (per-polygon)	Ghi chú
Huấn luyện (Train)	573	730	
Xác thực (Validation)	72	95	
Kiểm thử (Test)	72	92	Trung bình ~ 1.28 polygon/ảnh

Kiểm tra chéo số liệu: Tổng số mẫu per-polygon dùng trong ba tập của khóa luận ($730 + 95 + 92 = 917$) khớp gần đúng với con số 922 vùng gãy xương (fracture instances) mà bài báo gốc công bố trên 717 ảnh bệnh lý [1]; chênh lệch nhỏ (5 mẫu, $<1\%$) hợp lý do một số polygon bị loại trong bước tiền xử lý (ví dụ polygon quá nhỏ hoặc lỗi định dạng), củng cố độ tin cậy của quy trình chuẩn bị dữ liệu.

Quy mô huấn luyện của FracAtlas (730 mẫu) nhỏ hơn đáng kể so với BTXRD (1 493 mẫu, chỉ bằng $\approx 49\%$), đây là điều kiện thực nghiệm khắc khe hơn để đánh giá khả năng học đặc trưng của PGA-UNet với ít dữ liệu huấn luyện hơn.

4.4.2 PGA-UNet toàn diện trên FracAtlas (256×256 và 512×512 , ba kịch bản prompt)

Tương tự Mục 4.2.3 và 4.2.4, PGA-UNet được huấn luyện lại từ đầu trên FracAtlas ở cả hai độ phân giải 256×256 và 512×512 , đánh giá trên cả ba kịch bản prompt (Zoom-out, Shift, Mixed 70/30), image-level (N=72 ảnh).


Bảng 4.14: PGA-UNet trên FracAtlas: kết quả toàn diện tại 256×256 và 512×512 , ba kịch bản prompt (N=72 ảnh, image-level)

Độ phân giải	Kịch bản	Dice $\uparrow$	IoU $\uparrow$	Pre $\uparrow$	Rec $\uparrow$	HD95 $\downarrow$ (px)	CBL $\uparrow$
PGA-UNet (256)	Zoom-out	0.8110	0.6886	0.7790	0.8628	3.57	0.9456
PGA-UNet (256)	Shift	0.7842	0.6531	0.7566	0.8333	4.02	0.9260
PGA-UNet (256)	Mixed	0.8088	0.6864	0.7801	0.8581	3.57	0.9431
PGA-UNet (512)	Zoom-out	0.8169	0.6953	0.7645	0.8975	7.45 [¶]	0.9546
PGA-UNet (512)	Shift	0.7850	0.6537	0.7349	0.8618	8.88 [¶]	0.9308
PGA-UNet (512)	Mixed	0.8129	0.6904	0.7614	0.8913	7.80 [¶]	0.9499

[¶]*Lưu ý HD95 khác đơn vị độ phân giải:* Giá trị HD95 thô (px) của PGA-256 và PGA-512 **không thể so sánh trực tiếp** vì đo trên hai không gian ảnh khác kích thước (1 px lỗi tại 256 tương đương ~ 2 px tại 512); do đó HD95 không được in đậm ở hàng 512 dù giá trị tuyệt đối cao hơn – đây không phải PGA-512 kém bám biên hơn, chỉ là khác đơn vị đo (tương tự cách xử lý HD95* chuẩn hóa ở Bảng 4.4).

Nhận xét: Ngay cả với chỉ 730 mẫu huấn luyện (bằng $\approx 49\%$ BTXRD), PGA-UNet vẫn đạt Dice > 0.78 ở cả ba kịch bản tại cả hai độ phân giải. Tăng độ phân giải lên 512×512 cải thiện hầu hết chỉ số ở cả ba kịch bản (Zoom-out Dice: $0.8110 \rightarrow 0.8169$; Shift: $0.7842 \rightarrow 0.7850$; Mixed: $0.8088 \rightarrow 0.8129$; IoU, Recall, CBL đều tăng tương ứng), nhất quán với quan sát trên BTXRD (Mục 4.2.4) rằng độ phân giải cao hơn có lợi cho PGA-UNet. Riêng Precision giảm nhẹ ở cả ba kịch bản khi tăng độ phân giải ($256 \rightarrow 512$: Zoom-out -0.0145 , Shift -0.0217 , Mixed -0.0187), khác với xu hướng chung trên BTXRD – nhất quán theo cả ba kịch bản nên khó là

ngẫu nhiên, có thể phản ánh đặc thù của đường gãy mảnh: ở độ phân giải cao hơn mô hình phát hiện được nhiều vùng nghi ngờ hơn (Recall tăng) nhưng đồng thời bắt luôn một số vùng biên mờ không phải gãy xương thực sự (Precision giảm nhẹ), một đánh đổi hợp lý về mặt lâm sàng (thà nghi ngờ thêm còn hơn bỏ sót). Mức sụt Dice Zoom-out $\rightarrow$ Shift cũng nhỏ ở cả hai độ phân giải (256: -0.0268 ; 512: -0.0319), xác nhận tính bền bỉ của cơ chế Gaussian heatmap không phụ thuộc độ phân giải. Nhìn chung, kết quả cho thấy kiến trúc PSG+CAD không chỉ hiệu quả với đặc tính tổn thương dạng khối (u xương, BTXRD) mà còn khái quát tốt sang đặc tính tổn thương dạng đường nứt mảnh (gãy xương, FracAtlas), dù tập huấn luyện nhỏ hơn đáng kể.



Hình 4.4: PGA-UNet trên FracAtlas: Dice Score tại 256 $\times$ 256 và 512 $\times$ 512, ba kịch bản prompt (Bảng 4.14).

4.4.3 So sánh cơ sở (Baseline): PGA-UNet vs U-Net trên FracAtlas

Tương tự Mục 4.2 trên BTXRD, U-Net (không prompt) được huấn luyện lại từ đầu trên FracAtlas ở 512 $\times$ 512 để làm baseline cơ sở, đối chiếu

với PGA-UNet (512) kích bản Zoom-out, cùng N=72 ảnh image-level.

Bảng 4.15: So sánh hiệu năng phân đoạn: U-Net (tự động) so với PGA-UNet (512, Zoom-out) trên FracAtlas (N=72 ảnh, image-level, cùng độ phân giải 512×512)

Mô hình	Dice↑	IoU↑	Precision↑	Recall↑	HD95↓ (px)	CBL↑
U-Net	0.3831	0.2836	0.4387	0.4642	136.82	0.4628
PGA-UNet (512, Zoom-out)	0.8169	0.6953	0.7645	0.8975	7.45	0.9546

Nhận xét: Khoảng cách giữa U-Net và PGA-UNet trên FracAtlas ($\Delta\text{Dice} = +0.4338$) còn lớn hơn trên BTXRD ($\Delta\text{Dice} = +0.3794$, Bảng 4.2), củng cố quan sát đã có ở Mục 4.4.4: đặc tính đường gãy mảnh của FracAtlas càng bất lợi hơn cho mô hình không có định hướng không gian. HD95 của U-Net trên FracAtlas (136.82 px) cũng cao hơn nhiều so với PGA-UNet (7.45 px, chênh lệch ~ 18 lần), cho thấy khi không có câu nhắc, U-Net không chỉ bỏ sót tổn thương mà còn định vị hoàn toàn sai vị trí ở nhiều ca.

4.4.4 So sánh với SAM-Med2D (Fine-tuned và Zero-shot) trên FracAtlas

Khác với thực nghiệm trên BTXRD (nơi PGA-UNet đánh giá image-level còn SAM-Med2D chỉ đánh giá per-polygon do giới hạn triển khai ban đầu), ở FracAtlas cả ba mô hình (PGA-UNet, SAM-Med2D fine-tuned, SAM-Med2D zero-shot) đều được quy về **cùng đơn vị đánh giá image-level** (N=72 ảnh, GT union + max-merge dự đoán), cho phép so sánh trực tiếp không cần quy đổi.

Ghi chú về checkpoint fine-tuned: Lần huấn luyện đầu tiên của SAM-Med2D trên FracAtlas hội tụ quá sớm (checkpoint tốt nhất lưu ngay tại epoch 1, do quá khớp trên tập huấn luyện nhỏ khiến early stopping kích hoạt sau đó), khiến dự đoán gần như trùng khớp với zero-shot. Sau khi huấn luyện lại, checkpoint fine-tuned hiện tại (**best_sam.pth**, train Dice tăng liên tục $0.6266 \rightarrow 0.8981$ qua 11 epoch) hội tụ đầy đủ và cải thiện rõ

Bảng 4.16: So sánh toàn diện PGA-UNet (256) với SAM-Med2D fine-tuned và zero-shot trên FracAtlas, ba kịch bản prompt (tất cả cùng image-level, N=72 ảnh, cùng độ phân giải 256×256)

Mô hình	Kịch bản	Dice $\uparrow$	IoU $\uparrow$	Pre $\uparrow$	Rec $\uparrow$	HD95 $\downarrow$ (px)	CBL $\uparrow$
PGA-UNet (256)	Zoom-out	0.8110	0.6886	0.7790	0.8628	3.57	0.9456
PGA-UNet (256)	Shift	0.7842	0.6531	0.7566	0.8333	4.02	0.9260
PGA-UNet (256)	Mixed	0.8088	0.6864	0.7801	0.8581	3.57	0.9431
SAM-Med2D (FT)	Zoom-out	0.7339	0.5897	0.7358	0.7508	4.33	0.9040
SAM-Med2D (FT)	Shift	0.6743	0.5227	0.6715	0.6925	5.19	0.8606
SAM-Med2D (FT)	Mixed	0.7209	0.5745	0.7185	0.7396	4.57	0.8916
SAM-Med2D (ZS)	Zoom-out	0.5278	0.3720	0.4854	0.6519	8.53	0.8514
SAM-Med2D (ZS)	Shift	0.4976	0.3458	0.4303 [§]	0.5987 [§]	9.71	0.8129
SAM-Med2D (ZS)	Mixed	0.5077	0.3537	0.4481 [§]	0.6138 [§]	9.31	0.8305

rệt so với zero-shot ở cả ba kịch bản – số liệu trình bày trong bảng trên là kết quả sau khi huấn luyện lại.

[§] *Ghi chú đơn vị:* Precision/Recall image-level của SAM-Med2D zero-shot ở kịch bản Shift và Mixed **không được ghi nhận** ở bước tổng hợp image-level trong lần chạy notebook hiện tại (chỉ Dice/IoU/HD95/CBL được tính tại bước này). Hai giá trị hiển thị ở trên là Precision/Recall **per-polygon thô** (N=92 mẫu, đơn vị khác với các cột Dice/IoU/HD95/CBL còn lại trong bảng vốn tính ở cấp độ ảnh) — dùng làm tham chiếu gần đúng, không đối chiếu trực tiếp 1-1 với các số image-level khác. Cần chạy lại bước tổng hợp image-level để có số liệu chính xác cùng đơn vị.

Phân tích: Sau khi fine-tuning hội tụ đầy đủ, SAM-Med2D (FT) cải thiện rõ rệt so với zero-shot ở cả ba kịch bản (Dice: Zoom-out +0.2061, Shift +0.1767, Mixed +0.2132), xác nhận fine-tuning trên FracAtlas thực sự mang lại lợi ích khi mô hình được huấn luyện đủ epoch. Dù vậy, PGA-UNet vẫn vượt trội SAM-Med2D (FT) trên toàn bộ ba kịch bản, với biên độ đã thu hẹp đáng kể so với biên độ đối với zero-shot (+0.08 đến +0.11 Dice so với FT, so với +0.28 đến +0.29 Dice so với ZS). Biên độ còn lại phù hợp với đặc tính hình thái của FracAtlas: tổn thương gãy xương dạng đường nứt mảnh có diện tích nhỏ hơn nhiều so với khối u BTXRD,

khiến giới hạn độ phân giải 256×256 của SAM-Med2D vẫn bắt lợi hơn dù đã fine-tuned đúng cách (tương tự phát hiện ở nhóm “Tổn thương nhỏ” Bảng 4.11). Đồng thời, PGA-UNet vẫn giữ được tính bền bỉ tốt hơn: mức sụt Dice từ Zoom-out sang Shift chỉ -0.0268 (256), nhỏ hơn nhiều so với PGA-UNet@256 trên BTXRD (-0.0372 , Bảng 4.5) và nhỏ hơn cả SAM-Med2D (FT) trên FracAtlas (-0.0596), cho thấy cơ chế hướng dẫn mềm (Gaussian heatmap) ổn định hơn trước sai lệch câu nhắc ngay cả khi so sánh với một mô hình nền tảng đã fine-tuned đúng cách.

4.4.5 Đánh giá theo đặc tính tổn thương (Sub-Category) trên FracAtlas

PGA-UNet so với U-Net theo độ khó tác vụ


Tương tự Mục 4.3.3 trên BTXRD, tập test FracAtlas được chia thành hai nhóm **hậu nghiệm** theo chính Dice của U-Net (baseline không prompt): TOP-DICE (nhóm ảnh U-Net dự đoán tốt nhất) và BOTTOM-DICE (nhóm ảnh U-Net dự đoán kém nhất). Do FracAtlas chỉ có 72 ảnh test (nhỏ hơn nhiều so với 187 ảnh của BTXRD), quy mô mỗi nhóm được điều chỉnh còn $N=36$ ảnh/nhóm (thay vì top/bottom-50 như BTXRD) để hai nhóm không chồng lấp lên nhau ($2 \times 36 = 72 = 72$).

Bảng 4.17: So sánh hiệu năng PGA-UNet với U-Net theo độ khó tác vụ trên FracAtlas (36 ảnh mỗi nhóm, image-level; phân nhóm dễ nhất / khó nhất theo Dice của U-Net, kịch bản Zoom-out)

Nhóm	Mô hình	Dice	IoU	Pre	Rec	HD95 (px)	CBL
TOP-DICE (N=36)	U-Net	0.6532	0.5018	0.6266	0.7500	82.10	0.7595
	PGA-UNet	0.8324	0.7179	0.7920	0.8975	8.04	0.9600
BOTTOM-DICE (N=36)	U-Net	0.1130	0.0654	0.1397	0.1784	191.54	0.1662
	PGA-UNet	0.8015	0.6726	0.7370	0.8974	6.85	0.9493

Nhận xét: Xu hướng từ BTXRD (Bảng 4.10) được tái khẳng định rõ ràng trên FracAtlas. Ở nhóm TOP-DICE, U-Net vẫn đạt được Dice khá (0.6532) vì đây là các ca dễ nhất theo chính đánh giá của nó; PGA-UNet vẫn vượt trội hơn ($\Delta = +0.1791$). Ở nhóm BOTTOM-DICE, U-Net gần

như sụp đổ hoàn toàn (Dice = 0.1130, HD95 = 191.54 px), trong khi PGA-UNet **gần như không đổi** so với nhóm TOP-DICE (Dice = 0.8015 so với 0.8324, $\Delta = +0.6886$ so với U-Net). Đáng chú ý, PGA-UNet trên FracAtlas duy trì ổn định hơn cả trên BTXRD ở nhóm khó nhất (BTXRD: PGA Dice = 0.8120 ở nhóm Khó bottom-50 so với U-Net chỉ 0.0062, Bảng 4.10) – ở cả hai bộ dữ liệu, cơ chế câu nhắc giúp mô hình không phụ thuộc vào việc ảnh có "dễ" hay "khó" theo tiêu chuẩn của một mô hình tự động, mà luôn bám theo vùng được bác sĩ chỉ định.



Hình 4.5: So sánh U-Net và PGA-UNet theo độ khó tác vụ trên FracAtlas (Bảng 4.17).


PGA-UNet so với SAM-Med2D theo đặc tính lâm sàng

Tương tự Mục 4.3.3, tập test FracAtlas được chia thành ba nhóm bằng nhau theo cùng tiêu chí (diện tích tổn thương nhỏ nhất, Dice SAM-Med2D thấp nhất trong phần còn lại, diện tích lớn nhất trong phần còn lại), 24 ảnh/nhóm ($3 \times 24 = 72$). Theo yêu cầu phạm vi, chỉ kịch bản **Zoom-out** được trình bày ở phân tích sub-category (kịch bản đại diện, nhất quán với cách trình bày sub-category trên BTXRD).

Bảng 4.18: So sánh SAM-Med2D (FT, 256), PGA-UNet (256) và PGA-UNet (512) theo đặc tính tổn thương trên FracAtlas (kịch bản Zoom-out, 24 ảnh/nhóm, image-level)

Nhóm	Mô hình	Dice	IoU	Pre	Rec	HD95 (px)	CBL
Tổn thương nhỏ (N=24)	SAM-Med2D (FT)	0.4395	0.3141	0.7793	0.3507	30.94	0.8210
	PGA-UNet (256)	0.7584	0.6178	0.6652	0.9006	6.04	0.9125
	PGA-UNet (512)	0.8028	0.6756	0.7269	0.9150	5.05	0.9400
Biên giới mờ (N=24)	SAM-Med2D (FT)	0.5787	0.4132	0.7814	0.4953	14.80	0.9005
	PGA-UNet (256)	0.7926	0.6627	0.7118	0.9060	9.41	0.9566
	PGA-UNet (512)	0.8039	0.6775	0.7439	0.8925	9.29	0.9552
Tổn thương rõ nét (N=24)	SAM-Med2D (FT)	0.7677	0.6253	0.8451	0.7178	9.86	0.9373
	PGA-UNet (256)	0.8358	0.7213	0.8105	0.8801	8.17	0.9563
	PGA-UNet (512)	0.8404	0.7280	0.8203	0.8786	8.09	0.9626

Phân tích: Xu hướng chính từ BTXRD (Bảng 4.11) được tái khẳng định trên FracAtlas: PGA-UNet vượt SAM-Med2D (256, đã fine-tuned đúng cách) về Dice ở cả ba nhóm, khoảng cách lớn nhất tại nhóm *Tổn thương nhỏ* ($\Delta = +0.3633$ Dice so với PGA-512, xấp xỉ mức chênh lệch tương ứng trên BTXRD $+0.3759$), thu hẹp dần ở *Biên giới mờ* ($\Delta = +0.2251$) và *Tổn thương rõ nét* ($\Delta = +0.0726$) – cùng khuôn mẫu quan sát được trên BTXRD. Đáng chú ý, ở cả ba nhóm SAM-Med2D lại đạt Precision cao hơn PGA-UNet (ví dụ nhóm *Tổn thương rõ nét*: SAM = 0.8451 so với PGA-512 = 0.8203), trong khi Recall và Dice tổng thể vẫn thấp hơn nhiều; điều này cho thấy mô hình nền tảng đã fine-tuned có xu hướng dự đoán bảo thủ hơn (dự đoán vùng nhỏ hơn nhưng chính xác khi đã dự đoán), còn PGA-UNet ưu tiên bao phủ đầy đủ vùng tổn thương (Recall cao hơn) – một đánh đổi hợp lý về mặt lâm sàng vì bỏ sót tổn thương thường nguy hiểm hơn dự đoán dư. Không còn xuất hiện bất thường về độ phân giải như quan sát trước đây (PGA-UNet 512 nay vượt PGA-UNet 256 ở toàn bộ ba nhóm, nhất quán với các bảng khác trong khóa luận): nguyên nhân là hai nhóm *Biên giới mờ*/*Tổn thương rõ nét* được phân loại hậu nghiệm theo thứ hạng Dice của chính SAM-Med2D, nên khi checkpoint SAM-Med2D được huấn luyện lại đúng cách (thay vì hội tụ sớm như trước), thành phần ảnh trong hai nhóm này cũng thay đổi theo, kéo theo số liệu PGA-UNet trên các nhóm này được tính lại trên tập ảnh mới.



Hình 4.6: So sánh SAM-Med2D (FT), PGA-UNet (256) và PGA-UNet (512) theo ba nhóm đặc tính tổn thương trên FracAtlas (Bảng 4.18).

4.4.6 Thảo luận: khả năng tổng quát hóa liên miền dữ liệu

Ba quan sát tổng hợp từ thực nghiệm FracAtlas:

- Tổng quát hóa kiến trúc, không phải overfitting vào BTXRD:**
 Dù được huấn luyện lại hoàn toàn từ đầu trên một bộ dữ liệu có nguồn gốc, đặc tính tổn thương và quy mô huấn luyện khác biệt (730 mẫu so với 1 493 mẫu, chỉ $\approx 49\%$), PGA-UNet vẫn đạt Dice > 0.78 ở mọi kịch bản và cả hai độ phân giải, vượt trội U-Net (baseline không prompt) với biên độ còn lớn hơn BTXRD ($+0.4338$ so với $+0.3794$) và vượt SAM-Med2D (FT, đã fine-tuned đúng cách) với biên độ $+0.08$ đến $+0.11$ Dice (biên độ so với zero-shot lớn hơn, $+0.28$ đến $+0.29$ Dice). Phân tích theo độ khó tác vụ (Bảng 4.17) cho thấy PGA-UNet gần như không đổi giữa nhóm ảnh dễ và khó (theo đánh giá hậu nghiệm của U-Net), trong khi U-Net sụp đổ hoàn toàn ở nhóm khó – cùng một khuôn mẫu quan sát được trên BTXRD (Bảng 4.10). Điều này củng cố luận điểm rằng lợi ích của cơ chế Prompt Spatial Gate và Conditioned Attention không phải là hiện tượng đặc thù (overfit) của

một bộ dữ liệu, mà là đặc tính kiến trúc tổng quát của phương pháp prompt-guided segmentation.


- **Tính bền bỉ trước sai số câu nhắc được tái khẳng định ở cả hai độ phân giải:** Mức sụt Dice Zoom-out $\rightarrow$ Shift trên FracAtlas nhỏ ở cả 256 (-0.0268) và 512 (-0.0319), thấp hơn BTXRD ở cùng độ phân giải (-0.0372 tại 256) và thấp hơn cả SAM-Med2D (FT) trên FracAtlas (-0.0596), cho thấy cơ chế hướng dẫn mềm (Gaussian heatmap) không chỉ hoạt động tốt mà còn ổn định qua các miền dữ liệu khác nhau.
- **SAM-Med2D fine-tuned cải thiện rõ rệt so với zero-shot, nhưng PGA-UNet vẫn duy trì ưu thế:** Sau khi fine-tuning hội tụ đầy đủ trên FracAtlas (train Dice $0.6266 \rightarrow 0.8981$ qua 11 epoch), SAM-Med2D (FT) vượt zero-shot $+0.18$ đến $+0.21$ Dice ở cả ba kích bản (Bảng 4.16), xác nhận chất lượng fine-tuning ảnh hưởng lớn đến hiệu năng của mô hình nền tảng trên miền dữ liệu mới. Dù vậy, PGA-UNet vẫn vượt trội SAM-Med2D (FT) ở toàn bộ ba kích bản ($+0.08$ đến $+0.11$ Dice), cho thấy lợi thế của kiến trúc nhẹ huấn luyện trực tiếp trên miền đích không chỉ đến từ việc so sánh với một checkpoint chưa hội tụ, mà vẫn được giữ vững khi so sánh với một SAM-Med2D đã fine-tuned đúng cách.

4.5 Trực quan hóa kết quả (Qualitative Results)

Bên cạnh các đánh giá định lượng bằng số liệu thống kê, việc quan sát trực tiếp kết quả phân đoạn mang ý nghĩa đặc biệt quan trọng trong lĩnh vực y khoa lâm sàng. Mục này trình bày các hình ảnh trực quan hóa nhằm minh họa rõ nét cách mô hình PGA-UNet xử lý các trường hợp phức tạp trong thực tế.

4.5.1 Trực quan hóa các kích bản phân đoạn tiêu biểu

Hình 4.7 minh họa một ca kiểm thử tiêu biểu của PGA-UNet (kích bản Zoom-out): mặt nạ phân đoạn bám sát đường biên tổn thương nhờ cơ chế Prompt Spatial Gate và Conditioned Attention dẫn đường từ Prompt Heatmap.



Hình 4.7: Trực quan hóa kết quả phân đoạn của PGA-UNet kích bản Zoom-out: ảnh gốc (trái), mặt nạ Ground Truth (giữa), mặt nạ dự đoán (phải). Đường biên bám sát GT nhờ cơ chế Prompt Spatial Gate và Conditioned Attention.

4.6 Giới hạn kiến trúc và phân tích trường hợp thất bại

Bên cạnh các kết quả tích cực đã trình bày, việc phân tích khách quan các trường hợp kiến trúc PGA-UNet hoạt động kém là cần thiết để đánh giá đúng giới hạn và định hướng cải tiến.

4.6.1 Trường hợp PGA-UNet dự đoán kém

Qua quá trình phân tích trên tập kiểm thử, ba nhóm trường hợp mà PGA-UNet cho kết quả phân đoạn dưới mức trung bình ($\text{Dice} < 0.70$) được

nhận diện như sau:

- **Tổn thương có hình dáng bất thường:** Các khối u dạng kéo dài, phân nhánh hoặc có đường biên không liên tục thường vượt quá khả năng biểu diễn của bản đồ nhiệt Gaussian (vốn có dạng hình elip đối xứng). Hậu quả là mô hình có xu hướng “cắt tròn” đường biên thay vì bám sát hình dạng thực tế.
- **Vùng chồng lấp đa lớp xương dày đặc:** Tại các vị trí như khớp cổ chân nơi nhiều cấu trúc xương chồng lên nhau, gradient cạnh bị nhiễu nghiêm trọng khiến bộ giải mã gặp khó khăn trong việc xác định ranh giới chính xác, ngay cả khi có prompt hướng dẫn.
- **Ảnh chất lượng thấp:** Các ảnh X-quang bị mờ, thiếu sáng hoặc có nhiều kỹ thuật còn sót lại sau tiền xử lý đều làm suy giảm chất lượng đặc trưng mà bộ mã hóa trích xuất được.

4.7 Đánh giá module Gatekeeper và pipeline end-to-end

Phần này trình bày đánh giá module Gatekeeper (EfficientNet_B3), thành phần hỗ trợ được tích hợp để lấp đầy khoảng trống giữa điều kiện huấn luyện và triển khai thực tế, cùng với đánh giá pipeline end-to-end trên dữ liệu hỗn hợp. Phân tích sai số tích lũy của pipeline được trình bày tại Mục 4.7.3.

4.7.1 Đánh giá mô hình phân lớp góc cổng (EfficientNet_B3)

Mô hình phân lớp đóng vai trò là "người gác cổng" (gatekeeper) trong luồng xử lý đầu cuối của phần mềm. Nhiệm vụ của mô hình là sàng lọc tự động ảnh X-quang đầu vào thành hai nhóm: Bình thường (Âm tính) và Có bệnh lý bất thường (Dương tính). Việc đánh giá chính xác hiệu năng của module này mang ý nghĩa quyết định, bởi một dự đoán sai sót ở bước

này có thể khiến bệnh nhân bị lọt lưới sàng lọc mà không bao giờ đi tới được bước phân đoạn chi tiết phía sau.

Kiến trúc: EfficientNet_B3 tinh chỉnh hai giai đoạn. Mô hình **EfficientNet_B3** [8] được tiền huấn luyện trên ImageNet-1K sử dụng chiến lược *compound scaling*, đồng thời mở rộng chiều rộng, chiều sâu và độ phân giải theo một hệ số hợp lý. Backbone gồm các khối MBConv kết hợp với cơ chế Squeeze-and-Excitation (SE). Với $\sim 10.7M$ tham số và đầu vào 300×300 , EfficientNet_B3 đạt cân bằng tốt giữa hiệu năng phân lớp và tốc độ suy luận. Tầng phân lớp gốc được thay thế bởi $\text{Linear}(1536, 1) + \text{Sigmoid}$, xuất xác suất $p \in (0, 1)$; ngưỡng $p \geq 0.5 \rightarrow$ dương tính.

Giai đoạn 1 (25 epoch): Đóng băng backbone, chỉ cập nhật head với $\text{LR} = 10^{-4}$, giúp head thích nghi không gian đặc trưng X-quang mà không phá hủy biểu diễn ImageNet.

Giai đoạn 2 (tối đa 100 epoch, dừng sớm tại epoch 68): Mở khóa toàn bộ, $\text{LR} = 10^{-5}$, CosineAnnealingLR. Hàm mất mát: BCEWithLogitsLoss; tối ưu: AdamW; dừng sớm: $\text{patience} = 15$ (theo Accuracy); Gradient Clipping: $\text{max_norm} = 1.0$. Lưu song song hai checkpoint: theo Loss tốt nhất và theo Accuracy tốt nhất.

Các độ đo đánh giá (Evaluation Metrics): Để có cái nhìn toàn diện, mô hình được đánh giá qua các độ đo tiêu chuẩn của bài toán phân loại nhị phân: Độ chính xác tổng thể (Accuracy), Độ chính xác (Precision), Độ bao phủ/Độ nhạy (Recall/Sensitivity), Độ đặc hiệu (Specificity) và Điểm F1 (F1-Score).

Đặc biệt trong bối cảnh y tế dự phòng và sàng lọc, **Độ nhạy (Recall)** là chỉ số được ưu tiên hàng đầu. Một mô hình sàng lọc tốt thà báo động nhầm (False Positive) để bác sĩ tốn thêm chút thời gian kiểm tra lại ở bước phân đoạn, còn hơn là bỏ sót bệnh nhân thực sự có khối u (False Negative).

Phân tích kết quả: Bảng 4.19 tổng hợp hiệu năng của mô hình phân lớp gác cổng sau quá trình tinh chỉnh hai giai đoạn, đánh giá thống nhất trên tập kiểm thử **dataset_online** (375 ảnh: 187 bệnh lý + 188 bình thường). Kết quả cho thấy module Gatekeeper đạt mức cân bằng tốt giữa

Bảng 4.19: Kết quả đánh giá hiệu năng của mô hình phân lớp sàng lọc trên tập kiểm thử

Độ đo đánh giá (Metrics)	Kết quả
Độ chính xác tổng thể (Accuracy)	88.00%
Độ chính xác (Precision / PPV)	87.37%
Độ nhạy (Recall / Sensitivity)	88.77%
Độ đặc hiệu (Specificity)	87.23%
Giá trị dự báo Âm tính (NPV)	88.65%
Điểm F1 (F1-Score)	88.06%
Diện tích dưới đường cong (AUC-ROC)	0.9405

Sensitivity và Specificity:

- **AUC-ROC 0.9405:** Khả năng phân biệt bệnh/không bệnh rất tốt, bất kể ngưỡng phân loại.
- **Recall/Sensitivity 88.77%:** Phát hiện đúng $\approx 89\%$ ca bệnh thực sự (bỏ sót 21/187 ca), đảm bảo an toàn sàng lọc.
- **Specificity 87.23%:** Loại đúng $\approx 87\%$ ca bình thường (24/188 ảnh lành bị phân loại nhầm thành dương tính).
- **Precision 87.37%:** Khi báo dương tính, xác suất đúng là $\approx 87\%$.
- **NPV 88.65%:** Khi kết luận "bình thường", xác suất thực sự không bệnh là $\approx 89\%$, đủ tin cậy làm bộ lọc sơ cấp.
- **F1-Score 88.06%:** Cân bằng tốt giữa Precision và Recall, phù hợp với kịch bản dữ liệu cân bằng (187 vs 188).

4.7.2 Phân tích các ca bỏ sót (False Negative) và thử nghiệm ngưỡng phân loại

Bảng 4.23 (Mục 4.7.4) cho thấy Gatekeeper bỏ sót 21/187 ảnh bệnh lý (FN) ở ngưỡng mặc định $p = 0.5$. Mục này phân tích sâu hơn đặc điểm của 21 ca này và thử nghiệm dịch chuyển ngưỡng phân loại để đánh giá đánh đổi giữa Sensitivity và Specificity.

Đặc điểm của 21 ca FN: Xác suất dự đoán p của mô hình cho 21 ảnh này dao động trong khoảng $[0.0000, 0.4202]$, trung bình 0.1635, trung vị 0.0922 — tức phần lớn không phải các ca “suýt đúng” ở sát ngưỡng 0.5.

Bảng 4.20: Phân bố xác suất dự đoán (cls_prob) của 21 ảnh FN theo khoảng cách tới ngưỡng 0.5

Khoảng xác suất dự đoán	Số ca (/21)
$p \in [0.4, 0.5)$ — cận ngưỡng (“near-miss”)	2 (9.5%)
$p \in [0.3, 0.4)$	3 (14.3%)
$p \in [0.2, 0.3)$	4 (19.0%)
$p \in [0.1, 0.2)$	1 (4.8%)
$p < 0.1$ — mô hình dự đoán tự tin (nhưng sai) là ảnh lành	11 (52.4%)

Như vậy hơn một nửa số ca FN (11/21) không phải lỗi “suýt đúng” mà là các ca mô hình dự đoán rất tự tin là bình thường — cho thấy hạ ngưỡng phân loại một cách đơn thuần sẽ khó cứu được nhóm này.

Tương quan với kích thước tổn thương: So sánh diện tích tổn thương (tính theo % diện tích ảnh, đo trên toàn bộ polygon của từng ảnh) giữa nhóm bị bỏ sót (FN, 23 tổn thương trong 21 ảnh) và nhóm phát hiện đúng (TP, 209 tổn thương trong 166 ảnh):

Trung vị diện tích tổn thương ở nhóm FN chỉ bằng khoảng 22% trung vị nhóm TP (0.226% so với 1.018% diện tích ảnh); kiểm định phi tham số Mann–Whitney U (giả thuyết một phía: diện tích nhóm FN nhỏ hơn nhóm

Bảng 4.21: So sánh diện tích tổn thương (% diện tích ảnh) giữa nhóm FN và nhóm TP

Thống kê diện tích tổn thương	Nhóm FN (n=23)	Nhóm TP (n=209)
Trung vị (% diện tích ảnh)	0.226%	1.018%
Trung bình	0.310%	2.100%
Nhỏ nhất / Lớn nhất	0.036% / 1.430%	0.003% / 18.378%

TP) cho $p = 0.0001$, khác biệt có ý nghĩa thống kê. Điều này cho thấy các ca bị Gatekeeper bỏ sót **không phải lỗi ngẫu nhiên**, mà tương quan rõ với tổn thương có kích thước nhỏ — nhất quán với hạn chế đã biết của một mô hình phân loại toàn ảnh khi tín hiệu bất thường chỉ chiếm một phần rất nhỏ diện tích đầu vào.

Thử nghiệm dịch chuyển ngưỡng phân loại: Bảng 4.22 khảo sát Sensitivity/Specificity khi hạ ngưỡng quyết định dương tính từ mặc định 0.5 xuống các mức thấp hơn (tính lại trên toàn bộ 375 ảnh của dataset_online).

Bảng 4.22: Đánh đổi Sensitivity/Specificity khi dịch chuyển ngưỡng phân loại của Gatekeeper

Ngưỡng	TP	FP	FN	TN	Sensitivity	Specificity
0.50 (mặc định)	166	24	21	164	88.77%	87.23%
0.40	168	31	19	157	89.84%	83.51%
0.30	171	36	16	152	91.44%	80.85%
0.20	175	42	12	146	93.58%	77.66%
0.10	176	51	11	137	94.12%	72.87%
0.05	180	59	7	129	96.26%	68.62%
0.01	182	83	5	105	97.33%	55.85%

Nhận xét: Không tồn tại một ngưỡng nào cho phép tăng mạnh Sensitivity mà gần như không đánh đổi Specificity — đường cong đánh đổi khá thoải chứ không có điểm “miễn phí”. Ví dụ, hạ ngưỡng từ 0.5 xuống

0.1 cứu thêm 10/21 ca FN (Sensitivity 88.77% $\rightarrow$ 94.12%) nhưng đổi lại số ảnh lành bị báo động nhầm tăng hơn gấp đôi (FP từ 24 lên 51, Specificity giảm còn 72.87%). Để loại bỏ gần hết FN (Sensitivity $\rightarrow$ 100%) cần ngưỡng gần bằng 0, tại đó Specificity sụp đổ về gần 0% — tương đương từ bỏ hoàn toàn khả năng phân biệt của Gatekeeper. Do đó, việc chỉ điều chỉnh ngưỡng không phải là giải pháp triệt để; kết hợp với thiết kế triage mềm (Mục 3.1, Chương 3) — nơi bác sĩ luôn xác nhận lại gợi ý trước khi kết thúc quy trình — là lớp phòng vệ bổ sung cần thiết bên cạnh việc cải thiện bản thân mô hình phân lớp.

Hậu quả khi Gatekeeper chặn nhầm một ca có bệnh (kịch bản không có xác nhận của bác sĩ): Trong kịch bản đánh giá thận trọng nhất của Mục 4.7.4 (không có bước bác sĩ xác nhận), mỗi ca FN đồng nghĩa với việc một tổn thương thật — theo phân tích ở trên, thường là tổn thương nhỏ (trung vị 0.226% diện tích ảnh) — hoàn toàn không được đưa vào PGA-UNet và bị tính Dice = 0 trong Pipeline Dice end-to-end (Mục 4.7.4). Trong hệ thống triển khai thực tế (Chương 3), hậu quả này chỉ xảy ra nếu bác sĩ đồng thời cũng không phát hiện ra tổn thương khi xem lại ảnh gốc và xác nhận theo gợi ý sai của mô hình — một rủi ro thuộc phạm trù *automation bias* chưa được đánh giá trong khóa luận này (đã nêu tại Chương 5).

4.7.3 Phân tích sai số tích lũy (Cascading Error)

Khi đánh giá **hệ thống end-to-end** trên tập **dataset_online** (375 ảnh hỗn hợp, bao gồm 187 ảnh bệnh lý và 188 ảnh bình thường), sai số từ bước phân lớp lan truyền sang bước phân đoạn qua hai kênh, và cả hai kênh đều phải được tính là lỗi phân đoạn (Dice = 0) trong một chỉ số end-to-end đúng nghĩa:

1. **Sai số Recall (FN):** Các ca bệnh bị gác cổng bỏ sót $\rightarrow$ không chuyển xuống PGA-UNet, bệnh nhân có tổn thương thật nhưng không được phân đoạn (21 ảnh FN, tương ứng Sensitivity = 88.77%). Đây là

lỗi nghiêm trọng nhất trong một pipeline y khoa và **phải được gán Dice = 0**, không thể loại khỏi mẫu số như một trường hợp “không tính”.

2. **Sai số Specificity (FP)**: Các ảnh bình thường bị phân loại nhầm thành dương tính $\rightarrow$ PGA-UNet chạy nhưng không có GT mask (24 ảnh FP, tương ứng Specificity = 87.23%), cũng đóng góp Dice = 0 vào mẫu số.

Chất lượng phân đoạn thuần của PGA-UNet, tính *có điều kiện* rằng ảnh đã được gác cổng chuyển đúng xuống (166/166 ảnh TP), đạt $\overline{\text{Dice}}_{\text{TP}} = 86.35\%$. Đây **không phải** hiệu năng thật của toàn hệ thống vì nó bỏ qua hoàn toàn 21 ảnh FN và 24 ảnh FP.

Phân rã theo từng kênh lỗi (mẫu số chỉ tính một kênh tại một thời điểm):

- Chỉ tính kênh FP (mẫu số = 166 TP + 24 FP = 190): Dice = **0.7544** — đây là con số từng được báo cáo là “Pipeline Dice”, nhưng thực chất bỏ hẵn 21 ảnh FN ra khỏi phép tính nên đo hiệu năng *cao hơn thực tế*.
- Chỉ tính kênh FN (mẫu số = 166 TP + 21 FN = 187, tương đương Sensitivity $\times \overline{\text{Dice}}_{\text{TP}} = 88.77\% \times 86.35\%$): Dice = **0.7665**.

Khi tính **đúng và đủ** trên toàn bộ 211 ảnh liên quan đến bước phân đoạn (166 TP + 24 FP + 21 FN), với cả FP lẫn FN đều đóng góp Dice = 0 vào mẫu số:

$$\text{Pipeline Dice}_{\text{end-to-end}} = \frac{\sum_{i \in \text{ảnh TP}} \text{Dice}_{\text{img}}(i)}{N_{\text{TP}} + N_{\text{FP}} + N_{\text{FN}}} = \frac{\sum \text{Dice}_{\text{TP}}}{166 + 24 + 21} = \mathbf{0.6793} \quad (4.5)$$

tức **thấp hơn 0.0751 điểm Dice** so với con số 0.7544 từng báo cáo, đúng như kỳ vọng vì phạt đầy đủ cả 21 ca bệnh bị bỏ sót hoàn toàn. Đây là chỉ

số Pipeline Dice chính thức được dùng trong Mục 4.7.4. Cải thiện đồng thời cả Sensitivity lẫn Specificity là hướng ưu tiên tiếp theo. Định hướng cải thiện được trình bày tại Chương 5.

4.7.4 Đánh giá pipeline end-to-end trên dữ liệu hỗn hợp

Để đánh giá pipeline trong điều kiện thực tế, nơi không phải ảnh nào cũng có bệnh lý, hệ thống được chạy trên tập **dataset_online** (375 ảnh: 187 ảnh bệnh lý + 188 ảnh bình thường). Tập này được ghép từ **tập kiểm thử của PGA-UNet** (187 ảnh bệnh lý, có chú thích đa giác) và **tập kiểm thử của EfficientNet_B3** (188 ảnh bình thường), cả hai đều thuộc phân vùng kiểm thử BTRD (10%), đảm bảo không mô hình nào đã thấy các ảnh này trong quá trình huấn luyện, tránh rò rỉ dữ liệu (data leakage).

Thiết kế đánh giá: Đánh giá này mô phỏng kịch bản **thận trọng nhất** — giả định gợi ý của Gatekeeper được làm theo tuyệt đối, không có bước bác sĩ xem lại và xác nhận như trong thiết kế *triage mềm* thực tế của hệ thống (Mục 3.1, Chương 3) — nhằm đo cận dưới (worst-case) của hiệu năng end-to-end nếu gợi ý sàng lọc không được con người kiểm tra lại. Mỗi ảnh đi qua toàn bộ pipeline (EfficientNet_B3 → PGA-UNet). Kết quả chia thành 4 trường hợp: TP (có JSON, dự đoán dương, PGA chạy thực tế), FP (không có JSON, dự đoán dương, Dice = 0 vì không có GT mask), FN (có JSON, dự đoán âm, không qua PGA, **Dice = 0 vì bệnh nhân có tổn thương thật không được phân đoạn**), TN (không có JSON, dự đoán âm, không tính vào mẫu số phân đoạn).

Dice pipeline được tính trên *toàn bộ ảnh có liên quan đến nhiệm vụ phân đoạn*, tức mọi ảnh mà hệ thống **lẽ ra phải phân đoạn đúng** (mẫu số = ảnh TP + ảnh FP + ảnh FN), phản ánh đúng rủi ro lâm sàng khi cả sai số dương giả lẫn âm giả đều làm giảm chất lượng end-to-end. Mỗi ảnh TP được tính một Dice image-level (max-merge predictions, union GT);

mỗi ảnh FP và mỗi ảnh FN đều đóng góp 1 đơn vị với $\text{Dice} = 0$:

$$\text{Pipeline Dice} = \frac{\sum_{i \in \text{ảnh TP}} \text{Dice}_{\text{img}}(i)}{N_{\text{ảnh TP}} + N_{\text{ảnh FP}} + N_{\text{ảnh FN}}} \quad (4.6)$$

Nhận xét: Pipeline Dice end-to-end = **0.6793** (mẫu số 211 đơn vị image-level: 166 ảnh TP, 24 ảnh FP và 21 ảnh FN, với cả FP lẫn FN đều bị gán $\text{Dice} = 0$) phản ánh đúng và đủ hiệu năng tổng thể của pipeline khi xử lý luồng ảnh hỗn hợp, kể cả các ca bệnh bị Gatekeeper bỏ sót hoàn toàn. Con số này thấp hơn PGA-UNet độc lập ($\text{Dice} = 0.8584$) do hai nguồn suy giảm: (1) 24 ảnh bình thường bị phân loại sai (FP, $\text{Specificity} = 87.23\%$) đóng góp $\text{Dice} = 0$ vào mẫu số; (2) 21 ảnh bệnh bị bỏ sót hoàn toàn (FN, $\text{Sensitivity} = 88.77\%$) cũng đóng góp $\text{Dice} = 0$ vào mẫu số thay vì bị loại khỏi phép tính. So với cách tính trước đây (loại hẳn 21 ảnh FN khỏi mẫu số, cho $\text{Dice} = 0.7544$), chỉ số end-to-end đã sửa lại này thấp hơn 0.0751 điểm Dice — phản ánh trung thực hơn rủi ro lâm sàng thực sự: một ca bệnh bị Gatekeeper bỏ sót gây hậu quả tương đương một ca phân đoạn sai hoàn toàn ($\text{Dice} = 0$), không phải một trường hợp “không tính”. Đây là **kết quả thực nghiệm đầy đủ** trên dữ liệu hỗn hợp thực tế, minh chứng cho sai số tích lũy tất yếu của kiến trúc hai tầng.

Mô hình phân lớp gác cổng đạt $\text{AUC-ROC} = 0.9405$ trên dataset_online là bản lề để toàn bộ hệ thống vận hành ổn định. Cải thiện đồng thời Sensitivity và Specificity (hiện tương đương nhau ở mức $\sim 88\%$) nhằm giảm cả FN lẫn FP là hướng ưu tiên phát triển tiếp theo (xem Chương 5).

4.7.5 Các chỉ số end-to-end bổ sung: Sensitivity bệnh lý, FNR và Lesion-level Recall

Pipeline Dice end-to-end (Mục 4.7.4) là một chỉ số tổng hợp duy nhất; với một hệ thống sàng lọc y khoa, một con số tổng hợp không đủ để thể

Bảng 4.23: Kết quả pipeline end-to-end trên tập dataset_online (hỗn hợp bình thường + có bệnh)

Thống kê	Giá trị
Tổng ảnh đầu vào	375 (187 có bệnh, 188 bình thường)
TP / FP / FN / TN (ảnh)	166 / 24 / 21 / 164
<i>Phân loại (EfficientNet_B3 trên dataset_online)</i>	
Sensitivity (Recall)	88.77%
Specificity	87.23%
Accuracy	88.00%
AUC-ROC	0.9405
<i>Phân đoạn pipeline (PGA-UNet, đánh giá image-level)</i>	
Ảnh TP đưa vào PGA	166 ảnh (209 polygon, tb. 1.26 polygon/ảnh)
Dice trung bình thuần trên ảnh TP (tham khảo, có điều kiện góc cổng đúng)	0.8635
Ảnh FP (Dice = 0)	24 ảnh
Ảnh FN (Dice = 0, bệnh bị bỏ sót hoàn toàn)	21 ảnh
Mẫu số end-to-end (TP + FP + FN)	$166 + 24 + 21 = \mathbf{211 \text{ đơn vị}}$
Pipeline Dice (end-to-end)	0.6793
Pipeline IoU (end-to-end)	0.6027
Tham khảo — cách tính cũ, bỏ qua FN (mẫu số = 190)	$\text{Dice} = 0.7544 / \text{IoU} = 0.6693$

hiện rủi ro lâm sàng cụ thể. Phần này báo cáo bổ sung các chỉ số an toàn ở cấp độ ảnh (image-level) và cấp độ từng tổn thương (lesion-level), tách bạch rõ nguồn gốc rủi ro thay vì chỉ dựa vào Pipeline Dice.

Cấp độ ảnh: Sensitivity bệnh lý (Recall) = **88.77%** (166/187 ảnh bệnh được Gatekeeper phát hiện đúng); False Negative Rate (FNR) = **11.23%** (21/187 ảnh bệnh bị Gatekeeper bỏ sót hoàn toàn, không được PGA-UNet xử lý).

Cấp độ tổn thương (lesion-level): Một ảnh có thể chứa nhiều đa giác tổn thương, nên chỉ số image-level có thể che khuất rủi ro thực sự trên từng tổn thương riêng lẻ. Chạy lại toàn bộ 375 ảnh qua pipeline (Efficient-Net_B3 $\rightarrow$ PGA-UNet, tái lập cục bộ, kết quả phân loại khớp tuyệt đối với Mục 4.7.1: TP=166, FP=24, FN=21, TN=164) và tính Dice/IoU cho *từng đa giác riêng lẻ* (không gộp theo ảnh) trên toàn bộ 232 tổn thương của 187 ảnh bệnh lý cho kết quả:

Nhận xét: Lesion-level Recall (90.09%) cao hơn nhẹ so với Sensitivity ở cấp độ ảnh (88.77%): 21 ảnh FN có trung bình 1.10 tổn thương/ảnh, thấp hơn 1.26 tổn thương/ảnh của 166 ảnh TP, cho thấy Gatekeeper có xu hướng phát hiện đúng nhiều hơn ở các ảnh có nhiều tổn thương. Khi tính tỉ lệ tổn thương thực sự được phân đoạn đạt chất lượng chấp nhận được ($\text{Dice} \geq 0.5$), toàn hệ thống chỉ đạt **89.66%** (208/232), và giảm còn **84.91%** ở ngưỡng chặt hơn ($\text{Dice} \geq 0.7$) — nghĩa là cứ khoảng 6–10 tổn thương thì có 1 tổn thương hoặc bị Gatekeeper bỏ sót hoàn toàn, hoặc bị PGA-UNet phân đoạn dưới ngưỡng chấp nhận được. Các chỉ số lesion-level và FNR này phản ánh trực tiếp hơn hậu quả lâm sàng so với một con số Pipeline Dice tổng hợp duy nhất, và nên được báo cáo song song khi đánh giá mức độ sẵn sàng của hệ thống cho vai trò hỗ trợ sàng lọc.

Bảng 4.24: Các chỉ số end-to-end bổ sung ở cấp độ tổn thương (lesion-level), tính trên 232 tổn thương của 187 ảnh bệnh lý trong dataset_online

Chỉ số	Giá trị
Tổng số tổn thương (đa giác) trong 187 ảnh bệnh	232 (209 trong 166 ảnh TP + 23 trong 21 ảnh FN)
Lesion-level Recall (tổn thương đến được PGA-UNet, không bị Gatekeeper bỏ sót)	90.09% (209/232)
Lesion-level FNR (tổn thương bị mất hoàn toàn do Gatekeeper)	9.91% (23/232)
Dice trung bình trên từng tổn thương riêng lẻ (166 ảnh TP, chưa gộp theo ảnh)	0.8560
Tỉ lệ tổn thương đạt $\text{Dice} \geq 0.5$ trên toàn pipeline (tổn thương bị FN tính là không đạt)	89.66% (208/232)
Tỉ lệ tổn thương đạt $\text{Dice} \geq 0.7$ trên toàn pipeline (tổn thương bị FN tính là không đạt)	84.91% (197/232)

CHƯƠNG 5

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1 Kết luận những đóng góp đạt được

Mục tiêu xuyên suốt của khóa luận này là nghiên cứu, thiết kế và phát triển một hệ thống phân đoạn tương tác ảnh X-quang xương thông minh, an toàn và có tính tương tác cao, hỗ trợ bác sĩ đọc ảnh trong quy trình xác định và khoanh vùng tổn thương. Vượt qua những giới hạn của các phương pháp phân đoạn tự động hoàn toàn truyền thống và rào cản tài nguyên của các mô hình nền tảng hạng nặng, khóa luận đã hoàn thành các mục tiêu chính đề ra với những đóng góp kỹ thuật cụ thể sau:

- **Đề xuất kiến trúc PGA-UNet:** Khóa luận đã thiết kế thành công mô hình Prompt-Guided Attention U-Net ($\sim 3M$ tham số). Bằng cách tích hợp Cổng không gian (Prompt Spatial Gate) tại nhánh mã hóa và Cơ chế chú ý có điều kiện (Conditioned Attention) tại nhánh giải mã, hệ thống biến đổi thành công Bounding Box thành tín hiệu định hướng không gian sâu sát. Thực nghiệm trên $N=187$ ảnh image-level (tập BTXRD): PGA-UNet đạt **Dice = 0.8584** (Zoom-out), vượt U-Net (0.4790, +0.3794) và SAM-Med2D fine-tuned (0.7432, +0.1234) dù nhỏ hơn $\sim 30\times$ về tham số. Đặc biệt, Gaussian heatmap prompt giúp duy trì Dice = 0.8454 ngay cả khi câu nhắc bị lệch tâm (Shift), chứng minh tính bền bỉ cao trong điều kiện lâm sàng thực tế. Phân tích sub-category cho thấy lợi thế lớn nhất ở nhóm tổn thương khó (PGA Dice = 0.8120 vs U-Net Dice = 0.0062 trên nhóm Khó bottom-50, $\Delta=+0.8058$).
- **Đánh giá thực nghiệm toàn pipeline end-to-end:** Khóa luận xây dựng kịch bản đánh giá kết hợp module phân lớp góc cổng (Effi-

cientNet_B3, AUC-ROC = 0.9405) và PGA-UNet, mô phỏng luồng xử lý thực tế trên tập dữ liệu hỗn hợp 375 ảnh (gồm cả ảnh bình thường và ảnh bệnh lý). Đây là đóng góp thực nghiệm bổ sung, phản ánh điều kiện triển khai lâm sàng sát thực hơn so với đánh giá phân đoạn đơn lẻ trên tập ảnh bệnh thuần túy. Pipeline đạt **Pipeline Dice end-to-end = 0.6793** (mẫu số 211 đơn vị image-level: 166 TP + 24 FP + 21 FN, với cả FP lẫn FN đều bị gán Dice = 0), suy giảm so với PGA-UNet độc lập (0.8584) do sai số tích lũy tất yếu của kiến trúc hai tầng (24 FP và 21 FN từ bước phân lớp), và là hướng ưu tiên cải tiến trong tương lai.

5.2 Hạn chế của hệ thống

Mặc dù đạt được nhiều kết quả khả quan, hệ thống đề xuất vẫn còn tồn tại một số giới hạn nhất định cần được nhìn nhận khách quan:

- **Sai số tích lũy pipeline hai giai đoạn (Cascading Error):** Pipeline hiện tại gồm hai module độc lập (Gatekeeper → PGA-UNet). Sai số từ bước phân lớp lan truyền sang bước phân đoạn: thực nghiệm pipeline trên tập hỗn hợp 375 ảnh đạt Pipeline Dice end-to-end = 0.6793 (mẫu số 211 đơn vị image-level: 166 ảnh TP + 24 ảnh FP + 21 ảnh FN, với FP lẫn FN đều bị gán Dice = 0), thấp hơn đáng kể so với PGA-UNet đơn lẻ (Dice = 0.8584). Nguồn suy giảm: 24 ảnh bình thường bị phân loại sai (FP, Specificity = 87.23%) và đặc biệt 21 ảnh bệnh bị Gatekeeper bỏ sót hoàn toàn (FN, Recall = 88.77%) — cả hai đều phải được phạt Dice = 0 chứ không được loại khỏi phép tính — kéo điểm pipeline xuống dưới hiệu năng của từng module đơn lẻ. Đây là hạn chế cố hữu của kiến trúc hai giai đoạn và là hướng ưu tiên cải tiến trong tương lai. Cần lưu ý rằng con số này đo kịch bản thận trọng nhất — gợi ý của Gatekeeper được làm theo tuyệt đối không qua xác nhận của con người; trong

thiết kế triage mềm thực tế của hệ thống (Mục 3.1, Chương 3), bác sĩ luôn xem và xác nhận gợi ý trước khi hệ thống dừng hay tiếp tục, nên một ca FN của mô hình không nhất thiết trở thành một ca bị bỏ sót trong thực tế nếu bác sĩ phát hiện và bác bỏ gợi ý sai. Tuy nhiên, rủi ro con người quá tin tưởng vào gợi ý AI (automation bias) vẫn tồn tại và chưa được đánh giá trong khóa luận này.

- **Hạn chế của thông tin không gian 2D:** Do ảnh X-quang là hình chiếu 2D của cấu trúc xương 3D phức tạp, sự chồng lấp giữa các khớp xương dày đặc đôi khi tạo ra những tín hiệu gradient gây nhiễu. Bounding Box hình chữ nhật dù được chuyển đổi thành Gaussian Heatmap vẫn mang tính chất ước lượng viền thô, có thể gặp khó khăn với các khối u có hình dáng kéo dài hoặc phân nhánh phức tạp.
- **Kiểm định đa tập dữ liệu mới ở bước đầu:** Ngoài BTXRD, khóa luận đã huấn luyện và đánh giá lại đầy đủ PGA-UNet (cả hai độ phân giải, ba kịch bản prompt), U-Net baseline và phân tích theo độ khó tác vụ trên bộ dữ liệu độc lập thứ hai (FracAtlas, dữ liệu gãy xương, khác đặc tính hình thái với u xương của BTXRD), xác nhận kiến trúc tổng quát hóa tốt sang miền dữ liệu mới (Mục 4.4, Chương 4). Hạn chế còn lại: cả hai bộ dữ liệu đều là ảnh công khai đã qua chuẩn hóa, chưa kiểm định trên dữ liệu thô thu thập trực tiếp từ một cơ sở y tế cụ thể (thiết bị, protocol chụp riêng của từng bệnh viện).
- **Hạn chế về độ phân giải ảnh đầu vào:** Ảnh X-quang BTXRD gốc có kích thước 2.000–3.000 px mỗi chiều; việc resize về 512×512 tương đương thu nhỏ còn khoảng $\frac{1}{4}$ đến $\frac{1}{6}$ diện tích gốc. Trên feature map ở tầng sâu nhất của U-Net ($\frac{512}{16} = 32 \times 32$), các chi tiết cấu trúc xương nhỏ có thể bị mất hoàn toàn. Đây là yếu tố tiềm ẩn hạn chế hiệu năng, đặc biệt với tổn thương nhỏ.
- **Câu nhắc lý tưởng (Oracle Prompt):** Trong thực nghiệm, bound-

ing box $\mathbf{B}_i$ được sinh *tự động* từ ground-truth mask theo kịch bản zoom-out và shift có kiểm soát. Trong triển khai thực tế, bác sĩ vẽ hộp bằng tay không có ground-truth tham chiếu, hộp thực tế có thể rộng hơn hoặc lệch tâm hơn so với hai kịch bản mô phỏng. Mô hình chưa được kiểm định trên prompt do bác sĩ thực sự tạo ra, và giả định 30% Shift trong kịch bản Mixed là ước lượng chưa có cơ sở thực nghiệm lâm sàng.

5.3 Định hướng phát triển tương lai

Từ những kết quả đạt được và các hạn chế còn tồn đọng, nhóm nghiên cứu đề xuất các định hướng phát triển tiếp theo nhằm hoàn thiện hệ thống:

- **Hướng 1: Mô hình đa phương thức tích hợp thông tin lâm sàng:** Hệ thống hiện tại chỉ xử lý tín hiệu hình ảnh (visual prompt + ảnh X-quang) và thiếu khả năng tận dụng ngữ cảnh lâm sàng phong phú mà bác sĩ đã có trước khi chụp X-quang. Hướng này đề xuất xây dựng một **mô hình đa phương thức mới** kết hợp đặc trưng hình ảnh và đặc trưng lâm sàng phi hình ảnh (tuổi bệnh nhân, giới tính, vị trí đau, thời gian khởi phát, tiền sử gia đình, kết quả xét nghiệm ALP, LDH) thành một luồng suy luận thống nhất, đồng thời duy trì tốc độ phản hồi đủ nhanh cho môi trường lâm sàng thực tế.

Thông tin lâm sàng được mã hóa thành vector đặc trưng số học (qua bảng tra cứu hoặc một mô hình ngôn ngữ nhỏ) và dung hợp với đặc trưng hình ảnh thông qua cơ chế cross-attention hoặc phép cộng có trọng số tại tầng tiếp nối. Kiến trúc này cải thiện đồng thời hai nhiệm vụ:

- **Phân lớp chính xác hơn:** Với các ca biên giới mà tín hiệu hình ảnh đơn thuần không đủ phân biệt bình thường/bệnh lý, thông tin lâm sàng cung cấp ngữ cảnh bổ sung giúp giảm cả FP lẫn FN, hai nguồn suy giảm chính của Pipeline Dice hiện tại.

- **Phân đoạn có ngữ cảnh:** Khi biết trước tuổi bệnh nhân và giá trị ALP/LDH, mô hình có thể điều chỉnh mức độ nhạy cảm với các vùng nghi ngờ u, từng bước hướng tới khả năng hỗ trợ phân loại lành tính/ác tính dựa trên đặc điểm hình thái kết hợp hồ sơ lâm sàng.

Hướng này trực tiếp giải quyết ba hạn chế cùng lúc: nâng hiệu năng phân lớp (thay cho pipeline hai module riêng biệt), tăng cường bối cảnh cho phân đoạn, và duy trì kiến trúc nhẹ đủ triển khai trên phần cứng y tế. Khi thông tin lâm sàng đã xác nhận rõ sự hiện diện khối u (sinh thiết, chẩn đoán trước đó), luồng phân lớp có thể được bypass để đưa thẳng ảnh vào module phân đoạn, tránh rủi ro phân loại nhầm ca bệnh đã biết.

- **Hướng 2: Xử lý ảnh gốc không resize (Full-Resolution Processing):** Hạn chế về kích thước đầu vào hiện tại (resize từ 2.000–3.000 px về 512×512 , tương đương giữ lại $\frac{1}{4}$ – $\frac{1}{6}$ diện tích gốc) khiến các tổn thương nhỏ có thể bị mất hoàn toàn ở tầng sâu nhất của encoder. Thay vì tiếp tục tăng kích thước resize, hướng này tập trung vào việc **loại bỏ hoàn toàn bước resize** để mô hình tiếp nhận và học trực tiếp trên ảnh gốc độ phân giải cao.

Hai phương án kiến trúc phù hợp: (a) *Sliding Window with Prompt-Aware Stitching*: chia ảnh gốc thành các patch chồng lấp (ví dụ 512×512 mỗi patch, bước trượt 256 px), chạy PGA-UNet trên từng patch với heatmap câu nhắc được chiếu về tọa độ cục bộ tương ứng, sau đó tổng hợp mask từ các patch bằng phép hợp; (b) *Hierarchical Encoder*: bộ mã hóa phân cấp (như Swin Transformer với window attention) cho phép học đặc trưng cục bộ chi tiết mà không tốn bộ nhớ theo bậc hai như ViT thông thường. Cả hai phương án đều giữ nguyên module phân đoạn và cơ chế câu nhắc hiện có, chỉ thay thế bước tiền xử lý kích thước đầu vào. Hướng này đặc biệt quan trọng cho sub-category *Tổn thương nhỏ* (Mục 4.3.3), nhóm hưởng lợi nhiều

nhất từ việc bảo toàn độ phân giải.

- **Hướng 3: Học bán giám sát dựa trên câu nhắc thừa và thông tin lâm sàng (Prompt-Guided Semi-Supervised Learning):**

Toàn bộ thực nghiệm hiện tại giả định mỗi ảnh huấn luyện đều có mặt nạ phân đoạn pixel-level đầy đủ, trong khi chi phí gán nhãn polygon do bác sĩ chuyên khoa thực hiện là rất tốn kém và khó mở rộng quy mô. Hướng này đề xuất giảm phụ thuộc vào nhãn đầy đủ bằng cách khai thác chính đặc tính của PGA-UNet: mô hình vốn đã nhận bounding box làm câu nhắc, mà bounding box lại là loại nhãn rẻ hơn polygon rất nhiều (chỉ cần khoanh một hình chữ nhật thay vì vẽ đường biên chi tiết).

Cụ thể, tập huấn luyện được chia thành hai nhóm: một tập nhỏ có đầy đủ (ảnh, bounding box, mặt nạ pixel-level) huấn luyện có giám sát như hiện tại, và một tập lớn hơn nhiều chỉ có (ảnh, bounding box, thông tin lâm sàng) mà không có mặt nạ pixel-level. Với tập không nhãn pixel, PGA-UNet huấn luyện từ tập nhỏ được dùng để sinh nhãn giả (pseudo-mask); thông tin lâm sàng (tuổi, vị trí đau, kết quả xét nghiệm, cùng nguồn dữ liệu với Hướng 1) đóng vai trò bộ lọc độ tin cậy: chỉ giữ lại nhãn giả tại những ca có ngữ cảnh lâm sàng phù hợp với dự đoán hình ảnh (ví dụ vị trí đau khớp với vị trí mô hình khoanh vùng), loại bỏ nhãn giả ở các ca có mâu thuẫn ngữ cảnh rõ ràng. Kết hợp cùng ràng buộc nhất quán (consistency regularization) giữa các phép biến đổi câu nhắc khác nhau trên cùng một ảnh (Zoom-out/Shift/Mixed đã có sẵn từ Chương 3), hướng này cho phép mở rộng quy mô tập huấn luyện đáng kể mà không cần tăng tương ứng chi phí gán nhãn polygon, đặc biệt phù hợp khi mở rộng sang các bộ dữ liệu mới như FracAtlas (Mục 4.4) nơi nhãn pixel-level đầy đủ không phải lúc nào cũng sẵn có.

TÀI LIỆU THAM KHẢO

- [1] Abedeen, Iftekharul et al. “FracAtlas: A Dataset for Fracture Classification, Localization and Segmentation of Musculoskeletal Radiographs”. In: *Scientific Data* 10 (2023), p. 521. DOI: 10.1038/s41597-023-02432-4.
- [2] Cambridge University Hospitals NHS Foundation Trust. *X-ray – Imaging & Radiology*. <https://www.cuh.nhs.uk/our-services/imaging-radiology/x-ray/>. Truy cập năm 2025. 2024.
- [3] Cheng, Junlong et al. “SAM-Med2D”. In: *arXiv preprint arXiv:2308.16184* (2023). URL: <https://arxiv.org/abs/2308.16184>.
- [4] Dwyer, Brad, Nelson, Joseph, and Solawetz, Jacob. *Roboflow: Give Your Software the Power to See*. <https://roboflow.com>. 2023.
- [5] Jocher, Glenn, Chaurasia, Ayush, and Qiu, Jing. *Ultralytics YOLO11*. <https://docs.ultralytics.com/models/yolo11>. Phiên bản 11. 2024.
- [6] Oktay, Ozan et al. “Attention U-Net: Learning Where to Look for the Pancreas”. In: *Medical Imaging with Deep Learning (MIDL)*. 2018. URL: <https://arxiv.org/abs/1804.03999>.
- [7] Ronneberger, Olaf, Fischer, Philipp, and Brox, Thomas. “U-Net: Convolutional Networks for Biomedical Image Segmentation”. In: *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*. Springer, 2015, pp. 234–241. DOI: 10.1007/978-3-319-24574-4_28.
- [8] Tan, Mingxing and Le, Quoc V. “EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks”. In: *International Conference on Machine Learning (ICML)*. 2019, pp. 6105–6114. URL: <https://arxiv.org/abs/1905.11946>.

- [9] Yao, Shunhan et al. “A Radiograph Dataset for the Classification, Localization, and Segmentation of Primary Bone Tumors”. In: *Scientific Data* 12 (2025), p. 88. DOI: 10.1038/s41597-024-04311-y.