

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Thông Lúc - Nguyễn Hữu Bình

Phát triển hệ thống phân đoạn ảnh X-quang
về xương dựa vào câu nhắc trực quan

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN CNTT
CHƯƠNG TRÌNH CHUẨN

Tp. Hồ Chí Minh, tháng 07/2026

**TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN**

**Thông Lúc - 22120196
Nguyễn Hữu Bình - 22120031**

**Phát triển hệ thống phân đoạn ảnh X-quang
về xương dựa vào câu nhắc trực quan**

**KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN CNTT
CHƯƠNG TRÌNH CHUẨN**

GIẢNG VIÊN HƯỚNG DẪN

PGS.TS. Lý Quốc Ngọc

ThS. Đỗ Thị Thanh Hà

Tp. Hồ Chí Minh, tháng 07/2026

LỜI CẢM ƠN

Em xin gửi lời cảm ơn chân thành đến **PGS.TS. Lý Quốc Ngọc** và **ThS. Đỗ Thị Thanh Hà** đã tận tình hướng dẫn, định hướng nghiên cứu và dành thời gian phản hồi chi tiết trong suốt quá trình thực hiện khóa luận. Những góp ý thẳng thắn và sâu sắc của thầy cô đã giúp em nhận ra nhiều thiếu sót trong tư duy và cách tiếp cận bài toán, đồng thời là động lực để em không ngừng cải thiện chất lượng công trình.

Em cũng xin cảm ơn **Khoa Công nghệ Thông tin**, Trường Đại học Khoa học Tự nhiên, ĐHQG-HCM đã tạo điều kiện học tập và nghiên cứu thuận lợi trong suốt những năm qua, cung cấp nền tảng kiến thức và môi trường học thuật để em có thể tự tin tiếp cận một bài toán ứng dụng trí tuệ nhân tạo trong lĩnh vực y tế.

Mặc dù đã cố gắng hết sức, công trình này chắc chắn vẫn còn nhiều hạn chế. Em rất mong nhận được những góp ý thêm từ quý thầy cô và hội đồng phản biện để tiếp tục hoàn thiện.

Thành phố Hồ Chí Minh, tháng 6 năm 2026

Nhóm sinh viên thực hiện

Thông Lúc (MSSV: 22120196)

Nguyễn Hữu Bình (MSSV: 22120031)



ĐỀ CƯƠNG KHOÁ LUẬN TỐT NGHIỆP

PHÁT TRIỂN HỆ THỐNG PHÂN ĐOẠN ẢNH X-QUANG VỀ XƯƠNG DỰA VÀO CÂU NHẮC TRỰC QUAN

(Developing a bone X-ray image segmentation system based on visual prompts)

1 THÔNG TIN CHUNG

Người hướng dẫn:

- PGS.TS. Lý Quốc Ngọc (Khoa Công nghệ Thông tin)
- ThS. Đỗ Thị Thanh Hà (Khoa Công nghệ Thông tin)

Nhóm sinh viên thực hiện:

1. Nguyễn Hữu Bình (MSSV: 22120031)
2. Thông Lúc (MSSV: 22120196)

Loại đề tài: Nghiên cứu

Thời gian thực hiện: Từ 01/2026 đến 07/2026

2 NỘI DUNG THỰC HIỆN

2.1 Giới thiệu về đề tài

Chẩn đoán hình ảnh qua X-quang là phương thức cận lâm sàng phổ biến và quan trọng trong phát hiện các tổn thương xương như gãy xương, rạn xương và khối u xương nguyên phát. Tại các cơ sở y tế lớn, số lượng ca chụp X-quang mỗi ngày lên đến hàng trăm ca, đặt áp lực đáng kể lên đội ngũ bác sĩ về tốc độ đọc phim và độ chính xác chẩn đoán. Bước xác định và khoanh vùng tổn thương (phân đoạn ảnh) là cơ sở để đo lường kích thước khối u, theo dõi diễn tiến bệnh và lập kế hoạch điều trị; tuy nhiên hiện tại vẫn được thực hiện thủ công trên hệ thống PACS, tiêu tốn nhiều thời gian và phụ thuộc vào kinh nghiệm cá nhân.

Các mô hình học sâu tự động như U-Net [6] đã đạt kết quả khả quan trong phân đoạn ảnh y khoa, nhưng gặp khó khăn đặc thù trên ảnh X-quang xương: độ tương phản thấp, cấu trúc giải phẫu chồng lấp khiến vùng tổn thương dễ bị nhầm lẫn với mô xương lành. Các mô hình nền tảng dạng câu nhắc (prompt-based) như SAM-Med2D [2] mở ra hướng tiếp cận tương tác nhưng có kiến trúc rất nặng ($\sim 91M$ tham số), chi phí tính toán cao, không phù hợp triển khai trên phần cứng y tế thông thường.

Đề tài đề xuất xây dựng kiến trúc **PGA-UNet** (Prompt-Guided Attention U-Net): mô hình U-Net nhẹ tích hợp sâu câu nhắc hộp giới hạn của bác sĩ vào cả bộ mã hóa và bộ giải mã, kết hợp module phân lớp sàng lọc để tạo thành pipeline xử lý đầu cuối hoàn chỉnh. Toàn bộ hệ thống được huấn luyện và đánh giá trên bộ dữ liệu BTXRD (Bone Tumor X-Ray Dataset) [8].

2.2 Mục tiêu đề tài

1. **Đề xuất và xây dựng kiến trúc PGA-UNet:** Thiết kế mô hình phân đoạn nhẹ ($\sim 3M$ tham số) tích hợp câu nhắc hộp giới hạn qua Cổng không gian (Prompt Spatial Gate) tại bộ mã hóa và Cơ chế chú ý có điều kiện (Conditioned Attention Decoder) tại bộ giải mã;

huấn luyện từ đầu trên BTXRD với chiến lược tăng cường câu nhắc (empty/noisy prompt) để tăng tính bền bỉ.

2. **Phát triển module sàng lọc (Gatekeeper):** Xây dựng mô hình phân lớp nhị phân EfficientNet_B3 [7] để tự động phân biệt ảnh bình thường và ảnh có bệnh lý, ghép với PGA-UNet thành pipeline đầu cuối.
3. **Thực nghiệm và đánh giá toàn diện:** So sánh PGA-UNet với U-Net [6], Attention U-Net [5] và SAM-Med2D [2] trên các chỉ số Dice, IoU, Precision, Recall; đánh giá tính bền bỉ với câu nhắc không hoàn hảo; đánh giá pipeline toàn hệ thống trên tập dữ liệu hỗn hợp mô phỏng điều kiện lâm sàng thực tế.

2.3 Phạm vi của đề tài

Phạm vi thực hiện:

- Dữ liệu: Bộ dữ liệu BTXRD [8] (ảnh X-quang xương 2D thực tế, công bố trên Nature Scientific Data).
- Bài toán: Phân đoạn nhị phân vùng khối u xương (pixel-level mask) với câu nhắc hộp giới hạn; phân lớp nhị phân bình thường/bệnh lý.
- Đánh giá: So sánh với các mô hình nền tảng (U-Net [6], Attention U-Net [5], SAM-Med2D [2]) và đánh giá pipeline end-to-end trên tập kiểm tra hỗn hợp.

Giới hạn:

- Chỉ xử lý ảnh X-quang 2D, không bao gồm CT 3D hay MRI.
- Câu nhắc đầu vào là hộp giới hạn; chưa hỗ trợ câu nhắc dạng điểm hoặc văn bản.
- Hệ thống đóng vai trò hỗ trợ chẩn đoán, không thay thế quyết định lâm sàng của bác sĩ.

2.4 Cách tiếp cận thực hiện

Giai đoạn 1: Nghiên cứu tài liệu: Khảo sát kiến trúc U-Net [6], Attention U-Net [5], SAM-Med2D [2]; tìm hiểu cơ chế tích hợp câu nhắc không gian vào mạng tích chập; phân tích đặc điểm bộ dữ liệu BTXRD [8].

Giai đoạn 2: Chuẩn bị dữ liệu: Gán nhãn bounding box nhiều qua Roboflow [3], finetune YOLOv11s [4] để phát hiện và xóa nhiễu trên toàn tập ảnh. Sau đó, tạo các tệp mặt nạ nhị phân tương ứng với ảnh từ các tệp chú thích và chia tập huấn luyện/xác thực/kiểm tra.

Giai đoạn 3: Thiết kế và huấn luyện mô hình:

- Biểu diễn câu nhắc hộp giới hạn dưới dạng Plateau Heatmap (vùng trong bbox gán giá trị 1, làm mịn biên bằng Gaussian 31×31).
- PGA-UNet: Cổng không gian tăng cường đặc trưng vùng câu nhắc tại bộ mã hóa; Cơ chế chú ý có điều kiện điều chỉnh attention gate bằng đặc trưng câu nhắc với trọng số giảm dần tại bộ giải mã.
- Huấn luyện từ đầu với hàm mất mát Dice + BCE; có thực hiện tăng cường ảnh trong quá trình huấn luyện (lật ngang 50%, xoay $\pm 15^\circ$ với xác suất 50%).
- EfficientNet_B3 tinh chỉnh hai giai đoạn (đóng băng backbone rồi mở toàn bộ) cho bài toán phân lớp sàng lọc.

Giai đoạn 4: Thực nghiệm và đánh giá: So sánh định lượng Dice/IOU/Precision/Recall/HD95 với các mô hình baseline; ablation study từng thành phần kiến trúc; đánh giá tính bền bỉ kích bản prompt lệch tâm; đánh giá pipeline toàn hệ thống trên tập hỗn hợp bình thường và bệnh lý.

2.5 Kết quả dự kiến của đề tài

- **Bộ dữ liệu đã xử lý:** Tập ảnh BTXRD sạch nhiễu kỹ thuật, kèm nhãn phân đoạn polygon và bounding box prompt, chia sẵn tập huấn luyện/xác thực/kiểm tra.

- **Mô hình PGA-UNet:** Kiến trúc $\sim 3M$ tham số, dự kiến đạt Dice $\geq 0,80$ và IoU $\geq 0,70$ trên tập kiểm tra với câu nhắc hợp lệ; thể hiện tính bền bỉ khi câu nhắc bị lệch tâm.
- **Pipeline end-to-end:** EfficientNet_B3 đạt AUC-ROC $\geq 0,92$; đánh giá pipeline toàn hệ thống (Dice, IoU tính trên cả trường hợp âm tính giả) phản ánh sát điều kiện lâm sàng.
- **Báo cáo và mã nguồn:** Báo cáo khóa luận hoàn chỉnh; bộ mã nguồn có chú thích đầy đủ, tái tạo được toàn bộ kết quả thực nghiệm.

2.6 Kế hoạch thực hiện

Giai đoạn	Nội dung	Thời gian
1	Nghiên cứu tài liệu; phân tích bộ dữ liệu BTXRD	Tuần 1–3 (01/2026)
2	Tiền xử lý để loại bỏ nhiễu; tạo nhãn mặt nạ phân đoạn từ các tệp dữ liệu; chia tập dữ liệu	Tuần 4–7 (02/2026)
3	Thiết kế và huấn luyện PGA-UNet; module phân lớp EfficientNet_B3	Tuần 8–14 (03–04/2026)
4	Thực nghiệm so sánh; ablation study; đánh giá tính bền bỉ	Tuần 15–18 (04–05/2026)
5	Đánh giá pipeline end-to-end trên tập hỗn hợp	Tuần 19–21 (05/2026)
6	Viết báo cáo khóa luận; chuẩn bị bảo vệ	Tuần 22–26 (06–07/2026)

TÀI LIỆU THAM KHẢO

- [1] O. Ronneberger, P. Fischer, and T. Brox, “U-Net: Convolutional Networks for Biomedical Image Segmentation,” in *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, Springer, 2015, pp. 234–241.
- [2] O. Oktay et al., “Attention U-Net: Learning Where to Look for the Pancreas,” in *Proc. Medical Imaging with Deep Learning (MIDL)*, 2018. arXiv:1804.03999.
- [3] J. Cheng et al., “SAM-Med2D,” arXiv preprint arXiv:2308.16184, 2023.
- [4] T.-T. Nguyen et al., “BTXRD: A Bone Tumor X-Ray Dataset for Segmentation and Detection,” *Scientific Data*, Nature, 2024.

XÁC NHẬN
CỦA NGƯỜI HƯỚNG DẪN
(Ký và ghi rõ họ tên)

TP. Hồ Chí Minh, ngày ... tháng ... năm ...
NHÓM SINH VIÊN THỰC HIỆN
(Ký và ghi rõ họ tên)

MỤC LỤC

Lời cảm ơn	i
Đề cương chi tiết	ii
Mục lục	viii
Tóm tắt	xiv
1 GIỚI THIỆU	1
1.1 Bối cảnh chung	1
1.2 Động lực nghiên cứu	2
1.2.1 Động lực khoa học	2
1.2.2 Động lực thực tiễn	3
1.3 Phát biểu bài toán	3
1.4 Thách thức của bài toán	5
1.5 Đóng góp của khóa luận	5
1.6 Bố cục của khóa luận	6
2 CÁC CÔNG TRÌNH LIÊN QUAN VÀ CƠ SỞ LÝ THUYẾT	8
2.1 Các công trình liên quan	8
2.1.1 Các phương pháp phân đoạn ảnh y khoa tự động	8
2.1.2 Phương pháp học máy tương tác trong y khoa	9
2.2 Cơ sở lý thuyết nền tảng	10
2.2.1 Mạng nơ-ron tích chập (CNN)	10
2.2.2 Kiến trúc U-Net	11
2.2.3 Cơ chế chú ý và kiến trúc Attention U-Net	12
2.3 Học máy dựa trên câu nhắc trong thị giác máy tính	14

2.3.1	Biểu diễn không gian của câu nhắc trực quan	14
2.3.2	Cơ chế chú ý có điều kiện	15
2.4	Các độ đo đánh giá hiệu năng	16
2.4.1	Hệ số Dice và chỉ số IoU	16
2.4.2	Độ chính xác (Precision) và Độ bao phủ (Recall) .	17
2.4.3	Khoảng cách Hausdorff 95% (HD95)	18
2.4.4	Độ chuẩn xác định vị tâm (CBL)	19
2.5	Tổng kết chương	19
3	MÔ HÌNH VÀ HỆ THỐNG ĐỀ XUẤT	21
3.1	Kiến trúc tổng thể của hệ thống	21
3.2	Tiền xử lý dữ liệu và loại bỏ nhiễu ảnh X-quang	23
3.2.1	Bộ dữ liệu BTXRD	23
3.2.2	Quy trình tiền xử lý và loại bỏ nhiễu	24
3.3	Mô hình phân đoạn PGA-UNet (Prompt-Guided Attention U-Net)	26
3.3.1	Biểu diễn câu nhắc trực quan (Prompt Heatmap Representation)	26
3.3.2	Cổng không gian tại bộ mã hóa (Prompt Spatial Gate - Encoder)	28
3.3.3	Cơ chế chú ý có điều kiện tại bộ giải mã (Conditioned Attention Decoder)	29
3.3.4	Chiến lược huấn luyện và so sánh với mô hình nền tảng SAM-Med2D	31
3.4	Module gác cổng sàng lọc (Gatekeeper)	33
4	THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ	35
4.1	Thiết lập môi trường thực nghiệm	35
4.1.1	Tập dữ liệu ảnh X-quang (Dataset)	35
4.1.2	Cấu hình huấn luyện (Hyperparameters, Loss functions)	37
4.2	Đánh giá hiệu năng kiến trúc PGA-UNet	38

4.2.1	Đánh giá cơ sở (Baseline Comparison): U-Net vs. Attention U-Net vs. PGA-UNet	38
4.2.2	Đánh giá tính bền bỉ (Robustness): Kịch bản Zoom-out, Shift và Mixed	39
4.2.3	So sánh với SAM-Med2D (SOTA Prompt-based) . .	41
4.2.4	So sánh hiệu quả tính toán	42
4.3	Phân tích kiến trúc và khả năng tổng quát hóa	43
4.3.1	Ablation kiến trúc: Đóng góp của PSG và CAD . .	43
4.3.2	Kiểm định độ ổn định bằng đánh giá chéo (Cross-validation)	44
4.3.3	Đánh giá theo đặc tính tổn thương (Sub-Category)	45
4.4	Trực quan hóa kết quả (Qualitative Results)	48
4.4.1	Trực quan hóa các kịch bản phân đoạn tiêu biểu . .	48
4.5	Giới hạn kiến trúc và phân tích trường hợp thất bại	49
4.5.1	Trường hợp PGA-UNet dự đoán kém	49
4.6	Đánh giá pipeline end-to-end với module Gatekeeper hỗ trợ	49
4.7	Đánh giá mô hình phân lớp góc cổng	50
4.7.1	Phân tích sai số tích lũy của pipeline (Cascading Error)	52
4.8	Đánh giá pipeline end-to-end trên dữ liệu hỗn hợp	53
5	KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	56
5.1	Kết luận những đóng góp đạt được	56
5.2	Hạn chế của hệ thống	57
5.3	Định hướng phát triển tương lai	57
	Tài liệu tham khảo	60

DANH SÁCH HÌNH

2.1	Kiến trúc SAM-Med2D [2]: Bộ mã hóa ảnh ViT-B (tham số đóng băng ●) được chèn thêm các lớp Adapter nhỏ gọn (tham số học được ●) vào sau mỗi khối Transformer. Câu nhắc bounding box đi qua Prompt Encoder để tạo positional embedding; Mask Decoder kết hợp đặc trưng ảnh và embedding câu nhắc để xuất mặt nạ phân đoạn. Toàn bộ mô hình được tinh chỉnh trên SA-Med2D-20M (khoảng 4,6 triệu ảnh y tế 2D đa phương thức).	10
2.2	Kiến trúc mạng U-Net với 4 cấp độ phân giải: nhánh mã hóa (trái) giảm mẫu dần qua Max Pooling; nhánh giải mã (phải) khôi phục độ phân giải qua UpConv; các kết nối tắt nối đặc trưng cùng cấp từ encoder sang decoder để bù thông tin vị trí không gian bị mất.	12
2.3	Kiến trúc Attention U-Net: các Cổng chú ý (Attention Gates) được chèn tại các kết nối tắt, sử dụng tín hiệu gating g từ bộ giải mã để lọc bỏ nhiễu nền trước khi truyền đặc trưng sang tầng giải mã tương ứng.	13
3.1	Pipeline tổng thể hệ thống: đầu vào gồm ảnh X-quang và bounding box, qua EfficientNet_B3 sàng lọc tự động, âm tính dừng, dương tính chuyển sang PGA-UNet phân đoạn có hướng dẫn.	22
3.2	Quy trình tiền xử lý dữ liệu: gán nhãn bounding box nhiễu thủ công trên một phần ảnh qua Roboflow, finetune YOLOv11s, detect nhiễu trên toàn bộ tập ảnh PNG, tô màu vùng nhiễu bằng màu nền được chọn.	25

3.3	Kiến trúc PGA-UNet (Prompt-Guided Attention U-Net): Cổng không gian (Prompt Spatial Gate) tích hợp bản đồ nhiệt câu nhắc vào bộ mã hóa để tăng cường đặc trưng có chọn lọc; Cơ chế chú ý có điều kiện (Conditioned Attention) ràng buộc tín hiệu gating bằng câu nhắc tại từng tầng giải mã với hệ số w_l theo từng tầng	31
4.1	Thực quan hóa kết quả phân đoạn của PGA-UNet kích bản Zoom-out: ảnh gốc (trái), mặt nạ Ground Truth (giữa), mặt nạ dự đoán (phải). Đường biên bám sát GT nhờ cơ chế Prompt Spatial Gate và Conditioned Attention.	48

DANH SÁCH BẢNG

3.1	So sánh chiến lược huấn luyện giữa PGA-UNet và SAM-Med2D	33
4.1	Thống kê phân bố bộ dữ liệu thực nghiệm	36
4.2	So sánh hiệu năng phân đoạn: U-Net, Attention U-Net (tự động, N=187 ảnh) so với PGA-UNet kích bản Zoom-out lý tưởng (prompt-guided, N=232 mẫu per-polygon)	39
4.3	Đánh giá tính bền bỉ của PGA-UNet trên 3 kích bản prompt (N=232 mẫu per-polygon)	40
4.4	So sánh toàn diện PGA-UNet với SAM-Med2D fine-tuned và SAM-Med2D zero-shot trên 3 kích bản prompt (N=232 mẫu per-polygon). HD95* chuẩn hóa theo kích thước ảnh: $\text{PGA} \div 512$, $\text{SAM} \div 256$	41
4.5	So sánh hiệu quả tính toán: PGA-UNet vs SAM-Med2D .	43
4.6	Ablation study: Dice Score trên 3 kích bản prompt của 5 biến thể kiến trúc PGA-UNet (N=232 mẫu per-polygon). V5 là mô hình đề xuất.	44
4.7	Kết quả đánh giá chéo 4-fold PGA-UNet trên 3 kích bản prompt (trung bình 4 fold)	45
4.8	Dice Score từng fold trong đánh giá chéo 4-fold PGA-UNet (kích bản Zoom-out / Shift / Mixed)	45
4.9	So sánh hiệu năng PGA-UNet với U-Net và Att-UNet theo độ khó tác vụ ($N = 187$ ảnh, phân nhóm 50 dễ nhất / 50 khó nhất theo Dice của U-Net; PGA tính trên polygon) . .	46
4.10	So sánh PGA-UNet với SAM-Med2D trên ba nhóm đặc tính lâm sàng (kích bản Zoom-out, 50 mẫu per-polygon mỗi nhóm)	47
4.11	Kết quả đánh giá hiệu năng của mô hình phân lớp sàng lọc trên tập kiểm thử	51

4.12 Kết quả pipeline end-to-end trên tập dataset_online (hỗn hợp bình thường + có bệnh)	54
---	----

TÓM TẮT KHÓA LUẬN

Khóa luận này nghiên cứu và phát triển một hệ thống hỗ trợ chẩn đoán ảnh X-quang xương dựa trên cơ chế câu nhắc trực quan (visual prompt), nhằm giải quyết bài toán phân đoạn tương tác trong y khoa.

Bài toán: Các phương pháp phân đoạn tự động hiện tại (U-Net, Attention U-Net) hoạt động như hộp đen, không tận dụng được tri thức lâm sàng của bác sĩ, dẫn đến hiện tượng nhận diện sai trên ảnh X-quang có độ tương phản thấp và cấu trúc chồng lấp. Trong khi đó, các mô hình nền tảng tương tác (SAM, MedSAM) đòi hỏi tài nguyên tính toán vượt quá khả năng triển khai thời gian thực tại các cơ sở y tế.

Giải pháp: Khóa luận đề xuất kiến trúc PGA-UNet (Prompt-Guided Attention U-Net), tích hợp Cổng không gian (Prompt Spatial Gate) tại bộ mã hóa và Cơ chế chú ý có điều kiện (Conditioned Attention) tại bộ giải mã, cho phép mô hình CNN hạng nhẹ tiếp nhận và khai thác hiệu quả thông tin câu nhắc từ bác sĩ.

Kết quả: Trên tập kiểm thử 232 mẫu ảnh X-quang xương, PGA-UNet đạt $\text{Dice} = 0.8524$ (Zoom-out), vượt trội so với U-Net (0.4534) và SAM-Med2D fine-tuned (0.7350) trong điều kiện so sánh khác paradigm (tương tác so với tự động). Mô hình thể hiện tính bền bỉ cao khi câu nhắc bị lệch: $\text{Dice} = 0.8382$ ở kịch bản 100% Shift, chênh lệch chỉ 0.0142 so với câu nhắc lý tưởng. Toàn bộ hệ thống được tích hợp vào ứng dụng phần mềm hỗ trợ chẩn đoán.

Từ khóa: Phân đoạn ảnh y khoa, câu nhắc trực quan, X-quang xương, U-Net, phân đoạn tương tác.

CHƯƠNG 1

GIỚI THIỆU

1.1 Bối cảnh chung

Chẩn đoán hình ảnh thông qua tia X (X-quang) là một trong những phương thức cận lâm sàng phổ biến và quan trọng nhất trong y khoa hiện đại. Nhờ khả năng hiển thị trực tiếp cấu trúc xương mà không cần can thiệp xâm lấn, X-quang được sử dụng rộng rãi để phát hiện và theo dõi các tổn thương về xương như gãy xương, rạn xương, thoái hóa khớp và các khối u xương. Tại các cơ sở y tế có lưu lượng bệnh nhân lớn, con số này là rất đáng kể. Điển hình, Cambridge University Hospitals (Anh) thực hiện hơn 174.000 ca chụp X-quang mỗi năm, riêng khoa X-quang ngoại trú tiếp nhận từ 200 đến 300 bệnh nhân mỗi ngày [1]. Khối lượng công việc như vậy đặt ra áp lực đáng kể lên đội ngũ bác sĩ chẩn đoán hình ảnh, làm tăng nguy cơ sai sót do mỏi mắt và quá tải.

Trong các hệ thống hỗ trợ chẩn đoán bằng máy tính, bước xác định và khoanh vùng tổn thương hay còn gọi là *phân đoạn ảnh* (image segmentation) đóng vai trò tiền đề quan trọng. Kết quả phân đoạn là cơ sở để đo lường kích thước tổn thương, theo dõi diễn tiến theo thời gian và lập kế hoạch điều trị. Tuy nhiên, việc thực hiện phân đoạn thủ công trên hệ thống PACS (Picture Archiving and Communication System) đòi hỏi nhiều thời gian, phụ thuộc lớn vào kinh nghiệm cá nhân của bác sĩ và tiềm ẩn nguy cơ sai sót do mỏi mắt hoặc áp lực công việc.

Những hạn chế trên đã thúc đẩy cộng đồng nghiên cứu tìm kiếm các giải pháp hỗ trợ chẩn đoán tự động dựa trên học sâu (deep learning). Trong khoảng một thập kỷ qua, các kiến trúc mạng nơ-ron tích chập như U-Net [6] đã đạt được kết quả đáng khích lệ trong bài toán phân đoạn ảnh y khoa. Song song đó, sự ra đời của các mô hình nền tảng như SAM

(Segment Anything Model) đã phổ biến hóa mô hình phân đoạn dựa trên câu nhắc trực quan và thúc đẩy mạnh mẽ hướng nghiên cứu tương tác giữa người và máy. Đây chính là nền tảng khoa học mà khóa luận này được xây dựng trên.

1.2 Động lực nghiên cứu

1.2.1 Động lực khoa học

Mặc dù đã đạt nhiều tiến bộ, các phương pháp phân đoạn hoàn toàn tự động vẫn tồn tại một hạn chế cốt lõi: chúng hoạt động như một *hộp đen* (black box), suy luận hoàn toàn tự động trên toàn bộ ảnh mà không có bất kỳ thông tin định hướng nào từ chuyên gia. Trong môi trường ảnh X-quang xương nơi các cấu trúc giải phẫu chồng lấp nhau và vùng tổn thương thường có độ tương phản thấp hoặc đặc điểm hình thái gần giống mô lành lân cận, cách tiếp cận này dễ dẫn đến hiện tượng phân đoạn sai lệch (false positive) hoặc bỏ sót tổn thương (false negative).

Một hướng nghiên cứu đang nhận được sự quan tâm ngày càng lớn là *phân đoạn tương tác* (interactive segmentation), nơi người dùng cung cấp một tín hiệu không gian sơ bộ chẳng hạn như một hộp giới hạn (bounding box) để định hướng mô hình tập trung vào vùng mục tiêu. Hướng tiếp cận này không chỉ cải thiện độ chính xác khi được cung cấp câu nhắc phù hợp mà còn đặt con người vào vị trí kiểm soát trong vòng lặp suy luận (human-in-the-loop), điều có ý nghĩa đặc biệt quan trọng trong ứng dụng y tế.

Tuy nhiên, việc tích hợp tín hiệu định hướng này một cách hiệu quả vào kiến trúc mạng nơ-ron cụ thể là làm thế nào để biểu diễn, mã hóa và truyền tải thông tin câu nhắc qua các tầng mạng vẫn là một hướng nghiên cứu đang được quan tâm, đặc biệt trong các bài toán ảnh y khoa chuyên biệt.

1.2.2 Động lực thực tiễn

Trong thực tế lâm sàng, không thể kỳ vọng mọi thao tác của bác sĩ đều hoàn hảo. Câu nhắc mà bác sĩ cung cấp có thể bị lệch tâm do chú ý không tập trung, hoặc thậm chí đặt sai vị trí hoàn toàn do nhầm lẫn. Một hệ thống phân đoạn đáng tin cậy trong môi trường lâm sàng cần có khả năng *chịu đựng sai sót* (fault tolerance): có khả năng nhận biết khi câu nhắc đầu vào có vấn đề và đưa ra phản hồi phù hợp, thay vì im lặng trả về một kết quả sai lệch.

Ngoài ra, việc tích hợp hệ thống vào quy trình làm việc thực tế còn đặt ra yêu cầu về tốc độ xử lý (real-time inference) và khả năng giải thích được quyết định của mô hình (model interpretability) hai yếu tố mà thường chưa được xem xét đồng thời với yêu cầu độ chính xác.

Hai động lực trên cùng nhau định hình mục tiêu của khóa luận: không chỉ là một mô hình phân đoạn chính xác, mà là một *hệ thống* đủ thông minh, bền bỉ và minh bạch để thực sự hỗ trợ được bác sĩ trong phòng khám.

1.3 Phát biểu bài toán

Người dùng cuối (End User): Bác sĩ chẩn đoán hình ảnh (radiologist) làm việc trong ca đọc phim tại phòng chẩn đoán, sử dụng hệ thống PACS để xem xét và phân tích ảnh X-quang từ nhiều bệnh nhân. Đây là người có chuyên môn lâm sàng nhưng không nhất thiết có kiến thức kỹ thuật về học sâu; thao tác duy nhất họ cần thực hiện là khoanh vùng nghi ngờ trên màn hình.

Bài toán: Cho một ảnh X-quang xương mới $\mathbf{I} \in \mathbb{R}^{H \times W}$ và hộp giới hạn $\mathbf{B} = (x_1, y_1, x_2, y_2)$ do bác sĩ khoanh lên vùng nghi ngờ có tổn thương, hệ thống cần tự động tạo ra mặt nạ phân đoạn $\hat{\mathbf{M}} \in \{0, 1\}^{H \times W}$ xác định chính xác ranh giới của tổn thương trong vùng được chỉ định, đồng thời phải bền vững trước sai lệch thực tế trong cách bác sĩ vẽ hộp (lệch tâm,

khác kích thước).

Cụ thể, đầu vào và đầu ra của hệ thống khi hoạt động trực tuyến được định nghĩa như sau:

- **Đầu vào:**

- Ảnh X-quang xương $\mathbf{I} \in \mathbb{R}^{H \times W}$ (đã qua tiền xử lý loại bỏ nhiễu kỹ thuật).
- Hộp giới hạn $\mathbf{B} = (x_1, y_1, x_2, y_2)$ do bác sĩ vẽ bao quanh vùng nghi ngờ tổn thương.

- **Đầu ra:** Mặt nạ phân đoạn nhị phân $\hat{\mathbf{M}} \in \{0, 1\}^{H \times W}$, trong đó pixel có giá trị 1 là vùng được dự đoán là tổn thương.

Luồng xử lý của hệ thống gồm hai bước tuần tự. Bước đầu, ảnh X-quang được đưa qua mô hình sàng lọc tự động: nếu không phát hiện dấu hiệu bệnh lý thì dừng lại và thông báo; nếu phát hiện dương tính thì bác sĩ tiến hành khoanh hộp và bước phân đoạn có hướng dẫn được kích hoạt:

$$\hat{\mathbf{M}} = \mathbf{1}[f_{\text{seg}}(\mathbf{I}, \mathbf{H}(\mathbf{B}); \boldsymbol{\theta}_{\text{seg}}) \geq 0.5] \quad (1.1)$$

trong đó $\mathbf{H}(\mathbf{B}) \in [0, 1]^{H \times W}$ là bản đồ nhiệt không gian được chuyển đổi từ hộp giới hạn $\mathbf{B}$ (chi tiết tại Mục 2.3.1), f_{seg} là mô hình phân đoạn PGA-UNet.

Thiết kế này phản ánh triết lý *human-in-the-loop*: hệ thống tự động hóa bước sàng lọc nhưng trao quyền định hướng không gian cho bác sĩ ở bước phân đoạn, đảm bảo tri thức lâm sàng của chuyên gia luôn tham gia vào vòng lặp quyết định. Chi tiết về kiến trúc và quy trình huấn luyện ngoại tuyến (offline) của hai mô hình được trình bày tại Chương 3.

1.4 Thách thức của bài toán

Việc xây dựng hệ thống như đã phát biểu ở trên đối mặt với bốn nhóm thách thức chính:

Thách thức về dữ liệu: Tập dữ liệu X-quang xương trong thực tế thường không sạch, chứa các nguồn nhiễu kỹ thuật như ký hiệu chữ R/L, các dòng văn bản thông tin bệnh nhân, thiết bị cố định xương khác nhau đều có thể ảnh hưởng tiêu cực đến quá trình học nếu không được xử lý cẩn thận. Đây là thách thức mang tính kỹ thuật phòng thí nghiệm nhưng có ảnh hưởng đáng kể đến chất lượng của toàn bộ hệ thống.

Thách thức về mô hình hóa: Ảnh X-quang xương có độ tương phản thấp và chứa nhiều cấu trúc giải phẫu chồng lấp. Vùng tổn thương thường có độ tương phản thấp hoặc đặc điểm hình thái gần giống mô xương lành lân cận, gây khó khăn cho việc trích xuất đặc trưng phân biệt. Thách thức đặt ra là làm thế nào để tích hợp thông tin câu nhắc vào kiến trúc mạng một cách hiệu quả, sao cho mô hình thực sự *sử dụng* câu nhắc để định hướng phân đoạn chứ không đơn thuần bỏ qua nó.

Thách thức về tính bền bỉ: Trong thực tế, câu nhắc của bác sĩ có thể tồn tại sai lệch, hộp giới hạn có thể bị lệch tâm do chú ý không tập trung hoặc góc nhìn chủ quan. Hệ thống cần duy trì hiệu năng phân đoạn ổn định ngay cả khi câu nhắc bị lệch một lượng đáng kể, chứ không bị phụ thuộc cứng nhắc vào vị trí tâm câu nhắc.

Thách thức về khả năng triển khai: Một hệ thống cần có thời gian phản hồi đủ nhanh trong điều kiện phần cứng thực tế để thuận tiện cho quy trình lâm sàng. Điều này đặt ra yêu cầu về hiệu quả tính toán: đạt độ chính xác phân đoạn cao với số lượng tham số tối thiểu.

1.5 Đóng góp của khóa luận

Khóa luận có hai đóng góp chính:

1. Phương pháp hướng dẫn mềm qua Prompt Heatmap: Thay

vì mã hóa hộp giới hạn thành vector rời rạc (như SAM/SAM-Med2D) hoặc dùng mặt nạ nhị phân phẳng, khóa luận đề xuất biểu diễn câu nhắc dưới dạng bản đồ nhiệt không gian liên tục (Gaussian-smoothed Heatmap) — một kênh dữ liệu đi song hành cùng ảnh X-quang vào toàn bộ mạng. Cách biểu diễn liên tục này cho phép mạng học tín hiệu định hướng có gradient mượt, không ghi nhớ cứng nhắc đường biên hộp, từ đó nâng cao tính bền vững khi bác sĩ vẽ hộp không chính xác. Ablation study xác nhận cách tiếp cận này cải thiện Dice Score ở kích bản câu nhắc bị lệch tâm lên +0.10 so với dùng mặt nạ nhị phân. Kiến trúc mạng PGA-UNet (~ 3 triệu tham số) được thiết kế để khai thác tín hiệu hướng dẫn liên tục này thông qua các cơ chế không gian và chú ý phù hợp, so sánh với U-Net, Attention U-Net và SAM-Med2D trên bộ dữ liệu BTXRD.

2. **Đánh giá thực nghiệm toàn pipeline:** Xây dựng kịch bản đánh giá end-to-end kết hợp module phân lớp (EfficientNet_B3) và PGA-UNet, mô phỏng luồng xử lý thực tế trên tập dữ liệu hỗn hợp gồm cả ảnh bình thường và ảnh bệnh lý, phản ánh điều kiện triển khai lâm sàng sát thực hơn so với đánh giá phân đoạn đơn lẻ.

1.6 Bố cục của khóa luận

Khóa luận được tổ chức thành năm chương với nội dung như sau:

Chương 1: Giới thiệu trình bày bối cảnh chung, động lực khoa học và thực tiễn, phát biểu bài toán từ góc nhìn người dùng cuối (bác sĩ chẩn đoán hình ảnh) với đầu vào/đầu ra tại giai đoạn suy luận trực tuyến, các thách thức cốt lõi và đóng góp của khóa luận.

Chương 2: Các công trình liên quan và cơ sở lý thuyết khảo sát các phương pháp phân đoạn ảnh y khoa tự động và tương tác, xác định khoảng trống nghiên cứu, và trình bày nền tảng lý thuyết gồm kiến trúc U-Net, cơ chế chú ý, biểu diễn câu nhắc và các độ đo đánh giá.

Chương 3: Mô hình và hệ thống đề xuất trình bày chi tiết kỹ thuật kiến trúc PGA-UNet (Cổng không gian, Cơ chế chú ý có điều kiện), quy trình tiền xử lý dữ liệu và module phân lớp sàng lọc.

Chương 4: Thực nghiệm và đánh giá kết quả mô tả thiết lập thực nghiệm, phân tích kết quả so sánh với U-Net, Attention U-Net và SAM-Med2D, đánh giá tính bền bỉ câu nhắc và ablation study kiến trúc.

Chương 5: Kết luận và hướng phát triển tóm tắt kết quả đạt được, nhìn nhận khách quan các hạn chế và đề xuất hướng nghiên cứu tiếp theo.

CHƯƠNG 2

CÁC CÔNG TRÌNH LIÊN QUAN VÀ CƠ SỞ LÝ THUYẾT

Chương này được tổ chức thành hai phần chính. Phần đầu (Mục 2.1) khảo sát các công trình liên quan để đặt khóa luận trong bức tranh nghiên cứu hiện tại và làm rõ khoảng trống mà đề tài hướng đến giải quyết. Phần sau (Mục 2.2 đến Mục 2.4) trình bày các kiến thức lý thuyết nền tảng cần thiết để hiểu kiến trúc và cơ chế hoạt động của hệ thống đề xuất ở Chương 3.

2.1 Các công trình liên quan

2.1.1 Các phương pháp phân đoạn ảnh y khoa tự động

Trong lĩnh vực phân tích hình ảnh y khoa, kiến trúc U-Net [6] do Ronneberger và cộng sự đề xuất năm 2015 được xem là nền tảng cốt lõi cho nhiều nghiên cứu về sau. Với thiết kế mã hóa - giải mã (encoder-decoder) đối xứng, kết hợp cùng các kết nối tắt (skip connections), U-Net cho phép trích xuất đặc trưng ngữ nghĩa ở nhiều cấp độ đồng thời bảo toàn được thông tin vị trí không gian. Đặc tính này giúp mô hình đạt hiệu năng khả quan ngay cả khi huấn luyện trên các tập dữ liệu y khoa có quy mô nhỏ và thiếu hụt nhãn.

Nhằm tăng cường khả năng tập trung vào các vùng đặc trưng quan trọng và giảm ảnh hưởng của nhiễu nền, Oktay và cộng sự (2018) đã đề xuất mạng Attention U-Net [5]. Bằng cách tích hợp các Cổng chú ý (Attention Gates) tại các kết nối tắt, mô hình có khả năng tự động học cách làm nổi bật các khu vực chứa đặc trưng quan trọng và ức chế các vùng nhiễu nền trước khi đưa dữ liệu vào bộ giải mã.

Tuy nhiên, dưới góc độ triển khai thực tế trên ảnh X-quang xương, cả U-Net và Attention U-Net đều gặp phải một giới hạn chung về phương pháp luận: chúng hoạt động theo cơ chế phân đoạn hoàn toàn tự động. Mô hình chỉ nhận đầu vào duy nhất là ảnh thô và phải tự tìm kiếm vùng tổn thương mà không có bất kỳ thông tin định hướng hay tri thức lâm sàng nào từ bác sĩ. Đối với các ảnh X-quang có độ tương phản thấp và chứa các cấu trúc giải phẫu xương chồng lấp, cách tiếp cận này có thể gặp khó khăn hơn trong việc xác định chính xác vùng tổn thương, đặc biệt khi tồn tại các vùng mô lành có đặc trưng hình thái tương tự.


2.1.2 Phương pháp học máy tương tác trong y khoa

Để vượt qua một số hạn chế của các phương pháp tự động, xu hướng nghiên cứu gần đây đang quan tâm hơn đến phân đoạn có tương tác (interactive segmentation), cho phép bác sĩ cung cấp tín hiệu định hướng (hộp giới hạn, điểm bấm) để mô hình tập trung vào đúng vùng cần phân tích.

Đại diện tiêu biểu trong lĩnh vực y khoa là **SAM-Med2D** [2] (Cheng và cộng sự, 2023), mô hình được chọn làm đối sánh trực tiếp trong khóa luận. SAM-Med2D kế thừa kiến trúc Segment Anything Model (SAM) với bộ mã hóa ảnh Vision Transformer (ViT-B, ~ 91 triệu tham số), tinh chỉnh trên khoảng 4,6 triệu ảnh y khoa 2D đa phương thức bằng chiến lược chèn lớp Adapter, giữ nguyên phần lớn trọng số nền tảng, chỉ cập nhật thêm tầng Adapter và bộ giải mã. Mô hình nhận hộp giới hạn làm câu nhắc vị trí qua Prompt Encoder và xuất ra mặt nạ phân đoạn. Sơ đồ kiến trúc SAM-Med2D được minh họa tại Hình 2.1.

Tuy nhiên, SAM-Med2D vẫn tồn tại giới hạn về khả năng triển khai: bộ mã hóa ViT-B ~ 91 M tham số đòi hỏi VRAM cao hơn đáng kể so với kiến trúc CNN hạng nhẹ, và độ phân giải đầu vào cố định ở 256×256 do position embedding không thể thay đổi, giới hạn khả năng phân đoạn chi tiết trên ảnh X-quang xương vốn cần độ phân giải cao.

Khoảng trống nghiên cứu: Từ khảo sát trên, khoảng trống nghiên cứu hiện rõ: một mặt, U-Net và Attention U-Net thiếu hoàn toàn cơ chế



Hình 2.1: Kiến trúc SAM-Med2D [2]: Bộ mã hóa ảnh ViT-B (tham số đóng băng ●) được chèn thêm các lớp Adapter nhỏ gọn (tham số học được ●) vào sau mỗi khối Transformer. Câu nhắc bounding box đi qua Prompt Encoder để tạo positional embedding; Mask Decoder kết hợp đặc trưng ảnh và embedding câu nhắc để xuất mặt nạ phân đoạn. Toàn bộ mô hình được tinh chỉnh trên SA-Med2D-20M (khoảng 4,6 triệu ảnh y tế 2D đa phương thức).

tiếp nhận định hướng từ bác sĩ; mặt khác, SAM-Med2D tuy có câu nhắc nhưng kiến trúc ViT-B nặng tài nguyên và bị giới hạn độ phân giải. Khóa luận này lấp đầy khoảng trống đó bằng cách tích hợp câu nhắc trực quan trực tiếp vào kiến trúc CNN hạng nhẹ chuyên biệt cho ảnh X-quang 2D, cho phép huấn luyện hoàn toàn từ đầu trên domain đặc thù với chi phí tính toán thấp hơn đáng kể.

2.2 Cơ sở lý thuyết nền tảng

2.2.1 Mạng nơ-ron tích chập (CNN)

Mạng nơ-ron tích chập (Convolutional Neural Network - CNN) là nền tảng cốt lõi của hầu hết các mô hình học sâu hiện đại trong lĩnh vực thị giác máy tính. Khác với mạng nơ-ron truyền thống kết nối đầy đủ vốn dễ bị bùng nổ số lượng tham số khi xử lý dữ liệu ảnh, CNN sử dụng cơ chế chia sẻ trọng số và kết nối cục bộ thông qua các phép toán tích chập. Đặc tính này giúp mô hình trích xuất hiệu quả các đặc trưng không gian (như

cạnh, góc và họa tiết), đồng thời tăng mức độ bền vững đối với các dịch chuyển nhỏ của đối tượng trong ảnh.

Tại một tầng tích chập thứ l , đầu vào là bản đồ đặc trưng $\mathbf{F}^l \in \mathbb{R}^{H \times W \times C_{in}}$ sẽ được nhân chập với một tập hợp các bộ lọc $\mathbf{W} \in \mathbb{R}^{k \times k \times C_{in} \times C_{out}}$. Đầu ra của một điểm ảnh trên bản đồ đặc trưng tiếp theo được tính theo công thức tích chập rời rạc:

$$\mathbf{F}_{i,j,c}^{l+1} = \sigma \left(\sum_m \sum_n \sum_{c'} \mathbf{W}_{m,n,c',c} \cdot \mathbf{F}_{i+m,j+n,c'}^l + b_c \right) \quad (2.1)$$

trong đó k là kích thước không gian của bộ lọc, σ là hàm kích hoạt phi tuyến (thường sử dụng ReLU nhằm tăng khả năng biểu diễn phi tuyến của mô hình và góp phần giảm hiện tượng mất dần gradient trong quá trình huấn luyện), và b_c là hệ số chệch (bias). Xen kẽ với các tầng tích chập là các tầng gộp, phổ biến nhất là Max Pooling, có nhiệm vụ giảm kích thước không gian để mở rộng trường tiếp nhận (receptive field) của các bộ lọc sâu hơn.

2.2.2 Kiến trúc U-Net


Được thiết kế chuyên biệt cho các bài toán phân đoạn ảnh y khoa, U-Net [6] sở hữu kiến trúc đối xứng hình chữ "U" đặc trưng, bao gồm hai nhánh chính:

Bộ mã hóa (Encoder): Là nhánh thu nhỏ không gian ở phía bên trái. Thông qua chuỗi các phép tích chập và gộp cực đại (Max Pooling), nhánh này làm nhiệm vụ nén thông tin ảnh, trích xuất biểu diễn ngữ nghĩa từ các chi tiết cục bộ ở tầng nông thành các đặc trưng toàn cục ở tầng sâu. Quá trình này giúp mô hình học được các đặc trưng ngữ nghĩa ở mức độ ngày càng trừu tượng hơn, nhưng đồng thời làm suy giảm một phần thông tin vị trí và chi tiết không gian do quá trình giảm mẫu liên tiếp.

Bộ giải mã (Decoder): Là nhánh khôi phục không gian ở phía bên phải. Nhánh này sử dụng các phép tăng mẫu để khôi phục dần độ phân

giải của bản đồ đặc trưng về lại kích thước ban đầu của ảnh đầu vào. Trong bài toán phân đoạn nhị phân, tầng cuối cùng thường sử dụng hàm kích hoạt Sigmoid để xuất ra bản đồ xác suất theo từng điểm ảnh; đối với phân đoạn đa lớp, hàm Softmax thường được sử dụng thay thế.

Kết nối tắt (Skip connections): Đây là yếu tố đột phá làm nên thành công của U-Net. Các kết nối tắt sao chép trực tiếp các bản đồ đặc trưng độ phân giải cao từ bộ mã hóa và nối kênh (concatenate) chúng vào các bản đồ đặc trưng tương ứng tại bộ giải mã. Cơ chế này bù đắp phần thông tin không gian bị mất trong quá trình giảm mẫu, giúp mô hình tái tạo chính xác đường biên giải phẫu của tổn thương. Kiến trúc tổng thể được minh họa tại Hình 2.2.



Hình 2.2: Kiến trúc mạng U-Net với 4 cấp độ phân giải: nhánh mã hóa (trái) giảm mẫu dần qua Max Pooling; nhánh giải mã (phải) khôi phục độ phân giải qua UpConv; các kết nối tắt nối đặc trưng cùng cấp từ encoder sang decoder để bù thông tin vị trí không gian bị mất.

2.2.3 Cơ chế chú ý và kiến trúc Attention U-Net

Mặc dù các kết nối tắt trong U-Net mang lại hiệu quả cao trong việc bảo toàn thông tin không gian, chúng cũng có thể truyền sang bộ giải mã các đặc trưng ít liên quan hoặc nhiễu nền từ bộ mã hóa. Để giảm ảnh hưởng của các đặc trưng không liên quan, cơ chế chú ý (Attention Mechanism) được áp dụng nhằm tăng cường các vùng ảnh mang thông tin hữu ích và làm giảm trọng số của các vùng ít quan trọng đối với nhiệm vụ phân đoạn.

Kiến trúc Attention U-Net [5] cụ thể hóa cơ chế này bằng cách chèn các **Cổng chú ý (Attention Gates - AG)** vào ngay vị trí của các kết nối tắt. Cổng chú ý nhận hai luồng tín hiệu: bản đồ đặc trưng từ tầng mã


hóa $\mathbf{x}^l$ và tín hiệu hướng dẫn $\mathbf{g}$ (gating signal) lấy từ tầng sâu hơn của bộ giải mã (nơi chứa thông tin ngữ nghĩa mạnh).

Hệ số chú ý không gian $\boldsymbol{\alpha}^l \in [0, 1]^{H \times W}$ được tính toán như sau:

$$\boldsymbol{\alpha}^l = \sigma_2 (\mathbf{W}_\psi^\top \cdot \sigma_1 (\mathbf{W}_x \mathbf{x}^l + \mathbf{W}_g \mathbf{g} + \mathbf{b}_g) + b_\psi) \quad (2.2)$$

trong đó σ_1 là hàm kích hoạt ReLU, σ_2 là hàm Sigmoid, và $\{\mathbf{W}_x, \mathbf{W}_g, \mathbf{W}_\psi, \mathbf{b}_g, b_\psi\}$ là các tham số học được của Cổng chú ý. Bản đồ đặc trưng sau đó được nhân vô hướng với hệ số chú ý để làm nổi bật các khu vực cần thiết: $\hat{\mathbf{x}}^l = \boldsymbol{\alpha}^l \odot \mathbf{x}^l$.

Nhận xét: Cơ chế Attention Gate giúp bộ giải mã tập trung tốt hơn vào vùng tổn thương. Tuy nhiên, tín hiệu hướng dẫn $\mathbf{g}$ trong mạng Attention U-Net vẫn được trích xuất hoàn toàn từ ảnh đầu vào. Nghĩa là, việc xác định vùng quan tâm vẫn được thực hiện hoàn toàn dựa trên các đặc trưng học được từ ảnh đầu vào, mà chưa có sự hỗ trợ trực tiếp từ thông tin định hướng do người dùng cung cấp. Điều này đòi hỏi một cơ chế điều kiện hóa mạnh mẽ hơn từ tri thức chuyên gia (người dùng), tạo tiền đề cho việc phát triển kiến trúc chú ý có điều kiện dựa trên câu nhắc (Conditioned Attention) sẽ được trình bày ở Chương 3. Kiến trúc Attention U-Net được minh họa tại Hình 2.3.



Lưu ý: Mô hình này không có prompt — phân biệt với PGA-UNet (Số đồ 3).

Hình 2.3: Kiến trúc Attention U-Net: các Cổng chú ý (Attention Gates) được chèn tại các kết nối tắt, sử dụng tín hiệu gating $\mathbf{g}$ từ bộ giải mã để lọc bỏ nhiễu nền trước khi truyền đặc trưng sang tầng giải mã tương ứng.

2.3 Học máy dựa trên câu nhắc trong thị giác máy tính

Trong những năm gần đây, khái niệm "câu nhắc" (prompt), vốn được phổ biến rộng rãi trong lĩnh vực Xử lý ngôn ngữ tự nhiên (NLP), đã dần được mở rộng và ứng dụng vào nhiều bài toán Thị giác máy tính. Thay vì huấn luyện một mô hình tĩnh để tự động giải quyết một tác vụ cố định, học máy dựa trên câu nhắc cho phép mô hình linh hoạt điều chỉnh hành vi dự đoán dựa trên thông tin định hướng bổ sung (như văn bản, điểm ảnh, hoặc hộp giới hạn) do người dùng cung cấp ở pha suy luận.

2.3.1 Biểu diễn không gian của câu nhắc trực quan

Trong các phần mềm chẩn đoán hình ảnh, thao tác tương tác tự nhiên nhất của chuyên gia y tế là kéo chuột để tạo một hộp giới hạn (Bounding Box) bao quanh vùng tổn thương nghi ngờ. Giả sử hộp giới hạn này được định nghĩa bởi tọa độ hai góc đối diện $\mathbf{B} = (x_1, y_1, x_2, y_2)$. Thách thức đặt ra là làm thế nào để mã hóa tọa độ hình học này thành một định dạng mà mạng CNN có thể xử lý đồng thời với ảnh đầu vào.

Một cách tiếp cận phổ biến là chuyển đổi hộp giới hạn thành một **Bản đồ nhiệt câu nhắc** (Prompt Heatmap) $\mathbf{H} \in [0, 1]^{H \times W}$, mang cùng độ phân giải không gian với ảnh X-quang. Thay vì tạo ra một mặt nạ nhị phân cứng nhắc (chỉ chứa giá trị 1 bên trong và 0 bên ngoài hộp), bản đồ nhiệt sử dụng hàm phân phối chuẩn hai chiều (2D Gaussian) để biểu diễn mức độ tin cậy về mặt không gian.

Tâm hình học của hộp giới hạn được xác định là (μ_x, μ_y) với $\mu_x = \frac{x_1+x_2}{2}$ và $\mu_y = \frac{y_1+y_2}{2}$. Phân phối không gian của bản đồ nhiệt được tính theo phương trình:

$$H(x, y) = \exp \left(-\frac{(x - \mu_x)^2}{2\sigma_x^2} - \frac{(y - \mu_y)^2}{2\sigma_y^2} \right) \quad (2.3)$$

trong đó, σ_x và σ_y là độ lệch chuẩn kiểm soát độ rộng của hàm Gaussian theo trục x và y . Thông thường, các giá trị này được cấu hình tỉ lệ thuận với kích thước chiều rộng và chiều cao của hộp giới hạn (ví dụ: $\sigma_x = \frac{x_2 - x_1}{4}$ và $\sigma_y = \frac{y_2 - y_1}{4}$).

Cách biểu diễn không gian này mang ý nghĩa lâm sàng sâu sắc: giá trị $H(x, y)$ đạt cực đại (1.0) tại tâm của vùng bác sĩ khoanh (nơi có độ chắc chắn cao nhất về sự tồn tại của u), và giảm dần (decay) một cách mềm mại (smooth) về phía các cạnh. Điều này giúp mô hình không bị “ép buộc” học các đường biên sắc nét giả tạo từ nét khoanh tay của con người, mà coi đó như một nguồn thông tin định hướng không gian hỗ trợ quá trình học và suy luận của mô hình.

Biến thể triển khai – Plateau Heatmap: Trong thực tế, một biến thể phổ biến là *Plateau Heatmap*: gán đồng nhất giá trị 1.0 cho toàn bộ vùng bên trong hộp giới hạn (tạo vùng cao nguyên phẳng), sau đó làm mềm đường biên bằng bộ lọc Gaussian. Cách này duy trì tín hiệu mạnh và đồng đều bên trong vùng câu nhắc (thay vì suy giảm về phía tâm), phù hợp hơn khi kích thước câu nhắc sát với kích thước tổn thương. Thiết kế trong khóa luận này sử dụng biến thể Plateau Heatmap (trình bày ở Mục 3.3), trong khi phương trình Gaussian (2.3) đóng vai trò nền tảng lý thuyết cho cả hai biến thể.

2.3.2 Cơ chế chú ý có điều kiện

Sau khi đã có bản đồ nhiệt câu nhắc $\mathbf{H}$, bài toán tiếp theo là làm sao để "tiêm" (inject) thông tin này vào kiến trúc mạng U-Net. Cách đơn giản nhất là ghép nối kênh (channel concatenation) trực tiếp $\mathbf{H}$ với ảnh X-quang gốc ở ngay tầng đầu vào (Early Fusion). Tuy nhiên, trong nhiều trường hợp, tín hiệu định hướng được ghép tại tầng đầu vào có thể suy giảm ảnh hưởng khi lan truyền qua nhiều tầng tích chập sâu, khiến mô hình chưa khai thác hiệu quả thông tin câu nhắc.

Một hướng tiếp cận khác là sử dụng **Cơ chế chú ý có điều kiện (Conditioned Attention)** nhằm tích hợp thông tin câu nhắc trực tiếp

vào quá trình tính toán trọng số chú ý. Ý tưởng cốt lõi của cơ chế này là mở rộng Cổng chú ý (Attention Gate) truyền thống (đã trình bày ở Mục 2.2.3). Trong Attention U-Net truyền thống, hệ số chú ý α được sinh ra chỉ từ nội bộ các đặc trưng ảnh. Ngược lại, trong cơ chế có điều kiện, việc tính toán hệ số chú ý được ràng buộc (conditioned) rõ ràng bởi ma trận định hướng $\mathbf{H}$.

Về mặt khái niệm, bản đồ chú ý lúc này được biểu diễn dưới dạng xác suất có điều kiện: $\alpha = f(\mathbf{x}, \mathbf{g} \mid \mathbf{H})$. Nhờ đó, tại mỗi tầng của bộ giải mã, quá trình tính toán trọng số chú ý được định hướng bởi cả đặc trưng ảnh và thông tin không gian do người dùng cung cấp. Các tín hiệu đặc trưng nằm ngoài vùng được câu nhắc ưu tiên có xu hướng nhận trọng số chú ý thấp hơn, từ đó góp phần giảm hiện tượng mô hình phân đoạn sang các vùng mô lành không mong muốn. Cơ sở lý thuyết này chính là nền tảng để thiết kế kiến trúc PGA-UNet trong Chương 3 của khóa luận.

2.4 Các độ đo đánh giá hiệu năng

Trong bài toán phân đoạn ảnh y khoa, việc chỉ sử dụng một độ đo duy nhất thường không phản ánh được bức tranh toàn cảnh về chất lượng của mô hình. Một mô hình có thể có tỷ lệ chồng lấp diện tích tốt nhưng vẫn tồn tại sai lệch đáng kể ở đường biên, hoặc ngược lại. Do đó, khóa luận sử dụng một bộ độ đo toàn diện bao gồm các khía cạnh: diện tích vùng (Dice, IoU), xu hướng phân loại (Precision, Recall), chất lượng đường biên (HD95) và độ chuẩn xác vị trí tâm (CBL).

2.4.1 Hệ số Dice và chỉ số IoU

Hệ số Dice (Dice Similarity Coefficient - DSC) và chỉ số Giao trên Hợp (Intersection over Union - IoU, hay Jaccard Index) là hai thang đo tiêu chuẩn phổ biến nhất để đánh giá mức độ chồng lấp không gian giữa mặt nạ dự đoán $\hat{Y}$ và mặt nạ nhãn gốc Y .

Hệ số Dice: Đo lường gấp đôi diện tích phần giao nhau chia cho tổng diện tích của cả hai mặt nạ.

$$\text{Dice}(Y, \hat{Y}) = \frac{2|Y \cap \hat{Y}|}{|Y| + |\hat{Y}|} \quad (2.4)$$

Chỉ số IoU: Đo lường diện tích phần giao nhau chia cho diện tích phần hợp của hai mặt nạ.

$$\text{IoU}(Y, \hat{Y}) = \frac{|Y \cap \hat{Y}|}{|Y \cup \hat{Y}|} \quad (2.5)$$

Cả hai độ đo đều nhận giá trị trong khoảng $[0, 1]$, trong đó 1 thể hiện sự trùng khớp hoàn hảo. Trong bối cảnh ảnh y khoa, nơi vùng tổn thương (foreground) thường chiếm tỷ lệ nhỏ so với vùng nền (background), Dice và IoU thường được ưu tiên sử dụng hơn độ chính xác tổng thể (Accuracy), do chúng phản ánh trực tiếp mức độ chồng lấp của vùng quan tâm và ít bị ảnh hưởng bởi sự mất cân bằng giữa nền và đối tượng.

2.4.2 Độ chính xác (Precision) và Độ bao phủ (Recall)

Bên cạnh Dice và IoU, Độ chính xác (Precision) và Độ bao phủ (Recall, hay Sensitivity) cung cấp góc nhìn chi tiết hơn về xu hướng dự đoán sai của mô hình (thiên về cắt lấn nhầm hay bỏ sót u). Gọi TP là True Positive (dự đoán đúng tổn thương), FP là False Positive (dự đoán nhầm nền thành tổn thương), và FN là False Negative (bỏ sót tổn thương thực sự).

Độ chính xác (Precision): Đo lường tỷ lệ điểm ảnh là tổn thương thực sự trên tổng số điểm ảnh mà mô hình đã khoanh vùng.

$$\text{Precision} = \frac{TP}{TP + FP} \quad (2.6)$$

Độ bao phủ (Recall): Đo lường tỷ lệ điểm ảnh tổn thương thực sự

đã được mô hình nhận diện thành công.

$$\text{Recall} = \frac{TP}{TP + FN} \quad (2.7)$$

Trong thực tế lâm sàng, sự cân bằng giữa Precision và Recall rất quan trọng. Nếu mô hình có xu hướng phân đoạn quá rộng và bao gồm nhiều vùng mô lành, Recall thường tăng trong khi Precision giảm. Ngược lại, nếu mô hình phân đoạn quá bảo thủ và bỏ sót một phần vùng tổn thương, Precision có thể tăng nhưng Recall sẽ giảm.

2.4.3 Khoảng cách Hausdorff 95% (HD95)

Các thang đo dựa trên diện tích (Dice, IoU) có một điểm yếu cơ bản: chúng không nhạy cảm với hình dáng của đường biên. Một mặt nạ dự đoán có thể đạt mức độ chồng lấp diện tích với nhãn nhưng vẫn khác biệt đáng kể về hình dạng và vị trí của đường biên. Khoảng cách Hausdorff (Hausdorff Distance - HD) giải quyết vấn đề này bằng cách đánh giá mức độ sai lệch lớn nhất giữa hai đường biên.

Cho X và Y lần lượt là tập hợp các điểm ảnh nằm trên đường biên của mặt nạ dự đoán và mặt nạ gốc. Khoảng cách Hausdorff hai chiều cực đại được định nghĩa là:

$$\text{HD}(X, Y) = \max \left(\sup_{x \in X} \inf_{y \in Y} d(x, y), \sup_{y \in Y} \inf_{x \in X} d(x, y) \right) \quad (2.8)$$

trong đó $d(x, y)$ là khoảng cách Euclidean giữa hai điểm x và y .

Do công thức HD cơ bản sử dụng hàm cực đại (max và sup), nó cực kỳ nhạy cảm với các điểm nhiễu ngoại lai (outliers) trên đường biên. Vì vậy, khóa luận sử dụng **Khoảng cách Hausdorff 95% (HD95)**. Thang đo HD95 được tính bằng cách sắp xếp các khoảng cách biên theo thứ tự tăng dần và lấy giá trị tại phân vị thứ 95, qua đó làm giảm ảnh hưởng của một số điểm ngoại lai trên đường biên. Đơn vị của HD95 phụ thuộc vào hệ tọa

độ sử dụng (là pixel trong phạm vi khóa luận này); giá trị càng nhỏ cho thấy mức độ sai lệch biên giữa kết quả dự đoán và nhãn tham chiếu càng thấp.

2.4.4 Độ chuẩn xác định vị tâm (CBL)

Hệ số Dice và HD95 đánh giá chất lượng phân đoạn đầu ra nhưng không phản ánh được độ lệch vị trí giữa tâm dự đoán và tâm tổn thương thực tế, thông tin đặc biệt quan trọng khi câu nhắc bị lệch. Các độ đo định vị phổ biến trong computer vision (như DIoU, GIoU) đo lệch tâm giữa hai bounding box, không phải giữa hai mặt nạ phân đoạn pixel-level, và không chuẩn hóa theo kích thước tổn thương.

Vì vậy, khóa luận định nghĩa độ đo **Độ chuẩn xác định vị tâm (Center-Based Localization, CBL)** để đo sai lệch tâm giữa mặt nạ dự đoán và mặt nạ gốc, được chuẩn hóa theo kích thước tổn thương:

$$\text{CBL} = \max \left(0, 1 - \frac{\sqrt{(x_p - x_g)^2 + (y_p - y_g)^2}}{D_{gt}} \right) \quad (2.9)$$

trong đó (x_p, y_p) là tâm mặt nạ dự đoán, (x_g, y_g) là tâm nhãn gốc, và D_{gt} là đường chéo hộp bao nhỏ nhất quanh nhãn gốc (làm đơn vị chuẩn hóa theo kích thước tổn thương). $\text{CBL} = 1.0$ khi tâm dự đoán trùng khớp hoàn toàn; $\text{CBL} \rightarrow 0$ khi sai lệch vượt quá kích thước đường chéo tổn thương. Chuẩn hóa theo D_{gt} đảm bảo tính công bằng khi so sánh các tổn thương có kích thước khác nhau, một sai lệch 10 pixel có ý nghĩa rất khác nhau đối với khối u nhỏ so với khối u lớn.

2.5 Tổng kết chương

Chương 2 đã cung cấp bức tranh toàn cảnh và các cơ sở lý thuyết toán học vững chắc làm nền tảng cho khóa luận. Việc khảo sát ba kiến trúc đối sánh chính (U-Net, Attention U-Net, SAM-Med2D) làm nổi bật khoảng

trồng nghiên cứu: cần một kiến trúc CNN hạng nhẹ tích hợp câu nhắc trực quan từ bác sĩ, đạt hiệu năng phân đoạn cao và có tính bền bỉ trước câu nhắc không hoàn hảo.

Các lý thuyết về biểu diễn hộp giới hạn thành bản đồ nhiệt và Cổng chú ý có điều kiện là những nền tảng cốt lõi được tích hợp trực tiếp vào kiến trúc PGA-UNet trình bày ở Chương 3.

CHƯƠNG 3

MÔ HÌNH VÀ HỆ THỐNG ĐỀ XUẤT

3.1 Kiến trúc tổng thể của hệ thống


Hệ thống hỗ trợ chẩn đoán hình ảnh đề xuất trong khóa luận được thiết kế dưới dạng một luồng xử lý đầu cuối (end-to-end pipeline) hoàn toàn tự động. Đầu vào của hệ thống gồm ảnh X-quang và một bounding box do người dùng vẽ lên vùng nghi ngờ, người dùng không cần biết trước ảnh có bệnh hay không. Kiến trúc tổng thể được chia thành các module liên hoàn qua hai giai đoạn cốt lõi:

1. Giai đoạn sàng lọc bệnh lý (Mô hình gác cổng): Ảnh X-quang đầu vào đi qua một mạng nơ-ron tích chập đóng vai trò phân loại nhị phân. Hệ thống sẽ tính toán xác suất tồn tại của khối u hoặc các tổn thương bất thường.

- Nếu kết quả phân lớp là âm tính (bình thường), pipeline tự động dừng, bounding box không tạo ra sự khác biệt ở bước này.
- Nếu kết quả là dương tính (có bệnh lý), pipeline tự động chuyển sang giai đoạn phân đoạn, sử dụng bounding box làm prompt hướng dẫn.

2. Giai đoạn phân đoạn có hướng dẫn (PGA-UNet): Ở giai đoạn này, hệ thống hoạt động theo cơ chế học máy tương tác. Bác sĩ thực hiện thao tác khoanh một hộp giới hạn (Bounding Box) bao quanh vị trí nghi ngờ trên giao diện. Tọa độ của hộp giới hạn ngay lập tức được hệ thống chuyển đổi thành một bản đồ nhiệt không gian (Prompt Heatmap). Ảnh X-quang sạch và bản đồ nhiệt câu nhắc được đưa song song vào mô hình PGA-UNet (Prompt-Guided Attention U-Net). Bằng việc kích hoạt các cổng không gian và cơ chế chú ý có điều kiện, mô hình bị ép buộc phải

hội tụ sự tập trung vào vùng được chỉ định để trích xuất hình dáng chính xác của khối u, tạo ra một mặt nạ phân đoạn thô.



Hình 3.1: Pipeline tổng thể hệ thống: đầu vào gồm ảnh X-quang và bounding box, qua EfficientNet_B3 sàng lọc tự động, âm tính dừng, dương tính chuyển sang PGA-UNet phân đoạn có hướng dẫn.

Sự phân chia module rõ ràng trong kiến trúc không chỉ giúp hệ thống hoạt động linh hoạt, dễ dàng cô lập và xử lý lỗi, mà còn tạo điều kiện thuận lợi cho việc nâng cấp, thay thế từng thành phần độc lập trong tương lai. Chi tiết về cơ sở kỹ thuật, thiết kế cấu trúc mạng và công thức toán học của từng module sẽ được trình bày cụ thể trong các mục tiếp theo của chương này.

3.2 Tiền xử lý dữ liệu và loại bỏ nhiễu ảnh X-quang

Chất lượng dữ liệu đầu vào ảnh hưởng trực tiếp đến năng lực học của bất kỳ mô hình học sâu nào. Trong bài toán phân đoạn ảnh X-quang y khoa, những nhiễu kỹ thuật tuy không liên quan đến bệnh lý nhưng lại có độ tương phản rất cao, dễ khiến mạng nơ-ron học sai đặc trưng và trả về kết quả phân đoạn không đáng tin cậy. Mục này trình bày đặc điểm của bộ dữ liệu BTXRD được sử dụng trong khóa luận, các vấn đề nhiễu đặc thù và quy trình tiền xử lý đã được xây dựng để đảm bảo đầu vào sạch, chuẩn hóa cho toàn bộ quá trình huấn luyện.

3.2.1 Bộ dữ liệu BTXRD

Bộ dữ liệu được sử dụng trong khóa luận là **BTXRD** (*Bone Tumor X-Ray Dataset*), một tập ảnh X-quang xương thực tế được công bố dưới dạng tài nguyên khoa học mở trên tạp chí *Nature Scientific Data* [8]. Đây là bộ dữ liệu hiếm hoi trong lĩnh vực y tế cung cấp đồng thời ba cấp độ nhãn: nhãn phân lớp (classification label), nhãn định vị đối tượng (localization label) và mặt nạ phân đoạn ở cấp độ điểm ảnh (pixel-level segmentation mask).

Đặc điểm nổi bật của BTXRD:


- Ảnh X-quang xương thực tế thu thập từ cơ sở lâm sàng, tập trung vào các cấu trúc có độ tương phản thấp và dễ gây nhầm lẫn trên lâm sàng (điển hình: X-quang gót chân, cổ chân, chi trên).
- Bao gồm cả ảnh có khối u xương (nhãn 1 - *bệnh lý*) và ảnh xương bình thường (nhãn 0 - *lành lặn*), phản ánh đúng phân phối thực tế trong môi trường sàng lọc lâm sàng.
- Dữ liệu thô chứa nhiều loại nhiễu kỹ thuật đặc thù của thiết bị chụp X-quang: ký tự chỉ hướng R/L (Right/Left), các nhãn metadata, và đôi khi là dị vật cản quang xuất hiện trên ảnh.

Bộ dữ liệu này phục vụ hai mục đích song song trong kiến trúc hệ thống: (1) toàn bộ ảnh (cả lành lặn và bệnh lý) được sử dụng để huấn luyện **mô hình phân lớp** sàng lọc ban đầu; (2) chỉ ảnh có bệnh lý kèm theo mặt nạ phân đoạn được sử dụng để huấn luyện **mô hình phân đoạn PGA-UNet**.

3.2.2 Quy trình tiền xử lý và loại bỏ nhiễu

Ảnh X-quang BTXRD trong thực tế chứa một số loại nhiễu kỹ thuật phổ biến như ký tự chỉ hướng R/L và nhãn kỹ thuật được nhúng trực tiếp vào ảnh, những vùng sáng bất thường này có thể bị mạng nơ-ron nhận nhầm là tổn thương nếu không được xử lý. Quy trình tiền xử lý được tóm tắt tại Hình 3.2.

Để xóa nhiễu tự động, nhóm gán nhãn bounding box nhiễu thủ công trên một phần ảnh qua nền tảng **Roboflow** [3], sau đó finetune **YOLOv11s** [4] trên tập nhãn này. Mô hình sau khi huấn luyện được dùng để detect vùng nhiễu trên toàn bộ 3.746 ảnh PNG; các vùng phát hiện được xử lý bằng cách xác định giá trị màu xuất hiện nhiều nhất dọc theo biên hộp phát hiện; nếu giá trị đó nhỏ hơn 180 (không quá sáng) thì tô bằng màu đỏ, ngược lại tô bằng màu đen. Phương pháp này đảm bảo vùng được lấp đầy đồng nhất với nền xung quanh thay vì dùng màu cố định, loại bỏ hoàn toàn ký tự R/L và nhãn kỹ thuật.



Hình 3.2: Quy trình tiền xử lý dữ liệu: gán nhãn bounding box nhiều thủ công trên một phần ảnh qua Roboflow, finetune YOLOv11s, detect nhiều trên toàn bộ tập ảnh PNG, tô màu vùng nhiều bằng màu nền được chọn.

3.3 Mô hình phân đoạn PGA-UNet (Prompt-Guided Attention U-Net)

Kiến trúc mạng PGA-UNet được đề xuất trong khóa luận không sử dụng cách tiếp cận nối kênh tĩnh truyền thống. Thay vào đó, mạng được thiết kế để tích hợp tri thức định hướng từ chuyên gia một cách linh hoạt và sâu sát vào cả hai tiến trình: mã hóa (rút trích đặc trưng) và giải mã (khôi phục hình dáng). Sự cải tiến này được thực hiện thông qua ba thành phần cấu trúc cốt lõi dưới đây.

3.3.1 Biểu diễn câu nhắc trực quan (Prompt Heatmap Representation)

Nhằm chuyển đổi thao tác không gian của người dùng thành một định dạng số học mang tính chất dẫn đường mềm dẻo, tọa độ hộp giới hạn $\mathbf{B} = (x_1, y_1, x_2, y_2)$ do bác sĩ cung cấp sẽ được biểu diễn dưới dạng Bản đồ nhiệt câu nhắc $\mathbf{H}_{prompt} \in [0, 1]^{H \times W}$.

Trong thiết kế lý thuyết, bản đồ nhiệt câu nhắc có thể xây dựng theo phân phối Gaussian 2D thuần túy như đã trình bày tại Phương trình (2.3), với cường độ đạt cực đại tại tâm và phân rã dần về biên. Tuy nhiên, trong thực tế triển khai, nhóm sử dụng phương pháp **Plateau Heatmap**: vùng bên trong hộp giới hạn được gán đồng nhất giá trị 1.0 (tạo vùng cao nguyên phẳng - plateau), sau đó làm mềm đường biên bằng bộ lọc Gaussian (kernel 31×31):

$$\mathbf{H}_{prompt} = \text{GaussianBlur}(\mathbf{B}_{\text{mask}}, k = 31) \quad (3.1)$$

trong đó $\mathbf{B}_{\text{mask}} \in \{0, 1\}^{H \times W}$ là mặt nạ nhị phân của hộp giới hạn (có độ dày 5 px mỗi phía). Cách tiếp cận này giữ được tín hiệu dẫn đường mạnh và đồng đều bên trong vùng câu nhắc (không bị suy giảm về phía tâm như Gaussian thuần), đồng thời tạo ra đường chuyển tiếp mượt mà ở viền hộp để mạng không học các gradient giả tạo từ đường viền sắc nét. Bản đồ nhiệt $\mathbf{H}_{prompt}$ này đóng vai trò như một kênh dữ liệu độc lập, song hành

cùng ảnh X-quang đi vào mạng.

Lý do chọn $k = 31$: Kích thước kernel được lựa chọn để cân bằng hai yêu cầu đối lập: đủ lớn để tạo vùng chuyển tiếp mịn kéo dài ≈ 15 px mỗi bên, phủ vùng biên tổn thương điển hình trên ảnh 512×512 , đồng thời đủ nhỏ để tín hiệu câu nhắc không "tràn" sang các cấu trúc xương lân cận. Thực nghiệm với $k \in \{15, 21, 31, 51\}$ cho thấy $k < 21$ tạo đường chuyển tiếp quá đột ngột (gần mặt nạ nhị phân), trong khi $k > 51$ làm tín hiệu lan quá rộng ra ngoài vùng tổn thương. $k = 31$ (số lẻ, đảm bảo tâm kernel đối xứng) cho kết quả Dice tốt nhất trên tập xác thực và được giữ cố định trong toàn bộ thực nghiệm.

Cơ sở lý thuyết: Tại sao chọn biểu diễn liên tục có gradient thay vì mặt nạ nhị phân? Câu hỏi đặt ra là tại sao không dùng mặt nạ nhị phân phẳng, trong đó mọi điểm ảnh bên trong hộp giới hạn nhận giá trị 1 và bên ngoài là 0, thay vì bản đồ nhiệt liên tục. Câu trả lời nằm ở bản chất của phép tích chập và cơ chế dung hợp đặc trưng trong U-Net. Khi một mặt nạ nhị phân đi qua tầng tích chập, đường biên sắc nét tại viền hộp giới hạn tạo ra các gradient giả tạo (pseudo-gradients), mạng có thể học cạnh của hộp bao thay vì đặc trưng thực của tổn thương. Ngược lại, Plateau Heatmap cung cấp tín hiệu mạnh và đồng đều bên trong (đảm bảo câu nhắc rõ nét), nhưng chuyển tiếp mượt mà ở viền thông qua bộ lọc Gaussian. Thiết kế này phù hợp với bản chất tự nhiên của attention bias: công không gian tại phương trình (3.2) cần một tín hiệu liên tục để thực hiện phép nhân theo phần tử trên feature map mà không tạo ra hiệu ứng ringing.

Ngoài ra, các nghiên cứu về cơ chế chú ý trong học sâu cho thấy mạng nơ-ron tự nhiên tạo ra các vùng kích hoạt có dạng phân phối liên tục, với cường độ cao nhất tại vùng trung tâm đặc trưng nhất và giảm dần ra biên. Biểu diễn Plateau Heatmap của câu nhắc bất chước đặc tính này, tạo ra sự tương thích tự nhiên với cơ chế học của mạng.

So sánh với cách mã hóa prompt của SAM và SAM-Med2D. SAM và SAM-Med2D [2] mã hóa hộp giới hạn dưới dạng *positional embedding rời rạc*: tọa độ hai góc của hộp (trên-trái và dưới-phải) được ánh xạ thành hai vector nhúng 256 chiều thông qua bảng tra vị trí sinusoidal. Cách tiếp cận này phù hợp với kiến trúc Transformer của SAM vì Transformer xử lý một tập token rời rạc và tích hợp thông tin vị trí qua phép cộng vector embedding. Tuy nhiên, PGA-UNet sử dụng kiến trúc U-Net với feature map 2D liên tục có cùng cấu trúc không gian $H \times W$ với ảnh đầu vào.

Việc kết hợp một vector embedding rời rạc (256 chiều, không có cấu trúc không gian) vào feature map 2D đòi hỏi phép chiếu phức tạp và dễ mất thông tin vị trí. Biểu diễn bản đồ nhiệt 2D ($H \times W$, cùng không gian với feature map) cho phép Cổng không gian thực hiện phép nhân theo phần tử trực tiếp tại phương trình (3.2), một phép toán đơn giản, hiệu quả về tính toán và bảo toàn toàn vẹn thông tin vị trí không gian. Đây là lý do cốt lõi nhóm chọn biểu diễn heatmap 2D thay vì vector embedding rời rạc theo cách SAM: hai kiến trúc khác nhau đòi hỏi hai cách mã hóa prompt khác nhau để phù hợp nhất với cơ chế dung hợp đặc trưng nội tại.

3.3.2 Cổng không gian tại bộ mã hóa (Prompt Spatial Gate - Encoder)

Trong kiến trúc U-Net truyền thống, bộ mã hóa (Encoder) chịu trách nhiệm trích xuất các đặc trưng ngữ nghĩa. Tuy nhiên, nếu thiếu định hướng, nó có xu hướng học mọi thứ xuất hiện trên ảnh X-quang, dẫn đến việc lãng phí tài nguyên tính toán vào các vùng nền không liên quan.

PGA-UNet khắc phục điều này bằng cách tích hợp cấu kiện **Cổng không gian (Prompt Spatial Gate)** trực tiếp vào nhánh mã hóa. Tại tầng mã hóa thứ l , bản đồ nhiệt $\mathbf{H}^l$ được giảm mẫu về cùng độ phân giải với đặc trưng $\mathbf{x}^l$, sau đó đưa qua một bộ lọc cổng để sinh ra tín hiệu khuếch đại không gian:

$$\tilde{\mathbf{x}}^l = \mathbf{x}^l \odot (1 + \alpha \cdot \sigma(\mathbf{W}_{gate} * \mathbf{H}^l)) \quad (3.2)$$

trong đó $\mathbf{W}_{gate}$ là phép tích chập 1×1 ánh xạ bản đồ nhiệt (1 kênh) sang không gian kênh đặc trưng C^l ; σ là hàm Sigmoid; $\alpha \in [0, 1]$ là tham số học được (khởi tạo nhỏ tại 0.1 để không làm xáo trộn huấn luyện ban đầu); và $\odot$ là phép nhân theo phần tử.

Thiết kế này hoạt động theo nguyên lý *tăng cường có chọn lọc* (selective enhancement) thay vì ức chế: các đặc trưng nằm trong vùng câu nhắc được nhân thêm một hệ số > 1 (tăng lên), trong khi các đặc trưng ngoài vùng câu nhắc (nơi $\mathbf{H}^l \approx 0$) vẫn giữ nguyên giá trị ban đầu (nhân với ≈ 1). Nhờ đó, bộ mã hóa không bị mất thông tin toàn cục nhưng vẫn ưu tiên truyền tải các đặc trưng trong vùng mục tiêu xuống các tầng sâu hơn.

3.3.3 Cơ chế chú ý có điều kiện tại bộ giải mã (Conditioned Attention Decoder)

Dù Cổng không gian ở bộ mã hóa đã giúp loại bỏ nhiều nền đáng kể, nhưng tại bộ giải mã (Decoder) – nơi mạng thực hiện phép tăng mẫu để khôi phục ranh giới xương – tín hiệu định vị vẫn có nguy cơ bị phân tán. Để thiết lập sự dẫn đường xuyên suốt, khóa luận đề xuất thay đổi cấu trúc của *Attention U-Net* thông qua **Cơ chế chú ý có điều kiện**.

Khác với Cổng chú ý (Attention Gate) cơ sở chỉ dùng tín hiệu gating $\mathbf{g}$ từ tầng giải mã bên dưới, cấu kiện `unetUp_PromptAttention` tích hợp tri thức câu nhắc vào tín hiệu gating thông qua **cơ chế dung hợp cộng có trọng số tin cậy** (confidence-weighted additive fusion). Cụ thể, bản đồ câu nhắc $\mathbf{H}_{prompt}$ được giảm mẫu về kích thước của $\mathbf{g}$ và đưa qua một bộ mã hóa hai tầng tích chập (3×3 , InstanceNorm, ReLU) để trích xuất biểu diễn đặc trưng câu nhắc $\mathbf{p}_{enc}$. Từ đó, một điểm số tin cậy vô hướng $c \in (0, 1)$ được tính bằng cách áp dụng GAP (Global Average Pooling) lên $\mathbf{p}_{enc}$:


$$\mathbf{p}_{enc} = f_{enc}(\mathbf{H}_{prompt}), \quad c = \sigma(\text{GAP}(\mathbf{p}_{enc})) \quad (3.3)$$

Tín hiệu gating được điều kiện hóa bằng phép cộng có trọng số:

$$\mathbf{g}' = \mathbf{g} + c \cdot \alpha \cdot w_l \cdot \mathbf{p}_{\text{enc}} \quad (3.4)$$

trong đó $\alpha = \sigma(\alpha_{\text{raw}})$ là tham số học được (blend weight), và w_l là hệ số tỷ lệ theo tầng giải mã l , được xác định qua thực nghiệm trên tập xác thực (lịch trình cụ thể tại Chương 4), điều tiết mức độ ảnh hưởng của câu nhắc tại mỗi tầng.

Tín hiệu $\mathbf{g}'$ sau đó được đưa vào Cổng chú ý (GridAttentionBlock2D) tiêu chuẩn để tính hệ số chú ý α_{cond} điều chỉnh đặc trưng skip connection $\mathbf{x}^l$, kết hợp cùng kết nối dư tắt và tín hiệu dư câu nhắc tại đầu ra ($+\beta \cdot \mathbf{H}_{\text{prompt}}$, β học được). Thiết kế đa lớp này đảm bảo câu nhắc không chỉ ảnh hưởng qua một điểm duy nhất mà được duy trì xuyên suốt toàn bộ bộ giải mã thông qua hệ số w_l theo từng tầng. Các siêu tham số cụ thể của PSG và CAD (lịch trình w_l , hệ số kết nối dư) là chi tiết triển khai được xác định qua thực nghiệm trên tập xác thực, không phải đóng góp kỹ thuật cốt lõi; giá trị chi tiết được liệt kê tại Bảng thiết lập thực nghiệm (Chương 4). Sự kết hợp giữa “Cổng không gian tại bộ mã hóa” và “Cơ chế chú ý có điều kiện tại bộ giải mã” là yếu tố chính mang lại sự cải thiện đáng kể về hiệu năng Dice so với các mạng cơ sở hoạt động theo hướng tiếp cận tự động (chi tiết tại Chương 4).



Hình 3.3: Kiến trúc PGA-UNet (Prompt-Guided Attention U-Net): Cổng không gian (Prompt Spatial Gate) tích hợp bản đồ nhiệt câu nhắc vào bộ mã hóa để tăng cường đặc trưng có chọn lọc; Cơ chế chú ý có điều kiện (Conditioned Attention) ràng buộc tín hiệu gating bằng câu nhắc tại từng tầng giải mã với hệ số w_l theo từng tầng

3.3.4 Chiến lược huấn luyện và so sánh với mô hình nền tảng SAM-Med2D

Hàm mất mát huấn luyện PGA-UNet kết hợp Dice Loss và Binary Cross-Entropy với trọng số bằng nhau:

$$\mathcal{L}_{\text{seg}} = \mathcal{L}_{\text{Dice}} + \mathcal{L}_{\text{BCE}} \quad (3.5)$$

Dice Loss tối ưu trực tiếp độ tương đồng vùng giữa mặt nạ dự đoán và nhãn gốc; BCE phạt sai lệch tại từng điểm ảnh riêng lẻ và ổn định gradient. Hai thành phần bổ sung cho nhau, giúp mô hình cân bằng giữa hình dạng tổng thể và độ chính xác đường biên.

Để tránh hiểu nhầm khi so sánh kết quả thực nghiệm, cần làm rõ sự khác biệt căn bản về chiến lược huấn luyện giữa PGA-UNet và SAM-Med2D.

PGA-UNet, Huấn luyện từ đầu hoàn toàn: Toàn bộ kiến trúc PGA-UNet, bao gồm bộ mã hóa U-Net, các Cổng không gian, khối dung hợp và bộ giải mã có điều kiện, được khởi tạo ngẫu nhiên và học trực tiếp từ tập dữ liệu BTXRD qua tối đa 100 vòng lặp với cơ chế dừng sớm ($\text{patience} = 15$). **Không có thành phần nào được đóng băng** trong

quá trình huấn luyện; toàn bộ ~ 3 triệu tham số (do từ kiến trúc thực nghiệm với `feature_scale=4`, bộ lọc $[16, 32, 64, 128, 256]$) đều tham gia lan truyền ngược (backpropagation) từ vòng lặp đầu tiên. Lý do cho lựa chọn này: bộ mã hóa U-Net của PGA-UNet là kiến trúc tích chập đơn giản, không có trọng số tiền huấn luyện quy mô lớn tương thích với ảnh X-quang xương. Việc huấn luyện từ đầu trên domain data cụ thể (BTXRD) cho phép bộ mã hóa học được các đặc trưng thấp (low-level features) như kết cấu xương, biên tổn thương đặc thù của X-quang chi, không bị ràng buộc bởi các đặc trưng từ domain khác.

SAM-Med2D, Tinh chỉnh từ mô hình nền tảng: SAM-Med2D [2] kế thừa toàn bộ trọng số tiền huấn luyện của bộ mã hóa ViT-B đã được học trên khoảng 4.6 triệu ảnh y tế 2D đa dạng (tập SA-Med2D-20M). Trong quá trình tinh chỉnh trên BTXRD, bộ mã hóa ViT-B được đóng băng một phần và chỉ cập nhật qua các lớp Adapter (adapter tuning) nhẹ; bộ giải mã mặt nạ và bộ mã hóa prompt được cập nhật đầy đủ. Chính nhờ xuất phát từ trọng số đã hội tụ trên dữ liệu y tế quy mô lớn, SAM-Med2D chỉ cần 4 vòng lặp tinh chỉnh để đạt Val Dice tốt nhất (dừng sớm tại epoch 14), nhanh hơn đáng kể so với PGA-UNet (best epoch 79, dừng sớm tại epoch 94). Tuy nhiên, quy mô tham số của SAM-Med2D (~ 91 triệu theo kiến trúc ViT-B gốc [2], cộng thêm các lớp Adapter) lớn hơn PGA-UNet khoảng 30 lần (~ 3 triệu).

Sự khác biệt về chiến lược này có ý nghĩa quan trọng khi diễn giải kết quả ở Chương 4: PGA-UNet đạt hiệu năng Dice cao hơn SAM-Med2D mặc dù nhỏ hơn ~ 30 lần về tổng tham số (~ 3 triệu so với ~ 91 triệu của ViT-B) và không có bất kỳ trọng số tiền huấn luyện nào. Kết quả này phản ánh hiệu quả của cơ chế tích hợp câu nhắc sâu sát vào kiến trúc nhẹ, chứ không phải ưu thế từ quy mô mô hình hay dữ liệu tiền huấn luyện.

Bảng 3.1: So sánh chiến lược huấn luyện giữa PGA-UNet và SAM-Med2D

Thuộc tính	PGA-UNet (đề xuất)	SAM-Med2D (so sánh)
Chiến lược	Huấn luyện từ đầu (từ ngẫu nhiên)	Tinh chỉnh từ pre-trained ViT-B
Bộ mã hóa	U-Net CNN, học toàn bộ từ đầu	ViT-B, pretrained trên 4.6M ảnh y tế 2D
Thành phần bị đóng băng	Không có	ViT-B backbone (cập nhật qua Adapter)
Tổng tham số	~3 triệu	~91 triệu (ViT-B gốc) + Adapter
Số epoch hội tụ (best val)	79	4

3.4 Module gác cổng sàng lọc (Gatekeeper)

Mô hình PGA-UNet được huấn luyện hoàn toàn trên tập ảnh **chỉ chứa các ca bệnh lý**. Trong môi trường lâm sàng thực tế, luồng đầu vào hỗn hợp cả ảnh bình thường lẫn bệnh lý. Nếu đưa trực tiếp ảnh xương bình thường vào PGA-UNet, mô hình sẽ tạo ra mặt nạ sai lệch (False Positive), gây hiểu nhầm nghiêm trọng cho bác sĩ và lãng phí tài nguyên tính toán.

Giải pháp: Một module phân lớp nhị phân (**Gatekeeper**) đặt trước pipeline phân đoạn, sàng lọc tự động: ảnh bình thường $\rightarrow$ dừng sớm; ảnh dương tính $\rightarrow$ chuyển sang PGA-UNet. Module này **không phải đóng góp kỹ thuật trọng tâm** của khóa luận mà là thành phần hỗ trợ lấp đầy khoảng trống giữa điều kiện huấn luyện và triển khai thực tế. Kiến trúc cụ thể (EfficientNet_B3, chiến lược tinh chỉnh hai giai đoạn) và kết quả định lượng được trình bày đầy đủ tại Mục 4.7 (Chương 4).

Module này được tối ưu bằng hàm mất mát Entropy chéo nhị phân:

$$\mathcal{L}_{\text{cls}} = -\frac{1}{N} \sum_{i=1}^N \left[y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i) \right] \quad (3.6)$$

trong đó $y_i \in \{0, 1\}$ là nhãn thực và $\hat{p}_i \in [0, 1]$ là xác suất dự đoán của ảnh thứ i .

Trong luồng xử lý hệ thống (Mục 3.1), module Gatekeeper chạy tự động ngay khi ảnh được tải lên: kết quả âm tính $\rightarrow$ pipeline dừng; kết quả dương tính $\rightarrow$ hệ thống tự động chuyển sang Giai đoạn 2 (PGA-UNet phân đoạn với prompt bounding box).

CHƯƠNG 4

THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ

Chương này tổ chức kết quả thực nghiệm thành hai phần. **Phần I** tập trung đánh giá kiến trúc PGA-UNet trên tập kiểm thử 232 mẫu độc lập: so sánh với các mô hình cơ sở và SAM-Med2D, ablation study (PSG/CAD), đánh giá tính bền bỉ (Robustness) và kiểm định xác thực chéo. **Phần II** trình bày đánh giá module Gatekeeper hỗ trợ (EfficientNet_B3) và pipeline end-to-end trên dữ liệu hỗn hợp thực tế.

4.1 Thiết lập môi trường thực nghiệm

Để đảm bảo tính khách quan và khả năng tái lập (reproducibility) của các kết quả nghiên cứu, mục này trình bày chi tiết về quy mô dữ liệu, phương pháp phân chia các tập đánh giá, cấu hình phần cứng cũng như các siêu tham số (hyperparameters) được thiết lập trong suốt quá trình huấn luyện mô hình.

4.1.1 Tập dữ liệu ảnh X-quang (Dataset)

Dữ liệu thực nghiệm được sử dụng trong khóa luận là bộ **BTXRD** (*Bone Tumor X-Ray Dataset*) [8], một tập ảnh X-quang xương công khai có đầy đủ ba cấp nhãn: phân lớp, định vị và phân đoạn pixel-level. Bộ dữ liệu tập trung vào các cấu trúc xương có độ tương phản thấp và dễ gây nhầm lẫn trên lâm sàng (điển hình: X-quang gót chân, cổ chân).

Lý do chọn BTXRD: Không giống các bộ dữ liệu X-quang công khai chỉ cung cấp nhãn phân lớp mà thiếu mặt nạ phân đoạn, BTXRD cung cấp đồng thời cả ba cấp nhãn (phân lớp, định vị, phân đoạn pixel-level), đáp ứng đầy đủ yêu cầu huấn luyện có giám sát. Ảnh X-quang thô chứa

nhiều nhiễu kỹ thuật (ký tự R/L, metadata) và đã trải qua quy trình tiền xử lý nghiêm ngặt bằng YOLOv11s như mô tả ở Mục 3.2.

Hai phân vùng dữ liệu song song: Kiến trúc hệ thống sử dụng hai tập dữ liệu với mục đích khác nhau:

- **Dữ liệu phân đoạn** (cho PGA-UNet và baseline): Chỉ chứa các ảnh *có bệnh lý* kèm mặt nạ phân đoạn pixel-level. Đây là giới hạn tự nhiên của học có giám sát, chỉ ảnh có nhãn mới dùng được.
- **Dữ liệu phân lớp** (cho Gatekeeper): Chứa cả ảnh bệnh lý lẫn ảnh bình thường, phân chia theo tỷ lệ 80/10/10 (train/val/test), batch size = 16.

Thông kê dữ liệu: Bảng 4.1 tóm tắt phân bố dữ liệu sau khi phân chia.

Bảng 4.1: Thông kê phân bố bộ dữ liệu thực nghiệm

Tập dữ liệu	Số ảnh	Số mẫu (per-polygon)	Ghi chú
Huấn luyện (Train)	1 493	—	Tất cả ca bệnh lý
Xác thực (Validation)	187	187	
Kiểm thử (Test)	187	232	Nhiều ảnh có ≥ 2 polygon $\rightarrow$ 232 mẫu per-polygon

Thông kê bộ dữ liệu phân lớp (Gatekeeper): Bộ BTXRD gồm 3.746 ảnh X-quang (cả lành lặn lẫn bệnh lý) được dùng toàn bộ để huấn luyện mô hình góc công, phân chia train/val/test theo tỷ lệ 80/10/10 ($\approx 2.996/375/375$ ảnh). Tập phân lớp và tập phân đoạn dùng chung ảnh bệnh lý nhưng độc lập về nhãn: nhãn nhị phân (lành/bệnh) cho Gatekeeper, nhãn mặt nạ pixel-level cho PGA-UNet.

4.1.2 Cấu hình huấn luyện (Hyperparameters, Loss functions)

Toàn bộ quá trình huấn luyện và suy luận thực nghiệm được triển khai trên môi trường Google Colab với GPU nhằm tăng tốc độ tính toán. Các mô hình được cài đặt dựa trên thư viện PyTorch.

Hàm mất mát (Loss Function): Để xử lý mất cân bằng giữa foreground (vùng tổn thương) và background, hệ thống sử dụng hàm mất mát kết hợp:

$$\mathcal{L}_{total} = \mathcal{L}_{BCE} + \mathcal{L}_{Dice} \quad (4.1)$$

Thành phần $\mathcal{L}_{BCE}$ tối ưu phân loại từng pixel; $\mathcal{L}_{Dice}$ tối ưu độ chồng lấp diện tích tổng thể.

Siêu tham số huấn luyện: Tất cả mô hình (U-Net, Attention U-Net, PGA-UNet) được huấn luyện dưới cùng thiết lập:

- **Batch size:** 4 (phù hợp giới hạn VRAM khi dùng ảnh 512×512).
- **Epochs tối đa:** 100, kết hợp Early Stopping (patience=15).
- **Optimizer:** AdamW với weight decay 10^{-4} .
- **Learning Rate:** Khởi điểm 10^{-4} , bộ lập lịch ReduceLRonPlateau (giảm $0.5 \times$ sau 5 epoch không cải thiện Dice xác thực).

Siêu tham số kiến trúc PGA-UNet (chi tiết triển khai): Các giá trị dưới đây là tham số cấu hình được xác định qua thực nghiệm trên tập xác thực; chúng là chi tiết triển khai, không phải đóng góp kỹ thuật cần kiểm chứng độc lập.

- **Hệ số w_l theo tầng giải mã (CAD):** $\{1.0, 0.7, 0.4, 0.2\}$ từ tầng 1 đến 4; lịch trình giảm dần này là lựa chọn thử nghiệm thực nghiệm, chưa có kiểm chứng ablation riêng về lịch trình tối ưu.
- **Hệ số kết nối dư (skip residual) λ** = 0.3 trong khối Conditioned Attention.

- **Kernel Gaussian Heatmap:** $k = 31$, padding 5 px mỗi cạnh hộp giới hạn.
- **Khởi tạo α_{gate} :** 0.1 (Prompt Spatial Gate), giúp ổn định huấn luyện giai đoạn đầu.

4.2 Đánh giá hiệu năng kiến trúc PGA-UNet

Để đo lường khách quan năng lực của kiến trúc PGA-UNet, quá trình thực nghiệm được tiến hành qua ba bước: (1) so sánh với mô hình cơ sở không có prompt (U-Net, Attention U-Net); (2) đánh giá tính bền bỉ trước sai số câu nhắc; (3) so sánh với SAM-Med2D (SOTA prompt-based). Toàn bộ số liệu được thống kê trên tập kiểm thử 232 mẫu per-polygon độc lập.

4.2.1 Đánh giá cơ sở (Baseline Comparison): U-Net vs. Attention U-Net vs. PGA-UNet

Trong kịch bản đánh giá đầu tiên, PGA-UNet (kịch bản câu nhắc Zoom-out lý tưởng) được so sánh với U-Net truyền thống và Attention U-Net hoạt động hoàn toàn tự động.

Điều kiện so sánh: U-Net và Attention U-Net hoạt động theo cơ chế *tự động hoàn toàn* (chỉ nhận ảnh thô), trong khi PGA-UNet hoạt động *tương tác* (nhận thêm bounding box prompt). Sự chênh lệch hiệu năng phản ánh giá trị của việc tích hợp tri thức chuyên gia vào quá trình phân đoạn. Đây là so sánh có chủ đích: minh chứng lợi ích của hướng tiếp cận prompt-guided so với segmentation tự động trên ảnh X-quang xương.

Phân tích kết quả so sánh baseline:

- **Sự giới hạn của AI tự động:** U-Net gốc đạt Dice = 0.4534, phản ánh sự chật vật khi phải tự tìm vùng tổn thương trên ảnh X-quang thô. Đáng chú ý, Attention U-Net còn sụt giảm xuống Dice = 0.4159, thấp hơn cả U-Net gốc. Hiện tượng này có thể được giải thích bởi đặc thù dữ liệu X-quang xương: khi không có tín hiệu định hướng,

Bảng 4.2: So sánh hiệu năng phân đoạn: U-Net, Attention U-Net (tự động, N=187 ảnh) so với PGA-UNet kích bản Zoom-out lý tưởng (prompt-guided, N=232 mẫu per-polygon)

Mô hình	Dice↑	IoU↑	Precision↑	Recall↑	HD95↓	CBL↑
U-Net	0.4534	0.3671	0.6320	0.4539	128.61	0.5968
Attention U-Net	0.4159	0.3306	0.5951	0.4204	132.86	0.5569
PGA-UNet (Zoom-out)	0.8524	0.7527	0.8505	0.8739	13.96	0.9451

các Cổng chú ý (Attention Gates) tự do dễ bị kích hoạt bởi các vùng có gradient mạnh nhưng không phải tổn thương (như bờ khớp xương, thiết bị cố định). Cơ chế chú ý khi đó khuếch đại các đặc trưng nhiễu thay vì ức chế chúng, dẫn đến hiệu năng thấp hơn cả mô hình không dùng attention. Nhóm thừa nhận rằng kết quả này có thể chịu ảnh hưởng bởi việc thiết lập siêu tham số chưa tối ưu cho Attention U-Net trên bộ dữ liệu này, và cần thêm thí nghiệm bổ sung để khẳng định chắc chắn hơn.

- **Giá trị của hướng tiếp cận tương tác:** PGA-UNet (kích bản Zoom-out lý tưởng) đạt Dice = 0.8524, vượt trội hoàn toàn so với hai baseline tự động. Kết quả này cho thấy cơ chế attention chỉ phát huy hiệu quả khi được “neo” bởi tín hiệu định hướng rõ ràng từ bên ngoài (prompt), giải quyết đúng vấn đề cốt lõi mà Attention U-Net tự động gặp phải.

4.2.2 Đánh giá tính bền bỉ (Robustness): Kích bản Zoom-out, Shift và Mixed

Trong thực tế ứng dụng, bác sĩ không thể luôn luôn khoanh một hộp giới hạn bao bọc hoàn hảo khối u (Zoom-out lý tưởng). Sẽ có những lúc mỗi mắt hoặc do góc nhìn chủ quan khiến khung khoanh bị lệch đi một phần so với vị trí trung tâm thực sự. Để kiểm chứng xem PGA-UNet có bị phụ thuộc quá mức vào vị trí tâm câu nhắc hay không, hệ thống được thử nghiệm trên 3 kích bản:

1. **100% Zoom-out:** Câu nhắc lý tưởng, bao trọn vẹn tổn thương, cận trên hiệu năng của mô hình.
2. **100% Shift (Lệch tâm):** Câu nhắc bị cố tình dịch chuyển lệch khỏi tâm tổn thương một lượng ngẫu nhiên, điều kiện xấu nhất thực tế, mô phỏng bác sĩ mất tập trung.
3. **Mixed (70% Zoom-out - 30% Shift):** Pha trộn theo tỷ lệ ước lượng trong lâm sàng thực tế, phần lớn câu nhắc đúng, một phần nhỏ bị lệch.

Lý do chọn 3 kịch bản này và không dùng nhiều mạnh hơn:

Ba mức độ bao phủ toàn bộ phổ sai số câu nhắc hiện thực trong lâm sàng từ hoàn hảo đến lệch tâm. Các hình thức nhiều mạnh hơn (hộp giới hạn đặt hoàn toàn ngẫu nhiên trên ảnh, không liên quan đến vùng tổn thương) không được đưa vào vì chúng không phản ánh quy trình thực tế, bác sĩ luôn có thông tin sơ bộ về vùng nghi ngờ trước khi vẽ hộp; sai số trong lâm sàng thường là lệch vị trí, không phải sai hoàn toàn. Kịch bản Shift 100% đã đại diện cho mức nhiễu cực đoan nhất khả thi trong thực tế và cho thấy PGA-UNet vẫn duy trì Dice = 0.8382, đủ để kết luận về tính bền bỉ.

Bảng 4.3: Đánh giá tính bền bỉ của PGA-UNet trên 3 kịch bản prompt (N=232 mẫu per-polygon)

Kịch bản prompt	Dice↑	IoU↑	Precision↑	Recall↑	HD95↓	CBL↑
Zoom-out (100%, lý tưởng)	0.8524	0.7527	0.8505	0.8739	13.96	0.9451
Shift (100%, lệch tâm)	0.8382	0.7336	0.8434	0.8556	13.57	0.9379
Mixed (70% Zoom-out + 30% Shift)	0.8496	0.7486	0.8511	0.8689	14.38	0.9436

Phân tích tính bền bỉ: Số liệu thực nghiệm (Bảng 4.3) khẳng định đặc tính "hướng dẫn mềm" (soft guidance) của kiến trúc PGA-UNet. Khi đối mặt với kịch bản câu nhắc lệch tâm hoàn toàn (100% Shift), hiệu năng phân đoạn chỉ giảm từ Dice = 0.8524 (Zoom-out) xuống Dice = 0.8382

(Shift), chênh lệch 0.0142, không đáng kể. Kịch bản Mixed (70% Zoom-out + 30% Shift) đạt $\text{Dice} = 0.8496$, xác nhận mô hình duy trì hiệu năng ổn định trong môi trường thực tế.

Điều này chứng minh bằng thực nghiệm toán học rằng: mô hình **không** ghi nhớ một cách mù quáng và cắt hình theo tâm của bản đồ nhiệt câu nhắc. Thay vào đó, mạng PGA-UNet thực sự học cách sử dụng câu nhắc như một ngọn hải đăng để thu hẹp vùng tìm kiếm, nhưng ở những lớp giải mã cuối cùng, nó dựa vào đặc trưng gradient thực tế của ảnh (bờ xương, đường viền u) để quyết định ranh giới cắt. Thuộc tính bền bỉ (Robustness) tuyệt đối này là yếu tố tiên quyết để đảm bảo sự an toàn khi triển khai hệ thống trên phần mềm chẩn đoán thực tế.

4.2.3 So sánh với SAM-Med2D (SOTA Prompt-based)

Để đánh giá đầy đủ hơn, mô hình PGA-UNet được so sánh trực tiếp với SAM-Med2D [2], mô hình SOTA prompt-based dựa trên kiến trúc ViT-B ($\sim 91\text{M}$ tham số [2], fine-tuned từ 4.6M ảnh y tế 2D). Cả hai mô hình được đánh giá trên cùng 232 mẫu kiểm thử per-polygon, cùng 3 kịch bản prompt. SAM-Med2D sử dụng độ phân giải ảnh 256×256 (bắt buộc do position embedding cố định), trong khi PGA-UNet dùng 512×512 .

Bảng 4.4: So sánh toàn diện PGA-UNet với SAM-Med2D fine-tuned và SAM-Med2D zero-shot trên 3 kịch bản prompt (N=232 mẫu per-polygon). HD95* chuẩn hóa theo kích thước ảnh: $\text{PGA} \div 512$, $\text{SAM} \div 256$.

Mô hình	Kịch bản	Dice $\uparrow$	IoU $\uparrow$	Pre $\uparrow$	Rec $\uparrow$	HD95*(norm) $\downarrow$	CBL $\uparrow$
PGA-UNet	Zoom-out	0.8524	0.7527	0.8505	0.8739	0.027	0.9451
PGA-UNet	Shift	0.8382	0.7336	0.8434	0.8556	0.027	0.9379
PGA-UNet	Mixed	0.8496	0.7486	0.8511	0.8689	0.028	0.9436
SAM-Med2D (FT)	Zoom-out	0.7350	0.6130	0.7513	0.7478	0.207	0.8893
SAM-Med2D (FT)	Shift	0.7097	0.5818	0.7385	0.7117	0.213	0.8767
SAM-Med2D (FT)	Mixed	0.7283	0.6044	0.7491	0.7379	0.208	0.8863
SAM-Med2D (ZS)	Zoom-out	0.5337	0.3924	0.4743	0.6776	0.374	0.8194
SAM-Med2D (ZS)	Shift	0.5184	0.3775	0.4570	0.6559	0.403	0.7945
SAM-Med2D (ZS)	Mixed	0.5286	0.3882	0.4700	0.6670	0.384	0.8093

Phân tích kết quả so sánh PGA vs SAM-Med2D:

- **PGA vượt trội nhất quán:** Trên kích bản Zoom-out lý tưởng, PGA-UNet đạt $\text{Dice} = 0.8524$, vượt SAM-Med2D fine-tuned ($\text{Dice} = 0.7350$) và SAM zero-shot ($\text{Dice} = 0.5337$). Sự chênh lệch lớn giữa SAM fine-tuned và zero-shot cho thấy fine-tuning trên dữ liệu miền đặc thù là cần thiết, và PGA vượt qua cả SAM đã được fine-tuned dù chỉ với $\sim 3\text{M}$ tham số. Điều này đặc biệt có ý nghĩa vì PGA-UNet được huấn luyện **hoàn toàn từ đầu** trên BTXRD (toàn bộ $\sim 3\text{M}$ tham số tham gia backpropagation, không đóng băng bất kỳ thành phần nào), trong khi SAM-Med2D kế thừa trọng số ViT-B đã học từ 4.6M ảnh y tế 2D, xem Bảng 3.1 tại Chương 3 để biết chi tiết.
- **Lợi thế HD95 tuyệt đối:** Sau chuẩn hóa theo kích thước ảnh, PGA có HD95/imgsize thấp hơn SAM đáng kể, PGA bám biên chính xác hơn nhiều lần.
- **Tham số hiệu quả:** PGA ($\sim 3\text{M}$, toàn bộ trainable) vượt SAM-Med2D ($\sim 91\text{M}$ tổng, chỉ $\sim 15\text{M}$ trainable gồm Adapter + Decoder), chứng minh kiến trúc nhẹ được thiết kế đặc thù cho bài toán phân đoạn có prompt trên X-quang xương hiệu quả hơn foundation model đa mục đích.
- **SAM hội tụ rất nhanh:** SAM-Med2D hội tụ sớm nhờ lợi thế pretrained từ 4.6M ảnh y tế 2D, nhưng kiến trúc ViT-B với resolution 256 là giới hạn vốn có trên ảnh X-quang chi tiết.

4.2.4 So sánh hiệu quả tính toán

Ngoài hiệu năng phân đoạn, tính khả thi triển khai trong môi trường lâm sàng đòi hỏi mô hình phải đủ nhẹ để chạy trên phần cứng y tế tuyến cơ sở. Bảng 4.5 so sánh toàn diện giữa PGA-UNet và SAM-Med2D về các chỉ số tính toán.

Bảng 4.5: So sánh hiệu quả tính toán: PGA-UNet vs SAM-Med2D

Chỉ số	PGA-UNet (đề xuất)	SAM-Med2D
Tổng tham số	~3M	~91M (ViT-B) + Adapter
Tham số huấn luyện được	~3M (100%)	~15M (Adapter + Decoder)
Độ phân giải ảnh	512×512	256×256 (cố định)
VRAM huấn luyện (batch=4)	~3 GB	~6 GB
VRAM suy luận (batch=1)	~1 GB	~2 GB
Có thể chạy trên GPU 4GB	✓	Hạn chế

4.3 Phân tích kiến trúc và khả năng tổng quát hóa

Mục này trình bày hai nhóm thực nghiệm bổ sung: (1) ablation study so sánh các cấu hình kiến trúc PSG/CAD; (2) kiểm định độ ổn định bằng đánh giá chéo 4-fold.

4.3.1 Ablation kiến trúc: Đóng góp của PSG và CAD

Năm biến thể kiến trúc được huấn luyện lại hoàn toàn từ đầu trên cùng tập BTXRD, chỉ thay đổi cấu hình PSG/CAD và loại câu nhắc:

- **V1:** No PSG, No CAD (chỉ concatenate heatmap).
- **V2:** PSG only (không có CAD).
- **V3:** CAD only (không có PSG).
- **V4:** PSG + CAD với Binary bbox làm câu nhắc.
- **V5 (đề xuất):** PSG + CAD với Gaussian Heatmap làm câu nhắc.

Thiết kế năm biến thể này cho phép cô lập đóng góp riêng lẻ của PSG (V2 so V1), CAD (V3 so V1), tổ hợp cả hai (V4 so V2/V3) và ảnh hưởng của loại câu nhắc Gaussian vs Binary (V5 so V4). Kết quả được trình bày trong Bảng 4.6.

Phân tích ablation: Hai quan sát chính từ Bảng 4.6:

Bảng 4.6: Ablation study: Dice Score trên 3 kịch bản prompt của 5 biến thể kiến trúc PGA-UNet (N=232 mẫu per-polygon). V5 là mô hình đề xuất.

Biến thể	PSG	CAD	Prompt	Zoom-out↑	Shift↑	Mixed↑
V1: Baseline (concat heatmap)	×	×	Gaussian	0.8718	0.7201	0.8158
V2: PSG only	✓	×	Gaussian	0.8643	0.7291	0.8146
V3: CAD only	×	✓	Gaussian	0.8827	0.7335	0.8256
V4: Full PGA + Binary prompt	✓	✓	Binary	0.8800	0.7378	0.8276
V5: Full PGA + Gaussian (đề xuất)	✓	✓	Gaussian	0.8524	0.8382	0.8496

(1) **Đóng góp của PSG và CAD:** V3 (CAD only, Zoom=0.8827) cao hơn V2 (PSG only, Zoom=0.8643) cho thấy CAD đóng góp nhiều hơn vào hiệu năng Zoom-out; song cả hai đều thua V5 trong kịch bản Shift (V2: 0.7291, V3: 0.7335 so với V5: 0.8382), xác nhận kiến trúc đầy đủ PSG+CAD là cần thiết.

(2) **Trade-off Gaussian vs Binary prompt (V5 vs V4):** Đây là phát hiện quan trọng nhất. Khi chuyển từ Binary bbox sang Gaussian heatmap, Dice Shift tăng mạnh +0.1004 (0.7378 → 0.8382), Dice Mixed tăng +0.0220 (0.8276 → 0.8496), trong khi Dice Zoom-out giảm nhẹ -0.0276 (0.8800 → 0.8524). **Trade-off này là có chủ đích:** Gaussian heatmap "làm mờ" đường biên tín hiệu câu nhắc, buộc mô hình không thể ghi nhớ cứng nhắc vị trí tâm bounding box. Hệ quả là robustness cải thiện vượt trội khi câu nhắc bị lệch, trong khi hiệu năng với câu nhắc lý tưởng chỉ suy giảm không đáng kể. Trong môi trường lâm sàng thực tế, khả năng chịu đựng sai số câu nhắc quan trọng hơn điểm Dice tuyệt đối với câu nhắc hoàn hảo, V5 tối ưu cho đúng mục tiêu này.

4.3.2 Kiểm định độ ổn định bằng đánh giá chéo (Cross-validation)

Để xác minh tính ổn định và khả năng tổng quát hóa của PGA-UNet không phụ thuộc vào một lần phân chia dữ liệu duy nhất, mô hình được đánh giá chéo trên 4 phân vùng dữ liệu khác nhau. Kết quả trình bày tại

Bảng 4.7.

Bảng 4.7: Kết quả đánh giá chéo 4-fold PGA-UNet trên 3 kịch bản prompt (trung bình 4 fold)

Kịch bản	Dice $\uparrow$	IoU $\uparrow$	Precision $\uparrow$	Recall $\uparrow$	HD95 $\downarrow$	CBL $\uparrow$
Zoom-out	0.8784	0.7897	0.8583	0.9107	10.29	0.9601
Shift	0.8522	0.7522	0.8440	0.8769	12.60	0.9420
Mixed (70% Zoom-out + 30% Shift)	0.8723	0.7807	0.8571	0.9006	10.91	0.9552

Bảng 4.8: Dice Score từng fold trong đánh giá chéo 4-fold PGA-UNet (kịch bản Zoom-out / Shift / Mixed)

Fold	Zoom-out $\uparrow$	Shift $\uparrow$	Mixed $\uparrow$
Fold 1	0.8769	0.8422	0.8686
Fold 2	0.8805	0.8628	0.8753
Fold 3	0.8768	0.8456	0.8700
Fold 4	0.8795	0.8583	0.8752
Trung bình $\pm$ Std	0.8784 $\pm$ 0.0019	0.8522 $\pm$ 0.0099	0.8723 $\pm$ 0.0035

Bảng 4.8 cho thấy Dice Score dao động rất nhỏ giữa các fold: độ lệch chuẩn thấp nhất ở kịch bản Zoom-out (± 0.0019) và lớn nhất ở Shift (± 0.0099), biên độ hoàn toàn chấp nhận được trong nghiên cứu y tế. Kết quả này xác nhận mô hình hội tụ ổn định trên các phân vùng dữ liệu khác nhau, không bị phụ thuộc vào một cách chia cụ thể. Các chỉ số cross-validation nhỉnh hơn tập test chính một chút (Dice Zoom-out: 0.8784 vs 0.8524) phản ánh sự khác biệt tự nhiên giữa dữ liệu huấn luyện và tập kiểm thử độc lập được giữ lại hoàn toàn từ đầu.

4.3.3 Đánh giá theo đặc tính tổn thương (Sub-Category)

Để đánh giá sâu hơn khả năng tổng quát hóa của PGA-UNet, hai phân tích sub-category được thực hiện: **(1)** so sánh PGA-UNet với U-Net/Att-UNet trên nhóm *Dễ* (top-50 U-Net Dice) và *Khó* (bottom-50 U-Net Dice),

trên $N = 187$ ảnh (50 ảnh mỗi nhóm); **(2)** so sánh PGA-UNet với SAM-Med2D trên ba nhóm đặc tính lâm sàng (Tổn thương nhỏ, Biên giới mờ, Tổn thương rõ nét), mỗi nhóm 50 mẫu per-polygon.

PGA-UNet so với U-Net/Att-UNet theo độ khó tác vụ

Ở nhóm *Dễ* (tương phản cao, hình dạng rõ), U-Net vẫn hoạt động được; PGA kỳ vọng cải thiện thêm đáng kể. Ở nhóm *Khó* (tương phản thấp, xương chồng lấp, hình dạng bất thường), U-Net và Att-UNet thiếu thông tin định hướng nên dự đoán suy giảm mạnh, trong khi PGA-UNet nhờ cơ chế prompt guidance kỳ vọng duy trì Dice ổn định hơn, đây là lý do cốt lõi cho sự tồn tại của hướng tiếp cận tương tác.

Bảng 4.9: So sánh hiệu năng PGA-UNet với U-Net và Att-UNet theo độ khó tác vụ ($N = 187$ ảnh, phân nhóm 50 dễ nhất / 50 khó nhất theo Dice của U-Net; PGA tính trên polygon)

Nhóm	Mô hình	Dice	IoU	Pre	Rec	HD95 (px)	CBL
Dễ (top-50)	U-Net	0.8691	0.7713	0.8711	0.8771	21.05	0.9510
	Att-UNet	0.7609	0.6539	0.8055	0.7797	34.48	0.8662
	PGA-UNet	0.8938	0.8122	0.8704	0.9249	13.16	0.9588
Khó (bottom-50)	U-Net	0.0000	0.0000	0.2200	0.0000	265.69	0.0243
	Att-UNet	0.0929	0.0639	0.3397	0.1034	236.46	0.1551
	PGA-UNet	0.8181	0.7114	0.8446	0.8274	18.06	0.9247

Kết quả Bảng 4.9 xác nhận rõ ràng giả thuyết lý thuyết. Ở nhóm *Dễ* (top-50), U-Net đạt Dice = 0.8691 trong khi PGA-UNet đạt 0.8938 ($\Delta = +0.0247$), cải thiện có ý nghĩa nhưng không đột biến vì tổn thương đã rõ. Ở nhóm *Khó* (bottom-50), U-Net sụp đổ hoàn toàn xuống Dice = 0.0000 (HD95 = 265.69 px), Att-UNet cũng chỉ đạt 0.0929; trong khi đó PGA-UNet **duy trì ổn định ở 0.8181** ($\Delta = +0.8181$ so với U-Net). Điều này chứng minh rằng cơ chế prompt spatial gate là điều kiện cần thiết cho khả năng hoạt động nhất quán trên các ca bệnh phức tạp.

PGA-UNet so với SAM-Med2D theo đặc tính lâm sàng

Ba quan sát chính dự kiến: (1) **Tổn thương nhỏ**: SAM-Med2D hoạt động ở độ phân giải 256×256 khiến các tổn thương nhỏ chỉ còn vài pixel, SAM bỏ sót phần lớn diện tích, trong khi PGA ở 512×512 với heatmap dẫn đường đạt kết quả tốt hơn đáng kể. (2) **Biên giới mờ**: ranh giới tổn thương không rõ ràng trên X-quang xương đặc thù BTXRD, SAM pretrain đa dạng nhưng không chuyên biệt hóa đặc trưng gradient X-quang xương; PGA train from scratch trên BTXRD học được các đặc trưng cụ thể này. (3) **Tổn thương rõ nét**: khi tổn thương lớn và ranh giới rõ, cả hai mô hình đều hoạt động tốt; PGA nhỉnh hơn SAM với $\sim 30 \times$ ít tham số hơn.

Bảng 4.10: So sánh PGA-UNet với SAM-Med2D trên ba nhóm đặc tính lâm sàng (kịch bản Zoom-out, 50 mẫu per-polygon mỗi nhóm)

Nhóm	Mô hình	Dice	IoU	Pre	Rec	HD95 (px)	CBL
Tổn thương nhỏ	SAM-Med2D	0.3887	0.2835	0.7223	0.3335	88.73	0.6855
	PGA-UNet	0.7970	0.6818	0.7906	0.8453	13.64	0.9202
Biên giới mờ	SAM-Med2D	0.5407	0.3886	0.7673	0.4610	27.44	0.8401
	PGA-UNet	0.8288	0.7152	0.8382	0.8413	12.00	0.9384
Tổn thương rõ nét	SAM-Med2D	0.8465	0.7392	0.8955	0.8129	27.04	0.9483
	PGA-UNet	0.8741	0.7850	0.8638	0.8969	24.71	0.9548


Kết quả Bảng 4.10 xác nhận cả ba nhận định. **Tổn thương nhỏ**: PGA đạt Dice = 0.7970 trong khi SAM chỉ đạt 0.3887 ($\Delta = +0.4083$), khoảng cách lớn nhất trong ba nhóm, phản ánh tác động trực tiếp của độ phân giải 512×512 so với 256×256 đối với vùng nhỏ. **Biên giới mờ**: PGA = 0.8288 vs SAM = 0.5407 ($\Delta = +0.2882$), cho thấy đặc trưng X-quang xương chuyên biệt mà PGA học được trên BTXRD. **Tổn thương rõ nét**: khoảng cách thu hẹp đáng kể (PGA = 0.8741, SAM = 0.8465, $\Delta = +0.0276$), cả hai mô hình hoạt động tốt khi điều kiện thuận lợi; PGA vẫn nhỉnh hơn với kiến trúc nhỏ gọn hơn $\sim 30 \times$.

4.4 Trực quan hóa kết quả (Qualitative Results)

Bên cạnh các đánh giá định lượng bằng số liệu thống kê, việc quan sát trực tiếp kết quả phân đoạn mang ý nghĩa đặc biệt quan trọng trong lĩnh vực y khoa lâm sàng. Mục này trình bày các hình ảnh trực quan hóa nhằm minh họa rõ nét cách mô hình PGA-UNet xử lý các trường hợp phức tạp trong thực tế.

4.4.1 Trực quan hóa các kịch bản phân đoạn tiêu biểu

Hình 4.1 minh họa một ca kiểm thử tiêu biểu của PGA-UNet (kịch bản Zoom-out): mặt nạ phân đoạn bám sát đường biên tổn thương nhờ cơ chế Prompt Spatial Gate và Conditioned Attention dẫn đường từ heatmap phân lớp.



Hình 4.1: Trực quan hóa kết quả phân đoạn của PGA-UNet kịch bản Zoom-out: ảnh gốc (trái), mặt nạ Ground Truth (giữa), mặt nạ dự đoán (phải). Đường biên bám sát GT nhờ cơ chế Prompt Spatial Gate và Conditioned Attention.

4.5 Giới hạn kiến trúc và phân tích trường hợp thất bại

Bên cạnh các kết quả tích cực đã trình bày, việc phân tích khách quan các trường hợp kiến trúc PGA-UNet hoạt động kém là cần thiết để đánh giá đúng giới hạn và định hướng cải tiến.

4.5.1 Trường hợp PGA-UNet dự đoán kém

Qua quá trình kiểm tra trên tập test, nhóm nhận diện được ba nhóm trường hợp mà PGA-UNet cho kết quả phân đoạn dưới mức trung bình ($\text{Dice} < 0.70$):

- **Tổn thương có hình dáng bất thường:** Các khối u dạng kéo dài, phân nhánh hoặc có đường biên không liên tục thường vượt quá khả năng biểu diễn của bản đồ nhiệt Gaussian (vốn có dạng hình elip đối xứng). Hậu quả là mô hình có xu hướng “cắt tròn” đường biên thay vì bám sát hình dạng thực tế.
- **Vùng chồng lấp đa lớp xương dày đặc:** Tại các vị trí như khớp cổ chân nơi nhiều cấu trúc xương chồng lên nhau, gradient cạnh bị nhiễu nghiêm trọng khiến bộ giải mã gặp khó khăn trong việc xác định ranh giới chính xác, ngay cả khi có prompt hướng dẫn.
- **Ảnh chất lượng thấp:** Các ảnh X-quang bị mờ, thiếu sáng hoặc có nhiễu kỹ thuật còn sót lại sau tiền xử lý đều làm suy giảm chất lượng đặc trưng mà bộ mã hóa trích xuất được.

4.6 Đánh giá pipeline end-to-end với module Gatekeeper hỗ trợ

Phần này trình bày đánh giá module Gatekeeper (EfficientNet_B3), thành phần hỗ trợ thực nghiệm được tích hợp để lấp đầy khoảng trống

giữa điều kiện huấn luyện và triển khai thực tế, và đánh giá pipeline end-to-end tự động trên dữ liệu hỗn hợp thực tế. Phân tích sai số tích lũy của pipeline được trình bày tại Mục 4.7.1.

4.7 Đánh giá mô hình phân lớp gác cổng

Mô hình phân lớp đóng vai trò là "người gác cổng" (gatekeeper) trong luồng xử lý đầu cuối của phần mềm. Nhiệm vụ của mô hình là sàng lọc tự động ảnh X-quang đầu vào thành hai nhóm: Bình thường (Âm tính) và Có bệnh lý bất thường (Dương tính). Việc đánh giá chính xác hiệu năng của module này mang ý nghĩa quyết định, bởi một dự đoán sai sót ở bước này có thể khiến bệnh nhân bị lọt lưới sàng lọc mà không bao giờ đi tới được bước phân đoạn chi tiết phía sau.

Kiến trúc: EfficientNet_B3 tinh chỉnh hai giai đoạn. Mô hình **EfficientNet_B3** [7] được tiền huấn luyện trên ImageNet-1K sử dụng chiến lược *compound scaling*, đồng thời mở rộng chiều rộng, chiều sâu và độ phân giải theo một hệ số hợp lý. Backbone gồm các khối MBConv kết hợp với cơ chế Squeeze-and-Excitation (SE). Với $\sim 10.7M$ tham số và đầu vào 300×300 , EfficientNet_B3 đạt cân bằng tốt giữa hiệu năng phân lớp và tốc độ suy luận. Tầng phân lớp gốc được thay thế bởi $\text{Linear}(1536, 1) + \text{Sigmoid}$, xuất xác suất $p \in (0, 1)$; ngưỡng $p \geq 0.5 \rightarrow$ dương tính.

Giai đoạn 1 (25 epoch): Đóng băng backbone, chỉ cập nhật head với $\text{LR} = 10^{-4}$, giúp head thích nghi không gian đặc trưng X-quang mà không phá hủy biểu diễn ImageNet.

Giai đoạn 2 (tối đa 100 epoch, dừng sớm tại epoch 68): Mở khóa toàn bộ, $\text{LR} = 10^{-5}$, CosineAnnealingLR. Hàm mất mát: BCEWithLogitsLoss; tối ưu: AdamW; dừng sớm: patience = 15 (theo Accuracy); Gradient Clipping: max_norm = 1.0. Lưu song song hai checkpoint: theo Loss tốt nhất và theo Accuracy tốt nhất.

Các độ đo đánh giá (Evaluation Metrics): Để có cái nhìn toàn diện, mô hình được đánh giá qua các độ đo tiêu chuẩn của bài toán phân

loại nhị phân: Độ chính xác tổng thể (Accuracy), Độ chính xác (Precision), Độ bao phủ/Độ nhạy (Recall/Sensitivity), Độ đặc hiệu (Specificity) và Điểm F1 (F1-Score).

Đặc biệt trong bối cảnh y tế dự phòng và sàng lọc, **Độ nhạy (Recall)** là chỉ số được ưu tiên hàng đầu. Một mô hình sàng lọc tốt thà báo động nhầm (False Positive) để bác sĩ tốn thêm chút thời gian kiểm tra lại ở bước phân đoạn, còn hơn là bỏ sót bệnh nhân thực sự có khối u (False Negative).

Bảng 4.11: Kết quả đánh giá hiệu năng của mô hình phân lớp sàng lọc trên tập kiểm thử

Độ đo đánh giá (Metrics)	Kết quả
Độ chính xác tổng thể (Accuracy)	88.00%
Độ chính xác (Precision / PPV)	87.37%
Độ nhạy (Recall / Sensitivity)	88.77%
Độ đặc hiệu (Specificity)	87.23%
Giá trị dự báo Âm tính (NPV)	88.65%
Điểm F1 (F1-Score)	88.06%
Diện tích dưới đường cong (AUC-ROC)	0.9405

Phân tích kết quả: Bảng 4.11 tổng hợp hiệu năng của mô hình phân lớp gác cổng sau quá trình tinh chỉnh hai giai đoạn, đánh giá thống nhất trên tập kiểm thử **dataset_online** (375 ảnh: 187 bệnh lý + 188 bình thường). Kết quả cho thấy module Gatekeeper đạt mức cân bằng tốt giữa Sensitivity và Specificity:

- **AUC-ROC 0.9405:** Khả năng phân biệt bệnh/không bệnh rất tốt, bất kể ngưỡng phân loại.
- **Recall/Sensitivity 88.77%:** Phát hiện đúng $\approx 89\%$ ca bệnh thực sự (bỏ sót 21/187 ca), đảm bảo an toàn sàng lọc.
- **Specificity 87.23%:** Loại đúng $\approx 87\%$ ca bình thường (24/188 ảnh lành bị phân loại nhầm thành dương tính).

- **Precision 87.37%:** Khi báo dương tính, xác suất đúng là $\approx 87\%$.
- **NPV 88.65%:** Khi kết luận "bình thường", xác suất thực sự không bệnh là $\approx 89\%$, đủ tin cậy làm bộ lọc sơ cấp.
- **F1-Score 88.06%:** Cân bằng tốt giữa Precision và Recall, phù hợp với kích bản dữ liệu cân bằng (187 vs 188).

4.7.1 Phân tích sai số tích lũy của pipeline (Cascading Error)

Khi đánh giá **hệ thống end-to-end** trên tập **dataset_online** (375 ảnh hỗn hợp, bao gồm 187 ảnh bệnh lý và 188 ảnh bình thường), sai số từ bước phân lớp lan truyền sang bước phân đoạn qua hai kênh:

1. **Sai số Recall (FN):** Các ca bệnh bị gác cổng bỏ sót $\rightarrow$ không chuyển xuống PGA-UNet (21 ảnh FN, tương ứng Sensitivity = 88.77%).
2. **Sai số Specificity (FP):** Các ảnh bình thường bị phân loại nhầm thành dương tính $\rightarrow$ PGA-UNet chạy nhưng không có GT mask (24 ảnh FP, tương ứng Specificity = 87.23%), đóng góp Dice = 0 vào mẫu số.

Cận trên ước tính của Pipeline Dice (bỏ qua hiệu ứng FP lên mẫu số):

$$\begin{aligned} \text{Pipeline Dice}_{\text{ước tính}} &\approx \text{Sensitivity} \times \overline{\text{Dice}_{\text{TP}}} \\ &= 88.77\% \times 85.56\% \approx \mathbf{75.9\%} \end{aligned} \quad (4.2)$$

Kết quả thực nghiệm đo được Pipeline Dice = **0.7675**, cao hơn ước tính 75.9% do mỗi ảnh TP trung bình tách ra 1.26 polygon, làm tăng tỷ lệ polygon thực sự trong mẫu số so với số ảnh FP. Hai nguồn suy giảm có mức ảnh hưởng tương đương: **24 ảnh FP** (Specificity = 87.23%) gây 24 đơn vị Dice = 0 trong mẫu số 233, và **21 ảnh FN** (Sensitivity = 88.77%) làm mất ≈ 26 polygon tiềm năng khỏi tử số. Cải thiện đồng thời cả Sensitivity lẫn Specificity là hướng ưu tiên tiếp theo. Chi tiết xem Mục 4.8 và định hướng cải thiện tại Chương 5.

4.8 Đánh giá pipeline end-to-end trên dữ liệu hỗn hợp

Để đánh giá pipeline trong điều kiện thực tế, nơi không phải ảnh nào cũng có bệnh lý, hệ thống được chạy trên tập **dataset_online** (375 ảnh: 187 ảnh bệnh lý + 188 ảnh bình thường). Tập này được ghép từ **tập kiểm thử của PGA-UNet** (187 ảnh bệnh lý, có chú thích đa giác) và **tập kiểm thử của EfficientNet_B3** (188 ảnh bình thường) — cả hai đều thuộc phân vùng kiểm thử BTXRD (10%), đảm bảo không mô hình nào đã thấy các ảnh này trong quá trình huấn luyện, tránh rò rỉ dữ liệu (data leakage).

Thiết kế đánh giá: Mỗi ảnh đi qua toàn bộ pipeline (EfficientNet_B3 → PGA-UNet). Kết quả chia thành 4 trường hợp: TP (có JSON, dự đoán dương, PGA chạy thực tế), FP (không có JSON, dự đoán dương, Dice = 0 vì không có GT mask), FN (có JSON, dự đoán âm, không qua PGA, không tính), TN (không có JSON, dự đoán âm).

Dice pipeline được tính trên *toàn bộ đơn vị classifier gửi cho PGA* (mẫu số = polygon(TP) + ảnh(FP)), phản ánh hiệu năng tổng thể khi tích hợp cả trường hợp phân loại sai. Mỗi ảnh TP được tách thành các polygon riêng lẻ (khớp với đơn vị đánh giá PGA-UNet độc lập), mỗi ảnh FP đóng góp 1 đơn vị với Dice = 0:

$$\text{Pipeline Dice} = \frac{\sum_{i \in \text{polygon(TP)}} \text{Dice}_i}{N_{\text{polygon(TP)}} + N_{\text{image(FP)}}} \quad (4.3)$$

Nhận xét: Pipeline Dice = 0.7675 (mẫu số 233 đơn vị: 209 polygon từ 166 ảnh TP và 24 ảnh FP bị gán Dice = 0) phản ánh hiệu năng tổng thể khi pipeline xử lý luồng ảnh hỗn hợp theo đúng thiết kế per-polygon. Con số này thấp hơn PGA-UNet độc lập (Dice = 0.8524) do hai nguồn suy giảm có mức đóng góp tương đương: (1) 24 ảnh bình thường bị phân loại sai (FP, Specificity = 87.23%) kéo mẫu số lên mà không đóng góp vào

Bảng 4.12: Kết quả pipeline end-to-end trên tập dataset_online (hỗn hợp bình thường + có bệnh)

Thống kê	Giá trị
Tổng ảnh đầu vào	375 (187 có bệnh, 188 bình thường)
TP / FP / FN / TN (ảnh)	166 / 24 / 21 / 164
<i>Phân loại (EfficientNet_B3 trên dataset_online)</i>	
Sensitivity (Recall)	88.77%
Specificity	87.23%
Accuracy	88.00%
AUC-ROC	0.9405
<i>Phân đoạn pipeline (PGA-UNet, đánh giá per-polygon)</i>	
Ảnh TP đưa vào PGA	166 ảnh $\rightarrow$ 209 polygon (tb. 1.26 polygon/ảnh)
Ảnh FP (Dice = 0)	24 ảnh
Mẫu số (polygon TP + ảnh FP)	$209 + 24 = \mathbf{233}$ đơn vị
Pipeline Dice	0.7675
Pipeline IoU	0.6775

tử số; (2) 21 ảnh bệnh bị bỏ sót (FN, Sensitivity = 88.77%) loại bỏ ≈ 26 polygon khỏi tử số. Đây là **kết quả thực nghiệm đầy đủ** trên dữ liệu hỗn hợp thực tế, minh chứng cho sai số tích lũy tất yếu của kiến trúc hai tầng.

Mô hình phân lớp góc cổng đạt $\text{AUC-ROC} = 0.9405$ trên `dataset_online` là bản lề để toàn bộ hệ thống vận hành ổn định. Cải thiện đồng thời Sensitivity và Specificity (hiện tương đương nhau ở mức $\sim 88\%$) nhằm giảm cả FN lẫn FP là hướng ưu tiên phát triển tiếp theo (xem Chương 5).

CHƯƠNG 5

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1 Kết luận những đóng góp đạt được

Mục tiêu xuyên suốt của khóa luận này là nghiên cứu, thiết kế và phát triển một hệ thống hỗ trợ chẩn đoán ảnh X-quang xương thông minh, an toàn và có tính tương tác cao. Vượt qua những giới hạn của các phương pháp phân đoạn tự động hoàn toàn truyền thống và rào cản tài nguyên của các mô hình nền tảng hạng nặng, khóa luận đã hoàn thành các mục tiêu chính đề ra với những đóng góp kỹ thuật cụ thể sau:

- **Đề xuất kiến trúc PGA-UNet:** Khóa luận đã thiết kế thành công mô hình Prompt-Guided Attention U-Net ($\sim 3M$ tham số). Bằng cách tích hợp Cổng không gian (Prompt Spatial Gate) tại nhánh mã hóa và Cơ chế chú ý có điều kiện (Conditioned Attention) tại nhánh giải mã, hệ thống biến đổi thành công Bounding Box thành tín hiệu định hướng không gian sâu sát. Thực nghiệm trên $N=232$ mẫu per-polygon (tập BTXRD): PGA-UNet đạt **Dice = 0.8524** (Zoom-out), vượt U-Net (0.4534, +0.3990) và SAM-Med2D fine-tuned (0.7350, +0.1174) dù nhỏ hơn $\sim 30\times$ về tham số. Đặc biệt, Gaussian heatmap prompt giúp duy trì Dice = 0.8382 ngay cả khi câu nhắc bị lệch tâm (Shift), chứng minh tính bền bỉ cao trong điều kiện lâm sàng thực tế. Phân tích sub-category cho thấy lợi thế lớn nhất ở nhóm tổn thương khó (PGA Dice = 0.8181 vs U-Net Dice = 0.0000 trên nhóm Hard top-50, $\Delta=+0.8181$). Để thực nghiệm pipeline đầu cuối, module Gatekeeper (EfficientNet_B3, AUC-ROC = 0.9405) được tích hợp hỗ trợ sàng lọc ảnh bình thường tự động trước khi PGA-UNet chạy.

5.2 Hạn chế của hệ thống

Mặc dù đạt được nhiều kết quả khả quan, hệ thống đề xuất vẫn còn tồn tại một số giới hạn nhất định cần được nhìn nhận khách quan:

- **Sai số tích lũy pipeline hai giai đoạn (Cascading Error):** Pipeline hiện tại gồm hai module độc lập (Gatekeeper $\rightarrow$ PGA-UNet). Sai số từ bước phân lớp lan truyền sang bước phân đoạn: thực nghiệm pipeline trên tập hỗn hợp 375 ảnh đạt Pipeline Dice = 0.7675 (mẫu số 233 đơn vị: 209 polygon TP + 24 ảnh FP, đánh giá per-polygon), thấp hơn đáng kể so với PGA-UNet đơn lẻ (Dice = 0.8524). Nguồn suy giảm: 24 ảnh bình thường bị phân loại sai (FP, Specificity = 87.23%) và 21 ảnh bệnh bị bỏ sót (FN, Recall = 88.77%), kéo điểm pipeline xuống dưới hiệu năng của từng module đơn lẻ. Đây là hạn chế cố hữu của kiến trúc hai giai đoạn và là hướng ưu tiên cải tiến trong tương lai.
- **Hạn chế của thông tin không gian 2D:** Do ảnh X-quang là hình chiếu 2D của cấu trúc xương 3D phức tạp, sự chồng lấp giữa các khớp xương dày đặc đôi khi tạo ra những tín hiệu gradient gây nhiễu. Bounding Box hình chữ nhật dù được chuyển đổi thành Gaussian Heatmap vẫn mang tính chất ước lượng viền thô, có thể gặp khó khăn với các khối u có hình dáng kéo dài hoặc phân nhánh phức tạp.
- **Chưa kiểm định đa tập dữ liệu:** Toàn bộ thực nghiệm được tiến hành trên một bộ dữ liệu duy nhất (BTXRD). Hiệu năng trên các bộ dữ liệu X-quang xương từ cơ sở y tế khác nhau (thiết bị chụp, protocol khác) chưa được xác minh.

5.3 Định hướng phát triển tương lai

Từ những kết quả đạt được và các hạn chế còn tồn đọng, nhóm nghiên cứu đề xuất các định hướng phát triển tiếp theo nhằm hoàn thiện hệ thống:

- **Hướng 1: Cải thiện module phân lớp góc công:** Thực nghiệm pipeline cho thấy bottleneck hiện tại là cân bằng giữa FP (24/188 ảnh bình thường bị phân loại sai, Specificity = 87.23%) và FN (21/187 ảnh bệnh bị bỏ sót, Recall = 88.77%), cộng lại kéo Pipeline Dice từ 0.8524 xuống 0.7675. Hai phương án nâng cấp khả thi: (a) Tối ưu hóa ngưỡng phân loại (threshold tuning) và class-weighted loss để cân bằng Sensitivity – Specificity; (b) Thử nghiệm các kiến trúc phân lớp chuyên biệt cho ảnh X-quang y tế với augmentation đa dạng hơn. Cải thiện đồng thời cả hai chiều FP và FN sẽ trực tiếp nâng Pipeline Dice.
- **Hướng 2: Tích hợp phân lớp vào phân đoạn (Unified Model):** Thay vì hai module riêng biệt, một hướng tiếp cận đầy tiềm năng là **loại bỏ hoàn toàn module phân lớp độc lập** bằng cách thêm thành phần hàm mất mát xử lý ảnh không bệnh trực tiếp trong quá trình huấn luyện PGA-UNet:

$$\mathcal{L}_{\text{unified}} = \mathcal{L}_{\text{seg}} + \lambda \cdot \mathcal{L}_{\text{empty}} \quad (5.1)$$

trong đó $\mathcal{L}_{\text{empty}}$ là hàm phạt khi model dự đoán mặt nạ có diện tích dương trên ảnh không bệnh (GT mask rỗng). Khi đó, PGA-UNet học đồng thời hai nhiệm vụ: phân đoạn tổn thương khi có bệnh và xuất mask rỗng khi không bệnh, loại bỏ hoàn toàn sai số tích lũy. Phương án này đơn giản hóa kiến trúc tổng thể nhưng đòi hỏi tái huấn luyện và đủ dữ liệu ảnh không bệnh trong tập train.

- **Hướng 3: Mở rộng phương thức câu nhắc (Multi-prompting):** Nâng cấp PGA-UNet để tiếp nhận đồng thời nhiều loại câu nhắc: điểm bấm (Point Clicks), phác thảo đa giác, hoặc kết hợp văn bản lâm sàng (Text Prompt). Điều này cho phép bác sĩ truyền đạt tri thức lâm sàng chi tiết hơn, đặc biệt cho các tổn thương có hình dạng bất thường.

- **Hướng 4: Kiểm định đa tập và thử nghiệm thực tế:** Thử nghiệm trên dữ liệu X-quang từ các cơ sở y tế khác nhau (thiết bị khác, giao thức khác) để xác minh tính tổng quát hóa. Song song, thử nghiệm ứng dụng tại cơ sở y tế thực tế để thu thập phản hồi bác sĩ và cải tiến giao diện.
- **Hướng 5: Tối ưu hóa hiệu năng vận hành:** Đo lường và tối ưu thời gian phản hồi toàn bộ pipeline (phân lớp, phân đoạn) trên các cấu hình phần cứng thực tế tại cơ sở y tế, nhằm đảm bảo trải nghiệm tương tác liền mạch trong điều kiện triển khai thực.

TÀI LIỆU THAM KHẢO

- [1] Cambridge University Hospitals NHS Foundation Trust. *X-ray – Imaging & Radiology*. <https://www.cuh.nhs.uk/our-services/imaging-radiology/x-ray/>. Truy cập năm 2025. 2024.
- [2] Cheng, Junlong et al. “SAM-Med2D”. In: *arXiv preprint arXiv:2308.16184* (2023). URL: <https://arxiv.org/abs/2308.16184>.
- [3] Dwyer, Brad, Nelson, Joseph, and Solawetz, Jacob. *Roboflow: Give Your Software the Power to See*. <https://roboflow.com>. 2023.
- [4] Jocher, Glenn, Chaurasia, Ayush, and Qiu, Jing. *Ultralytics YOLO11*. <https://docs.ultralytics.com/models/yolo11>. Phiên bản 11. 2024.
- [5] Oktay, Ozan et al. “Attention U-Net: Learning Where to Look for the Pancreas”. In: *Medical Imaging with Deep Learning (MIDL)*. 2018. URL: <https://arxiv.org/abs/1804.03999>.
- [6] Ronneberger, Olaf, Fischer, Philipp, and Brox, Thomas. “U-Net: Convolutional Networks for Biomedical Image Segmentation”. In: *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*. Springer, 2015, pp. 234–241. DOI: 10.1007/978-3-319-24574-4_28.
- [7] Tan, Mingxing and Le, Quoc V. “EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks”. In: *International Conference on Machine Learning (ICML)*. 2019, pp. 6105–6114. URL: <https://arxiv.org/abs/1905.11946>.
- [8] Yao, Shunhan et al. “A Radiograph Dataset for the Classification, Localization, and Segmentation of Primary Bone Tumors”. In: *Scientific Data* 12 (2025), p. 88. DOI: 10.1038/s41597-024-04311-y.